TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ – 52300220
SỬ THỊ YẾN LINH – 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ – 52300220
SỬ THỊ YẾN LINH – 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chỉn chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khoẻ, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của riêng chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026
Tác giả
(Ký tên và ghi rõ họ tên)

Lê Minh Lý **Sử Thị Yến Linh**

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Hệ thống khuyến nghị giúp cửa hàng trực tuyến chọn ra cho mỗi khách những sản phẩm phù hợp trong một danh mục rất lớn. Với dữ liệu thời trang, bài toán này khó vì mỗi khách chỉ mua một phần rất nhỏ của danh mục, làm cho ma trận tương tác giữa khách hàng và sản phẩm rất thưa. Nhân tử hoá ma trận (MF) là phương pháp phổ biến, nhưng chỉ học từ mã khách hàng, mã sản phẩm và chỉ kết hợp chúng bằng một tích vô hướng tuyến tính. Đề tài xây dựng mô hình lai NeuMF-F dựa trên kiến trúc Neural Matrix Factorization (NeuMF), gồm nhánh nhân tử hoá ma trận tổng quát (GMF) và nhánh perceptron nhiều lớp (MLP). Trong NeuMF-F, mỗi khách hàng và sản phẩm được biểu diễn bằng vector nhúng mã định danh cộng với phần chiếu của đặc trưng. Các đặc trưng gồm thuộc tính và mô tả của sản phẩm, thông tin khách hàng, doanh số gần đây của sản phẩm và lịch sử mua gần đây của khách.

Nhóm đánh giá mô hình trên dữ liệu giao dịch thời trang của H&M. Dữ liệu được chia theo thời gian, và đặc trưng chỉ dùng thông tin có trước thời điểm dự đoán. Cấu hình của các mô hình được chọn trên một mẫu khách hàng, còn kết quả cuối được đo trên một mẫu khách hàng khác theo kế hoạch đã đăng ký trước, có kiểm định thống kê. NeuMF-F được so sánh với các mô hình đối chứng thuộc ba nhóm, và mọi mô hình được tinh chỉnh với cùng ngân sách. Kết quả sau đó được kiểm chứng lại trên bộ dữ liệu Amazon Beauty.

Kết quả cho thấy bổ sung đặc trưng giúp mô hình khuyến nghị tốt hơn rõ rệt so với khi chỉ dùng mã định danh. Các mô hình có đặc trưng dẫn đầu trên cả H&M và Amazon Beauty. NeuMF-F tốt hơn có ý nghĩa thống kê so với NeuMF chỉ dùng mã định danh, các mô hình học máy truyền thống và mô hình phổ biến theo thời gian, nhưng NeuMF-F tương đương nhánh GMF-F đứng riêng. Mô hình hợp nhất muộn LateFusion-F, trộn điểm của hai nhánh được huấn luyện riêng, đạt kết quả trung bình cao nhất trên cả hai bộ dữ liệu. Chênh lệch giữa LateFusion-F và NeuMF-F không có ý nghĩa thống kê trên H&M nhưng có ý nghĩa trên Amazon Beauty. Vì LateFusion-F dùng chính hai nhánh có đặc trưng của NeuMF-F, kết quả này cũng xác nhận giá trị của biểu diễn có đặc trưng mà đề tài đề xuất. Đề tài cũng xây dựng một hệ thống demo minh hoạ khuyến nghị cho từng khách hàng.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Recommender systems help online shops select suitable products for each customer from a very large catalogue. With fashion data this task is hard, because each customer buys only a tiny part of the catalogue, which makes the customer-item interaction matrix very sparse. Matrix factorization (MF) is a common method, but it learns only from customer and item identifiers and combines them with a linear inner product. This project builds the hybrid model NeuMF-F on the Neural Matrix Factorization (NeuMF) architecture, which has a generalized matrix factorization (GMF) branch and a multi-layer perceptron (MLP) branch. In NeuMF-F, every customer and item is represented by an identifier embedding plus a projection of features. The features are item attributes and descriptions, customer information, recent item sales and the customer's recent purchase history.

We evaluate the model on fashion transaction data from H&M. The data are split by time, and features use only information available before the prediction time. Model configurations are selected on one customer sample, while the final results are measured on a different customer sample under a pre-registered plan, with statistical testing. NeuMF-F is compared with baselines from three groups, and every model is tuned with the same budget. The results are then checked again on the Amazon Beauty dataset.

The results show that adding features clearly improves recommendation quality compared with using identifiers only. The feature-augmented models lead on both H&M and Amazon Beauty. NeuMF-F is significantly better than the identifier-only NeuMF, the traditional machine learning models and the time-aware popularity model, but it is on par with the stand-alone GMF-F branch. The late-fusion model LateFusion-F, which mixes the scores of two separately trained branches, achieves the highest average results on both datasets. Its difference from NeuMF-F is not statistically significant on H&M but is significant on Amazon Beauty. Because LateFusion-F reuses the two feature-augmented branches built for NeuMF-F, this result also confirms the value of the proposed feature-based representation. A demo system illustrates the recommendations for each customer.

MỤC LỤC

DANH MỤC HÌNH VẼ ..... **x**

DANH MỤC BẢNG BIỂU ..... **xi**

DANH MỤC CÁC CHỮ VIẾT TẮT ..... **xii**

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI **1**

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài 1

1.1.1 Bài toán khuyến nghị trên dữ liệu thời trang H&M 1

1.1.2 Hạn chế của nhân tử hoá ma trận 1

1.1.3 Mô hình đề xuất và câu hỏi nghiên cứu 2

1.2 Mục tiêu và phạm vi nghiên cứu 3

1.2.1 Mục tiêu nghiên cứu 3

1.2.2 Phạm vi nghiên cứu 3

1.3 Phương pháp nghiên cứu 4

1.4 Ý nghĩa khoa học và thực tiễn của đề tài 5

1.4.1 Ý nghĩa khoa học 5

1.4.2 Ý nghĩa thực tiễn 5

1.5 Bố cục của báo cáo 6

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN **7**

2.1 Tổng quan về hệ thống khuyến nghị 7

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai 7

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình 8

2.1.3 Phản hồi ẩn 9

2.1.4 Độ thưa dữ liệu và vấn đề cold start 10

2.2 Lọc cộng tác và nhân tử hoá ma trận 10

2.2.1 Mô hình nhân tử hoá ma trận 10

2.2.2 Hạn chế của tích vô hướng 11

2.2.3 Tối ưu thứ hạng theo cặp: BPR 11
2.3 Kiến trúc lọc cộng tác bằng mạng lưới thần kinh (NCF) 11
2.3.1 Generalized Matrix Factorization (GMF) 11
2.3.2 Multi-Layer Perceptron (MLP) 12
2.3.3 Mô hình lai NeuMF 12
2.3.4 Hợp nhất sớm và hợp nhất muộn 13
2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân 15
2.4 Mô hình lai dựa trên đặc trưng 15
2.4.1 Bổ sung đặc trưng vào mô hình lai 15
2.4.2 Lý do chọn kiến trúc hai nhánh 16
2.5 Các độ đo đánh giá Top-K 16
2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu 17
2.5.2 Độ đo ngoài độ chính xác 18
2.6 Ba nghiên cứu nền tảng 18
2.7 Khoảng trống nghiên cứu 20
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F 22
3.1 Quy trình tổng thể huấn luyện và đánh giá mô hình 22
3.2 Dữ liệu và tiền xử lý 23
3.2.1 Đặc tả bộ dữ liệu H&M 23
3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định 24
3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử 25
3.2.4 Giai đoạn đánh giá và tập ứng viên 27
3.2.5 Xây dựng đặc trưng theo thời điểm 29
3.3 Thiết kế mô hình lai NeuMF-F 31
3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng 32
3.3.2 Nhánh GMF-F 33
3.3.3 Nhánh MLP-F 33

3.3.4 Lớp hợp nhất và lớp dự đoán 34
3.4 Mô hình đối chứng 34
3.4.1 Các mô hình cài đặt trên cùng khung với NeuMF-F 35
3.4.2 Các mô hình đối chứng còn lại 36
3.5 Lấy mẫu âm theo thời điểm và hàm mục tiêu 37
3.5.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm 37
3.5.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn 38
3.6 Quy trình huấn luyện và tinh chỉnh 38
3.6.1 Không gian tinh chỉnh và dừng sớm 38
3.7 Quy trình đánh giá không thiên lệch 40
3.8 Suy luận Top-K và xử lý khách hàng mới 45
3.9 Thiết kế hệ thống demo 46
3.9.1 Kiến trúc ba tầng 46
3.9.2 Thiết kế API suy luận 47
3.9.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng 48
3.9.4 Minh hoạ hệ thống demo 48
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 51
4.1 Thiết lập thực nghiệm 51
4.2 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển 53
4.3 Kết quả đánh giá cuối trên mẫu kiểm định 55
4.3.1 So sánh các độ đo xếp hạng 55
4.3.2 Kết quả theo $K = 10, 15, 20$ 57
4.3.3 Kiểm định ý nghĩa thống kê 59
4.3.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống 61
4.3.5 Phân tích bóc tách thành phần 62
4.3.6 Độ phủ và chi phí huấn luyện 63
4.3.7 Độ ổn định giữa hai mẫu 64
4.4 Kiểm chứng trên dữ liệu Amazon Beauty 65

4.4.1 Dữ liệu và thiết lập kiểm chứng 65
4.4.2 Kết quả trên tập kiểm thử Amazon Beauty 67
4.4.3 Đối chiếu kết luận giữa H&M và Amazon Beauty 71
4.4.4 Phân tích bóc tách và độ phủ trên Amazon Beauty 73
4.5 Nguồn gốc của phần cải thiện 74
4.6 Phạm vi của kết luận 75
4.7 Thảo luận và trả lời câu hỏi nghiên cứu 75
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 78
5.1 Kết quả đạt được 78
5.2 Kết luận 78
5.3 Hạn chế của đề tài 80
5.4 Hướng phát triển 80
TÀI LIỆU THAM KHẢO 81

DANH MỤC HÌNH VẼ

Hình 1.1: Các bước thực hiện đề tài 5

Hình 2.1: Kiến trúc NeuMF 13
Hình 2.2: Hợp nhất sớm và hợp nhất muộn 15

Hình 3.1: Đường ống huấn luyện và đánh giá mô hình 23
Hình 3.2: Quy trình xử lý dữ liệu H&M..... 25
Hình 3.3: Chia dữ liệu theo thời gian 28
Hình 3.4: Kiến trúc mô hình đề xuất NeuMF-F 32
Hình 3.5: Quy trình tinh chỉnh và đánh giá cuối 42
Hình 3.6: Kiến trúc ba tầng của hệ thống demo 47
Hình 3.7: Giao diện demo: cửa hàng mô phỏng, đã hiện các món khách mua sau mốc 49
Hình 3.8: Giao diện demo: màn hình kết quả đánh giá 50

Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử H&M..... 57
Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh trên H&M..... 61
Hình 4.3: Phân tích bóc tách NeuMF-F trên H&M..... 63
Hình 4.4: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối 65

DANH MỤC BẢNG BIỂU

Bảng 2.1: Ba nghiên cứu nền tảng và thiết lập của đề tài 19

Bảng 3.1: Lọc k-core trên toàn bộ dữ liệu H&M 24
Bảng 3.2: Lọc k-core trên mẫu phát triển 27
Bảng 3.3: Quy mô dữ liệu H&M 29
Bảng 3.4: Đặc trưng đầu vào trên H&M 30
Bảng 3.5: Ba nhóm mô hình đối chứng 35
Bảng 3.6: Không gian tinh chỉnh 39
Bảng 3.7: Các điểm cuối của API suy luận 48

Bảng 4.1: Điều kiện thực nghiệm chung của các mô hình 52
Bảng 4.2: Cấu hình tốt nhất trên tập xác thực 54
Bảng 4.3: Các cách kết hợp của Hybrid-CBCF 55
Bảng 4.4: Kết quả trên tập kiểm thử H&M 56
Bảng 4.5: NDCG@K và Recall@K trên H&M 58
Bảng 4.6: HR@K và Precision@K trên H&M 59
Bảng 4.7: Kiểm định họ 10 so sánh trên H&M 60
Bảng 4.8: Kiểm định bổ sung với Hybrid-CBCF trên H&M 61
Bảng 4.9: Phân tích bóc tách NeuMF-F trên H&M 62
Bảng 4.10: Độ phủ top-10 và chi phí huấn luyện trên H&M 64
Bảng 4.11: Đặc trưng trên H&M và Amazon Beauty 66
Bảng 4.12: Quy mô dữ liệu Amazon Beauty 67
Bảng 4.13: Kết quả trên tập kiểm thử Amazon Beauty 68
Bảng 4.14: NDCG@K và Recall@K trên Amazon Beauty 69
Bảng 4.15: HR@K và Precision@K trên Amazon Beauty 70
Bảng 4.16: Kiểm định bổ sung với Hybrid-CBCF trên Amazon Beauty 70
Bảng 4.17: Kiểm định họ 10 so sánh trên Amazon Beauty 72
Bảng 4.18: Kết luận họ 10 so sánh trên H&M và Amazon Beauty 73
Bảng 4.19: Phân tích bóc tách NeuMF-F trên Amazon Beauty 74
Bảng 4.20: Các yếu tố có thể tác động đến kết quả và cách loại trừ 74

Bảng 5.1: Mức độ hoàn thành mục tiêu 78

DANH MỤC CÁC CHỮ VIẾT TẮT

API	Application Programming Interface (Giao diện lập trình ứng dụng)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hoá Bayes)
CBCF	Content-Based and Collaborative Filtering (Kết hợp lọc nội dung và lọc cộng tác; Hybrid-CBCF: mô hình lai truyền thống)
CF	Collaborative Filtering (Lọc cộng tác)
CI	Confidence Interval (Khoảng tin cậy)
CPU	Central Processing Unit (Bộ xử lý trung tâm)
DCG	Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu)
DNN	Deep Neural Network (Mạng lưới thần kinh sâu)
FM	Factorization Machines (Máy nhân tử hoá)
GMF	Generalized Matrix Factorization (Nhân tử hoá ma trận tổng quát)
HR	Hit Ratio (Tỉ lệ trúng)
IDCG	Ideal Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu lý tưởng)
ItemKNN	Item-based k-Nearest Neighbors (Lọc cộng tác theo k sản phẩm láng giềng gần nhất)
MAE	Mean Absolute Error (Sai số tuyệt đối trung bình)
MF	Matrix Factorization (Nhân tử hoá ma trận)
MLP	Multi-Layer Perceptron (Perceptron nhiều lớp)

NCF	Neural Collaborative Filtering (Lọc cộng tác bằng mạng lưới thần kinh)
NDCG	Normalized Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu chuẩn hoá)
NeuMF	Neural Matrix Factorization (Nhân tử hoá ma trận bằng mạng lưới thần kinh)
NeuMF-F	NeuMF bổ sung đặc trưng (mô hình đề xuất; GMF-F, MLP-F: hai nhánh có đặc trưng)
ReLU	Rectified Linear Unit (Đơn vị tuyến tính chỉnh lưu)
RMSE	Root Mean Square Error (Căn bậc hai sai số bình phương trung bình)
SVD	Singular Value Decomposition (Phân tích giá trị suy biến)
TF-IDF	Term Frequency–Inverse Document Frequency (Tần suất từ nhân nghịch đảo tần suất văn bản)
UserKNN	User-based k-Nearest Neighbors (Lọc cộng tác theo k người dùng láng giềng gần nhất)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Bài toán khuyến nghị trên dữ liệu thời trang H&M

Trong bán lẻ trực tuyến, hệ thống khuyến nghị (*recommender system*, còn gọi là hệ thống gợi ý) chọn ra cho mỗi khách một danh sách K sản phẩm phù hợp nhất giữa hàng chục nghìn mặt hàng, gọi là khuyến nghị Top-K. Đề tài dùng bộ dữ liệu H&M Personalized Fashion Recommendations do tập đoàn thời trang H&M công bố. Tệp giao dịch có khoảng 31,8 triệu lượt mua của 1,36 triệu khách hàng trên 104.547 sản phẩm, trong hai năm từ 09/2018 đến 09/2020.

Dữ liệu này có hai đặc điểm gây khó cho hệ thống khuyến nghị:

- Ma trận tương tác giữa khách hàng và sản phẩm rất thưa. Mỗi khách chỉ mua vài chục trong số hàng chục nghìn sản phẩm, nên mật độ của ma trận chỉ khoảng 0,03–0,05%.
- Nhu cầu thời trang thay đổi nhanh theo mùa và theo xu hướng. Sản phẩm bán chạy trong vài tuần gần đây chưa chắc là sản phẩm bán nhiều nhất trong hai năm.

Ngoài lịch sử mua, bộ dữ liệu còn có thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng và ngày mua. Các thông tin này có thể bù cho phần dữ liệu tương tác bị thiếu.

1.1.2 Hạn chế của nhân tử hoá ma trận

Phương pháp cơ bản của lọc cộng tác (*collaborative filtering*, CF) là nhân tử hoá ma trận (*matrix factorization*, MF). MF gán cho mỗi khách hàng u và mỗi sản phẩm i một vector ẩn $p_u, q_i \in \mathbb{R}^d$, rồi dự đoán mức độ quan tâm bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{1.1}$$

Trên dữ liệu H&M, MF có hai hạn chế:

- Về cách kết hợp hai vector: tích vô hướng cộng các chiều ẩn với trọng số như nhau, nên MF chỉ biểu diễn được tương tác tuyến tính giữa khách hàng và sản phẩm.

– Về nguồn thông tin: vector q_i chỉ được học từ các lần sản phẩm i được mua. Sản phẩm ít người mua vì vậy có vector kém tin cậy, và tăng số chiều hay huấn luyện lâu hơn không khắc phục được điều này.

1.1.3 Mô hình đề xuất và câu hỏi nghiên cứu

Mô hình Neural Matrix Factorization (NeuMF) khắc phục hạn chế thứ nhất bằng cách kết hợp MF với mạng lưới thần kinh sâu (*deep neural network*, DNN), còn gọi là mạng nơ-ron sâu. NeuMF có hai nhánh chạy song song và được ghép ở lớp dự đoán:

– Nhánh GMF (*generalized matrix factorization*) là dạng tổng quát của MF, học tương tác tuyến tính.
– Nhánh MLP (*multi-layer perceptron*) là một mạng nhiều lớp, học tương tác phi tuyến.

Tuy vậy, NeuMF vẫn chỉ học từ mã khách hàng và mã sản phẩm, nên chưa giải quyết được hạn chế thứ hai. Các nghiên cứu đánh giá lại NCF cũng cho thấy NeuMF chỉ dùng mã định danh (ID) khó vượt MF đã được tinh chỉnh kỹ.

Từ đó nhóm xây dựng mô hình đề xuất NeuMF-F. Mô hình giữ hai nhánh GMF và MLP của NeuMF để khắc phục hạn chế thứ nhất. Để khắc phục hạn chế thứ hai, mỗi khách hàng và sản phẩm được biểu diễn bằng vector nhúng (*embedding*) của mã ID cộng với một phép chiếu của đặc trưng. Chữ "F" (*features*) trong tên mô hình chỉ phần đặc trưng này, gồm:

– Thuộc tính và mô tả văn bản của sản phẩm.
– Thông tin khách hàng.
– Doanh số gần đây của sản phẩm.
– Thời gian từ lần mua gần nhất và số sản phẩm khách đã mua.

Mô hình lai giữa MF và DNN có thể được ghép theo hai cách:

– Hợp nhất sớm (*early fusion*): ghép hai nhánh trong một mạng và huấn luyện chung, như NeuMF-F.
– Hợp nhất muộn (*late fusion*): huấn luyện hai mô hình riêng rồi trộn điểm của chúng.

Đúng với tên đề tài, nhóm chọn hợp nhất sớm cho mô hình đề xuất, để MF và DNN được kết hợp trong một mô hình duy nhất và học chung. Hợp nhất muộn của cùng hai nhánh có đặc trưng được đưa vào làm mô hình đối chứng LateFusion-F, để

đo ảnh hưởng của lựa chọn này.

Từ các vấn đề trên, đề tài đặt ra ba câu hỏi nghiên cứu.

Câu hỏi 1: NeuMF-F có khuyến nghị tốt hơn các mô hình đối chứng (*baseline*) được tinh chỉnh đầy đủ không?

Câu hỏi 2: Bổ sung đặc trưng có giúp mô hình lai khuyến nghị tốt hơn không, và nhóm đặc trưng nào đóng góp nhiều nhất? Câu hỏi này được trả lời bằng cách so NeuMF-F với NeuMF chỉ dùng ID và bằng phân tích bóc tách (*ablation study*).

Câu hỏi 3: Ghép hai nhánh có tốt hơn từng nhánh đứng riêng không, và nên hợp nhất sớm hay hợp nhất muộn? Câu hỏi này được trả lời bằng cách so NeuMF-F với hai nhánh GMF-F, MLP-F đứng riêng và với LateFusion-F, mô hình hợp nhất muộn của cùng hai nhánh.

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Để trả lời ba câu hỏi trên, đề tài đặt ra năm mục tiêu.

(1) Hệ thống hoá cơ sở lý thuyết về lọc cộng tác, nhân tử hoá ma trận, kiến trúc NeuMF, mô hình lai dựa trên đặc trưng, hợp nhất sớm và hợp nhất muộn.

(2) Xây dựng quy trình xử lý dữ liệu H&M: lấy mẫu theo khách hàng, dựng ma trận tương tác từ lịch sử mua, chia dữ liệu theo thời gian và tính đặc trưng chỉ từ thông tin trước thời điểm dự đoán.

(3) Cài đặt NeuMF-F và các mô hình đối chứng, tinh chỉnh siêu tham số (*hyperparameter tuning*) cho mọi mô hình với cùng ngân sách.

(4) Đánh giá các mô hình bằng các độ đo xếp hạng NDCG@K, Recall@K, HR@K và Precision@K, có kiểm định thống kê, rồi kiểm chứng trên bộ dữ liệu thứ hai là Amazon Beauty.

(5) Xây dựng hệ thống demo minh hoạ khuyến nghị của các mô hình cho từng khách hàng.

1.2.2 Phạm vi nghiên cứu

Đối tượng nghiên cứu là mô hình NeuMF, mô hình đề xuất NeuMF-F và hai cách hợp nhất nhân tử hoá ma trận với mạng lưới thần kinh sâu, trong bài toán khuyến

nghị Top-K.

Phạm vi dữ liệu và thực nghiệm như sau:

- Dữ liệu chính là bộ H&M, gồm tệp giao dịch, tệp sản phẩm và tệp khách hàng.
- Vì toàn bộ dữ liệu quá lớn so với tài nguyên tính toán hiện có, nhóm thực nghiệm trên hai mẫu khách hàng không có khách chung, mỗi mẫu khoảng 500.000 giao dịch của khoảng 21.000 khách chọn ngẫu nhiên.
  + Mẫu phát triển dùng để chọn cấu hình.
  + Mẫu kiểm định dùng để đánh giá cuối.
- Mỗi sản phẩm là một mẫu thiết kế, gộp mọi màu của cùng một mẫu. Tín hiệu tương tác là việc khách đã mua hay chưa mua sản phẩm, kèm ngày mua.
- Ảnh sản phẩm không được dùng làm đầu vào của mô hình.
- Kết quả được kiểm chứng lại trên bộ Amazon Beauty với cấu hình đã chọn trên H&M.

1.3 Phương pháp nghiên cứu

Đề tài được thực hiện qua bốn bước, được tóm tắt trong Hình 1.1:

- Nghiên cứu tài liệu về lọc cộng tác, nhân tử hoá ma trận, kiến trúc NeuMF và mô hình lai dựa trên đặc trưng.
- Xử lý dữ liệu: lấy mẫu theo khách hàng, lọc bỏ khách và sản phẩm có quá ít lượt mua (lọc k-core), chia dữ liệu theo thời gian và tính đặc trưng.
- Cài đặt và huấn luyện các mô hình bằng hàm mất mát entropy chéo nhị phân (*binary cross-entropy*, BCE) với lấy mẫu âm (*negative sampling*). Mọi mô hình được tinh chỉnh với cùng ngân sách trên tập xác thực (*validation set*) của mẫu phát triển.
- Đánh giá trên mẫu kiểm định theo kế hoạch được ghi lại trước khi có kết quả, gọi là đăng ký trước (*pre-registration*). Mỗi mô hình được huấn luyện lại với 5 giá trị khởi tạo ngẫu nhiên (*seed*) khác nhau. Kết luận dựa trên kiểm định dấu hạng Wilcoxon (*Wilcoxon signed-rank test*), khoảng tin cậy (*confidence interval*, CI) bootstrap và hiệu chỉnh Holm cho nhiều phép so sánh.



Hình 1.1: Các bước thực hiện đề tài

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

- Đề tài xây dựng một mô hình lai giữa MF và DNN có bổ sung đặc trưng, và đánh giá nó trên dữ liệu giao dịch thời trang thực tế với kiểm định thống kê.
- Các mô hình đối chứng được thiết kế để tách riêng phần cải thiện do đặc trưng và phần do cách ghép hai nhánh. Cách thiết kế này cho phép xác định nhóm thông tin nào có giá trị nhất cho khuyến nghị thời trang.
- Quy trình đánh giá của đề tài tính đặc trưng không dùng thông tin tương lai, tinh chỉnh mọi mô hình với cùng ngân sách và lấy kết luận trên một mẫu khách hàng riêng. Quy trình này dùng lại được cho các nghiên cứu hệ thống khuyến nghị khác.

1.4.2 Ý nghĩa thực tiễn

- Mô hình chỉ dùng dữ liệu doanh nghiệp bán lẻ đã có: lịch sử giao dịch, danh mục sản phẩm, thông tin hội viên và doanh số theo ngày.
- Phân tích từng nhóm đặc trưng giúp doanh nghiệp biết nên ưu tiên cập nhật loại dữ liệu nào.
- Quy trình xử lý dữ liệu áp dụng được cho bộ dữ liệu thương mại điện tử

khác, như đã làm với Amazon Beauty.

– Hệ thống demo cho phép so sánh trực quan các mô hình trên từng khách hàng.

1.5 Bố cục của báo cáo

Báo cáo gồm năm chương:

– Chương 1 trình bày bối cảnh, câu hỏi nghiên cứu, mục tiêu, phạm vi, phương pháp và ý nghĩa của đề tài.

– Chương 2 trình bày cơ sở lý thuyết về hệ thống khuyến nghị, nhân tử hoá ma trận, kiến trúc NeuMF, hợp nhất sớm và hợp nhất muộn, các độ đo đánh giá và các nghiên cứu liên quan.

– Chương 3 trình bày dữ liệu, mô hình NeuMF-F, các mô hình đối chứng, cách huấn luyện, quy trình đánh giá và hệ thống demo.

– Chương 4 trình bày kết quả thực nghiệm trên H&M và Amazon Beauty, rồi trả lời ba câu hỏi nghiên cứu.

– Chương 5 tổng kết kết quả, nêu hạn chế và hướng phát triển của đề tài.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Tổng quan về hệ thống khuyến nghị

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai

Hệ thống khuyến nghị có ba hướng tiếp cận chính, khác nhau ở loại thông tin được dùng.

- Lọc dựa trên nội dung (*content-based filtering*) dùng thông tin của sản phẩm. Khách vừa mua một chiếc áo len sẽ được khuyến nghị những mẫu có loại hàng, nhóm hàng hay mô tả gần với chiếc áo đó.
- Lọc cộng tác (CF) dùng hành vi mua của nhiều khách. Nếu nhiều người mua chung hai mẫu quần, khách mua mẫu thứ nhất có thể cũng quan tâm mẫu thứ hai. Cách này cần đủ lượt mua, nên hoạt động kém khi dữ liệu thưa.
- Lọc lai (*hybrid filtering*) dùng cả hai nguồn thông tin để bù cho nhau.

Trước khi có học sâu, hệ thống khuyến nghị lai được ghép từ các kỹ thuật truyền thống. Burke [6] phân loại bảy cách lai:

- Lai có trọng số (*weighted*): cộng có trọng số điểm của nhiều kỹ thuật.
- Lai chuyển đổi (*switching*): chọn một kỹ thuật tuỳ tình huống.
- Lai hỗn hợp (*mixed*): trình bày đồng thời khuyến nghị của nhiều kỹ thuật.
- Kết hợp đặc trưng (*feature combination*): dùng dữ liệu của kỹ thuật này làm đặc trưng cho kỹ thuật kia.
- Lai phân tầng (*cascade*): kỹ thuật sau tinh chỉnh kết quả của kỹ thuật trước.
- Tăng cường đặc trưng (*feature augmentation*): đầu ra của kỹ thuật này làm đầu vào cho kỹ thuật kia.
- Lai mức mô hình (*meta-level*): mô hình học được của kỹ thuật này làm đầu vào cho kỹ thuật kia.

Dựa trên phân loại này, luận án của Hồ Thị Linh [3] xây dựng một mô hình lai gồm ba thành phần, có điểm được tổng hợp qua một mạng truyền thẳng:

- Lọc nội dung.

– Lọc cộng tác theo người dùng (UserKNN).
– Lọc cộng tác theo sản phẩm (ItemKNN).

Đề tài dùng lại ý tưởng này làm mô hình đối chứng Hybrid-CBCF, với hàm mục tiêu học theo cặp cho phản hồi ẩn. So sánh NeuMF-F với Hybrid-CBCF cho biết hợp nhất bằng mạng lưới thần kinh có hơn việc ghép điểm của các kỹ thuật truyền thống hay không.

Đề tài chọn hướng lai vì ba đặc điểm của dữ liệu H&M:

– Lịch sử mua dài hai năm, đủ để lọc cộng tác học sở thích của khách mua thường xuyên.
– Danh mục thời trang thay đổi liên tục và nhiều sản phẩm có ít lượt mua, nên lọc cộng tác chỉ dùng mã ID khó khuyến nghị tốt các sản phẩm này.
– Bộ dữ liệu có sẵn mô tả văn bản, nhóm hàng và doanh số theo ngày.

Vì vậy, mô hình của đề tài lấy lọc cộng tác (nhân tử hoá ma trận kết hợp mạng lưới thần kinh sâu) làm lõi, rồi bổ sung đặc trưng nội dung và thời gian.

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình

Theo cách khai thác dữ liệu tương tác, lọc cộng tác chia thành hai nhánh.

Nhánh dựa trên bộ nhớ (*memory-based*) giữ nguyên ma trận tương tác và so trực tiếp các hàng hoặc các cột của nó. Hai khách được coi là giống nhau nếu đã mua nhiều sản phẩm chung, và hai sản phẩm giống nhau nếu có nhiều người cùng mua. Cách làm này không có tham số nào phải học. Với lọc cộng tác theo sản phẩm (ItemKNN) [7], độ tương đồng cosine giữa hai sản phẩm i và j được tính trên vector cột tương tác của chúng:

$$\text{sim}(i, j) = \cos(\vec{i}, \vec{j}) = \frac{\vec{i} \cdot \vec{j}}{\|\vec{i}\| \, \|\vec{j}\|} \tag{2.1}$$

Với phản hồi ẩn nhị phân, điểm của sản phẩm i đối với người dùng u là tổng độ tương đồng giữa i và các sản phẩm u đã mua, chỉ xét k láng giềng gần nhất (*nearest neighbors*) $\mathcal{N}_k(i)$ của i:

$$\hat{y}_{ui} = \sum_{j \in \mathcal{N}_k(i) \cap \mathcal{I}_u} \text{sim}(i, j) \tag{2.2}$$

Lọc cộng tác theo người dùng (UserKNN) làm đối xứng. Mô hình tìm k người dùng có lịch sử mua giống u nhất, ký hiệu $\mathcal{N}_k(u)$, rồi tính điểm mỗi sản phẩm bằng tổng độ

tương đồng của các láng giềng đã mua sản phẩm đó:

$$\hat{y}_{ui} = \sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v)\, y_{vi} \tag{2.3}$$

Với dữ liệu mua hàng, độ tương đồng cosine thường được tính trên vector mua nhị phân. Mẫu số được cộng thêm hệ số co (*shrinkage*) λ để giảm trọng số của các cặp có quá ít tương tác chung: $\text{sim}(a, b) = |\mathcal{I}_a \cap \mathcal{I}_b| / (\sqrt{|\mathcal{I}_a|\,|\mathcal{I}_b|} + \lambda)$, với $\mathcal{I}_a$ là tập sản phẩm a đã mua (hoặc tập người dùng đã mua sản phẩm a). Mỗi hàng của ma trận tương đồng chỉ giữ k láng giềng và được lưu dưới dạng ma trận thưa.

Nhánh dựa trên bộ nhớ có ưu điểm và nhược điểm sau:

- Ưu điểm: đơn giản, không cần huấn luyện và dễ giải thích, vì chỉ ra được người dùng hay sản phẩm nào dẫn tới một khuyến nghị.
- Nhược điểm: ma trận tương đồng đầy đủ tăng theo bình phương số đối tượng, và chất lượng giảm khi dữ liệu quá thưa.

Nhánh dựa trên mô hình (*model-based*) không giữ cả ma trận mà học một hàm có tham số, chẳng hạn nhân tử hoá ma trận hay mạng lưới thần kinh, để tóm tắt mỗi khách và mỗi sản phẩm bằng một vector ngắn. Vì mỗi đối tượng chỉ còn vài chục con số thay cho hàng nghìn ô của ma trận, mô hình vẫn chấm điểm được những cặp chưa từng xuất hiện, và chi phí huấn luyện chỉ tăng tuyến tính theo số tương tác. Nhân tử hoá ma trận và các mô hình dùng mạng lưới thần kinh như NeuMF đều thuộc nhánh này.

2.1.3 Phản hồi ẩn

Thông tin về sở thích của người dùng có hai dạng:

- Phản hồi tường minh (*explicit feedback*): người dùng tự nêu mức yêu thích, ví dụ chấm sao cho một bộ phim.
- Phản hồi ẩn (*implicit feedback*): suy ra từ hành vi như mua, xem hay bấm vào sản phẩm.

Tệp giao dịch H&M không có điểm đánh giá, chỉ có các giao dịch đã xảy ra. Vì vậy đề tài dùng phản hồi ẩn dạng nhị phân, lấy từ sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu người dùng } u \text{ đã mua sản phẩm } i \\ 0, & \text{ngược lại} \end{cases} \tag{2.4}$$

Nhãn $y_{ui} = 1$ chỉ xác nhận khách đã mua, không xác nhận khách hài lòng. Nhãn $y_{ui} = 0$

có thể nghĩa là khách chưa biết đến sản phẩm, không nhất thiết là không thích. Do đó các cặp chưa tương tác không thể coi là nhãn âm chắc chắn, và kỹ thuật lấy mẫu âm phải được thiết kế cẩn thận.

2.1.4 Độ thưa dữ liệu và vấn đề cold start

Lọc cộng tác có hai thách thức chính:

– Độ thưa dữ liệu. Mỗi khách chỉ mua một phần rất nhỏ trong hàng nghìn sản phẩm, nên gần như mọi ô của ma trận $M \times N$ đều trống. Lọc k-core (chỉ giữ khách và sản phẩm có ít nhất k lượt mua) làm giảm độ thưa, nhưng ma trận vẫn rất thưa.

– *Cold start*. Khách vừa đăng ký hoặc sản phẩm vừa lên kệ chưa có lượt mua nào, nên lọc cộng tác không có dữ liệu để học vector cho chúng. Những đối tượng chỉ có ít lượt mua gặp dạng nhẹ hơn của vấn đề này: vector mã ID của chúng kém tin cậy.

Đề tài bổ sung đặc trưng nội dung và ngữ cảnh vào mô hình lai chủ yếu để giảm ảnh hưởng của hai thách thức này.

2.2 Lọc cộng tác và nhân tử hoá ma trận

2.2.1 Mô hình nhân tử hoá ma trận

Ý tưởng của nhân tử hoá ma trận [8] là mô tả mỗi người dùng và mỗi sản phẩm bằng d con số, với $d \ll \min(M, N)$. Có thể hình dung mỗi chiều như một "khẩu vị" ẩn, chẳng hạn thiên về đồ thể thao hay đồ công sở, dù mô hình không đặt tên cho các chiều này. Người dùng u ứng với vector $p_u \in \mathbb{R}^d$, sản phẩm i ứng với $q_i \in \mathbb{R}^d$, và điểm dự đoán là tích vô hướng của hai vector:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{2.5}$$

Các biến thể của MF khác nhau ở cách học hai ma trận P và Q. Phân tích giá trị suy biến (*singular value decomposition*, SVD) cổ điển cần ma trận đầy đủ, vì vậy không áp dụng trực tiếp được cho ma trận tương tác thưa, nơi phần lớn ô chưa được quan sát. Các biến thể dùng trong hệ thống khuyến nghị thay vào đó tối ưu sai số trên các ô đã biết, kèm điều chuẩn (*regularization*). Với phản hồi ẩn, BPR tối ưu trực tiếp thứ hạng theo cặp, và đề tài dùng BPR-MF làm mô hình đối chứng MF chính.

2.2.2 Hạn chế của tích vô hướng

Tích vô hướng kết hợp các chiều ẩn theo dạng tuyến tính. Các tác giả của kiến trúc lọc cộng tác bằng mạng lưới thần kinh (*neural collaborative filtering*, NCF) cho rằng vì lý do đó phép toán này không học được tương tác phi tuyến giữa các chiều ẩn của người dùng và sản phẩm. Lập luận này là động cơ của kiến trúc NCF. Việc bổ sung thành phần phi tuyến có thực sự cải thiện chất lượng khuyến nghị hay không phụ thuộc vào dữ liệu, và được đề tài kiểm tra bằng thực nghiệm trên dữ liệu H&M.

2.2.3 Tối ưu thứ hạng theo cặp: BPR

MF, GMF và MLP được huấn luyện như một bài toán phân loại, trong đó mỗi cặp (u, i) được chấm riêng thành $\hat{y}_{ui}$ rồi so với nhãn 0 hoặc 1. Trong khi đó, hệ thống khuyến nghị chỉ cần xếp đúng thứ tự: món khách sẽ mua phải đứng trên món khách không mua. Bayesian Personalized Ranking (BPR) [9] huấn luyện thẳng theo yêu cầu này, với giả định người dùng thích một sản phẩm đã tương tác i hơn một sản phẩm chưa tương tác j. Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR là:

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j) \in \mathcal{D}_S} \ln \sigma \left(\hat{y}_{ui} - \hat{y}_{uj} \right) + \lambda_\Theta \|\Theta\|^2 \tag{2.6}$$

trong đó $\mathcal{D}_S$ là tập các bộ ba được lấy mẫu. Khi $\hat{y}_{ui}$ được tính theo Công thức (2.5), ta có mô hình BPR-MF, một mô hình đối chứng của đề tài. Mục tiêu theo cặp của BPR sát với bài toán xếp hạng Top-K hơn hàm mất mát theo từng điểm, nhưng BPR-MF vẫn là mô hình tuyến tính.

2.3 Kiến trúc lọc cộng tác bằng mạng lưới thần kinh (NCF)

Kiến trúc NCF do He và cộng sự [4] đề xuất gồm hai mô hình thành phần, GMF và MLP, và mô hình hợp nhất của chúng, NeuMF.

2.3.1 Generalized Matrix Factorization (GMF)

GMF viết lại MF dưới dạng một mạng lưới thần kinh. Thay vì cộng ngay các tích $p_{uf} q_{if}$ như Công thức (2.5), GMF giữ chúng thành một vector bằng phép nhân từng phần tử (tích Hadamard, ký hiệu $\odot$) giữa vector nhúng của người dùng p_u^G và của sản phẩm q_i^G:

$$\phi^{GMF} = p_u^G \odot q_i^G \tag{2.7}$$

$$\hat{y}_{ui}^{GMF} = \sigma\left(h^T \phi^{GMF}\right) = \sigma\left(h^T (p_u^G \odot q_i^G)\right) \tag{2.8}$$

trong đó h là vector trọng số của lớp đầu ra và $\sigma(x) = 1/(1+e^{-x})$ là hàm sigmoid. Nếu mọi phần tử của h bằng 1 và bỏ hàm sigmoid, GMF trở về đúng MF. Khi h được học, mỗi chiều ẩn có trọng số riêng.

2.3.2 Multi-Layer Perceptron (MLP)

Nhánh MLP nối vector nhúng p_u^M và q_i^M thành đầu vào của một chuỗi lớp ẩn:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \tag{2.9}$$

$$\phi_L^{MLP} = a_L\left(W_L^T \phi_{L-1}^{MLP} + b_L\right) \tag{2.10}$$

trong đó W_L, b_L và a_L lần lượt là ma trận trọng số, vector độ lệch (*bias*) và hàm kích hoạt phi tuyến (ví dụ ReLU) của lớp thứ L. Cấu trúc này cho phép mô hình học tương tác phi tuyến giữa biểu diễn của người dùng và của sản phẩm.

2.3.3 Mô hình lai NeuMF

NeuMF ghép song song nhánh tuyến tính GMF và nhánh phi tuyến MLP trước lớp dự đoán:

$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \tag{2.11}$$

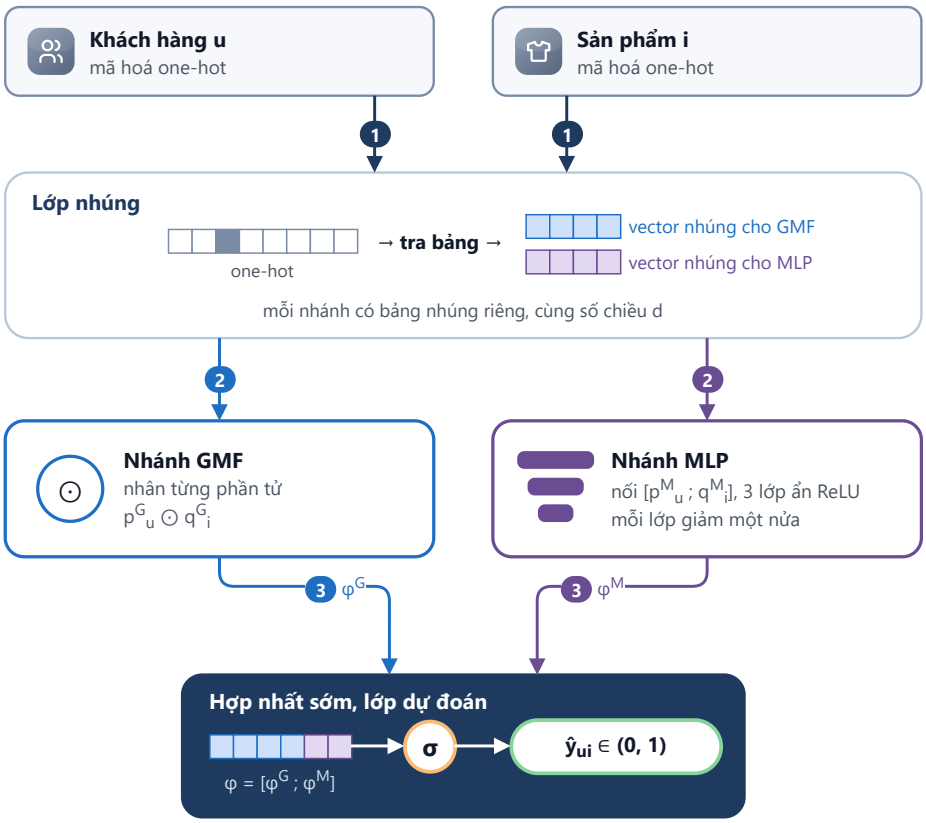
$$\hat{y}_{ui} = \sigma\left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix}\right) \tag{2.12}$$

Chữ "lai" trong tên đề tài trước hết chỉ việc kết hợp hai cách mô hình hoá tương tác, nhân tử hoá ma trận (tuyến tính) và mạng lưới thần kinh sâu (phi tuyến), trong cùng một mô hình. Vì hai nhánh được ghép ngay ở mức biểu diễn, trước lớp dự đoán, NeuMF là một mô hình hợp nhất sớm. Mô hình đề xuất NeuMF-F giữ cấu trúc này và bổ sung đặc trưng sản phẩm, khách hàng và thời gian vào vector của cả hai nhánh. Vì kết hợp lọc cộng tác với thông tin nội dung, NeuMF-F cũng là một hệ thống khuyến nghị lai theo nghĩa rộng.

Hình 2.1 vẽ kiến trúc NeuMF theo cách trình bày của bài báo gốc:

- Người dùng và sản phẩm được mã hoá one-hot.
- Mỗi nhánh có bộ vector nhúng riêng: màu xanh cho GMF, màu tím cho MLP.

– Hai nhánh gặp nhau ở lớp hợp nhất trước khi qua hàm sigmoid.
– Hai nhánh dùng cùng d, và chuỗi lớp ẩn của MLP, thường gọi là tháp (*tower*), giảm một nửa số chiều qua mỗi lớp như cấu hình gốc của NCF.



Hình 2.1: Kiến trúc NeuMF

2.3.4 Hợp nhất sớm và hợp nhất muộn

Khi hệ thống khuyến nghị kết hợp nhiều nguồn thông tin, hay nhiều góc nhìn về người dùng và sản phẩm, có hai cách hợp nhất cơ bản. Hai cách này khác nhau ở mức diễn ra phép hợp nhất [3].

– Hợp nhất sớm diễn ra ở mức đặc trưng hoặc biểu diễn. Các vector $v_1, \ldots, v_m$ của từng góc nhìn được nối thành một biểu diễn chung, rồi một mô hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h\big([v_1;\, v_2;\, \ldots;\, v_m]\big) \tag{2.13}$$

– Hợp nhất muộn diễn ra ở mức điểm dự đoán. Mỗi góc nhìn được xử lý bởi một mô hình riêng h_j, rồi các dự đoán được kết hợp bằng một cơ chế F,

như lấy trung bình, bỏ phiếu, trọng số cố định hoặc một mô hình học:

$$p = F\big(h_1(v_1),\, h_2(v_2),\, \ldots,\, h_m(v_m)\big) \tag{2.14}$$

Khi F là tổng có trọng số, đây chính là cách lai có trọng số trong phân loại của Burke. Mô hình lai ở chương 3 luận án thuộc loại này, và mô hình đối chứng Hybrid-CBCF của đề tài cũng vậy. Ở hai mô hình này, F là bỏ phiếu hoặc tổng có trọng số của điểm từ ba mô hình truyền thống.

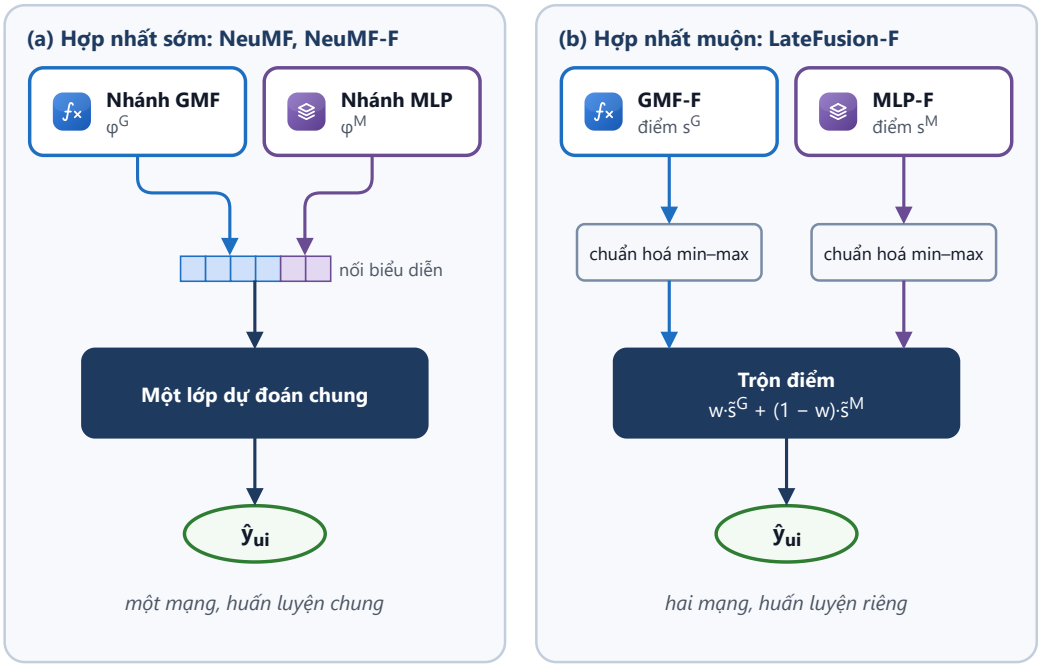
Ưu điểm của hợp nhất sớm là học được tương tác giữa các nguồn thông tin, nhưng nó đòi hỏi một mô hình phù hợp với mọi nguồn. Hợp nhất muộn linh hoạt hơn, song chỉ làm việc trên kết quả dự đoán nên không nắm được tương tác đó.

Trong đề tài, hai góc nhìn chính là hai cách mô hình hoá tương tác: góc nhìn tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và góc nhìn phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi đưa qua một lớp dự đoán chung (Công thức (2.11), (2.12)). Đây là hợp nhất sớm ở mức biểu diễn, và cả mạng được huấn luyện chung từ đầu đến cuối, như phần (a) của Hình 2.2. Mô hình đề xuất của đề tài giữ cách hợp nhất này. Ngoài ra, đặc trưng nội dung và ngữ cảnh được cộng vào vector của từng nhánh ngay ở đầu vào, do đó cũng được hợp nhất sớm với thông tin cộng tác.

Hợp nhất muộn tương ứng là trộn điểm của hai mô hình MF và DNN được huấn luyện riêng:

$$\hat{y}_{ui} = w\,\tilde{s}_{ui}^{MF} + (1-w)\,\tilde{s}_{ui}^{DNN}, \qquad \tilde{s}_{ui} = \frac{s_{ui} - \min_{j\in\mathcal{C}_u} s_{uj}}{\max_{j\in\mathcal{C}_u} s_{uj} - \min_{j\in\mathcal{C}_u} s_{uj}} \tag{2.15}$$

trong đó điểm s_{ui} của mỗi mô hình được chuẩn hoá min–max trên tập ứng viên $\mathcal{C}_u$ để hai thang điểm so sánh được. Tập ứng viên là các sản phẩm được đem ra xếp hạng cho người dùng u. Trọng số $w \in [0,1]$ được chọn trên tập xác thực. Với $w = 1$ hoặc $w = 0$, thứ hạng trùng với thứ hạng của từng thành phần. Trong đề tài, mô hình hợp nhất muộn LateFusion-F trộn điểm của hai nhánh có đặc trưng được huấn luyện riêng, như phần (b) của Hình 2.2. Riêng nhánh MLP khi đứng một mình chỉ nối vector người dùng và sản phẩm ở đầu vào. Đó là một mô hình DNN thuần, chưa có phần MF.



Hình 2.2: Hợp nhất sớm và hợp nhất muộn

2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân

Dữ liệu mua hàng chỉ cho biết khách đã mua gì, vì vậy chỉ có nhãn dương ($y_{ui} = 1$). Để mô hình học được cả chiều ngược lại, NCF lấy mẫu âm: với mỗi lượt mua, chọn ngẫu nhiên vài sản phẩm khách chưa mua và tạm coi là nhãn âm ($y_{ui} = 0$). Mô hình sau đó được huấn luyện như một bộ phân loại nhị phân, với hàm mất mát entropy chéo nhị phân (BCE):

$$\mathcal{L}_{BCE} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui}\log\hat{y}_{ui} + (1-y_{ui})\log(1-\hat{y}_{ui})] \tag{2.16}$$

trong đó $\mathcal{Y}$ là tập tương tác dương và $\mathcal{Y}^-$ là tập cặp âm được lấy mẫu.

2.4 Mô hình lai dựa trên đặc trưng

2.4.1 Bổ sung đặc trưng vào mô hình lai

Một cách khắc phục hạn chế về thông tin của MF là cho mô hình học từ cả đặc trưng, không chỉ từ mã ID. Các mô hình tiêu biểu theo hướng này gồm:

– Factorization Machines (FM) [10]: mỗi đặc trưng có một vector ẩn, và mức độ hai đặc trưng hợp nhau được đo bằng tích vô hướng của hai vector đó. Khi chỉ có mã khách hàng và mã sản phẩm, FM trở về MF.

– Wide & Deep [11] và DeepFM [12]: ghép một thành phần tuyến tính với một mạng MLP trên đầu vào có đặc trưng. Cấu trúc này gần giống NeuMF, chỉ khác ở đầu vào.

NeuMF-F đi theo hướng này. Mô hình giữ hai nhánh GMF và MLP, nhưng biểu diễn mỗi khách hàng và sản phẩm bằng vector nhúng mã ID cộng với phép chiếu tuyến tính của đặc trưng.

Khi mô hình nhận cả mã ID và đặc trưng, nó có thể dựa hẳn vào mã ID mà bỏ qua đặc trưng. DropoutNet [13] xử lý điều này bằng cách bỏ ngẫu nhiên vector ID khi huấn luyện, buộc mô hình học chấm điểm từ đặc trưng. Kỹ thuật này hữu ích khi muốn mô hình chấm được cả những sản phẩm có ít hoặc chưa có lượt mua.

Văn bản của sản phẩm (tên, mô tả) được biểu diễn bằng TF-IDF [14]. Một từ có trọng số cao với một sản phẩm khi nó lặp lại trong mô tả của sản phẩm đó nhưng ít gặp trong cả danh mục. Ma trận TF-IDF sau đó được giảm chiều bằng phân tích giá trị suy biến rút gọn (*truncated SVD*) [15]. Nhờ bước này, các mô tả cùng chủ đề nhưng dùng từ khác nhau có vector gần nhau. Cách biểu diễn này không cần dữ liệu tương tác và tính nhanh.

2.4.2 Lý do chọn kiến trúc hai nhánh

Ngoài mô hình lai dựa trên đặc trưng, hệ thống khuyến nghị còn có các hướng như mô hình theo chuỗi hành vi, mô hình trên đồ thị tương tác và mô hình ngôn ngữ lớn. Đề tài chọn kiến trúc hai nhánh của NeuMF vì ba lý do:

– Về dữ liệu: giao dịch H&M chỉ ghi ngày mua, không có giờ hay mã phiên, nên khó áp dụng mô hình chuỗi. Bộ dữ liệu lại có thuộc tính và mô tả sản phẩm, phù hợp với cách biểu diễn "vector nhúng ID cộng đặc trưng".
– Về mục tiêu: hai nhánh tách biệt cho phép đo riêng đóng góp của đặc trưng và của cách hợp nhất.
– Về tài nguyên: mô hình đồ thị và mô hình ngôn ngữ lớn cần nhiều tài nguyên tính toán hơn mức đề tài có.

2.5 Các độ đo đánh giá Top-K

Với mỗi người dùng được đánh giá u, mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\mathrm{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm mục tiêu của u và $\mathrm{hits}_u = |T_u \cap \mathrm{Rec}_K(u)|$. Khi chia dữ liệu theo một mốc thời gian chung như trong đề tài, một người dùng có thể có nhiều sản phẩm mục tiêu. Mọi độ đo được tính cho

từng người dùng rồi lấy trung bình trên tập người dùng được đánh giá $\mathcal{U}_{test}$.

Hit Ratio (HR@K) là độ đo đơn giản nhất. Nó kiểm tra trong K khuyến nghị có ít nhất một món khách thật sự mua hay không. Mỗi người dùng được tính 1 nếu có và 0 nếu không:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}\left(\text{hits}_u \geq 1\right) \tag{2.17}$$

Precision@K là tỉ lệ khuyến nghị đúng trong K khuyến nghị, đo độ chính xác từ phía danh sách. Recall@K là tỉ lệ các món khách thật sự mua đã có mặt trong danh sách, đo độ bao phủ từ phía khách:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \qquad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \tag{2.18}$$

Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K bằng HR@K chia cho K. Hai độ đo này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm mục tiêu.

Ba độ đo trên không phân biệt món đúng nằm ở vị trí đầu hay vị trí thứ K, trong khi người dùng thường chỉ xem vài khuyến nghị đầu. NDCG@K (*normalized discounted cumulative gain*) tính đến vị trí bằng cách giảm dần đóng góp của một món đúng khi nó nằm càng xa đầu danh sách. Với mức liên quan nhị phân, định nghĩa của Järvelin và Kekäläinen [16] là:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^{K} \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|,K)} \frac{1}{\log_2(j+1)} \end{aligned} \tag{2.19}$$

IDCG là giá trị DCG khi mọi sản phẩm mục tiêu xếp ở đầu danh sách, nên NDCG@K nằm trong $[0, 1]$. Với $|T_u| = 1$ và sản phẩm mục tiêu ở hạng r, NDCG@K bằng $1/\log_2(r+1)$ nếu $r \leq K$ và bằng 0 nếu ngược lại.

2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu

Một số công trình, trong đó có NCF, đánh giá bằng cách xếp sản phẩm mục tiêu giữa một tập nhỏ ứng viên lấy mẫu, cụ thể là sản phẩm kiểm thử cùng 100 sản phẩm người dùng chưa tương tác. Krichene và Rendle [17] chứng minh độ đo trên tập ứng viên lấy mẫu không nhất quán với độ đo trên toàn bộ danh mục, thậm chí có thể đảo ngược kết luận "A tốt hơn B", và đề nghị không lấy mẫu. Đề tài vì vậy chỉ dùng

cách xếp hạng toàn bộ (*full ranking*). Mỗi người dùng được xếp hạng trên toàn bộ tập ứng viên, trừ sản phẩm đã mua. Ở tập kiểm thử (*test set*) của mẫu kiểm định, tập này có khoảng 6.710 sản phẩm.

2.5.2 Độ đo ngoài độ chính xác

Một mô hình chỉ khuyến nghị những món bán chạy nhất vẫn có thể đạt HR@K khá, vì món bán chạy dễ trúng, nhưng danh sách của nó gần như giống nhau với mọi khách. Để mô tả danh sách khuyến nghị ngoài độ chính xác, đề tài dùng độ phủ (*coverage*): tỉ lệ sản phẩm của không gian ứng viên $\mathcal{I}_{cand}$ xuất hiện trong danh sách khuyến nghị của ít nhất một người dùng:

$$\text{Coverage@K} = \frac{\left|\bigcup_{u \in \mathcal{U}_{test}} \text{Rec}_K(u)\right|}{|\mathcal{I}_{cand}|} \tag{2.20}$$

Độ phủ thấp cho thấy mô hình chỉ dùng một phần nhỏ danh mục. Trường hợp giới hạn là Most Popular, khi mọi người dùng nhận gần như cùng một danh sách. Độ đo này chỉ mang tính mô tả.

2.6 Ba nghiên cứu nền tảng

Đề tài chọn ba nghiên cứu làm nền tảng tham chiếu vì chúng liên quan trực tiếp tới mô hình và cách đánh giá:

- He và cộng sự [4] đề xuất kiến trúc NeuMF mà NeuMF-F kế thừa.
- Rendle và cộng sự [5] kiểm tra lại liệu NeuMF có tốt hơn MF được tinh chỉnh kỹ hay không, câu hỏi mà đề tài đặt lại trên dữ liệu H&M.
- Luận án của Hồ Thị Linh [3] hệ thống hoá hai cách hợp nhất sớm, muộn và việc bổ sung nguồn thông tin ngoài ma trận tương tác.

Bảng 2.1 đối chiếu thiết lập thực nghiệm của ba nghiên cứu với đề tài. Số liệu của mỗi nghiên cứu lấy từ bài gốc.

Các con số trong bảng không so sánh trực tiếp được với nhau:

- Hai bài về NCF xếp sản phẩm mục tiêu giữa 101 ứng viên, nên HR@10 đạt khoảng 0,7 đến 0,9.
- Đề tài xếp hạng trên khoảng 6 đến 7 nghìn ứng viên, nên cùng độ đo cho giá trị thấp hơn nhiều.
- Luận án giải bài toán dự đoán điểm đánh giá với độ đo sai số, không xếp hạng.

Vì vậy chỉ nên đọc mức cải thiện tương đối so với đối chứng trong từng nghiên cứu. Từ ba nghiên cứu này, đề tài kế thừa kiến trúc và cách huấn luyện của NeuMF, yêu cầu tinh chỉnh đầy đủ mô hình đối chứng, và khung hợp nhất sớm, hợp nhất muộn.

Bảng 2.1: Ba nghiên cứu nền tảng và thiết lập của đề tài

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
He và cộng sự, 2017	MovieLens 1M (6.040 người dùng, 3.706 phim, 1.000.209 tương tác) và Pinterest (55.187 người dùng, 9.916 sản phẩm, 1.500.809 tương tác), phản hồi ẩn. Xếp hạng Top-K; HR@10, NDCG@10	Giữ lại tương tác mới nhất của mỗi người dùng làm kiểm thử. 101 ứng viên: sản phẩm kiểm thử và 100 sản phẩm chưa tương tác lấy ngẫu nhiên	NeuMF có tiền huấn luyện: MovieLens HR@10 = 0,730, NDCG@10 = 0,447 (64 nhân tố); Pinterest HR@10 = 0,880, NDCG@10 = 0,558 (16 nhân tố). Trung bình cao hơn eALS 4,5% và BPR 4,9% (tương đối).
Rendle và cộng sự, 2020	Như NCF: MovieLens 1M và Pinterest; HR@10, NDCG@10	Như NCF: giữ lại tương tác mới nhất; 101 ứng viên	MF tinh chỉnh kỹ: MovieLens 0,7294 / 0,4523, Pinterest 0,8895 / 0,5794 (HR@10 / NDCG@10); NeuMF trong bảng so sánh của bài: 0,7093 / 0,4349 và 0,8777 / 0,5576. MF cao hơn NeuMF 2,8% HR@10 và 4,0% NDCG@10 (MovieLens), 1,3% và 3,9% (Pinterest).

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
Hồ Thị Linh, 2023	MovieLens (77.764 đánh giá, 27.042 người dùng, 8.203 phim); Amazon Electronics (85.065 đánh giá, 1.042 người dùng), Toys and Games (71.780; 5.462), Video Games (98.769; 2.291). Dự đoán điểm đánh giá; RMSE, MAE, Precision	Chia ngẫu nhiên 80% huấn luyện (20% trong đó để xác thực), 20% kiểm thử. Không xếp hạng trên tập ứng viên	Hợp nhất sớm vector MF và đặc trưng văn bản qua mạng lưới thần kinh (chương 4), Electronics: RMSE 1,01, Precision 82,86% so với SVD 1,16 và 69,55% (RMSE giảm 12,93%, Precision tăng 19,14%). Transformer hợp nhất nhiều góc nhìn (chương 5), Toys and Games: MAE 0,445, RMSE 0,743, Precision 92,07% so với SVD 0,844 / 1,120 / 68,06%.
Đề tài, 2026	H&M, mẫu kiểm định (7.994 khách, 6.749 sản phẩm, 243.696 cặp) và Amazon Beauty 5-core (10.681 khách, 6.069 sản phẩm, 94.009 cặp), phản hồi ẩn. Xếp hạng Top-K; NDCG@10 (chính), Recall, HR, Precision ở $K = 10, 15, 20$	Theo mốc thời gian chung; mẫu khách hàng độc lập (H&M). Ứng viên: mọi sản phẩm đã có dữ liệu huấn luyện, trừ sản phẩm khách đã mua; trung bình 6.710 (H&M), 6.058 (Amazon)	NeuMF-F: NDCG@10 = 0,04003 (H&M), 0,03277 (Amazon Beauty). Cao hơn NeuMF chỉ dùng ID +43,8% và +65,7% (tương đối). Mô hình cao nhất trên cả hai bộ là LateFusion-F (0,04093 và 0,03747).

2.7 Khoảng trống nghiên cứu

Các nghiên cứu liên quan còn ba điểm chưa giải quyết:

– Các nghiên cứu về NCF chủ yếu được đánh giá trên dữ liệu phim ảnh hoặc mạng xã hội hình ảnh, với cách giữ lại tương tác cuối và tập ứng viên lấy mẫu.

– Các nghiên cứu đánh giá lại cho thấy NeuMF chỉ dùng mã ID khó vượt các

mô hình đơn giản được tinh chỉnh kỹ.

– Các mô hình dùng đặc trưng thường được đánh giá cho bài toán dự đoán nhấp chuột, không phải xếp hạng Top-K trên toàn bộ danh mục.

Từ đó, đề tài tập trung vào hai việc:

– Về mô hình: xây dựng NeuMF-F, giữ cấu trúc hai nhánh MF và DNN của NeuMF và dùng thêm đặc trưng của sản phẩm, khách hàng, thời gian.

– Về đánh giá: thử mô hình trên dữ liệu giao dịch thời trang thực tế với cách làm gần với khi triển khai.

  + Dữ liệu được chia theo thời gian.
  + Đặc trưng không dùng thông tin tương lai.
  + Mọi mô hình được tinh chỉnh với cùng ngân sách và xếp hạng trên toàn bộ tập ứng viên.
  + Kết luận được lấy trên một mẫu khách hàng không dùng để chọn cấu hình.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F

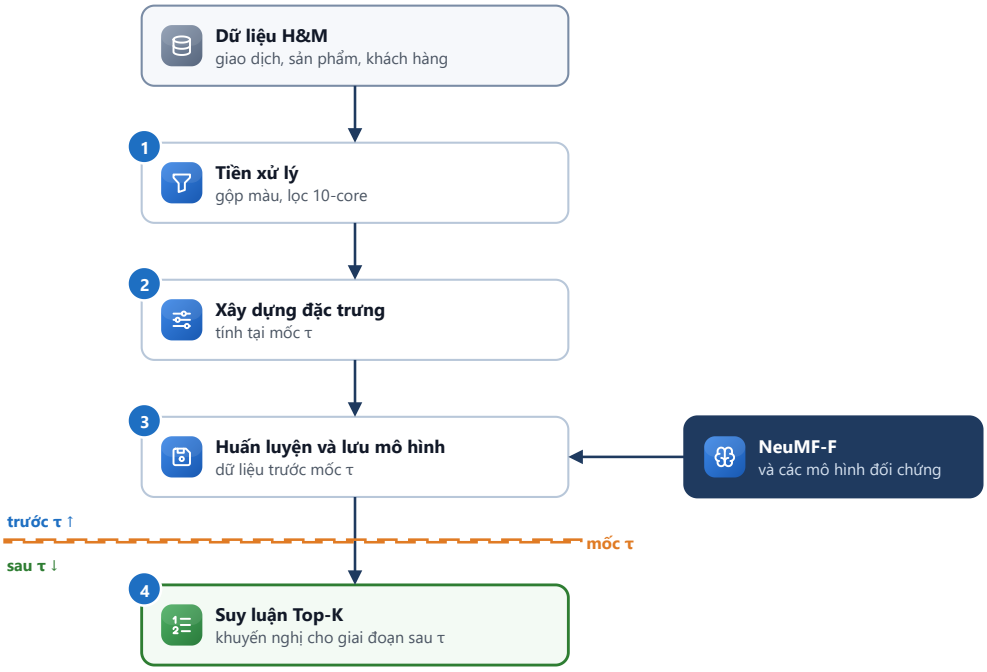
3.1 Quy trình tổng thể huấn luyện và đánh giá mô hình

Hệ thống được tổ chức theo các bước mà một mô hình khuyến nghị trải qua khi đưa vào sử dụng, như trong Hình 3.1. Chuỗi bước này được gọi là quy trình xử lý (*pipeline*), gồm:

- Tiền xử lý dữ liệu.
- Xây dựng đặc trưng.
- Huấn luyện và lưu mô hình.
- Suy luận danh sách khuyến nghị Top-K.

Mỗi lần chạy, quy trình nhận một mốc thời gian τ. Mọi bước chỉ dùng dữ liệu trước τ, và bước suy luận trả về danh sách khuyến nghị cho giai đoạn sau τ. Cách làm này giống tình huống doanh nghiệp huấn luyện mô hình trên lịch sử đến hôm nay rồi khuyến nghị cho những tuần tới. Việc đánh giá là một quy trình riêng: gọi lại quy trình xử lý với các mốc khác nhau, rồi so danh sách khuyến nghị với những gì khách đã mua thật.

Mọi mô hình, kể cả mô hình đối chứng, đều đi qua quy trình này với cùng tệp dữ liệu, cùng tập ứng viên và cùng quy tắc loại sản phẩm đã mua. Nhờ vậy, khi hai mô hình cho kết quả khác nhau, nhóm có thể quy chênh lệch đó cho bản thân mô hình.



Hình 3.1: Đường ống huấn luyện và đánh giá mô hình

3.2 Dữ liệu và tiền xử lý

3.2.1 Đặc tả bộ dữ liệu H&M

Bộ dữ liệu H&M Personalized Fashion Recommendations [1] ghi lại hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn. Đề tài dùng ba tệp.

- `transactions_train.csv` (3,49 GB): 31.788.324 dòng giao dịch từ 20/09/2018 đến 22/09/2020, của 1.362.281 khách hàng trên 104.547 sản phẩm. Ba trường được dùng là `customer_id` (mã khách), `article_id` (mã sản phẩm, 10 chữ số) và `t_dat` (ngày mua, không có giờ). Giá và kênh bán không được dùng.
- `articles.csv`: 105.542 sản phẩm của danh mục. Mỗi sản phẩm có 11 thuộc tính dạng mã: loại sản phẩm, nhóm sản phẩm, hoạ tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu và nhóm may mặc. Sản phẩm còn có mô tả văn bản gồm tên và mô tả chi tiết.
- `customers.csv`: 1.371.980 khách hàng với tuổi, trạng thái hội viên, tần suất nhận tin thời trang và hai cờ FN, Active. Mã bưu chính không được dùng.

Ảnh sản phẩm có trong bộ dữ liệu nhưng không được dùng làm đầu vào của mô hình, và chỉ được hiển thị trong hệ thống demo.

Khi đánh giá bằng xếp hạng toàn bộ, mô hình phải chấm điểm mọi sản phẩm ứng viên cho mỗi người dùng. Chi phí vì thế tăng theo tích của số người dùng và số sản phẩm. Để ước lượng quy mô bài toán, đề tài lọc k-core trên toàn bộ 31.788.324 dòng giao dịch với ba ngưỡng $k = 3, 5, 10$. Kết quả lọc được ghi trong Bảng 3.1. Mật độ trong bảng là số tương tác chia cho tích số người dùng và số sản phẩm. Ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm, tương ứng hàng chục tỷ cặp phải chấm điểm cho mỗi mô hình. Khối lượng này vượt quá tài nguyên tính toán của nhóm, do đó nhóm thực nghiệm trên các mẫu lấy theo khách hàng.

Bảng 3.1: Lọc k-core trên toàn bộ dữ liệu H&M

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định

Đề tài lấy mẫu theo khách hàng thay vì theo dòng. Lấy mẫu theo dòng, hoặc cắt n dòng đầu, sẽ cắt vụn lịch sử của từng khách. Vì tệp gốc sắp theo ngày, cách đó còn chỉ phủ vài ngày giao dịch. Cả bước lọc k-core lẫn việc chia dữ liệu theo thời gian đều hỏng nếu làm vậy. Quy trình lấy mẫu gồm hai lượt đọc tệp theo lô, với bộ nhớ đỉnh khoảng 0,5 GB:

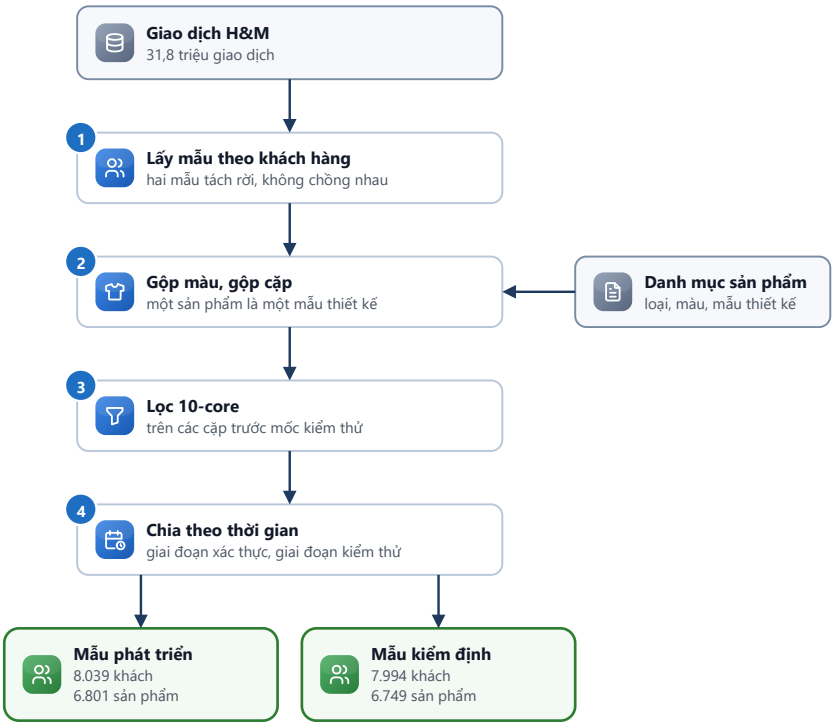
- Lượt thứ nhất chọn khách: băm `customer_id` bằng một khoá cố định vào 100.000 nhóm và đếm số giao dịch của từng nhóm. Hàm băm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua.
- Lượt thứ hai ghi mẫu: giữ toàn bộ giao dịch của các khách được chọn, trải đủ từ 20/09/2018 đến 22/09/2020.

Các mẫu được lấy từ những đoạn nhóm băm liền nhau và không chồng lên nhau. Mỗi mẫu gồm số nhóm ít nhất đủ khoảng 500.000 giao dịch.

- Mẫu phát triển gồm các nhóm $[0, 1597)$: 500.269 giao dịch của 21.599 khách hàng. Mẫu này chỉ dùng để tinh chỉnh trên tập xác thực.
- Mẫu kiểm định gồm các nhóm $[3160, 4734)$: 500.164 giao dịch của 21.351 khách hàng. Vì các đoạn nhóm không chồng nhau, không khách hàng nào thuộc cả mẫu phát triển lẫn mẫu kiểm định. Mẫu kiểm định chỉ dùng cho đánh giá cuối.

Vì dùng hàm băm với khoá cố định, lấy mẫu lại luôn cho đúng cùng hai mẫu. Vì mẫu kiểm định gồm những khách hàng khác hẳn và chưa từng được dùng để chọn mô hình, kết quả trên mẫu này ước lượng hiệu năng của mô hình với khách hàng khác của cùng cửa hàng, trong cùng giai đoạn thời gian.

Toàn bộ quá trình xử lý, từ tệp giao dịch gốc tới hai mẫu đã lọc, gồm bốn bước, được minh hoạ trong Hình 3.2. Mỗi bước được áp dụng như nhau cho hai mẫu. Mẫu phát triển chỉ dùng để tinh chỉnh, mẫu kiểm định chỉ dùng để đánh giá cuối. Quy mô dữ liệu sau từng bước được nêu ở các mục dưới đây.



Hình 3.2: Quy trình xử lý dữ liệu H&M

3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử

Mỗi sản phẩm là một mẫu thiết kế. Mã `article_id` 10 chữ số của H&M gồm mã mẫu thiết kế `product_code` và ba chữ số cuối chỉ biến thể màu, nên một mẫu áo có thể mang nhiều `article_id`. Đề tài coi một sản phẩm là một `product_code`, nghĩa là mọi màu của cùng một mẫu được gộp làm một sản phẩm. Khách mua nhiều màu của cùng một mẫu chỉ được tính một cặp (khách, sản phẩm). Trước mốc kiểm thử, việc gộp này giảm số sản phẩm của mẫu phát triển từ 55.971 xuống 27.370 và số cặp từ 401.293 xuống 359.181. Với mẫu kiểm định, số sản phẩm giảm từ 55.683 xuống 27.291 và số cặp từ 398.653 xuống 356.740.

Một khách có thể mua cùng một sản phẩm nhiều lần. Các giao dịch lặp được gộp thành một cặp (khách, sản phẩm) duy nhất, giữ ngày mua đầu tiên t_{ui}, trước khi lọc k-core. Nếu lọc trực tiếp trên dòng giao dịch, số lượt mua lặp sẽ làm bậc của khách và sản phẩm cao hơn thực tế. Trên mẫu phát triển, 500.269 giao dịch sau khi gộp chỉ còn 429.964 cặp duy nhất.

Lọc k-core được lặp đến khi hội tụ, vì loại một sản phẩm có thể làm một khách rơi xuống dưới ngưỡng và ngược lại. Sau khi lọc, mỗi khách và mỗi sản phẩm còn lại có ít nhất k đối tác khác nhau. Phép lọc chỉ dùng các cặp có ngày mua đầu trước mốc kiểm thử (29/07/2020), nên không dựa vào thông tin nào của giai đoạn kiểm thử. Với $k = 10$, quy mô hai mẫu sau khi lọc như sau:

- Mẫu phát triển: 8.039 khách, 6.801 sản phẩm và 245.644 cặp.
- Mẫu kiểm định: 7.994 khách, 6.749 sản phẩm và 243.696 cặp.

Mã khách và mã sản phẩm được đánh lại chỉ số liên tục, và $y_{ui} = 1$ khi khách u đã mua sản phẩm i. Dữ liệu đã lọc của mỗi mẫu được ghi ra một tệp, và mọi mô hình đọc cùng tệp này. Thuật toán 3.1 tóm tắt bước chuẩn bị dữ liệu.

Khi nạp dữ liệu cho một giai đoạn đánh giá, chương trình chỉ giữ các khách và sản phẩm thuộc k-core.

Thuật toán 3.1 Chuẩn bị dữ liệu và lọc k-core

Đầu vào: giao dịch (c, a, t) của một mẫu; mốc kiểm thử τ_{test}; ngưỡng k
Đầu ra: tệp các cặp (c, i, t_{ci}) kèm cờ thuộc k-core

$i \leftarrow \lfloor a/1000 \rfloor$ với mọi giao dịch ▷ *gộp màu theo* `product_code`
gộp theo cặp (c, i), giữ t_{ci} là ngày mua sớm nhất
$E \leftarrow \{(c, i) : t_{ci} < \tau_{test}\}$ ▷ *chỉ dữ liệu trước mốc*
lặp
    $E' \leftarrow E$
    $U \leftarrow$ các khách có ít nhất k sản phẩm trong E
    $I \leftarrow$ các sản phẩm có ít nhất k khách trong E
    $E \leftarrow \{(c, i) \in E : c \in U,\ i \in I\}$
đến khi $E = E'$
ghi mọi cặp kèm cờ $(c, i) \in E$ ra tệp ▷ *mọi mô hình đọc tệp này*

Ngưỡng k được chọn bằng cách thử lọc trên 429.964 cặp của mẫu phát triển, với kết quả trong Bảng 3.2. Lần thử này được làm khi mỗi sản phẩm vẫn còn là một

`article_id`, vì vậy số sản phẩm trong bảng lớn hơn số sau khi gộp màu. Với $k = 5$, danh mục còn 23.067 sản phẩm, và đánh giá xếp hạng toàn bộ cần khoảng 10,7 GB bộ nhớ, vượt quá tài nguyên tính toán của đề tài. Nhóm vì vậy chọn $k = 10$. Đổi lại, dữ liệu nghiêng về những khách mua nhiều.

Bảng 3.2: Lọc k-core trên mẫu phát triển

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	7.519	10.345	220.292	0,283
15	3.017	3.186	83.088	0,864

3.2.4 Giai đoạn đánh giá và tập ứng viên

Dữ liệu được chia theo thời gian bằng hai mốc cố định, chung cho mọi khách hàng, như minh hoạ trong Hình 3.3. Trục thời gian trong hình không theo tỉ lệ. Mốc xác thực là τ_{val} = 01/07/2020, với cửa sổ xác thực 4 tuần từ 01/07 đến 28/07/2020. Mốc kiểm thử là τ_{test} = 29/07/2020, với cửa sổ kiểm thử 8 tuần từ 29/07 đến 22/09/2020. Với mỗi mốc τ, gọi là một giai đoạn, các tập sau được định nghĩa:

$$\mathcal{D}_\tau = \{(u,i) \text{ đã lọc } k\text{-core} : t_{ui} < \tau\} \quad \text{(dữ liệu huấn luyện)} \tag{3.1}$$

$$\mathcal{I}_\tau = \{i : \exists u,\ (u,i) \in \mathcal{D}_\tau\} \quad \text{(sản phẩm có dữ liệu huấn luyện)} \tag{3.2}$$

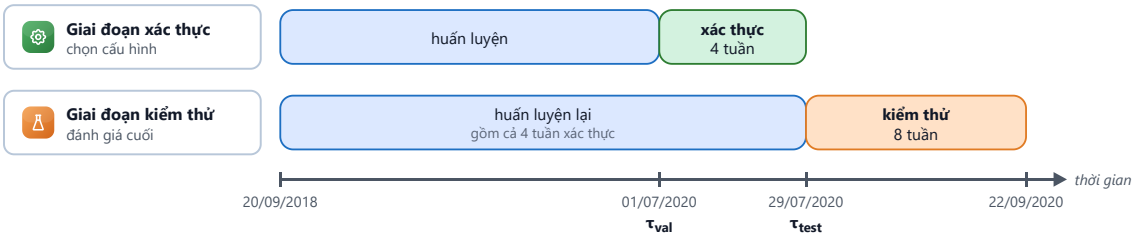
$$\mathcal{C}_u(\tau) = \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau) \quad \text{(tập ứng viên của khách } u) \tag{3.3}$$

$$T_u(\tau) = \{i \in \mathcal{C}_u(\tau) : \tau \le t_{ui} < \tau_{end}\} \quad \text{(sản phẩm mục tiêu của } u) \tag{3.4}$$

trong đó $\mathcal{I}_u(\tau)$ là các sản phẩm u đã mua trước τ, và τ_{end} là cuối cửa sổ của giai đoạn. Chỉ những khách có dữ liệu huấn luyện trong $\mathcal{D}_\tau$ và có ít nhất một sản phẩm mục tiêu mới được đánh giá. Có hai điểm cần giải thích.

- Tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện. Sản phẩm chưa có cặp nào trong dữ liệu huấn luyện của giai đoạn, trong đó có sản phẩm vừa ra mắt, không thuộc tập ứng viên lẫn tập sản phẩm mục tiêu. Với tập ứng viên này, mọi mô hình, kể cả mô hình chỉ dùng mã ID, đều chấm được mọi ứng viên. Phép so sánh vì thế không phụ thuộc vào khả năng xử lý sản phẩm chưa có lịch sử bán. Đổi lại, kết quả không nói về khả năng khuyến nghị sản phẩm vừa ra mắt.
- Mô hình được huấn luyện lại trên dữ liệu mới nhất. Ở giai đoạn kiểm thử,

$\mathcal{D}_{\tau_{test}}$ gồm cả cửa sổ xác thực. Tập xác thực chỉ dùng để chọn cấu hình và số epoch. Mỗi epoch là một lượt mô hình duyệt hết dữ liệu huấn luyện. Trước khi đánh giá trên tập kiểm thử, mô hình được huấn luyện lại từ đầu trên $\mathcal{D}_{\tau_{test}}$. Khi dự đoán, mô hình đã thấy toàn bộ quá khứ, giống như khi triển khai thật.



Hình 3.3: Chia dữ liệu theo thời gian

Đề tài không chia theo cách giữ lại tương tác cuối của từng người dùng (*leave-one-out*) như NCF. Cách này để lọt thông tin tương lai, vì tập huấn luyện chứa tương tác của người dùng khác xảy ra sau thời điểm cần dự đoán [18]. Khi thử chia mẫu phát triển theo cách này, nhóm thấy:

- Trung bình 11,2% tương tác trong tập huấn luyện của mỗi người dùng xảy ra sau ngày mua sản phẩm kiểm thử của người đó.
- 60,9% người dùng có sản phẩm xác thực và sản phẩm kiểm thử mua cùng một ngày.

Vì vậy đề tài chia theo một mốc thời gian chung cho mọi người dùng.

Theo định nghĩa, mỗi cặp (khách, sản phẩm) chỉ có một ngày mua đầu. Do đó một cặp không thể vừa thuộc dữ liệu huấn luyện vừa là sản phẩm mục tiêu trong cùng một giai đoạn. Sản phẩm khách đã mua trước mốc cũng không bao giờ được tính là sản phẩm mục tiêu, vì mục tiêu là dự đoán những món khách chưa từng mua.

Quy mô dữ liệu của hai mẫu được tóm tắt trong Bảng 3.3:

- Sau khi lọc, hai mẫu có số người dùng và số sản phẩm gần như bằng nhau, dù không có khách chung.
- Số người dùng được đánh giá chỉ chiếm từ 32% (giai đoạn xác thực) đến 40% (giai đoạn kiểm thử) số người dùng sau lọc, vì chỉ khách có mua sản phẩm mới trong cửa sổ đánh giá mới được tính.
- Ở giai đoạn kiểm thử, mỗi người dùng được xếp hạng trên khoảng 6.710 ứng viên nhưng trung bình chỉ có hơn ba sản phẩm mục tiêu. Đây là lý do

các độ đo xếp hạng có giá trị tuyệt đối thấp.

Mẫu phát triển chỉ dùng ở giai đoạn xác thực, nên các dòng của giai đoạn kiểm thử ở cột này để trống.

Bảng 3.3: Quy mô dữ liệu H&M

	Mẫu phát triển	Mẫu kiểm định
Người dùng sau lọc 10-core	8.039	7.994
Sản phẩm (`product_code`) sau lọc 10-core	6.801	6.749
Cặp (khách, sản phẩm) trước mốc kiểm thử	245.644	243.696
Xác thực: cặp huấn luyện (trước 01/07/2020)	236.845	234.610
Xác thực: người dùng được đánh giá	2.569	2.579
Xác thực: cặp đúng	8.636	8.985
Kiểm thử: người dùng được đánh giá	—	3.165
Kiểm thử: cặp đúng	—	10.285
Kiểm thử: số ứng viên trung bình mỗi người dùng	—	6.710

3.2.5 Xây dựng đặc trưng theo thời điểm

Các đặc trưng đầu vào được liệt kê trong Bảng 3.4. Nguyên tắc bắt buộc khi xây dựng đặc trưng là không dùng thông tin tương lai, nghĩa là đặc trưng của một cặp (khách u, sản phẩm i) tại ngày t chỉ được tính từ dữ liệu trước ngày t. Khi huấn luyện, mỗi cặp dương mang chính ngày mua đầu t_{ui} của nó. Khi đánh giá, t là mốc τ của giai đoạn.

Đặc trưng thời gian của sản phẩm được tính như sau. Gọi $n_{i,d}$ là số giao dịch của sản phẩm i trong ngày d trên toàn bộ H&M và d_i^0 là ngày bán đầu tiên. Tại ngày t:

$$\begin{aligned} s_i^{(w)}(t) &= \sum_{d=t-w}^{t-1} n_{i,d}, \\ x_i^{tg}(t) &= \left[\tfrac{\log(1+s_i^{(7)})}{10},\ \tfrac{\log(1+s_i^{(28)})}{10},\ \tfrac{\log(1+s_i^{(91)})}{10},\ \tfrac{\log(1+\max(0,\,t-d_i^0))}{10},\ \mathbb{I}(d_i^0 \geq t) \right] \end{aligned} \tag{3.5}$$

Tổng chỉ chạy tới ngày $t-1$ để không dùng doanh số của chính ngày t. Phép $\log(1+x)$ nén giá trị của các sản phẩm bán rất chạy, còn hệ số $1/10$ đưa đặc trưng về cỡ $[0, 1]$. Doanh số được tính trên toàn bộ giao dịch H&M, không chỉ trong mẫu. Đây là dữ liệu doanh nghiệp có tại thời điểm dự đoán, và nó phản ánh xu hướng bán gần đây của sản phẩm trên toàn cửa hàng.

Văn bản của sản phẩm được biểu diễn bằng TF-IDF trên từ đơn và cặp từ, rồi

giảm còn 64 chiều bằng SVD rút gọn và chuẩn hoá về độ dài 1. Bộ từ vựng bỏ từ dừng tiếng Anh và giữ tối đa 30.000 mục từ xuất hiện ở ít nhất 3 sản phẩm. Phép biến đổi được khớp trên toàn bộ danh mục và không dùng dữ liệu mua hàng.

Đặc trưng ban đầu được tính cho từng `article_id`, rồi được gộp theo mẫu thiết kế. Thuộc tính danh mục lấy theo biến thể có `article_id` nhỏ nhất. Ba thuộc tính màu (nhóm màu, độ đậm màu, màu chủ đạo) được đặt về một giá trị hằng vì không còn mô tả một màu cụ thể. Vector văn bản là trung bình các biến thể, chuẩn hoá lại về độ dài 1. Doanh số theo ngày là tổng các biến thể, và ngày bán đầu tiên là ngày sớm nhất của các biến thể.

Thuộc tính tĩnh của khách hàng lấy từ `customers.csv`. Tệp này không có mốc thời gian, nhóm coi các thuộc tính này là ít thay đổi. Đặc trưng thời gian của khách tại ngày t chỉ dùng các cặp có ngày mua đầu trước t: khoảng cách tới lần mua gần nhất và số cặp đã mua.

Bảng 3.4: Đặc trưng đầu vào trên H&M

Nhóm	Đặc trưng	Mã hoá	Nguồn
Sản phẩm: thuộc tính	11 thuộc tính danh mục (loại, nhóm sản phẩm, hoạ tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc); sau khi gộp theo mẫu, ba thuộc tính màu là hằng số	Vector nhúng 8 chiều mỗi thuộc tính (88 chiều), học cùng mô hình	`articles.csv`
Sản phẩm: văn bản	Tên và mô tả chi tiết	TF-IDF (từ đơn và cặp từ), SVD 64 chiều, chuẩn hoá L2	`articles.csv`
Sản phẩm: thời gian tại t	Doanh số trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ "chưa từng bán trước t"	$\log(1+x)/10$; cờ 0/1 (5 chiều)	Giao dịch toàn H&M
Khách hàng: tĩnh	Nhóm tuổi (9 mức, gồm "không rõ"), trạng thái hội viên, tần suất nhận tin, FN, Active	Vector nhúng 8 chiều mỗi thuộc tính (40 chiều)	`customers.csv`
Khách hàng: thời gian tại t	Số ngày từ lần mua gần nhất (tối đa 730); số cặp đã mua	$\log(1+x)/10$ (2 chiều)	Dữ liệu huấn luyện

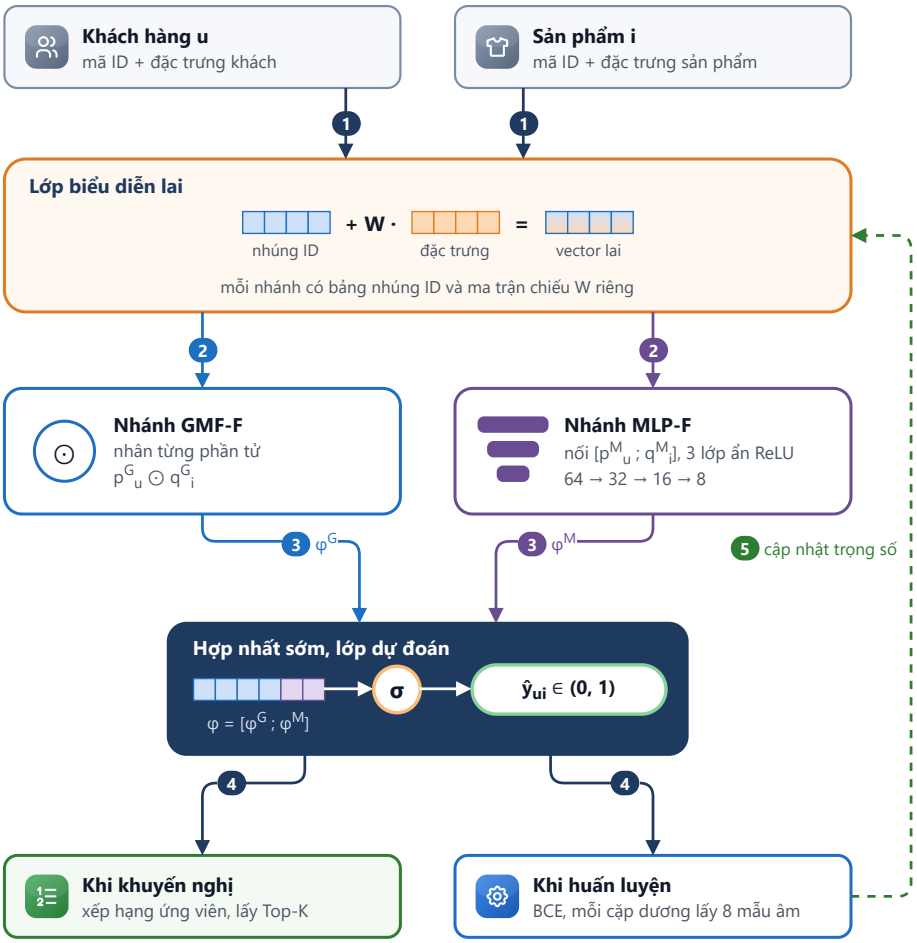
3.3 Thiết kế mô hình lai NeuMF-F

NeuMF-F giữ nguyên cấu trúc hai nhánh của NeuMF. Nhánh GMF học tương tác tuyến tính, nhánh MLP học tương tác phi tuyến, và hai nhánh được ghép ở một lớp dự đoán chung. Điểm khác duy nhất nằm ở đầu vào. Trong mỗi nhánh, vector của khách hàng và sản phẩm là tổng của vector nhúng mã ID với một phép chiếu tuyến tính của đặc trưng. Mỗi nhánh có bảng vector nhúng ID và ma trận chiếu đặc trưng riêng.

Kiến trúc NeuMF-F trong Hình 3.4 được đọc từ trên xuống:

- Cặp khách hàng và sản phẩm đi qua lớp biểu diễn lai, hai nhánh GMF-F và MLP-F, lớp hợp nhất và lớp dự đoán để cho điểm $\hat{y}_{ui}$.
- Khi huấn luyện, điểm được so với nhãn thật y_{ui} bằng hàm mất mát BCE.
- Khi đánh giá và khuyến nghị, điểm được tính cho mọi sản phẩm ứng viên của khách, rồi K sản phẩm có điểm cao nhất tạo thành danh sách khuyến nghị.

Với $d = 32$, tháp MLP là $64 \to 32 \to 16 \to 8$ và $\phi \in \mathbb{R}^{40}$. Trên mẫu kiểm định H&M, $|\mathcal{U}| = 7.994$, $|\mathcal{I}| = 6.749$, $d_U = 42$ và $d_I = 157$.



Hình 3.4: Kiến trúc mô hình đề xuất NeuMF-F

3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng

Với mỗi nhánh $b \in \{G, M\}$ (GMF và MLP), mô hình có bảng vector nhúng ID của khách hàng $P^b \in \mathbb{R}^{|\mathcal{U}| \times d}$, của sản phẩm $Q^b \in \mathbb{R}^{|\mathcal{I}^{ID}| \times d}$, và hai ma trận chiếu đặc trưng $W_U^b \in \mathbb{R}^{d \times d_U}$, $W_I^b \in \mathbb{R}^{d \times d_I}$, không có độ lệch. Vector của khách u và sản phẩm i tại ngày t trong nhánh b là:

$$p_u^b(t) = P_u^b + W_U^b\, x_u(t), \qquad q_i^b(t) = m_i\, Q_i^b + W_I^b\, x_i(t) \tag{3.6}$$

Vector đặc trưng của sản phẩm $x_i(t) = [e(a_{i,1}); \ldots; e(a_{i,11});\ v_i;\ x_i^{tg}(t)] \in \mathbb{R}^{d_I}$ gồm vector nhúng 8 chiều của 11 thuộc tính danh mục, vector văn bản v_i (64 chiều) và 5 đặc trưng thời gian (Công thức (3.5)), nên $d_I = 88 + 64 + 5 = 157$. Tương tự, $x_u(t) = [e(c_{u,1}); \ldots; e(c_{u,5});\ x_u^{tg}(t)] \in \mathbb{R}^{d_U}$ với $d_U = 40 + 2 = 42$. Vector nhúng của các thuộc tính $e(\cdot)$ được học cùng mô hình và dùng chung cho hai nhánh, còn ma trận chiếu W^b riêng cho từng nhánh.

Hệ số m_i cho biết vector nhúng ID của sản phẩm có được dùng hay không.

Khi $m_i = 0$, vector của sản phẩm chỉ còn phần đặc trưng. Vì mọi sản phẩm trong tập ứng viên đều có dữ liệu huấn luyện, khi chấm điểm luôn có $m_i = 1$. Khi huấn luyện, m_i có thể được đặt về 0 ngẫu nhiên với xác suất $\rho \in \{0;\ 0{,}25;\ 0{,}5\}$ theo ý tưởng của DropoutNet, gọi là bỏ ID ngẫu nhiên, để mô hình học chấm điểm một phần từ đặc trưng. ρ được chọn trên tập xác thực như các siêu tham số khác.

Như NeuMF, hai nhánh dùng hai không gian nhúng độc lập, vì nhánh GMF tối ưu vector cho phép nhân Hadamard còn nhánh MLP tối ưu vector làm đầu vào của mạng phi tuyến. Hai nhánh dùng cùng số chiều $d \in \{32, 64\}$. Các bảng vector nhúng được khởi tạo theo phân phối chuẩn $\mathcal{N}(0;\ 0{,}01^2)$. Hàng "không có ID" là vector 0 cố định. Các lớp tuyến tính được khởi tạo theo Xavier, và lớp đầu ra h không có độ lệch.

3.3.2 Nhánh GMF-F

Nhánh GMF-F là dạng tổng quát của nhân tử hoá ma trận trên vector lai. Thay vì cộng ngay tích các chiều thành một số, nhánh giữ kết quả nhân theo từng chiều qua phép nhân Hadamard:

$$\phi^G = p_u^G(t) \odot q_i^G(t) \tag{3.7}$$

Phép cộng các chiều được chuyển sang vector trọng số h ở lớp đầu ra, nhờ đó mô hình học được trọng số riêng cho từng chiều. Đây là phần "tổng quát" trong tên gọi GMF: khi $h = \mathbf{1}$ và không có đặc trưng, GMF-F trở về MF. Vì p_u^G và q_i^G đều chứa phần chiếu của đặc trưng, tích $p_u^G \odot q_i^G$ còn mô hình hoá tương tác tuyến tính giữa thuộc tính của khách và thuộc tính của sản phẩm, tương tự Factorization Machines.

3.3.3 Nhánh MLP-F

Nhánh MLP-F nối hai vector lai thành đầu vào của một mạng nhiều lớp, không áp đặt trước cách hai vector tương tác:

$$z_1 = \begin{bmatrix} p_u^M(t) \\ q_i^M(t) \end{bmatrix} \in \mathbb{R}^{2d}, \qquad \phi_L^M = a_L\big(W_L^T \cdots a_2(W_2^T z_1 + b_2) \cdots + b_L\big) \tag{3.8}$$

Như NCF, tháp giảm một nửa số chiều qua mỗi lớp ẩn: $[2d \to d \to d/2 \to d/4]$. Với $d = 32$, tháp là $[64 \to 32 \to 16 \to 8]$. Mỗi lớp ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và dropout. Dropout bỏ ngẫu nhiên một phần đơn vị của lớp khi huấn luyện, với tỉ lệ được tinh chỉnh trong $\{0;\ 0{,}2\}$. Cùng với dropout, mô hình được chống quá khớp (*overfitting*) bằng điều chuẩn L_2 và dừng sớm (*early stopping*) theo NDCG@10 trên tập xác thực.

3.3.4 Lớp hợp nhất và lớp dự đoán

Vector của nhánh GMF-F và của nhánh MLP-F được nối thành một vector hợp nhất, rồi qua một lớp tuyến tính cuối và hàm sigmoid:

$$\hat{y}_{ui} = \sigma\big(h^T[\phi^G;\ \phi_L^M]\big) = \sigma\big(h_G^T\,(p_u^G \odot q_i^G) + h_M^T\,\phi_L^M\big) \tag{3.9}$$

Theo cách phân loại hợp nhất sớm và hợp nhất muộn, đây là hợp nhất sớm ở mức biểu diễn của góc nhìn tuyến tính (MF) và góc nhìn phi tuyến (DNN). Một lớp dự đoán chung học trọng số giữa hai góc nhìn, và toàn bộ mạng được huấn luyện chung. Bên cạnh đó, đặc trưng của sản phẩm và khách hàng được đưa vào ngay ở mức vector của cả hai nhánh, do đó thông tin nội dung và ngữ cảnh cũng được hợp nhất sớm với thông tin cộng tác.

Khi xếp hạng, mô hình dùng trực tiếp giá trị trước sigmoid (logit). Sigmoid đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hoà về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả. Khi đánh giá một giai đoạn, vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần rồi dùng lại cho mọi cặp. Vì vậy chi phí chấm toàn bộ tập ứng viên gần bằng chi phí của NeuMF chỉ dùng ID.

3.4 Mô hình đối chứng

Các mô hình đối chứng được xếp thành ba nhóm trong Bảng 3.5, mỗi nhóm ứng với một mục tiêu đánh giá riêng về mô hình đề xuất. Mọi mô hình được đánh giá trên cùng dữ liệu, cùng tập ứng viên và cùng quy tắc chấm. Mô hình Random cho điểm ngẫu nhiên và chỉ dùng làm mốc dưới. Tính cả NeuMF-F, đánh giá cuối gồm 14 mô hình đăng ký trước. Hybrid-CBCF, đánh dấu * trong bảng, là mô hình thứ 15, được bổ sung sau khi đánh giá cuối của 14 mô hình đã hoàn tất, theo một kế hoạch riêng.

Bảng 3.5: Ba nhóm mô hình đối chứng

Nhóm	Mô hình	Mục đích đánh giá đối chứng
Mô hình đơn lẻ	GMF, MLP (chỉ dùng ID); GMF-F, MLP-F (có đặc trưng)	Đánh giá việc hợp nhất hai nhánh MF và DNN so với từng nhánh độc lập
Học máy truyền thống	Content, ItemKNN, UserKNN, BPR-MF; mô hình lai truyền thống Hybrid-CBCF*	So sánh mô hình lai học sâu với các phương pháp khuyến nghị truyền thống và mô hình lai cổ điển
Chuyên biệt cho khuyến nghị	Most Popular, MostPopular-Recent; NeuMF (NCF chỉ dùng ID); LateFusion-F (hợp nhất muộn)	Đối chiếu với xu hướng phổ biến gần đây, kiến trúc NCF nguyên bản và cơ chế hợp nhất muộn

3.4.1 Các mô hình cài đặt trên cùng khung với NeuMF-F

Để thực hiện các phép so sánh trực tiếp và nhất quán, các mô hình sau được cài đặt trên cùng mã nguồn, cùng bộ đặc trưng và cùng quy trình huấn luyện với NeuMF-F.

- GMF-F và MLP-F là NeuMF-F chỉ giữ một nhánh. Chúng đo đóng góp của từng nhánh và lợi ích của việc hợp nhất. MLP-F đứng riêng là một mô hình DNN thuần, không phải mô hình hợp nhất MF với DNN.
- LateFusion-F là hợp nhất muộn của cùng hai thành phần. GMF-F và MLP-F được huấn luyện riêng, rồi điểm đã chuẩn hoá min–max trên tập ứng viên của từng khách được trộn theo trọng số w chọn trên tập xác thực. So sánh NeuMF-F với LateFusion-F là so sánh hai cách hợp nhất trên cùng hai thành phần.
- GMF, MLP và NeuMF chỉ dùng ID là kiến trúc NCF gốc, không có đặc trưng. Chúng đo lợi ích của đặc trưng.
- Các biến thể bóc tách của NeuMF-F dùng cùng siêu tham số với NeuMF-F và tắt lần lượt một thành phần: vector văn bản, đặc trưng thời gian, thông tin khách hàng, thuộc tính sản phẩm, hoặc cơ chế bỏ ID ngẫu nhiên. Đặc trưng thời gian gồm cả phần của sản phẩm và phần của khách, còn thông tin khách hàng gồm thuộc tính tĩnh và đặc trưng thời gian của khách. Biến thể nào trùng với chính NeuMF-F thì không chạy.

3.4.2 Các mô hình đối chứng còn lại

Các mô hình còn lại được cài đặt riêng, nhưng dùng cùng tệp dữ liệu, cùng tập ứng viên và cùng cách chấm với NeuMF-F.

- Most Popular: điểm của sản phẩm là số khách trong dữ liệu huấn luyện của mẫu đã mua sản phẩm đó. Mọi khách nhận cùng một danh sách, trừ sản phẩm đã mua.
- MostPopular-Recent: độ phổ biến gần đây trên toàn bộ H&M. Điểm của sản phẩm i là số giao dịch của nó trong W ngày trước mốc dự đoán, $\sum_{d=\tau-W}^{\tau-1} n_{i,d}$, với W chọn trên tập xác thực. Đây là mô hình đối chứng mạnh với dữ liệu thời trang có xu hướng thay đổi nhanh. Mô hình này dùng cùng nguồn doanh số với đặc trưng thời gian của NeuMF-F. So sánh với nó cho biết NeuMF-F có học được gì vượt trên xu hướng chung hay không.
- Content: khuyến nghị theo nội dung thuần. Mỗi sản phẩm được biểu diễn bằng vector văn bản nối với mã hoá one-hot của ba thuộc tính: nhóm sản phẩm, nhóm chỉ mục và nhóm may mặc. Thuộc tính màu không được dùng vì sau khi gộp các màu của một mẫu thiết kế, nó không còn phân biệt sản phẩm. Vector được chuẩn hoá về độ dài 1. Hồ sơ của khách là trung bình có trọng số các vector sản phẩm đã mua, với trọng số giảm theo thời gian theo chu kỳ bán rã (*half-life*) h ngày, $\omega = 2^{-(\tau - t_{uj})/h}$, hoặc bằng 1 nếu không dùng trọng số. Điểm là độ tương đồng cosine giữa hồ sơ và sản phẩm.
- ItemKNN và UserKNN: lọc cộng tác dựa trên láng giềng, với số láng giềng k và hệ số co chọn trên tập xác thực.
- BPR-MF: nhân tử hoá ma trận tối ưu thứ hạng theo cặp, đại diện cho MF tuyến tính được tinh chỉnh cùng ngân sách.
- Hybrid-CBCF: mô hình lai truyền thống theo kiểu lai có trọng số, áp dụng cho phản hồi ẩn. Mô hình kết hợp ba mô hình Content, UserKNN và ItemKNN ở mức điểm dự đoán, giữ nguyên cấu hình của ba thành phần như khi tinh chỉnh. Điểm của mỗi thành phần được chuẩn hoá min–max trên tập ứng viên của khách như LateFusion-F, tạo thành vector $x_{ui} = (x_{ui}^{CB}, x_{ui}^{U}, x_{ui}^{I})$. Có hai cách kết hợp:
  + Bỏ phiếu: lấy trung bình, giá trị lớn nhất hoặc nhỏ nhất của ba điểm.
  + Tổng có trọng số: $\hat{y}_{ui} = w \cdot x_{ui}$. Vì phản hồi ẩn không có điểm đánh

giá, nhóm học w theo cặp. Với mỗi sản phẩm mục tiêu p và sản phẩm ngoài tập mục tiêu j trong tập ứng viên của cùng một khách, $P(p \text{ xếp trên } j) = \sigma\big(w \cdot (x_{up} - x_{uj})\big)$. Đây là hồi quy logistic trên hiệu đặc trưng, cùng tiêu chí với BPR nhưng với hàm điểm tuyến tính.

Mô hình không có tham số khởi tạo ngẫu nhiên nên cho cùng kết quả ở mọi seed.

Most Popular, ItemKNN, UserKNN và BPR-MF chỉ dùng mã ID, như GMF, MLP và NeuMF.

3.5 Lấy mẫu âm theo thời điểm và hàm mục tiêu

3.5.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm

Phản hồi ẩn chỉ ghi nhận các tương tác đã xảy ra, không có nhãn âm tường minh. Lấy mẫu âm giả định các sản phẩm khách chưa mua nhiều khả năng là âm. Với mô hình có đặc trưng, mỗi cặp dương (u, i) mang ngày mua đầu t_{ui}, vì thế việc chọn mẫu âm cũng phải nhất quán về thời gian. Với mỗi cặp dương, quy trình huấn luyện lấy ngẫu nhiên N_{ratio} sản phẩm j trong các sản phẩm của tập huấn luyện đã ra mắt trước hoặc trong ngày t_{ui} ($d_j^0 \leq t_{ui}$), trừ những sản phẩm khách u đã mua, và gán nhãn $y_{uj} = 0$. Đặc trưng của mẫu âm được tính tại cùng ngày t_{ui}.

Ràng buộc "đã ra mắt" là cần thiết. Một sản phẩm chưa ra mắt ở ngày t_{ui} thì khách không thể mua, do đó không phải là một mẫu âm có ý nghĩa. Nếu vẫn lấy, mô hình có thể học quy luật sai "sản phẩm có cờ chưa ra mắt là âm", một tín hiệu chỉ có trong cách tạo dữ liệu huấn luyện. Với mô hình chỉ dùng ID, mẫu âm được lấy đều trong các sản phẩm có ID, trừ sản phẩm khách đã mua, như NCF gốc. N_{ratio} được tinh chỉnh trong $\{4, 8\}$. Mẫu âm được lấy lại ở mỗi epoch để mô hình thấy nhiều tổ hợp cặp âm khác nhau. Thuật toán 3.2 mô tả bước này cho mô hình có đặc trưng.

Thuật toán 3.2 Lấy mẫu âm theo thời điểm

Đầu vào: cặp dương $\mathcal{D} = \{(u, i, t)\}$; ngày bán đầu tiên d_j^0; số mẫu âm N_{ratio}
Đầu ra: các bộ huấn luyện (u, j, t, y) của một epoch

$\mathcal{P} \leftarrow$ các sản phẩm có trong $\mathcal{D}$; $\mathcal{I}_u \leftarrow$ các sản phẩm u đã mua trong $\mathcal{D}$
$\mathcal{B} \leftarrow \emptyset$
với mỗi $(u, i, t) \in \mathcal{D}$ làm
    thêm $(u, i, t, 1)$ vào $\mathcal{B}$
    $\mathcal{A}_t \leftarrow \{j \in \mathcal{P} : d_j^0 \leq t\}$ ▷ *đã ra mắt tại ngày t*
    với $n = 1, \ldots, N_{ratio}$ làm
        rút đều $j \in \mathcal{A}_t$, rút lại nếu $j \in \mathcal{I}_u$ (tối đa 20 lần)
        thêm $(u, j, t, 0)$ vào $\mathcal{B}$ ▷ *cùng ngày t với mẫu dương*
trả về $\mathcal{B}$

3.5.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm mất mát entropy chéo nhị phân được tối thiểu hoá cùng số hạng điều chuẩn L_2:

$$\mathcal{L} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_\Theta \|\Theta\|_2^2 \tag{3.10}$$

trong đó Θ là toàn bộ tham số học được (vector nhúng ID, vector nhúng thuộc tính, ma trận chiếu, tháp MLP, lớp đầu ra) và $\lambda_\Theta \in \{0;\ 10^{-6}\}$ được tinh chỉnh. Hàm mất mát được tính trên logit để ổn định số học. Các mô hình được cài đặt bằng PyTorch [19] và tối ưu bằng Adam [20] với kích thước lô (*batch size*) 512.

3.6 Quy trình huấn luyện và tinh chỉnh

3.6.1 Không gian tinh chỉnh và dừng sớm

Để mọi mô hình có cùng ngân sách tinh chỉnh, mỗi mô hình có học được thử đúng 6 cấu hình trong không gian ở Bảng 3.6. Đó là cấu hình mặc định và 5 cấu hình rút ngẫu nhiên không lặp từ lưới của mô hình, bằng một bộ sinh số ngẫu nhiên cố định. Mô hình chỉ có một tham số (MostPopular-Recent, Content, LateFusion-F) được thử đủ lưới. Mọi cấu hình được huấn luyện với seed 42 và chấm trên tập xác thực của mẫu phát triển.

Bảng 3.6: Không gian tinh chỉnh

Mô hình	Siêu tham số và giá trị thử	Cấu hình mặc định
GMF, MLP, NeuMF; GMF-F, MLP-F, NeuMF-F	tốc độ học $\{10^{-3},\ 5 \cdot 10^{-4}\}$; số chiều d $\{32, 64\}$; số mẫu âm $\{4, 8\}$; hệ số điều chuẩn L2 $\{0,\ 10^{-6}\}$; dropout của tháp MLP $\{0;\ 0{,}2\}$ (trừ GMF, GMF-F)	10^{-3}; 32; 4; 10^{-6}; 0,2
Thêm cho GMF-F, MLP-F, NeuMF-F	xác suất bỏ ID ρ $\{0;\ 0{,}25;\ 0{,}5\}$	0,25
Cố định cho mọi mạng lưới thần kinh	Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm khi NDCG@10 xác thực không cải thiện sau 5 epoch; vector nhúng thuộc tính 8 chiều, vector văn bản 64 chiều	không có
BPR-MF	d $\{32, 64, 128\}$; tốc độ học $\{0{,}01;\ 0{,}03;\ 0{,}05\}$; hệ số điều chuẩn $\{0{,}001;\ 0{,}005;\ 0{,}01\}$; số epoch $\{20, 40\}$	32; 0,03; 0,005; 20
ItemKNN, UserKNN	số láng giềng k $\{20, 50, 100, 200, 500\}$; hệ số co $\{0, 10, 50\}$	100; 0
MostPopular-Recent	cửa sổ W $\{7, 14, 28, 56, 91\}$ ngày	thử đủ lưới
Content	chu kỳ bán rã của trọng số theo thời gian $\{$không trọng số$, 30, 90, 180, 365\}$ ngày	thử đủ lưới
LateFusion-F	w $\{0;\ 0{,}1;\ \ldots;\ 1\}$ trên GMF-F và MLP-F tốt nhất	thử đủ lưới
Hybrid-CBCF (bổ sung)	cách kết hợp: trung bình, lớn nhất, nhỏ nhất, tổng có trọng số học theo cặp	thử cả bốn

Sau mỗi epoch, mạng được chấm NDCG@10 trên tập xác thực bằng cách xếp hạng toàn bộ. Trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi độ đo không cải thiện sau 5 epoch liên tiếp (*patience* $P = 5$). Số epoch tốt nhất e^* được ghi lại để dùng khi huấn luyện lại. Trước khi dự đoán cho giai đoạn kiểm thử, mô hình được huấn luyện lại từ đầu trên mọi cặp trước mốc kiểm thử đúng e^* epoch. Lúc này không còn tập xác thực để dừng, và tập kiểm thử không bao giờ được dùng để dừng. Thuật toán 3.3 tóm tắt quá trình này.

Thuật toán 3.3 Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch

Đầu vào: cấu hình θ, seed s; $\mathcal{D}_{\tau_{val}}$ và tập xác thực V; $\mathcal{D}_{\tau_{test}}$; $E_{max} = 20$; $P = 5$
Đầu ra: mô hình f^* và số epoch e^*

hàm HuấnLuyện($\mathcal{D}, E, V$)
    khởi tạo f theo θ và s; $b \leftarrow -\infty$; $e^* \leftarrow 0$; $c \leftarrow 0$
    với $e = 1, \ldots, E$ làm
        lấy lại mẫu âm theo Thuật toán 3.2; một lượt Adam theo BCE, lô 512
        nếu $V = \emptyset$ thì ▷ *huấn luyện lại: chạy đủ E epoch*
            $e^* \leftarrow e$
        ngược lại nếu NDCG@10 của f trên V lớn hơn b thì
            $b \leftarrow$ NDCG@10 đó; $e^* \leftarrow e$; lưu trọng số; $c \leftarrow 0$
        ngược lại
            $c \leftarrow c + 1$; dừng nếu $c = P$
    trả về f (trọng số đã lưu nếu $V \neq \emptyset$), e^*
$(\cdot, e^*) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{val}}, E_{max}, V$) ▷ *chọn số epoch*
$(f^*, \cdot) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{test}}, e^*, \emptyset$) ▷ *huấn luyện lại từ đầu*
trả về f^*, e^*

3.7 Quy trình đánh giá không thiên lệch

Trước khi xây dựng mô hình đề xuất, nhóm khảo sát NeuMF chỉ dùng mã ID trên mẫu phát triển. NeuMF chỉ dùng ID không vượt BPR-MF đã tinh chỉnh, nên nhóm chọn bổ sung thông tin cho mô hình thay vì thêm tham số, và đây là cơ sở để xây dựng NeuMF-F. Khảo sát cũng cho thấy ở quy mô mẫu này, khả năng khuyến nghị sản phẩm chưa từng bán hầu như không đo được, nên tập ứng viên chỉ giữ sản phẩm đã có dữ liệu huấn luyện. Để kết luận không bị ảnh hưởng bởi những gì đã thấy khi khảo sát, kết luận chỉ được lấy trên một mẫu khách hàng chưa từng được dùng.

Khi đánh giá mô hình khuyến nghị học sâu, Ferrari Dacrema và cộng sự [21] chỉ ra hai lỗi thường gặp: chọn số epoch hay cấu hình dựa trên chính tập kiểm thử, và tinh chỉnh mô hình đối chứng sơ sài. Rủi ro thứ ba là sau khi đã xem tập kiểm thử, các quyết định tiếp theo dễ bị ảnh hưởng bởi kết quả đã thấy. Quy trình đánh giá của đề tài tránh ba rủi ro này bằng sáu nguyên tắc dưới đây, tóm tắt trong Hình 3.5. Quy trình chỉ gọi lại các bước huấn luyện và suy luận của quy trình ở Hình 3.1 với những mốc thời gian khác nhau, rồi so danh sách khuyến nghị với những gì khách đã mua thật.

- Tách mẫu phát triển và mẫu kiểm định. Mọi lựa chọn mô hình, siêu tham số và số epoch dựa trên tập xác thực:
  + Tinh chỉnh trên tập xác thực của mẫu phát triển.
  + Chọn số epoch khi đánh giá cuối trên tập xác thực của mẫu kiểm định.
  + Tập kiểm thử của mẫu kiểm định chỉ được mở một lần, ở đánh giá cuối.
- Đăng ký trước và khoá tập kiểm thử. Kế hoạch thực nghiệm được ghi lại trước khi có kết quả tinh chỉnh của mô hình có đặc trưng nào. Kế hoạch gồm mô hình đề xuất, danh sách mô hình, lưới tinh chỉnh, số seed, độ đo chính, họ 10 phép so sánh và tiêu chí kết luận. Tập kiểm thử chỉ được dựng sau khi kế hoạch đã cố định. Kiểm chứng trên Amazon Beauty và phân tích bổ sung với Hybrid-CBCF có kế hoạch riêng theo cùng cách.
- Cùng ngân sách tinh chỉnh. Mọi mô hình có tham số học được đều được thử 6 cấu hình.
- Huấn luyện lại trước khi chấm. Với mỗi seed (42, 2024, 2025, 2026, 3407):
  + Mỗi mạng lưới thần kinh được huấn luyện trên dữ liệu trước 01/07/2020 của mẫu kiểm định, và số epoch e^* được chọn bằng dừng sớm theo NDCG@10 trên tập xác thực của chính mẫu này.
  + Sau đó mô hình được huấn luyện lại từ đầu trên mọi cặp trước 29/07/2020 đúng e^* epoch rồi mới chấm tập kiểm thử.
  + BPR-MF và các mô hình không phải mạng lưới thần kinh được khớp trên mọi cặp trước 29/07/2020. LateFusion-F trộn GMF-F và MLP-F đã huấn luyện lại ở cùng seed.
- Kiểm định thống kê. Với mỗi khách được đánh giá, NDCG@10 được lấy trung bình qua 5 seed. Dao động giữa các seed được báo cáo riêng bằng độ lệch chuẩn.
  + Từng cặp mô hình được so sánh bằng kiểm định dấu hạng Wilcoxon ghép cặp theo người dùng [22] và khoảng tin cậy 95% của hiệu trung bình bằng bootstrap ghép cặp với 10.000 lần lấy mẫu lại [23].
  + Giá trị p được hiệu chỉnh Holm [24] trên một họ 10 so sánh đăng ký trước.
  + Chín so sánh đầu đặt NeuMF-F cạnh chín mô hình: NeuMF, GMF-F,

MLP-F, LateFusion-F, BPR-MF, ItemKNN, UserKNN, Content và MostPopular-Recent. So sánh với NeuMF đo lợi ích của đặc trưng, với GMF-F và MLP-F đo lợi ích của việc ghép hai nhánh, với LateFusion-F đặt hợp nhất sớm cạnh hợp nhất muộn.

+ So sánh thứ mười đặt mô hình lai chỉ dùng ID (NeuMF) cạnh MF (BPR-MF).

– Tiêu chí kết luận cố định. Kết luận "A tốt hơn B" chỉ được viết khi đồng thời $p_{\text{Holm}} < 0{,}05$, khoảng tin cậy không chứa 0 và chênh lệch tương đối NDCG@10 không dưới 5%. Các trường hợp còn lại được kết luận là "không khác biệt có ý nghĩa". Ngưỡng 5% là mức cải thiện tối thiểu có ý nghĩa thực tiễn, đặt theo quy ước.



Hình 3.5: Quy trình tinh chỉnh và đánh giá cuối

Ngoài họ so sánh trên, phân tích bóc tách chỉ chạy một seed, được báo cáo kèm

khoảng tin cậy nhưng không kiểm định và không dùng để kết luận chính. Độ phủ, số epoch và thời gian huấn luyện cũng chỉ mang tính mô tả.

Thuật toán 3.4 mô tả cách mọi mô hình được chấm trên một giai đoạn. Để phép so sánh công bằng:

- Mọi mô hình dùng cùng tập ứng viên $\mathcal{C}_u$, cùng tập sản phẩm mục tiêu T_u và bốn độ đo HR, Precision, Recall, NDCG.
- Khi hai sản phẩm bằng điểm (*tie-breaking*), thứ tự được quyết định bởi một khoá cố định $h(u, i)$, là giá trị băm của cặp (u, i) sinh từ seed 2026. Nhờ vậy chênh lệch giữa hai mô hình chỉ đến từ điểm số của chúng.
- Hạng của từng sản phẩm mục tiêu được lưu theo từng khách, nên độ đo ở một K bất kỳ có thể tính lại mà không phải chấm lại tập kiểm thử.

Thuật toán 3.5 chọn trọng số trộn của LateFusion-F chỉ trên tập xác thực của mẫu phát triển. Trọng số này (w=0,4 (GMF-F), $1 - w$=0,6 (MLP-F)) được giữ nguyên ở đánh giá cuối.

Thuật toán 3.4 Đánh giá bằng xếp hạng toàn bộ tập ứng viên

Đầu vào: hàm điểm $s(u, i)$; tập khách $\mathcal{U}_{eval}$, mỗi khách có $\mathcal{C}_u$ và T_u; các giá trị K
Đầu ra: độ đo trung bình theo khách; hạng R_u của các sản phẩm mục tiêu

với mỗi $u \in \mathcal{U}_{eval}$ làm
    tính $s(u, i)$ với mọi $i \in \mathcal{C}_u$ ▷ *mạng lưới thần kinh: dùng logit*
    sắp $\mathcal{C}_u$ giảm dần theo $s(u, i)$; bằng điểm thì theo khoá cố định $h(u, i)$
    $R_u \leftarrow$ hạng của các $i \in T_u$ trong danh sách đã sắp; lưu R_u
    tính HR@K, Precision@K, Recall@K, NDCG@K của u từ R_u với mỗi K
trả về trung bình các độ đo trên $\mathcal{U}_{eval}$; các R_u

Thuật toán 3.5 Chọn trọng số của LateFusion-F

Đầu vào: GMF-F, MLP-F đã chọn khi tinh chỉnh; tập xác thực V; lưới $W = \{0;\ 0{,}1;\ \ldots;\ 1\}$

Đầu ra: trọng số w^*

với mỗi khách u của V làm

  $a_u \leftarrow \text{minmax}\big(s^{\text{GMF-F}}(u, \mathcal{C}_u)\big);\ b_u \leftarrow \text{minmax}\big(s^{\text{MLP-F}}(u, \mathcal{C}_u)\big)$

với mỗi $w \in W$ làm

  $N(w) \leftarrow$ NDCG@10 trên V của điểm $w\, a_u + (1 - w)\, b_u$ ▷ *Thuật toán 3.4*

trả về $w^* = \arg\max_{w \in W} N(w)$

Thuật toán 3.6 chọn cách kết hợp của Hybrid-CBCF, cũng chỉ trên tập xác thực của mẫu phát triển:

- Ba cách bỏ phiếu (trung bình, lớn nhất, nhỏ nhất) được chấm trực tiếp bằng NDCG@10.
- Cách tổng có trọng số học w bằng hồi quy logistic có điều chuẩn L_2, không hệ số chặn. Mỗi sản phẩm mục tiêu được ghép với $m = 50$ sản phẩm ngoài tập mục tiêu, rút bằng một seed cố định. Để so công bằng với các cách bỏ phiếu, khách được chia làm hai nửa, và trọng số dùng để chấm một khách luôn được học trên nửa còn lại.

Ba mô hình thành phần được khớp trên dữ liệu trước mốc xác thực. Cách kết hợp và trọng số được chọn giữ nguyên khi đánh giá trên mẫu kiểm định và trên Amazon Beauty.

Thuật toán 3.6 Chọn cách kết hợp của Hybrid-CBCF

Đầu vào: Content, UserKNN, ItemKNN đã tinh chỉnh; tập xác thực V; $m = 50$
Đầu ra: cách kết hợp F^*; trọng số w^* nếu F^* là tổng có trọng số

$x_{ui} \leftarrow$ ba điểm đã chuẩn hoá min–max trên $\mathcal{C}_u$, với mọi $u \in V$, $i \in \mathcal{C}_u$
với $F \in \{\text{trung bình}, \max, \min\}$ làm ▷ *bỏ phiếu*
    $N(F) \leftarrow$ NDCG@10 trên V của điểm $F(x_{ui})$
chia khách của V thành P_0, P_1 theo chỉ số chẵn, lẻ ▷ *cross-fitting*
với $k \in \{0, 1\}$ làm
    $w_k \leftarrow$ HọcTrọngSố($V \setminus P_k$); chấm khách $u \in P_k$ bằng $w_k \cdot x_{ui}$
$N(\text{trọng số}) \leftarrow$ NDCG@10 trên V của điểm vừa chấm
$F^* \leftarrow \arg\max_F N(F)$
nếu F^* là tổng có trọng số thì
    $w^* \leftarrow$ HọcTrọngSố(V)
trả về F^*, w^*

hàm HọcTrọngSố(tập khách S)
    với mỗi sản phẩm mục tiêu p của $u \in S$: rút m sản phẩm ngoài tập mục tiêu $j \in \mathcal{C}_u$
    trả về hồi quy logistic (L_2, không hệ số chặn) trên các hiệu $\pm(x_{up} - x_{uj})$

3.8 Suy luận Top-K và xử lý khách hàng mới

Bước cuối của quy trình là suy luận. Với một khách hàng và một số K cho trước, hệ thống trả về K sản phẩm có điểm cao nhất. Thuật toán 3.7 mô tả bước này, và hệ thống demo thực hiện suy luận theo đúng các bước đó. Với khách đã có trong dữ liệu đã học, đây là các bước chấm điểm và sắp xếp giống như khi đánh giá, chỉ khác là không có sản phẩm mục tiêu để so sánh. Vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần khi nạp mô hình, vì thế mỗi yêu cầu khuyến nghị chỉ còn một lượt lan truyền thuận trên các sản phẩm ứng viên của khách.

Khách hàng mới là tình huống *cold start* của người dùng. Mô hình chỉ có vector nhúng ID và đặc trưng thời gian cho khách đã có trong dữ liệu đã học, nên hệ thống xử lý theo hai trường hợp:

- Khách đã có lịch sử mua trong dữ liệu đã học: dùng NeuMF-F.
- Khách chưa mua gì, hoặc mua quá ít để qua bước lọc 10-core: trả về các

sản phẩm được nhiều khách mua nhất trước mốc, chính là mô hình Most Popular.

Với quy tắc này, mọi yêu cầu đều nhận được một danh sách khuyến nghị.

Thuật toán 3.7 Suy luận Top-K cho một khách hàng

Đầu vào: mã khách c; số khuyến nghị K; NeuMF-F đã lưu; danh sách phổ biến L_{pop}
Đầu ra: K sản phẩm khuyến nghị

1: nếu c không có trong dữ liệu đã học thì ▷ *khách mới*
2: trả về K sản phẩm đầu của L_{pop}
3: $u \leftarrow$ mã nội bộ của c; $\mathcal{C}_u \leftarrow \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau)$ ▷ *bỏ sản phẩm đã mua*
4: $s_{ui} \leftarrow h^\top \left[p_u^G \odot q_i^G;\ \mathrm{MLP}([p_u^M;\ q_i^M]) \right]$ với mọi $i \in \mathcal{C}_u$
5: trả về K sản phẩm có s_{ui} lớn nhất (bằng điểm: theo khoá cố định)

3.9 Thiết kế hệ thống demo

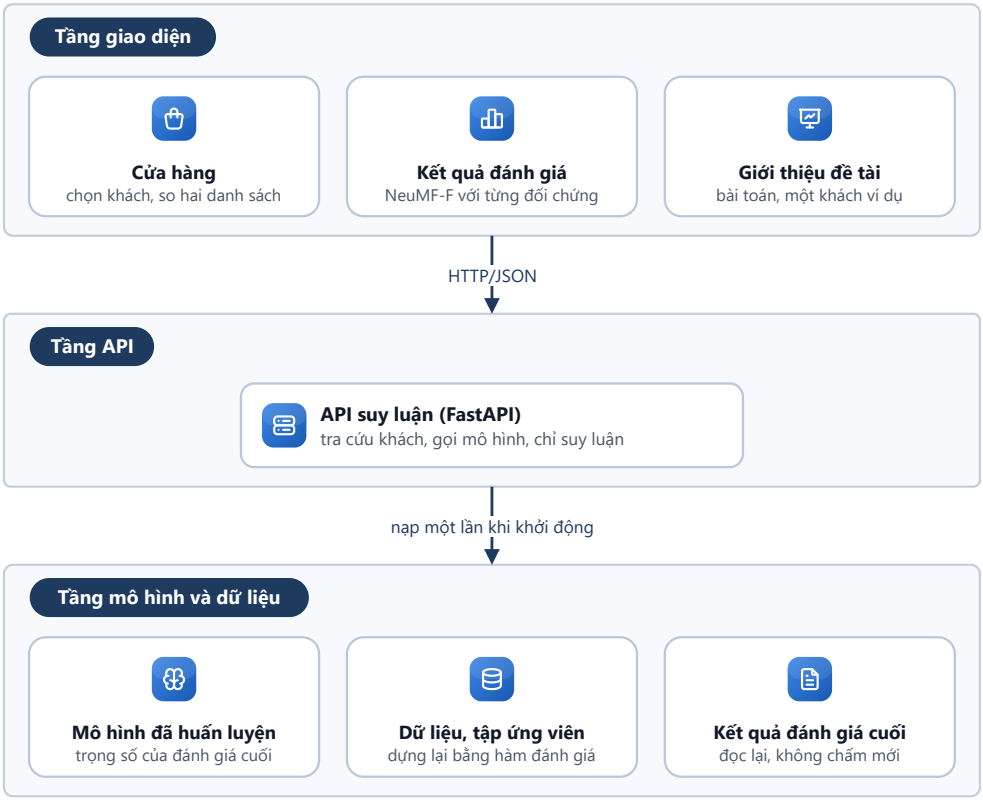
Hệ thống demo minh hoạ các mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt với phần huấn luyện: nó chỉ nạp trọng số mô hình đã lưu và gọi lại các hàm xử lý dữ liệu, xếp hạng của quy trình đánh giá.

3.9.1 Kiến trúc ba tầng

Demo gồm ba tầng, được thể hiện trong Hình 3.6:

- Giao diện: trang web tĩnh với ba màn hình là cửa hàng mô phỏng, kết quả đánh giá và giới thiệu đề tài. Giao diện chỉ gọi API, không đọc trực tiếp trọng số hay dữ liệu.
- API suy luận: viết bằng FastAPI, chỉ suy luận, không huấn luyện.
- Mô hình và dữ liệu: khi khởi động, tầng này dựng lại dữ liệu của mẫu kiểm định bằng các hàm của đánh giá cuối, nạp trọng số đã huấn luyện và đọc kết quả đánh giá đã lưu.

Vì suy luận được tách khỏi huấn luyện, thời gian phản hồi không phụ thuộc vào chi phí huấn luyện. Với khách đã được đánh giá, demo hiện kèm kết quả đã lưu để người xem đối chiếu.



Hình 3.6: Kiến trúc ba tầng của hệ thống demo

3.9.2 Thiết kế API suy luận

Chức năng chính của API là khuyến nghị Top-K. Các điểm cuối khác phục vụ việc tra cứu khách, sản phẩm và kết quả, được liệt kê trong Bảng 3.7. Chức năng khuyến nghị chạy các bước suy luận Top-K ở trên và dùng lại các hàm của quy trình đánh giá. Kết quả được ánh xạ về mẫu thiết kế (`product_code`) kèm tên, loại sản phẩm, số màu và ảnh của biến thể đại diện trước khi trả về giao diện.

Bảng 3.7: Các điểm cuối của API suy luận

Điểm cuối	Chức năng
`GET /api/users/search, /random`	Tìm hoặc chọn ngẫu nhiên một khách hàng.
`GET /api/users/{id}/history`	Lịch sử mua mà mô hình đã học, sắp theo thời gian.
`GET /api/users/{id}/recommend`	Top-K của một mô hình ($K \in \{10, 15, 20\}$), hạng của từng sản phẩm đích và độ đo của khách đó. Khách mới nhận danh sách sản phẩm bán chạy.
`GET /api/users/{id}/neighbors, /api/items/{id}/similar`	Khách có gu giống nhất theo UserKNN và sản phẩm tương tự nhất theo ItemKNN.
`GET /api/results`	Kết quả đánh giá cuối: NDCG@10 của từng mô hình, kết luận kiểm định, kết quả bóc tách.

3.9.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng

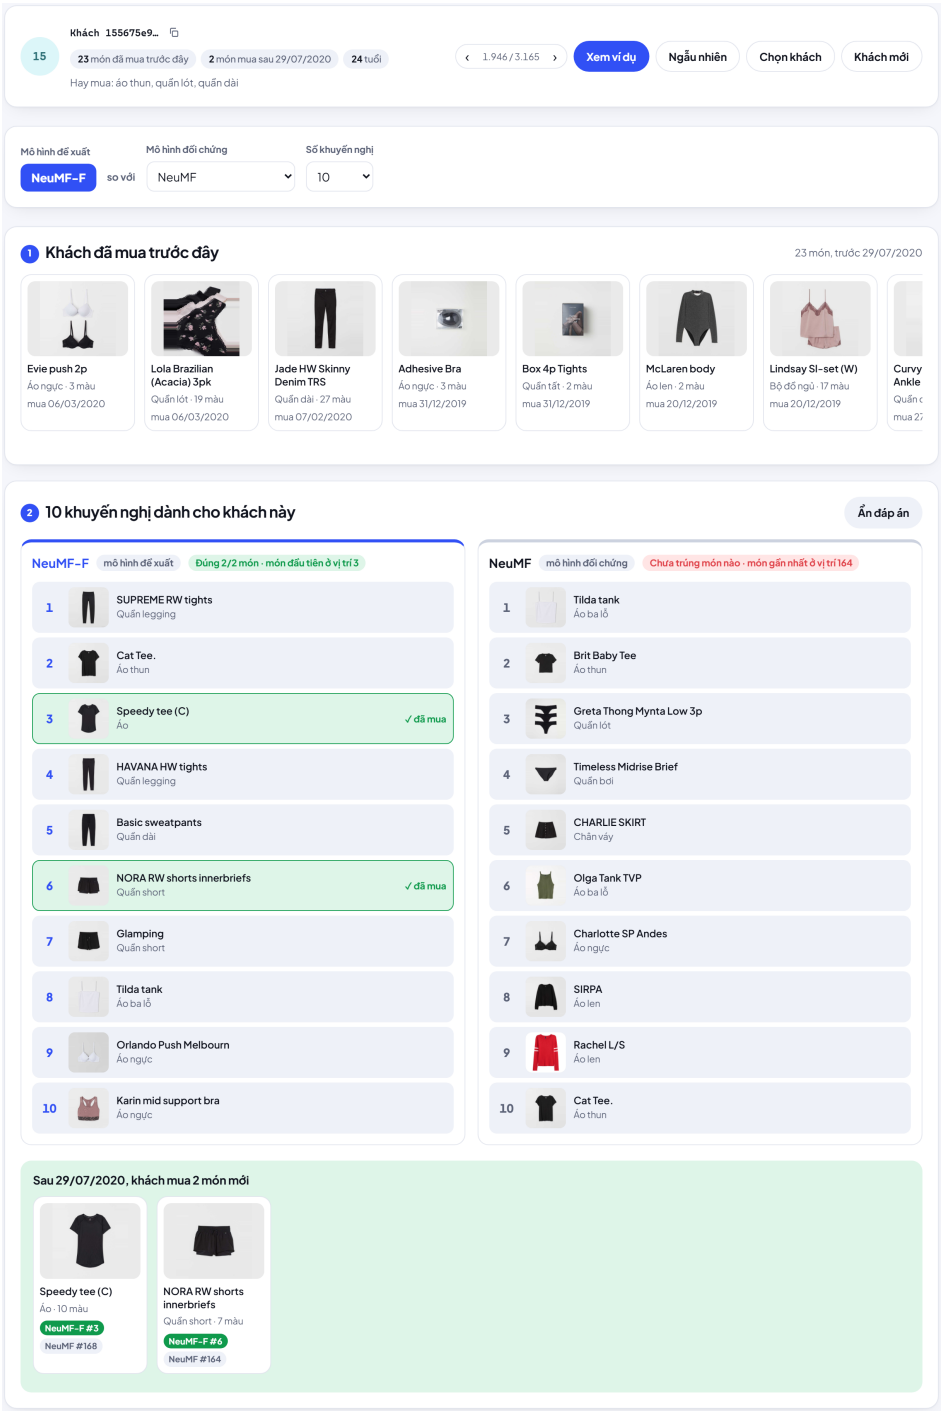
Trong demo, NeuMF-F luôn là mô hình chính. Người xem chọn một mô hình đối chứng để đặt cạnh NeuMF-F, gồm các mô hình của đánh giá cuối (trừ Random) và Hybrid-CBCF. Mặc định là NeuMF chỉ dùng ID, để thấy tác dụng của đặc trưng trên cùng một khách. Demo dùng trọng số của seed 42, nên hạng và độ đo của từng khách có thể khác đôi chút so với trung bình 5 seed.

Về yêu cầu phi chức năng, vector của mọi khách và sản phẩm tại mốc dự đoán được tính một lần khi nạp. Mỗi yêu cầu khuyến nghị chỉ là một lượt lan truyền thuận trên khoảng 6.710 ứng viên. Một yêu cầu Top-10 của NeuMF-F mất trung vị 10 ms, tính cả thời gian xử lý của API.

3.9.4 Minh hoạ hệ thống demo

Demo được thiết kế như một cửa hàng trực tuyến, để người xem thấy mô hình khuyến nghị hoạt động trên từng khách trước khi xem số liệu tổng hợp. Màn hình chính là cửa hàng mô phỏng, thể hiện trong Hình 3.7. Người xem chọn một khách bằng mã khách, ngẫu nhiên, hoặc bằng nút khách ví dụ. Cửa hàng hiện những sản phẩm khách đã mua trước mốc kiểm thử, cũng là dữ liệu mô hình đã học, và K sản phẩm được khuyến nghị. Danh sách của NeuMF-F nằm bên trái, danh sách của mô hình đối chứng nằm bên phải. Khi bấm nút “Xem khách đã mua gì”, những sản phẩm

khách thật sự mua sau mốc được tô màu, kèm thứ hạng của chúng trong danh sách của từng mô hình.

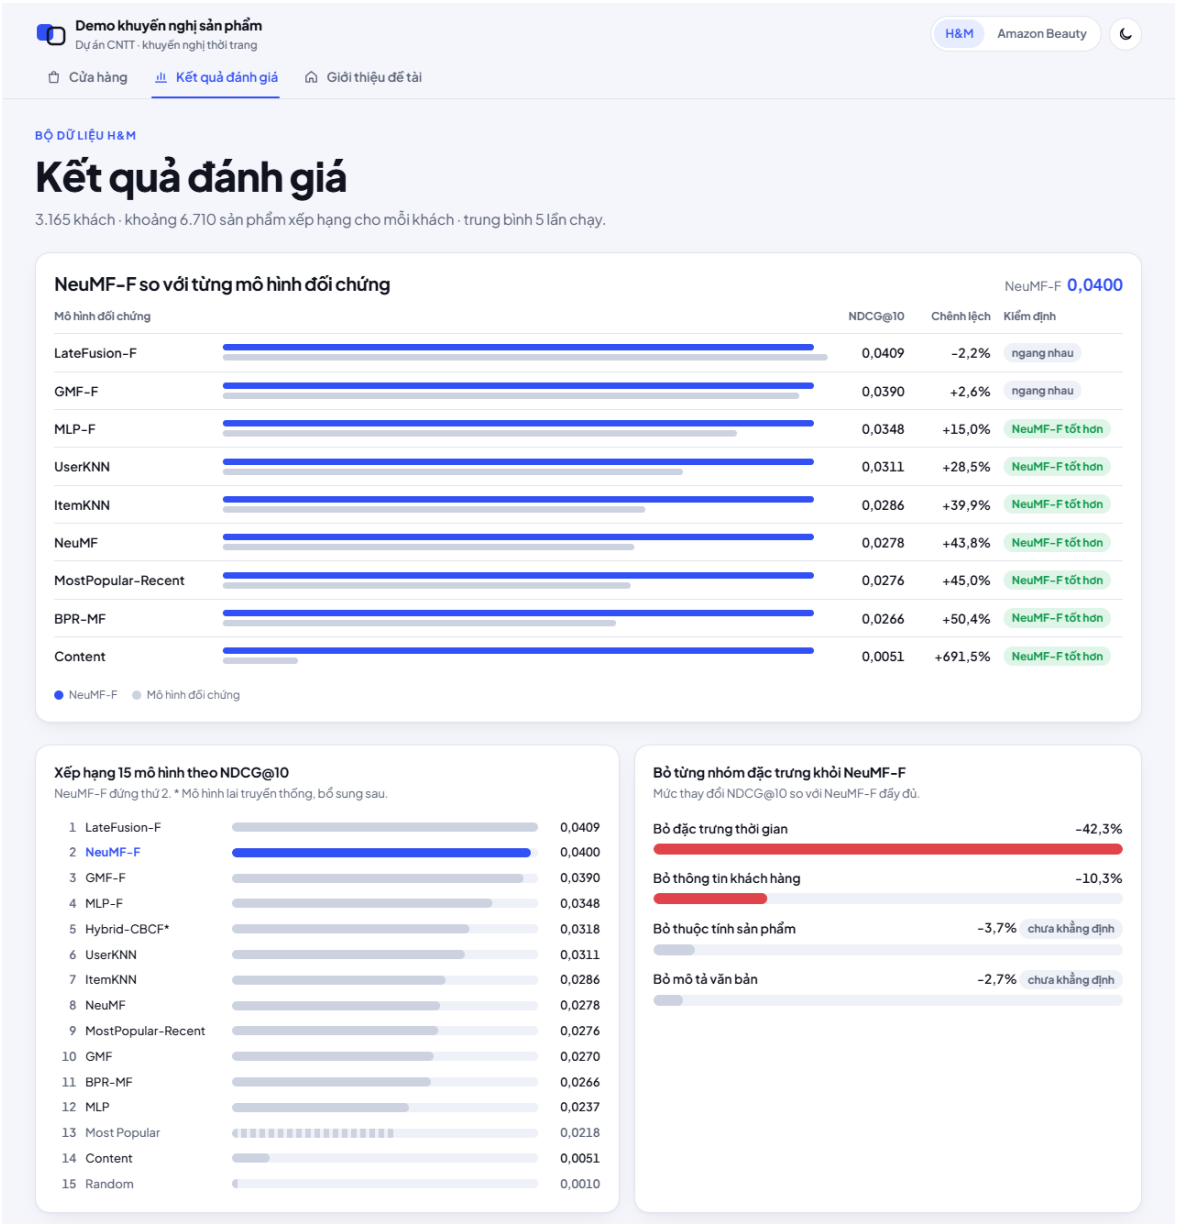


Hình 3.7: Giao diện demo: cửa hàng mô phỏng, đã hiện các món khách mua sau mốc

Bấm vào một sản phẩm sẽ mở thẻ chi tiết gồm mô tả gốc, số khách đã mua và các sản phẩm tương tự theo ItemKNN. Phía dưới cửa hàng là danh sách khách có gu giống khách đang xem theo UserKNN, minh hoạ cách lọc cộng tác dựa trên láng

giềng chọn ra khuyến nghị. Khách mới chưa có trong dữ liệu đã học nhận danh sách sản phẩm bán chạy kèm nhãn rõ ràng.

Màn hình kết quả đánh giá tổng hợp trên toàn bộ khách của mẫu kiểm định, như Hình 3.8. Phần đầu đặt NeuMF-F cạnh từng mô hình đối chứng với kết luận kiểm định. Phần dưới xếp hạng mọi mô hình theo NDCG@10 và cho biết mức giảm khi bỏ từng nhóm đặc trưng. Màn hình thứ ba giới thiệu bài toán qua một khách ví dụ.



Hình 3.8: Giao diện demo: màn hình kết quả đánh giá

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Thiết lập thực nghiệm

Thực nghiệm chính trên H&M gồm hai bước:

- Tinh chỉnh mọi mô hình trên tập xác thực của mẫu phát triển.
- Đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định.

Độ đo chính là NDCG@10 lấy trung bình theo khách. Các độ đo còn lại được báo cáo ở $K = 10, 15, 20$, mỗi kết quả gồm giá trị trung bình và độ lệch chuẩn qua 5 seed. Đề tài không dùng $K = 5$, vì mỗi khách chỉ có vài sản phẩm mục tiêu giữa hàng nghìn ứng viên. Danh sách 5 sản phẩm quá ngắn để khuyến nghị đúng, và độ đo ở mức này dao động giữa các seed nhiều hơn.

Để phép so sánh công bằng, mô hình đề xuất và mọi mô hình đối chứng được chạy trong cùng một điều kiện, liệt kê trong Bảng 4.1. Các mô hình chỉ khác nhau ở bản thân mô hình và ở cấu hình được chọn trên tập xác thực. Kiểm chứng trên Amazon Beauty giữ nguyên các điều kiện này, trừ mốc thời gian và bộ đặc trưng, và không tinh chỉnh lại.

Bảng 4.1: Điều kiện thực nghiệm chung của các mô hình

Thành phần	Thiết lập chung
Dữ liệu và cách chia	Cùng mẫu khách hàng, cùng bước lọc 10-core trước mốc kiểm thử. Chia theo thời gian: huấn luyện trước 01/07/2020, xác thực từ 01/07 đến 28/07/2020, kiểm thử từ 29/07 đến 22/09/2020.
Tập ứng viên	Mọi sản phẩm có dữ liệu huấn luyện mà khách chưa mua, giống nhau cho mọi mô hình. Sản phẩm bằng điểm được xếp theo một khoá cố định.
Đặc trưng	GMF-F, MLP-F, NeuMF-F và LateFusion-F dùng cùng bộ đặc trưng. GMF, MLP, NeuMF, BPR-MF, ItemKNN, UserKNN và Most Popular chỉ dùng mã ID.
Seed	Seed 42 khi tinh chỉnh. Năm seed 42, 2024, 2025, 2026, 3407 ở đánh giá cuối, giống nhau cho mọi mô hình.
Tinh chỉnh	Mỗi mô hình có học thử 6 cấu hình, mô hình chỉ có một tham số thử đủ lưới. Cấu hình được chọn theo NDCG@10 trên tập xác thực của mẫu phát triển.
Kiến trúc chung của mạng lưới thần kinh	Cùng số chiều vector nhúng $d \in \{32, 64\}$. MLP, MLP-F, NeuMF và NeuMF-F dùng cùng tháp 3 lớp ẩn $[2d \to d \to d/2 \to d/4]$ với ReLU. Lớp đầu ra dùng hàm sigmoid.
Huấn luyện mạng lưới thần kinh	Hàm mất mát BCE, lấy mẫu âm theo thời điểm, Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm sau 5 epoch không cải thiện, huấn luyện lại đúng số epoch đã chọn.
Đánh giá	Xếp hạng toàn bộ tập ứng viên. Độ đo chính NDCG@10. Recall, HR, Precision và NDCG ở $K = 10, 15, 20$. Kiểm định Wilcoxon, khoảng tin cậy bootstrap, hiệu chỉnh Holm.
Môi trường phần mềm	Python 3.12, PyTorch 2.6, NumPy, pandas, SciPy, scikit-learn. Mọi mô hình chạy trên cùng mã nguồn đánh giá.
Phần cứng	Đánh giá cuối trên H&M và Amazon Beauty chạy trên cùng một máy: CPU AMD Ryzen 7 6800H with Radeon Graphics, GPU NVIDIA GeForce RTX 3050 Laptop GPU. Thời gian huấn luyện trong các bảng được đo trên máy này. Riêng Hybrid-CBCF, phần bổ sung sau, chạy trên CPU 11th Gen Intel Core i5-1135G7 @ 2.40GHz.

4.2 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển

Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển được trình bày trong Bảng 4.2. Bảng này cho thấy:

- Bốn mô hình có đặc trưng đứng đầu, trong đó LateFusion-F và NeuMF-F dẫn đầu.
- Không tính Hybrid-CBCF, mô hình đối chứng không dùng mạng lưới thần kinh cao nhất là UserKNN, tiếp theo là BPR-MF và ItemKNN.
- NeuMF-F và MLP-F đều chọn xác suất bỏ ID bằng 0, chỉ GMF-F chọn 0,25. Cơ chế bỏ ID ngẫu nhiên vì vậy không có trong cấu hình cuối của mô hình đề xuất.

Các số trong bảng chỉ dùng để chọn cấu hình, không dùng để kết luận. Trong cột cấu hình, d là số chiều vector nhúng, lr là tốc độ học, neg là số mẫu âm cho mỗi mẫu dương. Wd và reg là hệ số điều chuẩn, shrink là hệ số co của hai mô hình láng giềng, còn "bỏ ID" là xác suất bỏ vector nhúng ID của sản phẩm.

Dòng Hybrid-CBCF (đánh dấu *) là mô hình bổ sung, được chọn cấu hình sau cùng như trình bày dưới đây.

Bảng 4.2: Cấu hình tốt nhất trên tập xác thực

Mô hình	Cấu hình chọn	NDCG@10	HR@10
NeuMF-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03337	0,12807
LateFusion-F	w=0,4 (GMF-F), $1-w$=0,6 (MLP-F)	0,03556	0,14480
GMF-F	d=32; lr=0,001; neg=8; wd=0; bỏ ID=0,25	0,03162	0,13157
MLP-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03212	0,13429
NeuMF	d=64; lr=0,0005; neg=4; wd=10^{-6}; dropout=0,2	0,02696	0,11016
GMF	d=32; lr=0,001; neg=8; wd=10^{-6}	0,02857	0,11405
MLP	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0	0,02742	0,10977
BPR-MF	d=128; lr=0,03; reg=0,001; 20 epoch	0,02636	0,10666
ItemKNN	k=100; shrink=50	0,02599	0,09537
UserKNN	k=200; shrink=0	0,02753	0,10432
Content	chu kỳ bán rã 30 ngày	0,00459	0,02180
MostPopular-Recent	cửa sổ 28 ngày	0,02334	0,10432
Most Popular	—	0,02174	0,09420
Hybrid-CBCF*	tổng có trọng số học theo cặp: Content 0,12; UserKNN 0,60; ItemKNN 0,28	0,02815	0,10588

Với Hybrid-CBCF, nhóm chọn tổng có trọng số học theo cặp, vì đây là cách kết hợp tốt nhất trên tập xác thực và là cách duy nhất vượt thành phần mạnh nhất. Bảng 4.3 đặt ba thành phần đứng riêng cạnh bốn cách kết hợp, giá trị cao nhất mỗi cột in đậm:

- Bỏ phiếu lấy trung bình thấp hơn UserKNN đứng riêng, vì Content rất yếu nhưng vẫn nhận trọng số ngang hai thành phần còn lại. Lấy giá trị lớn nhất hoặc nhỏ nhất còn kém hơn.
- Trong trọng số học được, lọc cộng tác giữ vai trò chính (UserKNN 0,60 và ItemKNN 0,28), còn lọc nội dung chỉ chiếm 0,12.

NDCG@10 của Content trong bảng này lệch nhẹ so với bảng kết quả tinh chỉnh do vector văn bản được tính lại, nhưng thứ hạng của Content không đổi.

Bảng 4.3: Các cách kết hợp của Hybrid-CBCF

Mô hình	NDCG@10	HR@10
Thành phần đứng riêng		
Content	0,00435	0,02141
UserKNN	0,02753	0,10432
ItemKNN	0,02599	0,09537
Hybrid-CBCF theo cách kết hợp		
Bỏ phiếu: trung bình	0,02634	0,10004
Bỏ phiếu: lớn nhất	0,01483	0,05411
Bỏ phiếu: nhỏ nhất	0,02143	0,08447
Tổng có trọng số học theo cặp (được chọn)	0,02815	0,10588

4.3 Kết quả đánh giá cuối trên mẫu kiểm định

4.3.1 So sánh các độ đo xếp hạng

Kết quả trên tập kiểm thử được trình bày trong Bảng 4.4 và Hình 4.1:

- Bốn mô hình có đặc trưng đứng đầu, giống trên tập xác thực. LateFusion-F đạt NDCG@10 cao nhất (0,04093), tiếp theo là NeuMF-F, rồi GMF-F và MLP-F.
- Mô hình đứng ngay sau nhóm này là UserKNN.
- NeuMF chỉ dùng ID thấp hơn rõ so với cùng kiến trúc khi có đặc trưng.
- Với NeuMF-F, khoảng 15% số khách có ít nhất một sản phẩm mục tiêu trong 10 khuyến nghị đầu.

Thứ hạng nêu trong chương tính trên 14 mô hình đăng ký trước. Hybrid-CBCF (đánh dấu *) không thuộc họ 10 so sánh và được bàn riêng trong phân tích bổ sung.

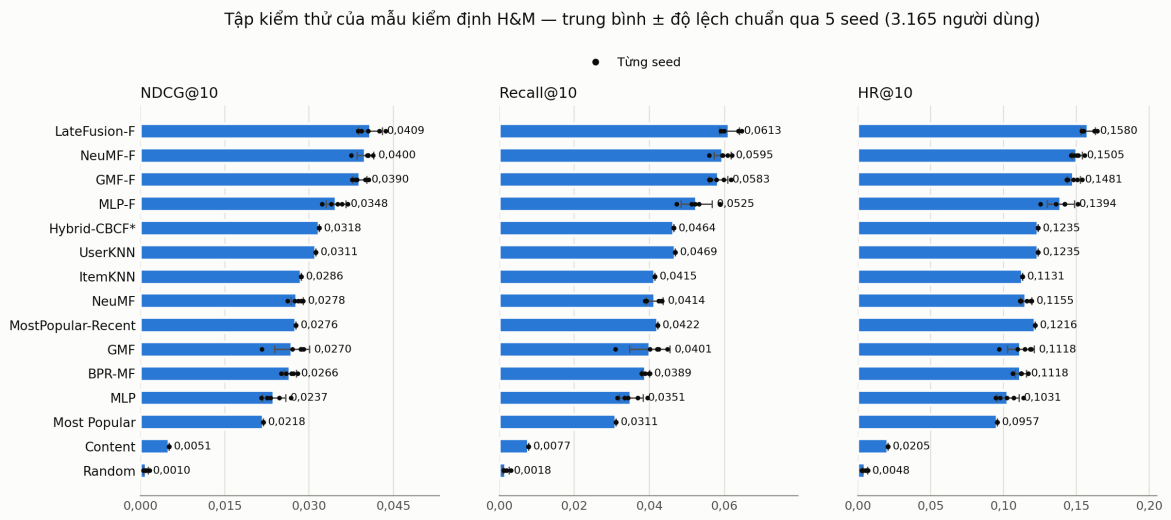
Trong bảng, các mô hình được xếp theo ba nhóm mô hình đối chứng. Mỗi ô có hai dòng: dòng trên là giá trị trung bình, dòng dưới là độ lệch chuẩn qua 5 seed, tính trên 3.165 khách được đánh giá. Các mô hình không có bước ngẫu nhiên khi huấn luyện, gồm UserKNN, ItemKNN, Content, hai mô hình phổ biến và Hybrid-CBCF, cho cùng một kết quả ở mọi seed nên có độ lệch chuẩn bằng 0. Giá trị cao nhất của mỗi cột được in đậm.

Giá trị tuyệt đối của các độ đo thấp vì mỗi khách chỉ có vài sản phẩm mục tiêu giữa hàng nghìn ứng viên. Đoán trước những món khách sẽ mua lần đầu trong 8 tuần

tới cũng là bài toán khó với hàng thời trang. Khi đọc bảng, cần chú ý tới thứ hạng tương đối giữa các mô hình và việc chênh lệch có ý nghĩa thống kê hay không, hơn là giá trị tuyệt đối.

Bảng 4.4: Kết quả trên tập kiểm thử H&M

Mô hình	NDCG @10	Recall @10	HR @10	Precision @10
Mô hình đề xuất				
NeuMF-F	0,04003 ± 0,00147	0,05953 ± 0,00226	0,15046 ± 0,00354	0,01723 ± 0,00027
Nhóm 1: mô hình đơn lẻ				
GMF-F	0,03902 ± 0,00124	0,05834 ± 0,00243	0,14812 ± 0,00452	0,01712 ± 0,00049
MLP-F	0,03480 ± 0,00177	0,05251 ± 0,00417	0,13940 ± 0,00943	0,01584 ± 0,00096
GMF	0,02695 ± 0,00311	0,04007 ± 0,00539	0,11179 ± 0,00909	0,01243 ± 0,00121
MLP	0,02373 ± 0,00207	0,03510 ± 0,00316	0,10306 ± 0,00765	0,01129 ± 0,00092
Nhóm 2: học máy truyền thống				
Hybrid-CBCF*	0,03183 ± 0,00000	0,04641 ± 0,00000	0,12354 ± 0,00000	0,01362 ± 0,00000
UserKNN	0,03114 ± 0,00000	0,04686 ± 0,00000	0,12354 ± 0,00000	0,01365 ± 0,00000
ItemKNN	0,02860 ± 0,00000	0,04146 ± 0,00000	0,11311 ± 0,00000	0,01267 ± 0,00000
BPR-MF	0,02661 ± 0,00114	0,03895 ± 0,00106	0,11179 ± 0,00381	0,01238 ± 0,00040
Content	0,00506 ± 0,00000	0,00772 ± 0,00000	0,02054 ± 0,00000	0,00209 ± 0,00000
Nhóm 3: chuyên biệt cho khuyến nghị				
LateFusion-F	0,04093 ± 0,00212	0,06125 ± 0,00268	0,15798 ± 0,00498	0,01833 ± 0,00066
NeuMF	0,02783 ± 0,00109	0,04137 ± 0,00223	0,11545 ± 0,00382	0,01301 ± 0,00037
MostPopular-Recent	0,02760 ± 0,00000	0,04219 ± 0,00000	0,12164 ± 0,00000	0,01393 ± 0,00000
Most Popular	0,02184 ± 0,00000	0,03107 ± 0,00000	0,09573 ± 0,00000	0,01027 ± 0,00000
Cận dưới				
Random	0,00098 ± 0,00040	0,00176 ± 0,00082	0,00480 ± 0,00169	0,00049 ± 0,00018



Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử H&M

4.3.2 Kết quả theo $K = 10, 15, 20$

Việc chọn $K = 10$ làm độ đo chính không làm thay đổi kết luận. Bảng 4.5 và Bảng 4.6 ghi giá trị trung bình qua 5 seed ở $K = 10, 15, 20$, giá trị cao nhất mỗi cột in đậm. Từ hai bảng này:

- Ở mọi K và với cả bốn độ đo, thứ tự của bốn mô hình có đặc trưng giữ nguyên: LateFusion-F, NeuMF-F, GMF-F rồi MLP-F, và cả bốn đứng trên mọi mô hình còn lại.
- Khi K tăng, HR@K và Recall@K của NeuMF-F tăng, còn Precision@K giảm, vì danh sách dài hơn chứa thêm sản phẩm mục tiêu nhưng tỉ lệ sản phẩm mục tiêu trong danh sách thấp đi.
- Thứ tự giữa các mô hình đối chứng chỉ đổi nhẹ, ví dụ MostPopular-Recent vượt UserKNN ở HR@15 và HR@20.

Bảng 4.5: NDCG@K và Recall@K trên H&M

Mô hình	NDCG@K			Recall@K		
	@10	@15	@20	@10	@15	@20
LateFusion-F	0,0409	0,0475	0,0530	0,0613	0,0806	0,0985
NeuMF-F	0,0400	0,0464	0,0517	0,0595	0,0780	0,0945
GMF-F	0,0390	0,0455	0,0505	0,0583	0,0771	0,0931
MLP-F	0,0348	0,0415	0,0469	0,0525	0,0720	0,0893
Hybrid-CBCF*	0,0318	0,0375	0,0419	0,0464	0,0625	0,0764
UserKNN	0,0311	0,0357	0,0409	0,0469	0,0596	0,0764
ItemKNN	0,0286	0,0343	0,0384	0,0415	0,0584	0,0713
NeuMF	0,0278	0,0330	0,0370	0,0414	0,0563	0,0693
MostPopular-Recent	0,0276	0,0332	0,0379	0,0422	0,0586	0,0730
GMF	0,0270	0,0317	0,0356	0,0401	0,0539	0,0665
BPR-MF	0,0266	0,0320	0,0364	0,0389	0,0542	0,0682
MLP	0,0237	0,0287	0,0327	0,0351	0,0492	0,0619
Most Popular	0,0218	0,0255	0,0298	0,0311	0,0417	0,0548
Content	0,0051	0,0062	0,0068	0,0077	0,0108	0,0131
Random	0,0010	0,0013	0,0015	0,0018	0,0026	0,0033

Bảng 4.6: HR@K và Precision@K trên H&M

Mô hình	HR@K			Precision@K		
	@10	@15	@20	@10	@15	@20
LateFusion-F	0,1580	0,1999	0,2367	0,0183	0,0160	0,0146
NeuMF-F	0,1505	0,1941	0,2298	0,0172	0,0153	0,0140
GMF-F	0,1481	0,1917	0,2267	0,0171	0,0152	0,0139
MLP-F	0,1394	0,1844	0,2215	0,0158	0,0145	0,0134
Hybrid-CBCF*	0,1235	0,1621	0,1946	0,0136	0,0125	0,0116
UserKNN	0,1235	0,1589	0,1934	0,0136	0,0121	0,0114
ItemKNN	0,1131	0,1494	0,1779	0,0127	0,0116	0,0106
NeuMF	0,1155	0,1493	0,1773	0,0130	0,0117	0,0107
MostPopular-Recent	0,1216	0,1633	0,1991	0,0139	0,0127	0,0119
GMF	0,1118	0,1440	0,1717	0,0124	0,0111	0,0102
BPR-MF	0,1118	0,1494	0,1812	0,0124	0,0115	0,0108
MLP	0,1031	0,1390	0,1676	0,0113	0,0105	0,0098
Most Popular	0,0957	0,1220	0,1596	0,0103	0,0091	0,0091
Content	0,0205	0,0297	0,0348	0,0021	0,0021	0,0018
Random	0,0048	0,0075	0,0099	0,0005	0,0005	0,0005

4.3.3 Kiểm định ý nghĩa thống kê

Kết quả kiểm định trên họ 10 so sánh đã đăng ký được trình bày trong Bảng 4.7 và Hình 4.2:

– NeuMF-F tốt hơn có ý nghĩa ở 7 so sánh: so với NeuMF chỉ dùng ID, với nhánh MLP-F và với cả năm mô hình đối chứng. Trong các so sánh giữa hai mô hình học sâu, chênh lệch lớn nhất là so với NeuMF chỉ dùng ID (+43,8%).

– Ba so sánh không khác biệt có ý nghĩa:
  + NeuMF-F so với nhánh GMF-F.
  + NeuMF-F so với LateFusion-F.
  + NeuMF chỉ dùng ID so với BPR-MF.

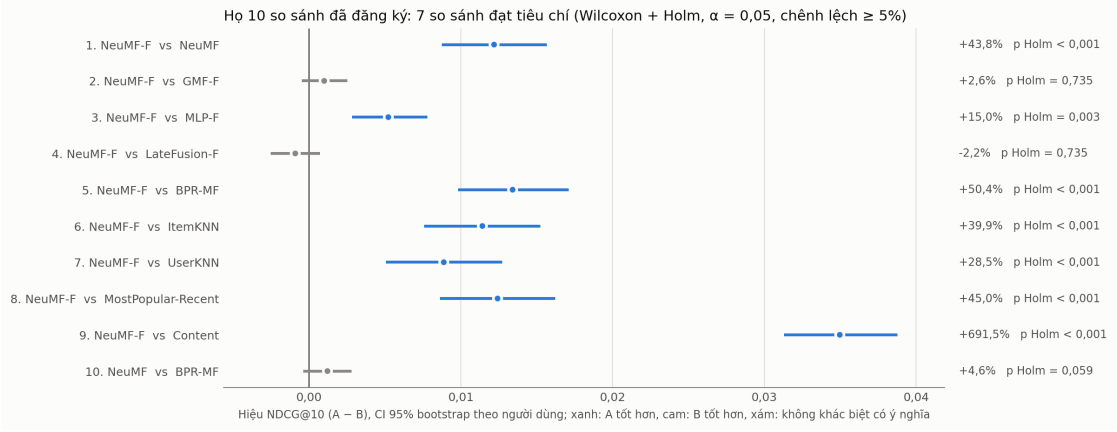
  Ở cả ba trường hợp, khoảng tin cậy đều chứa 0, nên kết luận không phụ thuộc vào ngưỡng 5%.

Mỗi dòng của bảng so sánh mô hình A với mô hình B qua ba đại lượng: chênh

lệch tương đối của NDCG@10, khoảng tin cậy bootstrap 95% của hiệu theo khách, và giá trị p của kiểm định Wilcoxon sau hiệu chỉnh Holm. Cột kết luận áp dụng tiêu chí ở Mục 3.7. Dấu "—" nghĩa là không khác biệt có ý nghĩa.

Bảng 4.7: Kiểm định họ 10 so sánh trên H&M

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F NeuMF	0,04003 0,02783	+43,8%	[+0,00876; +0,01566]	< 0,001	A tốt hơn
2	NeuMF-F GMF-F	0,04003 0,03902	+2,6%	[−0,00045; +0,00253]	0,735	—
3	NeuMF-F MLP-F	0,04003 0,03480	+15,0%	[+0,00283; +0,00782]	0,003	A tốt hơn
4	NeuMF-F LateFusion-F	0,04003 0,04093	−2,2%	[−0,00252; +0,00072]	0,735	—
5	NeuMF-F BPR-MF	0,04003 0,02661	+50,4%	[+0,00982; +0,01712]	< 0,001	A tốt hơn
6	NeuMF-F ItemKNN	0,04003 0,02860	+39,9%	[+0,00760; +0,01525]	< 0,001	A tốt hơn
7	NeuMF-F UserKNN	0,04003 0,03114	+28,5%	[+0,00509; +0,01273]	< 0,001	A tốt hơn
8	NeuMF-F MostPopular-Recent	0,04003 0,02760	+45,0%	[+0,00864; +0,01622]	< 0,001	A tốt hơn
9	NeuMF-F Content	0,04003 0,00506	+691,5%	[+0,03129; +0,03876]	< 0,001	A tốt hơn
10	NeuMF BPR-MF	0,02783 0,02661	+4,6%	[−0,00036; +0,00281]	0,059	—



Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh trên H&M

4.3.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống

Kết quả so sánh với mô hình lai truyền thống được trình bày trong Bảng 4.8:

- NeuMF-F tốt hơn Hybrid-CBCF có ý nghĩa, với chênh lệch +25,8%.
- Hybrid-CBCF xếp thứ năm trong 15 mô hình, đứng ngay sau bốn mô hình có đặc trưng và trên mọi mô hình đối chứng còn lại.
- Hybrid-CBCF so với UserKNN chỉ chênh ít và không khác biệt có ý nghĩa. Điều này khớp với trọng số đã học, dồn phần lớn vào UserKNN, và với việc Content đứng riêng rất yếu trên H&M.

Hybrid-CBCF được đánh giá trong một phân tích bổ sung, với kế hoạch riêng được cố định trước khi chấm tập kiểm thử. Cách kết hợp được chọn trên tập xác thực của mẫu phát triển, rồi chấm trên tập kiểm thử của mẫu kiểm định với cùng dữ liệu, tập ứng viên và quy tắc xếp thứ tự khi bằng điểm như 14 mô hình còn lại. Hai so sánh bổ sung dùng hiệu chỉnh Holm riêng: B1 đặt NeuMF-F cạnh Hybrid-CBCF, B2 đặt Hybrid-CBCF cạnh UserKNN, thành phần mạnh nhất của nó.

Bảng 4.8: Kiểm định bổ sung với Hybrid-CBCF trên H&M

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F Hybrid-CBCF	0,04003 0,03183	+25,8%	[+0,00445; +0,01195]	< 0,001	A tốt hơn
B2	Hybrid-CBCF UserKNN	0,03183 0,03114	+2,2%	[−0,00061; +0,00195]	0,152	—

4.3.5 Phân tích bóc tách thành phần

Phân tích bóc tách tắt lần lượt từng nhóm đặc trưng của NeuMF-F và đo NDCG@10 trên tập kiểm thử. Kết quả được trình bày trong Bảng 4.9 và Hình 4.3. Phân tích chỉ chạy với seed 42, nên NDCG@10 của mô hình đầy đủ trong bảng (0,04137) khác giá trị trung bình 5 seed. Cột "Thay đổi" là chênh lệch tương đối của NDCG@10 so với mô hình đầy đủ, cột cuối là khoảng tin cậy bootstrap 95% của hiệu này theo khách.

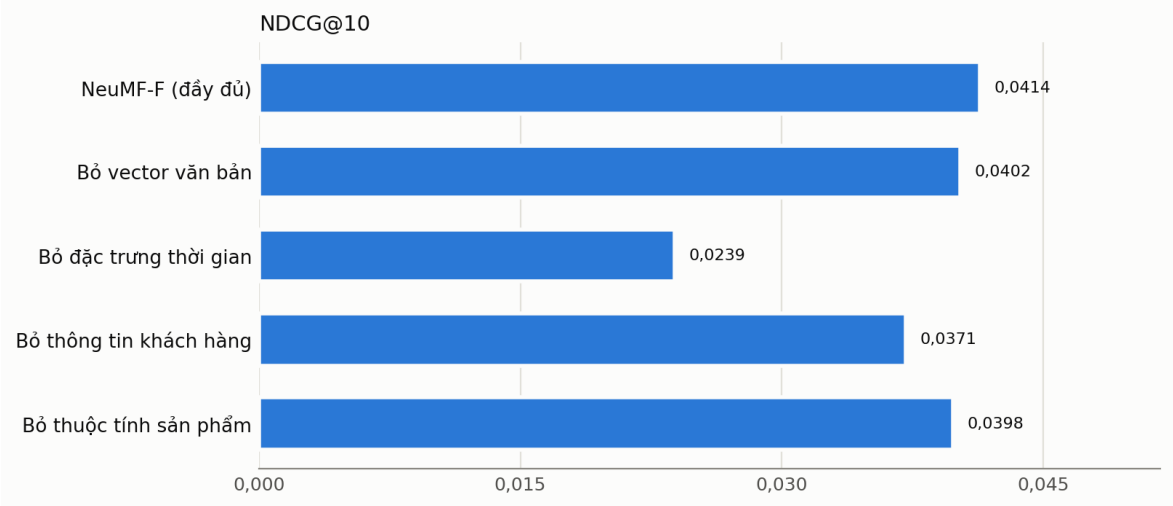
Đặc trưng thời gian đóng góp nhiều nhất cho NeuMF-F: bỏ nhóm đặc trưng này làm NDCG@10 thay đổi −42,3%, mức giảm lớn nhất trong các biến thể. Bỏ thông tin khách hàng làm NDCG@10 giảm nhiều thứ hai. Khi bỏ thuộc tính sản phẩm hoặc vector văn bản, khoảng tin cậy của hiệu chứa 0. Với một seed, nhóm chưa khẳng định được hai nhóm đặc trưng này có đóng góp.

Hai biến thể bỏ đặc trưng thời gian và bỏ thông tin khách hàng có một phần chung. Biến thể bỏ đặc trưng thời gian tắt cả 5 đặc trưng thời gian của sản phẩm và 2 đặc trưng thời gian của khách. Biến thể bỏ thông tin khách hàng tắt 5 thuộc tính tĩnh của khách và cũng tắt 2 đặc trưng thời gian đó. Vì vậy mức giảm của hai biến thể không cộng dồn được, và mức giảm khi bỏ thông tin khách hàng có thể một phần đến từ đặc trưng thời gian của khách.

Mỗi biến thể chỉ tắt một thành phần và giữ nguyên siêu tham số cùng quy trình huấn luyện của NeuMF-F. Biến thể không bỏ ID ngẫu nhiên trùng với chính NeuMF-F, vì cấu hình được chọn của NeuMF-F có xác suất bỏ ID bằng 0, nên không được chạy. Phân tích này không qua kiểm định đa so sánh và không được dùng để chọn lại cấu hình. Kết quả bóc tách chỉ cho biết nhóm đặc trưng nào đáng giữ lại khi phát triển tiếp mô hình.

Bảng 4.9: Phân tích bóc tách NeuMF-F trên H&M

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,04137	—	—
Bỏ vector văn bản	0,04025	−2,7%	[−0,00450; +0,00236]
Bỏ đặc trưng thời gian	0,02386	−42,3%	[−0,02122; −0,01380]
Bỏ thông tin khách hàng	0,03712	−10,3%	[−0,00720; −0,00132]
Bỏ thuộc tính sản phẩm	0,03983	−3,7%	[−0,00467; +0,00158]



Hình 4.3: Phân tích bóc tách NeuMF-F trên H&M

4.3.6 Độ phủ và chi phí huấn luyện

Ngoài độ chính xác, đề tài đo thêm độ phủ của danh sách khuyến nghị và chi phí huấn luyện, được trình bày trong Bảng 4.10. Độ phủ là tỉ lệ sản phẩm ứng viên xuất hiện trong danh sách 10 khuyến nghị đầu của ít nhất một khách, đo ở seed 42. Độ phủ thấp nghĩa là nhiều khách nhận những danh sách giống nhau.

Kết quả về độ phủ:

- Most Popular và MostPopular-Recent có độ phủ thấp nhất, vì mọi khách nhận gần như cùng một danh sách.
- Trong các mô hình cá nhân hoá, MLP chỉ dùng ID có độ phủ thấp nhất.
- NeuMF-F có độ phủ cao nhất trong các mạng lưới thần kinh. Không tính Random, NeuMF-F chỉ đứng sau Content và ItemKNN, hai mô hình chấm điểm theo độ giống thay vì độ phổ biến.
- Độ phủ của Hybrid-CBCF nằm giữa độ phủ của UserKNN và ItemKNN.
- Random có độ phủ gần như toàn bộ danh mục nhưng độ chính xác thấp nhất, nên độ phủ chỉ có giá trị khi được xem cùng với độ chính xác.

Hai cột còn lại của bảng là số epoch được chọn và thời gian huấn luyện, đều lấy trung bình qua 5 seed. Ô "—" dành cho mô hình không huấn luyện theo epoch. Các mạng lưới thần kinh chọn trung bình từ 3 đến khoảng 6 epoch, thấp hơn nhiều so với giới hạn 20 epoch. Điều đó cho thấy NDCG@10 trên tập xác thực đạt đỉnh sớm rồi không tăng thêm. LateFusion-F không tự huấn luyện mạng nào mà trộn điểm của GMF-F và MLP-F, nên muốn có LateFusion-F phải huấn luyện đủ hai nhánh này. Vì vậy thời gian của LateFusion-F trong bảng là tổng thời gian huấn luyện GMF-F và

MLP-F ở cùng seed. Con số này chưa tính bước chọn trọng số trộn, bước chỉ làm một lần lúc tinh chỉnh.

Bảng 4.10: Độ phủ top-10 và chi phí huấn luyện trên H&M

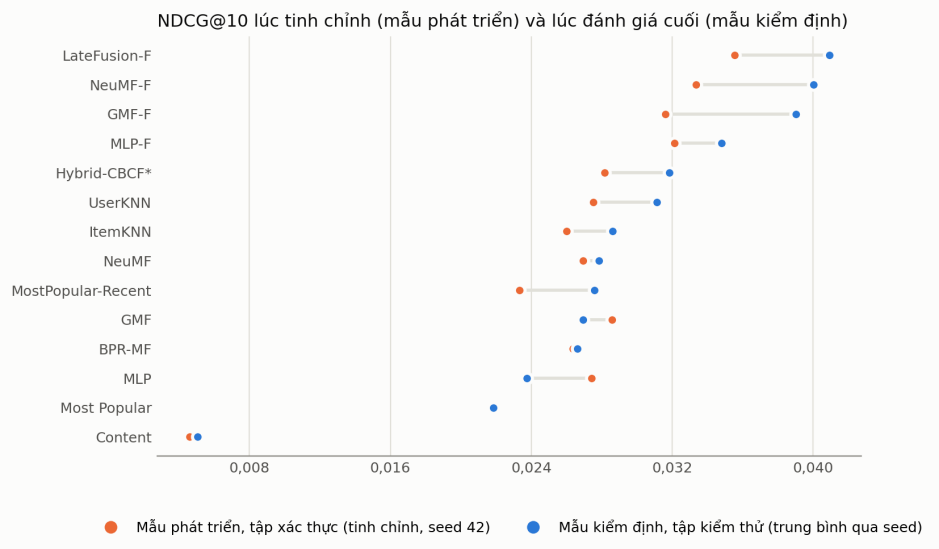
Mô hình	Độ phủ ứng viên	Số epoch chọn	Thời gian (phút)
LateFusion-F	5,3%	—	30,1
NeuMF-F	13,3%	3,0	15,2
GMF-F	6,9%	4,4	13,7
MLP-F	5,3%	4,6	16,4
Hybrid-CBCF*	10,8%	—	0,1
UserKNN	5,7%	—	0,0
ItemKNN	20,4%	—	0,0
NeuMF	6,0%	4,2	6,2
MostPopular-Recent	0,3%	—	0,0
GMF	7,3%	6,2	7,2
BPR-MF	5,1%	—	4,3
MLP	3,3%	4,8	8,4
Most Popular	0,3%	—	0,0
Content	78,2%	—	0,0
Random	98,9%	—	0,0

4.3.7 Độ ổn định giữa hai mẫu

Thứ hạng giữa các mô hình khá ổn định khi chuyển từ mẫu phát triển sang mẫu kiểm định, như Hình 4.4 cho thấy:

- Bốn mô hình có đặc trưng đứng đầu ở cả hai mẫu, và LateFusion-F, NeuMF-F giữ hai vị trí đầu.
- Thay đổi lớn nhất thuộc về GMF và MLP chỉ dùng ID, tụt từ thứ năm và thứ bảy lúc tinh chỉnh xuống thứ chín và thứ mười một ở đánh giá cuối. ItemKNN đi theo chiều ngược lại.

NDCG@10 của hai lần không cùng thang, vì khác mẫu khách hàng và cửa sổ kiểm thử dài gấp đôi cửa sổ xác thực, nên nhóm chỉ so thứ hạng.



Hình 4.4: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối

4.4 Kiểm chứng trên dữ liệu Amazon Beauty

Để biết các kết luận trên H&M có còn đúng trên một bộ dữ liệu khác không, nhóm lặp lại đánh giá cuối trên Amazon Beauty. Ba kết luận được đối chiếu là mô hình có đặc trưng so với mô hình chỉ dùng ID, NeuMF-F so với GMF-F, MLP-F và LateFusion-F, và NeuMF so với BPR-MF.

4.4.1 Dữ liệu và thiết lập kiểm chứng

Bộ dữ liệu kiểm chứng là Amazon Beauty, danh mục Làm đẹp của bộ dữ liệu đánh giá sản phẩm Amazon năm 2014 [2]. Bản 5-core gồm 198.502 đánh giá của 22.363 khách cho 12.101 sản phẩm, từ 12/06/2002 đến 23/07/2014. Kế hoạch kiểm chứng được đăng ký trước khi chạy mô hình nào trên bộ này. Mã nguồn, 14 mô hình, số seed, độ đo, họ 10 so sánh và tiêu chí kết luận giữ nguyên như H&M. Chỉ những điểm sau thay đổi theo dữ liệu.

- Tương tác: mỗi đánh giá được coi là một tương tác ẩn giữa khách và sản phẩm, như một lượt mua của H&M. Số sao không được dùng. Một sản phẩm là một mã `asin`.
- Chia theo thời gian: số epoch được chọn bằng các cặp trước 01/10/2013 và tập xác thực từ 01/10 đến 31/12/2013. Mô hình được huấn luyện lại trên mọi cặp trước 01/01/2014, và tập kiểm thử từ 01/01 đến 23/07/2014. Tỉ lệ độ dài xác thực và kiểm thử khoảng 1 : 2 như H&M. Vì chỉ có một bộ dữ liệu, Amazon không có mẫu khách hàng độc lập: bước chọn số epoch và

bước đánh giá cuối chỉ khác nhau về thời gian.

- Lọc 5-core chỉ trên các cặp trước mốc kiểm thử, bằng ngưỡng của bản 5-core gốc. H&M dùng $k = 10$, nhưng dữ liệu Amazon thưa hơn nhiều.
- Không tinh chỉnh lại: mọi mô hình dùng đúng cấu hình đã chọn trên tập xác thực của mẫu phát triển H&M. Thứ duy nhất được chọn trên dữ liệu Amazon là số epoch của các mạng lưới thần kinh.
- Đặc trưng thay theo những gì bộ dữ liệu có, chi tiết trong Bảng 4.11. Vì Amazon không có thông tin khách hàng, nhánh khách của NeuMF-F chỉ còn hai đặc trưng thời gian. Doanh số được thay bằng số đánh giá, đếm trên chính tệp 5-core.

So với H&M, văn bản được biểu diễn theo cùng một cách. Khác biệt nằm ở thuộc tính sản phẩm, nguồn của đặc trưng thời gian và thông tin khách hàng. Hai mô hình đối chứng có dùng dữ liệu ngoài mã ID, Content và MostPopular-Recent, cũng đổi nguồn theo cùng cách.

Bảng 4.11: Đặc trưng trên H&M và Amazon Beauty

Thành phần	H&M	Amazon Beauty
Thuộc tính sản phẩm	11 thuộc tính danh mục (88 chiều)	5 thuộc tính: thương hiệu, danh mục cấp 1, 2, 3, nhóm giá (8 nhóm, 0 là không có giá) (40 chiều)
Văn bản	tên và mô tả, TF-IDF và SVD 64 chiều	tiêu đề và mô tả, cùng cách biểu diễn
Thời gian của sản phẩm tại t	doanh số toàn H&M trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ chưa từng bán (5 chiều)	số đánh giá trong tệp 5-core trong 7, 28, 91 ngày trước t; tuổi tính từ đánh giá đầu tiên; cờ chưa có đánh giá (5 chiều)
Vector đặc trưng sản phẩm	$d_I = 88 + 64 + 5 = 157$	$d_I = 40 + 64 + 5 = 109$
Thông tin khách hàng	5 thuộc tính tĩnh và 2 đặc trưng thời gian ($d_U = 42$)	chỉ 2 đặc trưng thời gian ($d_U = 2$)
Content (đối chứng)	one-hot nhóm sản phẩm, nhóm chỉ mục, nhóm may mặc	one-hot danh mục cấp 1 và cấp 2
MostPopular-Recent	số giao dịch toàn H&M trong cửa sổ W ngày	số đánh giá trong cửa sổ W ngày

Từ 198.502 đánh giá của bộ 5-core gốc, chỉ các cặp trước mốc kiểm thử được đưa vào bước lọc, và sau khi lọc lại 5-core còn 10.681 khách và 6.069 sản phẩm. Quy mô dữ liệu được ghi trong Bảng 4.12. Số cặp huấn luyện của giai đoạn kiểm thử đúng bằng số cặp sau lọc, vì phép lọc chỉ dùng dữ liệu trước mốc kiểm thử. Mỗi khách được xếp hạng trên số ứng viên gần bằng H&M nhưng có ít sản phẩm mục tiêu hơn (khoảng 2,3 so với 3,2 trên H&M). Vì vậy các độ đo trên Amazon cũng có giá trị tuyệt đối thấp.

Bảng 4.12: Quy mô dữ liệu Amazon Beauty

	Amazon Beauty
Đánh giá trong bộ 5-core gốc (mỗi đánh giá là một tương tác)	198.502
Sản phẩm có đánh giá trước 01/01/2014	11.493
Cặp (khách, sản phẩm) trước 01/01/2014	140.193
Khách sau lọc 5-core	10.681
Sản phẩm (`asin`) sau lọc 5-core	6.069
Cặp sau lọc 5-core	94.009
Xác thực: cặp huấn luyện (trước 01/10/2013)	82.281
Xác thực: khách được đánh giá	3.153
Xác thực: cặp đúng	7.880
Kiểm thử: cặp huấn luyện (trước 01/01/2014)	94.009
Kiểm thử: khách được đánh giá	2.644
Kiểm thử: cặp đúng	6.107
Kiểm thử: số ứng viên trung bình mỗi khách	6.058

4.4.2 Kết quả trên tập kiểm thử Amazon Beauty

Kết quả trên Amazon được trình bày như bảng kết quả trên H&M, tính trên 2.644 khách, với cấu hình chọn trên H&M. Kết quả được trình bày trong Bảng 4.13:

- Bốn mô hình có đặc trưng đứng đầu. LateFusion-F đạt NDCG@10 cao nhất (0,03747), còn NeuMF-F xếp thứ ba, sau cả GMF-F.
- Trong các mô hình đăng ký trước, tiếp theo là UserKNN và ItemKNN.
- BPR-MF chỉ đạt khoảng một nửa NDCG@10 của ItemKNN và thấp hơn cả MostPopular-Recent. Trên H&M, BPR-MF cũng thấp hơn hai mô hình này nhưng chỉ chênh một chút.

Bảng 4.13: Kết quả trên tập kiểm thử Amazon Beauty

Mô hình	NDCG @10	Recall @10	HR @10	Precision @10
Mô hình đề xuất				
NeuMF-F	0,03277 ± 0,00189	0,05568 ± 0,00403	0,09750 ± 0,00657	0,01092 ± 0,00077
Nhóm 1: mô hình đơn lẻ				
GMF-F	0,03298 ± 0,00259	0,05465 ± 0,00397	0,09410 ± 0,00780	0,01042 ± 0,00088
MLP-F	0,03065 ± 0,00193	0,05107 ± 0,00327	0,08737 ± 0,00656	0,00998 ± 0,00092
GMF	0,01627 ± 0,00173	0,02533 ± 0,00154	0,05582 ± 0,00303	0,00640 ± 0,00036
MLP	0,01271 ± 0,00054	0,02045 ± 0,00132	0,04667 ± 0,00324	0,00513 ± 0,00037
Nhóm 2: học máy truyền thống				
Hybrid-CBCF*	0,02664 ± 0,00000	0,03992 ± 0,00000	0,08169 ± 0,00000	0,00998 ± 0,00000
UserKNN	0,02506 ± 0,00000	0,03553 ± 0,00000	0,07716 ± 0,00000	0,00930 ± 0,00000
ItemKNN	0,02333 ± 0,00000	0,03526 ± 0,00000	0,07186 ± 0,00000	0,00870 ± 0,00000
BPR-MF	0,01144 ± 0,00091	0,01691 ± 0,00164	0,04115 ± 0,00309	0,00498 ± 0,00035
Content	0,00945 ± 0,00000	0,01448 ± 0,00000	0,03215 ± 0,00000	0,00356 ± 0,00000
Nhóm 3: chuyên biệt cho khuyến nghị				
LateFusion-F	0,03747 ± 0,00180	0,06286 ± 0,00167	0,10802 ± 0,00314	0,01222 ± 0,00045
NeuMF	0,01978 ± 0,00176	0,03035 ± 0,00187	0,06694 ± 0,00605	0,00762 ± 0,00090
MostPopular-Recent	0,01401 ± 0,00000	0,02483 ± 0,00000	0,03858 ± 0,00000	0,00416 ± 0,00000
Most Popular	0,00872 ± 0,00000	0,01576 ± 0,00000	0,03744 ± 0,00000	0,00390 ± 0,00000
Cận dưới				
Random	0,00101 ± 0,00028	0,00168 ± 0,00059	0,00446 ± 0,00143	0,00045 ± 0,00014

LateFusion-F cao nhất ở mọi K và với cả bốn độ đo, theo Bảng 4.14 và Bảng 4.15. NeuMF-F và GMF-F bám sát nhau và đổi chỗ tuỳ độ đo: GMF-F cao hơn một chút ở NDCG@K, còn NeuMF-F cao hơn một chút ở Recall@K, HR@K và

Precision@K.

Bảng 4.14: NDCG@K và Recall@K trên Amazon Beauty

Mô hình	NDCG@K			Recall@K		
	@10	@15	@20	@10	@15	@20
LateFusion-F	0,0375	0,0425	0,0457	0,0629	0,0794	0,0904
GMF-F	0,0330	0,0377	0,0416	0,0546	0,0700	0,0840
NeuMF-F	0,0328	0,0375	0,0414	0,0557	0,0715	0,0856
MLP-F	0,0307	0,0347	0,0376	0,0511	0,0646	0,0749
Hybrid-CBCF*	0,0266	0,0296	0,0321	0,0399	0,0498	0,0586
UserKNN	0,0251	0,0284	0,0310	0,0355	0,0470	0,0557
ItemKNN	0,0233	0,0253	0,0279	0,0353	0,0418	0,0510
NeuMF	0,0198	0,0228	0,0254	0,0304	0,0399	0,0491
GMF	0,0163	0,0190	0,0209	0,0253	0,0341	0,0407
MostPopular-Recent	0,0140	0,0171	0,0185	0,0248	0,0351	0,0399
MLP	0,0127	0,0148	0,0169	0,0205	0,0271	0,0345
BPR-MF	0,0114	0,0132	0,0148	0,0169	0,0225	0,0278
Content	0,0095	0,0115	0,0126	0,0145	0,0213	0,0255
Most Popular	0,0087	0,0095	0,0100	0,0158	0,0186	0,0200
Random	0,0010	0,0013	0,0015	0,0017	0,0025	0,0035

Bảng 4.15: HR@K và Precision@K trên Amazon Beauty

Mô hình	HR@K			Precision@K		
	@10	@15	@20	@10	@15	@20
LateFusion-F	0,1080	0,1358	0,1546	0,0122	0,0106	0,0092
GMF-F	0,0941	0,1200	0,1417	0,0104	0,0092	0,0083
NeuMF-F	0,0975	0,1224	0,1451	0,0109	0,0094	0,0086
MLP-F	0,0874	0,1099	0,1275	0,0100	0,0085	0,0075
Hybrid-CBCF*	0,0817	0,0991	0,1161	0,0100	0,0081	0,0072
UserKNN	0,0772	0,0957	0,1120	0,0093	0,0078	0,0069
ItemKNN	0,0719	0,0840	0,0983	0,0087	0,0069	0,0062
NeuMF	0,0669	0,0859	0,1011	0,0076	0,0067	0,0061
GMF	0,0558	0,0718	0,0846	0,0064	0,0056	0,0051
MostPopular-Recent	0,0386	0,0537	0,0639	0,0042	0,0041	0,0038
MLP	0,0467	0,0606	0,0750	0,0051	0,0046	0,0043
BPR-MF	0,0411	0,0526	0,0635	0,0050	0,0045	0,0041
Content	0,0321	0,0446	0,0514	0,0036	0,0034	0,0030
Most Popular	0,0374	0,0446	0,0492	0,0039	0,0031	0,0026
Random	0,0045	0,0064	0,0084	0,0005	0,0004	0,0004

Kết luận bổ sung cũng lặp lại: NeuMF-F tốt hơn Hybrid-CBCF có ý nghĩa, theo Bảng 4.16. Hybrid-CBCF, dùng nguyên cách kết hợp và trọng số chọn trên H&M, xếp thứ năm trong 15 mô hình, cũng đứng ngay sau bốn mô hình có đặc trưng. Khác H&M, trên Amazon Hybrid-CBCF tốt hơn UserKNN có ý nghĩa. Một khác biệt có thể góp phần: NDCG@10 của Content đứng riêng chỉ bằng khoảng một phần sáu của UserKNN trên H&M, nhưng hơn một phần ba trên Amazon. Thành phần nội dung vì thế mang thêm nhiều thông tin hơn.

Bảng 4.16: Kiểm định bổ sung với Hybrid-CBCF trên Amazon Beauty

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F Hybrid-CBCF	0,03277 0,02664	+23,0%	[+0,00138; +0,01083]	< 0,001	A tốt hơn
B2	Hybrid-CBCF UserKNN	0,02664 0,02506	+6,3%	[+0,00026; +0,00292]	0,009	A tốt hơn

4.4.3 Đối chiếu kết luận giữa H&M và Amazon Beauty

Trong ba kết luận được đối chiếu:

- Kết luận về đặc trưng, kết luận chính của đề tài, giữ nguyên trên Amazon.
- Kết luận về cách hợp nhất hai nhánh thay đổi theo dữ liệu.
- Kết luận về NeuMF so với BPR-MF không dùng để đối chiếu, vì BPR-MF dùng cấu hình chọn trên H&M.

Bảng 4.17 là kiểm định họ 10 so sánh trên Amazon, với cùng cấu trúc và tiêu chí như trên H&M. Bảng 4.18 đặt kết luận của từng so sánh trên hai bộ dữ liệu cạnh nhau, trong đó cột "Chênh" là chênh lệch tương đối $(A-B)/B$ của NDCG@10. Hai so sánh có BPR-MF trên Amazon được đánh dấu * vì BPR-MF ở đây dùng cấu hình chọn trên H&M và kém cả ItemKNN lẫn UserKNN.

Kết luận thứ nhất, về đặc trưng so với chỉ dùng ID, còn đúng trên Amazon: NeuMF-F hơn NeuMF chỉ dùng ID +65,7% và tốt hơn có ý nghĩa cả năm mô hình đối chứng trong họ so sánh. Đây là kết luận vững nhất của đề tài. Nó giữ nguyên khi đổi lĩnh vực (mỹ phẩm thay vì thời trang), loại tương tác (đánh giá thay vì lượt mua) và bộ đặc trưng (không có thông tin khách hàng), dù mô hình không được tinh chỉnh lại.

Kết luận thứ hai, về NeuMF-F so với từng nhánh và với hợp nhất muộn, chỉ đúng một phần:

- NeuMF-F vẫn không khác biệt có ý nghĩa với nhánh GMF-F.
- Lợi thế so với MLP-F trên H&M không còn trên Amazon: giá trị p đã hiệu chỉnh xấp xỉ ngưỡng 0,05 nhưng khoảng tin cậy chứa 0.
- Ngược với H&M, hợp nhất muộn LateFusion-F tốt hơn NeuMF-F có ý nghĩa.

Kết quả này cho thấy cách hợp nhất phù hợp phụ thuộc vào dữ liệu. Một cách giải thích là trên Amazon, hai nhánh GMF-F và MLP-F khuyến nghị những tập sản phẩm rất khác nhau, thể hiện qua độ phủ top-10. Khi huấn luyện riêng rồi trộn điểm, hai danh sách bổ sung cho nhau tốt hơn so với khi hai nhánh được học chung trong một mạng.

Kết luận thứ ba, về NeuMF chỉ dùng ID so với BPR-MF, không đối chiếu được. Trên Amazon, NeuMF tốt hơn BPR-MF có ý nghĩa, trong khi trên H&M hai mô hình không khác biệt có ý nghĩa. Tuy nhiên BPR-MF trên Amazon dùng cấu hình chọn trên H&M và kém xa ItemKNN lẫn MostPopular-Recent. Khoảng cách này vì thế nhiều khả năng phản ánh cấu hình không hợp với dữ liệu hơn là ưu thế của NeuMF. Vì lý do

tương tự, so sánh NeuMF-F với BPR-MF trên Amazon không được dùng làm thước đo lợi ích của NeuMF-F.

Bảng 4.17: Kiểm định họ 10 so sánh trên Amazon Beauty

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F NeuMF	0,03277 0,01978	+65,7%	[+0,00936; +0,01681]	< 0,001	A tốt hơn
2	NeuMF-F GMF-F	0,03277 0,03298	−0,6%	[−0,00228; +0,00186]	0,534	—
3	NeuMF-F MLP-F	0,03277 0,03065	+6,9%	[−0,00044; +0,00457]	0,050	—
4	NeuMF-F LateFusion-F	0,03277 0,03747	−12,5%	[−0,00668; −0,00279]	< 0,001	B tốt hơn
5	NeuMF-F BPR-MF	0,03277 0,01144	+186,5%	[+0,01756; +0,02528]	< 0,001	A tốt hơn
6	NeuMF-F ItemKNN	0,03277 0,02333	+40,5%	[+0,00477; +0,01417]	< 0,001	A tốt hơn
7	NeuMF-F UserKNN	0,03277 0,02506	+30,8%	[+0,00313; +0,01232]	< 0,001	A tốt hơn
8	NeuMF-F MostPopular-Recent	0,03277 0,01401	+134,0%	[+0,01553; +0,02201]	< 0,001	A tốt hơn
9	NeuMF-F Content	0,03277 0,00945	+246,7%	[+0,01902; +0,02766]	< 0,001	A tốt hơn
10	NeuMF BPR-MF	0,01978 0,01144	+72,9%	[+0,00630; +0,01038]	< 0,001	A tốt hơn

Bảng 4.18: Kết luận họ 10 so sánh trên H&M và Amazon Beauty

#	So sánh (A so với B)	H&M		Amazon Beauty	
		Chênh	Kết luận	Chênh	Kết luận
1	NeuMF-F so với NeuMF	+43,8%	A tốt hơn	+65,7%	A tốt hơn
2	NeuMF-F so với GMF-F	+2,6%	không khác biệt có ý nghĩa	−0,6%	không khác biệt có ý nghĩa
3	NeuMF-F so với MLP-F	+15,0%	A tốt hơn	+6,9%	không khác biệt có ý nghĩa
4	NeuMF-F so với LateFusion-F	−2,2%	không khác biệt có ý nghĩa	−12,5%	B tốt hơn
5	NeuMF-F so với BPR-MF	+50,4%	A tốt hơn	+186,5%	A tốt hơn *
6	NeuMF-F so với ItemKNN	+39,9%	A tốt hơn	+40,5%	A tốt hơn
7	NeuMF-F so với UserKNN	+28,5%	A tốt hơn	+30,8%	A tốt hơn
8	NeuMF-F so với MostPopular-Recent	+45,0%	A tốt hơn	+134,0%	A tốt hơn
9	NeuMF-F so với Content	+691,5%	A tốt hơn	+246,7%	A tốt hơn
10	NeuMF so với BPR-MF	+4,6%	không khác biệt có ý nghĩa	+72,9%	A tốt hơn *

4.4.4 Phân tích bóc tách và độ phủ trên Amazon Beauty

Như trên H&M, bỏ đặc trưng thời gian làm NDCG@10 giảm nhiều nhất, theo Bảng 4.19. Phân tích này cũng chỉ chạy với seed 42. Vì Amazon không có thuộc tính khách hàng, biến thể "bỏ thông tin khách hàng" ở đây chỉ bỏ hai đặc trưng thời gian của khách. Khác H&M, thuộc tính sản phẩm (thương hiệu, danh mục, nhóm giá) có đóng góp rõ, với khoảng tin cậy của hiệu không chứa 0. Bỏ thông tin khách hàng không làm NDCG@10 thay đổi có ý nghĩa, và bỏ vector văn bản cũng vậy. Về độ phủ top-10, Most Popular và MostPopular-Recent vẫn thấp nhất.

Bảng 4.19: Phân tích bóc tách NeuMF-F trên Amazon Beauty

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,03378	—	—
Bỏ vector văn bản	0,03047	−9,8%	[−0,00701; +0,00051]
Bỏ đặc trưng thời gian	0,02310	−31,6%	[−0,01569; −0,00561]
Bỏ thông tin khách hàng	0,03424	+1,3%	[−0,00271; +0,00369]
Bỏ thuộc tính sản phẩm	0,02892	−14,4%	[−0,00844; −0,00133]

4.5 Nguồn gốc của phần cải thiện

Phần cải thiện của NeuMF-F chỉ có giá trị nếu nó đến từ đặc trưng, không đến từ một yếu tố khác của thực nghiệm. Thiết kế thực nghiệm giữ mỗi yếu tố như vậy giống nhau cho mọi mô hình, hoặc kiểm tra nó bằng một phép đo riêng. Bảng 4.20 liệt kê từng yếu tố và cách đề tài loại trừ nó.

Bảng 4.20: Các yếu tố có thể tác động đến kết quả và cách loại trừ

Yếu tố có thể tác động	Cách loại trừ
Tinh chỉnh không đều giữa các mô hình	Mọi mô hình có cùng ngân sách tinh chỉnh. Cấu hình được chọn theo cùng độ đo trên cùng tập xác thực.
Điều kiện đánh giá khác nhau	Cùng mẫu khách hàng, cùng tập ứng viên, cùng năm seed và cùng mã nguồn đánh giá (Bảng 4.1).
Rò rỉ thông tin tương lai	Dữ liệu chia theo thời gian. Đặc trưng và mẫu âm được tính tại đúng thời điểm, chỉ từ dữ liệu trước mốc dự đoán.
Dao động ngẫu nhiên	Năm lần chạy. Kiểm định Wilcoxon trên từng khách, khoảng tin cậy bootstrap và hiệu chỉnh Holm cho cả họ so sánh.
Khác biệt về kiến trúc	NeuMF-F và NeuMF có cùng kiến trúc hai nhánh, chỉ khác ở đặc trưng. Phân tích bóc tách tắt từng nhóm đặc trưng và giữ nguyên phần còn lại.
Chọn cấu hình theo dữ liệu kiểm thử	Cấu hình được chọn trên mẫu phát triển. Kết luận rút ra trên mẫu kiểm định, gồm những khách hàng khác.
Kết quả chỉ đúng với một bộ dữ liệu	Kiểm chứng lại trên Amazon Beauty, khác lĩnh vực, giữ nguyên cấu hình chọn trên H&M.

Khi các yếu tố trên như nhau, chênh lệch giữa NeuMF-F và NeuMF chỉ dùng ID phản ánh giá trị của đặc trưng. Chênh lệch này là +43,8% trên H&M và +65,7%

trên Amazon Beauty, đều có ý nghĩa thống kê. Phân tích bóc tách cho cùng kết luận theo chiều ngược lại: tắt đặc trưng thời gian làm NDCG@10 thay đổi −42,3% trên H&M và −31,6% trên Amazon Beauty. Hai cách đo độc lập cùng chỉ về đặc trưng, nên phần cải thiện không do cách thiết lập thực nghiệm tạo ra.

4.6 Phạm vi của kết luận

Các kết luận của chương áp dụng cho những khách hàng của H&M có lịch sử mua đủ dày để qua bước lọc 10-core, trong khung thời gian từ tháng 7 đến tháng 9 năm 2020 và ở mức mẫu thiết kế. Phân tích bóc tách dùng một seed để mô tả mức đóng góp của từng nhóm đặc trưng, còn các kết luận chính dựa trên họ so sánh có kiểm định. Kiểm chứng trên Amazon Beauty dùng lại cấu hình chọn trên H&M. Các kết luận lặp lại trên bộ này vì thế không nhờ vào việc tinh chỉnh theo dữ liệu mới.

4.7 Thảo luận và trả lời câu hỏi nghiên cứu

Câu hỏi thứ nhất là NeuMF-F có khuyến nghị tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ không. Câu trả lời là có, với các mô hình đã được kiểm định và không dùng chung bộ đặc trưng của NeuMF-F, gồm năm mô hình đối chứng trong họ so sánh, NeuMF chỉ dùng ID và Hybrid-CBCF:

- Trên H&M, NeuMF-F tốt hơn có ý nghĩa cả năm mô hình đối chứng trong họ so sánh, chênh lệch nhỏ nhất với UserKNN và lớn nhất với Content. Kết quả này lặp lại trên Amazon Beauty.
- NeuMF-F tốt hơn mô hình lai truyền thống Hybrid-CBCF trên cả hai bộ dữ liệu, trong khi Hybrid-CBCF chỉ hơn thành phần mạnh nhất của nó một khoảng nhỏ. Trên hai bộ dữ liệu này, đưa đặc trưng vào mô hình lai học sâu cho kết quả tốt hơn ghép điểm của các kỹ thuật truyền thống.
- GMF-F và LateFusion-F dùng chính bộ đặc trưng của NeuMF-F và đạt mức tương đương hoặc cao hơn. Kết quả này củng cố nhận định rằng đặc trưng là nguồn cải thiện chính, và được bàn ở câu hỏi thứ ba.

Câu hỏi thứ hai là bổ sung đặc trưng có giúp mô hình lai không. Câu trả lời cũng là có:

- NeuMF-F và NeuMF chỉ dùng ID có cùng kiến trúc hai nhánh, nên chênh lệch giữa hai mô hình phản ánh trực tiếp giá trị của đặc trưng. Đây là chênh lệch lớn nhất giữa hai mô hình học sâu trong họ so sánh, và lặp lại trên

Amazon Beauty.

- Khi chỉ dùng mã ID, NeuMF không khác biệt có ý nghĩa với BPR-MF trên H&M. Trên Amazon, NeuMF tốt hơn BPR-MF, nhưng so sánh này không dùng để kết luận vì BPR-MF dùng cấu hình chọn trên H&M.
- Phân tích bóc tách cho thấy mức đóng góp của từng nhóm đặc trưng:
  + Đặc trưng thời gian đóng góp nhiều nhất, gồm doanh số gần đây của sản phẩm, thời gian từ lần mua gần nhất và số sản phẩm khách đã mua.
  + Thông tin khách hàng đứng thứ hai. Hai biến thể này cùng tắt đặc trưng thời gian của khách, nên mức đóng góp của chúng không tách rời hoàn toàn.
  + Thuộc tính và mô tả văn bản của sản phẩm đóng góp nhỏ hơn, trong phạm vi dao động của một lần chạy.

Câu hỏi thứ ba là ghép hai nhánh có tốt hơn từng nhánh không, và nên hợp nhất sớm hay muộn. Khi đã có đặc trưng, các cách ghép cho kết quả gần nhau:

- Trên H&M, NeuMF-F tốt hơn nhánh MLP-F nhưng không tốt hơn nhánh GMF-F đứng riêng, và không khác biệt có ý nghĩa với LateFusion-F.
- Trên Amazon Beauty, lợi thế so với MLP-F không còn, còn LateFusion-F tốt hơn NeuMF-F có ý nghĩa.

Từ hai kết quả này, nhóm cho rằng phần cải thiện của mô hình lai đến chủ yếu từ biểu diễn có đặc trưng, còn cách ghép hai nhánh nên được chọn theo dữ liệu.

Dù LateFusion-F có NDCG@10 trung bình cao nhất trên cả hai bộ dữ liệu, kết quả này không làm giảm giá trị của mô hình đề xuất:

- NeuMF-F là mô hình đúng với mục tiêu của đề tài: một mô hình lai duy nhất kết hợp MF và DNN, huấn luyện chung. LateFusion-F gồm hai mô hình huấn luyện riêng rồi trộn điểm, được nhóm đưa vào họ so sánh để đo ảnh hưởng của cách hợp nhất.
- NeuMF-F đạt mục tiêu chính của đề tài. Trên cả hai bộ dữ liệu, mô hình tốt hơn có ý nghĩa NeuMF chỉ dùng ID, năm mô hình đối chứng trong họ so sánh và mô hình lai truyền thống Hybrid-CBCF.
- LateFusion-F dùng chính hai nhánh có đặc trưng mà đề tài xây dựng cho NeuMF-F và chỉ khác ở bước trộn điểm. Kết quả cao của LateFusion-F vì vậy cũng đến từ biểu diễn lai của đề tài.

So với LateFusion-F, NeuMF-F có cả điểm thấp hơn lẫn điểm cao hơn đo được. Về độ chính xác, NDCG@10 của NeuMF-F chênh −2,2% so với LateFusion-F trên H&M (không khác biệt có ý nghĩa, p Holm = 0,735) và −12,5% trên Amazon Beauty (LateFusion-F tốt hơn có ý nghĩa, p Holm < 0,001). Về chi phí, NeuMF-F chỉ huấn luyện một mạng, trung bình 15,2 phút mỗi seed trên H&M và 4,1 phút trên Amazon Beauty, còn LateFusion-F cần huấn luyện cả GMF-F lẫn MLP-F, tổng cộng 30,1 và 10,9 phút. Độ phủ top-10 ở seed 42 của NeuMF-F cũng cao hơn trên cả hai bộ: 13,3% so với 5,3% trên H&M, 20,5% so với 15,3% trên Amazon Beauty. Các số trên là thời gian huấn luyện. Thời gian NeuMF-F tạo một danh sách khuyến nghị trong demo được nêu ở Mục 3.9. Ngược lại, LateFusion-F có ưu điểm là chỉnh được trọng số trộn mà không phải huấn luyện lại.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết quả đạt được

Đề tài đã hoàn thành năm mục tiêu đặt ra ban đầu. Kết quả của từng mục tiêu được tóm tắt trong Bảng 5.1.

Bảng 5.1: Mức độ hoàn thành mục tiêu

Mục tiêu	Kết quả đạt được
(1) Hệ thống hoá cơ sở lý thuyết	Trình bày lọc cộng tác, nhân tử hoá ma trận, BPR, kiến trúc NCF, mô hình lai dựa trên đặc trưng, hợp nhất sớm và hợp nhất muộn, các độ đo Top-K. Đối chiếu thiết lập của ba nghiên cứu nền tảng.
(2) Quy trình xử lý dữ liệu	Lấy mẫu theo khách hàng, gộp sản phẩm theo mẫu thiết kế, lọc 10-core trước mốc kiểm thử, chia dữ liệu theo thời gian và tính đặc trưng tại thời điểm dự đoán. Quy trình được dùng lại cho Amazon Beauty.
(3) Cài đặt và tinh chỉnh mô hình	Cài đặt NeuMF-F, 13 mô hình đối chứng và mô hình lai truyền thống Hybrid-CBCF. Mọi mô hình có tham số học được đều được thử 6 cấu hình.
(4) Đánh giá có kiểm định	Xếp hạng toàn bộ tập ứng viên, bốn độ đo ở $K = 10, 15, 20$, 5 lần chạy, kiểm định Wilcoxon, khoảng tin cậy bootstrap và hiệu chỉnh Holm trên mẫu kiểm định. Kiểm chứng lại trên Amazon Beauty.
(5) Hệ thống demo	Hệ thống ba tầng cho phép xem khuyến nghị của NeuMF-F và một mô hình đối chứng trên cùng một khách hàng, chạy được với cả hai bộ dữ liệu.

5.2 Kết luận

Kết quả thực nghiệm trả lời được ba câu hỏi nghiên cứu:

- Trên H&M, NeuMF-F tốt hơn có ý nghĩa thống kê so với NeuMF chỉ dùng ID, nhánh MLP-F và năm mô hình đối chứng trong họ so sánh:
  + BPR-MF.
  + Hai mô hình láng giềng ItemKNN và UserKNN.

    + Mô hình phổ biến theo thời gian MostPopular-Recent.
    + Mô hình lọc nội dung Content.
- NeuMF-F tốt hơn mô hình lai truyền thống Hybrid-CBCF trên cả hai bộ dữ liệu.
- Kết luận về vai trò của đặc trưng lặp lại trên Amazon Beauty, dù bộ dữ liệu này khác lĩnh vực, không có thông tin khách hàng và mô hình không được tinh chỉnh lại.

Mọi mô hình được tinh chỉnh và đánh giá trong cùng điều kiện, nên các kết quả trên phản ánh giá trị của đặc trưng, không do khác biệt về tinh chỉnh, dữ liệu hay dao động ngẫu nhiên (Mục 4.5).

Phần cải thiện của mô hình lai đến chủ yếu từ việc bổ sung đặc trưng, trong đó đặc trưng thời gian đóng góp nhiều nhất trên cả hai bộ dữ liệu. Cách hợp nhất hai nhánh ảnh hưởng ít hơn:

- NeuMF-F không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng.
- So với NeuMF-F, mô hình hợp nhất muộn LateFusion-F cho kết quả tương đương trên H&M và tốt hơn trên Amazon Beauty. LateFusion-F có NDCG@10 trung bình cao nhất trên cả hai bộ dữ liệu. Mô hình này dùng chính hai nhánh có đặc trưng mà đề tài xây dựng cho NeuMF-F, nên kết quả của nó cũng xác nhận giá trị của biểu diễn có đặc trưng.

Trên H&M, kết quả này phù hợp với nhận định của các nghiên cứu đánh giá lại NCF: khi chỉ dùng mã ID, mô hình lai khó vượt nhân tử hoá ma trận đã được tinh chỉnh. Kết quả của NeuMF-F cho thấy bổ sung đặc trưng là cách giúp mô hình lai vượt qua giới hạn này.

Đề tài có các đóng góp sau:

- Xây dựng được một mô hình lai có đặc trưng tốt hơn NeuMF gốc và các mô hình khuyến nghị truyền thống được so sánh trên hai bộ dữ liệu.
- Qua phân tích bóc tách, chỉ ra đặc trưng thời gian là nhóm đặc trưng đóng góp nhiều nhất cho NeuMF-F trên cả hai bộ dữ liệu.
- Xây dựng một quy trình đánh giá có thể dùng lại cho bài toán khuyến nghị khác.

Về ứng dụng, doanh nghiệp bán lẻ có thể cải thiện khuyến nghị bằng dữ liệu sẵn có, trước hết là doanh số theo ngày và lịch sử mua của khách.

5.3 Hạn chế của đề tài

Theo phạm vi nhóm đã chọn, đề tài có ba giới hạn:

- Nhóm dùng hai mẫu, mỗi mẫu khoảng 1,6% khách hàng của H&M, với ngưỡng lọc $k = 10$. Quy mô này cho phép tinh chỉnh mọi mô hình với cùng ngân sách và chạy đủ năm seed trong tài nguyên tính toán sẵn có. Kết luận vì vậy áp dụng cho nhóm khách có lịch sử mua tương đối nhiều.
- Đề tài tập trung vào khách hàng và sản phẩm đã có lịch sử. Khách hàng mới nhận danh sách sản phẩm bán chạy (Mục 3.8), còn chất lượng khuyến nghị cho sản phẩm mới và khách hàng mới chưa được đo định lượng.
- Mô tả sản phẩm được biểu diễn bằng TF-IDF, cách biểu diễn gọn và dễ giải thích. Ảnh sản phẩm chưa được sử dụng. Lợi ích của đặc trưng được đo trong họ mô hình NeuMF, đúng với phạm vi của đề tài.

5.4 Hướng phát triển

Hướng phát triển của đề tài mở rộng từ ba giới hạn trên.

- Mở rộng quy mô dữ liệu. Thực nghiệm có thể chạy trên nhiều khách hàng hơn và với ngưỡng lọc thấp hơn, khi có thêm tài nguyên tính toán, để kiểm tra kết luận với nhóm khách mua ít.
- Đánh giá trên sản phẩm mới và khách hàng mới. NeuMF-F đã có cơ chế chấm điểm sản phẩm chỉ từ đặc trưng khi bỏ vector ID. Bước tiếp theo là huấn luyện với cơ chế này và đánh giá riêng trên tập sản phẩm vừa ra mắt.
- Bổ sung và so sánh đặc trưng. Ảnh và mô tả sản phẩm có thể được biểu diễn bằng mô hình tiền huấn luyện, và đặc trưng thời gian có thể thêm yếu tố mùa vụ. Cùng bộ đặc trưng đó nên được thử với Factorization Machines để tách vai trò của đặc trưng khỏi vai trò của mạng lưới thần kinh.

TÀI LIỆU THAM KHẢO

Dữ liệu

[1] H&M Group, *H&M Personalized Fashion Recommendations*, https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations, Cuộc thi trên Kaggle, 2022.

[2] J. McAuley, C. Targett, Q. Shi, và A. van den Hengel, "Image-Based Recommendations on Styles and Substitutes," in *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '15)*, Santiago, Chile, 2015, pp. 43–52. DOI: 10.1145/2766462.2767755

Nghiên cứu nền tảng

[3] Hồ Thị Linh, "Multi-Source Integration for Recommendation Systems," Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

[4] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, "Neural Collaborative Filtering," in *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

[5] S. Rendle, W. Krichene, L. Zhang, và J. Anderson, "Neural Collaborative Filtering vs. Matrix Factorization Revisited," in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

Hệ thống khuyến nghị và lọc cộng tác

[6] R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

[7] B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, "Item-based Collaborative Filtering Recommendation Algorithms," in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

[8] Y. Koren, R. Bell, và C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

[9] S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, "BPR: Bayesian Personalized Ranking from Implicit Feedback," in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI '09)*, Montreal, QC, Canada, 2009, pp. 452–461.

Mô hình dựa trên đặc trưng và biểu diễn văn bản

[10] S. Rendle, "Factorization Machines," in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

[11] H.-T. Cheng và cộng sự, "Wide & Deep Learning for Recommender Systems," in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS 2016)*, Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

[12] H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, "DeepFM: A Factorization-Machine based Neural Network for CTR Prediction," in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

[13] M. Volkovs, G. Yu, và T. Poutanen, "DropoutNet: Addressing Cold Start in Recommender Systems," in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 4957–4966.

[14] G. Salton và C. Buckley, "Term-weighting Approaches in Automatic Text Retrieval," *Information Processing and Management*, vol. 24, no. 5, pp. 513–523, 1988.

[15] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, và R. Harshman, "Indexing by Latent Semantic Analysis," *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

Đánh giá, kiểm định và công cụ

[16] K. Järvelin và J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

[17] W. Krichene và S. Rendle, “On Sampled Metrics for Item Recommendation,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD ’20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

[18] Z. Meng, R. McCreadie, C. Macdonald, và I. Ounis, “Exploring Data Splitting Strategies for the Evaluation of Recommendation Models,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys ’20)*, 2020, pp. 681–686. DOI: 10.1145/3383313.3418479

[19] A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

[20] D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

[21] M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, “Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys ’19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

[22] F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[23] B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[24] S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.