

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI
KẾT HỢP NHÂN TỬ HOÁ MA TRẬN
VÀ MẠNG LƯỚI THẦN KINH SÂU**

**DỰ ÁN CÔNG NGHỆ THÔNG TIN
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI
KẾT HỢP NHÂN TỬ HOÁ MA TRẬN
VÀ MẠNG LƯỚI THẦN KINH SÂU**

**DỰ ÁN CÔNG NGHỆ THÔNG TIN
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

**Giảng viên hướng dẫn
TS. HỒ THỊ LINH**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chu chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày tháng năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan báo cáo dự án này là công trình nghiên cứu độc lập của chúng tôi dưới sự hướng dẫn khoa học trực tiếp của TS. Hồ Thị Linh. Mọi số liệu, quá trình phân tích và kết quả thực nghiệm trình bày trong báo cáo là hoàn toàn trung thực, khách quan và chưa từng được công bố dưới bất kỳ hình thức nào trước đây.

Các nguồn tài liệu tham khảo, số liệu trích dẫn phục vụ cho dự án đều có nguồn gốc rõ ràng, có độ tin cậy cao và được chú thích đầy đủ trong danh mục tài liệu tham khảo.

Chúng tôi xin hoàn toàn chịu trách nhiệm trước Nhà trường và pháp luật về tính chân thực, bản quyền cũng như các vi phạm quyền sở hữu trí tuệ liên quan đến nội dung báo cáo dự án này.

TP. Hồ Chí Minh, ngày tháng năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Nhân tử hóa ma trận (Matrix Factorization – MF) mô hình hóa tương tác giữa khách hàng và sản phẩm bằng tích vô hướng của hai vector ẩn [1]: một phép kết hợp tuyến tính, và chỉ học được từ những sản phẩm đã có người mua. Với dữ liệu thời trang – cực thừa và có nhiều sản phẩm mới ra mắt liên tục – cả hai điều này đều là giới hạn. Dự án xây dựng **NeuMF-F**, một mô hình lai giữ cấu trúc hai nhánh của Neural Matrix Factorization [2] – nhánh tuyến tính Generalized Matrix Factorization (GMF) và nhánh phi tuyến Multi-Layer Perceptron (MLP), hợp nhất ở lớp dự đoán – nhưng biểu diễn mỗi khách hàng và sản phẩm bằng Embedding mã ID cộng với phép chiếu của đặc trưng: thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng, doanh số và thời gian. Khi huấn luyện, ID của sản phẩm được bỏ ngẫu nhiên để mô hình học cách chấm điểm cả những sản phẩm chưa từng được bán.

Thực nghiệm dùng bộ dữ liệu H&M Personalized Fashion Recommendations [3] (31,8 triệu giao dịch). Hai mẫu khách hàng không giao nhau được lấy tái lập được theo hàm băm: mẫu phát triển A (21.599 khách) chỉ dùng để tinh chỉnh trên tập xác thực, mẫu kiểm định B (21.030 khách) chỉ dùng một lần cho đánh giá cuối. Dữ liệu được chia theo thời gian; lọc k -core chỉ dùng dữ liệu trước mốc kiểm thử; tập ứng viên gồm cả sản phẩm mới (**[chưa có]**% sản phẩm đúng ở tập kiểm thử của mẫu B là sản phẩm chưa từng bán trước mốc); mọi đặc trưng được tính theo thời điểm, không dùng thông tin tương lai. Mười bốn mô hình – NeuMF-F, từng nhánh GMF-F và MLP-F, hợp nhất muộn LateFusion-F, NeuMF chỉ dùng ID cùng hai nhánh của nó, và bảy baseline Random, Most Popular, MostPopular-Recent, gợi ý theo nội dung, ItemKNN, UserKNN, BPR-MF – được tinh chỉnh với cùng ngân sách. Đánh giá cuối theo kế hoạch đăng ký trước, có khoá tập kiểm thử: Full Ranking, 5 seed, kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm trên họ 10 so sánh.

Trên tập kiểm thử của mẫu B (**[chưa có]** khách hàng), NeuMF-F đạt $NDCG@10 = \text{[chưa có]}$, xếp **[chưa có]** trong 14 mô hình; NeuMF chỉ dùng ID đạt **[chưa có]**, BPR-MF **[chưa có]**, UserKNN **[chưa có]**, MostPopular-Recent **[chưa có]**. **[chưa có]** Trên nhóm sản phẩm mới, NeuMF-F đạt $NDCG@10 = \text{[chưa có]}$, trong khi mọi mô hình chỉ dùng ID bằng 0 theo cấu tạo. Giai đoạn phát triển trước

đó (NeuMF chỉ dùng ID, đánh giá trên chính mẫu phát triển) được báo cáo như lịch sử phát triển: NeuMF không vượt MF đã tinh chỉnh – lý do đề tài chuyển sang bổ sung thông tin thay vì chỉ tăng độ phức tạp của mô hình. Hệ thống demo suy diễn (FastAPI) minh họa và so sánh các mô hình trên từng khách hàng.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Matrix Factorization (MF) models customer–item interactions with the inner product of two latent vectors [1]: a linear combination that can only be learned for items somebody has already bought. On fashion data – extremely sparse, with new products launched all the time – both are limitations. This project builds **NeuMF-F**, a hybrid model that keeps the two-branch structure of Neural Matrix Factorization [2] – a linear Generalized Matrix Factorization (GMF) branch and a non-linear Multi-Layer Perceptron (MLP) branch fused at the prediction layer – but represents every customer and item by an ID embedding plus a projection of features: item attributes and text description, customer attributes, sales and time. During training, item IDs are randomly dropped so that the model learns to score items that have never been sold.

Experiments use the H&M Personalized Fashion Recommendations dataset [3] (31.8 million transactions). Two disjoint, reproducible customer samples are drawn by hashing: development sample A (21,599 customers) is used only for tuning on its validation set, and holdout sample B (21,030 customers) is used once, for the final evaluation. Data are split by time; the k -core filter uses only data before the test cut-off; the candidate set includes new items ([chura có] % of the test targets of sample B were never sold before the cut-off); all features are computed point-in-time, without future information. Fourteen models – NeuMF-F, its GMF-F and MLP-F branches, the late-fusion LateFusion-F, ID-only NeuMF with its two branches, and seven baselines (Random, Most Popular, recent popularity, content-based, ItemKNN, UserKNN, BPR-MF) – are tuned with the same budget. The final evaluation follows a pre-registered plan with a locked test set: full ranking, five seeds, per-user Wilcoxon signed-rank tests with bootstrap confidence intervals and Holm correction over a family of ten comparisons.

On the test set of sample B ([chura có] customers), NeuMF-F reaches $\text{NDCG@10} = [\text{chura có}]$, compared with $[\text{chura có}]$ for ID-only NeuMF, $[\text{chura có}]$ for BPR-MF, $[\text{chura có}]$ for UserKNN and $[\text{chura có}]$ for recent popularity. In the pre-registered family, $[\text{chura có}]$. On new items, NeuMF-F reaches $\text{NDCG@10} = [\text{chura có}]$, whereas every ID-only model scores zero by construction. The earlier

development phase (ID-only NeuMF, evaluated on the development sample itself) is reported as development history: NeuMF did not outperform a tuned MF baseline, which is why the project turned to adding information rather than only model complexity. An inference-only demo (FastAPI) compares the models for individual customers.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	xii
DANH MỤC BẢNG BIỂU.....	xiii
DANH MỤC CÁC CHỮ VIẾT TẮT.....	xiv
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài.....	1
1.1.2 Vì sao nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này.....	1
1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F).....	2
1.2 Mục tiêu và phạm vi nghiên cứu	3
1.2.1 Mục tiêu nghiên cứu	3
1.2.2 Phạm vi nghiên cứu.....	3
1.3 Phương pháp nghiên cứu	4
1.4 Ý nghĩa khoa học và thực tiễn của đề tài.....	5
1.4.1 Ý nghĩa khoa học	5
1.4.2 Ý nghĩa thực tiễn.....	5
1.5 Bố cục của báo cáo dự án	6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	7
2.1 Tổng quan về hệ thống gợi ý (Recommendation System)	7
2.1.1 Lọc nội dung, lọc cộng tác và lọc lai: lựa chọn của đề tài	7
2.1.2 Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based)	8
2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback)	9
2.1.4 Độ thưa dữ liệu và khởi đầu lạnh: hai giới hạn định hình thiết kế của đề tài	9
2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận	10
2.2.1 Mô hình Nhân tử hóa ma trận (Matrix Factorization – MF)	10

2.2.2	Hạn chế của tích vô hướng trong mô hình hóa tương tác	10
2.2.3	Tối ưu hóa xếp hạng theo cặp: Bayesian Personalized Ranking (BPR)	11
2.3	Kiến trúc Mạng khuyến nghị thần kinh (Neural Collaborative Filtering – NCF).....	11
2.3.1	Generalized Matrix Factorization (GMF)	11
2.3.2	Multi-Layer Perceptron (MLP)	12
2.3.3	Kiến trúc mô hình lai NeuMF	12
2.3.4	Chiến lược hợp nhất: Early Fusion và Late Fusion.....	12
2.3.5	Lấy mẫu âm (Negative Sampling) và hàm tổn thất Binary Cross-Entropy .	14
2.4	Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu	15
2.4.1	Mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm	15
2.4.2	Gợi ý theo chuỗi hành vi và Transformer	16
2.4.3	Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)	16
2.4.4	Mô hình tự mã hóa biến phân (Variational Autoencoder) cho lọc cộng tác	17
2.5	Các chỉ số đánh giá hệ thống gợi ý Top-K.....	18
2.5.1	Các chỉ số đánh giá ngoài độ chính xác (Beyond-Accuracy Metrics)	19
2.6	Tổng quan các công trình nghiên cứu liên quan.....	20
2.7	Khoảng trống nghiên cứu	24
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F.....		25
3.1	Kiến trúc tổng thể của hệ thống nghiên cứu.....	25
3.2	Dữ liệu và tiền xử lý.....	25
3.2.1	Đặc tả bộ dữ liệu H&M	25
3.2.2	Lấy mẫu theo khách hàng: mẫu phát triển A và mẫu kiểm định B	27
3.2.3	Ma trận tương tác và lọc k-core trước mốc kiểm thử.....	28
3.2.4	Giai đoạn đánh giá, sản phẩm mới và tập ứng viên.....	29
3.2.5	Xây dựng đặc trưng theo thời điểm.....	31
3.3	Thiết kế mô hình lai NeuMF-F	32
3.3.1	Biểu diễn lai: Embedding ID kết hợp đặc trưng	32

3.3.2	Nhánh GMF-F	34
3.3.3	Nhánh MLP-F.....	34
3.3.4	Tầng hợp nhất và lớp dự đoán đầu ra	34
3.3.5	Các mô hình đối chiếu xây dựng trên cùng khung.....	35
3.4	Lấy mẫu âm theo thời điểm và hàm mục tiêu.....	36
3.4.1	Lấy mẫu âm động theo ngày ra mắt của sản phẩm.....	36
3.4.2	Hàm tổn thất Binary Cross-Entropy và điều chuẩn	36
3.5	Quy trình huấn luyện và tinh chỉnh.....	36
3.5.1	Bảng thiết lập siêu tham số và kỹ thuật dừng sớm.....	36
3.6	Quy trình đánh giá không thiên lệch	38
3.7	Thiết kế hệ thống giao diện thực nghiệm (Demo)	39
3.7.1	Kiến trúc tổng thể: ba tầng tách biệt.....	39
3.7.2	Thiết kế API suy diễn.....	41
3.7.3	Lựa chọn mô hình triển khai và yêu cầu phi chức năng.....	42
3.7.4	Minh họa hệ thống demo đã cài đặt.....	42
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ		44
4.1	Cấu hình thực nghiệm.....	44
4.2	Phương pháp đối chứng (Baselines).....	45
4.3	Kết quả tinh chỉnh trên tập xác thực của mẫu A	46
4.4	Kết quả đánh giá cuối trên mẫu kiểm định B	46
4.4.1	So sánh các độ đo xếp hạng (Full Ranking).....	46
4.4.2	Kiểm định ý nghĩa thống kê.....	47
4.4.3	Sản phẩm cũ và sản phẩm mới.....	47
4.4.4	Phân tích bóc tách thành phần (Ablation Study).....	48
4.4.5	Độ phủ, sản phẩm mới trong gợi ý và chi phí huấn luyện	48
4.4.6	Hội tụ và độ ổn định giữa hai mẫu	48
4.5	Lịch sử phát triển: giao thức v1	49
4.6	Phạm vi và giới hạn thực nghiệm	50

4.7	Thảo luận	50
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....		52
5.1	Kết luận.....	52
5.2	Hạn chế của đề tài.....	53
5.3	Hướng phát triển	53
5.4	Triển khai thực tế giao diện thực nghiệm	54
PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN		55
PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM.....		58
TÀI LIỆU THAM KHẢO.....		59

DANH MỤC HÌNH VẼ

Hình 2.1: Sơ đồ kiến trúc chi tiết mô hình lai Neural Matrix Factorization (NeuMF)	13
Hình 2.2: Hai cách hợp nhất cùng hai thành phần MF (GMF) và DNN (MLP): ở mức biểu diễn (NeuMF, NeuMF-F) và ở mức điểm dự đoán (Late Fusion, LateFusion-F)	14
Hình 3.1: Kiến trúc tổng thể của hệ thống nghiên cứu theo giao thức v2, từ dữ liệu thô H&M đến đánh giá cuối trên mẫu kiểm định.....	26
Hình 3.2: Kiến trúc mô hình lai NeuMF-F: mỗi nhánh có bảng Embedding ID và phép chiếu đặc trưng riêng; $m_i = 0$ với sản phẩm chưa có dữ liệu huấn luyện	33
Hình 3.3: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo).....	40

DANH MỤC BẢNG BIỂU

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan	20
Bảng 3.1: Độ nhảy k -core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ)	27
Bảng 3.2: Độ nhảy của mẫu A theo ngưỡng lọc k -core (khảo sát ở giai đoạn phát triển, 429.964 cặp trước khi lọc)	29
Bảng 3.3: Đặc trưng của mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F).....	31
Bảng 3.4: Không gian tinh chỉnh (giá trị in đậm là cấu hình mặc định)	37
Bảng 3.5: Các endpoint chính của API suy diễn	41

DANH MỤC CÁC CHỮ VIẾT TẮT

ALS	Alternating Least Squares (Bình phương tối thiểu luân phiên)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hóa Bayes)
CF	Collaborative Filtering (Lọc cộng tác)
CI	Confidence Interval (Khoảng tin cậy)
CPU	Central Processing Unit (Bộ xử lý trung tâm)
CTR	Click-Through Rate (Tỷ lệ nhấp chuột)
DCG	Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu)
DL	Deep Learning (Học sâu)
DNN	Deep Neural Network (Mạng nơ-ron sâu)
FM	Factorization Machines (Máy nhân tử hóa)
GMF	Generalized Matrix Factorization (Nhân tử hóa ma trận tổng quát)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
HR	Hit Ratio (Tỷ lệ đánh trúng)
iALS	implicit Alternating Least Squares (Bình phương tối thiểu luân phiên cho phản hồi ẩn)
IDCG	Ideal Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu lý tưởng)
ItemKNN	Item-based k -Nearest Neighbors (Lọc cộng tác theo k sản phẩm láng giềng gần nhất)
LSA	Latent Semantic Analysis (Phân tích ngữ nghĩa tiềm ẩn)

MD5	Message-Digest Algorithm 5 (Hàm băm MD5)
MF	Matrix Factorization (Nhân tử hóa ma trận)
MLP	Multi-Layer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
NCF	Neural Collaborative Filtering (Lọc cộng tác dựa trên nơ-ron)
NDCG	Normalized Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu chuẩn hóa)
NeuMF	Neural Matrix Factorization (Nhân tử hóa ma trận thần kinh)
NeuMF-F	NeuMF bổ sung đặc trưng (mô hình đề tài; GMF-F, MLP-F: hai nhánh có đặc trưng)
RAM	Random Access Memory (Bộ nhớ truy cập ngẫu nhiên)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
SVD	Singular Value Decomposition (Phân rã giá trị kỳ dị)
TF-IDF	Term Frequency – Inverse Document Frequency (Tần suất từ – nghịch đảo tần suất văn bản)
UserKNN	User-based k -Nearest Neighbors (Lọc cộng tác theo k người dùng láng giềng gần nhất)
VAE	Variational Autoencoder (Bộ tự mã hóa biến phân)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài

Động lực trực tiếp của đề tài xuất phát từ việc khảo sát bộ dữ liệu H&M Personalized Fashion Recommendations [3]: tệp giao dịch gốc ghi nhận 31.788.324 dòng mua hàng của 1.362.281 khách hàng trên 104.547 sản phẩm thời trang trong hai năm (mục 3.2.1). Hai đặc điểm của dữ liệu này đặt ra yêu cầu cho mô hình gợi ý. Thứ nhất, ma trận tương tác *cực thưa*: ngay cả sau khi lọc k -core, mật độ chỉ khoảng 0,03% trên toàn bộ dữ liệu (Bảng 3.1) – mỗi khách chỉ mua một phần rất nhỏ của danh mục, và lệch mạnh về một nhóm nhỏ sản phẩm phổ biến. Thứ hai, danh mục *thay đổi rất nhanh* theo mùa: trong mẫu dữ liệu của đề tài, 27% cặp (khách, sản phẩm) được mua lần đầu trong 8 tuần cuối là sản phẩm chưa từng được bán trước đó (mục 3.2.4). Một mô hình chỉ học từ mã khách hàng và mã sản phẩm không có thông tin gì về những sản phẩm mới này. Trong khi đó, bộ dữ liệu có sẵn thuộc tính và mô tả văn bản của từng sản phẩm, thông tin khách hàng và doanh số theo thời gian.

Câu hỏi của đề tài vì vậy là: trên dữ liệu giao dịch thời trang thực tế – cực thưa, lệch về sản phẩm phổ biến và có nhiều sản phẩm mới – một mô hình lai kết hợp nhân tử hóa ma trận với mạng nơ-ron sâu, được bổ sung đặc trưng sản phẩm, khách hàng và thời gian, có cho chất lượng gợi ý tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ và tốt hơn chính các thành phần của nó hay không. Đề tài không dựa vào kết quả công bố của các công trình tham khảo (dùng dữ liệu phim ảnh, mạng xã hội hình ảnh với giao thức khác), mà xây dựng và đánh giá mô hình trực tiếp trên dữ liệu H&M với cách chia dữ liệu và giao thức đánh giá riêng.

Ở góc độ ứng dụng, cá nhân hóa gợi ý sản phẩm trong thương mại điện tử giúp giảm chi phí tìm kiếm của khách hàng và hỗ trợ doanh nghiệp dự báo nhu cầu [4], [5]. Với ngành thời trang, khả năng gợi ý được sản phẩm *mới* có giá trị đặc biệt: đó chính là hàng hóa doanh nghiệp cần giới thiệu tới khách hàng.

1.1.2 Vì sao nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này

Cách tiếp cận đơn giản nhất cho bài toán trên là Nhân tử hóa ma trận (Matrix Factorization – MF): mỗi User u và Item i được gán một vector ẩn $p_u, q_i \in \mathbb{R}^d$, và mức

độ tương tác được dự đoán bằng tích vô hướng của hai vector [1]:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^d p_{uf} q_{if} \quad (1.1)$$

Công thức này có hai giới hạn trên dữ liệu H&M. Một là giới hạn về *biểu diễn*: tích vô hướng cộng dồn các chiều đặc trưng theo cùng một trọng số cố định và chỉ mô hình hóa được tương tác tuyến tính – He và cộng sự [2] lấy đây làm động cơ để bổ sung một thành phần phi tuyến. Hai là giới hạn về *thông tin*: vector q_i chỉ học được từ các lần sản phẩm i đã được mua, nên sản phẩm mới – chưa có lần mua nào – không có biểu diễn có nghĩa; đây là vấn đề khởi đầu lạnh của sản phẩm [6], và không thể giải quyết chỉ bằng cách làm mô hình phức tạp hơn mà phải bổ sung thông tin về chính sản phẩm.

1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F)

NeuMF – do He và cộng sự đề xuất năm 2017 [2] – giải quyết giới hạn thứ nhất bằng cách kết hợp thay vì thay thế MF: một nhánh tương đương MF dưới dạng mạng nơ-ron (Generalized Matrix Factorization, GMF) giữ khả năng học tương tác tuyến tính, và một nhánh Multi-Layer Perceptron (MLP) song song học thêm tương tác phi tuyến; hai nhánh được hợp nhất ở lớp dự đoán. Tuy nhiên, giai đoạn phát triển của đề tài (mục 4.5) cho thấy NeuMF chỉ dùng mã ID không vượt được MF được tinh chỉnh tốt trên dữ liệu H&M – phù hợp với các tái đánh giá độc lập [7], [8] – và không gợi ý được sản phẩm mới.

Đề tài vì vậy xây dựng **NeuMF-F**: giữ nguyên cấu trúc hai nhánh GMF và MLP của NeuMF, nhưng biểu diễn mỗi khách hàng và sản phẩm bằng tổng của Embedding ID và một phép chiếu của đặc trưng (thuộc tính và mô tả sản phẩm, thông tin khách hàng, doanh số và thời gian), theo hướng các mô hình lai dựa trên đặc trưng như Wide & Deep [9] và DeepFM [10]. Sản phẩm mới không có ID vẫn có vector từ đặc trưng, nên được chấm điểm như mọi sản phẩm khác. Cấu trúc hai nhánh tường minh cho phép *tách bạch* từng đóng góp bằng các phép so sánh trực tiếp: với NeuMF chỉ dùng ID (đóng góp của đặc trưng), với từng nhánh đứng riêng (đóng góp của việc hợp nhất), và với Late Fusion của cùng hai nhánh (hợp nhất sớm hay muộn).

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

- Nghiên cứu cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận, Mạng nơ-ron sâu, kiến trúc NeuMF, mô hình lai dựa trên đặc trưng và hai cách hợp nhất Early Fusion, Late Fusion [1], [2], [11].
- Xây dựng quy trình xử lý dữ liệu hoàn chỉnh trên bộ dữ liệu H&M [3]: lấy mẫu theo khách hàng, xây dựng ma trận tương tác phản hồi ẩn, chia dữ liệu theo thời gian, xây dựng đặc trưng sản phẩm, khách hàng và thời gian *theo thời điểm* – không dùng bất kỳ thông tin nào xảy ra sau thời điểm cần dự đoán.
- Thiết kế và cài đặt mô hình lai NeuMF-F trên nền tảng PyTorch [12], cùng các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, NeuMF chỉ dùng ID) và sáu baseline (Most Popular, MostPopular-Recent, gợi ý theo nội dung, ItemKNN, UserKNN, BPR-MF), mọi mô hình được tinh chỉnh với cùng ngân sách.
- Đánh giá thực nghiệm định lượng theo giao thức Full Ranking với tập ứng viên gồm cả sản phẩm mới, bằng các độ đo NDCG@K [13], Recall@K, HR@K, Precision@K; kết luận trên một mẫu khách hàng độc lập chưa từng được dùng để ra quyết định, theo kế hoạch đăng ký trước, với 5 lần chạy và kiểm định thống kê có hiệu chỉnh đa so sánh; phân tích theo nhóm sản phẩm cũ/mới và ablation từng nhóm đặc trưng.
- Xây dựng hệ thống demo minh họa mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang.

1.2.2 Phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Kiến trúc Neural Collaborative Filtering (GMF, MLP, NeuMF) [2] và mở rộng có đặc trưng của nó (NeuMF-F); hai cách hợp nhất mô hình MF với mạng nơ-ron sâu – Early Fusion (mức biểu diễn) và Late Fusion (mức điểm dự đoán) [11]; các phương pháp đánh giá hệ thống gợi ý Top-K.
- **Dữ liệu thực nghiệm:** Bộ dữ liệu H&M Personalized Fashion Recommendations [3]: tệp giao dịch, tệp danh mục sản phẩm (thuộc tính, mô tả văn bản) và tệp thông tin khách hàng. Khảo sát quy mô được chạy trên toàn bộ

31,8 triệu giao dịch; huấn luyện và đánh giá được thực hiện trên hai mẫu khoảng 500.000 giao dịch, mỗi mẫu khoảng 21.000 khách hàng được chọn ngẫu nhiên theo hàm băm, không có khách chung, giữ trọn lịch sử 2 năm (lý do ở mục 3.2.2). Ảnh sản phẩm không được dùng làm đầu vào mô hình.

- **Tín hiệu tương tác:** Phản hồi ẩn dạng nhị phân từ lịch sử mua hàng (mua hay chưa mua), kèm ngày mua.
- **Khởi đầu lạnh:** sản phẩm mới (chưa từng bán trước thời điểm dự đoán) nằm *trong* phạm vi đánh giá; người dùng mới (chưa có lịch sử mua) nằm ngoài phạm vi đánh giá định lượng – hệ thống demo xử lý trường hợp này bằng gợi ý theo luật.

1.3 Phương pháp nghiên cứu

Để giải quyết các mục tiêu đã đặt ra (mục 1.2.1), đề tài kết hợp bốn nhóm phương pháp, được triển khai tuần tự theo trình tự trình bày trong các chương tiếp theo:

1. **Phương pháp nghiên cứu lý thuyết (phân tích và tổng hợp tài liệu):** Hệ thống hóa cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận, kiến trúc NCF/NeuMF và mô hình lai dựa trên đặc trưng từ các công trình nền tảng [1], [2], [9], [14], đồng thời khảo sát các hướng nghiên cứu hiện đại hơn để xác định vị trí đóng góp và giới hạn của hướng tiếp cận được lựa chọn (Chương 2). Các công trình được dùng làm cơ sở về phương pháp; số liệu của chúng không được dùng làm chuẩn so sánh vì khác dữ liệu và giao thức.
2. **Phương pháp xử lý dữ liệu định lượng:** Xây dựng quy trình tiền xử lý tường minh, tái lập được và kiểm chứng được ở từng bước – lấy mẫu theo khách hàng, gộp giao dịch, lọc k -core chỉ trên dữ liệu trước mốc kiểm thử, chia giai đoạn theo thời gian, xây dựng đặc trưng theo thời điểm – với bộ kiểm thử tự động xác nhận không rò rỉ thông tin tương lai (Chương 3).
3. **Phương pháp thực nghiệm khoa học (mô hình hóa và huấn luyện):** Cài đặt các mô hình bằng PyTorch [12], huấn luyện bằng hàm mất mát Binary Cross-Entropy với lấy mẫu âm theo thời điểm, tối ưu bằng Adam [15]; siêu tham số của mọi mô hình được tinh chỉnh với cùng ngân sách, chỉ trên tập xác thực của mẫu phát triển.
4. **Phương pháp đánh giá định lượng và kiểm chứng thống kê:** Đánh giá

Full Ranking trên tập ứng viên gồm cả sản phẩm mới; đăng ký trước kế hoạch đánh giá và khoá tập kiểm thử; kết luận trên một mẫu khách hàng độc lập; kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm [16], [17], [18] (Chương 4).

Điểm xuyên suốt của phương pháp luận là ưu tiên tính tái lập và kiểm chứng được: mọi số liệu kết quả trong báo cáo đều được trích xuất tự động từ tập kết quả do chính quy trình thực nghiệm sinh ra, không nhập tay.

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

- Cung cấp kết quả thực nghiệm có kiểm định thống kê, trên dữ liệu giao dịch thời trang thực tế và trên một mẫu khách hàng chưa từng dùng để ra quyết định, về việc mô hình lai MF + DNN có đặc trưng (NeuMF-F) có vượt các baseline được tinh chỉnh cùng ngân sách, vượt NeuMF chỉ dùng ID và vượt từng nhánh thành phần của nó hay không (kết quả ở Chương 4).
- Làm rõ vị trí của NeuMF/NeuMF-F trong phân loại Early Fusion/Late Fusion (mục 2.3.4) và so sánh trực tiếp hai cách hợp nhất trên cùng hai thành phần.
- Xây dựng một quy trình đánh giá chống thiên lệch có thể tái sử dụng cho các nghiên cứu hệ gợi ý khác: tập ứng viên gồm cả sản phẩm mới, đặc trưng theo thời điểm, cùng ngân sách tinh chỉnh, mẫu kiểm định độc lập, đăng ký trước, khoá tập kiểm thử kèm nhật ký truy cập, kiểm định cặp có hiệu chỉnh đa so sánh.

1.4.2 Ý nghĩa thực tiễn

- Mô hình gợi ý được cả sản phẩm cũ lẫn sản phẩm mới ra mắt – yêu cầu thực tế của ngành bán lẻ thời trang – chỉ từ dữ liệu mà một doanh nghiệp bán lẻ sẵn có (lịch sử giao dịch, danh mục sản phẩm, thông tin hội viên).
- Quy trình tiền xử lý tách phần đọc dữ liệu khỏi logic xử lý cốt lõi, đọc tệp theo lô (khoảng 0,5 GB RAM cho tệp 3,5 GB), nên thực nghiệm trên dữ liệu giao dịch lớn khả thi trên máy tính cá nhân và có thể tái sử dụng cho các bộ dữ liệu thương mại điện tử khác.
- Hệ thống demo suy diễn (FastAPI) cho phép so sánh trực quan các mô hình

trên từng khách hàng của mẫu kiểm định.

1.5 Bố cục của báo cáo dự án

Báo cáo dự án được trình bày trong 5 chương chính:

- **Chương 1 – Tổng quan về đề tài:** bối cảnh, tính cấp thiết, mục tiêu, phạm vi, phương pháp nghiên cứu và ý nghĩa của đề tài.
- **Chương 2 – Cơ sở lý thuyết và các công trình liên quan:** hệ thống gợi ý, Nhân tử hóa ma trận, BPR, GMF, MLP, NeuMF, Early/Late Fusion, mô hình lai dựa trên đặc trưng và khởi đầu lạnh, các chỉ số đánh giá và tổng quan các nghiên cứu liên quan.
- **Chương 3 – Phương pháp nghiên cứu và thiết kế mô hình lai NeuMF-F:** dữ liệu H&M và hai mẫu khách hàng, giai đoạn đánh giá có sản phẩm mới, đặc trưng theo thời điểm, kiến trúc NeuMF-F và các mô hình đối chiếu, lấy mẫu âm, huấn luyện, quy trình tinh chỉnh và đánh giá không thiên lệch, thiết kế hệ thống demo.
- **Chương 4 – Thực nghiệm và đánh giá kết quả:** kết quả tinh chỉnh trên mẫu phát triển, kết quả đánh giá cuối trên mẫu kiểm định, kiểm định thống kê, phân tích theo nhóm sản phẩm cũ/mới, ablation, lịch sử phát triển và thảo luận.
- **Chương 5 – Kết luận và hướng phát triển:** tổng kết kết quả, hạn chế và hướng mở rộng.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

Chương này trình bày cơ sở lý thuyết về hệ thống gợi ý, các mô hình được sử dụng trong đề tài và các công trình liên quan. Các công trình được dẫn là cơ sở về phương pháp (định nghĩa mô hình, cách huấn luyện, cách đánh giá); thực nghiệm trong các công trình đó dùng dữ liệu và giao thức khác nên số liệu của chúng không được dùng làm chuẩn để so sánh với kết quả của đề tài. Trong chương này, *User* (người dùng) và *Item* (sản phẩm) được dùng như thuật ngữ kỹ thuật theo cách gọi phổ biến trong tài liệu về hệ gợi ý.

2.1 Tổng quan về hệ thống gợi ý (Recommendation System)

2.1.1 *Lọc nội dung, lọc cộng tác và lọc lai: lựa chọn của đề tài*

Một hệ thống gợi ý có ba hướng tiếp cận chính. **Lọc dựa trên nội dung** (Content-Based) gợi ý những sản phẩm có đặc tính giống các sản phẩm User đã thích, dựa trên mô tả sản phẩm và hồ sơ sở thích của User [4], [19]. **Lọc cộng tác** (Collaborative Filtering – CF) khai thác lịch sử tương tác chung giữa nhiều User và Item: những User từng mua giống nhau có khả năng sẽ mua giống nhau [1], [20]; CF chỉ cần ma trận tương tác User–Item, không đòi hỏi đặc trưng mô tả đối tượng [21]. **Lọc lai** (Hybrid) kết hợp nhiều kỹ thuật – thường gặp nhất là kết hợp nội dung với cộng tác – để bù hạn chế của từng kỹ thuật [9], [10], [22].

Lựa chọn của đề tài được quyết định bởi *đặc điểm của dữ liệu*. Bộ dữ liệu H&M (mục 3.2.1) có lịch sử giao dịch đủ dài để CF học được sở thích của khách mua thường xuyên, nhưng danh mục thời trang thay đổi rất nhanh: một phần đáng kể sản phẩm khách mua trong vài tuần tới là sản phẩm chưa từng được bán (mục 3.2.4). CF thuần dựa trên ID không có thông tin gì về những sản phẩm này, trong khi bộ dữ liệu lại có sẵn thuộc tính, mô tả văn bản của sản phẩm, thông tin khách hàng và doanh số theo thời gian. Vì vậy đề tài chọn hướng **lai**: lõi của mô hình là lọc cộng tác dựa trên mô hình – nhân tử hóa ma trận kết hợp mạng nơ-ron sâu (mục 2.2, 2.3) – được bổ sung đặc trưng nội dung và ngữ cảnh (mục 2.4.1). Các mô hình chỉ dùng ID và một mô hình gợi ý theo nội dung thuần được giữ làm đối chứng, để đo riêng đóng góp của từng nguồn thông tin.

2.1.2 *Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based)*

Xét theo cách khai thác dữ liệu tương tác, các phương pháp Lọc cộng tác được chia thành hai nhánh chính, đặt nền móng lý thuyết cho toàn bộ hướng tiếp cận Model-based mà đề tài lựa chọn.

Lọc cộng tác dựa trên bộ nhớ (Memory-based CF) tính toán trực tiếp độ tương đồng giữa các User hoặc Item từ ma trận tương tác thô, không qua bước học tham số trung gian, theo nguyên lý khởi nguồn của hệ thống GroupLens [23]. Với **Item-based CF** [20] – kỹ thuật được Amazon triển khai thành công ở quy mô công nghiệp [5] – độ tương đồng cosine giữa hai sản phẩm i, j được tính theo vector cột tương tác của chúng:

$$\text{sim}(i, j) = \cos(\vec{i}, \vec{j}) = \frac{\vec{i} \cdot \vec{j}}{\|\vec{i}\| \|\vec{j}\|} \quad (2.1)$$

Với phản hồi ẩn nhị phân, điểm của sản phẩm i cho User u là tổng độ tương đồng giữa i và những sản phẩm u đã mua, chỉ xét k láng giềng gần nhất $\mathcal{N}_k(i)$ của i (ItemKNN):

$$\hat{y}_{ui} = \sum_{j \in \mathcal{N}_k(i) \cap \mathcal{I}_u} \text{sim}(i, j) \quad (2.2)$$

Đối xứng với cách trên, **User-based CF** (UserKNN) tìm k User có lịch sử mua giống u nhất, $\mathcal{N}_k(u)$ – chính là “Top- K người dùng tương đồng” của u – rồi tính điểm mỗi sản phẩm bằng tổng độ tương đồng của những láng giềng đã mua sản phẩm đó:

$$\hat{y}_{ui} = \sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v) y_{vi} \quad (2.3)$$

Trong cài đặt của đề tài, độ tương đồng cosine được tính trên vector mua nhị phân, có thêm hệ số co (shrink) λ ở mẫu số để giảm trọng số của những cặp chỉ có rất ít tương tác chung: $\text{sim}(a, b) = |\mathcal{I}_a \cap \mathcal{I}_b| / (\sqrt{|\mathcal{I}_a| |\mathcal{I}_b|} + \lambda)$, với $\mathcal{I}_a$ là tập sản phẩm a đã mua (hoặc tập User đã mua sản phẩm a). Mỗi hàng của ma trận tương đồng chỉ giữ k láng giềng và được lưu dưới dạng ma trận thưa, nên chạy được với khoảng 10.000 sản phẩm; k và λ được chọn trên tập xác thực, và hai mô hình là baseline của đề tài (mục 4.2). Ưu điểm của nhánh này là đơn giản, không cần huấn luyện và dễ diễn giải – có thể chỉ ra cụ thể những User hoặc sản phẩm nào dẫn tới một gợi ý; nhược điểm là ma trận tương đồng đầy đủ tăng bậc hai theo số thực thể ($O(N^2)$) và chất lượng suy giảm khi ma trận tương tác quá thưa.

Lọc cộng tác dựa trên mô hình (Model-based CF) không tính tương đồng

trực tiếp mà học một hàm tham số hóa (Nhân tử hóa ma trận, mạng nơ-ron) để nén thông tin tương tác thành các vector biểu diễn ẩn có số chiều thấp, cho phép tổng quát hóa tốt hơn trên dữ liệu thưa và mở rộng quy mô tuyến tính theo số lượng tương tác thay vì bậc hai theo số Item [1], [21]. Toàn bộ các mô hình MF, GMF, MLP và NeuMF trình bày từ mục 2.2 trở đi thuộc nhánh Model-based, là hướng tiếp cận chính của đề tài.

2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback)

Về nguyên tắc, phản hồi của User có thể là phản hồi hiện (Explicit) – điểm số đánh giá trực tiếp như rating 1–5 sao – hoặc phản hồi ẩn (Implicit) – suy ra gián tiếp từ hành vi như lịch sử mua hàng, lượt click [2], [24]. Điểm cần nói rõ ở đây không phải là định nghĩa chung của hai khái niệm này, mà là một ràng buộc thực tế: tệp giao dịch H&M không có bất kỳ cột đánh giá (rating) nào – chỉ có bản ghi giao dịch đã xảy ra. Điều này loại bỏ hoàn toàn khả năng dùng Explicit Feedback, và buộc toàn bộ đề tài phải xây dựng tín hiệu tương tác dưới dạng nhị phân từ chính sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu tồn tại giao dịch giữa User } u \text{ và Item } i \text{ trong dữ liệu} \\ 0, & \text{ngược lại} \end{cases} \quad (2.4)$$

Hệ quả trực tiếp của cách xây dựng nhãn này – $y_{ui} = 1$ chỉ xác nhận *đã mua*, không xác nhận *hài lòng*, và $y_{ui} = 0$ có thể là “chưa từng biết đến sản phẩm” chứ không hẳn “không thích” [2] – là lý do trực tiếp khiến kỹ thuật lấy mẫu âm (Negative Sampling, mục 3.4.1) phải được thiết kế cẩn thận thay vì coi mọi cặp chưa tương tác là nhãn âm chắc chắn đúng.

2.1.4 Độ thưa dữ liệu và khởi đầu lạnh: hai giới hạn định hình thiết kế của đề tài

Hai thách thức kinh điển của Collaborative Filtering trực tiếp định hình thiết kế mô hình và phạm vi thực nghiệm của đề tài (mục 1.2.2):

- **Độ thưa dữ liệu (Data Sparsity):** Số cặp User–Item thực sự có tương tác chỉ chiếm một phần rất nhỏ trong toàn bộ ma trận $M \times N$ [1]. Trên dữ liệu của đề tài (Bảng 3.2, Bảng 3.1), ngay cả sau khi lọc k -core, mật độ chỉ khoảng 0,28% trên mẫu thực nghiệm ($k = 10$), và chỉ 0,03% trên toàn bộ 889.062 người dùng ở quy mô đầy đủ ($k = 5$).
- **Khởi đầu lạnh (Cold-Start):** xảy ra khi một User hoặc Item chưa có lịch

sử tương tác, khiến mô hình CF không có dữ liệu để học vector biểu diễn cho đối tượng đó [6]. Đề tài phân biệt hai trường hợp. *Khởi đầu lạnh của người dùng* nằm ngoài phạm vi: mọi khách được đánh giá đều có lịch sử mua trước mốc dự đoán (sau lọc k -core, mục 3.2.3). *Khởi đầu lạnh của sản phẩm* thì không thể tránh với dữ liệu thời trang – sản phẩm mới ra mắt liên tục – nên được đưa vào phạm vi đánh giá: sản phẩm chưa từng bán trước mốc dự đoán vẫn nằm trong tập ứng viên (mục 3.2.4), và mô hình đề tài chấm điểm chúng bằng đặc trưng nội dung (mục 2.4.1, 3.3).

2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận

2.2.1 Mô hình Nhân tử hóa ma trận (*Matrix Factorization – MF*)

Nhân tử hóa ma trận (MF) chiếu cả User và Item vào một không gian đặc trưng ẩn chung có số chiều $d \ll \min(M, N)$ [1]. Mỗi User u được biểu diễn bởi vector $p_u \in \mathbb{R}^d$ và mỗi Item i bởi vector $q_i \in \mathbb{R}^d$. Mức độ tương tác dự đoán $\hat{y}_{ui}$ được tính bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^d p_{uf} q_{if} \quad (2.5)$$

Các kỹ thuật MF khác nhau ở cách học hai ma trận nhân tử P và Q . Phân rã giá trị kỳ dị (Singular Value Decomposition – SVD) cổ điển phân rã một ma trận *đầy đủ*, nên không áp dụng trực tiếp được cho ma trận tương tác cực thưa, nơi phần lớn ô chưa được quan sát; các biến thể dùng trong hệ gợi ý thay vào đó tối ưu sai số trên các ô đã biết kèm điều chuẩn [1]. Với phản hồi ẩn, Bình phương tối thiểu luân phiên (Alternating Least Squares – ALS) dạng iALS [25] coi mọi ô là quan sát với độ tin cậy khác nhau và luân phiên giải bài toán bình phương tối thiểu cho P khi cố định Q rồi ngược lại; còn BPR (mục 2.2.3) tối ưu trực tiếp thứ hạng theo cặp. Đề tài dùng BPR-MF làm baseline MF chính; iALS [26] chỉ được thử trong giai đoạn phát triển (mục 4.5).

2.2.2 Hạn chế của tích vô hướng trong mô hình hóa tương tác

Tích vô hướng kết hợp các chiều đặc trưng ẩn độc lập theo dạng tuyến tính. He và cộng sự [2] lập luận rằng vì vậy phép toán này không học được các tương tác phức tạp, phi tuyến giữa các chiều đặc trưng của User và Item, và không đủ linh hoạt để biểu diễn chính xác quan hệ tương đồng giữa các User trong không gian ẩn. Lập luận này là động cơ lý thuyết của kiến trúc NCF (mục 2.3); việc bổ sung thành phần phi

tuyến có thực sự cải thiện chất lượng gợi ý hay không phụ thuộc vào dữ liệu, và được đề tài kiểm tra bằng thực nghiệm trên dữ liệu H&M (Chương 4).

2.2.3 Tối ưu hóa xếp hạng theo cặp: *Bayesian Personalized Ranking (BPR)*

Khác với cách tiếp cận Pointwise (dự đoán độc lập từng điểm $\hat{y}_{ui}$ rồi so khớp với nhãn nhị phân như MF/GMF/MLP), Bayesian Personalized Ranking (BPR) [24] tối ưu hóa trực tiếp *thứ hạng tương đối* theo cặp (Pairwise Ranking), xuất phát từ giả định người dùng luôn ưa thích sản phẩm đã tương tác i hơn sản phẩm chưa tương tác j . Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR cực đại hóa xác suất hậu nghiệm dưới dạng:

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j) \in \mathcal{D}_S} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \lambda_{\Theta} \|\Theta\|^2 \quad (2.6)$$

trong đó $\hat{y}_{ui}, \hat{y}_{uj}$ được tính theo Công thức (2.5) khi kết hợp với MF (tạo thành baseline BPR-MF dùng trong Chương 4), và $\mathcal{D}_S$ là tập các bộ ba lấy mẫu. So với hàm tổn thất Binary Cross-Entropy theo hướng Pointwise được NeuMF sử dụng (Công thức (2.16)), mục tiêu Pairwise của BPR bám sát hơn với bản chất bài toán xếp hạng Top-K nhưng không tận dụng được các tầng phi tuyến sâu như kiến trúc NCF.

2.3 Kiến trúc Mạng khuyến nghị thần kinh (Neural Collaborative Filtering – NCF)

2.3.1 Generalized Matrix Factorization (GMF)

Generalized Matrix Factorization (GMF) là sự mở rộng của MF dưới dạng biểu diễn mạng nơ-ron [2], thực hiện phép nhân Element-wise (Hadamard product $\odot$) giữa vector Embedding của User p_u^G và Item q_i^G :

$$\phi^{GMF} = p_u^G \odot q_i^G \quad (2.7)$$

$$\hat{y}_{ui}^{GMF} = \sigma(h^T \phi^{GMF}) = \sigma(h^T (p_u^G \odot q_i^G)) \quad (2.8)$$

trong đó $\odot$ là phép nhân từng phần tử, h là vector trọng số lớp đầu ra, và $\sigma(x) = \frac{1}{1+e^{-x}}$ là hàm kích hoạt Sigmoid.

2.3.2 Multi-Layer Perceptron (MLP)

Nhánh Multi-Layer Perceptron (MLP) nối vector Embedding p_u^M và q_i^M (Concatenation) làm đầu vào cho chuỗi các lớp mạng liên tiếp [2]:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \quad (2.9)$$

$$\phi_L^{MLP} = a_L (W_L^T \phi_{L-1}^{MLP} + b_L) \quad (2.10)$$

trong đó W_L, b_L, a_L lần lượt là trọng số, độ lệch (bias) và hàm kích hoạt phi tuyến (như ReLU) tại lớp thứ L . Cấu trúc này giúp mô hình học các tương tác phi tuyến tính phức tạp giữa đặc trưng của User và Item.

2.3.3 Kiến trúc mô hình lai NeuMF

Mô hình lai NeuMF kết hợp song song hai luồng biểu diễn tuyến tính (GMF) và phi tuyến (MLP) trước lớp dự đoán cuối cùng [2]:

$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \quad (2.11)$$


$$\hat{y}_{ui} = \sigma \left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \right) \quad (2.12)$$

Chữ “lai” trong tên đề tài trước hết chỉ việc kết hợp hai cách mô hình hóa tương tác – nhân tử hóa ma trận (tuyến tính) và mạng nơ-ron sâu (phi tuyến) – trong cùng một mô hình, đúng như NeuMF được He và cộng sự [2] xây dựng bằng cách hợp nhất GMF với MLP. Theo phân loại cách hợp nhất ở mục 2.3.4, NeuMF là một mô hình Early Fusion ở mức biểu diễn. Mô hình đề tài NeuMF-F (mục 3.3) giữ đúng cấu trúc này và bổ sung đặc trưng nội dung của sản phẩm, thông tin khách hàng và thời gian vào vector của cả hai nhánh, nên còn là “hệ gợi ý lai” theo nghĩa rộng của Burke [22] – kết hợp lọc cộng tác với thông tin nội dung.

2.3.4 Chiến lược hợp nhất: Early Fusion và Late Fusion

Khi một hệ gợi ý kết hợp nhiều nguồn thông tin hoặc nhiều góc nhìn (view) về người dùng và sản phẩm, có hai cách hợp nhất cơ bản, phân biệt theo *mức* diễn ra phép hợp nhất [11], [27], [28]:

- **Early Fusion (hợp nhất ở mức đặc trưng/biểu diễn):** các vector đặc trưng $v_1, \dots, v_m$ của từng view được nối thành một biểu diễn chung, rồi *một* mô



Hình 2.1: Sơ đồ kiến trúc chi tiết mô hình lai Neural Matrix Factorization (NeuMF)

hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h([v_1; v_2; \dots; v_m]) \quad (2.13)$$

- **Late Fusion (hợp nhất ở mức quyết định/điểm dự đoán):** mỗi view được xử lý bởi một mô hình riêng h_j cho ra dự đoán độc lập, rồi các dự đoán được kết hợp bằng một cơ chế F – lấy trung bình, bỏ phiếu, trọng số cố định hoặc một mô hình học:

$$p = F(h_1(v_1), h_2(v_2), \dots, h_m(v_m)) \quad (2.14)$$

Khi F là tổng có trọng số, đây chính là kiểu lai *weighted* trong phân loại hệ gợi ý lai của Burke [22].


Ngoài hai cách trên còn có *hybrid fusion*, kết hợp cả mức đặc trưng lẫn mức quyết định [27]. Early Fusion học được tương tác giữa các view nhưng đòi hỏi một mô hình phù hợp với mọi view; Late Fusion linh hoạt hơn nhưng không nắm bắt được tương tác ở mức tín hiệu giữa các view, vì chỉ làm việc trên kết quả dự đoán [11].

Vị trí của các mô hình trong đề tài. Hai view chính ở đây là hai cách mô hình hóa tương tác: view tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và view phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi

đưa qua một lớp dự đoán chung (công thức (2.11)–(2.12)), nên là một mô hình **Early Fusion ở mức biểu diễn**, được huấn luyện chung từ đầu đến cuối (Hình 2.2a). Mô hình đề tài NeuMF-F giữ nguyên cách hợp nhất này với hai nhánh có đặc trưng GMF-F và MLP-F; thêm vào đó, đặc trưng nội dung và ngữ cảnh được cộng vào vector của từng nhánh ngay ở đầu vào, tức cũng được hợp nhất sớm với thông tin cộng tác (mục 3.3.1). Late Fusion tương ứng là trộn điểm của hai mô hình MF và DNN được huấn luyện *riêng*:

$$\hat{y}_{ui} = w \tilde{s}_{ui}^{MF} + (1 - w) \tilde{s}_{ui}^{DNN}, \quad \tilde{s}_{ui} = \frac{s_{ui} - \min_{j \in \mathcal{C}_u} s_{uj}}{\max_{j \in \mathcal{C}_u} s_{uj} - \min_{j \in \mathcal{C}_u} s_{uj}} \quad (2.15)$$

trong đó điểm s_{ui} của từng mô hình được chuẩn hóa min–max trên tập ứng viên $\mathcal{C}_u$ của User u để hai thang điểm so sánh được, và $w \in [0, 1]$ được chọn trên tập xác thực ($w = 1$ và $w = 0$ cho đúng thứ hạng của từng thành phần). Để so sánh công bằng với NeuMF-F, đề tài dùng chính hai thành phần của nó – **LateFusion-F** trộn điểm của GMF-F và MLP-F được huấn luyện riêng (Hình 2.2b); so sánh hai cách hợp nhất này là một câu hỏi của họ kiểm định (mục 3.6). Riêng nhánh MLP khi đứng một mình chỉ nối vector User và Item ở đầu vào: đó là mô hình DNN thuần, không phải phép hợp nhất MF với DNN (mục 3.3.5).



Hình 2.2: Hai cách hợp nhất cùng hai thành phần MF (GMF) và DNN (MLP): ở mức biểu diễn (NeuMF, NeuMF-F) và ở mức điểm dự đoán (Late Fusion, LateFusion-F)

2.3.5 Lấy mẫu âm (Negative Sampling) và hàm tổn thất Binary Cross-Entropy

Do dữ liệu phản hồi ẩn chỉ cung cấp các tương tác dương ($y_{ui} = 1$), kỹ thuật lấy mẫu âm (Negative Sampling) chọn ngẫu nhiên các Item mà User chưa từng tương

tác để gán nhãn âm ($y_{ui} = 0$); đây là cách làm được He và cộng sự sử dụng khi huấn luyện NCF [2].

Hàm tổn thất Binary Cross-Entropy (BCE) được áp dụng để tối ưu hóa toàn bộ tham số mô hình:

$$\mathcal{L}_{BCE} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] \quad (2.16)$$

trong đó $\mathcal{Y}$ là tập tương tác dương và $\mathcal{Y}^-$ là tập cặp âm được lấy mẫu.

2.4 Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu

Sau NCF/NeuMF [2], lĩnh vực hệ gợi ý phát triển theo nhiều hướng song song. Mục này chỉ điểm qua những hướng liên quan trực tiếp tới vị trí của đề tài (mục 2.7) và tới các hướng phát triển (Chương 5); các khảo sát của Zhang và cộng sự [29] và Li và cộng sự [30] hệ thống hóa đầy đủ hơn.

2.4.1 Mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm

Một nhánh phát triển trực tiếp của ý tưởng “lai tuyến tính – phi tuyến” là các mô hình dùng nhiều đặc trưng hơn cặp mã User–Item, xuất phát từ bài toán dự đoán tỷ lệ nhấp chuột (Click-Through Rate – CTR). Factorization Machines (FM) [14] tổng quát hóa MF cho vector đặc trưng bất kỳ: mỗi đặc trưng có một vector ẩn, và tương tác bậc hai giữa hai đặc trưng được mô hình hóa bằng tích vô hướng của hai vector ẩn đó; khi đặc trưng chỉ gồm mã User và mã Item, FM suy biến đúng về MF. Wide & Deep [9] chạy song song một nhánh tuyến tính (Wide) để ghi nhớ các tổ hợp đặc trưng tường minh và một nhánh MLP (Deep) để khái quát hóa, hai nhánh được huấn luyện chung và cộng ở lớp đầu ra; DeepFM [10] thay nhánh Wide bằng FM, hai nhánh dùng chung Embedding đặc trưng; Deep Interest Network [31] thêm cơ chế Attention trên lịch sử hành vi. Điểm chung của các kiến trúc này – một thành phần tuyến tính kiểu nhân tử hóa và một thành phần phi tuyến kiểu MLP, hợp nhất ở lớp dự đoán và huấn luyện chung – chính là cấu trúc của NeuMF; khác biệt là đầu vào gồm cả đặc trưng chứ không chỉ mã ID. Mô hình đề tài NeuMF-F (mục 3.3) đi theo hướng này: giữ hai nhánh GMF và MLP của NeuMF, và biểu diễn mỗi User/Item bằng tổng của Embedding ID và một phép chiếu tuyến tính của đặc trưng.

Lợi ích quan trọng nhất của đặc trưng trên dữ liệu thời trang là xử lý **khởi đầu lạnh của sản phẩm**. Một sản phẩm mới chưa có tương tác nào nên không có Embedding ID có nghĩa, nhưng vẫn có thuộc tính và mô tả – đủ để đặt nó gần những

sản phẩm tương tự đã bán. Schein và cộng sự [6] chỉ ra rằng gợi ý cho đối tượng khởi đầu lạnh đòi hỏi kết hợp thông tin nội dung với dữ liệu cộng tác. DropoutNet [32] đề xuất một kỹ thuật huấn luyện đơn giản cho mô hình nhận cả biểu diễn sở thích lẫn nội dung: khi huấn luyện, phần biểu diễn sở thích (học từ tương tác) của đối tượng bị bỏ ngẫu nhiên, buộc mô hình học cách chấm điểm chỉ từ nội dung – đúng tình huống của đối tượng mới lúc dự đoán. NeuMF-F áp dụng ý tưởng này bằng cách bỏ ngẫu nhiên Embedding ID của sản phẩm khi huấn luyện (mục 3.3.1).

Đặc trưng văn bản của sản phẩm (tên, mô tả) được biểu diễn theo cách cổ điển của truy hồi thông tin và lọc nội dung [19]: trọng số TF-IDF [33] – từ xuất hiện nhiều trong mô tả của một sản phẩm nhưng hiếm trong toàn danh mục thì có trọng số cao – rồi giảm chiều bằng phân rã giá trị kỳ dị rút gọn, tức phân tích ngữ nghĩa tiềm ẩn (Latent Semantic Analysis) [34], để các mô tả dùng từ khác nhau nhưng cùng chủ đề có vector gần nhau. Cách biểu diễn này không cần dữ liệu tương tác và không cần tài nguyên tính toán lớn như các mô hình ngôn ngữ hiện đại.

2.4.2 Gợi ý theo chuỗi hành vi và Transformer

NeuMF và MF coi lịch sử của User như một *tập hợp không thứ tự*. Gợi ý theo chuỗi mô hình hóa trình tự $(i_1, \dots, i_t)$ để dự đoán i_{t+1} : GRU4Rec [35] dùng mạng hồi quy có công cho phiên duyệt web; SASRec [36] thay hồi quy bằng Self-Attention một chiều; BERT4Rec [37] dùng Transformer hai chiều, huấn luyện bằng cách che ngẫu nhiên một số vị trí trong chuỗi rồi dự đoán lại. Hướng này hợp với dữ liệu có phiên rõ ràng; trên H&M, giao dịch chỉ ghi ngày mua (không có giờ hay mã phiên) và nhiều sản phẩm được mua cùng giỏ trong một ngày nên thứ tự trong ngày không xác định – vì vậy đề tài dùng yếu tố thời gian để chia dữ liệu, để huấn luyện lại trên dữ liệu mới nhất (mục 3.2.4) và làm đặc trưng tổng hợp (doanh số gần đây của sản phẩm, khoảng cách tới lần mua gần nhất của khách, mục 3.2.5), còn mô hình chuỗi là hướng phát triển. Transformer còn được dùng theo cách khác: làm mô hình hợp nhất nhiều view theo kiểu Early Fusion, như trong hướng tích hợp đa nguồn của Hồ Thị Linh [11].

2.4.3 Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)

Ma trận tương tác User–Item có thể xem là một đồ thị hai phía. NGCF [38] lan truyền Embedding qua láng giềng nhiều bước để vector mã hóa cả tín hiệu tương tác bậc cao (*high-order connectivity*); LightGCN [39] bỏ các phép biến đổi và hàm kích hoạt phi tuyến – được chỉ ra là không cần thiết cho CF thuần – và chỉ giữ phép lan

truyền tuyến tính:

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}} e_i^{(k)}, \quad e_u^* = \sum_{k=0}^K \alpha_k e_u^{(k)} \quad (2.17)$$

trong đó $\mathcal{N}_u$ là tập Item lân cận của User u trên đồ thị và e_u^* là biểu diễn cuối, tổng hợp có trọng số qua K tầng lan truyền. LightGCN được báo cáo vượt MF và NGCF trên các bộ dữ liệu thưa như Gowalla và Amazon-Book [39]; đây là một hướng phát triển của đề tài (mục 5.3), với điều kiện được đánh giá theo cùng quy trình không thiên lệch.

2.4.4 Mô hình tự mã hóa biến phân (Variational Autoencoder) cho lọc cộng tác

Mult-VAE [40] nhận *toàn bộ* vector mua $x_u \in \{0, 1\}^N$ của một User làm đầu vào, mã hóa thành một phân phối ẩn Gauss $q_\phi(z_u | x_u)$, rồi giải mã ra phân phối đa thức trên toàn bộ catalog $\pi(z_u) = \text{softmax}(f_\theta(z_u))$. Mô hình được huấn luyện bằng cách cực đại cận dưới biến phân (ELBO), với hệ số β điều chỉnh số hạng KL:

$$\mathcal{L}_\beta(x_u) = \mathbb{E}_{q_\phi(z_u | x_u)} [\log p_\theta(x_u | z_u)] - \beta \cdot \text{KL}(q_\phi(z_u | x_u) \parallel p(z_u)) \quad (2.18)$$

với hàm hợp lý đa thức $\log p_\theta(x_u | z_u) = \sum_i x_{ui} \log \pi_i(z_u)$. Khác NeuMF (tính điểm từng cặp (u, i) độc lập và cần lấy mẫu âm), Mult-VAE tính điểm cho cả catalog trong một lượt và dùng toàn bộ sản phẩm chưa mua làm tín hiệu âm, nên hợp tự nhiên với giao thức Full Ranking. Đề tài chưa cài đặt mô hình này; nó là một ứng viên cho nhánh học sâu ở hướng phát triển.

Các hướng mới hơn – học tự giám sát trên đồ thị [41], gợi ý sinh và mô hình ngôn ngữ lớn [42], [43], mô hình khuếch tán [44] – cần tài nguyên tính toán vượt phạm vi của đề tài (máy tính cá nhân), nên chỉ được ghi nhận ở đây. Ở quy mô công nghiệp, kiến trúc hai tháp [45] mã hóa User và Item thành hai vector độc lập để truy hồi bằng tìm kiếm lân cận gần đúng – cũng là lý do mô hình tích vô hướng dễ triển khai hơn MLP khi catalog rất lớn. Khảo sát của Li và cộng sự [30] xác nhận các khối GMF/MLP theo tinh thần NCF vẫn được dùng phổ biến trong các hệ lai hiện đại, dù không còn là hướng tiên phong.

Trong phạm vi đề tài, kiến trúc hai nhánh của NeuMF – bổ sung đặc trưng thành NeuMF-F – được lựa chọn làm trọng tâm (thay vì các hướng mới hơn kể trên) vì ba lý do cụ thể: (i) *Đặc điểm dữ liệu*: tập giao dịch H&M chỉ ghi ngày mua, không có phiên để áp dụng trực tiếp mô hình chuỗi (mục 2.4.2), nhưng có thuộc tính và mô tả

văn bản của sản phẩm – loại thông tin mà cách biểu diễn “Embedding ID + đặc trưng” khai thác được trực tiếp (mục 2.4.1); ảnh sản phẩm không được dùng vì chi phí tính toán; (ii) *Mục tiêu khoa học*: kiến trúc hai nhánh GMF/MLP tách biệt cho phép bóc tách từng thành phần, so sánh trực tiếp hai cách hợp nhất trên cùng hai thành phần (mục 2.3.4) và so sánh với chính NeuMF chỉ dùng ID để đo riêng đóng góp của đặc trưng – điều khó làm tương đương với các kiến trúc End-to-End phức tạp hơn; (iii) *Hạ tầng tính toán*: thực nghiệm chạy trên máy tính cá nhân với RAM 16 GB (mục 4.1), không đủ cho các mô hình sinh quy mô lớn. Ba lý do này nhất quán với khoảng trống nghiên cứu ở mục 2.7.

2.5 Các chỉ số đánh giá hệ thống gợi ý Top-K

Với mỗi người dùng được đánh giá u , mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\text{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm đúng của u (với giao thức Leave-One-Out $|T_u| = 1$; với giao thức chia theo mốc thời gian chung của đề tài, một người dùng có thể có nhiều sản phẩm đúng) và $\text{hits}_u = |T_u \cap \text{Rec}_K(u)|$. Mọi chỉ số được tính cho từng người dùng rồi lấy trung bình trên tập người dùng được đánh giá $\mathcal{U}_{test}$.

- **Hit Ratio at K (HR@K)**: người dùng được tính là “trúng” nếu có ít nhất một sản phẩm đúng trong top- K [2]:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}(\text{hits}_u \geq 1) \quad (2.19)$$

- **Precision@K và Recall@K**: tỉ lệ gợi ý đúng trong K sản phẩm, và tỉ lệ sản phẩm đúng tìm lại được:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \quad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \quad (2.20)$$

Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K = HR@K/ K – lý do các chỉ số này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm đúng.

- **Normalized Discounted Cumulative Gain at K (NDCG@K)**: thưởng nhiều hơn khi sản phẩm đúng nằm ở vị trí cao, theo định nghĩa của Järvelin

và Kekäläinen [13] với mức liên quan nhị phân:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^K \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|, K)} \frac{1}{\log_2(j+1)} \end{aligned} \quad (2.21)$$

IDCG là giá trị DCG khi mọi sản phẩm đúng xếp ở đầu danh sách, nên $\text{NDCG@K} \in [0, 1]$. Với $|T_u| = 1$ và sản phẩm đúng ở hạng r : $\text{NDCG@K} = 1/\log_2(r+1)$ nếu $r \leq K$, ngược lại bằng 0.

- **Chỉ số theo nhóm sản phẩm đúng (cũ/mới):** để biết mô hình gợi ý đúng loại sản phẩm nào, tập sản phẩm đúng được tách thành T_u^{cu} (sản phẩm đã có dữ liệu huấn luyện) và T_u^{moi} (sản phẩm chưa từng bán trước mốc dự đoán, mục 3.2.4). NDCG@K của nhóm được tính theo Công thức (2.21) với T_u thay bằng tập của nhóm, dùng *cùng* danh sách xếp hạng đầy đủ – tức sản phẩm đúng của nhóm kia được coi như không liên quan; người dùng không có sản phẩm đúng thuộc nhóm không được tính vào trung bình của nhóm.

Full Ranking và Sampled Ranking. Một số công trình, trong đó có He và cộng sự [2], đánh giá bằng cách xếp sản phẩm đúng giữa 100 ứng viên (1 đúng + 99 âm lấy mẫu) – gọi là Sampled Ranking. Krichene và Rendle [46] chứng minh chỉ số trên tập ứng viên lấy mẫu không nhất quán với chỉ số trên toàn bộ catalog – có thể đảo ngược kết luận “A tốt hơn B” – và khuyến nghị tránh lấy mẫu. Đề tài vì vậy chỉ dùng **Full Ranking**: xếp hạng toàn bộ tập ứng viên (khoảng 17 nghìn sản phẩm, gồm cả sản phẩm mới) trừ sản phẩm người dùng đã mua. Một phép đối chiếu với Sampled-99 ở giai đoạn phát triển cho thấy thứ hạng giữa các mô hình thay đổi giữa hai giao thức (mục 4.5).

2.5.1 Các chỉ số đánh giá ngoài độ chính xác (Beyond-Accuracy Metrics)

Chỉ tối ưu $\text{HR@K}/\text{NDCG@K}$ có thể khiến mô hình thiên lệch về việc luôn gợi ý các sản phẩm phổ biến nhất (*popularity bias*), vốn dễ trúng nhưng ít giá trị cá nhân hóa [47]. Để mô tả danh sách gợi ý ngoài độ chính xác, đề tài dùng hai chỉ số:

- **Độ phủ (Coverage):** tỉ lệ sản phẩm của không gian ứng viên $\mathcal{I}_{cand}$ xuất

hiện trong danh sách gợi ý của ít nhất một người dùng:

$$\text{Coverage}@K = \frac{|\bigcup_{u \in \mathcal{U}_{test}} \text{Rec}_K(u)|}{|\mathcal{I}_{cand}|} \quad (2.22)$$

Độ phủ thấp cho thấy mô hình chỉ khai thác một phần nhỏ danh mục – trường hợp giới hạn là Most Popular, mọi người dùng nhận gần như cùng một danh sách.

- **Tỉ lệ sản phẩm mới trong danh sách gợi ý:** trung bình theo người dùng của tỉ lệ sản phẩm mới (chưa từng bán trước mốc dự đoán) trong top- K . Mô hình chỉ dùng ID luôn có tỉ lệ này bằng 0; với mô hình có đặc trưng, chỉ số cho biết mô hình có thực sự đưa sản phẩm mới vào gợi ý hay không.

Hai chỉ số này chỉ mang tính mô tả và được trình bày cạnh NDCG@K trong Chương 4.

2.6 Tổng quan các công trình nghiên cứu liên quan

Bảng 2.1 tổng hợp các công trình nền tảng liên quan trực tiếp đến hướng tiếp cận của dự án.

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Sarwar et al. (2001) [20]	Item-based CF (ItemKNN)	MovieLens	Gợi ý theo độ tương đồng giữa sản phẩm, tính trước được và dễ diễn giải. <i>Hạn chế:</i> ma trận tương đồng tăng bậc hai theo số sản phẩm; chất lượng giảm khi dữ liệu quá thưa.
Rendle et al. (2009) [24]	BPR (Bayesian Personalized Ranking)	MovieLens, Netflix	Khung tối ưu dựa trên so sánh cặp cho implicit feedback. <i>Hạn chế:</i> mô hình tuyến tính.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
He et al. (2017) [2]	NCF / NeuMF	MovieLens, Pinterest	Đề xuất khung NCF kết hợp GMF và MLP; báo cáo NeuMF tốt hơn các baseline trên hai bộ dữ liệu của bài. <i>Hạn chế:</i> chưa tích hợp đặc trưng nội dung.
Cheng et al. (2016) [9]	Wide & Deep Learning	Google Play Store	Kết hợp ghi nhớ (Wide) và khái quát hóa (Deep). <i>Hạn chế:</i> cần kỹ nghệ đặc trưng thủ công.
Guo et al. (2017) [10]	DeepFM	Criteo, Dữ liệu doanh nghiệp	Thay Wide bằng Factorization Machine. <i>Hạn chế:</i> chi phí tính toán tăng khi số đặc trưng lớn.
Volkovs et al. (2017) [32]	DropoutNet	CiteULike, RecSys Challenge 2017	Huấn luyện mô hình nhận cả biểu diễn sở thích và nội dung, bỏ ngẫu nhiên phần sở thích để mô hình chấm được đối tượng khởi đầu lạnh. <i>Hạn chế:</i> cần đặc trưng nội dung đủ giàu thông tin.
Kang & McAuley (2018) [36]	SASRec (Self-Attention tuần tự)	Amazon, Steam, MovieLens	Mô hình hóa chuỗi hành vi bằng Self-Attention. <i>Hạn chế:</i> cần mốc thời gian/phiên rõ ràng, chưa khai thác được với dữ liệu chỉ ghi ngày mua như H&M.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Wang et al. (2019); He et al. (2020) [38], [39]	NGCF / LightGCN (Graph-based CF)	Gowalla, Amazon-Book, Yelp2018	Lan truyền tín hiệu tương tác bậc cao qua đồ thị hai phía. <i>Hạn chế</i> : chi phí tính toán lan truyền tăng theo số tầng, chi phí tăng nhanh theo quy mô đồ thị khi catalog lớn.
Li et al. (2024) [30]	Khảo sát DNN cho Collaborative Filtering	Tổng hợp đa miền (2020–2024)	Hệ thống hóa các kiến trúc MLP, CNN, RNN, GNN, Autoencoder, GAN đã tích hợp vào CF, xác nhận GMF/MLP vẫn là thành phần nền tảng phổ biến. <i>Hạn chế</i> : khảo sát tổng hợp, không đề xuất mô hình mới hay thực nghiệm riêng.
Liang et al. (2018) [40]	Mult-VAE (tự mã hóa biến phân)	MovieLens-20M, Netflix, Million Song	Mô hình hóa cả vector mua của User bằng phân phối đa thức, chấm toàn bộ catalog trong một lượt. <i>Hạn chế</i> : không dùng thứ tự thời gian; cần đủ lịch sử cho mỗi User.
Hồ Thị Linh (2023) [11]	Tích hợp đa nguồn: Late Fusion (bổ phiếu, MLP) và Early Fusion Utility Matrix + văn bản (TF-IDF, BERT), Transformer	MovieLens, Amazon	Hệ thống hóa Early/Late Fusion cho hệ gợi ý đa nguồn; Transformer hợp nhất nhiều view cải thiện độ chính xác dự đoán rating. <i>Khác với đề tài</i> : bài toán dự đoán rating (MAE/RMSE) có nguồn văn bản; đề tài áp dụng phân loại Early/Late Fusion cho xếp hạng Top-K trên phản hồi ẩn.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Ferrari Dacrema et al. (2019) [8]	Tái lập 18 mô hình gợi ý học sâu	MovieLens, Pinterest, Netflix, ...	Phần lớn mô hình học sâu được tái lập không vượt baseline đơn giản được tinh chỉnh tốt (ItemKNN, SLIM); chỉ ra mã nguồn NCF chọn số epoch trên tập kiểm thử. <i>Hạn chế</i> : chủ yếu dùng giao thức lấy mẫu của các bài gốc.
Rendle et al. (2020) [7]	MF tích vô hướng so với NeuMF	MovieLens 1M, Pinterest	MF được tinh chỉnh kỹ vượt NeuMF trên chính dữ liệu và giao thức của bài NCF; MLP khó học được tích vô hướng và không phù hợp truy hồi nhanh. <i>Hạn chế</i> : vẫn dùng giao thức Leave-One-Out lấy mẫu của bài gốc.
Dự án đề xuất (2026)	NeuMF-F: hai nhánh GMF-F, MLP-F (Embedding ID + đặc trưng sản phẩm, khách hàng, thời gian), hợp nhất sớm	H&M Personalized Fashion Recommendations (hai mẫu khách hàng độc lập)	Tập ứng viên gồm cả sản phẩm mới, đặc trưng theo thời điểm; tinh chỉnh trên mẫu phát triển, đánh giá một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước, 5 seed, kiểm định cặp có hiệu chỉnh Holm; so với NeuMF chỉ dùng ID, từng nhánh, Late Fusion của cùng hai nhánh và sáu baseline được tinh chỉnh cùng ngân sách; ablation từng nhóm đặc trưng.

Các công trình trong Bảng 2.1 dùng dữ liệu, cách chia dữ liệu và giao thức đánh

giá khác nhau; bảng chỉ tổng hợp phương pháp và đóng góp để làm cơ sở lựa chọn cách làm cho đề tài, không dùng số liệu của các công trình này làm chuẩn so sánh với kết quả của đề tài.

2.7 Khoảng trống nghiên cứu

Các nghiên cứu nền tảng về NCF/NeuMF [2] chủ yếu được đánh giá trên dữ liệu điện ảnh (MovieLens) hoặc mạng xã hội hình ảnh (Pinterest), với tín hiệu tương tác nhị phân và giao thức Leave-One-Out; tập sản phẩm của những bộ dữ liệu này gần như cố định, nên giới hạn khởi đầu lạnh của sản phẩm ít được đo. Các tái đánh giá về sau [7], [8] cho thấy NeuMF chỉ dùng ID khó vượt các baseline đơn giản được tinh chỉnh kỹ. Các mô hình dùng đặc trưng (mục 2.4.1) giải quyết được khởi đầu lạnh, nhưng thường được đánh giá cho bài toán dự đoán nhấp chuột chứ không phải xếp hạng Top-K trên toàn bộ danh mục. Còn các hướng mới hơn như Graph-based CF [38], [39], Sequential Recommendation [36], [37] hay LLM-based Recommendation [42], [43] đòi hỏi cấu trúc dữ liệu đặc thù hoặc tài nguyên tính toán vượt phạm vi của đề tài.

Khoảng trống mà đề tài tập trung giải quyết vì vậy là: xây dựng một mô hình lai giữ cấu trúc MF + DNN của NeuMF nhưng khai thác được đặc trưng sản phẩm, khách hàng và thời gian (NeuMF-F), rồi đánh giá nó trên dữ liệu giao dịch thời trang thực tế (H&M) theo một giao thức gần với tình huống triển khai – sản phẩm mới nằm trong tập ứng viên, đặc trưng không dùng thông tin tương lai, kết luận lấy trên một mẫu khách hàng chưa từng được dùng để ra quyết định – và tránh các lỗi phương pháp mà Ferrari Dacrema và cộng sự [8] và Rendle và cộng sự [7] đã chỉ ra (chọn mô hình trên tập kiểm thử, baseline tinh chỉnh sơ sài, chỉ số trên tập ứng viên lấy mẫu). Thiết kế đối chứng cho phép tách riêng ba câu hỏi: đặc trưng có giúp mô hình lai không (NeuMF-F so với NeuMF), hợp nhất có giúp so với từng nhánh không (NeuMF-F so với GMF-F, MLP-F), và hợp nhất sớm hay hợp nhất muộn phù hợp hơn (NeuMF-F so với LateFusion-F, theo phân loại của Hồ Thị Linh [11]).

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F

Chương này trình bày phương pháp của **giao thức v2** – giao thức cho kết quả chính của báo cáo: dữ liệu và cách chia giai đoạn (mục 3.2), mô hình lai NeuMF-F kết hợp nhân tử hóa ma trận với mạng nơ-ron sâu và đặc trưng của sản phẩm, khách hàng, thời gian (mục 3.3), cách huấn luyện (mục 3.4, 3.5) và quy trình đánh giá không thiên lệch trên một mẫu khách hàng độc lập (mục 3.6). Giao thức dùng trong giai đoạn phát triển (gọi là v1: chỉ dùng mã khách hàng và mã sản phẩm, đánh giá trên chính mẫu phát triển) được tóm tắt như lịch sử phát triển ở mục 4.5; những gì rút ra từ v1 là lý do trực tiếp của các lựa chọn trong chương này.

3.1 Kiến trúc tổng thể của hệ thống nghiên cứu


Hệ thống thực nghiệm được tổ chức thành sáu tầng xử lý tuần tự (Hình 3.1), cùng một nhánh mô hình đối chứng (baseline) vận hành song song. Hai điểm khác biệt chính so với một quy trình thông thường nằm ở tầng 1 và tầng 6: dữ liệu được chia thành hai mẫu khách hàng không giao nhau – mẫu A chỉ dùng để phát triển và tinh chỉnh, mẫu B chỉ dùng một lần cho đánh giá cuối.

Ba đặc điểm thiết kế xuyên suốt: (i) mọi mô hình – NeuMF-F lẫn baseline – dùng đúng một bộ dữ liệu, một tập ứng viên và một quy tắc loại sản phẩm đã mua, nên so sánh là công bằng; (ii) mọi lựa chọn mô hình và siêu tham số chỉ dựa trên tập xác thực của mẫu A, còn kết luận chỉ dựa trên tập kiểm thử của mẫu B – những khách hàng chưa từng được dùng cho bất kỳ quyết định nào (mục 3.6); (iii) các baseline được tinh chỉnh với cùng ngân sách như mô hình đề tài, theo khuyến nghị về phương pháp đánh giá trong [7], [8]: so sánh chỉ công bằng khi baseline được tinh chỉnh đầy đủ như mô hình được đề xuất.

3.2 Dữ liệu và tiền xử lý

3.2.1 Đặc tả bộ dữ liệu H&M

Bộ dữ liệu H&M Personalized Fashion Recommendations [3] phản ánh hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn, gồm ba tập được đề tài sử dụng:



Hình 3.1: Kiến trúc tổng thể của hệ thống nghiên cứu theo giao thức v2, từ dữ liệu thô H&M đến đánh giá cuối trên mẫu kiểm định

- **transactions_train.csv** (3,49 GB): 31.788.324 dòng giao dịch từ 20/09/2018 đến 22/09/2020, của 1.362.281 khách hàng trên 104.547 sản phẩm. Ba trường được dùng: `customer_id` (mã khách, chuỗi băm 64 ký tự), `article_id` (mã sản phẩm, 10 chữ số) và `t_dat` (ngày mua, không có giờ). Giá và kênh bán không được dùng.
- **articles.csv**: 105.542 sản phẩm của danh mục, mỗi sản phẩm có các thuộc tính dạng mã (loại sản phẩm, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc) và mô tả văn bản (tên, mô tả chi tiết).
- **customers.csv**: 1.371.980 khách hàng với tuổi, trạng thái hội viên, tần suất nhận tin thời trang và hai cờ FN, Active. Mã bưu chính không được dùng. Tập này có nhiều dòng hơn giới hạn của bảng tính Excel (1.048.576 dòng), nên phải được đọc trực tiếp bằng chương trình; hệ thống kiểm tra số dòng trước khi dùng.

Ảnh sản phẩm có trong bộ dữ liệu nhưng không được dùng làm đầu vào của mô hình; ảnh chỉ được hiển thị trong hệ thống demo (mục 3.7).

Đánh giá Full Ranking (mục 2.5) phải chấm điểm *mọi* sản phẩm ứng viên cho mỗi người dùng được đánh giá, nên chi phí tỉ lệ với tích số người dùng và số sản phẩm. Bảng 3.1 cho thấy ở quy mô đầy đủ, ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm – tức hàng chục tỷ cặp cần tính điểm cho mỗi mô hình, vượt xa khả năng của phần cứng sẵn có (máy tính cá nhân, RAM 16 GB). Vì vậy đề tài thực nghiệm trên các mẫu theo khách hàng (mục 3.2.2).

Bảng 3.1: Độ nhảy k -core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ)

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển A và mẫu kiểm định B

Đề tài lấy mẫu *theo khách hàng* thay vì theo dòng: lấy mẫu theo dòng (hoặc cắt n dòng đầu) sẽ cắt vụn lịch sử của từng khách và – vì tệp gốc sắp theo ngày – chỉ phủ vài ngày giao dịch, làm hỏng cả bước lọc k -core lẫn việc chia dữ liệu theo thời gian. Quy trình gồm hai lượt đọc tệp theo lô (bộ nhớ đỉnh khoảng 0,5 GB):

1. **Lượt 1 – chọn khách:** bấm `customer_id` bằng một khoá cố định vào 100.000 nhóm (hàm bấm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua) và đếm số giao dịch của từng nhóm.
2. **Lượt 2 – ghi mẫu:** giữ *toàn bộ* giao dịch của các khách được chọn, trải đủ 20/09/2018 – 22/09/2020.

Hai mẫu được lấy từ hai đoạn nhóm bấm liền nhau và không chồng lên nhau:

- **Mẫu phát triển A** – các nhóm $[0, 1597)$, tức các nhóm đầu tiên đủ khoảng 500.000 giao dịch: 500.269 giao dịch của 21.599 khách hàng. Mẫu này được dùng trong toàn bộ giai đoạn phát triển (giao thức v1) và, trong giao thức v2, chỉ dùng để tinh chỉnh trên tập xác thực.
- **Mẫu kiểm định B** – các nhóm kế tiếp $[1597, 3160)$, cùng cỡ: 500.125 giao dịch của 21.030 khách hàng. Vì hai đoạn nhóm không chồng nhau, **không có khách hàng nào thuộc cả hai mẫu** (đã kiểm tra trực tiếp). Mẫu B được tạo sau giai đoạn phát triển và chỉ dùng cho đánh giá cuối.

Vì dựa trên hàm bấm với khoá cố định, chạy lại luôn cho đúng cùng hai tệp (mã băm MD5 của hai tệp được ghi trong kế hoạch đăng ký trước, mục 3.6). Lý do cần mẫu B: tập kiểm thử của mẫu A đã được xem nhiều lần trong giai đoạn phát triển (mục 4.5), nên không còn là dữ liệu “chưa từng thấy”. Mẫu B gồm những khách hàng khác hẳn, nên kết quả trên B ước lượng hiệu năng của mô hình khi gặp khách hàng mới của cùng cửa hàng, trong cùng giai đoạn thời gian.

3.2.3 Ma trận tương tác và lọc k -core trước mốc kiểm thử

Một khách có thể mua cùng một sản phẩm nhiều lần; bước đầu tiên là gộp các giao dịch lặp thành một cặp (khách, sản phẩm) duy nhất, giữ lại *ngày mua đầu tiên* t_{ui} , trước khi lọc k -core. Nếu lọc trực tiếp trên dòng giao dịch thô, bậc của một khách/sản phẩm bị thổi phồng bởi các lượt mua lặp. Trên mẫu A, 500.269 giao dịch gộp lại còn 429.964 cặp duy nhất.

Lọc k -core được áp dụng lặp đến khi hội tụ (loại một sản phẩm có thể khiến một khách rơi xuống dưới ngưỡng và ngược lại), để mỗi khách và mỗi sản phẩm còn lại có ít nhất k đối tác riêng biệt. Điểm khác với giao thức v1 là phép lọc **chỉ dùng các cặp có ngày mua đầu trước mốc kiểm thử** (29/07/2020): việc chọn khách và sản phẩm nào được giữ lại không dùng bất kỳ thông tin nào của giai đoạn kiểm thử. Sau khi lọc, mã khách và mã sản phẩm được đánh lại chỉ số liên tục, và phản hồi ẩn nhị phân $y_{ui} = 1$ khi khách u đã mua sản phẩm i (Công thức (2.4)).

Ngưỡng k được chọn từ khảo sát ở giai đoạn phát triển (Bảng 3.2, tính trên mọi cặp của mẫu A). Ngưỡng thường gặp trong tài liệu là $k = 5$, nhưng khi đó danh mục còn 23.067 sản phẩm và đánh giá Full Ranking ước tính cần khoảng 10,7 GB RAM – vượt giới hạn của máy thực nghiệm (16 GB, đã tính hệ điều hành và dữ liệu huấn luyện). Đề tài vì vậy chọn $k = 10$. Cái giá của lựa chọn này là dữ liệu thiên về khách mua nhiều – được ghi nhận là một hạn chế (mục 5.2).

Bảng 3.2: Độ nhảy của mẫu A theo ngưỡng lọc k -core (khảo sát ở giai đoạn phát triển, 429.964 cặp trước khi lọc)

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	7.519	10.345	220.292	0,283
15	3.017	3.186	83.088	0,864

3.2.4 Giai đoạn đánh giá, sản phẩm mới và tập ứng viên

Dữ liệu được chia theo thời gian bằng hai mốc cố định chung cho mọi khách hàng: mốc xác thực $\tau_{val} = 01/07/2020$ (cửa sổ xác thực 01/07 – 28/07/2020, 4 tuần) và mốc kiểm thử $\tau_{test} = 29/07/2020$ (cửa sổ kiểm thử 29/07 – 22/09/2020, 8 tuần). Với mỗi mốc τ (gọi là một *giai đoạn*), các tập sau được định nghĩa:

$$\mathcal{D}_\tau = \{(u, i) \text{ đã lọc } k\text{-core} : t_{ui} < \tau\} \quad (\text{dữ liệu huấn luyện}) \quad (3.1)$$

$$\mathcal{I}_\tau^{cu} = \{i : \exists u, (u, i) \in \mathcal{D}_\tau\} \quad (\text{sản phẩm cũ}) \quad (3.2)$$

$$\mathcal{I}_\tau^{moi} = \{i \in \text{danh mục} : d_i^0 \geq \tau\} \quad (\text{sản phẩm mới}) \quad (3.3)$$

$$\mathcal{C}_u(\tau) = (\mathcal{I}_\tau^{cu} \cup \mathcal{I}_\tau^{moi}) \setminus \mathcal{I}_u(\tau) \quad (\text{tập ứng viên của khách } u) \quad (3.4)$$

$$\mathcal{T}_u(\tau) = \{i \in \mathcal{C}_u(\tau) : \tau \leq t_{ui} < \tau_{end}\} \quad (\text{sản phẩm đúng của } u) \quad (3.5)$$

trong đó d_i^0 là ngày bán đầu tiên của sản phẩm i trên *toàn bộ* giao dịch H&M, $\mathcal{I}_u(\tau)$ là các sản phẩm u đã mua trước τ , và τ_{end} là cuối cửa sổ của giai đoạn. Chỉ những khách có dữ liệu huấn luyện trong $\mathcal{D}_\tau$ và có ít nhất một sản phẩm đúng mới được đánh giá. Ba điểm cần giải thích:

- **Sản phẩm mới nằm trong tập ứng viên.** Thời trang thay đổi theo mùa: trong mẫu A, 27% cặp (khách, sản phẩm) mua lần đầu trong cửa sổ kiểm thử là sản phẩm chưa từng bán trước 29/07/2020. Giao thức v1 bỏ những sản phẩm này khỏi cả tập ứng viên lẫn tập sản phẩm đúng, nên đã đánh giá một bài toán dễ hơn thực tế. Giao thức v2 giữ chúng, với **giả định**: doanh

nghiệp biết trước danh mục sắp bán (có thuộc tính và mô tả của sản phẩm) nhưng không biết sản phẩm nào sẽ bán được – giả định hợp lý với một nhà bán lẻ tự lên kế hoạch hàng hóa.

- **Mô hình chỉ dùng ID không chấm được sản phẩm mới.** Sản phẩm không có dữ liệu huấn luyện thì không có vector Embedding ID; với các mô hình chỉ dùng ID (Most Popular, ItemKNN, UserKNN, BPR-MF, GMF, MLP, NeuMF), những sản phẩm này nhận điểm $-\infty$, tức bị xếp cuối danh sách. Đây chính là giới hạn của lọc cộng tác thuần mà giao thức đo được; mô hình có đặc trưng (mục 3.3) và gợi ý theo nội dung chấm được sản phẩm mới.
- **Huấn luyện lại trên dữ liệu mới nhất.** Ở giai đoạn kiểm thử, $\mathcal{D}_{\text{test}}$ gồm cả cửa sổ xác thực, tức “tập huấn luyện $\cup$ xác thực”. Tập xác thực chỉ dùng để chọn cấu hình và số epoch; trước khi đánh giá trên tập kiểm thử, mô hình được huấn luyện lại từ đầu trên $\mathcal{D}_{\text{test}}$ (mục 3.6), nên khi dự đoán, mô hình đã thấy toàn bộ quá khứ như lúc triển khai thật.

Vì sao không chia theo Leave-One-Out. Cách chia của He và cộng sự [2] lấy sản phẩm mua cuối cùng của từng người dùng làm tập kiểm thử, phần còn lại làm tập huấn luyện. Cách này để lọt thông tin tương lai: tập huấn luyện chứa tương tác của những người dùng khác xảy ra *sau* thời điểm cần dự đoán [48]. Đo trên mẫu A ở giai đoạn phát triển, tính trung bình theo người dùng, 11,2% tương tác trong tập huấn luyện xảy ra sau ngày mua sản phẩm kiểm thử của người dùng đó; ngoài ra 60,9% người dùng có sản phẩm xác thực và sản phẩm kiểm thử mua cùng một ngày. Vì vậy đề tài chia theo mốc thời gian chung cho mọi người dùng.

Theo định nghĩa, mỗi cặp (khách, sản phẩm) chỉ có một ngày mua đầu, nên một cặp không thể vừa là dữ liệu huấn luyện vừa là sản phẩm đúng của cùng giai đoạn, và sản phẩm khách đã mua trước mốc không bao giờ là sản phẩm đúng – mô hình dự đoán những món *mới đối với khách*. Các điều kiện này, cùng việc lọc k -core chỉ dùng dữ liệu trước mốc kiểm thử, được kiểm chứng bằng bộ kiểm thử tự động. bảng kết quả (chưa có số liệu) tổng hợp quy mô dữ liệu của hai mẫu.

Chưa có số liệu: chạy `scripts/22_tune_v2.py` (mẫu A) và `scripts/23_final_v2.py` (mẫu B) rồi `scripts/24_report_v2.py`.

3.2.5 Xây dựng đặc trưng theo thời điểm

Bảng 3.3 liệt kê các đặc trưng mà mô hình có đặc trưng sử dụng. Nguyên tắc bắt buộc là **không dùng thông tin tương lai**: đặc trưng của một cặp (khách u , sản phẩm i) tại ngày t chỉ được tính từ dữ liệu trước ngày t . Khi huấn luyện, mỗi cặp dương mang chính ngày mua đầu t_{ui} của nó; khi đánh giá, t là mốc τ của giai đoạn.

Bảng 3.3: Đặc trưng của mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F)

Nhóm	Đặc trưng	Mã hóa	Nguồn
Sản phẩm – thuộc tính	11 thuộc tính danh mục (loại, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc)	Embedding 8 chiều mỗi thuộc tính (88 chiều), học cùng mô hình	articles.csv
Sản phẩm – văn bản	Tên và mô tả chi tiết	TF-IDF (từ đơn và cặp từ) $\rightarrow$ SVD 64 chiều $\rightarrow$ chuẩn hóa L2	articles.csv
Sản phẩm – thời gian tại t	Doanh số trong 7, 28, 91 ngày trước t ; tuổi sản phẩm; cờ “chưa từng bán trước t ”	$\log(1+x)/10$; cờ 0/1 (5 chiều)	Giao dịch toàn H&M
Khách hàng – tính	Nhóm tuổi (9 mức, gồm “không rõ”), trạng thái hội viên, tần suất nhận tin, FN, Active	Embedding 8 chiều mỗi thuộc tính (40 chiều)	customers.csv
Khách hàng – thời gian tại t	Số ngày từ lần mua gần nhất (tối đa 730); số cặp đã mua	$\log(1+x)/10$ (2 chiều)	Dữ liệu huấn luyện

Đặc trưng thời gian của sản phẩm. Gọi $n_{i,d}$ là số giao dịch của sản phẩm i trong ngày d trên toàn bộ H&M và d_i^0 là ngày bán đầu tiên. Tại ngày t :

$$s_i^{(w)}(t) = \sum_{d=t-w}^{t-1} n_{i,d}, \quad (3.6)$$

$$x_i^{tg}(t) = \left[\frac{\log(1+s_i^{(7)})}{10}, \frac{\log(1+s_i^{(28)})}{10}, \frac{\log(1+s_i^{(91)})}{10}, \frac{\log(1+\max(0, t-d_i^0))}{10}, \mathbb{I}(d_i^0 \geq t) \right]$$

Tổng chỉ chạy tới ngày $t-1$, nên doanh số của chính ngày t không được dùng. Phép $\log(1+x)$ nén các sản phẩm bán rất chạy, hệ số $1/10$ đưa đặc trưng về cỡ $[0, 1]$. Doanh

số lấy trên toàn bộ giao dịch H&M chứ không chỉ trong mẫu – đây là dữ liệu mà doanh nghiệp có tại thời điểm dự đoán, và là tín hiệu duy nhất về xu hướng của một sản phẩm vừa ra mắt.

Đặc trưng văn bản. Tên và mô tả của mỗi sản phẩm được biểu diễn bằng TF-IDF [33] trên từ đơn và cặp từ (bỏ từ dừng tiếng Anh, giữ tối đa 30.000 mục từ xuất hiện ở ít nhất 3 sản phẩm, tần suất từ theo thang logarit), rồi giảm còn 64 chiều bằng phân rã SVD rút gọn – tức phân tích ngữ nghĩa tiềm ẩn [34] – và chuẩn hóa về độ dài 1. Phép biến đổi này được khớp trên toàn bộ danh mục (kể cả sản phẩm ra mắt sau), phù hợp với giả định “biết trước danh mục”; nó không dùng dữ liệu mua hàng.

Đặc trưng của khách hàng. Thuộc tính tĩnh lấy từ `customers.csv`; tệp này không có mốc thời gian nên thuộc tính được coi là ít thay đổi (một hạn chế được ghi nhận, mục 5.2). Đặc trưng thời gian của khách tại ngày t chỉ dùng các cặp có ngày mua đầu *trước* t : khoảng cách tới lần mua gần nhất và số cặp đã mua.

Bộ kiểm thử tự động xác nhận rằng đặc trưng thời gian của sản phẩm tại ngày t không thay đổi khi thêm giao dịch của ngày t trở về sau, và đặc trưng của khách tại ngày t chỉ đếm các cặp trước t .


3.3 Thiết kế mô hình lai NeuMF-F

NeuMF-F giữ nguyên cấu trúc hai nhánh của NeuMF [2] – nhánh GMF mô hình hóa tương tác tuyến tính, nhánh MLP mô hình hóa tương tác phi tuyến, hợp nhất ở lớp dự đoán chung – và thay đổi một điểm: vector của khách hàng và sản phẩm trong mỗi nhánh không còn chỉ là Embedding của mã ID mà là *tổng của Embedding ID và một phép chiếu tuyến tính của đặc trưng*. Chữ “F” (features) chỉ phần đặc trưng này. Hình 3.2 trình bày kiến trúc tổng thể.

3.3.1 Biểu diễn lại: *Embedding ID kết hợp đặc trưng*

Với mỗi nhánh $b \in \{G, M\}$ (GMF và MLP), mô hình có bảng Embedding ID của khách hàng $P^b \in \mathbb{R}^{|\mathcal{U}| \times d}$, của sản phẩm $Q^b \in \mathbb{R}^{|\mathcal{I}^{ID}| \times d}$ và hai ma trận chiếu đặc trưng $W_U^b \in \mathbb{R}^{d \times d_U}$, $W_I^b \in \mathbb{R}^{d \times d_I}$ (không có hệ số chệch). Vector của khách u và sản phẩm i tại ngày t trong nhánh b là:

$$p_u^b(t) = P_u^b + W_U^b x_u(t), \quad q_i^b(t) = m_i Q_i^b + W_I^b x_i(t) \quad (3.7)$$



Hình 3.2: Kiến trúc mô hình lai NeuMF-F: mỗi nhánh có bảng Embedding ID và phép chiếu đặc trưng riêng; $m_i = 0$ với sản phẩm chưa có dữ liệu huấn luyện

trong đó vector đặc trưng của sản phẩm $x_i(t) = [e(a_{i,1}); \dots; e(a_{i,11}); v_i; x_i^{tg}(t)] \in \mathbb{R}^{d_I}$ gồm Embedding 8 chiều của 11 thuộc tính danh mục, vector văn bản v_i (64 chiều) và 5 đặc trưng thời gian (Công thức (3.6)), tức $d_I = 88 + 64 + 5 = 157$; tương tự $x_u(t) = [e(c_{u,1}); \dots; e(c_{u,5}); x_u^{tg}(t)] \in \mathbb{R}^{d_U}$ với $d_U = 40 + 2 = 42$. Embedding của các thuộc tính $e(\cdot)$ được học cùng mô hình và dùng chung cho hai nhánh; ma trận chiều W^b riêng cho từng nhánh.

Hệ số m_i quyết định sản phẩm có dùng Embedding ID hay không: $m_i = 1$ nếu sản phẩm i có dữ liệu huấn luyện ở giai đoạn đang xét (sản phẩm cũ), $m_i = 0$ với sản phẩm mới. Khi $m_i = 0$, vector của sản phẩm chỉ còn phần đặc trưng – nhờ vậy NeuMF-F chấm được điểm cho sản phẩm chưa từng bán, điều mà NeuMF chỉ dùng ID không làm được. Khi huấn luyện, m_i của từng mẫu được đặt về 0 ngẫu nhiên với xác suất ρ (“bỏ ID ngẫu nhiên”, $\rho \in \{0; 0,25; 0,5\}$ được tinh chỉnh): nếu không có cơ chế này, mọi sản phẩm lúc huấn luyện đều có ID, mô hình có thể dựa hoàn toàn vào Embedding ID và không học cách chấm điểm chỉ từ đặc trưng – đúng tình huống của sản phẩm mới lúc đánh giá. Ý tưởng bỏ ngẫu nhiên đầu vào sở thích để mô hình học chấm điểm cho đối tượng khởi đầu lạnh tham khảo từ DropoutNet [32].

Như NeuMF, hai nhánh dùng hai không gian nhúng độc lập: nhánh GMF tối ưu vector cho phép nhân Hadamard (tuyến tính), nhánh MLP tối ưu vector làm đầu

vào của mạng phi tuyến sâu; ép hai mục tiêu khác bản chất này dùng chung tham số có thể khiến gradient của hai nhánh xung đột [2]. Hai nhánh dùng cùng số chiều $d \in \{32, 64\}$. Bảng Embedding và Embedding thuộc tính được khởi tạo theo phân phối chuẩn $\mathcal{N}(0; 0,01^2)$ như công trình gốc, hàng “không có ID” là vector 0 cố định; các tầng tuyến tính khởi tạo theo Xavier; lớp đầu ra h không có hệ số chệch.

3.3.2 Nhánh GMF-F

Nhánh GMF-F là dạng tổng quát hóa của nhân tử hóa ma trận (Công thức (2.5)) trên vector lai: thay vì cộng dồn ngay tích các chiều thành một số vô hướng, nhánh giữ kết quả nhân theo từng chiều qua phép nhân Hadamard:

$$\phi^G = p_u^G(t) \odot q_i^G(t) \quad (3.8)$$

Phép cộng dồn được chuyển sang lớp trọng số h ở tầng đầu ra (mục 3.3.4), cho phép mô hình học trọng số riêng cho từng chiều – phần “tổng quát hóa” trong tên gọi GMF; khi $h = 1$ và không có đặc trưng, GMF-F trở về MF. Vì p_u^G và q_i^G đều chứa phần chiếu của đặc trưng, tích $p_u^G \odot q_i^G$ còn mô hình hóa tương tác tuyến tính giữa thuộc tính của khách và thuộc tính của sản phẩm – tinh thần tương tự Factorization Machines [14], mô hình tổng quát hóa MF cho vector đặc trưng bất kỳ.

3.3.3 Nhánh MLP-F

Nhánh MLP-F nối hai vector lai thành đầu vào của một mạng nhiều tầng, không áp đặt trước cách hai vector tương tác:

$$z_1 = \begin{bmatrix} p_u^M(t) \\ q_i^M(t) \end{bmatrix} \in \mathbb{R}^{2d}, \quad \phi_L^M = a_L(W_L^T \cdots a_2(W_2^T z_1 + b_2) \cdots + b_L) \quad (3.9)$$

Tháp có kiến trúc giảm một nửa qua mỗi tầng ẩn theo thiết kế của He và cộng sự [2]: $[2d \rightarrow d \rightarrow d/2 \rightarrow d/4]$ (với $d = 32$: $[64 \rightarrow 32 \rightarrow 16 \rightarrow 8]$). Mỗi tầng ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và Dropout (tỉ lệ tinh chỉnh trong $\{0; 0,2\}$) để hạn chế quá khớp. Cùng với Dropout, mô hình được chống quá khớp bằng điều chuẩn L_2 (mục 3.4.2) và dừng sớm theo NDCG@10 trên tập xác thực (mục 3.5.1).

3.3.4 Tầng hợp nhất và lớp dự đoán đầu ra

Vector của nhánh GMF-F (tương tác tuyến tính) và của nhánh MLP-F (tương tác phi tuyến) được nối thành một vector hợp nhất rồi qua một tầng tuyến tính cuối và

hàm Sigmoid:

$$\hat{y}_{ui} = \sigma(h^T[\phi^G; \phi_L^M]) = \sigma(h_G^T(p_u^G \odot q_i^G) + h_M^T \phi_L^M) \quad (3.10)$$

Theo phân loại ở mục 2.3.4, đây là **hợp nhất sớm (Early Fusion)** ở mức biểu diễn của view tuyến tính (MF) và view phi tuyến (DNN): một lớp dự đoán chung học trọng số giữa hai view, và toàn bộ mạng được huấn luyện chung từ đầu đến cuối. Đồng thời, đặc trưng của sản phẩm và khách hàng được đưa vào ngay ở mức vector của cả hai nhánh, tức thông tin nội dung và ngữ cảnh cũng được hợp nhất sớm với thông tin cộng tác (Embedding ID). Khi xếp hạng, hệ thống dùng trực tiếp giá trị trước Sigmoid (logit): Sigmoid đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hòa về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả. Khi đánh giá ở một giai đoạn, vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần rồi dùng lại cho mọi cặp, nên chi phí chấm toàn bộ tập ứng viên gần với chi phí của NeuMF chỉ dùng ID.

3.3.5 Các mô hình đối chiếu xây dựng trên cùng khung

Để trả lời từng câu hỏi nghiên cứu bằng một phép so sánh trực tiếp, các mô hình sau được cài đặt trên cùng mã nguồn, cùng đặc trưng và cùng quy trình huấn luyện với NeuMF-F:

- **GMF-F** và **MLP-F**: NeuMF-F chỉ giữ một nhánh – đo đóng góp của từng nhánh và lợi ích của việc hợp nhất. MLP-F đứng riêng là một mô hình DNN thuần (chỉ có view phi tuyến), không phải mô hình hợp nhất MF với DNN.
- **LateFusion-F**: hợp nhất muộn (Late Fusion) của cùng hai thành phần – GMF-F và MLP-F được huấn luyện *riêng*, rồi trộn điểm đã chuẩn hóa min-max trên tập ứng viên của từng khách theo trọng số w chọn trên tập xác thực (Công thức (2.15)). So sánh NeuMF-F với LateFusion-F là so sánh hai cách hợp nhất trên cùng hai thành phần.
- **GMF, MLP, NeuMF chỉ dùng ID**: kiến trúc NCF gốc [2], không có đặc trưng (sản phẩm mới bị xếp cuối, mục 3.2.4) – đo lợi ích của đặc trưng.
- **Ablation của NeuMF-F**: cùng siêu tham số với NeuMF-F, tắt lần lượt một thành phần – vector văn bản, đặc trưng thời gian, thông tin khách hàng, thuộc tính sản phẩm, hoặc cơ chế bỏ ID ngẫu nhiên.

Các baseline không thuộc khung này (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN, BPR-MF) được mô tả ở mục 4.2.

3.4 Lấy mẫu âm theo thời điểm và hàm mục tiêu

3.4.1 Lấy mẫu âm động theo ngày ra mắt của sản phẩm

Dữ liệu phản hồi ẩn (mục 2.1.3) chỉ ghi nhận tương tác đã xảy ra, không có nhãn âm tường minh; Negative Sampling giả định các sản phẩm khách chưa mua nhiều khả năng là âm [2]. Với mô hình có đặc trưng, mỗi cặp dương (u, i) mang ngày mua đầu t_{ui} , nên việc chọn mẫu âm phải nhất quán về thời gian: với mỗi cặp dương, hệ thống lấy ngẫu nhiên N_{ratio} sản phẩm j trong các sản phẩm của tập huấn luyện **đã ra mắt trước hoặc trong ngày** t_{ui} ($d_j^0 \leq t_{ui}$), trừ những sản phẩm khách u đã mua, và gán nhãn $y_{uj} = 0$; mẫu âm được tính đặc trưng tại cùng ngày t_{ui} . Một sản phẩm chưa ra mắt ở ngày t_{ui} thì khách không thể mua, nên không phải mẫu âm có ý nghĩa; nếu vẫn lấy, mô hình sẽ học được quy luật sai “sản phẩm có cò chưa ra mắt là âm” – đúng thông tin mà nó cần để chấm sản phẩm mới. Với mô hình chỉ dùng ID, mẫu âm được lấy đều trong các sản phẩm có ID, trừ sản phẩm khách đã mua, như NCF gốc. N_{ratio} được tinh chỉnh trong $\{4, 8\}$ (tham khảo thiết lập 3–6 mẫu âm cho mỗi mẫu dương của He và cộng sự [2]); mẫu âm được lấy lại ở *mỗi* epoch, giúp mô hình thấy nhiều tổ hợp cặp âm khác nhau.

3.4.2 Hàm tổn thất Binary Cross-Entropy và điều chuẩn

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm Binary Cross-Entropy được tối thiểu hóa cùng số hạng điều chuẩn L_2 (weight decay của bộ tối ưu):

$$\mathcal{L} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_{\Theta} \|\Theta\|_2^2 \quad (3.11)$$

trong đó Θ là toàn bộ tham số có thể học (Embedding ID, Embedding thuộc tính, ma trận chiếu, tháp MLP, lớp đầu ra) và $\lambda_{\Theta} \in \{0; 10^{-6}\}$ được tinh chỉnh. BCE được tính trên logit (BCEWithLogitsLoss) để ổn định số học; bộ tối ưu là Adam [15], kích thước lô 512.

3.5 Quy trình huấn luyện và tinh chỉnh

3.5.1 Bảng thiết lập siêu tham số và kỹ thuật dừng sớm

Bảng 3.4 liệt kê không gian tinh chỉnh của mọi mô hình có siêu tham số. Mỗi mô hình có học được thử đúng **6 cấu hình**: cấu hình mặc định (in đậm) cộng 5 cấu hình rút ngẫu nhiên không lặp từ lưới của mô hình đó bằng một bộ sinh số ngẫu nhiên

cố định; mô hình chỉ có một tham số (MostPopular-Recent, Content, LateFusion-F) được thử đủ lưới. Mọi cấu hình được huấn luyện với seed 42 và chấm trên tập xác thực của mẫu A.

Bảng 3.4: Không gian tinh chỉnh (giá trị in đậm là cấu hình mặc định)

Mô hình / siêu tham số	Giá trị thử
GMF, MLP, NeuMF; GMF-F, MLP-F, NeuMF-F	tốc độ học $\{10^{-3}, 5 \cdot 10^{-4}\}$; số chiều d $\{32, 64\}$; số mẫu âm $\{4, 8\}$; weight decay $\{0, \mathbf{10^{-6}}\}$; Dropout của tháp MLP $\{0; \mathbf{0,2}\}$ (trừ GMF, GMF-F)
Thêm cho GMF-F, MLP-F, NeuMF-F	xác suất bỏ ID ρ $\{0; \mathbf{0,25}; 0,5\}$; Embedding thuộc tính 8 chiều và vector văn bản 64 chiều (cố định)
Cố định cho mọi mạng nơ-ron	Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm khi NDCG@10 trên tập xác thực không cải thiện sau 5 epoch
BPR-MF	d $\{32, 64, 128\}$; tốc độ học $\{0,01; \mathbf{0,03}; 0,05\}$; hệ số điều chuẩn $\{0,001; \mathbf{0,005}; 0,01\}$; số epoch $\{20, 40\}$
ItemKNN, UserKNN	số láng giềng k $\{20, 50, \mathbf{100}, 200, 500\}$; hệ số co $\{0, 10, 50\}$
MostPopular-Recent	cửa sổ W $\{7, 14, 28, 56, 91\}$ ngày (đủ lưới)
Content	chu kỳ bán rã của trọng số theo thời gian $\{\text{không trọng số}, 30, 90, 180, 365\}$ ngày (đủ lưới)
LateFusion-F	w $\{0; 0,1; \dots; 1\}$ (đủ lưới, trên GMF-F và MLP-F tốt nhất)

Dừng sớm (Early Stopping): sau mỗi epoch, mạng được chấm NDCG@10 theo Full Ranking trên tập xác thực; trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi chỉ số không cải thiện sau 5 epoch liên tiếp. Số epoch tốt nhất e^* được ghi lại để dừng khi huấn luyện lại (mục 3.6).

Nhật ký tinh chỉnh: mỗi cấu hình ghi một dòng gồm tham số, mã băm cấu hình, phiên bản mã nguồn (commit) và *mã băm nội dung mã nguồn* (gồm toàn bộ thư mục mã của mô hình, dữ liệu, đánh giá và tệp cấu hình), epoch tốt nhất, thời gian và chỉ số trên tập xác thực. Mã băm nội dung cho phép kiểm tra rằng mọi cấu hình được chạy với cùng một mã nguồn, kể cả khi chạy trước lúc lưu phiên bản, và rằng đánh giá cuối cùng đúng mã nguồn đã dùng khi tinh chỉnh.

3.6 Quy trình đánh giá không thiên lệch

Ferrari Dacrema và cộng sự [8] chỉ ra hai lỗi phương pháp thường gặp khi đánh giá mô hình gợi ý học sâu: chọn số epoch hay cấu hình dựa trên chính tập kiểm thử, và tinh chỉnh baseline sơ sài; Rendle và cộng sự [7] nhấn mạnh kết luận so sánh phụ thuộc mạnh vào việc baseline có được tinh chỉnh đầy đủ hay không. Giai đoạn phát triển của đề tài còn cho thấy một rủi ro thứ ba: khi tập kiểm thử đã được xem, mọi quyết định sau đó đều có thể bị ảnh hưởng bởi kết quả đã thấy (mục 4.5). Giao thức v2 xử lý cả ba rủi ro bằng sáu nguyên tắc:

1. **Tách mẫu phát triển và mẫu kiểm định.** Mọi lựa chọn mô hình, siêu tham số và số epoch dựa trên tập *xác thực*: tinh chỉnh trên mẫu A, chọn số epoch khi đánh giá cuối trên tập xác thực của mẫu B. Tập kiểm thử của mẫu B chỉ được mở **đúng một lần**, ở đánh giá cuối; tập kiểm thử của mẫu A không được dựng trong giao thức v2.
2. **Đăng ký trước (pre-registration).** Danh sách mô hình, lưới tinh chỉnh, số seed, độ đo chính, họ so sánh, tiêu chí kết luận và các hạn chế đã biết được ghi vào kế hoạch thực nghiệm v2 *trước* khi có kết quả tinh chỉnh của bất kỳ mô hình có đặc trưng nào và trước khi dữ liệu của mẫu B được xử lý, rồi được lưu vào hệ thống quản lý phiên bản trước khi mở tập kiểm thử của mẫu B. Mô hình đề tài (NeuMF-F) được cố định từ trước, không chọn lại theo kết quả. Mọi thay đổi sau đó được ghi vào mục “lịch kế hoạch” kèm thời điểm.
3. **Khoá tập kiểm thử.** Chương trình đánh giá cuối từ chối chạy nếu kế hoạch chưa được lưu phiên bản, thiếu lý do chạy, mã nguồn có thay đổi chưa lưu hoặc có tệp mã chưa được theo dõi, tinh chỉnh chưa đủ mô hình, mã băm nội dung mã nguồn khác lúc tinh chỉnh, hoặc seed đó đã từng mở tập kiểm thử. Mỗi seed ghi một dòng nhật ký truy cập (thời gian, phiên bản mã nguồn, mã băm cấu hình, danh sách mô hình, lý do) *trước* khi chấm.
4. **Cùng ngân sách tinh chỉnh** cho mọi mô hình có học (6 cấu hình, mục 3.5.1).
5. **Huấn luyện lại trước khi chấm.** Với mỗi seed trong 5 seed (42, 2024, 2025, 2026, 3407) và mỗi mạng nơ-ron: huấn luyện trên dữ liệu trước 01/07/2020 của mẫu B, dừng sớm theo NDCG@10 trên tập xác thực của B để chọn số epoch e^* ; huấn luyện lại từ đầu trên mọi cặp trước 29/07/2020

đúng e^* epoch (không còn tập xác thực để dừng, và tập kiểm thử không được dùng để dừng); rồi chấm tập kiểm thử. BPR-MF và các mô hình không phải mạng nơ-ron được khớp trên mọi cặp trước 29/07/2020; LateFusion-F trộn đúng GMF-F và MLP-F đã huấn luyện lại ở cùng seed, với w chọn trên mẫu A.

6. **Kiểm định thống kê và tiêu chí kết luận cố định.** Với mỗi khách được đánh giá, NDCG@10 được lấy trung bình qua 5 seed (mô hình tắt định cho cùng giá trị ở mọi seed), rồi so sánh từng cặp mô hình bằng kiểm định Wilcoxon signed-rank theo người dùng [16] và khoảng tin cậy 95% của hiệu trung bình bằng bootstrap ghép cặp (10.000 lần lấy mẫu lại) [17]; giá trị p được hiệu chỉnh Holm [18] trên một họ **10 so sánh** đăng ký trước: NeuMF-F so với NeuMF (đặc trưng có giúp mô hình lai không), với GMF-F và MLP-F (hợp nhất so với từng nhánh), với LateFusion-F (hợp nhất sớm so với muộn), với BPR-MF, ItemKNN, UserKNN, MostPopular-Recent, Content; và NeuMF so với BPR-MF (mô hình lai chỉ dùng ID so với MF). Chỉ viết “A tốt hơn B” khi đồng thời: $p_{Holm} < 0,05$, khoảng tin cậy không chứa 0, và chênh lệch tương đối NDCG@10 $\geq 5\%$; ngược lại kết luận “không khác biệt có ý nghĩa”.


Các phân tích theo nhóm sản phẩm cũ/mới, ablation (một seed) và phân tích độ nhạy “chỉ sản phẩm cũ” được báo cáo kèm khoảng tin cậy nhưng không kiểm định và không dùng để kết luận chính. Mọi lần chạy đánh giá cuối được ghi vào nhật ký truy cập tập kiểm thử; nếu phải chạy lại một seed (ví dụ do lỗi máy), lần chạy lại được đánh dấu riêng và ghi vào mục lịch kế hoạch.

3.7 Thiết kế hệ thống giao diện thực nghiệm (Demo)

Mục này trình bày hệ thống demo minh họa các mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt về kiến trúc với phần huấn luyện: chỉ nạp trọng số mô hình đã lưu và gọi lại đúng các hàm xử lý dữ liệu, xếp hạng của quy trình đánh giá, không huấn luyện lại.

3.7.1 Kiến trúc tổng thể: ba tầng tách biệt

Hai nguyên tắc thiết kế quan trọng nhất: (i) tách suy diễn khỏi huấn luyện, nên thời gian phản hồi không phụ thuộc chi phí huấn luyện và tầng 2+3 có thể đóng gói thành một container độc lập; (ii) demo *tự kiểm tra* rằng dữ liệu dựng lại khớp với lần



Hình 3.3: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo)

chạy đã huấn luyện – nếu lệch (ví dụ sai tệp dữ liệu hoặc sai ngưỡng k), máy chủ báo lỗi thay vì nạp trọng số với ánh xạ ID sai. Bộ kiểm thử tự động của demo xác nhận tập ứng viên trùng với tập ứng viên của đánh giá cuối, hạng của từng sản phẩm đích và các chỉ số theo người dùng mà demo tính lại khớp tệp kết quả theo người dùng của Chương 4, và mô hình chỉ dùng ID xếp mọi sản phẩm mới sau mọi sản phẩm cũ. Nếu đánh giá cuối được chạy trên GPU, logit tính lại trên CPU có thể làm vài cặp sản phẩm gần như hoà điểm đổi chỗ ở hạng rất sâu (trên 100), không ảnh hưởng chỉ số @K.

3.7.2 Thiết kế API suy diễn

Bảng 3.5: Các endpoint chính của API suy diễn

Endpoint	Chức năng
GET /api/context	Thông tin bộ dữ liệu, lần chạy đang dùng, số người dùng/sản phẩm, số sản phẩm mới, các K hợp lệ, mô hình khả dụng.
GET /api/users/search, /random	Tìm hoặc chọn ngẫu nhiên một khách hàng có sản phẩm đích, lọc theo nhóm ít/trung bình/nhiều giao dịch.
GET /api/users/{id}/history	Lịch sử mua mà mô hình đã học (mọi cặp trước mốc kiểm thử), sắp theo thời gian.
GET /api/users/{id}/recommend	Top- K của một mô hình (gắn nhãn sản phẩm mới), hạng của từng sản phẩm đích, số ứng viên, $HR@K$, $NDCG@K$, $Recall@K$ của khách đó.
GET /api/users/{id}/neighbors	Top- K khách tương đồng nhất theo UserKNN: độ tương đồng, số sản phẩm mua chung, láng giềng nào đã mua sản phẩm đích của khách.
POST /api/onboarding/recommend	Gợi ý cho khách hàng mới theo luật (lọc theo lựa chọn + độ phổ biến trong dữ liệu huấn luyện) – được gắn nhãn rõ <i>không phải mô hình học</i> .
GET /api/dashboard	Số liệu tổng hợp đọc từ tệp kết quả đã chạy, kèm tên tệp nguồn.
POST /api/reload	Xoá cache, nạp lần chạy mới nhất mà không cần khởi động lại.

Luồng xử lý của chức năng gợi ý Top- K gồm 5 bước, dùng lại đúng các hàm của quy trình đánh giá:

1. Tra định danh khách hàng để lấy mã nội bộ. Khách chưa có lịch sử mua là

tình huống khởi đầu lạnh của người dùng, nằm ngoài phạm vi của mô hình (mục 4.6); demo chuyển sang màn hình Khách hàng mới với gợi ý theo luật thay vì suy diễn một kết quả không đáng tin cậy.

2. Xác định tập ứng viên: sản phẩm cũ (có dữ liệu huấn luyện) và sản phẩm mới, trừ những sản phẩm khách đã mua – cùng quy tắc dựng tập ứng viên của đánh giá Full Ranking (mục 3.2.4).
3. Tính điểm cho toàn bộ tập ứng viên theo lô (vector hoá), dùng logit với mô hình nơ-ron; mô hình chỉ dùng ID cho sản phẩm mới điểm $-\infty$.
4. Sắp xếp giảm dần với cùng quy tắc phá hoà tất định như lúc đánh giá, lấy K phần tử đầu.
5. Ánh xạ ngược mã nội bộ về `article_id`, kèm tên, loại sản phẩm và nhãn sản phẩm mới, trả về Tầng 1.

3.7.3 *Lựa chọn mô hình triển khai và yêu cầu phi chức năng*

Demo cho phép chọn và so sánh song song hai mô hình bất kỳ trong số 13 mô hình của đánh giá cuối (mặc định NeuMF-F và NeuMF chỉ dùng ID), để người xem tự đối chiếu với kết luận của Chương 4 – ví dụ thấy trực tiếp mô hình chỉ dùng ID không bao giờ đưa sản phẩm mới vào danh sách gợi ý; demo không khẳng định mô hình nào “tốt nhất” ngoài những gì kiểm định thống kê cho phép. Demo nạp đúng các trọng số của đánh giá cuối (seed 42) trên mẫu kiểm định B: lịch sử hiển thị là đúng dữ liệu mô hình đã học, và sản phẩm đích là các món khách mua lần đầu trong giai đoạn kiểm thử – nên số liệu trên demo là hiển thị lại kết quả của Chương 4, không phải một lần đánh giá mới trên tập kiểm thử. Màn hình Admin còn hiện 10 khách tương đồng nhất theo UserKNN để minh họa cách lọc cộng tác dựa trên láng giềng chọn ra gợi ý (mục 2.1.2). Kết quả của giai đoạn phát triển (giao thức v1) và chế độ khám phá cũ vẫn xem được bằng cách chọn chế độ khi khởi động. Về yêu cầu phi chức năng, vector của mọi khách và sản phẩm tại mốc dự đoán được tính một lần khi nạp, nên mỗi yêu cầu gợi ý chỉ là một lượt suy diễn thuận trên khoảng 17–19 nghìn ứng viên – đủ nhanh để phục vụ trực tuyến trên CPU.

3.7.4 *Minh họa hệ thống demo đã cài đặt*

Hệ thống đã được cài đặt và có bộ kiểm thử tự động riêng (kiểm tra khớp số liệu với đánh giá cuối, đúng quy tắc tập ứng viên, đúng định dạng API). hình kết quả (chưa có số liệu) minh họa màn hình Admin kiểm thử mô hình và hình kết quả (chưa

có số liệu) là bảng khách tương đồng của cùng khách hàng.

Chưa có số liệu: hình “Giao diện demo – màn hình Admin kiểm thử mô hình với mô hình của đánh giá cuối: lịch sử mua, Top-10 của NeuMF-F và NeuMF, hạng của từng sản phẩm đích (gồm cả sản phẩm mới) trong tập kiểm thử” — chụp màn hình demo (`python run.py demo`) và lưu thành `media/figures/demo/demo_v2.png`.

Chưa có số liệu: hình “Giao diện demo – 10 khách hàng tương đồng nhất theo UserKNN: độ tương đồng cosine, số sản phẩm mua chung và láng giềng đã mua sản phẩm đích nào của khách” — chụp màn hình demo và lưu thành `media/figures/demo/demo_v2_neighbors.png`.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

Thực nghiệm theo giao thức v2 (Chương 3) gồm hai bước tách biệt: tinh chỉnh trên tập xác thực của mẫu phát triển A, và đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định B – những khách hàng không có trong mẫu A. Quy mô dữ liệu của hai mẫu ở bảng kết quả (chưa có số liệu) (mục 3.2.4). Mọi bảng số liệu, hình và con số kết quả trong chương này được sinh tự động từ tập kết quả của quy trình thực nghiệm, không nhập tay. Các tài liệu tham khảo được dùng làm cơ sở về phương pháp (định nghĩa mô hình, cách huấn luyện và cách đánh giá); vì đề tài dùng dữ liệu, cách chia dữ liệu và giao thức đánh giá riêng, số liệu trong chương này *không* được so sánh trực tiếp với số liệu công bố trong các tài liệu đó – mọi so sánh đều giữa các mô hình của đề tài, trên cùng dữ liệu và cùng giao thức.

- **Full Ranking:** với mỗi khách được đánh giá, xếp hạng toàn bộ tập ứng viên – sản phẩm cũ và sản phẩm mới, trừ những sản phẩm khách đã mua trước mốc (trung bình [chưa có] ứng viên mỗi khách ở tập kiểm thử của mẫu B). Khi nhiều sản phẩm có điểm bằng nhau, thứ tự giữa chúng được quyết định bằng một khoá giả ngẫu nhiên cố định (seed 2026), giống nhau cho mọi mô hình.
- **Độ đo chính:** NDCG@10 trung bình theo người dùng trên tập kiểm thử của mẫu B ([chưa có] người dùng, [chưa có] cặp đúng, trong đó [chưa có] cặp – [chưa có]% – là sản phẩm mới). Độ đo phụ: Recall@10, HR@10, Precision@10, NDCG@5, NDCG@20 (định nghĩa ở mục 2.5); NDCG@10 theo nhóm sản phẩm cũ/mới.
- **Số lần chạy:** mỗi mô hình được chạy với 5 seed ([chưa có]); với mỗi seed, số epoch được chọn trên tập xác thực của mẫu B, rồi mô hình được huấn luyện lại trên mọi cặp trước 29/07/2020 trước khi chấm tập kiểm thử (mục 3.6). Báo cáo trung bình $\pm$ độ lệch chuẩn qua seed; kiểm định theo mục 3.6.
- **Môi trường chạy:** tinh chỉnh chạy trên máy tính cá nhân không có GPU (CPU 4 nhân, RAM 16 GB), mát tổng cộng [chưa có] giờ cho [chưa có] cấu hình. Đánh giá cuối chạy trên [chưa có] (CPU [chưa có]; GPU: [chưa

có]), Python [chưa có], PyTorch [chưa có] [12], mất [chưa có] giờ cho 5 seed. Mọi dòng nhật ký tinh chỉnh và mọi lần đánh giá cuối có cùng một mã băm nội dung mã nguồn ([chưa có]); đánh giá cuối chạy trên phiên bản mã nguồn [chưa có] đã lưu, không có thay đổi chưa lưu.

4.2 Phương pháp đối chứng (Baselines)

Ngoài mô hình đề tài NeuMF-F và các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, GMF, MLP, NeuMF – mục 3.3.5), bảy baseline được đánh giá với cùng dữ liệu, tập ứng viên và quy tắc đánh giá:

1. **Random** – điểm ngẫu nhiên, cận dưới.
2. **Most Popular** – điểm của sản phẩm là số khách trong dữ liệu huấn luyện của mẫu đã mua sản phẩm đó; mọi khách nhận cùng một danh sách (trừ sản phẩm đã mua). Sản phẩm mới có điểm 0 và bị xếp cuối.
3. **MostPopular-Recent** – độ phổ biến gần đây trên toàn bộ H&M: điểm của sản phẩm i là số giao dịch của nó trong W ngày trước mốc dự đoán, $\sum_{d=\tau-W}^{\tau-1} n_{i,d}$, với W chọn trên tập xác thực. Đây là baseline mạnh với dữ liệu thời trang có xu hướng thay đổi nhanh; nó dùng cùng nguồn doanh số với đặc trưng thời gian của NeuMF-F (mục 3.2.5), nên so sánh với nó cho biết NeuMF-F có học được gì vượt trên xu hướng chung hay không. Sản phẩm mới chưa có doanh số nên vẫn xếp sau sản phẩm đang bán.
4. **Content** – gợi ý theo nội dung thuần [19]: mỗi sản phẩm được biểu diễn bằng vector văn bản (mục 3.2.5) nối với mã hóa one-hot của bốn thuộc tính (nhóm sản phẩm, nhóm màu, nhóm chỉ mục, nhóm may mặc), chuẩn hóa về độ dài 1; hồ sơ của khách là trung bình có trọng số các vector sản phẩm đã mua, trọng số giảm theo thời gian với chu kỳ bán rã h ngày ($\omega = 2^{-(\tau-t_{uj})/h}$, hoặc bằng 1 nếu không dùng trọng số); điểm là độ tương đồng cosine giữa hồ sơ và sản phẩm. Content không dùng ID nên chấm được sản phẩm mới, nhưng không học từ hành vi của những khách khác.
5. **ItemKNN** [20] và **UserKNN** – lọc cộng tác dựa trên láng giềng (mục 2.1.2), với số láng giềng k và hệ số co chọn trên tập xác thực.
6. **BPR-MF** [24] – nhân tử hóa ma trận tối ưu xếp hạng theo cặp, đại diện cho MF tuyến tính được tinh chỉnh cùng ngân sách.

Most Popular, ItemKNN, UserKNN và BPR-MF chỉ dùng ID nên xếp mọi sản phẩm

mới cuối danh sách, giống GMF, MLP và NeuMF (mục 3.2.4). Đặt mô hình học sâu cạnh các baseline đơn giản được tinh chỉnh đầy đủ là nguyên tắc đánh giá được khuyến nghị trong Ferrari Dacrema và cộng sự [8].

4.3 Kết quả tinh chỉnh trên tập xác thực của mẫu A

bảng kết quả (chưa có số liệu) liệt kê cấu hình tốt nhất của từng mô hình. Mọi con số trong bảng là trên tập *xác thực* của mẫu A; chúng lạc quan vì chính tập này được dùng để chọn cấu hình, nên chỉ dùng để chọn, không dùng để kết luận.

Chưa có số liệu: chạy `scripts/22_tune_v2.py` rồi `scripts/24_report_v2.py`.

Trên tập xác thực của mẫu A, NeuMF-F đạt $\text{NDCG}@10 = [\text{chưa có}]$ với cấu hình **[chưa có]**; NeuMF chỉ dùng ID đạt **[chưa có]**, GMF-F **[chưa có]**, MLP-F **[chưa có]** và LateFusion-F **[chưa có]** (**[chưa có]**). Trong các baseline, cao nhất là UserKNN (**[chưa có]**) và ItemKNN (**[chưa có]**); MostPopular-Recent đạt **[chưa có]** và BPR-MF **[chưa có]**. Các mạng nơ-ron đạt $\text{NDCG}@10$ tốt nhất trên tập xác thực ở epoch trung vị **[chưa có]** (muộn nhất epoch **[chưa có]**) trong **[chưa có]** cấu hình mạng nơ-ron đã thử.

4.4 Kết quả đánh giá cuối trên mẫu kiểm định B

4.4.1 So sánh các độ đo xếp hạng (Full Ranking)

bảng kết quả (chưa có số liệu) và hình kết quả (chưa có số liệu) trình bày kết quả trên tập kiểm thử của mẫu B, trung bình qua 5 seed.

Chưa có số liệu: chạy `scripts/23_final_v2.py` rồi `scripts/24_report_v2.py`.

Chưa có số liệu: hình “ $\text{NDCG}@10$, $\text{Recall}@10$ và $\text{HR}@10$ trên tập kiểm thử của mẫu B: trung bình $\pm$ độ lệch chuẩn qua 5 seed, chấm đen là từng seed” — chạy `scripts/23_final_v2.py` rồi `scripts/24_report_v2.py`.

NeuMF-F đạt $\text{NDCG}@10 = [\text{chưa có}] \pm [\text{chưa có}]$, xếp **[chưa có]** trong 14 mô hình; NeuMF chỉ dùng ID đạt **[chưa có]** $\pm$ **[chưa có]**, BPR-MF **[chưa có]** $\pm$ **[chưa có]**, UserKNN **[chưa có]**, ItemKNN **[chưa có]**, MostPopular-Recent **[chưa có]** và Content **[chưa có]**. Thang giá trị tuyệt đối thấp vì mỗi khách có vài sản phẩm đúng giữa khoảng **[chưa có]** ứng viên, và dự đoán những món *chưa từng mua* trong 8 tuần

tới là bài toán khó với dữ liệu thời trang; thông tin quan trọng là thứ hạng tương đối và chênh lệch có ý nghĩa thống kê hay không.

4.4.2 Kiểm định ý nghĩa thống kê

bảng kết quả (chưa có số liệu) và hình kết quả (chưa có số liệu) trình bày kiểm định họ **[chưa có]** so sánh đã đăng ký trước (mục 3.6). **[chưa có]**

Chưa có số liệu: chạy `scripts/23_final_v2.py` rồi
`scripts/24_report_v2.py`.

Chưa có số liệu: hình “Hiệu $NDCG@10 (A - B)$ của họ 10 so sánh đã đăng ký, với khoảng tin cậy 95% bootstrap theo người dùng và giá trị p đã hiệu chỉnh Holm” — chạy `scripts/24_report_v2.py`.

Theo từng câu hỏi nghiên cứu: (1) đặc trưng có cải thiện mô hình lai không – NeuMF-F so với NeuMF chênh **[chưa có]** (**[chưa có]**); (2) hợp nhất có giúp so với từng nhánh không – so với GMF-F chênh **[chưa có]** (**[chưa có]**), so với MLP-F chênh **[chưa có]** (**[chưa có]**); (3) hợp nhất sớm hay muộn – so với LateFusion-F chênh **[chưa có]** (**[chưa có]**); (4) so với các baseline – BPR-MF **[chưa có]** (**[chưa có]**), ItemKNN **[chưa có]** (**[chưa có]**), UserKNN **[chưa có]** (**[chưa có]**), MostPopular-Recent **[chưa có]** (**[chưa có]**), Content **[chưa có]** (**[chưa có]**); (5) mô hình lai chỉ dùng ID so với MF – NeuMF so với BPR-MF chênh **[chưa có]** (**[chưa có]**).

4.4.3 Sản phẩm cũ và sản phẩm mới

bảng kết quả (chưa có số liệu) và hình kết quả (chưa có số liệu) tách $NDCG@10$ theo nhóm sản phẩm đúng (mục 2.5), và thêm phân tích độ nhạy khi tập ứng viên chỉ gồm sản phẩm cũ – gần với giao thức v1. Đây là phân tích mô tả, không kiểm định.

Chưa có số liệu: chạy `scripts/23_final_v2.py` rồi
`scripts/24_report_v2.py`.

Chưa có số liệu: hình “ $NDCG@10$ theo nhóm sản phẩm đúng cũ/mới và khi tập ứng viên chỉ gồm sản phẩm cũ (trung bình qua 5 seed, thanh lỗi: khoảng tin cậy 95% bootstrap theo người dùng)” — chạy `scripts/24_report_v2.py`.

Trên nhóm sản phẩm đúng mới (**[chưa có]** người dùng có ít nhất một sản phẩm đúng mới), các mô hình chỉ dùng ID đạt $NDCG@10$ bằng 0 theo cấu tạo; NeuMF-F đạt **[chưa có]**, Content **[chưa có]**. Trên nhóm sản phẩm đúng cũ, NeuMF-F đạt

[chưa có], so với [chưa có] của NeuMF, [chưa có] của BPR-MF và [chưa có] của UserKNN. Khi chỉ xét sản phẩm cũ (cột cuối), hiệu NDCG@10 giữa NeuMF-F và NeuMF là [chưa có] (khoảng tin cậy 95%: [[chưa có]; [chưa có]]), giữa NeuMF-F và BPR-MF là [chưa có] ([chưa có]; [chưa có]).

4.4.4 Phân tích bóc tách thành phần (Ablation Study)

bảng kết quả (chưa có số liệu) và hình kết quả (chưa có số liệu) so sánh NeuMF-F đầy đủ với năm biến thể tắt một thành phần, cùng siêu tham số và cùng quy trình huấn luyện (seed 42, mục 3.3.5). Đây là phân tích mô tả với một seed, không dùng để chọn lại cấu hình.

Chưa có số liệu: chạy `scripts/23_final_v2.py` rồi
`scripts/24_report_v2.py`.

Chưa có số liệu: hình “Ablation của NeuMF-F trên tập kiểm thử của mẫu B (seed 42): NDCG@10 trên mọi sản phẩm đúng, sản phẩm cũ và sản phẩm mới” — chạy `scripts/24_report_v2.py`.

So với NeuMF-F đầy đủ (NDCG@10 = [chưa có] ở seed 42), bỏ đặc trưng thời gian làm NDCG@10 thay đổi [chưa có], bỏ vector văn bản [chưa có], bỏ thuộc tính sản phẩm [chưa có], bỏ thông tin khách hàng [chưa có], và không bỏ ID ngẫu nhiên khi huấn luyện [chưa có].

4.4.5 Độ phủ, sản phẩm mới trong gợi ý và chi phí huấn luyện

Chưa có số liệu: chạy `scripts/23_final_v2.py` rồi
`scripts/24_report_v2.py`.

bảng kết quả (chưa có số liệu) mô tả danh sách top-10 (mục 2.5.1) và chi phí huấn luyện. Most Popular là trường hợp giới hạn với độ phủ [chưa có]; NeuMF-F có độ phủ [chưa có] và tỉ lệ sản phẩm mới trong top-10 là [chưa có] (Content: [chưa có]). Thời gian huấn luyện trung bình mỗi seed của NeuMF-F là [chưa có] phút, so với [chưa có] phút của NeuMF chỉ dùng ID và [chưa có] phút của BPR-MF.

4.4.6 Hội tụ và độ ổn định giữa hai mẫu

Chưa có số liệu: hình “Đường hội tụ của các mạng nơ-ron khi chọn số epoch trên tập xác thực của mẫu B (seed 42): NDCG@10 trên tập xác thực và hàm mất mát BCE trên tập huấn luyện theo epoch; vòng tròn là epoch được chọn” — chạy `scripts/24_report_v2.py`.

Chưa có số liệu: hình “NDCG@10 trên tập xác thực của mẫu A (lúc tinh chỉnh) và trên tập kiểm thử của mẫu B (đánh giá cuối)” — chạy scripts/24_report_v2.py.

hình kết quả (chưa có số liệu) cho thấy diễn biến NDCG@10 trên tập xác thực theo epoch khi chọn số epoch cho đánh giá cuối; hình kết quả (chưa có số liệu) đặt NDCG@10 lúc tinh chỉnh (mẫu A, tập xác thực) cạnh NDCG@10 lúc đánh giá cuối (mẫu B, tập kiểm thử). Hai con số không cùng thang – tập kiểm thử dài gấp đôi tập xác thực và có tỉ lệ sản phẩm mới khác – nên điều cần xem là thứ hạng giữa các mô hình có được giữ khi chuyển sang khách hàng mới hay không.

4.5 Lịch sử phát triển: giao thức v1

Trước giao thức v2, đề tài đã thực nghiệm theo giao thức v1 trên mẫu A: chỉ dùng mã khách hàng và mã sản phẩm (lọc cộng tác thuận), lọc k -core trên toàn bộ mẫu, chỉ giữ người dùng và sản phẩm đã có trong dữ liệu huấn luyện, và đánh giá trên tập kiểm thử của chính mẫu A (2.996 người dùng, 10.216 sản phẩm ứng viên). Bảy mô hình được so sánh: Random, Most Popular, BPR-MF, GMF, MLP và hai biến thể NeuMF – NeuMF-Scratch (khởi tạo ngẫu nhiên) và NeuMF-Pretrained (khởi tạo từ GMF, MLP đã huấn luyện theo chiến lược tiền huấn luyện của He và cộng sự [2]). Kết quả (trung bình 3 seed):

- BPR-MF có NDCG@10 trung bình cao nhất (0,01007); NeuMF-Pretrained đạt 0,00957, NeuMF-Scratch 0,00910, Most Popular 0,00917, GMF 0,00907, MLP 0,00931. Không so sánh nào trong họ 8 so sánh đăng ký trước đạt tiêu chí “tốt hơn” (0/8): NeuMF chỉ dùng ID không vượt MF đã tinh chỉnh, không vượt Most Popular và không khác biệt có ý nghĩa với chính các nhánh GMF, MLP của nó. Tiền huấn luyện không mang lại lợi ích đo được.
- Gần như toàn bộ độ chính xác đến từ nhóm sản phẩm phổ biến nhất (10% sản phẩm được mua nhiều nhất); trên nhóm sản phẩm ít phổ biến, không mô hình nào gợi ý đúng đáng kể.
- Theo giao thức lấy mẫu Sampled-99 (mỗi sản phẩm đứng xếp cùng 99 sản phẩm âm), mọi chỉ số bị thổi phồng nhiều lần và thứ hạng giữa các mô hình thay đổi (Most Popular đứng đầu) – minh họa cho khuyến nghị chỉ dùng Full Ranking [46].

Giai đoạn v1 để lại bốn bài học, là cơ sở trực tiếp của giao thức v2: (i) với dữ liệu thưa

như H&M, chỉ tăng độ phức tạp của mô hình trên cùng thông tin ID (NeuMF so với MF) không mang lại lợi ích – cần bổ sung *thông tin* chứ không chỉ bổ sung tham số; (ii) loại sản phẩm mới khởi đánh giá làm bài toán dễ hơn thực tế và che mất giới hạn lớn nhất của lọc cộng tác thuần; (iii) lọc k -core trên toàn bộ mẫu dùng cả thông tin của giai đoạn kiểm thử; (iv) tập kiểm thử của mẫu A đã được xem nhiều lần (27/09, 29/09/2026) và một số quyết định – như bổ sung bước huấn luyện lại trên tập huấn luyện $\cup$ xác thực, thêm Late Fusion và baseline láng giềng – được đưa ra sau khi đã xem kết quả, nên số liệu $v1$ không còn là ước lượng không thiên lệch. Vì vậy kết quả $v1$ chỉ được báo cáo như lịch sử phát triển, không gộp với kết quả $v2$; mọi kết luận của báo cáo lấy từ mẫu B.

4.6 Phạm vi và giới hạn thực nghiệm

Kết quả của chương này có giá trị trong phạm vi sau: (i) một mẫu kiểm định khoảng 21.000 khách hàng (khoảng 1,5% khách của H&M) sau lọc $k = 10$, thiên về khách mua nhiều; (ii) khung thời gian 07–09/2020 và giả định doanh nghiệp biết trước danh mục sắp bán (mục 3.2.4) – nếu không có giả định này, sản phẩm mới không thể nằm trong tập ứng viên của bất kỳ mô hình nào; (iii) khách hàng mới chưa có lịch sử mua nằm ngoài phạm vi; (iv) lọc k -core dùng mọi cặp trước mốc kiểm thử, nên tập người dùng/sản phẩm ở giai đoạn xác thực phụ thuộc một phần vào dữ liệu tháng 7/2020 – điều này chỉ ảnh hưởng việc chọn cấu hình trên mẫu A, không ảnh hưởng tập kiểm thử của mẫu B; (v) thuộc tính khách hàng là ảnh chụp tại thời điểm công bố dữ liệu (không có mốc thời gian); (vi) ablation chỉ chạy một seed; (vii) một bộ dữ liệu duy nhất. Đánh giá cuối được tính trên **[chưa có]**; chạy lại trên phần cứng khác (CPU so với GPU) có thể làm các mạng nơ-ron lệch nhẹ ở chữ số cuối – kết luận thống kê mới là điều cần được giữ nguyên khi chạy lại.

4.7 Thảo luận

Mô hình lai có đặc trưng có vượt các baseline hay không? Theo tiêu chí đã đăng ký trước: **[chưa có]** So sánh này có ý nghĩa vì ba điều kiện về phương pháp được bảo đảm: mọi mô hình được tinh chỉnh với cùng ngân sách, tập kiểm thử không được dùng để chọn mô hình, và kết luận lấy trên những khách hàng chưa từng được dùng để ra quyết định – các nguyên tắc đánh giá mà đề tài áp dụng theo khuyến nghị của Ferrari Dacrema và cộng sự [8] và Rendle và cộng sự [7].

Đặc trưng đóng góp gì? So sánh NeuMF-F với NeuMF chỉ dùng ID (**[chưa**

có, [**chưa có**]) đo trực tiếp giá trị của đặc trưng trong cùng kiến trúc hai nhánh. Phân tích theo nhóm sản phẩm (mục 4.4.3) tách phần đóng góp này thành hai nguồn: khả năng gợi ý sản phẩm mới – điều mô hình chỉ dùng ID không làm được – và thay đổi trên sản phẩm cũ; ablation (mục 4.4.4) cho biết nhóm đặc trưng nào quan trọng nhất.

Kết hợp tuyến tính – phi tuyến có mang lại lợi ích? So với từng nhánh đứng riêng, NeuMF-F chênh [**chưa có**] so với GMF-F và [**chưa có**] so với MLP-F; so với hợp nhất muộn của chính hai nhánh, chênh [**chưa có**] (**[chưa có]**).

Kết quả có giá trị gì nếu không ủng hộ giả thuyết? Kết quả được báo cáo đúng như quy tắc đã đăng ký trước, không chọn lọc số liệu có lợi. Dù kết luận theo hướng nào, giá trị của đề tài nằm ở một quy trình đánh giá đáng tin cậy – tập ứng viên gồm cả sản phẩm mới, đặc trưng không dùng thông tin tương lai, cùng ngân sách tính chính, mẫu kiểm định độc lập, khoá tập kiểm thử, kiểm định cặp có hiệu chỉnh đa so sánh – và ở các phép so sánh tách riêng được đóng góp của từng thành phần.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đối chiếu với các mục tiêu ở mục 1.2.1, đề tài đạt được các kết quả sau:

1. **Cơ sở lý thuyết:** Hệ thống hóa lý thuyết về lọc cộng tác trên phản hồi ẩn, nhân tử hóa ma trận, BPR, GMF, MLP, mô hình lai NeuMF, hai cách hợp nhất Early Fusion và Late Fusion, mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm [1], [2], [14], [24], [32], cùng các nghiên cứu về phương pháp đánh giá hệ gợi ý [7], [8], [46].
2. **Quy trình dữ liệu tái lập được, không rò rỉ thông tin tương lai:** lấy hai mẫu khách hàng không giao nhau từ 31,8 triệu giao dịch H&M; lọc k -core chỉ trên dữ liệu trước mốc kiểm thử; tập ứng viên gồm cả sản phẩm mới ra mắt; đặc trưng sản phẩm, khách hàng và thời gian được tính theo thời điểm; lấy mẫu âm chỉ trong sản phẩm đã ra mắt; các điều kiện này được kiểm chứng bằng bộ kiểm thử tự động (mục 3.2).
3. **Mô hình lai NeuMF-F:** giữ cấu trúc hai nhánh GMF và MLP hợp nhất sớm của NeuMF, biểu diễn mỗi khách hàng và sản phẩm bằng Embedding ID cộng phép chiếu của đặc trưng, bỏ ngẫu nhiên ID sản phẩm khi huấn luyện để chấm được sản phẩm mới (mục 3.3); cùng các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, NeuMF chỉ dùng ID) và bày baseline được tinh chỉnh cùng ngân sách.
4. **Đánh giá không thiên lệch:** tinh chỉnh chỉ trên tập xác thực của mẫu phát triển; đánh giá cuối một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước, có khoá tập kiểm thử và nhật ký truy cập; 5 seed; kiểm định Wilcoxon theo người dùng kèm bootstrap và hiệu chỉnh Holm trên họ 10 so sánh (mục 3.6).
5. **Kết quả chính:** Trên tập kiểm thử của mẫu kiểm định, NeuMF-F đạt $\text{NDCG@10} = [\text{chưa có}] \pm [\text{chưa có}]$ (xếp $[\text{chưa có}]$ trong 14 mô hình); NeuMF chỉ dùng ID đạt $[\text{chưa có}]$, BPR-MF $[\text{chưa có}]$, UserKNN $[\text{chưa có}]$, MostPopular-Recent $[\text{chưa có}]$. $[\text{chưa có}]$ Kết quả được báo cáo đầy đủ theo đúng kế hoạch đã đăng ký (Chương 4).
6. **Khả năng triển khai:** Hệ thống demo FastAPI chỉ suy diễn, dùng đúng

các mô hình của đánh giá cuối, tự kiểm tra khớp dữ liệu với lần chạy đã huấn luyện (mục 3.7).

5.2 Hạn chế của đề tài

- **Quy mô dữ liệu:** Hai mẫu khoảng 500.000 giao dịch (mỗi mẫu khoảng 1,5% khách hàng), không phải toàn bộ 31,8 triệu giao dịch, vì đánh giá Full Ranking trên toàn bộ danh mục vượt khả năng của phần cứng sẵn có (máy tính cá nhân, RAM 16 GB).
- **Ngưỡng k -core = 10:** chọn vì giới hạn bộ nhớ thay vì ngưỡng thường gặp $k = 5$; dữ liệu sau lọc thiên về khách mua nhiều, nên kết quả chưa đại diện cho khách ít giao dịch.
- **Giả định về danh mục:** tập ứng viên gồm sản phẩm mới dựa trên giả định doanh nghiệp biết trước danh mục sắp bán; thuộc tính khách hàng không có mốc thời gian nên được coi là ít thay đổi.
- **Một mẫu kiểm định, một khung thời gian:** kết luận đúng cho khách hàng mới của cùng cửa hàng trong giai đoạn 07–09/2020; chưa kiểm chứng trên khung thời gian khác hay bộ dữ liệu khác.
- **Phạm vi đặc trưng và mô hình:** chưa dùng ảnh sản phẩm, giá, chuỗi hành vi; mô tả văn bản chỉ được biểu diễn bằng TF-IDF và SVD; ablation chỉ chạy một seed. Khách hàng mới chưa có lịch sử mua nằm ngoài phạm vi đánh giá; demo xử lý trường hợp này bằng gợi ý theo luật, được gắn nhãn rõ.
- **Lịch sử phát triển:** tập kiểm thử của mẫu phát triển đã được xem nhiều lần ở giao thức v1 (mục 4.5); kết quả v1 vì vậy chỉ được dùng như lịch sử phát triển, và việc thiết kế giao thức v2 có tham khảo những gì rút ra từ v1 – nhưng không dùng bất kỳ dữ liệu nào của mẫu kiểm định.

5.3 Hướng phát triển

1. **Đặc trưng đa phương thức:** biểu diễn mô tả sản phẩm bằng mô hình ngôn ngữ (ví dụ BERT) và ảnh sản phẩm bằng mạng tích chập, hoặc dùng Transformer để hợp nhất nhiều view như hướng của Hồ Thị Linh [11], với cùng quy trình đánh giá không thiên lệch để đo đúng lợi ích so với vector TF-IDF hiện tại.

2. **Hợp nhất muộn có trọng số học được:** thay trọng số cố định của Late Fusion bằng trọng số học được theo nhóm khách hàng (ví dụ ít/nhiều giao dịch) hoặc theo loại sản phẩm (cũ/mới).
3. **Mở rộng quy mô và kiểm chứng chéo:** chạy trên mẫu lớn hơn với $k = 5$ hoặc trên toàn bộ H&M bằng Full Ranking theo lô trên GPU, lặp lại trên khung thời gian khác và trên một bộ dữ liệu giao dịch thứ hai; quy trình hiện tại tách phần đọc dữ liệu thành adapter riêng nên chỉ cần bổ sung một adapter mới.
4. **Mô hình chuỗi, đồ thị và tự mã hóa biến phân:** thử SASRec [36], LightGCN [39] hoặc Mult-VAE [40] trên cùng giao thức, với baseline được tinh chỉnh cùng ngân sách.
5. **Triển khai:** kiểm tra đầy đủ bản đóng gói Docker của demo; với danh mục lớn, dùng kiến trúc hai tháp và tìm kiếm lân cận gần đúng [45] thay vì chấm điểm toàn bộ danh mục bằng MLP.

5.4 Triển khai thực tế giao diện thực nghiệm

Thiết kế hệ thống demo (mục 3.7) đã được cài đặt thành hệ thống chạy được: nạp đúng trọng số của đánh giá cuối để suy diễn trực tiếp, tự đối chiếu dữ liệu với lần chạy trước khi nạp, tính lại các chỉ số theo người dùng khớp với kết quả của Chương 4, và minh họa “Top- K khách tương đồng” bằng UserKNN. Gợi ý cho khách hàng mới dùng luật đơn giản và được gắn nhãn rõ là không phải mô hình học. Tập Dockerfile đã có nhưng chưa được kiểm tra đầy đủ; đây là công việc tiếp theo nêu ở mục 5.3.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết và phương pháp luận được sử dụng trong dự án kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống. Các tài liệu là cơ sở về phương pháp; số liệu của chúng không được dùng làm chuẩn so sánh với kết quả của đề tài.

Mục	Luận điểm	Nguồn
<i>A.1. Tổng quan về Hệ thống gợi ý & Lọc cộng tác</i>		
1.1.1	Vai trò cá nhân hóa gợi ý trong thương mại điện tử	Schafer và cộng sự [4]; Linden và cộng sự [5]
2.1.1, 4.2	Lọc dựa trên nội dung; hệ gợi ý lai kết hợp nội dung với cộng tác	Lops và cộng sự [19]; Burke [22]
2.1.2	Nền tảng Lọc cộng tác dựa trên bộ nhớ (Memory-based CF, GroupLens, Item-based CF)	Resnick và cộng sự [23]; Sarwar và cộng sự [20]; Su và Khoshgoftaar [21]
2.1.2, 4.2	Baseline láng giềng (ItemKNN, UserKNN); nguyên tắc đặt mô hình học sâu cạnh baseline đơn giản được tinh chỉnh đầy đủ	Sarwar và cộng sự [20]; Ferrari Dacrema và cộng sự [8]
1.1.2	Hạn chế của tích vô hướng trong Nhân tử hóa ma trận (Matrix Factorization)	Koren và cộng sự [1]; He và cộng sự [2]
2.1.4, 1.1.2	Khởi đầu lạnh (Cold-Start) và nhu cầu kết hợp thông tin nội dung	Schein và cộng sự [6]
1.2.2	Bộ dữ liệu H&M Personalized Fashion Recommendations	H&M Group [3]
<i>A.2. Phản hồi ẩn, NCF, mô hình lai có đặc trưng & chiến lược hợp nhất</i>		
2.2.3	Xếp hạng cá nhân hóa Bayes (BPR) từ phản hồi ẩn	Rendle và cộng sự [24]
2.3	Khung làm việc NCF và kiến trúc mô hình lai NeuMF (GMF + MLP)	He và cộng sự [2]

Mục	Luận điểm	Nguồn
2.4.1, 3.3.2	Mô hình lai dựa trên đặc trưng: Factorization Machines, Wide & Deep, DeepFM, DIN	Rendle [14]; Cheng và cộng sự [9]; Guo và cộng sự [10]; Zhou và cộng sự [31]
2.4.1, 3.3.1	Bỏ ngẫu nhiên biểu diễn sở thích khi huấn luyện để chấm được đối tượng khỏi đầu lạnh (DropoutNet)	Volkovs và cộng sự [32]
2.4.1, 3.2.5	Biểu diễn văn bản bằng TF-IDF và phân tích ngữ nghĩa tiềm ẩn (SVD rút gọn)	Salton và Buckley [33]; Deerwester và cộng sự [34]
2.3.4	Chiến lược hợp nhất Early Fusion và Late Fusion; Late Fusion có trọng số là kiểu lai weighted	Atrey và cộng sự [27]; Liu và cộng sự [28]; Hồ Thị Linh [11]; Burke [22]
3.4.2	Thuật toán tối ưu hóa thích ứng Adam	Kingma và Ba [15]
<i>A.3. Xu hướng nghiên cứu hiện đại</i>		
2.4.2	Gợi ý theo chuỗi hành vi và Transformer	Hidasi và cộng sự [35]; Kang và McAuley [36]; Sun và cộng sự [37]
2.4.3	Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)	Wang và cộng sự [38]; He và cộng sự [39]
2.4.4	Tự mã hóa biến phân cho lọc cộng tác (Mult-VAE)	Liang và cộng sự [40]
2.4	Học tự giám sát, gợi ý sinh, mô hình ngôn ngữ lớn, mô hình khuếch tán; kiến trúc hai tháp; khảo sát tổng quan	Wu và cộng sự [41]; Rajput và cộng sự [42]; Wu và cộng sự [43]; Wei và Fang [44]; Covington và cộng sự [45]; Zhang và cộng sự [29]; Li và cộng sự [30]
<i>A.4. Đánh giá Top-K, cài đặt & kiểm định</i>		
2.5	Giao thức đánh giá hiệu năng xếp hạng Top-N Recommendation	Cremonesi và cộng sự [49]; He và cộng sự [2]
2.5, 4.5	Vấn đề đánh giá bằng tập ứng viên lấy mẫu (Sampled Metrics); chọn Full Ranking	Krichene và Rendle [46]

Mục	Luận điểm	Nguồn
3.2.4	Chia dữ liệu theo một mốc thời gian chung thay vì Leave-One-Out	Meng và cộng sự [48]
3.6, 4.7	Baseline phải được tinh chỉnh cùng ngân sách; không chọn mô hình trên tập kiểm thử	Ferrari Dacrema và cộng sự [8]; Rendle và cộng sự [7]
2.2.1, 4.5	Thuật toán iALS cho phản hồi ẩn và cách tinh chỉnh iALS	Hu và cộng sự [25]; Rendle và cộng sự [26]
3.6	Kiểm định Wilcoxon signed-rank, paired bootstrap, hiệu chỉnh Holm	Wilcoxon [16]; Efron và Tibshirani [17]; Holm [18]
1.3	Nền tảng và thư viện tính toán học sâu PyTorch	Paszke và cộng sự [12]
2.5	Đánh giá xếp hạng dựa trên độ đo NDCG	Järvelin và Kekäläinen [13]
2.5.1	Thiên lệch phổ biến và các chỉ số ngoài độ chính xác	Vargas và Castells [47]

Ghi chú. Các thông số cấu hình và thiết kế hệ thống trình bày trong Chương 3 và kết quả thực nghiệm trong Chương 4 do nhóm tác giả tự triển khai và tính toán từ mã nguồn thực nghiệm của dự án.

PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM

Mã nguồn nằm trong thư mục `neumf_project/` của kho mã dự án; hướng dẫn chi tiết ở tệp `README.md`. Các bước tạo ra toàn bộ số liệu của giao thức v2 (Chương 4):

1. **Dữ liệu:** đặt `transactions_train.csv`, `articles.csv` và `customers.csv` của cuộc thi H&M vào `data/raw/hm/`; chạy `python run.py sample-hm` để tạo mẫu phát triển A và `python run.py v2-data` để tạo mẫu kiểm định B cùng các tệp đặc trưng (danh mục sản phẩm, doanh số theo ngày). Mọi bước đều tắt định.
2. **Tinh chỉnh (chỉ tập xác thực của mẫu A):** `python run.py v2-tune --resume`; mỗi cấu hình ghi một dòng vào `audit/v2/tuning_log.csv` (kèm phiên bản và mã băm nội dung mã nguồn), cấu hình tốt nhất vào `audit/v2/best_configs.json`.
3. **Đăng ký trước:** kế hoạch `audit/PREREG_v2.md` phải được lưu vào git trước bước đánh giá cuối.
4. **Chạy thử (không chạm tập kiểm thử):** `python run.py v2-dry-run` chạy trọn đường ống đánh giá cuối trên tập xác thực của mẫu A với 1 epoch, để phát hiện lỗi trước khi mở tập kiểm thử.
5. **Đánh giá cuối:** `python run.py v2-final --reason "..."` chạy `23_final_v2.py` (5 seed trên mẫu B, có khoá tập kiểm thử: từ chối chạy nếu kế hoạch chưa lưu, thiếu lý do, mã nguồn có thay đổi chưa lưu hoặc khác mã nguồn lúc tinh chỉnh; mỗi seed ghi một dòng vào `audit/test_access_log.csv` trước khi chấm) rồi `24_report_v2.py` (kiểm định, bảng, hình và macro số liệu sang báo cáo).
6. **Biên dịch báo cáo:** chạy `compile.bat` trong thư mục báo cáo.

Kết quả của giai đoạn phát triển (giao thức v1, mục 4.5) được giữ nguyên trong kho mã (`outputs/final/`, `audit/PREREG.md`) cùng các lệnh tái lập tương ứng trong `README.md`. Nhật ký `audit/test_access_log.csv` liệt kê mọi lần đánh giá trên tập kiểm thử của cả hai giao thức, kèm phiên bản mã nguồn và mã băm cấu hình tương ứng.

TÀI LIỆU THAM KHẢO

Y. Koren, R. Bell, và C. Volinsky, “Matrix Factorization Techniques for Recommender Systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, “Neural Collaborative Filtering,” in *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

H&M Group, *H&M Personalized Fashion Recommendations*, <https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations>, Cuộc thi trên Kaggle, 2022.

J. B. Schafer, J. A. Konstan, và J. Riedl, “E-Commerce Recommendation Applications,” *Data Mining and Knowledge Discovery*, vol. 5, no. 1-2, pp. 115–153, 2001. DOI: 10.1023/A:1009804230409

G. Linden, B. Smith, và J. York, “Amazon.com Recommendations: Item-to-Item Collaborative Filtering,” *IEEE Internet Computing*, vol. 7, no. 1, pp. 76–80, 2003. DOI: 10.1109/MIC.2003.1167344

A. I. Schein, A. Popescul, L. H. Ungar, và D. M. Pennock, “Methods and Metrics for Cold-Start Recommendations,” in *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '02)*, 2002, pp. 253–260.

S. Rendle, W. Krichene, L. Zhang, và J. Anderson, “Neural Collaborative Filtering vs. Matrix Factorization Revisited,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, “Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

H.-T. Cheng và cộng sự, “Wide & Deep Learning for Recommender Systems,” in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS 2016)*, Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, “DeepFM: A Factorization-Machine based Neural Network for CTR Prediction,” in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

Hồ Thị Linh, “Multi-Source Integration for Recommendation Systems,” Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

K. Järvelin và J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

S. Rendle, “Factorization Machines,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

P. Lops, M. de Gemmis, và G. Semeraro, “Content-based Recommender Systems: State of the Art and Trends,” in *Recommender Systems Handbook*, F. Ricci, L. Rokach, B. Shapira, và P. B. Kantor, eds., Springer, 2011, pp. 73–105.

B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, “Item-based Collaborative Filtering Recommendation Algorithms,” in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

X. Su và T. M. Khoshgoftaar, “A Survey of Collaborative Filtering Techniques,” *Advances in Artificial Intelligence*, vol. 2009, pp. 1–19, 2009. DOI: 10.1155/2009/421425

R. Burke, “Hybrid Recommender Systems: Survey and Experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, và J. Riedl, “GroupLens: An Open Architecture for Collaborative Filtering of Netnews,” in *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, 1994, pp. 175–186. DOI: 10.1145/192844.192905

S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, “BPR: Bayesian Personalized Ranking from Implicit Feedback,” in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI '09)*, Montreal, QC, Canada, 2009, pp. 452–461.

Y. Hu, Y. Koren, và C. Volinsky, “Collaborative Filtering for Implicit Feedback Datasets,” in *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, 2008, pp. 263–272. DOI: 10.1109/ICDM.2008.22

S. Rendle, W. Krichene, L. Zhang, và Y. Koren, “Revisiting the Performance of iALS on Item Recommendation Benchmarks,” in *Proceedings of the 16th ACM Conference on Recommender Systems (RecSys '22)*, 2022. DOI: 10.1145/3523227.3548486

P. K. Atrey, M. A. Hossain, A. El Saddik, và M. S. Kankanhalli, “Multimodal Fusion for Multimedia Analysis: A Survey,” *Multimedia Systems*, vol. 16, no. 6, pp. 345–379, 2010.

K. Liu, Y. Li, N. Xu, và P. Natarajan, “Learn to Combine Modalities in Multimodal Deep Learning,” *arXiv preprint arXiv:1805.11730*, 2018.

S. Zhang, L. Yao, A. Sun, và Y. Tay, “Deep Learning Based Recommender System: A Survey and New Perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029

P. Li, S. A. Mohd Noah, và H. Mohd Sarim, “A Survey on Deep Neural Networks in Collaborative Filtering Recommendation Systems,” *arXiv preprint arXiv:2412.01378*, 2024.

G. Zhou và cộng sự, “Deep Interest Network for Click-Through Rate Prediction,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '18)*, 2018, pp. 1059–1068. DOI: 10.1145/3219819.3219823

M. Volkovs, G. Yu, và T. Poutanen, “DropoutNet: Addressing Cold Start in Recommender Systems,” in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 4957–4966.

G. Salton và C. Buckley, “Term-weighting Approaches in Automatic Text Retrieval,” *Information Processing and Management*, vol. 24, no. 5, pp. 513–523, 1988.

S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, và R. Harshman, “Indexing by Latent Semantic Analysis,” *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

B. Hidasi, A. Karatzoglou, L. Baltrunas, và D. Tikk, “Session-based Recommendations with Recurrent Neural Networks,” in *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016.

W.-C. Kang và J. McAuley, “Self-Attentive Sequential Recommendation,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2018, pp. 197–206. DOI: 10.1109/ICDM.2018.00035

F. Sun và cộng sự, “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer,” in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19)*, 2019, pp. 1441–1450. DOI: 10.1145/3357384.3357895

X. Wang, X. He, M. Wang, F. Feng, và T.-S. Chua, “Neural Graph Collaborative Filtering,” in *Proceedings of the 42nd International ACM SIGIR Conference on*

Research and Development in Information Retrieval (SIGIR '19), 2019, pp. 165–174. DOI: 10.1145/3331184.3331267

X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, và M. Wang, “LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '20)*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063

D. Liang, R. G. Krishnan, M. D. Hoffman, và T. Jebara, “Variational Autoencoders for Collaborative Filtering,” in *Proceedings of the 2018 World Wide Web Conference (WWW '18)*, 2018, pp. 689–698. DOI: 10.1145/3178876.3186150

J. Wu và cộng sự, “Self-supervised Graph Learning for Recommendation,” in *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '21)*, 2021, pp. 726–735. DOI: 10.1145/3404835.3462862

S. Rajput và cộng sự, “Recommender Systems with Generative Retrieval,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.

L. Wu và cộng sự, “A Survey on Large Language Models for Recommendation,” *World Wide Web*, vol. 27, no. 60, 2024. DOI: 10.1007/s11280-024-01291-2

T.-R. Wei và Y. Fang, “Diffusion Models in Recommendation Systems: A Survey,” *arXiv preprint arXiv:2501.10548*, 2025.

P. Covington, J. Adams, và E. Sargin, “Deep Neural Networks for YouTube Recommendations,” in *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys '16)*, 2016, pp. 191–198. DOI: 10.1145/2959100.2959190

W. Krichene và S. Rendle, “On Sampled Metrics for Item Recommendation,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

S. Vargas và P. Castells, “Rank and Relevance in Novelty and Diversity Metrics for Recommender Systems,” in *Proceedings of the 5th ACM Conference on Recommender Systems (RecSys '11)*, 2011, pp. 109–116. DOI: 10.1145/2043932.2043955

Z. Meng, R. McCreadie, C. Macdonald, và I. Ounis, “Exploring Data Splitting Strategies for the Evaluation of Recommendation Models,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020. DOI: 10.1145/3383313.3418479

P. Cremonesi, Y. Koren, và R. Turrin, “Performance of Recommender Algorithms on Top-N Recommendation Tasks,” in *Proceedings of the 4th ACM Conference on Recommender Systems (RecSys)*, 2010, pp. 39–46. DOI: 10.1145/1864708.1864721