

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI
KẾT HỢP NHÂN TỬ HOÁ MA TRẬN
VÀ MẠNG LƯỚI THẦN KINH SÂU**

**DỰ ÁN CÔNG NGHỆ THÔNG TIN
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218**

**XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI
KẾT HỢP NHÂN TỬ HOÁ MA TRẬN
VÀ MẠNG LƯỚI THẦN KINH SÂU**

**DỰ ÁN CÔNG NGHỆ THÔNG TIN
MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG
DỮ LIỆU**

**Giảng viên hướng dẫn
TS. HỒ THỊ LINH**

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chu chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày tháng năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan báo cáo dự án này là công trình nghiên cứu độc lập của chúng tôi dưới sự hướng dẫn khoa học trực tiếp của TS. Hồ Thị Linh. Mọi số liệu, quá trình phân tích và kết quả thực nghiệm trình bày trong báo cáo là hoàn toàn trung thực, khách quan và chưa từng được công bố dưới bất kỳ hình thức nào trước đây.

Các nguồn tài liệu tham khảo, số liệu trích dẫn phục vụ cho dự án đều có nguồn gốc rõ ràng, có độ tin cậy cao và được chú thích đầy đủ trong danh mục tài liệu tham khảo.

Chúng tôi xin hoàn toàn chịu trách nhiệm trước Nhà trường và pháp luật về tính chân thực, bản quyền cũng như các vi phạm quyền sở hữu trí tuệ liên quan đến nội dung báo cáo dự án này.

TP. Hồ Chí Minh, ngày tháng năm 2026

Tác giả

(Ký và ghi rõ họ tên)

Tác giả

(Ký và ghi rõ họ tên)

Lê Minh Lý

Sử Thị Yến Linh

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngàytháng

.....năm

(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Nhân tử hóa ma trận (Matrix Factorization – MF) mô hình hóa tương tác giữa người dùng và sản phẩm bằng tích vô hướng [1], một phép kết hợp tuyến tính được cho là khó nắm bắt các quan hệ phi tuyến [2]. Dự án xây dựng và đánh giá mô hình lai Neural Matrix Factorization (NeuMF), kết hợp nhánh tuyến tính Generalized Matrix Factorization (GMF) với nhánh phi tuyến Multi-Layer Perceptron (MLP) trên tín hiệu phản hồi ẩn, theo hai biến thể: huấn luyện từ đầu (Scratch) và khởi tạo từ GMF, MLP đã huấn luyện (Pretrained).

Thực nghiệm dùng bộ dữ liệu H&M Personalized Fashion Recommendations [3]. Từ 31,8 triệu giao dịch, dự án lấy mẫu tái lập được theo khách hàng (hm500k: 500.269 giao dịch của 21.599 khách, giữ trọn lịch sử hai năm), gộp cặp người dùng–sản phẩm, lọc 10-core (7.519 người dùng, 10.345 sản phẩm, mật độ 0,28%) và chia theo một mốc thời gian chung để mô hình không nhìn thấy tương lai. Mọi mô hình – NeuMF, hai nhánh GMF, MLP và các baseline Random, Most Popular, BPR-MF – được tinh chỉnh với cùng ngân sách chỉ trên tập xác thực; tập kiểm thử bị khoá, mọi lần chấm đều qua kịch bản ghi nhật ký, theo kế hoạch đã đăng ký trước. Trước khi chấm kiểm thử, mỗi mô hình được huấn luyện lại trên tập huấn luyện $\cup$ xác thực; bước này được bổ sung sau lần chấm đầu tiên và được báo cáo là lệch kế hoạch, kết luận không đổi giữa hai lần chấm. Đánh giá dùng Full Ranking trên toàn bộ catalog, 3 seed, kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm.

Trên tập kiểm thử (2.996 người dùng), BPR-MF đạt NDCG@10 trung bình cao nhất (0,01007); NeuMF-Pretrained đạt 0,00957, ngang Most Popular (0,00917); NeuMF-Scratch – mô hình lai được chọn theo tập xác thực – đạt 0,00910. Không so sánh nào trong 8 so sánh đã đăng ký đạt tiêu chí khác biệt có ý nghĩa: NeuMF không vượt baseline MF đã tinh chỉnh, không vượt các nhánh GMF, MLP của chính nó, và pre-training không mang lại lợi ích đo được. Theo phân loại Early Fusion/Late Fusion, NeuMF hợp nhất nhánh MF và nhánh DNN ở mức biểu diễn; Late Fusion thuần MF + DNN chưa được thực hiện, còn phép trộn điểm MF với NeuMF cho tín hiệu tích cực trên tập xác thực nhưng chưa được đánh giá trên tập kiểm thử. Kết quả âm này nhất quán với các nghiên cứu đối chứng gần đây về NCF [4], [5], cho thấy trên dữ liệu giao dịch thời trang thưa, độ phức tạp của NeuMF không được đền bù bằng độ chính xác.

Hệ thống demo suy diễn (FastAPI) minh họa và so sánh các mô hình trên từng khách hàng, kèm độ trễ gợi ý đo thực tế trên CPU.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Matrix Factorization (MF) models user–item interactions with an inner product [1], a linear combination that is argued to miss non-linear relationships [2]. This project builds and evaluates the hybrid Neural Matrix Factorization (NeuMF) model, which combines a linear Generalized Matrix Factorization (GMF) branch with a non-linear Multi-Layer Perceptron (MLP) branch on implicit feedback, in two variants: trained from scratch and initialised from pre-trained GMF and MLP.

Experiments use the H&M Personalized Fashion Recommendations dataset [3]. From 31.8 million transactions, a reproducible customer-level sample is drawn (hm500k: 500,269 transactions of 21,599 customers with their full two-year history), user–item pairs are aggregated, a 10-core filter is applied (7,519 users, 10,345 items, 0.28% density), and the data is split at a single global time point so that no model sees the future. All models – NeuMF, its GMF and MLP branches, and the Random, Most Popular and BPR-MF baselines – are tuned with the same budget on the validation set only; the test set is locked and every evaluation on it goes through a logged script, following a pre-registered plan. Before testing, each model is retrained on the union of the training and validation sets; this step was added after the first test run and is reported as a deviation from the plan, and the conclusions are the same in both runs. Evaluation uses full ranking over the whole catalogue, three seeds, and per-user Wilcoxon signed-rank tests with bootstrap confidence intervals and Holm correction.

On the test set, tuned BPR-MF has the highest mean NDCG@10; pre-trained NeuMF is on par with Most Popular, and the hybrid model selected on validation (NeuMF from scratch) scores lower still. None of the pre-registered comparisons reaches significance: NeuMF does not outperform a tuned MF baseline or its own GMF and MLP branches, and pre-training brings no measurable gain. In the early/late fusion taxonomy, NeuMF fuses the MF and DNN branches at the representation level (early fusion); a pure MF + DNN late fusion was not run, and a score-level blend of MF with NeuMF looked promising on validation but was not evaluated on the test set. This negative result is consistent with recent re-evaluations of NCF [4], [5]: on sparse fashion transaction data, the added complexity of NeuMF is not repaid in accuracy. An

inference-only demo (FastAPI) compares the models for individual customers, with recommendation latency measured on CPU.

MỤC LỤC

DANH MỤC HÌNH VẼ.....	xii
DANH MỤC BẢNG BIỂU.....	xiii
DANH MỤC CÁC CHỮ VIẾT TẮT.....	xiv
CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài	1
1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài.....	1
1.1.2 Vì sao Nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này	1
1.1.3 Lựa chọn NeuMF: kết hợp thay vì thay thế MF	2
1.2 Mục tiêu và phạm vi nghiên cứu	2
1.2.1 Mục tiêu nghiên cứu	2
1.2.2 Phạm vi nghiên cứu.....	3
1.3 Phương pháp nghiên cứu	3
1.4 Ý nghĩa khoa học và thực tiễn của đề tài.....	4
1.4.1 Ý nghĩa khoa học	4
1.4.2 Ý nghĩa thực tiễn.....	5
1.5 Bố cục của báo cáo dự án	5
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN	7
2.1 Tổng quan về hệ thống gợi ý (Recommendation System)	7
2.1.1 Vì sao đề tài chọn nhánh Lọc cộng tác thay vì Lọc nội dung	7
2.1.2 Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based)	7
2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback)	8
2.1.4 Độ thưa dữ liệu và Cold-Start: hai giới hạn định hình phạm vi đề tài	9
2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận.....	9
2.2.1 Mô hình Nhân tử hóa ma trận (Matrix Factorization – MF)	9
2.2.2 Hạn chế của tích vô hướng trong mô hình hóa tương tác	9

2.2.3	Tổng quát hóa MF với đặc trưng phụ trợ: <i>Factorization Machines (FM)</i> .	10
2.2.4	Tối ưu hóa xếp hạng theo cặp: <i>Bayesian Personalized Ranking (BPR)</i>	10
2.3	Kiến trúc Mạng khuyến nghị thần kinh (<i>Neural Collaborative Filtering – NCF</i>).....	11
2.3.1	<i>Generalized Matrix Factorization (GMF)</i>	11
2.3.2	<i>Multi-Layer Perceptron (MLP)</i>	11
2.3.3	Kiến trúc mô hình lai <i>NeuMF</i>	11
2.3.4	Chiến lược hợp nhất: <i>Early Fusion</i> và <i>Late Fusion</i>	12
2.3.5	Lấy mẫu tiêu cực (<i>Negative Sampling</i>) và hàm tổn thất <i>Binary Cross-Entropy</i>	13
2.4	Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu	14
2.4.1	Mô hình học sâu dựa trên đặc trưng tương tác (<i>Feature-rich Deep CTR Models</i>).....	14
2.4.2	Kiến trúc hai tháp (<i>Two-Tower</i>) cho truy hồi quy mô lớn.....	14
2.4.3	Gợi ý theo chuỗi hành vi (<i>Sequential và Session-based Recommendation</i>)	15
2.4.4	Học biểu diễn trên đồ thị (<i>Graph-based Collaborative Filtering</i>)	15
2.4.5	Học tự giám sát, sinh biểu diễn xác suất và mô hình ngôn ngữ lớn.....	16
2.5	Các chỉ số đánh giá hệ thống gợi ý Top-K.....	18
2.5.1	Các chỉ số đánh giá ngoài độ chính xác (<i>Beyond-Accuracy Metrics</i>).....	19
2.6	Tổng quan các công trình nghiên cứu liên quan.....	20
2.7	Khoảng trống nghiên cứu	22
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH NEUMF		24
3.1	Kiến trúc tổng thể của hệ thống nghiên cứu.....	24
3.2	Phân tích và tiền xử lý dữ liệu H&M Personalized Fashion Recommendations.....	24
3.2.1	Đặc tả bộ dữ liệu và thách thức về quy mô	24
3.2.2	Lấy mẫu <i>hm500k</i> theo khách hàng.....	26
3.2.3	Xây dựng ma trận tương tác phản hồi ẩn	27

3.2.4	Lựa chọn ngưỡng lọc k -core	27
3.2.5	Phân chia dữ liệu theo thời gian	28
3.3	Thiết kế kiến trúc mô hình NeuMF	30
3.3.1	Cấu hình không gian nhúng Embedding độc lập.....	30
3.3.2	Thiết kế nhánh Generalized Matrix Factorization (GMF).....	30
3.3.3	Thiết kế nhánh Multi-Layer Perceptron (MLP).....	30
3.3.4	Nhánh MLP đứng riêng: mô hình DNN thuần, không phải mô hình hợp nhất.....	31
3.3.5	Tầng kết hợp NeuMF và lớp dự đoán đầu ra	31
3.4	Kỹ thuật lấy mẫu tiêu cực và hàm mục tiêu huấn luyện.....	32
3.4.1	Kỹ thuật lấy mẫu tiêu cực động (Dynamic Negative Sampling).....	32
3.4.2	Hàm tổn thất Binary Cross-Entropy (BCE) và Regularization.....	32
3.5	Quy trình huấn luyện và tối ưu hóa mô hình	33
3.5.1	Chiến lược tiền huấn luyện (Pre-training GMF + MLP)	33
3.5.2	Bảng thiết lập siêu tham số và kỹ thuật dừng sớm (Early Stopping).....	33
3.6	Quy trình tinh chỉnh và đánh giá không thiên lệch	35
3.7	Thiết kế hệ thống giao diện thực nghiệm (Demo)	36
3.7.1	Kiến trúc tổng thể: ba tầng tách biệt.....	37
3.7.2	Thiết kế API suy diễn.....	37
3.7.3	Lựa chọn mô hình triển khai và yêu cầu phi chức năng.....	39
3.7.4	Minh họa hệ thống demo đã cài đặt.....	39
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ		40
4.1	Cấu hình thực nghiệm.....	40
4.2	Phương pháp đối chứng (Baselines).....	40
4.3	Kết quả tinh chỉnh trên tập xác thực.....	41
4.4	Kết quả trên tập kiểm thử	42
4.4.1	So sánh các độ đo xếp hạng (Full Ranking).....	42
4.4.2	Kiểm định ý nghĩa thống kê.....	43

4.4.3	<i>Phân tích bóc tách thành phần (Ablation Study)</i>	45
4.4.4	<i>Đánh giá phân tầng: sản phẩm phổ biến/ít phổ biến và người dùng ít/nhiều tương tác</i>	46
4.4.5	<i>Đối chiếu với giao thức Sampled-99</i>	47
4.4.6	<i>Độ trễ suy diễn</i>	48
4.5	Phạm vi và giới hạn thực nghiệm	49
4.6	Thảo luận	49
	CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	51
5.1	Kết luận.....	51
5.2	Hạn chế của đề tài.....	52
5.3	Hướng phát triển	53
5.4	Triển khai thực tế giao diện thực nghiệm	53
	PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN	54
	PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM	57
	TÀI LIỆU THAM KHẢO	58

DANH MỤC HÌNH VẼ

Hình 2.1: Sơ đồ kiến trúc chi tiết mô hình lai Neural Matrix Factorization (NeuMF)	12
Hình 3.1: Kiến trúc tổng thể của hệ thống nghiên cứu, từ dữ liệu thô H&M đến đánh giá cuối trên tập test	25
Hình 3.2: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo)	37
Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử: trung bình $\pm$ độ lệch chuẩn qua 3 seed, chấm đen là từng seed	42
Hình 4.2: Chênh lệch NDCG@10 (A – B) với khoảng tin cậy 95% bootstrap theo người dùng, kèm giá trị p đã hiệu chỉnh Holm	44
Hình 4.3: NDCG@10 trên validation (seed 42, cấu hình tốt nhất) so với trên test (trung bình 3 seed)	44

DANH MỤC BẢNG BIỂU

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan	20
Bảng 3.1: Độ nhảy k -core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ)	26
Bảng 3.2: Độ nhảy của mẫu hm500k theo ngưỡng lọc k -core (429.964 cặp trước khi lọc)	28
Bảng 3.3: Kết quả phân chia theo mốc thời gian chung trên hm500k ($k = 10$) ...	29
Bảng 3.4: Siêu tham số: giá trị mặc định và không gian tìm chỉnh	34
Bảng 3.5: Các endpoint chính của API suy diễn	38
Bảng 4.1: Cấu hình tốt nhất của từng mô hình sau tuning (chỉ trên tập validation, seed 42, 6 cấu hình/mô hình, protocol mốc thời gian chung)	41
Bảng 4.2: Kết quả trên tập test: trung bình $\pm$ độ lệch chuẩn qua 3 seed (Full Ranking, protocol mốc thời gian chung, train lại trên train $\cup$ val; 2.996 user, 10.216 item candidate).....	42
Bảng 4.3: Kiểm định cặp theo user trên NDCG@10 (trung bình qua 3 seed): Wilcoxon signed-rank, CI 95% paired bootstrap, hiệu chỉnh Holm trên họ 8 so sánh.....	43
Bảng 4.4: NDCG@10 theo nhóm item (head = 10% item phổ biến nhất trong train $\cup$ val) và nhóm user (cold = 20% user ít tương tác train $\cup$ val nhất); trung bình 3 seed	46
Bảng 4.5: Chỉ số ngoài độ chính xác của danh sách top-10 trên tập test (trung bình 3 seed)	47
Bảng 4.6: Đối chiếu Full Ranking với Sampled-99 (1 item đúng + 99 item âm, protocol NCF gốc) trên tập test; trung bình 3 seed	48
Bảng 4.7: Độ trễ phục vụ một yêu cầu gợi ý top-10 trên CPU (chăm toàn bộ candidate của một user rồi lấy top-10), mili giây.....	48

DANH MỤC CÁC CHỮ VIẾT TẮT

ALS	Alternating Least Squares (Bình phương tối thiểu luân phiên)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hóa Bayes)
CF	Collaborative Filtering (Lọc cộng tác)
DCG	Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu)
DL	Deep Learning (Học sâu)
GMF	Generalized Matrix Factorization (Nhân tử hóa ma trận tổng quát)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
HR	Hit Ratio (Tỷ lệ đánh trúng)
IDCG	Ideal Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu lý tưởng)
MF	Matrix Factorization (Nhân tử hóa ma trận)
MLP	Multi-Layer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
NCF	Neural Collaborative Filtering (Lọc cộng tác dựa trên nơ-ron)
NDCG	Normalized Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu chuẩn hóa)
NeuMF	Neural Matrix Factorization (Nhân tử hóa ma trận thần kinh)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
SGD	Stochastic Gradient Descent (Hạ độ dốc ngẫu nhiên)
SVD	Singular Value Decomposition (Phân rã giá trị kỳ dị)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài

Động lực trực tiếp của đề tài xuất phát từ việc khảo sát bộ dữ liệu H&M Personalized Fashion Recommendations [3] trước khi bắt tay vào xây dựng mô hình: tập giao dịch gốc ghi nhận 31.788.324 dòng mua hàng của 1.362.281 khách hàng trên 104.547 sản phẩm thời trang (mục 3.2.1), nhưng ngay cả sau khi lọc k -core, ma trận tương tác vẫn chỉ có mật độ khoảng 0,03% (Bảng 3.1) – mỗi khách hàng chỉ mua một phần cực nhỏ trong catalog. Cấu trúc dữ liệu “nhiều User – nhiều Item – cực thưa” này khác đáng kể so với kịch bản phim ảnh (MovieLens) hay mạng ảnh (Pinterest) mà phần lớn tài liệu về NCF/NeuMF gốc [2] sử dụng để kiểm chứng – đặt ra câu hỏi cụ thể mà nhóm muốn trả lời qua đề tài: một kiến trúc lai tuyến tính–phi tuyến như NeuMF có còn phát huy ưu thế trên dữ liệu giao dịch thời trang thực tế, cực thưa và lệch mạnh về một nhóm nhỏ sản phẩm phổ biến hay không.

Ở góc độ ứng dụng, việc cá nhân hóa gợi ý sản phẩm trong bối cảnh thương mại điện tử vẫn giữ nguyên giá trị đã được ghi nhận trong tài liệu học thuật – giảm chi phí tìm kiếm của khách hàng và hỗ trợ dự báo nhu cầu tiêu thụ cho doanh nghiệp [6], [7] – nhưng phần đóng góp cụ thể của đề tài này không nằm ở việc lặp lại luận điểm đó, mà ở việc *đo lường bằng số liệu thực* xem một kiến trúc học sâu cụ thể (NeuMF) hoạt động ra sao trên đúng loại dữ liệu giao dịch có cấu trúc như trên.

1.1.2 Vì sao Nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này

Cách tiếp cận đơn giản nhất cho bài toán trên là Nhân tử hóa ma trận (Matrix Factorization – MF): mỗi User u và Item i được gán một vector ẩn $p_u, q_i \in \mathbb{R}^d$, và mức độ tương tác được dự đoán bằng tích vô hướng của hai vector này [1]:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^d p_{uf} q_{if} \quad (1.1)$$

Vấn đề nhóm nhận thấy khi cân nhắc áp dụng trực tiếp công thức này lên H&M là: tích vô hướng cộng dồn các chiều đặc trưng theo cùng một trọng số cố định (ngầm định bằng 1 cho mọi chiều), trong khi với một ma trận tương tác cực thưa (mật độ 0,28% trên mẫu thực nghiệm sau lọc k -core, Bảng 3.2) và độ lệch phổ biến rõ rệt, mỗi vector

ẩn được học từ rất ít tương tác và khả năng cao là chỉ một vài chiều đặc trưng thực sự mang tính phân biệt, còn lại là nhiễu. He và cộng sự [2] chỉ ra vấn đề này ở mức tổng quát hơn: tích vô hướng là một phép kết hợp tuyến tính, không có cơ chế học trọng số riêng cho từng chiều hay mô hình hóa tương tác phi tuyến giữa các chiều đặc trưng – đây là cơ sở lý thuyết trực tiếp cho lựa chọn kiến trúc ở mục tiếp theo.

1.1.3 Lựa chọn NeuMF: kết hợp thay vì thay thế MF

Thay vì từ bỏ hoàn toàn cấu trúc tích vô hướng của MF (vốn đã được kiểm chứng hiệu quả và dễ diễn giải), NeuMF – do He và cộng sự đề xuất năm 2017 [2] – giữ lại một nhánh tương đương MF dưới dạng mạng nơ-ron (Generalized Matrix Factorization, GMF) để không đánh mất khả năng học tương tác tuyến tính đã biết là hoạt động tốt, đồng thời bổ sung song song một nhánh Multi-Layer Perceptron (MLP) để mạng có cơ hội tự học thêm các tương tác phi tuyến mà GMF bỏ lỡ. Đây là lý do cụ thể đề tài chọn NeuMF làm đối tượng nghiên cứu chính thay vì một kiến trúc học sâu khác: nó cho phép *tách bạch* được đóng góp của thành phần tuyến tính và phi tuyến trong cùng một mô hình (thông qua Ablation Study, mục 4.4.3) – điều mà một mạng nơ-ron end-to-end không có cấu trúc hai nhánh tường minh sẽ khó thực hiện tương đương.

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

- Nghiên cứu cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận, Mạng nơ-ron sâu và kiến trúc mô hình lai NeuMF [1], [2].
- Xây dựng quy trình xử lý dữ liệu hoàn chỉnh, áp dụng trên bộ dữ liệu H&M Personalized Fashion Recommendations [3] – biến đổi dữ liệu giao dịch thành ma trận tương tác User–Item dạng tín hiệu ẩn, thực hiện lấy mẫu tiêu cực (Negative Sampling) và phân chia tập dữ liệu theo thời gian sao cho mô hình không nhìn thấy tương lai.
- Thiết kế, cài đặt và tinh chỉnh các mô hình GMF, MLP độc lập và mô hình lai NeuMF trên nền tảng PyTorch, với cùng ngân sách tinh chỉnh như các baseline.
- Đánh giá thực nghiệm định lượng hiệu năng của NeuMF so với các nhánh thành phần (GMF, MLP) và baseline (Random, Most Popular, BPR-MF) qua các độ đo NDCG@K [8], Recall@K, HR@K, Precision@K theo giao

thức Full Ranking; thực hiện phân tích bóc tách thành phần (Ablation Study), đánh giá phân tầng theo độ phổ biến sản phẩm và mức độ hoạt động của người dùng, và kiểm định ý nghĩa thống kê theo người dùng qua nhiều lần chạy (3 seed).

Lưu ý về phạm vi: Dự án tập trung vào nhóm người dùng và sản phẩm đã có đủ lịch sử tương tác để xây dựng biểu diễn Embedding (sau khi lọc k -core). Bài toán khởi đầu lạnh (Cold-start) cho người dùng/sản phẩm hoàn toàn mới không nằm trong phạm vi đánh giá thực nghiệm của dự án và được ghi nhận như một hướng phát triển trong tương lai (Chương 5).

1.2.2 Phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Kiến trúc Neural Collaborative Filtering (GMF, MLP, NeuMF) [2], hai cách hợp nhất mô hình MF với mạng nơ-ron sâu – Early Fusion (mức biểu diễn) và Late Fusion (mức điểm dự đoán) [9] – kỹ thuật biểu diễn Embedding và các thuật toán đánh giá hệ thống gợi ý Top-K.
- **Dữ liệu thực nghiệm:** Bộ dữ liệu H&M Personalized Fashion Recommendations [3] (thời trang, catalog lớn và cực thưa), khai thác lịch sử giao dịch mua sắm giữa khách hàng và sản phẩm. Khảo sát k -core được chạy trên toàn bộ 31,8 triệu dòng giao dịch; huấn luyện và đánh giá mô hình được thực hiện trên mẫu hm500k – khoảng 500.000 giao dịch của 21.599 khách hàng được chọn ngẫu nhiên, giữ trọn lịch sử mua 2 năm (lý do ở mục 3.2.2).
- **Tín hiệu tương tác:** Phản hồi ẩn dạng nhị phân dựa trên lịch sử mua hàng. Mọi mô hình chỉ học từ ma trận tương tác User–Item (lọc cộng tác thuần); không dùng giá, thuộc tính sản phẩm, ảnh hay thông tin khách hàng làm đầu vào.

1.3 Phương pháp nghiên cứu

Để giải quyết các mục tiêu nghiên cứu đã đặt ra (mục 1.2.1), đề tài kết hợp bốn nhóm phương pháp bổ trợ lẫn nhau, được triển khai tuần tự theo đúng trình tự trình bày trong các chương tiếp theo:

1. **Phương pháp nghiên cứu lý thuyết (phân tích và tổng hợp tài liệu):** Hệ thống hóa cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận và kiến trúc NCF/NeuMF từ các công trình nền tảng [1], [2], đồng thời khảo sát các hướng nghiên cứu hiện đại hơn (Graph-based CF, Sequential Recommen-

dation, LLM/Diffusion-based Recommendation) để xác định chính xác vị trí đóng góp và các giới hạn cố hữu của hướng tiếp cận được lựa chọn (Chương 2).

2. **Phương pháp xử lý dữ liệu định lượng:** Xây dựng một pipeline tiền xử lý dữ liệu tường minh, có thể tái lập (reproducible) và kiểm chứng được ở từng bước – từ lấy mẫu theo khách hàng, gộp giao dịch trùng lặp, lọc k -core, đến phân chia theo một mốc thời gian chung kèm kiểm tra không giao nhau bắt buộc – áp dụng trên bộ dữ liệu H&M Personalized Fashion Recommendations (Chương 3).
3. **Phương pháp thực nghiệm khoa học (mô hình hóa và huấn luyện):** Cài đặt các mô hình GMF, MLP và NeuMF bằng framework PyTorch [10], áp dụng chiến lược tiền huấn luyện (Pre-training) và tinh chỉnh (Fine-tuning) của He và cộng sự [2], dùng thuật toán tối ưu Adam [11]; siêu tham số của mọi mô hình được tinh chỉnh với cùng ngân sách, chỉ trên tập xác thực.
4. **Phương pháp đánh giá định lượng và kiểm chứng thống kê:** Đo lường hiệu năng bằng các độ đo chuẩn (NDCG@K [8], Recall@K, HR@K, Precision@K) theo giao thức Full Ranking, dùng Sampled-99 chỉ để đối chiếu [12]; khoá tập kiểm thử và đăng ký trước tiêu chí kết luận; kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm [13], [14], [15]; bổ sung các chỉ số ngoài độ chính xác (Coverage, Novelty, tỉ lệ sản phẩm phổ biến) để tránh kết luận chỉ dựa trên độ chính xác (Chương 4).

Điểm xuyên suốt của phương pháp luận là ưu tiên tính có thể tái lập và kiểm chứng được: mọi số liệu trình bày trong báo cáo đều được trích xuất trực tiếp từ kết quả do chính quy trình thực nghiệm sinh ra, thay vì ước lượng hay diễn giải gián tiếp.

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

- Cung cấp bằng chứng thực nghiệm, có kiểm định thống kê, trên dữ liệu giao dịch thời trang thực tế và cực thưa (H&M) về việc NeuMF có vượt baseline MF đã tinh chỉnh và các nhánh thành phần của chính nó (GMF, MLP) hay không – một câu hỏi mà công trình gốc chủ yếu kiểm chứng trên dữ liệu phim ảnh (MovieLens) và mạng xã hội hình ảnh (Pinterest). Kết quả (không

vượt) nhất quán với các nghiên cứu đối chứng gần đây [4], [5].

- Xác định rõ vị trí của NeuMF trong phân loại Early Fusion/Late Fusion (mục 2.3.4): NeuMF là hợp nhất nhánh MF và nhánh DNN ở mức biểu diễn, và trên dữ liệu này không vượt có ý nghĩa thống kê so với từng nhánh đứng riêng; Late Fusion thuần MF + DNN chưa được thực hiện, còn phép trộn điểm MF với NeuMF cho tín hiệu tích cực trên tập xác thực nhưng chưa được đánh giá trên tập kiểm thử.
- Xây dựng một quy trình đánh giá chống thiên lệch có thể tái sử dụng – chia theo thời gian không rò rỉ tương lai, cùng ngân sách tính chính, khoá tập test có nhật ký truy cập, kiểm định cặp có hiệu chỉnh đa so sánh – áp dụng được cho các nghiên cứu hệ gợi ý khác.

1.4.2 Ý nghĩa thực tiễn

- Xây dựng một quy trình tiền xử lý và huấn luyện tách biệt phần đọc dữ liệu (adapter) khỏi logic xử lý cốt lõi, có thể tái sử dụng cho các bộ dữ liệu giao dịch thương mại điện tử khác bằng cách bổ sung một adapter tương ứng.
- Đề xuất cách lấy mẫu theo khách hàng, đọc tệp theo lô (khoảng 0,5 GB RAM cho tệp 3,5 GB) và tái lập được (mục 3.2.2), giúp thực nghiệm trên dữ liệu giao dịch lớn khả thi trên phần cứng phổ thông mà vẫn giữ trọn lịch sử thời gian của từng khách.
- Cung cấp hệ thống demo suy diễn (FastAPI) với độ trễ đo thực tế, cho phép so sánh trực quan các mô hình trên từng khách hàng, và kết luận thực tiễn rằng với dữ liệu giao dịch thưa, một mô hình MF đơn giản được tinh chỉnh tốt là lựa chọn hợp lý hơn NeuMF về cả độ chính xác lẫn chi phí.

1.5 Bố cục của báo cáo dự án

Báo cáo dự án được trình bày trong 5 chương chính:

- **Chương 1 – Tổng quan về đề tài:** Giới thiệu bối cảnh, tính cấp thiết, mục tiêu, phạm vi, phương pháp nghiên cứu và ý nghĩa của đề tài.
- **Chương 2 – Cơ sở lý thuyết và các công trình liên quan:** Trình bày nền tảng lý thuyết về hệ thống gợi ý, Matrix Factorization, GMF, MLP, NeuMF, các chỉ số đánh giá và tổng quan các nghiên cứu tiền nhiệm.
- **Chương 3 – Phương pháp nghiên cứu và thiết kế mô hình NeuMF:** Mô tả quy trình xử lý dữ liệu H&M, kiến trúc chi tiết mô hình NeuMF, kỹ thuật

Negative Sampling, chiến lược huấn luyện, quy trình tinh chỉnh và đánh giá không thiên lệch, và thiết kế hệ thống giao diện thực nghiệm (demo).

- **Chương 4 – Thực nghiệm và đánh giá kết quả:** Trình bày kết quả tinh chỉnh, kết quả trên tập kiểm thử, kiểm định thống kê, phân tích Ablation Study, đánh giá phân tầng, đối chiếu Sampled-99 và độ trễ suy diễn.
- **Chương 5 – Kết luận và hướng phát triển:** Tổng kết kết quả đạt được, chỉ ra các hạn chế và đề xuất hướng mở rộng nghiên cứu.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

2.1 Tổng quan về hệ thống gợi ý (Recommendation System)

2.1.1 Vì sao đề tài chọn nhánh *Lọc cộng tác* thay vì *Lọc nội dung*

Ba hướng tiếp cận chính của một hệ thống gợi ý – Lọc dựa trên nội dung (Content-Based, dựa trên đặc tính sản phẩm và hồ sơ sở thích quá khứ của User [6]), Lọc cộng tác (Collaborative Filtering – CF, dựa trên lịch sử tương tác chung giữa nhiều User/Item [1], [16]), và Lọc lai (Hybrid, kết hợp nhiều kỹ thuật gợi ý – thường gặp nhất là kết hợp nội dung với cộng tác [17], [18], [19]) – không cạnh tranh ngang hàng trong phạm vi đề tài này, vì lựa chọn thực chất bị quyết định bởi chính *những gì dữ liệu có*. Bộ dữ liệu H&M (mục 3.2.1) có kèm thông tin mô tả và hình ảnh sản phẩm, nhưng đề tài chủ động chỉ sử dụng mã khách hàng, mã sản phẩm và ngày mua trong tệp giao dịch để đo đúng năng lực của Lọc cộng tác thuần túy dựa trên ID – việc khai thác nội dung sản phẩm theo hướng Content-Based hay Hybrid được để lại cho hướng phát triển (Chương 5). Nhánh Collaborative Filtering – vốn chỉ cần ma trận tương tác User–Item mà không đòi hỏi đặc trưng mô tả đối tượng [20] – vì vậy là trọng tâm, và toàn bộ phần lý thuyết còn lại của chương này tập trung vào nhánh này.

2.1.2 *Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based)*

Xét theo cách khai thác dữ liệu tương tác, các phương pháp Lọc cộng tác được chia thành hai nhánh chính, đặt nền móng lý thuyết cho toàn bộ hướng tiếp cận Model-based mà đề tài lựa chọn.

Lọc cộng tác dựa trên bộ nhớ (Memory-based CF) tính toán trực tiếp độ tương đồng giữa các User hoặc Item từ ma trận tương tác thô, không qua bước học tham số trung gian, theo nguyên lý khởi nguồn của hệ thống GroupLens [21]. Với **Item-based CF** [16] – kỹ thuật được Amazon triển khai thành công ở quy mô công nghiệp [7] – độ tương đồng cosine giữa hai sản phẩm i, j được tính theo vector cột tương tác của chúng:

$$\text{sim}(i, j) = \cos(\vec{i}, \vec{j}) = \frac{\vec{i} \cdot \vec{j}}{\|\vec{i}\| \|\vec{j}\|} \quad (2.1)$$

Điểm dự đoán cho cặp (u, i) được ước lượng bằng tổng có trọng số các đánh giá của User u trên tập k láng giềng gần nhất $\mathcal{N}_k(i)$:

$$\hat{y}_{ui} = \frac{\sum_{j \in \mathcal{N}_k(i)} \text{sim}(i, j) \cdot y_{uj}}{\sum_{j \in \mathcal{N}_k(i)} |\text{sim}(i, j)|} \quad (2.2)$$

Phương pháp này (ItemKNN) không được đưa vào thực nghiệm của đề tài vì ma trận tương đồng dày vượt giới hạn bộ nhớ của cài đặt (mục 4.2). Ưu điểm là đơn giản, dễ diễn giải và không cần huấn luyện lại toàn bộ khi có tương tác mới; tuy nhiên độ phức tạp tính toán độ tương đồng theo cặp Item tăng bậc hai theo số lượng sản phẩm ($O(N^2)$), đồng thời chất lượng dự đoán suy giảm mạnh khi ma trận tương tác thưa.

Lọc cộng tác dựa trên mô hình (Model-based CF) không tính tương đồng trực tiếp mà học một hàm tham số hóa (Nhân tử hóa ma trận, mạng nơ-ron) để nén thông tin tương tác thành các vector biểu diễn ẩn có số chiều thấp, cho phép tổng quát hóa tốt hơn trên dữ liệu thưa và mở rộng quy mô tuyến tính theo số lượng tương tác thay vì bậc hai theo số Item [1], [20]. Toàn bộ các mô hình MF, GMF, MLP và NeuMF trình bày từ mục 2.2 trở đi thuộc nhánh Model-based, là hướng tiếp cận chính của đề tài.

2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback)

Về nguyên tắc, phản hồi của User có thể là phản hồi hiện (Explicit) – điểm số đánh giá trực tiếp như rating 1–5 sao – hoặc phản hồi ẩn (Implicit) – suy ra gián tiếp từ hành vi như lịch sử mua hàng, lượt click [2], [22]. Điểm cần nói rõ ở đây không phải là định nghĩa chung của hai khái niệm này, mà là một ràng buộc thực tế: tệp giao dịch H&M không có bất kỳ cột đánh giá (rating) nào – chỉ có bản ghi giao dịch đã xảy ra. Điều này loại bỏ hoàn toàn khả năng dùng Explicit Feedback, và buộc toàn bộ đề tài phải xây dựng tín hiệu tương tác dưới dạng nhị phân từ chính sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu tồn tại giao dịch giữa User } u \text{ và Item } i \text{ trong dữ liệu} \\ 0, & \text{ngược lại} \end{cases} \quad (2.3)$$

Hệ quả trực tiếp của cách xây dựng nhãn này – $y_{ui} = 1$ chỉ xác nhận *đã mua*, không xác nhận *hài lòng*, và $y_{ui} = 0$ có thể là “chưa từng biết đến sản phẩm” chứ không hẳn “không thích” [2] – là lý do trực tiếp khiến kỹ thuật lấy mẫu tiêu cực (Negative Sampling, mục 3.4.1) phải được thiết kế cẩn thận thay vì coi mọi cặp chưa tương tác là nhãn âm chắc chắn đúng.

2.1.4 Độ thưa dữ liệu và Cold-Start: hai giới hạn định hình phạm vi đề tài

Hai thách thức kinh điển của Collaborative Filtering không chỉ là lý thuyết trừu tượng trong phạm vi đề tài này – chúng trực tiếp định hình các quyết định về phạm vi thực nghiệm ở mục 1.2.2:

- **Độ thưa dữ liệu (Data Sparsity):** Số cặp User–Item thực sự có tương tác chỉ chiếm một phần rất nhỏ trong toàn bộ ma trận $M \times N$ [1]. Số liệu đo được cụ thể trên dữ liệu của đề tài (Bảng 3.2, Bảng 3.1) minh họa rõ mức độ thưa này: ngay cả sau khi lọc k -core, mật độ chỉ đạt 0,28% trên mẫu hm500k dùng để thực nghiệm ($k = 10$), và chỉ 0,03% nếu tính trên toàn bộ 889.062 người dùng ở quy mô đầy đủ ($k = 5$).
- **Vấn đề khởi đầu lạnh (Cold-Start):** Xảy ra khi một User hoặc Item hoàn toàn mới chưa có lịch sử tương tác nào, khiến mô hình không có dữ liệu để học vector biểu diễn cho thực thể đó. Đây chính là lý do kỹ thuật (không phải lựa chọn tùy ý) khiến bước lọc k -core (mục 3.2.3) là bắt buộc trước khi huấn luyện: mọi User/Item còn lại sau lọc đảm bảo có ít nhất k tương tác ($k = 10$ trong thực nghiệm), tức đã “ra khỏi” vùng Cold-Start theo định nghĩa trên; ngược lại, nhóm User/Item bị loại bởi k -core chính là nhóm Cold-Start mà đề tài xác định rõ là nằm ngoài phạm vi đánh giá định lượng (mục 1.2.2, mục 4.5).

2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận

2.2.1 Mô hình Nhân tử hóa ma trận (Matrix Factorization – MF)

Nhân tử hóa ma trận (MF) chiếu cả User và Item vào một không gian đặc trưng ẩn chung có số chiều $d \ll \min(M, N)$ [1]. Mỗi User u được biểu diễn bởi vector $p_u \in \mathbb{R}^d$ và mỗi Item i bởi vector $q_i \in \mathbb{R}^d$. Mức độ tương tác dự đoán $\hat{y}_{ui}$ được tính bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^d p_{uf} q_{if} \quad (2.4)$$

2.2.2 Hạn chế của tích vô hướng trong mô hình hóa tương tác

Tích vô hướng kết hợp các chiều đặc trưng ẩn độc lập theo dạng tuyến tính. Phép toán này không thể học được các tương tác phức tạp và phi tuyến giữa các chiều đặc trưng của User và Item, đồng thời không đủ linh hoạt để mô hình hóa chính xác

sự tương đồng không gian khi vị trí tương quan của các User thay đổi [2].

2.2.3 Tổng quát hóa MF với đặc trưng phụ trợ: Factorization Machines (FM)

Máy Nhân tử hóa (Factorization Machines – FM) [23] mở rộng MF từ bài toán chỉ có hai đặc trưng định danh (User ID, Item ID) sang bài toán tổng quát với vector đặc trưng bất kỳ $x \in \mathbb{R}^n$ (có thể bao gồm ID, danh mục sản phẩm, thời gian...), mô hình hóa mọi tương tác cặp đôi giữa các đặc trưng thông qua tích vô hướng của các vector nhân tử ẩn $v_i \in \mathbb{R}^d$:

$$\hat{y}(x) = w_0 + \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n \langle v_i, v_j \rangle x_i x_j \quad (2.5)$$

Khi x chỉ gồm hai đặc trưng one-hot (User, Item), FM suy biến chính xác về mô hình MF ở Công thức (2.4), cho thấy MF là một trường hợp riêng của FM. Đây là cơ sở lý thuyết cho các kiến trúc lai giữa thành phần tuyến tính bậc hai và mạng nơ-ron sâu như Wide & Deep [18] và DeepFM [19], được tổng hợp ở mục 2.4.

2.2.4 Tối ưu hóa xếp hạng theo cặp: Bayesian Personalized Ranking (BPR)

Khác với cách tiếp cận Pointwise (dự đoán độc lập từng điểm $\hat{y}_{ui}$ rồi so khớp với nhãn nhị phân như MF/GMF/MLP), Bayesian Personalized Ranking (BPR) [22] tối ưu hóa trực tiếp *thứ hạng tương đối* theo cặp (Pairwise Ranking), xuất phát từ giả định người dùng luôn ưa thích sản phẩm đã tương tác i hơn sản phẩm chưa tương tác j . Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR cực đại hóa xác suất hậu nghiệm dưới dạng:

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j) \in \mathcal{D}_S} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) + \lambda_{\Theta} \|\Theta\|^2 \quad (2.6)$$

trong đó $\hat{y}_{ui}, \hat{y}_{uj}$ được tính theo Công thức (2.4) khi kết hợp với MF (tạo thành baseline BPR-MF dùng trong Chương 4), và $\mathcal{D}_S$ là tập các bộ ba lấy mẫu. So với hàm tổn thất Binary Cross-Entropy theo hướng Pointwise được NeuMF sử dụng (Công thức (2.15)), mục tiêu Pairwise của BPR bám sát hơn với bản chất bài toán xếp hạng Top-K nhưng không tận dụng được các tầng phi tuyến sâu như kiến trúc NCF.

2.3 Kiến trúc Mạng khuyến nghị thần kinh (Neural Collaborative Filtering – NCF)

2.3.1 Generalized Matrix Factorization (GMF)

Generalized Matrix Factorization (GMF) là sự mở rộng của MF dưới dạng biểu diễn mạng nơ-ron [2], thực hiện phép nhân Element-wise (Hadamard product $\odot$) giữa vector Embedding của User p_u^G và Item q_i^G :

$$\phi^{GMF} = p_u^G \odot q_i^G \quad (2.7)$$

$$\hat{y}_{ui}^{GMF} = \sigma(h^T \phi^{GMF}) = \sigma(h^T (p_u^G \odot q_i^G)) \quad (2.8)$$

trong đó $\odot$ là phép nhân từng phần tử, h là vector trọng số lớp đầu ra, và $\sigma(x) = \frac{1}{1+e^{-x}}$ là hàm kích hoạt Sigmoid.

2.3.2 Multi-Layer Perceptron (MLP)

Nhánh Multi-Layer Perceptron (MLP) nối vector Embedding p_u^M và q_i^M (Concatenation) làm đầu vào cho chuỗi các lớp mạng liên tiếp [2]:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \quad (2.9)$$

$$\phi_L^{MLP} = a_L (W_L^T \phi_{L-1}^{MLP} + b_L) \quad (2.10)$$

trong đó W_L, b_L, a_L lần lượt là trọng số, độ lệch (bias) và hàm kích hoạt phi tuyến (như ReLU) tại lớp thứ L . Cấu trúc này giúp mô hình học các tương tác phi tuyến tính phức tạp giữa đặc trưng của User và Item.

2.3.3 Kiến trúc mô hình lai NeuMF


Mô hình lai NeuMF kết hợp song song hai luồng biểu diễn tuyến tính (GMF) và phi tuyến (MLP) trước lớp dự đoán cuối cùng [2]:

$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \quad (2.11)$$

$$\hat{y}_{ui} = \sigma \left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \right) \quad (2.12)$$

Chữ “lai” trong tên đề tài chỉ việc kết hợp hai cách mô hình hóa tương tác – nhân tử hóa ma trận (tuyến tính) và mạng nơ-ron sâu (phi tuyến) – trong cùng một mô hình,

đúng như NeuMF được He và cộng sự [2] xây dựng bằng cách hợp nhất GMF với MLP. Đây là nghĩa hẹp hơn “hệ gợi ý lai” của Burke [17], vốn thường kết hợp các kỹ thuật dựa trên những nguồn tri thức khác nhau (như lọc cộng tác với lọc nội dung); đề tài không lai với Lọc dựa trên nội dung. Theo phân loại cách hợp nhất ở mục 2.3.4, NeuMF là một mô hình Early Fusion ở mức biểu diễn.



Hình 2.1: Sơ đồ kiến trúc chi tiết mô hình lai Neural Matrix Factorization (NeuMF)

2.3.4 Chiến lược hợp nhất: *Early Fusion* và *Late Fusion*

Khi một hệ gợi ý kết hợp nhiều nguồn thông tin hoặc nhiều góc nhìn (view) về người dùng và sản phẩm, có hai cách hợp nhất cơ bản, phân biệt theo *mức* diễn ra phép hợp nhất [9], [24], [25]:

- **Early Fusion (hợp nhất ở mức đặc trưng/biểu diễn):** các vector đặc trưng $v_1, \dots, v_m$ của từng view được nối thành một biểu diễn chung, rồi *một* mô hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h([v_1; v_2; \dots; v_m]) \quad (2.13)$$

- **Late Fusion (hợp nhất ở mức quyết định/điểm dự đoán):** mỗi view được xử lý bởi một mô hình riêng h_j cho ra dự đoán độc lập, rồi các dự đoán được kết hợp bằng một cơ chế F – lấy trung bình, bỏ phiếu, trọng số cố định hoặc

một mô hình học:

$$p = F(h_1(v_1), h_2(v_2), \dots, h_m(v_m)) \quad (2.14)$$

Khi F là tổng có trọng số, đây chính là kiểu lai *weighted* trong phân loại hệ gợi ý lai của Burke [17].

Ngoài hai cách trên còn có *hybrid fusion*, kết hợp cả mức đặc trưng lẫn mức quyết định [24]. Early Fusion học được tương tác giữa các view nhưng đòi hỏi một mô hình phù hợp với mọi view; Late Fusion linh hoạt hơn nhưng không nắm bắt được tương tác ở mức tín hiệu giữa các view, vì chỉ làm việc trên kết quả dự đoán [9].

Vị trí của các mô hình trong đề tài. Hai view ở đây là hai cách mô hình hóa tương tác trên cùng ma trận tương tác (Utility Matrix): view tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và view phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi đưa qua một lớp dự đoán chung (công thức (2.11)–(2.12)), nên là một mô hình **Early Fusion ở mức biểu diễn**, được huấn luyện chung từ đầu đến cuối. Late Fusion tương ứng là trộn điểm của các mô hình MF và DNN được huấn luyện *riêng*, chẳng hạn $\hat{y}_{ui} = w \tilde{y}_{ui}^{MF} + (1 - w) \tilde{y}_{ui}^{DNN}$ với điểm đã chuẩn hóa; để so sánh công bằng với NeuMF, hai thành phần nên chính là GMF và MLP. Phép trộn điểm duy nhất đề tài đã thử – iALS với NeuMF-Scratch, chỉ trên tập xác thực (mục 3.6) – trộn một mô hình MF với chính mô hình lai NeuMF, nên *không* phải Late Fusion thuần MF + DNN; Late Fusion GMF + MLP chưa được thực hiện. Riêng nhánh MLP khi đứng một mình chỉ nối Embedding User và Item ở đầu vào: đó là mô hình DNN thuần, không phải phép hợp nhất MF với DNN (mục 3.3.4).

2.3.5 Lấy mẫu tiêu cực (Negative Sampling) và hàm tổn thất Binary Cross-Entropy

Do dữ liệu implicit feedback chỉ cung cấp các tương tác tích cực ($y_{ui} = 1$), kỹ thuật lấy mẫu tiêu cực (Negative Sampling) chọn ngẫu nhiên các Item mà User chưa từng tương tác để gán nhãn tiêu cực ($y_{ui} = 0$), theo giao thức chuẩn của He và cộng sự [2].

Hàm tổn thất Binary Cross-Entropy (BCE) được áp dụng để tối ưu hóa toàn bộ tham số mô hình:

$$\mathcal{L}_{BCE} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] \quad (2.15)$$

trong đó $\mathcal{Y}$ là tập tương tác tích cực và $\mathcal{Y}^-$ là tập tương tác tiêu cực được lấy mẫu.

2.4 Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu

Kiến trúc NCF/NeuMF [2] công bố năm 2017 mở ra làn sóng thay thế tích vô hướng bằng hàm học được, nhưng lĩnh vực hệ thống gợi ý sau đó tiếp tục phát triển theo nhiều hướng song song. Mục này hệ thống hóa các hướng nghiên cứu chính giai đoạn 2016–2024, làm cơ sở xác định vị trí đóng góp của đề tài (mục 2.7) và định hướng phát triển tương lai (Chương 5).

2.4.1 Mô hình học sâu dựa trên đặc trưng tương tác (*Feature-rich Deep CTR Models*)

Nhóm mô hình dự đoán tỷ lệ nhấp chuột (Click-Through Rate – CTR) mở rộng bài toán gợi ý sang không gian đặc trưng phong phú hơn cặp (User ID, Item ID). Wide & Deep Learning [18] kết hợp song song một nhánh tuyến tính rộng (Wide) để ghi nhớ (memorization) các tổ hợp đặc trưng tường minh và một nhánh MLP sâu (Deep) để khái quát hóa (generalization); DeepFM [19] thay thế nhánh Wide bằng Factorization Machines (mục 2.2.3) để loại bỏ nhu cầu kỹ nghệ đặc trưng thủ công. Deep Interest Network (DIN) [26] tiến xa hơn bằng cơ chế Attention, gán trọng số động cho từng sản phẩm trong lịch sử hành vi của User tùy theo mức độ liên quan với Item ứng viên đang được xếp hạng, thay vì biểu diễn toàn bộ lịch sử bằng một vector cố định như MLP truyền thống. Điểm chung của nhóm này là yêu cầu đặc trưng phụ trợ (danh mục, thuộc tính) phong phú hơn nhiều so với tín hiệu ID thuần túy mà NeuMF sử dụng.

2.4.2 Kiến trúc hai tháp (*Two-Tower*) cho truy hồi quy mô lớn

Trong các hệ thống công nghiệp có hàng triệu Item (ví dụ YouTube DNN [27]), việc xếp hạng đầy đủ mọi cặp (User, Item) bằng mạng hợp nhất sớm là bất khả thi về mặt tính toán. Kiến trúc hai tháp (Two-Tower) mã hóa User và Item thành hai vector độc lập qua hai mạng riêng biệt *không tương tác với nhau cho đến bước cuối*, cho phép tính trước (pre-compute) và lập chỉ mục vector Item bằng các cấu trúc tìm kiếm lân cận gần đúng (Approximate Nearest Neighbor) để truy hồi (retrieval) hàng nghìn ứng viên trong thời gian mili-giây, trước khi đưa qua một mô hình xếp hạng (ranking) tinh hơn ở tầng sau. Về mặt cấu trúc, nhánh MLP của NeuMF với hai bảng Embedding độc lập cho User/Item (mục 3.3.1) chia sẻ nguyên lý tương tự cấp độ biểu diễn, nhưng khác Two-Tower ở chỗ vẫn hợp nhất và học phi tuyến trên toàn bộ ma trận tương tác thay vì tối ưu cho truy hồi rời rạc quy mô lớn.

2.4.3 Gợi ý theo chuỗi hành vi (Sequential và Session-based Recommendation)

Một hạn chế cố hữu của NeuMF và các mô hình MF là coi lịch sử tương tác của User như một *tập hợp không thứ tự*, bỏ qua trình tự thời gian phát sinh hành vi. Hướng nghiên cứu Sequential/Session-based Recommendation khắc phục điều này bằng cách mô hình hóa chuỗi $(i_1, i_2, \dots, i_t)$ để dự đoán sản phẩm tiếp theo i_{t+1} :

- **GRU4Rec** [28] là công trình tiên phong dùng mạng hồi quy có cổng (Gated Recurrent Unit) để mã hóa phiên duyệt web thành trạng thái ẩn, dự đoán phân phối xác suất trên toàn bộ danh mục cho lượt click tiếp theo.
- **SASRec** [29] thay thế cơ chế hồi quy bằng Self-Attention một chiều (causal), cho phép mô hình học trọng số phụ thuộc linh hoạt giữa các sản phẩm ở vị trí xa nhau trong chuỗi mà không bị giới hạn bởi *vanishing gradient* như RNN, đạt cân bằng tốt giữa mô hình Markov bậc thấp và RNN.
- **BERT4Rec** [30] áp dụng kiến trúc Transformer hai chiều (Bidirectional) theo phong cách BERT, huấn luyện bằng mục tiêu Cloze (che ngẫu nhiên một số vị trí trong chuỗi và dự đoán lại), giúp khai thác ngữ cảnh từ cả hai phía thay vì chỉ chiều quá khứ như SASRec.

Hướng tiếp cận này phù hợp với dữ liệu có tính phiên rõ rệt (streaming, xem video, duyệt web); trên dữ liệu H&M, mỗi giao dịch chỉ ghi ngày mua (không có giờ hay mã phiên) và tần suất giao dịch của mỗi User thưa, nên đây được ghi nhận là hướng mở rộng tương lai thay vì lựa chọn chính (Chương 5).

2.4.4 Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)

Ma trận tương tác User–Item có thể biểu diễn tự nhiên dưới dạng đồ thị hai phía (bipartite graph). Neural Graph Collaborative Filtering (NGCF) [31] khai thác cấu trúc này bằng cách lan truyền (propagate) tín hiệu Embedding qua nhiều bước lan truyền láng giềng (giống mạng nơ-ron đồ thị – Graph Convolutional Network), giúp vector User/Item mã hóa được cả tín hiệu tương tác bậc cao (*high-order connectivity*) chứ không chỉ tương tác trực tiếp như MF. LightGCN [32] đơn giản hóa NGCF bằng cách loại bỏ các phép biến đổi tuyến tính và hàm kích hoạt phi tuyến – vốn được chứng minh là dư thừa và gây khó huấn luyện trong bài toán CF thuần túy – chỉ giữ lại phép

lan truyền tuyến tính:

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}} e_i^{(k)}, \quad e_u^* = \sum_{k=0}^K \alpha_k e_u^{(k)} \quad (2.16)$$

trong đó $\mathcal{N}_u$ là tập Item lân cận của User u trong đồ thị và e_u^* là biểu diễn cuối cùng, tổng hợp có trọng số qua K tầng lan truyền. Đây là hướng phát triển được đề tài xác định là ưu tiên hàng đầu (mục 5.3), do dữ liệu thời trang H&M vốn có độ thưa cực cao – bối cảnh mà tín hiệu bậc cao qua đồ thị đã được chứng minh mang lại cải thiện đáng kể so với MF/NCF truyền thống.

2.4.5 Học tự giám sát, sinh biểu diễn xác suất và mô hình ngôn ngữ lớn

Ba hướng nghiên cứu gần đây (2018–2024) tiếp tục định hình lại bài toán gợi ý:

- **Biến phân tự mã hóa (VAE) cho CF:** Mult-VAE [33] mô hình hóa toàn bộ vector tương tác của một User như một phân phối đa thức (multinomial) được sinh ra từ biến ẩn Gauss, tối ưu hóa qua cận dưới biến phân (ELBO) thay vì tối ưu điểm-đến-điểm như NeuMF.
- **Học tự giám sát (Self-Supervised Learning):** Self-supervised Graph Learning (SGL) [34] bổ sung một tác vụ phụ trợ đối chiếu (contrastive) giữa các góc nhìn augmentation khác nhau của cùng một đồ thị tương tác, giúp cải thiện tính vững (robustness) của biểu diễn trước dữ liệu thưa và nhiễu – một hướng đang được tích hợp rộng rãi vào các mô hình Graph-based CF hiện đại.
- **Mô hình ngôn ngữ lớn và gợi ý sinh (LLM-based / Generative Recommendation):** Làn sóng nghiên cứu 2023–2024 định hình lại bài toán gợi ý theo hướng sinh chuỗi: TIGER [35] mã hóa mỗi Item thành một chuỗi token ngữ nghĩa (Semantic ID) rồi huấn luyện một mô hình sinh kiểu Transformer để sinh trực tiếp token định danh Item tiếp theo, thay vì chấm điểm và xếp hạng toàn bộ danh mục; khảo sát của Wu và cộng sự [36] tổng hợp toàn diện việc khai thác tri thức và khả năng suy luận ngôn ngữ tự nhiên của LLM (GPT, LLaMA...) cho các tác vụ gợi ý, từ tăng cường đặc trưng, diễn giải kết quả đến gợi ý hội thoại (Conversational Recommendation).
- **Mô hình khuếch tán (Diffusion Models) cho gợi ý:** Song song với hướng LLM, một hướng nghiên cứu sinh (generative) khác nổi lên gần đây (2024–

2025) là ứng dụng mô hình khuếch tán – vốn đã chứng minh hiệu quả trong sinh ảnh – vào bài toán gợi ý. Theo khảo sát của Wei và Fang [37], ý tưởng cốt lõi là học một quá trình khử nhiễu (denoising) dần từ một phân phối nhiễu ngẫu nhiên về phân phối tương tác thực của User, cho phép mô hình hóa được tính đa phương thức (multi-modal) trong sở thích người dùng – điều mà các mô hình Pointwise như GMF/MLP/NeuMF (vốn chỉ dự đoán một điểm số $\hat{y}_{ui}$ duy nhất cho mỗi cặp) không biểu diễn được. Đây là hướng còn rất mới, chưa được kiểm chứng rộng rãi trên dữ liệu giao dịch thương mại điện tử dạng bảng (tabular).

Cả hai hướng LLM-based và Diffusion-based đều là những hướng nghiên cứu tiên tiến nhất tính đến thời điểm thực hiện đề tài, nhưng đòi hỏi tài nguyên tính toán (GPU) và việc khai thác dữ liệu văn bản/hình ảnh sản phẩm vượt ngoài phạm vi của một đề tài tập trung vào Lọc cộng tác thuần túy dựa trên ID.

Khảo sát tổng quan của Zhang và cộng sự [38] xác nhận NCF/NeuMF thuộc nhóm *Neural Collaborative Filtering* nền tảng, là tiền đề trực tiếp cho phần lớn hướng phát triển kể trên; khảo sát cập nhật hơn của Li và cộng sự [39] (tháng 12/2024) hệ thống hóa lại toàn bộ các kiến trúc mạng nơ-ron sâu (MLP, CNN, RNN, GNN, Autoencoder, GAN) đã và đang được tích hợp vào Collaborative Filtering, xác nhận rằng nhánh MLP/GMF theo tinh thần NCF vẫn là một trong các thành phần kiến trúc nền tảng được sử dụng phổ biến nhất trong các hệ thống lai hiện đại, dù không còn là hướng tiên phong. Điều này củng cố lựa chọn của đề tài: NeuMF vẫn là một kiến trúc *có cơ sở lý thuyết vững chắc và được công nhận rộng rãi* để làm nền tảng nghiên cứu, dù không phải là kiến trúc mới nhất.

Trong phạm vi đề tài, NeuMF được lựa chọn làm kiến trúc trọng tâm (thay vì các hướng mới hơn như Graph-based, Sequential hay LLM/Diffusion-based) vì ba lý do cụ thể: (i) *Đặc điểm dữ liệu*: tập giao dịch H&M chỉ ghi ngày mua, không có mốc thời gian phiên (session) rõ ràng để áp dụng trực tiếp mô hình tuần tự (mục 2.4.3); dù bộ dữ liệu có kèm mô tả văn bản và hình ảnh sản phẩm, đề tài chủ động chỉ dùng tín hiệu tương tác dạng ID để đo đúng năng lực của Lọc cộng tác thuần túy, và để việc khai thác đặc trưng đa phương thức cho hướng phát triển; (ii) *Mục tiêu khoa học của đề tài*: kiến trúc hai nhánh GMF/MLP tách biệt cho phép thực hiện Ablation Study kiểm soát chặt chẽ từng thành phần (mục 4.4.3) – điều khó thực hiện tương đương với các kiến trúc End-to-End phức tạp hơn như Graph Neural Network nhiều tầng hay mô hình sinh dựa trên Transformer; (iii) *Ràng buộc thực tế về hạ tầng tính toán*: toàn

bộ thực nghiệm được chạy trên CPU phổ thông (mục 4.1), trong khi các hướng LLM-based/Diffusion-based đòi hỏi GPU và tài nguyên tính toán vượt xa phạm vi một đề tài học thuật ở quy mô này. Ba lý do này nhất quán với khoảng trống nghiên cứu được xác định ở mục 2.7.

2.5 Các chỉ số đánh giá hệ thống gợi ý Top-K

Với mỗi người dùng kiểm thử u , mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\text{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm đúng của u (với giao thức Leave-One-Out $|T_u| = 1$; với giao thức chia theo mốc thời gian chung, một người dùng có thể có nhiều sản phẩm đúng) và $\text{hits}_u = |T_u \cap \text{Rec}_K(u)|$. Mọi chỉ số được tính cho từng người dùng rồi lấy trung bình trên $\mathcal{U}_{test}$.

- **Hit Ratio at K (HR@K):** người dùng được tính là “trúng” nếu có ít nhất một sản phẩm đúng trong top- K [2]:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}(\text{hits}_u \geq 1) \quad (2.17)$$

- **Precision@K và Recall@K:** tỉ lệ gợi ý đúng trong K sản phẩm, và tỉ lệ sản phẩm đúng tìm lại được:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \quad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \quad (2.18)$$

Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K = HR@K/ K – lý do các chỉ số này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm đúng.

- **Normalized Discounted Cumulative Gain at K (NDCG@K):** thưởng nhiều hơn khi sản phẩm đúng nằm ở vị trí cao, theo định nghĩa của Järvelin và Kekäläinen [8] với mức liên quan nhị phân:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^K \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|, K)} \frac{1}{\log_2(j+1)} \end{aligned} \quad (2.19)$$

IDCG là giá trị DCG khi mọi sản phẩm đúng xếp ở đầu danh sách, nên $\text{NDCG@K} \in [0, 1]$. Với $|T_u| = 1$ và sản phẩm đúng ở hạng r : NDCG@K

$$= 1/\log_2(r+1) \text{ nếu } r \leq K, \text{ ngược lại bằng } 0.$$

Full Ranking và Sampled Ranking. Giao thức của bài NCF gốc xếp sản phẩm đúng giữa 100 ứng viên (1 đúng + 99 âm lấy mẫu). Krichene và Rendle [12] chứng minh chỉ số trên tập ứng viên lấy mẫu không nhất quán với chỉ số trên toàn bộ catalog – có thể đảo ngược kết luận “A tốt hơn B” – và khuyến nghị tránh lấy mẫu. Đề tài vì vậy dùng **Full Ranking** (xếp hạng toàn bộ catalog trừ sản phẩm đã mua) làm giao thức chính, Sampled-99 chỉ để đối chiếu.

2.5.1 Các chỉ số đánh giá ngoài độ chính xác (Beyond-Accuracy Metrics)

Chỉ tối ưu HR@K/NDCG@K có thể khiến mô hình thiên lệch về việc luôn gợi ý các sản phẩm phổ biến nhất (*popularity bias*), vốn dễ trúng nhưng ít giá trị cá nhân hóa. Để đánh giá toàn diện hơn, đề tài bổ sung nhóm chỉ số ngoài độ chính xác, làm cơ sở lý thuyết cho phân tích Popular/Long-tail ở mục 4.4.4:

- **Catalog Coverage:** Tỷ lệ số sản phẩm khác nhau từng xuất hiện trong danh sách gợi ý của toàn bộ User trên tổng số sản phẩm trong danh mục:

$$\text{Coverage} = \frac{|\bigcup_{u \in \mathcal{U}} \text{Rec}_K(u)|}{N} \quad (2.20)$$

Coverage thấp cho thấy mô hình chỉ khai thác một phần nhỏ danh mục sản phẩm dù độ chính xác có thể vẫn cao.

- **Novelty (Self-Information):** Đo mức độ mới lạ trung bình của các sản phẩm được gợi ý, dựa trên thông tin tự thân (self-information) theo định nghĩa của Vargas và Castells [40]:

$$\text{Novelty} = \frac{1}{|\mathcal{U}| K} \sum_{u \in \mathcal{U}} \sum_{i \in \text{Rec}_K(u)} -\log_2 P(i) \quad (2.21)$$

trong đó $P(i)$ là tần suất xuất hiện của Item i trong tập huấn luyện. Sản phẩm càng hiếm gặp thì $-\log_2 P(i)$ càng lớn, do đó điểm Novelty cao đồng nghĩa mô hình gợi ý đa dạng, ít thiên về sản phẩm đại trà.

- **Head Rate (Tỷ lệ thiên lệch phổ biến):** Tỷ lệ trung bình các sản phẩm được gợi ý thuộc nhóm Head (top phổ biến nhất trong tập huấn luyện) trên tổng số gợi ý; giá trị càng gần 1 thể hiện mô hình càng thiên về chiến lược Most Popular thay vì cá nhân hóa thực sự.

Bộ ba chỉ số này được trình bày song song với HR@K/NDCG@K trong Chương 4, nhằm trả lời câu hỏi mô hình NeuMF có thực sự học được sở thích cá nhân hóa hay

chỉ khai thác hiệu ứng phổ biến của dữ liệu.

2.6 Tổng quan các công trình nghiên cứu liên quan

Bảng 2.1 tổng hợp các công trình nền tảng liên quan trực tiếp đến hướng tiếp cận của dự án.

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Rendle et al. (2009) [22]	BPR (Bayesian Personalized Ranking)	MovieLens, Netflix	Khung tối ưu dựa trên so sánh cặp cho implicit feedback. <i>Hạn chế:</i> mô hình tuyến tính.
He et al. (2017) [2]	NCF / NeuMF	MovieLens, Pinterest	Kết hợp GMF và MLP, chứng minh ưu thế của học sâu. <i>Hạn chế:</i> chưa tích hợp đặc trưng nội dung.
Cheng et al. (2016) [18]	Wide & Deep Learning	Google Play Store	Kết hợp ghi nhớ (Wide) và khái quát hóa (Deep). <i>Hạn chế:</i> cần kỹ nghệ đặc trưng thủ công.
Guo et al. (2017) [19]	DeepFM	Criteo, Dữ liệu doanh nghiệp	Thay Wide bằng Factorization Machine. <i>Hạn chế:</i> chi phí tính toán tăng khi số đặc trưng lớn.
Kang & McAuley (2018) [29]	SASRec (Self-Attention tuần tự)	Amazon, Steam, MovieLens	Mô hình hóa chuỗi hành vi bằng Self-Attention. <i>Hạn chế:</i> cần mốc thời gian/phiên rõ ràng, chưa khai thác được với dữ liệu chỉ ghi ngày mua như H&M.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Wang et al. (2019); He et al. (2020) [31], [32]	NGCF / LightGCN (Graph-based CF)	Gowalla, Amazon-Book, Yelp2018	Lan truyền tín hiệu tương tác bậc cao qua đồ thị hai phía. <i>Hạn chế</i> : chi phí tính toán lan truyền tăng theo số tầng, chi phí tăng nhanh theo quy mô đồ thị khi catalog lớn.
Wu et al. (2024) [36]	Khảo sát LLM cho Recommendation	Tổng hợp đa miền	Hệ thống hóa hướng khai thác LLM cho gợi ý (Generative, Conversational). <i>Hạn chế</i> : chi phí suy luận lớn, chưa phù hợp bài toán ID thuần túy quy mô vừa.
Li et al. (2024) [39]	Khảo sát DNN cho Collaborative Filtering	Tổng hợp đa miền (2020–2024)	Hệ thống hóa các kiến trúc MLP, CNN, RNN, GNN, Autoencoder, GAN đã tích hợp vào CF, xác nhận GMF/MLP vẫn là thành phần nền tảng phổ biến. <i>Hạn chế</i> : khảo sát tổng hợp, không đề xuất mô hình mới hay thực nghiệm riêng.
Wei & Fang (2025) [37]	Khảo sát Diffusion Models cho Recommendation	Tổng hợp đa miền	Hệ thống hóa hướng sinh (generative) dựa trên mô hình khuếch tán cho gợi ý. <i>Hạn chế</i> : còn rất mới, chưa kiểm chứng rộng rãi trên dữ liệu giao dịch dạng bảng.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Ferrari Dacrema et al. (2019) [5]	Tái lập 18 mô hình gợi ý học sâu	MovieLens, Pinterest, Netflix, ...	Phần lớn mô hình học sâu không vượt baseline đơn giản được tune tốt (ItemKNN, SLIM); mã NCF gốc chọn số epoch trên tập test. <i>Hạn chế</i> : chủ yếu dùng giao thức lấy mẫu của các bài gốc.
Rendle et al. (2020) [4]	MF tích vô hướng so với NeuMF	MovieLens 1M, Pinterest	MF được tune kỹ vượt NeuMF trên chính dữ liệu và giao thức của bài NCF; MLP khó học được tích vô hướng và không phù hợp truy hồi nhanh. <i>Hạn chế</i> : vẫn dùng giao thức Leave-One-Out lấy mẫu của bài gốc.
Dự án đề xuất (2026)	NeuMF (GMF + MLP, Scratch và Pretrained) so với baseline được tune cùng ngân sách	H&M Personalized Fashion Recommendations (mẫu hm500k)	Đánh giá NeuMF trên dữ liệu giao dịch thời trang cực thưa với chia theo thời gian không rò rỉ, Full Ranking, khoá tập test, 3 seed và kiểm định cặp có hiệu chỉnh Holm; Ablation Study, phân tầng head/tail và cold/warm, đối chiếu Sampled-99, đo độ trễ.

2.7 Khoảng trống nghiên cứu

Các nghiên cứu nền tảng về NCF/NeuMF [2] chủ yếu được đánh giá trên dữ liệu điện ảnh (MovieLens) hoặc mạng xã hội hình ảnh (Pinterest), với tín hiệu tương tác nhị phân đơn giản. Trong khi đó, các hướng nghiên cứu hiện đại hơn (mục 2.4) như Graph-based CF [31], [32], Sequential Recommendation [29], [30] hay LLM-based Recommendation [35], [36] đòi hỏi cấu trúc dữ liệu đặc thù (đồ thị tương tác đủ

dày, chuỗi phiên có mốc thời gian rõ ràng, hoặc văn bản/ngữ cảnh phong phú) hoặc tài nguyên tính toán vượt phạm vi của đề tài. Việc ứng dụng và đánh giá kiến trúc NeuMF – vẫn là một baseline Model-based CF vững chắc và có khả năng diễn giải cao – trên dữ liệu giao dịch thời trang thực tế, cực thưa (H&M Personalized Fashion Recommendations), đối chiếu với baseline Pairwise (BPR-MF, mục 2.2.4) được tinh chỉnh cùng ngân sách, theo một giao thức tránh được các lỗi mà Ferrari Dacrema và cộng sự [5] và Rendle và cộng sự [4] đã chỉ ra (chọn mô hình trên tập test, baseline tune sơ sài, chỉ số lấy mẫu), cùng việc phân tích bóc tách các thành phần mô hình và đánh giá đa chiều (accuracy lẫn beyond-accuracy, mục 2.5.1), chính là khoảng trống nghiên cứu mà dự án này tập trung giải quyết, đồng thời tạo nền tảng thực nghiệm vững chắc để mở rộng sang Graph-based CF trong tương lai (Chương 5).

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH NEUMF

3.1 Kiến trúc tổng thể của hệ thống nghiên cứu

Trước khi trình bày chi tiết từng thành phần, mục này mô tả kiến trúc tổng thể của toàn bộ hệ thống thực nghiệm – từ dữ liệu thô đến kết quả đánh giá cuối cùng – nhằm cung cấp một bức tranh toàn cảnh về luồng xử lý và mối liên hệ giữa các thành phần. Hệ thống được tổ chức thành sáu tầng xử lý tuần tự (Hình 3.1): Dữ liệu nguồn, Tiền xử lý, Phân chia dữ liệu & Lấy mẫu, Mô hình hóa, Huấn luyện & Tinh chỉnh và Đánh giá, cùng một nhánh Đối chứng (Baseline) vận hành song song.

Ba đặc điểm thiết kế xuyên suốt cần nhấn mạnh: (i) tầng tiền xử lý và tầng phân chia dữ liệu tách biệt khỏi tầng mô hình hóa, nên mọi mô hình – NeuMF lẫn baseline – dùng đúng một bộ dữ liệu, một tập ứng viên và một quy tắc loại sản phẩm đã mua, đảm bảo so sánh công bằng; (ii) mọi quyết định chọn mô hình và siêu tham số chỉ dựa trên tập xác thực, tập kiểm thử chỉ được dùng ở tầng 6, qua kịch bản có khoá và ghi nhật ký mọi lần truy cập (mục 3.6); (iii) baseline BPR-MF được tinh chỉnh với cùng ngân sách như NeuMF, vì các nghiên cứu đối chứng gần đây cho thấy lợi thế của mô hình học sâu thường biến mất khi baseline được tune đúng cách [4], [5].


3.2 Phân tích và tiền xử lý dữ liệu H&M Personalized Fashion Recommendations

Bộ dữ liệu thực nghiệm của dự án là H&M Personalized Fashion Recommendations [3], phản ánh hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn. Quy mô của bộ dữ liệu đặt ra thách thức về chi phí tính toán mà dự án phải giải quyết trước khi áp dụng quy trình xử lý chuẩn.

3.2.1 Đặc tả bộ dữ liệu và thách thức về quy mô

Tập giao dịch gốc (`transactions_train.csv`, 3,49 GB) chứa 31.788.324 dòng giao dịch mua hàng thời trang từ 20/09/2018 đến 22/09/2020, ghi nhận 1.362.281 khách hàng và 104.547 sản phẩm riêng biệt. Ba trường được dùng để xây dựng sự kiện tương tác:

- **customer_id**: Mã định danh khách hàng (User ID), dạng chuỗi mã băm 64



Hình 3.1: Kiến trúc tổng thể của hệ thống nghiên cứu, từ dữ liệu thô H&M đến đánh giá cuối trên tập test

ký tự.

- **article_id**: Mã định danh sản phẩm (Item ID), mã số 10 chữ số – phải đọc dưới dạng chuỗi và giữ số 0 ở đầu.
- **t_dat**: Ngày mua, dùng để sắp xếp tương tác theo thời gian (chỉ ở mức ngày, không có giờ).

Trường giá (price) và hai tệp thuộc tính `articles.csv`, `customers.csv` không được dùng làm đầu vào của bất kỳ mô hình nào: đề tài giới hạn ở lọc cộng tác thuần dựa trên ID (mục 1.2.2); hai tệp thuộc tính chỉ dùng để hiển thị tên sản phẩm trong hệ thống demo (mục 3.7). Ràng buộc này được kiểm chứng tự động: bộ kiểm thử của dự án khẳng định bộ đọc dữ liệu chỉ mở tệp giao dịch.

Đánh giá Full Ranking (mục 2.5) phải chấm điểm *mọi* sản phẩm cho mỗi người dùng kiểm thử, nên chi phí tỉ lệ với tích số người dùng và số sản phẩm. Bảng 3.1 cho thấy ở quy mô đầy đủ, ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm – tức hàng chục tỷ cặp cần chấm cho mỗi mô hình, vượt xa khả năng của phần cứng sẵn có (GPU 4 GB, RAM 16 GB).

Bảng 3.1: Độ nhảy k -core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ)

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu *hm500k* theo khách hàng

Để giữ Full Ranking khả thi mà vẫn bảo toàn tính thời gian của dữ liệu, dự án lấy một mẫu con *theo khách hàng* thay vì theo dòng. Lý do: lấy mẫu theo dòng (hoặc cắt n dòng đầu) sẽ cắt vụn lịch sử của từng khách và – vì tệp gốc sắp theo ngày – chỉ phủ vài ngày giao dịch, làm hỏng cả bước lọc k -core lẫn việc chia dữ liệu theo thời gian. Quy trình lấy mẫu gồm hai lượt đọc tệp theo lô (giữ bộ nhớ đỉnh khoảng 0,5 GB):

1. **Lượt 1 – chọn khách:** Băm `customer_id` bằng một khoá cố định vào 100.000 nhóm (hàm băm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua); đếm số giao dịch của từng nhóm; lấy lần lượt các nhóm theo chỉ số cho tới khi tổng số giao dịch vừa vượt 500.000. Kết quả: 1.597 nhóm (1,60% khách hàng).

2. **Lượt 2 – ghi mẫu:** Giữ *toàn bộ* giao dịch của các khách được chọn, trải đủ 20/09/2018 – 22/09/2020, giữ nguyên các cột như tệp gốc.

Mẫu thu được – gọi là **hm500k** – gồm 500.269 giao dịch của 21.599 khách hàng trên 59.483 sản phẩm. Vì dựa trên hàm băm với khoá cố định, chạy lại luôn cho đúng cùng một tệp (tái lập được), và toàn bộ quá trình mất khoảng 70 giây.

3.2.3 Xây dựng ma trận tương tác phản hồi ẩn

Một khách có thể mua cùng một sản phẩm nhiều lần; do đó bước đầu tiên là gộp các giao dịch lặp thành một cặp User–Item duy nhất (giữ lại ngày mua đầu tiên, ngày mua cuối cùng và số lần mua) *trước* khi lọc k -core. Thứ tự này quan trọng: nếu lọc k -core trực tiếp trên dòng giao dịch thô, bậc của một User/Item bị thổi phồng bởi các lượt mua lặp và tập sau lọc không phản ánh đúng số đối tác riêng biệt. Trên hm500k, 500.269 giao dịch gộp lại còn 429.964 cặp duy nhất.

Sau khi gộp, lọc k -core được áp dụng lặp đến khi hội tụ (loại một sản phẩm có thể khiến một người dùng rơi xuống dưới ngưỡng và ngược lại), để mỗi thực thể còn lại có ít nhất k đối tác riêng biệt. Toàn bộ ID được tái lập chỉ số về số nguyên liên tục:

$$u \in \{0, 1, \dots, M - 1\}, \quad i \in \{0, 1, \dots, N - 1\} \quad (3.1)$$

và ma trận tương tác nhị phân $Y \in \{0, 1\}^{M \times N}$ được tạo với $y_{ui} = 1$ nếu User u đã mua Item i . Phản hồi nhị phân là thiết lập duy nhất dùng cho kết quả; mọi thống kê phụ thuộc dữ liệu (độ phổ biến, nhóm head/tail, nhóm người dùng ít tương tác, tập mẫu âm) đều chỉ tính trên tập huấn luyện.

3.2.4 Lựa chọn ngưỡng lọc k -core

Bảng 3.2 khảo sát độ nhạy của hm500k theo ngưỡng k . Ngưỡng chuẩn trong tài liệu là $k = 5$, nhưng khi đó catalog còn 23.067 sản phẩm và đánh giá Full Ranking ước tính cần khoảng 10,7 GB RAM – vượt giới hạn của máy thực nghiệm (16 GB, đã tính hệ điều hành và dữ liệu huấn luyện). Dự án vì vậy chọn **$k = 10$** : 7.519 người dùng, 10.345 sản phẩm, 220.292 cặp tương tác, mật độ 0,283%; RAM đỉnh đo thực tế khi huấn luyện và đánh giá một seed là 4,1 GB. Cái giá của lựa chọn này là dữ liệu thiên về khách mua nhiều – được ghi nhận là một hạn chế (mục 5.2).

Bảng 3.2: Độ nhảy của mẫu hm500k theo ngưỡng lọc k -core (429.964 cặp trước khi lọc)

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	7.519	10.345	220.292	0,283
15	3.017	3.186	83.088	0,864

3.2.5 Phân chia dữ liệu theo thời gian

Giao thức chính – một mốc thời gian chung. Mỗi cặp (User, Item) được xếp theo ngày mua đầu tiên và chia bằng hai mốc cố định cho mọi người dùng:

$$\text{Train} < 01/07/2020 \leq \text{Validation} < 29/07/2020 \leq \text{Test (đến 22/09/2020)} \quad (3.2)$$

Tập xác thực phủ 4 tuần, tập kiểm thử phủ 8 tuần. Tập xác thực chỉ giữ người dùng và sản phẩm đã xuất hiện trong tập huấn luyện; tập kiểm thử chỉ giữ người dùng và sản phẩm đã xuất hiện trong tập huấn luyện $\cup$ xác thực (mô hình lọc cộng tác thuần ID không thể chấm điểm cho thực thể chưa từng thấy). Mỗi người dùng có thể có *nhiều* sản phẩm đúng, và sản phẩm người dùng đã mua trước đó không được tính là đích – mô hình dự đoán những món *mới* đối với người dùng. Cách chia này bảo đảm mô hình không bao giờ thấy tương tác xảy ra sau thời điểm cần dự đoán: khi tinh chỉnh, mô hình chỉ học từ dữ liệu trước 01/07/2020; khi chấm kiểm thử, chỉ học từ dữ liệu trước 29/07/2020 – đúng với tình huống triển khai thật [41].

Huấn luyện lại trước khi chấm kiểm thử. Tập xác thực chỉ dùng để chọn cấu hình và số epoch. Trước khi chấm tập kiểm thử, mỗi mô hình được huấn luyện lại từ đầu trên tập huấn luyện $\cup$ xác thực (mọi cặp trước 29/07/2020) với cấu hình tốt nhất, chạy đúng số epoch tốt nhất đã chọn trên tập xác thực; lúc này không còn tập xác thực để dừng sớm, và tập kiểm thử không được dùng để dừng. Most Popular và BPR-MF cũng được khớp trên tập huấn luyện $\cup$ xác thực. Nhờ vậy, khi chấm kiểm thử mô hình đã thấy toàn bộ quá khứ như lúc triển khai thật, thay vì bỏ trống 4 tuần sát kỳ dự đoán – một kiểm tra chỉ trên tập xác thực cho thấy bỏ trống 4 tuần như vậy làm NDCG@10 của Most Popular và BPR-MF giảm khoảng 17–19%, lớn hơn chênh lệch giữa các mô hình. Bước này được bổ sung *sau* lần chấm kiểm thử đầu tiên và được ghi nhận là lệch kế hoạch (mục 3.6).

Giao thức phụ – Leave-One-Out theo thời gian. Theo đúng NCF gốc [2]: với mỗi người dùng, sản phẩm mua cuối cùng làm tập kiểm thử, sản phẩm áp chót làm tập xác thực, phần còn lại làm tập huấn luyện. Giao thức này được giữ để đối chiếu với tài liệu, *không* dùng để chọn mô hình, vì nó rõ ràng tương lai: đo trên hm500k, tính trung bình theo người dùng, 11,2% tương tác trong tập huấn luyện (của toàn bộ người dùng) xảy ra *sau* ngày mua sản phẩm kiểm thử của người dùng đó – tức mô hình được học từ những gì xảy ra sau thời điểm cần dự đoán; ngoài ra 60,9% người dùng có sản phẩm xác thực và kiểm thử được mua cùng một ngày.

Kiểm tra không giao nhau. Sau khi chia, hệ thống bắt buộc kiểm tra phần giao giữa từng cặp tập ở cấp độ cặp (User, Item):

$$\mathcal{Y}_{train} \cap \mathcal{Y}_{val} = \emptyset, \quad \mathcal{Y}_{train} \cap \mathcal{Y}_{test} = \emptyset, \quad \mathcal{Y}_{val} \cap \mathcal{Y}_{test} = \emptyset \quad (3.3)$$

Quy trình chỉ tiếp tục khi cả ba điều kiện thỏa mãn. Ngoài ra, một bộ kiểm thử tự động chạy trên dữ liệu thật xác nhận thứ tự thời gian $train < validation < test$, người dùng/sản phẩm của tập xác thực là tập con của tập huấn luyện, và người dùng/sản phẩm của tập kiểm thử là tập con của tập huấn luyện $\cup$ xác thực. Bảng 3.3 tổng hợp kết quả phân chia theo giao thức chính.

Bảng 3.3: Kết quả phân chia theo mốc thời gian chung trên hm500k ($k = 10$)

Tập	Khoảng thời gian	Số cặp	Số người dùng	Số sản phẩm
Huấn luyện	20/09/2018 – 30/06/2020	201.801	7.506	10.145
Xác thực	01/07/2020 – 28/07/2020	7.057	2.275	2.642
Kiểm thử	29/07/2020 – 22/09/2020	9.229	2.996	2.772
Huấn luyện $\cup$ xác thực*	20/09/2018 – 28/07/2020	209.212	7.515	10.216
Giao nhau $Train \cap Val = Train \cap Test = Val \cap Test = 0$ cặp				

*Dữ liệu huấn luyện lại trước khi chấm kiểm thử: mọi cặp trước 29/07/2020, gồm cả 354 cặp của người dùng/sản phẩm mới xuất hiện trong giai đoạn xác thực (không được chấm ở tập xác thực vì chưa có trong tập huấn luyện).

Mỗi người dùng trong tập huấn luyện có trung bình 26,9 cặp tương tác (trung vị 20); mỗi người dùng kiểm thử có trung bình 3,08 sản phẩm đúng. Khi chấm validation, tập ứng viên là 10.145 sản phẩm của tập huấn luyện, trừ những sản phẩm người dùng đã mua trong tập huấn luyện; khi chấm test, tập ứng viên là 10.216 sản phẩm của tập huấn luyện $\cup$ xác thực, trừ những sản phẩm người dùng đã mua trong tập này.

3.3 Thiết kế kiến trúc mô hình NeuMF

3.3.1 Cấu hình không gian nhúng Embedding độc lập

Một quyết định thiết kế quan trọng của NeuMF là *không* dùng chung một bảng Embedding cho hai nhánh GMF và MLP. Nhánh GMF tối ưu vector Embedding cho phép nhân Hadamard (tuyến tính, đòi hỏi các chiều đặc trưng “thẳng hàng” về ý nghĩa), còn nhánh MLP tối ưu vector Embedding làm đầu vào cho một mạng phi tuyến sâu. Ép hai mục tiêu khác bản chất này chia sẻ cùng một không gian tham số có thể khiến gradient từ hai nhánh xung đột nhau [2]. Do đó mô hình dùng hai không gian nhúng độc lập:

- Bảng Embedding nhánh GMF: $P^G \in \mathbb{R}^{M \times d_G}$ và $Q^G \in \mathbb{R}^{N \times d_G}$.
- Bảng Embedding nhánh MLP: $P^M \in \mathbb{R}^{M \times d_M}$ và $Q^M \in \mathbb{R}^{N \times d_M}$.

Việc tách hai bảng còn cho phép hai nhánh có số chiều khác nhau ($d_G \neq d_M$), như He và cộng sự cho phép trong công trình gốc – điều cần thiết khi GMF và MLP tốt nhất sau tinh chỉnh có kích thước khác nhau (mục 3.6). Bảng Embedding được khởi tạo theo phân phối chuẩn $\mathcal{N}(0; 0,01)$, các tầng tuyến tính theo Xavier. Số tham số chủ yếu nằm ở Embedding, tỉ lệ với $(M + N) \times d$: với cấu hình tốt nhất, GMF ($d = 64$) có 1.143.360 tham số, MLP ($d = 32$) có 574.400, NeuMF-Scratch ($d = 64$) có 2.297.536 và NeuMF-Pretrained ($d_G = 64, d_M = 32$) có 1.717.760; BPR-MF ($d = 32$) có 571.648.

3.3.2 Thiết kế nhánh Generalized Matrix Factorization (GMF)

Nhánh GMF là dạng *tổng quát hóa* của nhân tử hóa ma trận cô điển (Công thức (2.4)): thay vì cộng dồn ngay tích các chiều thành một số vô hướng ($p_u^T q_i$), GMF giữ kết quả nhân theo từng chiều dưới dạng vector qua phép nhân Hadamard:

$$\phi^{GMF} = p_u^G \odot q_i^G \quad (3.4)$$

Mỗi chiều f của $\phi^{GMF} \in \mathbb{R}^{d_G}$ đo mức độ “khớp” giữa User u và Item i theo đặc trưng ẩn thứ f . Phép cộng dồn được chuyển sang lớp trọng số h ở tầng đầu ra (mục 3.3.5), cho phép mô hình học *trọng số riêng cho từng chiều* thay vì coi mọi chiều quan trọng như nhau – đây là phần “tổng quát hóa” trong tên gọi GMF; khi $h = 1$, GMF trở về MF.

3.3.3 Thiết kế nhánh Multi-Layer Perceptron (MLP)

Nhánh MLP *nối* (concatenate) hai vector Embedding thành một vector đầu vào duy nhất, không áp đặt trước cách hai vector tương tác – việc “học cách tương tác”

được giao cho các tầng mạng phía sau:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \in \mathbb{R}^{2d_M} \quad (3.5)$$

Mạng MLP có kiến trúc tháp giảm một nửa qua mỗi tầng ẩn, theo quy ước của NCF gốc:

$$[2d_M \longrightarrow d_M \longrightarrow d_M/2 \longrightarrow d_M/4] \quad (d_M = 32 : [64 \rightarrow 32 \rightarrow 16 \rightarrow 8]) \quad (3.6)$$

Mỗi tầng ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và lớp Dropout (tỉ lệ được tinh chỉnh trong $\{0; 0,2\}$) để hạn chế quá khớp – rủi ro thực sự khi dữ liệu huấn luyện chỉ có 201.801 cặp dương.

3.3.4 Nhánh MLP đứng riêng: mô hình DNN thuần, không phải mô hình hợp nhất

Khi đứng riêng, nhánh MLP nối Embedding của User và Item ngay ở đầu vào rồi đưa qua một tháp nơ-ron:

$$z_1 = \begin{bmatrix} p_u \\ q_i \end{bmatrix} \in \mathbb{R}^{2d}, \quad \hat{y}_{ui}^{MLP} = \sigma(h^T \cdot \text{MLP}(z_1)) \quad (3.7)$$

Mô hình này chỉ có view phi tuyến, không có thành phần MF nào, nên trong đề tài nó là **đối chứng DNN thuần** (tương đương bỏ nhánh MF khỏi NeuMF), không phải một mô hình hợp nhất theo nghĩa ở mục 2.3.4. Trong mã nguồn, nhóm từng cài đặt riêng một lớp EarlyFusionModel theo cách hiểu “nối biểu diễn User–Item ngay ở đầu vào”; đối chiếu với mục 3.3.3 cho thấy lớp này *trùng hoàn toàn* với MLP đứng riêng (cùng cặp bảng Embedding, cùng phép nối, cùng tháp và lớp đầu ra). Điều này được kiểm chứng bằng thực nghiệm (NDCG@10 trên validation giống hệt nhau với cùng seed) và bằng một bài kiểm thử tự động so sánh kiến trúc, nên lớp này không được tinh chỉnh hay đánh giá riêng (đã ghi trong kế hoạch thực nghiệm trước khi chấm test, mục 3.6). Phép hợp nhất MF với DNN của đề tài nằm ở tầng kết hợp của NeuMF (mục 3.3.5).

3.3.5 Tầng kết hợp NeuMF và lớp dự đoán đầu ra

Đây là bước hợp nhất của mô hình lai – Early Fusion ở mức biểu diễn theo phân loại ở mục 2.3.4: vector của nhánh GMF (ϕ^{GMF} , tương tác tuyến tính) và của

nhánh MLP (ϕ_L^{MLP} , tương tác phi tuyến) được ghép nối thành một vector hợp nhất:

$$\phi^{NeuMF} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \quad (3.8)$$

Vector này qua một tầng tuyến tính cuối với trọng số $h = [h_G^T, h_M^T]^T$ và hàm Sigmoid:

$$\hat{y}_{ui} = \sigma(h^T \phi^{NeuMF}) = \sigma(h_G^T(p_u^G \odot q_i^G) + h_M^T \phi_L^{MLP}) \quad (3.9)$$

Điểm dự đoán là một tổ hợp tuyến tính có trọng số học được giữa “quan điểm” của nhánh tuyến tính và nhánh phi tuyến. Với NeuMF-Pretrained, lúc khởi tạo $h = [\alpha h_{GMF}; (1 - \alpha) h_{MLP}]$ nên logit ban đầu đúng bằng α lần logit của GMF cộng $(1 - \alpha)$ lần logit của MLP – giống một phép trộn điểm; điểm khác với Late Fusion là sau đó toàn bộ mạng, kể cả hai nhánh, được tinh chỉnh chung thay vì giữ nguyên hai mô hình thành phần. Khi xếp hạng, hệ thống dùng trực tiếp giá trị trước Sigmoid (logit): Sigmoid là hàm đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hòa về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả.

3.4 Kỹ thuật lấy mẫu tiêu cực và hàm mục tiêu huấn luyện

3.4.1 Kỹ thuật lấy mẫu tiêu cực động (Dynamic Negative Sampling)

Dữ liệu phản hồi âm (mục 2.1.3) chỉ ghi nhận tương tác đã xảy ra ($y_{ui} = 1$), không có nhãn âm tường minh. Negative Sampling giả định các sản phẩm người dùng chưa tương tác nhiều khả năng là âm (dù một phần trong đó chỉ là người dùng chưa biết đến). Cụ thể, trong mỗi epoch, với mỗi cặp dương $(u, i) \in \mathcal{Y}_{train}$, hệ thống lấy ngẫu nhiên N_{ratio} sản phẩm $j \in \mathcal{I} \setminus \mathcal{I}_u^{train}$ và gán $y_{uj} = 0$. Tập loại trừ chỉ gồm sản phẩm của người dùng trong *tập huấn luyện*, để không dùng nhãn tương lai của tập xác thực/kiểm thử. N_{ratio} được tinh chỉnh trong $\{4, 8\}$: He và cộng sự [2] ghi nhận 1 mẫu âm là không đủ và tỉ lệ khoảng 3–6 cho kết quả tốt nhất. Mẫu âm được lấy lại hoàn toàn ở *mỗi* epoch (lấy mẫu động), giúp mô hình thấy nhiều tổ hợp cặp âm khác nhau và giảm nguy cơ học vẹt một tập âm cố định.

3.4.2 Hàm tổn thất Binary Cross-Entropy (BCE) và Regularization

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm Binary Cross-Entropy được tối thiểu hóa, cùng số hạng điều chuẩn L_2

(weight decay của bộ tối ưu):

$$\mathcal{L} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_{\Theta} \|\Theta\|_2^2 \quad (3.10)$$

trong đó Θ là toàn bộ tham số có thể học và $\lambda_{\Theta} \in \{0; 10^{-6}\}$ được tinh chỉnh. Trong cài đặt, BCE được tính trên logit (BCEWithLogitsLoss) để ổn định số học. Cực tiểu hóa $\mathcal{L}$ tương đương với huấn luyện mô hình phân biệt tốt nhất giữa cặp thật và cặp lấy mẫu ngẫu nhiên.

3.5 Quy trình huấn luyện và tối ưu hóa mô hình

3.5.1 Chiến lược tiền huấn luyện (Pre-training GMF + MLP)

Hàm mất mát của NeuMF không lồi và không gian tham số lớn, nên khởi tạo ngẫu nhiên toàn bộ mạng (NeuMF-Scratch) có thể hội tụ về một cực tiểu kém. Chiến lược tiền huấn luyện của công trình gốc [2] chia quá trình tối ưu thành hai giai đoạn:

1. **Huấn luyện trước:** Huấn luyện độc lập GMF và MLP bằng Adam [11] cho tới khi dừng sớm, lưu Embedding và trọng số tốt nhất của từng nhánh.
2. **Hợp nhất và tinh chỉnh:** Khởi tạo bốn bảng Embedding và các tầng MLP của NeuMF từ hai mô hình trên; khởi tạo trọng số đầu ra $h \leftarrow [\alpha h_{GMF}^T, (1 - \alpha) h_{MLP}^T]^T$, trong đó α cân bằng đóng góp ban đầu của hai nhánh (bài gốc dùng $\alpha = 0,5$; dự án tinh chỉnh $\alpha \in \{0,3; 0,5; 0,7\}$); sau đó tinh chỉnh toàn mạng với tốc độ học nhỏ (tinh chỉnh trong $\{10^{-3}, 5 \cdot 10^{-4}, 10^{-4}\}$).

Khác với bài gốc (tinh chỉnh bằng SGD), dự án dùng **Adam cho cả hai giai đoạn**: trên dữ liệu này, SGD với tốc độ học 0,01 khiến NeuMF không hội tụ (hàm mất mát dừng ở mức entropy của nhiễu). NeuMF-Pretrained và NeuMF-Scratch được huấn luyện và đánh giá song song trong mọi thực nghiệm để tách riêng đóng góp của Pre-training.

3.5.2 Bảng thiết lập siêu tham số và kỹ thuật dừng sớm (Early Stopping)

Bảng 3.4 liệt kê cấu hình mặc định và không gian tinh chỉnh. Cấu hình mặc định luôn là một trong các cấu hình được thử; cấu hình dùng cho kết quả cuối của từng mô hình là cấu hình tốt nhất trên tập xác thực (Bảng 4.1).

Early Stopping: sau mỗi epoch, mô hình được chấm NDCG@10 theo Full Ranking trên tập xác thực; trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi chỉ số không cải thiện sau 5 epoch liên tiếp.

Bảng 3.4: Siêu tham số: giá trị mặc định và không gian tìm kiếm

Siêu tham số	Mặc định	Không gian tìm kiếm
Kích thước lô (Batch Size)	512	cố định
Bộ tối ưu	Adam	cố định
Tốc độ học – GMF, MLP, NeuMF-Scratch	10^{-3}	$\{10^{-3}, 5 \cdot 10^{-4}\}$
Tốc độ học tinh chỉnh – NeuMF-Pretrained	10^{-3}	$\{10^{-3}, 5 \cdot 10^{-4}, 10^{-4}\}$
Hệ số α khởi tạo lớp đầu ra (Pretrained)	0,5	$\{0,3; 0,5; 0,7\}$
Kích thước Embedding d	32	$\{32, 64\}$
Cấu trúc tầng ẩn MLP	$[64, 32, 16, 8]$	$[2d, d, d/2, d/4]$
Tỷ lệ lấy mẫu âm N_{ratio}	4	$\{4, 8\}$
Tỷ lệ Dropout (MLP, NeuMF)	0,2	$\{0; 0,2\}$
Weight Decay λ	10^{-6}	$\{0; 10^{-6}\}$
Số epoch tối đa	20	cố định
Early Stopping: theo dõi / kiên nhẫn	NDCG@10 val / 5	cố định
BPR-MF: kích thước d	32	$\{32, 64, 128\}$
BPR-MF: tốc độ học	0,03	$\{0,01; 0,03; 0,05\}$
BPR-MF: hệ số điều chuẩn	0,005	$\{0,001; 0,005; 0,01\}$
BPR-MF: số epoch	20	$\{20, 40\}$

3.6 Quy trình tinh chỉnh và đánh giá không thiên lệch

Ferrari Dacrema và cộng sự [5] chỉ ra mã nguồn gốc của NCF chọn số epoch dựa trên chính tập kiểm thử, và các baseline trong nhiều bài báo học sâu được tinh chỉnh sơ sài; Rendle và cộng sự [4] cho thấy MF được tune kỹ vượt NeuMF trên chính dữ liệu của bài gốc. Để kết luận của đề tài không mắc các lỗi này, quy trình thực nghiệm áp dụng năm nguyên tắc:

1. **Khoá tập kiểm thử.** Mọi lựa chọn mô hình và siêu tham số chỉ dựa trên tập xác thực. Tập kiểm thử chỉ được chấm qua kịch bản đánh giá cuối (và kịch bản phân tích phụ, vốn chỉ nạp lại đúng các trọng số của kịch bản đó); các kịch bản này từ chối chạy nếu kế hoạch thực nghiệm chưa được lưu vào hệ thống quản lý phiên bản, nếu thiếu lý do chạy, hoặc nếu mã nguồn có thay đổi chưa lưu. Mỗi lần chấm test ghi một dòng vào nhật ký truy cập (thời gian, phiên bản mã nguồn, mã băm cấu hình, lý do).
2. **Đăng ký trước (pre-registration).** Độ đo chính, lưới tinh chỉnh, số seed, họ so sánh và tiêu chí kết luận được cố định và lưu lại *trước* lần chấm test đầu tiên. Mọi thay đổi sau đó được ghi vào mục “lịch kế hoạch” kèm thời điểm (trước hay sau khi xem test).
3. **Cùng ngân sách tinh chỉnh.** Mỗi mô hình có siêu tham số được thử đúng **6 cấu hình**, lấy bằng một lần rút ngẫu nhiên cố định từ lưới của mô hình đó (Bảng 3.4), cấu hình mặc định luôn nằm trong 6. Mỗi cấu hình ghi một dòng nhật ký (mã băm cấu hình, phiên bản mã nguồn, chỉ số trên validation, thời gian). NeuMF-Pretrained được nạp từ GMF và MLP tốt nhất.
4. **Chọn mô hình lai trên validation.** Trong hai biến thể NeuMF, mô hình có NDCG@10 validation cao nhất được xem là “mô hình lai được chọn”; tập test chỉ để báo cáo, không để chọn lại.
5. **Kiểm định thống kê và tiêu chí kết luận cố định.** Mỗi mô hình (với cấu hình tốt nhất) được chạy với 3 seed (42, 2024, 2025); với mỗi seed, mô hình được huấn luyện trên tập huấn luyện để chọn số epoch theo validation, rồi huấn luyện lại trên tập huấn luyện $\cup$ xác thực đúng số epoch đó và chấm trên test (mục 3.2.5). NDCG@10 của từng người dùng được lấy trung bình qua 3 seed, rồi so sánh từng cặp mô hình bằng kiểm định Wilcoxon signed-rank theo người dùng [13] và khoảng tin cậy 95% bằng paired bootstrap (10.000 lần lấy mẫu lại) [14]; giá trị p được hiệu chỉnh Holm [15] trên họ 8

so sánh cố định (NeuMF-Pretrained so với BPR-MF, Most Popular, GMF, MLP, NeuMF-Scratch; NeuMF-Scratch so với BPR-MF, GMF, MLP). Chỉ viết “A tốt hơn B” khi đồng thời: $p_{Holm} < 0,05$, khoảng tin cậy không chứa 0, và chênh lệch tương đối $NDCG@10 \geq 5\%$; ngược lại kết luận “không khác biệt có ý nghĩa”. Không dùng Wilcoxon theo seed vì với 3 seed, giá trị p nhỏ nhất có thể đạt là $2/2^3 = 0,25$.

Lịch kế hoạch trước lần chấm test đầu tiên. Kế hoạch ban đầu có thêm các ứng viên iALS [42], Most Popular theo cửa sổ thời gian gần, DeepCF/CFNet và một mô hình trộn điểm iALS + NeuMF-Scratch (trộn một mô hình MF với mô hình lai NeuMF); tất cả đã được tinh chỉnh trên validation nhưng sau đó bị loại khỏi phạm vi theo quyết định của nhóm (đã quá nhiều baseline), *trước* khi xem bất kỳ số liệu test nào. Kết quả validation của chúng vẫn được giữ trong nhật ký tinh chỉnh để minh bạch và được nhắc lại ở mục 4.6. Lớp EarlyFusionModel (nối Embedding ngay ở đầu vào) bị loại vì trùng kiến trúc MLP (mục 3.3.4). ItemKNN không được chạy vì ma trận tương đồng dày $N \times N$ với $N = 10.345$ vượt ngưỡng an toàn bộ nhớ của cài đặt.


Lịch kế hoạch sau lần chấm test đầu tiên. Lần chấm đầu (27/09/2026) huấn luyện các mô hình chỉ trên tập huấn luyện rồi chấm thẳng tập kiểm thử, bỏ trống 4 tuần của giai đoạn xác thực. Sau đó nhóm bổ sung bước huấn luyện lại trên tập huấn luyện $\cup$ xác thực (mục 3.2.5) và chấm lại toàn bộ (29/09/2026); cấu hình, độ đo, họ so sánh và tiêu chí kết luận giữ nguyên. Vì thay đổi này được quyết định *sau* khi đã xem số liệu test, số liệu ở Chương 4 – lấy từ lần chấm thứ hai – cần được hiểu là kết quả sau khi đã xem test một lần. Kết luận không đổi giữa hai lần chấm: ở lần đầu, BPR-MF cũng có $NDCG@10$ trung bình cao nhất (0,01062, so với 0,01001 của NeuMF-Pretrained và 0,00958 của NeuMF-Scratch) và cũng 0/8 so sánh đạt tiêu chí “tốt hơn”. Nhật ký truy cập ghi đủ cả hai lần chấm; số liệu của lần đầu được giữ trong lịch sử phiên bản của kho mã.

3.7 Thiết kế hệ thống giao diện thực nghiệm (Demo)

Mục này trình bày hệ thống demo minh họa mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt về kiến trúc với phần huấn luyện: chỉ nạp trọng số mô hình đã lưu và gọi lại đúng các hàm tiền xử lý, xếp hạng của pipeline

huấn luyện, không huấn luyện lại.

3.7.1 Kiến trúc tổng thể: ba tầng tách biệt



Hình 3.2: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo)

Hai nguyên tắc thiết kế quan trọng nhất: (i) tách suy diễn khỏi huấn luyện, nên thời gian phản hồi không phụ thuộc chi phí huấn luyện và tầng 2+3 có thể đóng gói thành một container độc lập; (ii) demo *tự kiểm tra* rằng dữ liệu dựng lại khớp với lần chạy đã huấn luyện – nếu lệch (ví dụ sai tệp dữ liệu hoặc sai ngưỡng k), máy chủ báo lỗi thay vì nạp trọng số với ánh xạ ID sai. Trung bình $\text{Hit}@K/\text{NDCG}@K$ theo người dùng mà demo tính lại khớp với kết quả của lần chạy tới sai số 10^{-6} .

3.7.2 Thiết kế API suy diễn

Luồng xử lý của chức năng gợi ý Top- K gồm 5 bước, dùng lại đúng các hàm của pipeline đánh giá:

1. Tra định danh khách hàng để lấy mã nội bộ. Khách chưa có trong dữ liệu

Bảng 3.5: Các endpoint chính của API suy diễn

Endpoint	Chức năng
GET /api/context	Thông tin bộ dữ liệu, lần chạy đang dùng, số người dùng/sản phẩm, các K hợp lệ, mô hình khả dụng.
GET /api/users/search, /random	Tìm hoặc chọn ngẫu nhiên một khách hàng có sản phẩm kiểm thử, lọc theo nhóm ít/trung bình/nhiều giao dịch.
GET /api/users/{id}/history	Lịch sử mua trong tập huấn luyện, sắp theo thời gian.
GET /api/users/{id}/recommend	Top- K của một mô hình, hạng của sản phẩm kiểm thử, số ứng viên, $\text{Hit}@K$ và $\text{NDCG}@K$ của khách đó.
POST /api/onboarding/recommend	Gợi ý cho khách hàng mới theo luật (lọc theo lựa chọn + độ phổ biến trong train) – được gắn nhãn rõ <i>không phải mô hình NeuMF</i> .
GET /api/dashboard	Số liệu tổng hợp đọc từ tệp kết quả đã chạy, kèm tên tệp nguồn.
POST /api/reload	Xoá cache, nạp lần chạy mới nhất mà không cần khởi động lại.

huấn luyện là tình huống Cold-start tuyệt đối, nằm ngoài khả năng của mô hình (mục 4.5); demo chuyển sang màn hình Khách hàng mới với gợi ý theo luật thay vì suy diễn một kết quả không đáng tin cậy.

2. Xác định tập ứng viên: toàn bộ sản phẩm trừ những sản phẩm khách đã mua – cùng hàm dựng tập ứng viên của đánh giá Full Ranking.
3. Tính điểm cho toàn bộ tập ứng viên theo lô (vector hoá), dùng logit với mô hình nơ-ron.
4. Sắp xếp giảm dần với cùng quy tắc phá hòa tấu định như lúc đánh giá, lấy K phần tử đầu.
5. Ánh xạ ngược mã nội bộ về `article_id`, kèm tên và loại sản phẩm, trả về Tầng 1.

3.7.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng

Demo cho phép chọn và so sánh song song hai mô hình bất kỳ trong số NeuMF-Pretrained, NeuMF-Scratch, GMF, MLP, BPR-MF và Most Popular, để người xem tự đối chiếu với kết luận của Chương 4; demo không khẳng định mô hình nào “tốt nhất” ngoài những gì kiểm định thống kê cho phép. Phiên bản demo hiện tại nạp trọng số của một lần chạy khám phá theo giao thức phụ Leave-One-Out với cấu hình mặc định (sản phẩm đích lấy từ tập xác thực để không làm lộ tập kiểm thử), không phải trọng số của đánh giá cuối; vì vậy số liệu hiển thị trong demo không trùng với các bảng của Chương 4. Về yêu cầu phi chức năng, mỗi yêu cầu gợi ý chỉ là một lượt suy diễn thuận trên khoảng 10.000 ứng viên, nên mục tiêu thiết kế là độ trễ mức mili giây trên CPU; độ trễ thực đo (trung vị và phân vị 95) được báo cáo ở mục 4.4.6.

3.7.4 Minh họa hệ thống demo đã cài đặt

Hệ thống đã được cài đặt và có bộ kiểm thử tự động riêng (kiểm tra khớp số liệu với lần chạy, đúng quy tắc tập ứng viên, đúng định dạng API). Hình ?? minh họa màn hình Admin kiểm thử mô hình.

Chưa có số liệu: hình “Giao diện demo – màn hình Admin kiểm thử mô hình: lịch sử mua, Top-10 của từng mô hình và hạng của sản phẩm kiểm thử” — chụp màn hình demo (`python run.py demo`) và lưu thành `media/figures/demo/demo_final.png`.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

Toàn bộ thực nghiệm dùng mẫu hm500k sau lọc k -core ($k = 10$): 7.519 người dùng, 10.345 sản phẩm, chia theo mốc thời gian chung (mục 3.2.5). Tinh chỉnh và đánh giá cuối được chạy trên GPU NVIDIA GeForce RTX 3050 Laptop (4 GB), RAM 16 GB, bằng PyTorch [10]; độ trễ suy diễn được đo riêng trên CPU (mục 4.4.6). Mọi bảng số liệu, hình và con số kết quả trong chương này được sinh tự động từ tệp kết quả của quy trình thực nghiệm, không nhập tay.

Giao thức đánh giá:

- **Full Ranking (chính):** với mỗi người dùng kiểm thử, xếp hạng toàn bộ 10.216 sản phẩm có trong tập huấn luyện $\cup$ xác thực, trừ các sản phẩm người dùng đã mua trong hai tập này; các sản phẩm đúng luôn nằm trong tập ứng viên. Hòa điểm được phá bằng một khoá tắt định (seed 2026), giống nhau cho mọi mô hình.
- **Độ đo chính:** NDCG@10 trung bình theo người dùng trên tập kiểm thử (2.996 người dùng, 9.229 cặp đúng). Độ đo phụ: Recall@10, HR@10, Precision@10, NDCG@5 (định nghĩa cho trường hợp nhiều sản phẩm đúng ở mục 2.5).
- **Sampled-99 (chỉ đối chiếu):** mỗi cặp đúng được xếp cùng 99 sản phẩm âm lấy ngẫu nhiên, theo giao thức NCF gốc [2]; không dùng để kết luận [12].
- **Số lần chạy:** mỗi mô hình được chạy với 3 seed (42, 2024, 2025); với mỗi seed, số epoch được chọn trên tập xác thực rồi mô hình được huấn luyện lại trên tập huấn luyện $\cup$ xác thực trước khi chấm test (mục 3.2.5); báo cáo trung bình $\pm$ độ lệch chuẩn qua seed; kiểm định theo mục 3.6.
- **Lần chấm:** số liệu dưới đây là lần chấm test thứ hai, sau khi bổ sung bước huấn luyện lại; lần chấm đầu cho cùng kết luận (mục 3.6, phần lệch kế hoạch).

4.2 Phương pháp đối chứng (Baselines)

Bảy mô hình được đánh giá, chia ba nhóm:

1. **Baseline: Random** (điểm ngẫu nhiên – cận dưới); **Most Popular** (điểm

là số người dùng đã mua sản phẩm trong tập huấn luyện, mọi người dùng nhận cùng một danh sách trừ sản phẩm đã mua); **BPR-MF** [22] – nhân tử hóa ma trận tuyến tính tối ưu xếp hạng theo cặp, được tinh chỉnh cùng ngân sách như NeuMF.

2. **Ablation: GMF** (chỉ nhánh MF) và **MLP** (chỉ nhánh DNN, mô hình DNN thuần – mục 3.3.4).
3. **Mô hình đề tài: NeuMF-Scratch** (khởi tạo ngẫu nhiên) và **NeuMF-Pretrained** (khởi tạo từ GMF, MLP đã huấn luyện) [2] – mô hình lai MF + DNN theo kiểu Early Fusion ở mức biểu diễn (mục 2.3.4).

Lọc cộng tác dựa trên độ tương đồng sản phẩm (ItemKNN [16]) không được đưa vào vì ma trận tương đồng dày 10.345×10.345 vượt ngưỡng bộ nhớ an toàn của cài đặt; đây là một hạn chế vì Ferrari Dacrema và cộng sự [5] cho thấy ItemKNN được tune tốt có thể vượt NeuMF.

4.3 Kết quả tinh chỉnh trên tập xác thực

Bảng 4.1 liệt kê cấu hình tốt nhất của từng mô hình sau 6 cấu hình thử (tổng thời gian tinh chỉnh 1,9 giờ GPU, mọi dòng nhật ký cùng một phiên bản mã nguồn, không có thay đổi chưa lưu). Mọi con số trong bảng là trên tập *xác thực*; chúng lạc quan vì chính tập này được dùng để chọn cấu hình, nên chỉ dùng để chọn, không dùng để kết luận.

Bảng 4.1: Cấu hình tốt nhất của từng mô hình sau tuning (chỉ trên tập validation, seed 42, 6 cấu hình/mô hình, protocol mốc thời gian chung)

Mô hình	Cấu hình tốt nhất	NDCG@10	Recall@10	HR@10
NeuMF-Scratch	d=64; lr=0,0005; neg=4; wd= 10^{-6} ; dropout=0,2	0,01107	0,01515	0,04088
NeuMF-Pretrained	GMF d=64 + MLP d=32; lr=0,0001; α =0,3; neg=8; wd=0	0,00913	0,01255	0,03341
BPR-MF	d=32; lr=0,03; reg=0,005; 20 epoch	0,00912	0,01386	0,03824
GMF	d=64; lr=0,0005; neg=4; wd=0	0,00843	0,01213	0,03033
MLP	d=32; lr=0,001; neg=8; wd=0; dropout=0,2	0,00837	0,01420	0,03648

Số trên validation của cấu hình tốt nhất lạc quan (chọn trên chính tập đó); không dùng để kết luận.

Ba nhận xét từ quá trình tinh chỉnh. Thứ nhất, trên validation NeuMF-Scratch đứng đầu (NDCG@10 = 0,01107), trong khi NeuMF-Pretrained (0,00913) chỉ ngang BPR-MF (0,00912) – pre-training không giúp trên dữ liệu này. Theo quy tắc đã đăng ký (mục 3.6), **NeuMF-Scratch là mô hình lai được chọn**. Thứ hai, các mô hình nơ-ron đạt đỉnh rất sớm (đa số ở epoch 1–3, muộn nhất epoch 9), dấu hiệu quá khớp nhanh trên dữ liệu thưa. Thứ ba, các ứng viên đã bị loại khỏi phạm vi trước khi chấm test

(mục 3.6) đều cao hơn NeuMF-Scratch trên validation: trộn điểm iALS + NeuMF-Scratch đạt 0,01260, DeepCF/CFNet 0,01169 và iALS đã tune 0,01141 (iALS mặc định chỉ 0,00906) – phù hợp với nhận định của Rendle và cộng sự [42] rằng MF được tune kỹ là baseline rất mạnh.

4.4 Kết quả trên tập kiểm thử


4.4.1 So sánh các độ đo xếp hạng (Full Ranking)

Bảng 4.2 và Hình 4.1 trình bày kết quả trên tập kiểm thử của 7 mô hình, trung bình qua 3 seed.

Bảng 4.2: Kết quả trên tập test: trung bình $\pm$ độ lệch chuẩn qua 3 seed (Full Ranking, protocol mốc thời gian chung, train lại trên $\text{train} \cup \text{val}$; 2.996 user, 10.216 item candidate)

Mô hình	NDCG@10	Recall@10	HR@10	Precision@10	NDCG@5
BPR-MF	0,01007 $\pm$ 0,00046	0,01526 $\pm$ 0,00065	0,04651 $\pm$ 0,00158	0,00520 $\pm$ 0,00016	0,00777 $\pm$ 0,00053
NeuMF-Pretrained	0,00957 $\pm$ 0,00081	0,01365 $\pm$ 0,00098	0,04350 $\pm$ 0,00540	0,00478 $\pm$ 0,00066	0,00748 $\pm$ 0,00099
MLP	0,00931 $\pm$ 0,00120	0,01399 $\pm$ 0,00147	0,04306 $\pm$ 0,00518	0,00473 $\pm$ 0,00064	0,00712 $\pm$ 0,00132
MostPopular	0,00917 $\pm$ 0,00000	0,01297 $\pm$ 0,00000	0,04339 $\pm$ 0,00000	0,00471 $\pm$ 0,00000	0,00753 $\pm$ 0,00000
NeuMF-Scratch	0,00910 $\pm$ 0,00019	0,01324 $\pm$ 0,00075	0,04005 $\pm$ 0,00318	0,00436 $\pm$ 0,00032	0,00705 $\pm$ 0,00037
GMF	0,00907 $\pm$ 0,00101	0,01305 $\pm$ 0,00143	0,04094 $\pm$ 0,00575	0,00448 $\pm$ 0,00071	0,00709 $\pm$ 0,00084
Random	0,00065 $\pm$ 0,00027	0,00081 $\pm$ 0,00033	0,00312 $\pm$ 0,00051	0,00031 $\pm$ 0,00005	0,00049 $\pm$ 0,00028

In đậm: giá trị trung bình cao nhất mỗi cột.



Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử: trung bình $\pm$ độ lệch chuẩn qua 3 seed, chấm đen là từng seed

Trước hết, thang giá trị tuyệt đối rất thấp (NDCG@10 cao nhất khoảng 0,01): mỗi người dùng kiểm thử có trung bình 3,08 sản phẩm đúng giữa hơn 10.000 ứng viên, và dự đoán những món *chưa từng mua* trong 8 tuần sau mốc huấn luyện là bài toán khó với dữ liệu thời trang. Vì vậy thông tin quan trọng là thứ hạng tương đối và

chênh lệch có ý nghĩa thống kê hay không, không phải độ lớn tuyệt đối.

Bốn quan sát chính:

1. **BPR-MF có trung bình cao nhất trên mọi độ đo** ($NDCG@10 = 0,01007 \pm 0,00046$), dù là mô hình tuyến tính đơn giản nhất trong nhóm có học.
2. **NeuMF-Pretrained ngang Most Popular**: 0,00957 so với 0,00917 (chênh +4,3%, không có ý nghĩa thống kê). Mô hình lai được chọn theo validation, NeuMF-Scratch, chỉ đạt 0,00910.
3. **GMF, MLP và hai biến thể NeuMF nằm sát nhau** ($NDCG@10$ từ 0,00907 đến 0,00957), chênh lệch nhỏ hơn hoặc cùng cỡ với độ lệch chuẩn giữa các seed của các mô hình nơ-ron.
4. **Mọi mô hình có học đều vượt xa Random** ($NDCG@10 = 0,00065$), tức đều học được tín hiệu thật từ dữ liệu. Most Popular là baseline mạnh: độ phổ biến giải thích phần lớn những gì các mô hình phức tạp hơn nắm bắt được.

4.4.2 Kiểm định ý nghĩa thống kê


Bảng 4.3 và Hình 4.2 trình bày kết quả kiểm định cặp theo người dùng (2.996 người dùng) trên họ 8 so sánh đã đăng ký trước.

Bảng 4.3: Kiểm định cặp theo user trên $NDCG@10$ (trung bình qua 3 seed): Wilcoxon signed-rank, CI 95% paired bootstrap, hiệu chỉnh Holm trên họ 8 so sánh

A	B	$NDCG@10$ A	$NDCG@10$ B	Chênh	CI 95% (A-B)	p Wilcoxon	p Holm	Kết luận
NeuMF-Pretrained	BPR-MF	0,00957	0,01007	-5,0%	[-0,00146; 0,00046]	0,128	0,893	không khác biệt có ý nghĩa
NeuMF-Pretrained	MostPopular	0,00957	0,00917	+4,3%	[-0,00043; 0,00124]	0,381	1,000	không khác biệt có ý nghĩa
NeuMF-Pretrained	GMF	0,00957	0,00907	+5,5%	[-0,00004; 0,00105]	0,043	0,342	không khác biệt có ý nghĩa
NeuMF-Pretrained	MLP	0,00957	0,00931	+2,7%	[-0,00071; 0,00122]	0,397	1,000	không khác biệt có ý nghĩa
NeuMF-Pretrained	NeuMF-Scratch	0,00957	0,00910	+5,1%	[-0,00113; 0,00206]	0,811	1,000	không khác biệt có ý nghĩa
NeuMF-Scratch	BPR-MF	0,00910	0,01007	-9,6%	[-0,00263; 0,00067]	0,305	1,000	không khác biệt có ý nghĩa
NeuMF-Scratch	GMF	0,00910	0,00907	+0,4%	[-0,00152; 0,00159]	0,775	1,000	không khác biệt có ý nghĩa
NeuMF-Scratch	MLP	0,00910	0,00931	-2,2%	[-0,00187; 0,00144]	0,819	1,000	không khác biệt có ý nghĩa

“A tốt hơn B” chỉ khi đồng thời $p_{Holm} < 0,05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$.


Số so sánh đạt tiêu chí “A tốt hơn B” là **0/8**: mọi khoảng tin cậy đều chứa 0 và mọi giá trị p sau hiệu chỉnh Holm đều $\geq 0,05$. So sánh gần ngưỡng nhất là NeuMF-Pretrained với GMF: $NDCG@10$ của NeuMF-Pretrained chênh +5,5% so với GMF và p Wilcoxon chưa hiệu chỉnh là 0,043 – dưới 0,05 nếu xét riêng lẻ – nhưng sau hiệu chỉnh cho 8 so sánh $p_{Holm} = 0,342$ và khoảng tin cậy $[-0,00004; 0,00105]$ vẫn chứa 0; đây là ví dụ trực tiếp cho lý do phải hiệu chỉnh đa so sánh. So với BPR-MF, NeuMF-Pretrained chênh -5,0% ($p_{Holm} = 0,893$). Kết luận đúng theo tiêu chí đã đăng ký: *NeuMF không vượt BPR-MF, không vượt Most Popular, và không khác biệt có ý*



Hình 4.2: Chênh lệch NDCG@10 (A – B) với khoảng tin cậy 95% bootstrap theo người dùng, kèm giá trị p đã hiệu chỉnh Holm

nghĩa với các nhánh GMF, MLP của chính nó.

Hình 4.3 đặt NDCG@10 trên validation (lúc tinh chỉnh) cạnh NDCG@10 trên test. Thứ hạng không được giữ nguyên: NeuMF-Scratch đứng đầu trên validation nhưng trên test chỉ xếp thứ năm trong bảy mô hình, dưới cả BPR-MF, NeuMF-Pretrained, MLP và Most Popular. Đây là minh chứng trực tiếp rằng chênh lệch giữa các mô hình nhỏ hơn mức nhiễu của việc chọn trên một tập validation 2.275 người dùng – và là lý do đề tài không kết luận dựa trên một lần chạy hay trên số liệu validation.



Hình 4.3: NDCG@10 trên validation (seed 42, cấu hình tốt nhất) so với trên test (trung bình 3 seed)

4.4.3 Phân tích bóc tách thành phần (Ablation Study)

- **Đóng góp của hai nhánh GMF và MLP:** Nếu hợp nhất GMF và MLP tạo ra cộng hưởng như khung NCF kỳ vọng, NeuMF phải vượt cả hai nhánh đơn lẻ. Số liệu không xác nhận điều này: NDCG@10 của NeuMF-Pretrained chênh +5,5% so với GMF và +2,7% so với MLP, của NeuMF-Scratch chênh +0,4% so với GMF và −2,2% so với MLP – cả bốn so sánh đều không có ý nghĩa thống kê (p_{Holm} lần lượt 0,342, 1,000, 1,000, 1,000). Tăng số tham số lên gấp đôi (NeuMF-Scratch có 2,30 triệu tham số so với 1,14 triệu của GMF) không chuyển thành lợi ích đo được.
- **Early Fusion và Late Fusion:** NeuMF hợp nhất nhánh MF và nhánh DNN ở mức biểu diễn (Early Fusion, mục 2.3.4); như ý trên, trên tập kiểm thử nó không khác biệt có ý nghĩa với từng nhánh đứng riêng. Late Fusion thuần MF + DNN với cùng thành phần – trộn điểm GMF và MLP được huấn luyện riêng – chưa được thực hiện, nên đề tài chưa kết luận được cách hợp nhất nào phù hợp hơn. Phép trộn điểm duy nhất đã thử là trộn iALS với NeuMF-Scratch (một mô hình MF với mô hình lai), trọng số chọn trên tập xác thực: NDCG@10 = 0,01260 trên tập xác thực, cao hơn từng thành phần đứng riêng (iALS 0,01141; NeuMF-Scratch 0,01107), gợi ý NeuMF mang tín hiệu bổ sung cho MF. Mô hình này đã bị loại khỏi phạm vi trước lần chấm test đầu tiên (mục 3.6) nên chưa có kết quả trên tập kiểm thử.
- **Hiệu quả của Pre-training:** NDCG@10 test của NeuMF-Pretrained chênh +5,1% so với NeuMF-Scratch, không có ý nghĩa thống kê ($p_{Holm} = 1,000$); trên validation thì ngược lại (Pretrained thấp hơn Scratch). Không có bằng chứng rằng Pre-training giúp trên dữ liệu này – khác với mức cải thiện 1–2% mà bài gốc báo cáo trên MovieLens và Pinterest [2].
- **Kích thước Embedding và tỉ lệ mẫu âm:** Được tinh chỉnh như mọi siêu tham số khác (Bảng 3.4). GMF và NeuMF-Scratch chọn $d = 64$, MLP chọn $d = 32$; MLP và NeuMF-Pretrained chọn 8 mẫu âm, các mô hình còn lại chọn 4 (Bảng 4.1). Số tầng của tháp MLP được giữ cố định theo thiết kế NCF ($[2d, d, d/2, d/4]$), chưa được khảo sát riêng.

4.4.4 Đánh giá phân tầng: sản phẩm phổ biến/ít phổ biến và người dùng ít/nhiều tương tác

Để kiểm tra mô hình có học được sở thích cá nhân hay chỉ nắm bắt độ phổ biến, tập kiểm thử được chia theo hai chiều, định nghĩa chỉ dựa trên dữ liệu mà mô hình được huấn luyện trước khi chấm test (tập huấn luyện $\cup$ xác thực): (i) theo sản phẩm – nhóm **head** là 10% sản phẩm được mua nhiều nhất, còn lại là **tail**; (ii) theo người dùng – nhóm **cold** là 20% người dùng có ít tương tác nhất (cold-start *tương đối*, không phải người dùng mới), còn lại là **warm**. Đây là phân tích mô tả, không kiểm định (mục 3.6).

Bảng 4.4: NDCG@10 theo nhóm item (head = 10% item phổ biến nhất trong train $\cup$ val) và nhóm user (cold = 20% user ít tương tác train $\cup$ val nhất); trung bình 3 seed

Mô hình	Tất cả (2996)	Head (1521)	Tail (2652)	Cold (555)	Warm (2441)
NeuMF-Pretrained	0,00957	0,02892	0,00010	0,01022	0,00942
NeuMF-Scratch	0,00910	0,02698	0,00023	0,00806	0,00934
GMF	0,00907	0,02735	0,00000	0,00917	0,00904
MLP	0,00931	0,02756	0,00000	0,00957	0,00925
BPR-MF	0,01007	0,02999	0,00013	0,00957	0,01019
MostPopular	0,00917	0,02762	0,00000	0,01053	0,00887

Số trong ngoặc: số user test của nhóm. User có item đúng ở cả head lẫn tail được tính ở cả hai nhóm, mỗi nhóm chỉ xét item đúng của nhóm đó.

Trên nhóm sản phẩm tail – nơi độ phổ biến không giúp được – NeuMF-Pretrained đạt NDCG@10 0,00010, BPR-MF 0,00013 và Most Popular 0,00000; trên nhóm head lần lượt là 0,02892, 0,02999 và 0,02762. Trên nhóm người dùng cold, NeuMF-Pretrained đạt 0,01022 so với 0,00942 ở nhóm warm. Gần như toàn bộ độ chính xác đến từ nhóm head: trên nhóm này mọi mô hình đạt NDCG@10 khoảng 0,03, còn trên nhóm tail không mô hình nào vượt quá 0,0003 (GMF, MLP và Most Popular bằng 0; cao nhất là NeuMF-Scratch với 0,00023). Nói cách khác, không mô hình nào – kể cả NeuMF – gợi ý đúng được sản phẩm ít phổ biến. Khoảng cách cold/warm nhỏ và không theo một chiều: Most Popular đạt 0,01053 ở nhóm cold, cao nhất trong mọi mô hình và cao hơn chính nó ở nhóm warm (0,00887); chỉ BPR-MF và NeuMF-Scratch thấp hơn ở nhóm cold (0,00957 so với 0,01019; 0,00806 so với 0,00934). Như vậy, với người dùng ít lịch sử, gợi ý theo độ phổ biến trên dữ liệu này không kém các mô hình cá nhân hóa – nhận xét mô tả, chưa kiểm định, và nhóm cold chỉ có 555 người dùng.

Bảng 4.5 bổ sung các chỉ số ngoài độ chính xác của danh sách top-10 (mục 2.5.1).

Bảng 4.5: Chỉ số ngoài độ chính xác của danh sách top-10 trên tập test (trung bình 3 seed)

Mô hình	Coverage	Novelty (bit)	ARP	HRR
NeuMF-Pretrained	4,9%	10,00	226,7	98,2%
NeuMF-Scratch	14,9%	10,92	138,2	90,3%
GMF	2,9%	10,02	220,5	99,5%
MLP	0,6%	9,80	243,3	99,9%
BPR-MF	7,4%	10,13	227,6	93,3%
MostPopular	0,2%	9,69	258,5	100,0%

Coverage: tỉ lệ item xuất hiện trong ít nhất một top-10. Novelty: $-\log_2 P(i)$ trung bình. ARP: số tương tác train $\cup$ val trung bình của item được gợi ý. HRR: tỉ lệ item head trong top-10.

Most Popular là trường hợp giới hạn: mọi người dùng nhận gần như cùng một danh sách gồm các sản phẩm phổ biến nhất, nên độ bao phủ catalog chỉ 0,2% và tỉ lệ sản phẩm head trong gợi ý là 100,0%. Các mô hình cá nhân hóa có độ bao phủ lần lượt 7,4% (BPR-MF), 2,9% (GMF), 0,6% (MLP), 14,9% (NeuMF-Scratch) và 4,9% (NeuMF-Pretrained). NeuMF-Scratch đa dạng nhất: độ bao phủ 14,9%, độ mới 10,92 bit và tỉ lệ sản phẩm head thấp nhất (90,3%) – nhưng độ chính xác không cao hơn (NDCG@10 0,00910, xếp thứ năm). Ngược lại, MLP gần như chỉ gợi ý sản phẩm phổ biến (độ bao phủ 0,6%, HRR 99,9%), sát với Most Popular; NeuMF-Pretrained và GMF cũng có HRR trên 98%. BPR-MF vừa có độ chính xác trung bình cao nhất vừa đa dạng thứ hai (độ bao phủ 7,4%, HRR 93,3%), nên trên dữ liệu này đa dạng hơn không nhất thiết đi kèm độ chính xác thấp hơn.

4.4.5 Đối chiếu với giao thức Sampled-99

Bảng 4.6 chấm lại cùng các mô hình theo giao thức của bài NCF gốc: mỗi trong 9.229 cặp đúng của tập kiểm thử được xếp cùng 99 sản phẩm âm lấy ngẫu nhiên (cố định, dùng chung cho mọi mô hình).

Mọi mô hình đều bị thổi phồng chỉ số dưới Sampled-99 (NeuMF-Pretrained: NDCG@10 0,1505, gấp 15,7 lần Full Ranking; Most Popular gấp 16,7 lần), vì xếp một sản phẩm đúng giữa 100 ứng viên dễ hơn nhiều so với giữa hơn 10.000. Thứ hạng giữa các mô hình có thay đổi so với Full Ranking: Most Popular chỉ xếp thứ tư

Bảng 4.6: Đối chiếu Full Ranking với Sampled-99 (1 item đúng + 99 item âm, protocol NCF gốc) trên tập test; trung bình 3 seed

Mô hình	NDCG@10 Full	NDCG@10 Sampled-99	HR@10 Sampled-99	Hệ số thời phòng
NeuMF-Pretrained	0,00957	0,1505	0,2603	15,7×
NeuMF-Scratch	0,00910	0,1465	0,2621	16,1×
GMF	0,00907	0,1482	0,2591	16,3×
MLP	0,00931	0,1491	0,2593	16,0×
BPR-MF	0,01007	0,1527	0,2623	15,2×
MostPopular	0,00917	0,1531	0,2612	16,7×

Hệ số thời phòng = NDCG@10 Sampled-99 / NDCG@10 Full Ranking.

theo Full Ranking nhưng đứng đầu theo Sampled-99. Đây là minh họa trực tiếp cho cảnh báo của Krichene và Rendle [12]: chỉ số lấy mẫu không nhất quán với chỉ số đầy đủ, nên không được dùng để so sánh mô hình – và là lý do các con số của bài gốc (HR@10 khoảng 0,7 trên MovieLens) không thể đặt cạnh kết quả của đề tài.

4.4.6 Độ trễ suy diễn

Để có bằng chứng định lượng về khả năng triển khai, độ trễ phục vụ một yêu cầu gợi ý được đo trên CPU: với mỗi người dùng chọn ngẫu nhiên trong tập kiểm thử, mô hình chấm toàn bộ khoảng 10.182 ứng viên rồi lấy top-10 (Bảng 4.7).

Bảng 4.7: Độ trễ phục vụ một yêu cầu gợi ý top-10 trên CPU (chấm toàn bộ candidate của một user rồi lấy top-10), mili giây

Mô hình	p50	p95	Trung bình
NeuMF-Pretrained	1,1	1,6	1,2
NeuMF-Scratch	2,0	2,6	2,1
GMF	0,3	0,4	0,3
MLP	0,7	1,1	0,8
BPR-MF	0,6	0,8	0,6
MostPopular	0,0	0,1	0,0

200 yêu cầu, user chọn ngẫu nhiên trong tập test, trung bình 10.182 candidate/yêu cầu; CPU: AMD64

Family 25 Model 68 Stepping 1, AuthenticAMD, 8 luồng PyTorch.

Độ trễ trung vị của NeuMF-Pretrained là 1,1 ms, phân vị 95 là 1,6 ms (BPR-MF: 0,6 / 0,8 ms). Ở quy mô catalog khoảng 10.000 sản phẩm, chấm toàn bộ catalog cho một người dùng trên CPU là khả thi cho phục vụ trực tuyến. Với catalog lớn hơn nhiều bậc, cách chấm toàn bộ bằng MLP sẽ không còn phù hợp: tích vô hướng của MF/BPR cho phép dùng tìm kiếm lân cận gần đúng, còn MLP thì không [4].

4.5 Phạm vi và giới hạn thực nghiệm

Kết quả của chương này có giá trị trong phạm vi sau: (i) mẫu hm500k (khoảng 1,6% khách hàng của H&M) sau lọc $k = 10$, thiên về khách mua nhiều; (ii) giao thức chia theo mốc thời gian chung; khi huấn luyện lại trên tập huấn luyện $\cup$ xác thực, số epoch được lấy từ lần huấn luyện chỉ trên tập huấn luyện (ít hơn khoảng 3,5% dữ liệu) vì không còn tập xác thực để dừng sớm, nên có thể chưa tối ưu; bước huấn luyện lại này được bổ sung sau lần chấm test đầu tiên (mục 3.6); (iii) chỉ người dùng và sản phẩm đã có trong dữ liệu huấn luyện (tập huấn luyện $\cup$ xác thực khi chấm test) – bài toán Cold-start tuyệt đối nằm ngoài phạm vi; (iv) ngày mua chỉ ở mức ngày, nên một sản phẩm kiểm thử có thể được mua cùng ngày (cùng giỏ hàng) với một sản phẩm trong lịch sử – ảnh hưởng như nhau với mọi mô hình; (v) lọc k -core được áp dụng trên toàn bộ mẫu trước khi chia, tức có dùng thông tin số lượng tương tác của giai đoạn xác thực/kiểm thử – rò rỉ nhỏ và như nhau cho mọi mô hình; (vi) một bộ dữ liệu duy nhất. Các mô hình nơ-ron trên GPU khác có thể cho số lệch nhẹ do phép tính cuDNN không tắt định; kết luận thống kê mới là điều cần được giữ nguyên khi chạy lại.

4.6 Thảo luận

NeuMF có vượt các baseline hay không? Không. Trên dữ liệu và giao thức của đề tài, cả hai biến thể NeuMF đều không vượt BPR-MF đã tinh chỉnh (BPR-MF có trung bình cao nhất) và không khác biệt có ý nghĩa với Most Popular. Kết quả này nhất quán với hai nghiên cứu đối chứng đáng tin cậy nhất về NCF: Rendle và cộng sự [4] cho thấy MF tích vô hướng được tune kỹ vượt NeuMF ngay trên dữ liệu của bài gốc, và Ferrari Dacrema và cộng sự [5] cho thấy nhiều cải thiện của mô hình học sâu biến mất khi baseline được tune đúng và tập test không bị dùng để chọn mô hình. Đề tài áp dụng đúng hai điều kiện đó (cùng ngân sách tinh chỉnh, khoá tập test) và thu được kết luận tương tự.

Kết hợp tuyến tính – phi tuyến có mang lại lợi ích? Không đo được. NeuMF – hợp nhất hai nhánh ở mức biểu diễn – không khác biệt có ý nghĩa với GMF hay MLP

đứng riêng. Một cách giải thích nhất quán với số liệu: với trung bình 26,9 tương tác huấn luyện mỗi người dùng, dữ liệu không đủ để tầng phi tuyến học được cấu trúc tương tác nào vượt quá những gì tích vô hướng đã nắm bắt – các mô hình nơ-ron đạt đỉnh trên tập xác thực chỉ sau 1–9 epoch rồi quá khớp. Rendle và cộng sự [4] còn chỉ ra rằng một MLP cần rất nhiều dữ liệu mới xấp xỉ được chính phép tích vô hướng.

Kết quả âm có giá trị gì? Kết quả âm được báo cáo đúng như quy tắc đã đăng ký trước, không chọn lọc số liệu có lợi. Giá trị của đề tài nằm ở một quy trình đánh giá đáng tin cậy – dữ liệu tái lập được, chia theo thời gian không rò rỉ tương lai, cùng ngân sách tính chính, khoá tập test, kiểm định cặp có hiệu chỉnh đa so sánh – và ở bằng chứng rằng trên dữ liệu giao dịch thời trang thừa, độ phức tạp của NeuMF không được đền bù bằng độ chính xác. Các hướng có tín hiệu tích cực trên validation (iALS được tune, trộn điểm MF với NeuMF) được chuyển thành hướng phát triển ở Chương 5.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đối chiếu với các mục tiêu ở mục 1.2.1, đề tài đạt được các kết quả sau:

1. **Cơ sở lý thuyết:** Hệ thống hóa lý thuyết về lọc cộng tác trên phản hồi ẩn, nhân tử hóa ma trận, BPR, GMF, MLP và mô hình lai NeuMF [1], [2], [22], cùng các hướng hiện đại (mục 2.4) và các nghiên cứu về đánh giá công bằng [4], [5], [12] để xác định vị trí và giới hạn của hướng tiếp cận.
2. **Quy trình dữ liệu tái lập được, không rò rỉ:** Lấy mẫu hm500k theo khách hàng từ 31,8 triệu giao dịch H&M (tắt định, khoảng 70 giây, 0,5 GB RAM); gộp cặp User–Item trước khi lọc k -core; chia theo một mốc thời gian chung để mô hình không thấy tương lai; kiểm tra không giao nhau và kiểm thử tự động trên dữ liệu thật (mục 3.2).
3. **Cài đặt mô hình:** GMF, MLP, NeuMF-Scratch và NeuMF-Pretrained bằng PyTorch [10], lấy mẫu âm động chỉ từ tập huấn luyện, pre-training với nhánh GMF và MLP có thể khác số chiều; xác định rõ NeuMF là mô hình lai MF + DNN theo kiểu Early Fusion ở mức biểu diễn (mục 2.3.4) và chỉ ra rằng biến thể “nối Embedding ngay ở đầu vào” cài đặt ban đầu trùng kiến trúc với MLP đơn lẻ (mục 3.3.4).
4. **Đánh giá không thiên lệch:** Tinh chỉnh cùng ngân sách (6 cấu hình/mô hình) chỉ trên validation, khoá tập test với nhật ký truy cập, đăng ký trước tiêu chí kết luận, 3 seed, kiểm định Wilcoxon theo người dùng kèm bootstrap và hiệu chỉnh Holm (mục 3.6).
5. **Kết quả chính:** Trên tập kiểm thử, BPR-MF đạt NDCG@10 trung bình cao nhất (0,01007); NeuMF-Pretrained (0,00957) ngang Most Popular (0,00917); 0/8 so sánh đạt tiêu chí “tốt hơn”. NeuMF không vượt baseline MF đã tinh chỉnh và không vượt các nhánh thành phần của chính nó; pre-training không mang lại lợi ích đo được (Chương 4). Kết quả âm này được báo cáo đúng như kế hoạch đã đăng ký và nhất quán với Rendle và cộng sự [4].
6. **Khả năng triển khai:** Hệ thống demo FastAPI chỉ suy diễn, tự kiểm tra khớp dữ liệu với lần chạy đã huấn luyện, và độ trễ gợi ý top-10 được đo

thực tế trên CPU (mục 4.4.6).

5.2 Hạn chế của đề tài

- **Quy mô dữ liệu:** Chỉ dùng mẫu hm500k (khoảng 1,6% khách hàng, 500.269 giao dịch), không phải toàn bộ 31,8 triệu giao dịch, vì đánh giá Full Ranking trên toàn bộ catalog vượt khả năng của phần cứng (GPU 4 GB, RAM 16 GB).
- **Ngưỡng k -core = 10:** Chọn vì giới hạn bộ nhớ thay vì ngưỡng chuẩn $k = 5$; dữ liệu sau lọc thiên về khách mua nhiều, nên kết quả chưa đại diện cho khách ít giao dịch.
- **Dữ liệu thừa:** 201.801 cặp huấn luyện (209.212 khi gộp tập xác thực để huấn luyện lại); các mô hình nơ-ron đạt đỉnh sau 1–9 epoch. Khi huấn luyện lại trên tập huấn luyện $\cup$ xác thực, số epoch được lấy từ lần huấn luyện chỉ trên tập huấn luyện vì không còn tập xác thực để dừng sớm.
- **Lịch kế hoạch sau khi xem test:** Bước huấn luyện lại trên tập huấn luyện $\cup$ xác thực được bổ sung sau lần chấm test đầu tiên (mục 3.6). Kết luận thống kê không đổi giữa hai lần chấm, nhưng số liệu của Chương 4 là kết quả sau khi đã xem test một lần.
- **Chỉ 3 seed:** Đủ cho kiểm định theo người dùng nhưng không đủ để kiểm định theo seed; độ lệch chuẩn giữa các seed của mô hình nơ-ron cùng cỡ với chênh lệch giữa các mô hình.
- **Phạm vi mô hình:** Chỉ lọc cộng tác thuần dựa trên ID – chưa dùng thuộc tính sản phẩm, ảnh, văn bản, thông tin khách hàng; chưa mô hình hóa chuỗi hành vi. Baseline mạnh ItemKNN không chạy được do giới hạn bộ nhớ; iALS và mô hình trộn điểm iALS + NeuMF đã bị loại khỏi phạm vi dù cho kết quả validation tốt hơn NeuMF; Late Fusion thuần MF + DNN (trộn điểm GMF và MLP) chưa được thực hiện, nên đề tài chưa so sánh được Early Fusion với Late Fusion; số tầng của tháp MLP chưa được khảo sát.
- **Cold-start tuyệt đối** (người dùng/sản phẩm chưa có giao dịch nào) nằm ngoài khả năng của mô hình; demo chỉ xử lý bằng gợi ý theo luật, được gắn nhãn rõ.
- **Một bộ dữ liệu:** Kết luận chưa được kiểm chứng chéo trên dữ liệu có mật độ và quy mô catalog khác.

5.3 Hướng phát triển

1. **So sánh Early Fusion với Late Fusion và đưa iALS vào đánh giá cuối.**
Thực hiện Late Fusion thuần MF + DNN với cùng thành phần như NeuMF (trộn điểm GMF và MLP huấn luyện riêng, trọng số chọn trên tập xác thực) để so trực tiếp với NeuMF; đồng thời chấm test cho iALS được tune [42] và phép trộn điểm iALS + NeuMF-Scratch – hai mô hình đều vượt NeuMF trên validation – sau khi đăng ký trước, đặc biệt để trả lời liệu NeuMF có giá trị như một thành phần bổ sung cho MF hay không.
2. **Mở rộng quy mô:** Chạy trên toàn bộ H&M (hoặc mẫu lớn hơn với $k = 5$) bằng đánh giá Full Ranking theo lô trên GPU lớn hơn, hoặc Full Ranking trên một mẫu con người dùng cố định.
3. **Tăng số seed** (từ 6 trở lên) để có thể kiểm định cả theo seed, và lặp lại trên một bộ dữ liệu giao dịch thứ hai; quy trình hiện tại tách phần đọc dữ liệu thành adapter riêng nên chỉ cần bổ sung một adapter mới.
4. **Đặc trưng nội dung và đa phương thức:** Tích hợp thuộc tính sản phẩm, ảnh và mô tả văn bản để hỗ trợ sản phẩm ít tương tác và Cold-start – ví dụ Early Fusion vector ẩn của MF với vector BERT của mô tả sản phẩm H&M, hoặc dùng Transformer để hợp nhất nhiều view như hướng của Hồ Thị Linh [9] – với cùng quy trình đánh giá không thiên lệch để đo đúng lợi ích.
5. **Mô hình chuỗi và đồ thị:** Thử SASRec [29] hoặc LightGCN [32] trên cùng giao thức chia theo thời gian, với baseline được tune cùng ngân sách.
6. **Triển khai:** Đóng gói demo bằng Docker, trả demo tới đúng các checkpoint của đánh giá cuối, và dùng tìm kiếm lân cận gần đúng cho MF khi catalog lớn.

5.4 Triển khai thực tế giao diện thực nghiệm

Thiết kế hệ thống demo (mục 3.7) đã được cài đặt thành hệ thống chạy được: nạp lại trọng số đã huấn luyện để suy diễn trực tiếp, tự đối chiếu dữ liệu với lần chạy trước khi nạp, và tính lại $\text{Hit}@K/\text{NDCG}@K$ theo người dùng khớp với kết quả thực nghiệm. Gợi ý cho khách hàng mới dùng luật đơn giản và được gắn nhãn rõ là không phải mô hình NeuMF. Tập Dockerfile đã có nhưng chưa được kiểm tra đầy đủ; đây là công việc tiếp theo nêu ở mục 5.3.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết và phương pháp luận được sử dụng trong dự án kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống.

Mục	Luận điểm	Nguồn
<i>A.1. Tổng quan về Hệ thống gợi ý & Lọc cộng tác</i>		
1.1.1	Vai trò cá nhân hóa gợi ý trong thương mại điện tử	Schafer và cộng sự [6]; Linden và cộng sự [7]
2.1.2	Nền tảng Lọc cộng tác dựa trên bộ nhớ (Memory-based CF, GroupLens, Item-based CF)	Resnick và cộng sự [21]; Sarwar và cộng sự [16]; Su và Khoshgoftaar [20]
1.1.2	Hạn chế của tích vô hướng trong Nhân tử hóa ma trận (Matrix Factorization)	Koren và cộng sự [1]
1.2.2	Bộ dữ liệu H&M Personalized Fashion Recommendations	H&M Group [3]
<i>A.2. Phản hồi ẩn & Kiến trúc Neural Collaborative Filtering</i>		
2.2.4	Xếp hạng cá nhân hóa Bayes (BPR) từ phản hồi ẩn	Rendle và cộng sự [22]
2.3	Khung làm việc NCF và kiến trúc mô hình lai NeuMF (GMF + MLP)	He và cộng sự [2]
2.3.4	Chiến lược hợp nhất Early Fusion và Late Fusion; kiểu lai weighted	Atrey và cộng sự [24]; Liu và cộng sự [25]; Hồ Thị Linh [9]; Burke [17]
3.5.1	Thuật toán tối ưu hóa thích ứng Adam (Pre-training và tinh chỉnh)	Kingma và Ba [11]
2.4.1	Mô hình Wide & Deep và DeepFM trong gợi ý (Feature-rich Deep CTR)	Cheng và cộng sự [18]; Guo và cộng sự [19]
<i>A.3. Xu hướng nghiên cứu hiện đại (2016–2025)</i>		
2.4.2	Kiến trúc hai tháp (Two-Tower) cho truy hồi quy mô lớn	Covington và cộng sự [27]

Mục	Luận điểm	Nguồn
2.4.3	Gợi ý theo chuỗi hành vi (Sequential/Session-based)	Hidasi và cộng sự [28]; Kang và McAuley [29]; Sun và cộng sự [30]
2.4.4	Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)	Wang và cộng sự [31]; He và cộng sự [32]
2.4.5	Biến phân tự mã hóa, học tự giám sát, LLM và Diffusion cho gợi ý	Liang và cộng sự [33]; Wu và cộng sự [34]; Rajput và cộng sự [35]; Wu và cộng sự [36]; Wei và Fang [37]
2.4	Khảo sát cập nhật (2024) về mạng nơ-ron sâu trong Collaborative Filtering	Li và cộng sự [39]; Zhang và cộng sự [38]
<i>A.4. Đánh giá Top-K, Cài đặt & Hướng phát triển</i>		
2.5	Giao thức đánh giá hiệu năng xếp hạng Top-N Recommendation	Cremonesi và cộng sự [43]; He và cộng sự [2]
2.5, 4.4.5	Vấn đề đánh giá bằng mẫu âm lấy mẫu con (Sampled Metrics); chọn Full Ranking	Krichene và Rendle [12]
3.2.5	Chia dữ liệu theo một mốc thời gian chung thay vì Leave-One-Out	Meng và cộng sự [41]
3.6, 4.6	Baseline phải được tinh chỉnh cùng ngân sách; không chọn mô hình trên tập test; MF được tune kỹ vượt NeuMF	Ferrari Dacrema và cộng sự [5]; Rendle và cộng sự [4]
3.6, 4.3	iALS được tinh chỉnh là baseline MF mạnh	Rendle và cộng sự [42]
3.6	Kiểm định Wilcoxon signed-rank, paired bootstrap, hiệu chỉnh Holm	Wilcoxon [13]; Efron và Tibshirani [14]; Holm [15]
1.3	Nền tảng và thư viện tính toán học sâu PyTorch	Paszke và cộng sự [10]
2.5	Đánh giá xếp hạng dựa trên độ đo NDCG	Järvelin và Kekäläinen [8]
2.5.1	Chỉ số ngoài độ chính xác: Novelty (Self-Information)	Vargas và Castells [40]

Ghi chú. Các thông số cấu hình và thiết kế hệ thống trình bày trong Chương 3 và kết

qua thực nghiệm trong Chương 4 do nhóm tác giả tự triển khai và tính toán từ mã nguồn thực nghiệm của dự án.

PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM

Mã nguồn nằm trong thư mục `neumf_project/` của kho mã dự án; hướng dẫn chi tiết (máy cá nhân và Google Colab) ở tệp `README.md`. Các bước tạo ra toàn bộ số liệu của Chương 4:

1. **Dữ liệu:** đặt `transactions_train.csv` của cuộc thi H&M vào `data/raw/hm/`, chạy `python run.py sample-hm` để tạo mẫu `hm500k` (tắt định, khoảng 70 giây).
2. **Tinh chỉnh (chỉ tập xác thực):** `python scripts/10_tune.py --model all`; mỗi cấu hình ghi một dòng vào `audit/tuning_log.csv`, cấu hình tốt nhất vào `audit/best_configs.json`.
3. **Đánh giá cuối trên tập kiểm thử:** `python scripts/11_final.py --reason "..."` (3 seed). Kịch bản từ chối chạy nếu `audit/PREREG.md` chưa được lưu vào git, thiếu lý do hoặc mã nguồn có thay đổi chưa lưu; mỗi lần chấm ghi một dòng vào `audit/test_access_log.csv`.
4. **Kiểm định và biểu đồ:** `python scripts/12_significance.py` rồi `python scripts/13_plot_final.py`.
5. **Phân tích phụ:** `python scripts/14_secondary.py --reason "..."` (phân tầng, beyond-accuracy, Sampled-99, độ trễ; nạp lại trọng số, không huấn luyện lại).
6. **Xuất sang báo cáo:** `python scripts/15_export_report.py` sinh các bảng `content/tables/*.tex`, macro số liệu và chép hình vào `media/figures/final/`; biên dịch lại báo cáo.

Notebook `notebooks/colab_final.ipynb` chạy tuần tự các bước 1 và 3–6 trên Google Colab (GPU T4) với cấu hình đã tinh chỉnh. Nhật ký `audit/test_access_log.csv` liệt kê mọi lần tập kiểm thử được chấm, kèm phiên bản mã nguồn và mã băm cấu hình tương ứng.

TÀI LIỆU THAM KHẢO

Y. Koren, R. Bell, và C. Volinsky, “Matrix Factorization Techniques for Recommender Systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, “Neural Collaborative Filtering,” in *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

H&M Group, *H&M Personalized Fashion Recommendations*, <https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations>, Cuộc thi trên Kaggle, 2022.

S. Rendle, W. Krichene, L. Zhang, và J. Anderson, “Neural Collaborative Filtering vs. Matrix Factorization Revisited,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, “Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

J. B. Schafer, J. A. Konstan, và J. Riedl, “E-Commerce Recommendation Applications,” *Data Mining and Knowledge Discovery*, vol. 5, no. 1-2, pp. 115–153, 2001. DOI: 10.1023/A:1009804230409

G. Linden, B. Smith, và J. York, “Amazon.com Recommendations: Item-to-Item Collaborative Filtering,” *IEEE Internet Computing*, vol. 7, no. 1, pp. 76–80, 2003. DOI: 10.1109/MIC.2003.1167344

K. Järvelin và J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

Hồ Thị Linh, “Multi-Source Integration for Recommendation Systems,” Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

W. Krichene và S. Rendle, “On Sampled Metrics for Item Recommendation,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, “Item-based Collaborative Filtering Recommendation Algorithms,” in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

R. Burke, “Hybrid Recommender Systems: Survey and Experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

H.-T. Cheng và cộng sự, “Wide & Deep Learning for Recommender Systems,” in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS 2016)*, Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, “DeepFM: A Factorization-Machine based Neural Network for CTR Prediction,” in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

X. Su và T. M. Khoshgoftaar, “A Survey of Collaborative Filtering Techniques,” *Advances in Artificial Intelligence*, vol. 2009, pp. 1–19, 2009. DOI: 10.1155/2009/421425

P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, và J. Riedl, “GroupLens: An Open Architecture for Collaborative Filtering of Netnews,” in *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, 1994, pp. 175–186. DOI: 10.1145/192844.192905

S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, “BPR: Bayesian Personalized Ranking from Implicit Feedback,” in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI '09)*, Montreal, QC, Canada, 2009, pp. 452–461.

S. Rendle, “Factorization Machines,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

P. K. Atrey, M. A. Hossain, A. El Saddik, và M. S. Kankanhalli, “Multimodal Fusion for Multimedia Analysis: A Survey,” *Multimedia Systems*, vol. 16, no. 6, pp. 345–379, 2010.

K. Liu, Y. Li, N. Xu, và P. Natarajan, “Learn to Combine Modalities in Multimodal Deep Learning,” *arXiv preprint arXiv:1805.11730*, 2018.

G. Zhou và cộng sự, “Deep Interest Network for Click-Through Rate Prediction,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '18)*, 2018, pp. 1059–1068. DOI: 10.1145/3219819.3219823

P. Covington, J. Adams, và E. Sargin, “Deep Neural Networks for YouTube Recommendations,” in *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys '16)*, 2016, pp. 191–198. DOI: 10.1145/2959100.2959190

B. Hidasi, A. Karatzoglou, L. Baltrunas, và D. Tikk, “Session-based Recommendations with Recurrent Neural Networks,” in *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016.

W.-C. Kang và J. McAuley, “Self-Attentive Sequential Recommendation,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2018, pp. 197–206. DOI: 10.1109/ICDM.2018.00035

F. Sun và cộng sự, “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer,” in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19)*, 2019, pp. 1441–1450. DOI: 10.1145/3357384.3357895

X. Wang, X. He, M. Wang, F. Feng, và T.-S. Chua, “Neural Graph Collaborative Filtering,” in *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '19)*, 2019, pp. 165–174. DOI: 10.1145/3331184.3331267

X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, và M. Wang, “LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '20)*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063

D. Liang, R. G. Krishnan, M. D. Hoffman, và T. Jebara, “Variational Autoencoders for Collaborative Filtering,” in *Proceedings of the 2018 World Wide Web Conference (WWW '18)*, 2018, pp. 689–698. DOI: 10.1145/3178876.3186150

J. Wu và cộng sự, “Self-supervised Graph Learning for Recommendation,” in *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '21)*, 2021, pp. 726–735. DOI: 10.1145/3404835.3462862

S. Rajput và cộng sự, “Recommender Systems with Generative Retrieval,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.

L. Wu và cộng sự, “A Survey on Large Language Models for Recommendation,” *World Wide Web*, vol. 27, no. 60, 2024. DOI: 10.1007/s11280-024-01291-2

T.-R. Wei và Y. Fang, “Diffusion Models in Recommendation Systems: A Survey,” *arXiv preprint arXiv:2501.10548*, 2025.

S. Zhang, L. Yao, A. Sun, và Y. Tay, “Deep Learning Based Recommender System: A Survey and New Perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029

P. Li, S. A. Mohd Noah, và H. Mohd Sarim, “A Survey on Deep Neural Networks in Collaborative Filtering Recommendation Systems,” *arXiv preprint arXiv:2412.01378*, 2024.

S. Vargas và P. Castells, “Rank and Relevance in Novelty and Diversity Metrics for Recommender Systems,” in *Proceedings of the 5th ACM Conference on Recommender Systems (RecSys '11)*, 2011, pp. 109–116. DOI: 10.1145/2043932.2043955

Z. Meng, R. McCreddie, C. Macdonald, và I. Ounis, “Exploring Data Splitting Strategies for the Evaluation of Recommendation Models,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020. DOI: 10.1145/3383313.3418479

S. Rendle, W. Krichene, L. Zhang, và Y. Koren, “Revisiting the Performance of iALS on Item Recommendation Benchmarks,” in *Proceedings of the 16th ACM Conference on Recommender Systems (RecSys '22)*, 2022. DOI: 10.1145/3523227.3548486

P. Cremonesi, Y. Koren, và R. Turrin, “Performance of Recommender Algorithms on Top-N Recommendation Tasks,” in *Proceedings of the 4th ACM Conference on Recommender Systems (RecSys)*, 2010, pp. 39–46. DOI: 10.1145/1864708.1864721