TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chỉn chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khoẻ, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan đây là công trình nghiên cứu của riêng chúng tôi và được sự hướng dẫn khoa học của TS. Hồ Thị Linh. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do chúng tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026
Tác giả
(Ký tên và ghi rõ họ tên)

Lê Minh Lý **Sử Thị Yến Linh**

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Khuyến nghị sản phẩm thời trang trên dữ liệu giao dịch thực tế gặp hai khó khăn. Ma trận tương tác giữa khách hàng và sản phẩm rất thưa, trong khi nhân tử hoá ma trận (MF) chỉ học từ mã khách hàng và mã sản phẩm qua một tích vô hướng tuyến tính. Đề tài xây dựng NeuMF-F, một mô hình lai giữ cấu trúc hai nhánh của Neural Matrix Factorization (NeuMF): nhánh nhân tử hoá ma trận tổng quát (GMF) và nhánh perceptron đa tầng (MLP). Mỗi khách hàng và sản phẩm được biểu diễn bằng vector nhúng mã định danh cộng với một phép chiếu của đặc trưng, gồm thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng, doanh số gần đây và nhịp mua của khách.

Mô hình được đánh giá trên bộ dữ liệu giao dịch thời trang H&M. Dữ liệu được chia theo thời gian, đặc trưng chỉ dùng thông tin trước thời điểm dự đoán, và cấu hình được chọn trên một mẫu khách hàng riêng. Kết quả cuối được đánh giá trên một mẫu khách hàng độc lập, theo kế hoạch đăng ký trước và có kiểm định thống kê. NeuMF-F được so sánh với các mô hình đối chứng thuộc ba nhóm, tất cả được tinh chỉnh với cùng ngân sách.

NeuMF-F vượt có ý nghĩa thống kê các mô hình đối chứng được tinh chỉnh đầy đủ, và kết quả này lặp lại trên bộ dữ liệu Amazon Beauty. Kết luận chính là bổ sung đặc trưng giúp mô hình khuyến nghị tốt hơn rõ rệt so với khi chỉ dùng mã định danh, trong đó đặc trưng thời gian đóng góp nhiều nhất. Các mô hình có đặc trưng dẫn đầu trên cả hai bộ dữ liệu với cả hai cách hợp nhất sớm và muộn. Đề tài cũng xây dựng một hệ thống demo minh hoạ khuyến nghị cho từng khách hàng.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Recommending fashion products from real transaction data faces two difficulties. The interaction matrix between customers and items is very sparse, while matrix factorization (MF) learns only from customer and item identifiers through a linear inner product. This project builds NeuMF-F, a hybrid model that keeps the two-branch structure of Neural Matrix Factorization (NeuMF): a generalized matrix factorization (GMF) branch and a multi-layer perceptron (MLP) branch. Every customer and item is represented by an identifier embedding plus a projection of features, namely item attributes and text descriptions, customer information, recent sales and the customer's purchase rhythm.

The model is evaluated on the H&M fashion transaction dataset. Data are split by time, features use only information available before the prediction time, and configurations are selected on a separate customer sample. Final results are measured on an independent customer sample under a pre-registered plan with statistical testing. NeuMF-F is compared with baselines from three groups, all tuned with the same budget.

NeuMF-F significantly outperforms the fully tuned baselines, and this result holds again on the Amazon Beauty dataset. The main conclusion is that adding features clearly improves recommendation quality over using identifiers alone, with temporal features contributing the most. The feature-augmented models lead on both datasets under both early and late fusion. The project also builds a demo system that illustrates the recommendations for each customer.

MỤC LỤC

DANH MỤC HÌNH VẼ ..... **x**

DANH MỤC BẢNG BIỂU ..... **xi**

DANH MỤC CÁC CHỮ VIẾT TẮT ..... **xii**

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI **1**

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài 1

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài *1*

1.1.2 Hạn chế của nhân tử hoá ma trận truyền thống *1*

1.1.3 Lựa chọn mô hình và câu hỏi nghiên cứu *2*

1.2 Mục tiêu và phạm vi nghiên cứu 3

1.2.1 Mục tiêu nghiên cứu *3*

1.2.2 Phạm vi nghiên cứu *3*

1.3 Phương pháp nghiên cứu 4

1.4 Ý nghĩa khoa học và thực tiễn của đề tài 5

1.4.1 Ý nghĩa khoa học *5*

1.4.2 Ý nghĩa thực tiễn *5*

1.5 Bố cục của báo cáo 5

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN **7**

2.1 Tổng quan về hệ khuyến nghị 7

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai *7*

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình *8*

2.1.3 Phản hồi ẩn *9*

2.1.4 Độ thưa dữ liệu và vấn đề cold start *10*

2.2 Lọc cộng tác và nhân tử hoá ma trận 10

2.2.1 Mô hình nhân tử hoá ma trận *10*

2.2.2 Hạn chế của tích vô hướng *11*

2.2.3 Tối ưu thứ hạng theo cặp: BPR *11*

2.3 Kiến trúc lọc cộng tác bằng mạng lưới thần kinh (NCF) 11
2.3.1 Generalized Matrix Factorization (GMF) 11
2.3.2 Multi-Layer Perceptron (MLP) 12
2.3.3 Mô hình lai NeuMF 12
2.3.4 Hợp nhất sớm và hợp nhất muộn 13
2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân 15
2.4 Các hướng nghiên cứu gần đây 15
2.4.1 Mô hình lai dựa trên đặc trưng 15
2.4.2 Các hướng ngoài phạm vi đề tài 16
2.4.3 Lý do chọn kiến trúc hai nhánh 17
2.5 Các độ đo đánh giá Top-K 17
2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu 18
2.5.2 Độ đo ngoài độ chính xác 18
2.6 Ba nghiên cứu nền tảng 19
2.7 Khoảng trống nghiên cứu 21
2.8 Tóm tắt chương 22
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F 23
3.1 Quy trình tổng thể của hệ thống 23
3.2 Dữ liệu và tiền xử lý 25
3.2.1 Đặc tả bộ dữ liệu H&M 25
3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định 26
3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử 26
3.2.4 Giai đoạn đánh giá và tập ứng viên 28
3.2.5 Xây dựng đặc trưng theo thời điểm 30
3.3 Thiết kế mô hình lai NeuMF-F 31
3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng 32
3.3.2 Nhánh GMF-F 33

3.3.3 Nhánh MLP-F *34*
3.3.4 Lớp hợp nhất và lớp dự đoán *34*
3.4 Mô hình đối chứng 34
3.4.1 Các mô hình cài đặt trên cùng khung với NeuMF-F *35*
3.4.2 Các mô hình đối chứng còn lại *36*
3.5 Lấy mẫu âm theo thời điểm và hàm mục tiêu 37
3.5.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm *37*
3.5.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn *38*
3.6 Quy trình huấn luyện và tinh chỉnh 38
3.6.1 Không gian tinh chỉnh và dừng sớm *38*
3.7 Quy trình đánh giá không thiên lệch 40
3.7.1 Khảo sát ban đầu và định hướng thiết kế *40*
3.7.2 Các nguyên tắc đánh giá *40*
3.8 Suy luận Top-K và xử lý khách hàng mới 45
3.9 Thiết kế hệ thống demo 46
3.9.1 Kiến trúc ba tầng *46*
3.9.2 Thiết kế API suy luận *47*
3.9.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng *48*
3.9.4 Minh hoạ hệ thống demo *49*
3.10 Tóm tắt chương 54
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 56
4.1 Cấu hình thực nghiệm 56
4.2 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển 56
4.3 Kết quả đánh giá cuối trên mẫu kiểm định 58
4.3.1 So sánh các độ đo xếp hạng *58*
4.3.2 Kết quả theo $K = 5, 10, 15, 20$ *60*
4.3.3 Kiểm định ý nghĩa thống kê *62*
4.3.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống *64*

4.3.5 Phân tích bóc tách thành phần *65*
4.3.6 Độ phủ và chi phí huấn luyện *66*
4.3.7 Hội tụ và độ ổn định giữa hai mẫu *67*
4.4 Kiểm chứng trên dữ liệu Amazon Beauty 68
4.4.1 Dữ liệu và thiết lập kiểm chứng *68*
4.4.2 Kết quả trên tập kiểm thử Amazon Beauty *71*
4.4.3 Đối chiếu kết luận giữa H&M và Amazon Beauty *76*
4.4.4 Phân tích bóc tách và độ phủ trên Amazon Beauty *78*
4.5 Phạm vi của kết luận 79
4.6 Thảo luận và trả lời câu hỏi nghiên cứu 79
4.7 Tóm tắt chương 80
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 82
5.1 Kết quả đạt được 82
5.2 Kết luận 83
5.3 Hạn chế của đề tài 83
5.4 Hướng phát triển 84
TÀI LIỆU THAM KHẢO 86

DANH MỤC HÌNH VẼ

Hình 2.1: Kiến trúc NeuMF 13
Hình 2.2: Hợp nhất sớm và hợp nhất muộn 15

Hình 3.1: Đường ống của hệ thống khuyến nghị 24
Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F 32
Hình 3.3: Quy trình tinh chỉnh và đánh giá cuối 43
Hình 3.4: Kiến trúc ba tầng của hệ thống demo 47
Hình 3.5: Giao diện demo: cửa hàng mô phỏng, đã hiện các món khách mua sau mốc 50
Hình 3.6: Giao diện demo: thẻ chi tiết sản phẩm và sản phẩm tương tự 51
Hình 3.7: Giao diện demo: khách có gu giống khách đang xem 51
Hình 3.8: Giao diện demo: khuyến nghị cho khách hàng mới 52
Hình 3.9: Giao diện demo: màn hình kết quả đánh giá 53
Hình 3.10: Giao diện demo: màn hình giới thiệu đề tài 54

Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử H&M 60
Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh trên H&M 64
Hình 4.3: Phân tích bóc tách NeuMF-F trên H&M 66
Hình 4.4: Đường hội tụ của các mạng lưới thần kinh khi chọn số epoch 68
Hình 4.5: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối 68
Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty 73

DANH MỤC BẢNG BIỂU

Bảng 2.1: Ba nghiên cứu nền tảng và thiết lập của đề tài 20

Bảng 3.1: Lọc k-core trên toàn bộ dữ liệu H&M 25
Bảng 3.2: Lọc k-core trên mẫu phát triển 28
Bảng 3.3: Quy mô dữ liệu H&M 30
Bảng 3.4: Đặc trưng đầu vào trên H&M 31
Bảng 3.5: Ba nhóm mô hình đối chứng 35
Bảng 3.6: Không gian tinh chỉnh 39
Bảng 3.7: Các điểm cuối của API suy luận 48

Bảng 4.1: Cấu hình tốt nhất trên tập xác thực 57
Bảng 4.2: Các cách kết hợp của Hybrid-CBCF 58
Bảng 4.3: Kết quả trên tập kiểm thử H&M 59
Bảng 4.4: NDCG@K và Recall@K trên H&M 61
Bảng 4.5: HR@K và Precision@K trên H&M 62
Bảng 4.6: Kiểm định họ 10 so sánh trên H&M 63
Bảng 4.7: Kiểm định bổ sung với Hybrid-CBCF trên H&M 64
Bảng 4.8: Phân tích bóc tách NeuMF-F trên H&M 65
Bảng 4.9: Độ phủ top-10 và chi phí huấn luyện trên H&M 67
Bảng 4.10: Đặc trưng trên H&M và Amazon Beauty 70
Bảng 4.11: Quy mô dữ liệu Amazon Beauty 71
Bảng 4.12: Kết quả trên tập kiểm thử Amazon Beauty 72
Bảng 4.13: NDCG@K và Recall@K trên Amazon Beauty 74
Bảng 4.14: HR@K và Precision@K trên Amazon Beauty 75
Bảng 4.15: Kiểm định bổ sung với Hybrid-CBCF trên Amazon Beauty 75
Bảng 4.16: Kiểm định họ 10 so sánh trên Amazon Beauty 77
Bảng 4.17: Kết luận họ 10 so sánh trên H&M và Amazon Beauty 78
Bảng 4.18: Phân tích bóc tách NeuMF-F trên Amazon Beauty 79

Bảng 5.1: Mức độ hoàn thành mục tiêu 82

DANH MỤC CÁC CHỮ VIẾT TẮT

API	Application Programming Interface (Giao diện lập trình ứng dụng)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hoá Bayes)
CBCF	Content-Based and Collaborative Filtering (Kết hợp lọc nội dung và lọc cộng tác; Hybrid-CBCF: mô hình lai truyền thống)
CF	Collaborative Filtering (Lọc cộng tác)
CI	Confidence Interval (Khoảng tin cậy)
CPU	Central Processing Unit (Bộ xử lý trung tâm)
DCG	Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu)
DNN	Deep Neural Network (Mạng lưới thần kinh sâu)
FM	Factorization Machines (Máy nhân tử hoá)
GMF	Generalized Matrix Factorization (Nhân tử hoá ma trận tổng quát)
HR	Hit Ratio (Tỉ lệ trúng)
IDCG	Ideal Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu lý tưởng)
ItemKNN	Item-based k-Nearest Neighbors (Lọc cộng tác theo k sản phẩm láng giềng gần nhất)
MAE	Mean Absolute Error (Sai số tuyệt đối trung bình)
MF	Matrix Factorization (Nhân tử hoá ma trận)
MLP	Multi-Layer Perceptron (Perceptron đa tầng)

NCF	Neural Collaborative Filtering (Lọc cộng tác bằng mạng lưới thần kinh)
NDCG	Normalized Discounted Cumulative Gain (Lợi ích tích luỹ có chiết khấu chuẩn hoá)
NeuMF	Neural Matrix Factorization (Nhân tử hoá ma trận bằng mạng lưới thần kinh)
NeuMF-F	NeuMF bổ sung đặc trưng (mô hình đề xuất; GMF-F, MLP-F: hai nhánh có đặc trưng)
ReLU	Rectified Linear Unit (Đơn vị tuyến tính chỉnh lưu)
RMSE	Root Mean Square Error (Căn bậc hai sai số bình phương trung bình)
SVD	Singular Value Decomposition (Phân tích giá trị suy biến)
TF-IDF	Term Frequency–Inverse Document Frequency (Tần suất từ nhân nghịch đảo tần suất văn bản)
UserKNN	User-based k-Nearest Neighbors (Lọc cộng tác theo k người dùng láng giềng gần nhất)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

Chương này giới thiệu bài toán khuyến nghị sản phẩm trên dữ liệu thời trang H&M, lý do nhóm chọn hướng mô hình lai có bổ sung đặc trưng, các câu hỏi nghiên cứu, mục tiêu, phạm vi và phương pháp thực hiện đề tài.

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài

Trong bán lẻ trực tuyến, hệ khuyến nghị (*recommender system*, còn gọi là hệ gợi ý) giúp mỗi khách tìm được sản phẩm phù hợp giữa hàng chục nghìn mặt hàng, đồng thời giúp doanh nghiệp tăng doanh số. Với hàng thời trang, bài toán khó hơn vì danh mục thay đổi liên tục theo mùa. Đề tài xuất phát từ bộ dữ liệu H&M Personalized Fashion Recommendations [1], do tập đoàn H&M công bố để tìm giải pháp khuyến nghị sản phẩm cho khách hàng của mình. Tệp giao dịch gốc có khoảng 31,8 triệu lượt mua của 1,36 triệu khách hàng trên 104.547 sản phẩm thời trang trong hai năm.

Khi khảo sát dữ liệu, nhóm nhận thấy hai đặc điểm gây khó cho hệ khuyến nghị. Đặc điểm đầu tiên là ma trận tương tác rất thưa. Mỗi khách chỉ mua một phần rất nhỏ của danh mục, nên kể cả sau khi lọc k-core, mật độ ma trận chỉ khoảng 0,03–0,05%. Đặc điểm thứ hai là nhu cầu thời trang thay đổi nhanh theo mùa và theo xu hướng. Sản phẩm bán chạy trong vài tuần gần đây chưa chắc là sản phẩm bán nhiều nhất trong hai năm.

Bên cạnh lịch sử mua, bộ dữ liệu còn có thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng và ngày mua. Một mô hình chỉ học từ mã khách hàng và mã sản phẩm sẽ bỏ qua toàn bộ các thông tin này. Vì vậy nhóm chọn hướng xây dựng một mô hình lai giữa nhân tử hoá ma trận (*matrix factorization*, MF) và mạng lưới thần kinh sâu (*deep neural network*, DNN), còn gọi là mạng nơ-ron sâu, có khai thác thêm đặc trưng của sản phẩm, khách hàng và thời gian. Dữ liệu được chia theo thời gian để mô hình không dùng thông tin tương lai.

1.1.2 Hạn chế của nhân tử hoá ma trận truyền thống

Cách tiếp cận cơ bản cho lọc cộng tác (*collaborative filtering*, CF) là MF [6]. Mỗi người dùng u và sản phẩm i được gán một vector ẩn $p_u, q_i \in \mathbb{R}^d$, và mức độ quan

tâm được dự đoán bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{1.1}$$

Trên dữ liệu H&M, công thức này có hai hạn chế. Hạn chế thứ nhất nằm ở biểu diễn. Tích vô hướng cộng các chiều ẩn với trọng số như nhau nên chỉ mô hình hoá được tương tác tuyến tính; He và cộng sự [3] lấy đây làm động cơ để bổ sung một thành phần phi tuyến. Hạn chế thứ hai nằm ở thông tin. Vector q_i chỉ học được từ các lần sản phẩm i được mua, nên sản phẩm ít người mua có biểu diễn kém tin cậy. Hạn chế này không khắc phục được bằng cách tăng số chiều hay số epoch, mà cần bổ sung thông tin về sản phẩm và khách hàng.

1.1.3 Lựa chọn mô hình và câu hỏi nghiên cứu

NeuMF khắc phục hạn chế về biểu diễn bằng hai nhánh chạy song song. Nhánh GMF (*generalized matrix factorization*) học tương tác tuyến tính qua tích từng phần tử của hai vector ẩn. Nhánh MLP (*multi-layer perceptron*) học tương tác phi tuyến. Hai nhánh được ghép ở lớp dự đoán. Tuy nhiên NeuMF vẫn chỉ học từ mã ID, nên chưa giải quyết được hạn chế về thông tin. Khảo sát ban đầu của nhóm cũng cho thấy NeuMF chỉ dùng mã ID không vượt được MF đã tinh chỉnh trên dữ liệu H&M.

Từ đó nhóm xây dựng mô hình đề xuất NeuMF-F. Mô hình giữ nguyên hai nhánh GMF và MLP, nhưng biểu diễn mỗi khách hàng và sản phẩm bằng tổng của vector nhúng (*embedding*) mã ID và một phép chiếu tuyến tính của đặc trưng. Đặc trưng gồm thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng, doanh số gần đây của sản phẩm và nhịp mua của khách. Chữ "F" (*features*) trong tên mô hình chỉ phần đặc trưng này.

Đề tài đặt ra ba câu hỏi nghiên cứu. Mỗi câu hỏi được trả lời bằng một phép so sánh trực tiếp, nhờ cấu trúc hai nhánh tường minh của NeuMF-F.

Câu hỏi 1: NeuMF-F có khuyến nghị tốt hơn các mô hình đối chứng (*baseline*) được tinh chỉnh đầy đủ không?

Câu hỏi 2: Bổ sung đặc trưng có giúp mô hình lai không, và nhóm đặc trưng nào đóng góp nhiều nhất? Câu hỏi này được trả lời bằng cách so NeuMF-F với NeuMF chỉ dùng mã ID và bằng phân tích bóc tách.

Câu hỏi 3: Ghép hai nhánh có tốt hơn từng nhánh đứng riêng không, và hợp nhất sớm hay hợp nhất muộn phù hợp hơn? Câu hỏi này được trả

lời bằng cách so NeuMF-F với hai nhánh GMF-F, MLP-F và với LateFusion-F, mô hình hợp nhất muộn của cùng hai nhánh.

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

Để trả lời ba câu hỏi trên, đề tài đặt ra năm mục tiêu.

(1) Hệ thống hoá cơ sở lý thuyết về lọc cộng tác, nhân tử hoá ma trận, mạng lưới thần kinh sâu, kiến trúc NeuMF, mô hình lai dựa trên đặc trưng và hai cách hợp nhất mô hình là hợp nhất sớm (*early fusion*) và hợp nhất muộn (*late fusion*).

(2) Xây dựng quy trình xử lý dữ liệu H&M gồm lấy mẫu theo khách hàng, dựng ma trận tương tác từ phản hồi ẩn (*implicit feedback*), chia dữ liệu theo thời gian và tính đặc trưng theo thời điểm, không dùng thông tin xảy ra sau thời điểm dự đoán.

(3) Cài đặt mô hình đề xuất NeuMF-F và các mô hình đối chứng thuộc ba nhóm: mô hình đơn lẻ, học máy truyền thống và chuyên biệt cho khuyến nghị. Mọi mô hình được tinh chỉnh siêu tham số (*hyperparameter tuning*) với cùng ngân sách.

(4) Đánh giá bằng cách xếp hạng toàn bộ (*full ranking*) tập ứng viên, với các độ đo NDCG@K, Recall@K, HR@K và Precision@K ở $K = 5, 10, 15, 20$. Kết luận được lấy trên một mẫu khách hàng độc lập, có kiểm định thống kê qua 5 giá trị khởi tạo ngẫu nhiên (*seed*), rồi được kiểm chứng trên bộ dữ liệu thứ hai là Amazon Beauty.

(5) Xây dựng hệ thống demo minh hoạ khuyến nghị của các mô hình cho từng khách hàng, luôn trả về khuyến nghị kể cả với khách hàng mới.

Trong báo cáo, "tinh chỉnh" luôn có nghĩa là tìm siêu tham số, không phải tinh chỉnh một mô hình đã huấn luyện trước (*fine-tuning*).

1.2.2 Phạm vi nghiên cứu

Đối tượng nghiên cứu là kiến trúc NCF (GMF, MLP, NeuMF), mở rộng có đặc trưng của nó (NeuMF-F), hai cách hợp nhất nhân tử hoá ma trận với mạng lưới thần kinh sâu và các phương pháp đánh giá hệ khuyến nghị Top-K.

Dữ liệu chính là bộ H&M, gồm tệp giao dịch, tệp danh mục sản phẩm và tệp

thông tin khách hàng. Khảo sát quy mô dùng toàn bộ 31,8 triệu giao dịch. Huấn luyện và đánh giá dùng hai mẫu khách hàng: mẫu phát triển (*development sample*) để chọn cấu hình và mẫu kiểm định (*holdout sample*) để đánh giá cuối. Mỗi mẫu gồm khoảng 500.000 giao dịch của khoảng 21.000 khách hàng chọn ngẫu nhiên theo hàm băm. Hai mẫu không có khách chung và giữ trọn lịch sử hai năm của mỗi khách. Mỗi sản phẩm là một mẫu thiết kế (`product_code`), tức mọi màu của cùng một mẫu được gộp lại. Ảnh sản phẩm không được dùng làm đầu vào của mô hình. Để kiểm chứng, toàn bộ đánh giá cuối được thực hiện lại trên bộ Amazon Beauty [2] với cấu hình đã chọn trên H&M.

Tín hiệu tương tác là phản hồi ẩn nhị phân từ lịch sử mua hàng (đã mua hoặc chưa mua), kèm ngày mua.

Bài toán *cold start*, tức khuyến nghị cho khách hàng hoặc sản phẩm chưa có lịch sử tương tác, nằm ngoài phạm vi đánh giá định lượng. Khi hệ thống được sử dụng, khách hàng mới nhận danh sách sản phẩm phổ biến, còn khách đã có lịch sử mua nhận khuyến nghị của mô hình đề xuất.

1.3 Phương pháp nghiên cứu

Đề tài được thực hiện qua bốn bước. Trước hết, nhóm tổng hợp tài liệu về lọc cộng tác, nhân tử hoá ma trận, kiến trúc NeuMF và mô hình lai dựa trên đặc trưng, đồng thời khảo sát các hướng nghiên cứu gần đây để xác định vị trí của đề tài.

Tiếp theo, nhóm xây dựng quy trình tiền xử lý tái lập được và kiểm chứng được ở từng bước. Quy trình gồm lấy mẫu theo khách hàng, gộp giao dịch, lọc k-core chỉ trên dữ liệu trước mốc kiểm thử, chia giai đoạn theo thời gian và tính đặc trưng theo thời điểm.

Sau đó, nhóm cài đặt các mô hình, huấn luyện bằng hàm mất mát entropy chéo nhị phân (*binary cross-entropy*, BCE) với lấy mẫu âm (*negative sampling*) theo thời điểm. Mọi mô hình được tinh chỉnh với cùng ngân sách tính toán, chỉ dựa trên tập xác thực (*validation set*) của mẫu phát triển.

Cuối cùng, nhóm đánh giá các mô hình bằng cách xếp hạng toàn bộ tập ứng viên trên mẫu kiểm định, theo kế hoạch đã đăng ký trước (*pre-registration*). Kết luận được lấy bằng kiểm định dấu hạng Wilcoxon (*Wilcoxon signed-rank test*) ghép cặp theo người dùng, khoảng tin cậy (*confidence interval*, CI) bootstrap và hiệu chỉnh Holm cho đa so sánh, rồi được kiểm chứng trên Amazon Beauty.

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

- Đề tài xây dựng và đánh giá một mô hình lai giữa MF và DNN có bổ sung đặc trưng trên dữ liệu giao dịch thời trang thực tế, với kết luận có kiểm định thống kê và được kiểm chứng trên bộ dữ liệu thứ hai.
- Thiết kế đối chứng theo từng thành phần cho phép tách được phần cải thiện đến từ đặc trưng và phần đến từ cách ghép hai nhánh MF và DNN, qua đó chỉ ra nhóm thông tin nào có giá trị nhất cho bài toán khuyến nghị thời trang.
- Kết quả của đề tài bổ sung bằng chứng cho nhận định của các nghiên cứu tái đánh giá rằng mô hình lai chỉ dùng mã ID khó vượt nhân tử hoá ma trận được tinh chỉnh kỹ, lần này trên dữ liệu giao dịch thời trang.
- Đề tài xây dựng một quy trình đánh giá hạn chế thiên lệch, dùng lại được cho các nghiên cứu hệ khuyến nghị khác. Trong quy trình này, đặc trưng được tính theo thời điểm, mọi mô hình được tinh chỉnh với cùng ngân sách, và kết luận được lấy trên mẫu kiểm định độc lập theo kế hoạch đăng ký trước.

1.4.2 Ý nghĩa thực tiễn

- Mô hình chỉ dùng dữ liệu mà doanh nghiệp bán lẻ sẵn có: lịch sử giao dịch, danh mục sản phẩm, thông tin hội viên và doanh số theo ngày. Mọi đặc trưng được tính theo thời điểm, nên cách huấn luyện và chấm điểm dùng được nguyên khi triển khai.
- Kết quả của đề tài chỉ ra loại dữ liệu nào doanh nghiệp nên ưu tiên thu thập và cập nhật để cải thiện khuyến nghị.
- Quy trình xử lý dữ liệu áp dụng được cho bộ dữ liệu thương mại điện tử khác, như đã làm với Amazon Beauty.
- Hệ thống demo cho phép so sánh trực quan các mô hình trên từng khách hàng và luôn trả về khuyến nghị, kể cả với khách hàng mới.

1.5 Bố cục của báo cáo

Báo cáo gồm năm chương.

- Chương 1 trình bày bối cảnh, câu hỏi nghiên cứu, mục tiêu, phạm vi, phương

pháp và ý nghĩa của đề tài.

- Chương 2 trình bày cơ sở lý thuyết về hệ khuyến nghị, nhân tử hoá ma trận, kiến trúc NCF và NeuMF, các cách hợp nhất mô hình, mô hình lai, các độ đo đánh giá và ba nghiên cứu nền tảng.
- Chương 3 trình bày dữ liệu, cách chia giai đoạn, đặc trưng theo thời điểm, kiến trúc NeuMF-F, các mô hình đối chứng, cách huấn luyện, quy trình đánh giá, cách suy luận (*inference*) và hệ thống demo.
- Chương 4 trình bày kết quả thực nghiệm trên H&M và Amazon Beauty, rồi trả lời lần lượt ba câu hỏi nghiên cứu.
- Chương 5 đánh giá mức độ hoàn thành mục tiêu, tổng kết các kết luận chính, nêu hạn chế và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

Chương 1 đã nêu bài toán và ba câu hỏi nghiên cứu. Chương này trình bày cơ sở lý thuyết cần để trả lời các câu hỏi đó, gồm các hướng tiếp cận của hệ khuyến nghị, các mô hình được dùng trong đề tài, các độ đo đánh giá và những công trình liên quan. Các công trình được dẫn là cơ sở về phương pháp, gồm định nghĩa mô hình, cách huấn luyện và cách đánh giá. Thực nghiệm trong các công trình đó dùng dữ liệu và giao thức khác, nên số liệu của chúng không được dùng làm chuẩn so sánh với kết quả của đề tài.

2.1 Tổng quan về hệ khuyến nghị

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai

Hệ khuyến nghị có ba hướng tiếp cận chính, khác nhau ở loại thông tin được dùng. Lọc dựa trên nội dung (*content-based filtering*) nhìn vào bản thân sản phẩm: khách vừa mua một chiếc áo len sẽ được khuyến nghị những mẫu có loại hàng, nhóm hàng hay mô tả gần với chiếc áo đó [7]. Lọc cộng tác (*collaborative filtering*, CF) không đọc mô tả mà nhìn vào hành vi của nhiều khách cùng lúc: nếu nhiều người đã mua chung hai mẫu quần, khách mua mẫu thứ nhất có khả năng cũng quan tâm mẫu thứ hai [8]. Hướng này cần đủ lượt mua để so sánh khách với nhau, nên kém đi khi ma trận tương tác thưa. Lọc lai (*hybrid filtering*) dùng cả hai nguồn thông tin để hướng này bù chỗ yếu của hướng kia.

Trước khi có học sâu, hệ khuyến nghị lai được ghép từ các kỹ thuật truyền thống. Burke [9] phân loại bảy cách lai:

- Lai có trọng số (*weighted*): cộng có trọng số điểm của nhiều kỹ thuật.
- Lai chuyển đổi (*switching*): chọn một kỹ thuật tuỳ tình huống.
- Lai hỗn hợp (*mixed*): trình bày đồng thời khuyến nghị của nhiều kỹ thuật.
- Kết hợp đặc trưng (*feature combination*): dùng dữ liệu của kỹ thuật này làm đặc trưng cho kỹ thuật kia.
- Lai phân tầng (*cascade*): kỹ thuật sau tinh chỉnh kết quả của kỹ thuật trước.
- Tăng cường đặc trưng (*feature augmentation*): đầu ra của kỹ thuật này làm đầu vào cho kỹ thuật kia.

– Lai mức mô hình (*meta-level*): mô hình học được của kỹ thuật này làm đầu vào cho kỹ thuật kia.

Dựa trên cách phân loại này, Chương 3 luận án của Hồ Thị Linh [4] xây dựng một mô hình lai từ ba thành phần: lọc nội dung, lọc cộng tác theo người dùng (UserKNN) và lọc cộng tác theo sản phẩm (ItemKNN). Điểm dự đoán của các thành phần được tổng hợp qua một mạng truyền thẳng để học trọng số phi tuyến. Đề tài dùng lại ý tưởng này, đổi hàm mục tiêu sang học theo cặp cho phản hồi ẩn, và làm mô hình lai truyền thống trong nhóm đối chứng (Hybrid-CBCF). So sánh NeuMF-F với Hybrid-CBCF cho biết lợi ích của việc hợp nhất biểu diễn bằng mạng lưới thần kinh so với việc ghép điểm của các kỹ thuật truyền thống.

Đề tài chọn hướng lai vì đặc điểm của dữ liệu H&M. Lịch sử hai năm đủ dài để lọc cộng tác học được sở thích của khách mua thường xuyên. Nhưng danh mục thời trang thay đổi liên tục, nhiều sản phẩm có ít lượt mua, và lọc cộng tác chỉ dùng mã ID khó khuyến nghị tốt các sản phẩm này. Bộ dữ liệu lại có sẵn mô tả văn bản, nhóm hàng và doanh số theo ngày. Vì vậy lõi của mô hình là lọc cộng tác dựa trên mô hình, kết hợp nhân tử hoá ma trận với mạng lưới thần kinh sâu, được bổ sung đặc trưng nội dung và thời gian.

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình

Theo cách khai thác dữ liệu tương tác, lọc cộng tác chia thành hai nhánh.

Nhánh dựa trên bộ nhớ (*memory-based*) giữ nguyên ma trận tương tác và so trực tiếp các hàng hoặc các cột của nó. Hai khách được coi là giống nhau nếu đã mua nhiều sản phẩm chung, và hai sản phẩm giống nhau nếu có nhiều người cùng mua. Cách làm này không có tham số nào phải học. Hướng tiếp cận này đã có từ hệ thống GroupLens [10]. Với lọc cộng tác theo sản phẩm (ItemKNN) [11], độ tương đồng cosine giữa hai sản phẩm i và j được tính trên vector cột tương tác của chúng:

$$\text{sim}(i, j) = \cos(\vec{i}, \vec{j}) = \frac{\vec{i} \cdot \vec{j}}{\|\vec{i}\| \, \|\vec{j}\|} \tag{2.1}$$

Với phản hồi ẩn nhị phân, điểm của sản phẩm i đối với người dùng u là tổng độ tương đồng giữa i và các sản phẩm u đã mua, chỉ xét k láng giềng gần nhất (*nearest neighbors*) $\mathcal{N}_k(i)$ của i:

$$\hat{y}_{ui} = \sum_{j \in \mathcal{N}_k(i) \cap \mathcal{I}_u} \text{sim}(i, j) \tag{2.2}$$

Lọc cộng tác theo người dùng (UserKNN) làm đối xứng. Mô hình tìm k người dùng

có lịch sử mua giống u nhất, ký hiệu $\mathcal{N}_k(u)$, rồi tính điểm mỗi sản phẩm bằng tổng độ tương đồng của các láng giềng đã mua sản phẩm đó:

$$\hat{y}_{ui} = \sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v)\, y_{vi} \tag{2.3}$$

Trong cài đặt của đề tài, độ tương đồng cosine được tính trên vector mua nhị phân. Mẫu số có thêm hệ số co (*shrinkage*) λ để giảm trọng số của các cặp có quá ít tương tác chung: $\text{sim}(a, b) = |\mathcal{I}_a \cap \mathcal{I}_b| / (\sqrt{|\mathcal{I}_a|\,|\mathcal{I}_b|} + \lambda)$, với $\mathcal{I}_a$ là tập sản phẩm a đã mua (hoặc tập người dùng đã mua sản phẩm a). Mỗi hàng của ma trận tương đồng chỉ giữ k láng giềng và được lưu dạng ma trận thưa. Số láng giềng k và hệ số co λ được chọn trên tập xác thực. Ưu điểm của nhánh này là đơn giản, không cần huấn luyện và dễ giải thích, vì chỉ ra được những người dùng hay sản phẩm nào dẫn tới một khuyến nghị. Nhược điểm là ma trận tương đồng đầy đủ tăng theo bình phương số đối tượng, và chất lượng giảm khi dữ liệu quá thưa.

Nhánh dựa trên mô hình (*model-based*) không giữ cả ma trận mà học một hàm có tham số, chẳng hạn nhân tử hoá ma trận hay mạng lưới thần kinh, để tóm tắt mỗi khách và mỗi sản phẩm bằng một vector ngắn. Vì mỗi đối tượng chỉ còn vài chục con số thay cho hàng nghìn ô của ma trận, mô hình vẫn chấm điểm được những cặp chưa từng xuất hiện, và chi phí huấn luyện chỉ tăng tuyến tính theo số tương tác. Các mô hình MF, GMF, MLP và NeuMF trình bày từ mục 2.2 thuộc nhánh này.

2.1.3 Phản hồi ẩn

Thông tin về sở thích có thể đến từ hai nguồn. Phản hồi tường minh (*explicit feedback*) là khi người dùng tự nói ra mức yêu thích, chẳng hạn chấm sao cho một bộ phim. Phản hồi ẩn (*implicit feedback*) phải đoán ra từ việc người dùng làm, như mua, xem hay bấm vào sản phẩm. Tệp giao dịch H&M không có cột điểm đánh giá nào, chỉ có các giao dịch đã xảy ra. Vì vậy đề tài dùng phản hồi ẩn dạng nhị phân, lấy từ sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu người dùng } u \text{ đã mua sản phẩm } i \\ 0, & \text{ngược lại} \end{cases} \tag{2.4}$$

Nhãn $y_{ui} = 1$ chỉ xác nhận khách đã mua, không xác nhận khách hài lòng. Nhãn $y_{ui} = 0$ có thể nghĩa là khách chưa biết đến sản phẩm, không nhất thiết là không thích. Do đó các cặp chưa tương tác không thể coi là nhãn âm chắc chắn, và kỹ thuật lấy mẫu âm phải được thiết kế cẩn thận.

2.1.4 Độ thưa dữ liệu và vấn đề cold start

Hai thách thức quen thuộc của lọc cộng tác định hình thiết kế mô hình và phạm vi thực nghiệm của đề tài.

Thách thức thứ nhất là độ thưa dữ liệu. Mỗi khách chỉ mua một phần rất nhỏ trong hàng nghìn sản phẩm, nên gần như mọi ô của ma trận $M \times N$ đều trống. Trên dữ liệu của đề tài, sau khi lọc k-core, mật độ khoảng 0,28% trên mẫu thực nghiệm với $k = 10$, và khoảng 0,03% trên toàn bộ dữ liệu với $k = 5$.

Thách thức thứ hai là *cold start* (khởi đầu lạnh), tình huống của một khách vừa đăng ký hoặc một mẫu áo vừa lên kệ. Khi đối tượng chưa có lượt mua nào, lọc cộng tác không có dữ liệu để học vector cho nó [12]. Đề tài phân biệt hai trường hợp. *Cold start* của người dùng nằm ngoài phạm vi đánh giá định lượng, vì mọi khách được đánh giá đều có lịch sử mua trước mốc dự đoán. Khi hệ thống được sử dụng, khách mới nhận danh sách sản phẩm phổ biến, và chỉ khi khách đã có lịch sử mua thì mô hình đề xuất mới được dùng. *Cold start* của sản phẩm cũng nằm ngoài phạm vi đánh giá, vì tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện trước mốc dự đoán. Dù vậy, do dữ liệu thưa, nhiều sản phẩm và khách hàng chỉ có ít tương tác, nên vector mã ID của chúng được học từ rất ít dữ liệu. Đề tài bổ sung đặc trưng nội dung và ngữ cảnh chủ yếu để khắc phục điểm yếu này.

2.2 Lọc cộng tác và nhân tử hoá ma trận

2.2.1 Mô hình nhân tử hoá ma trận

Ý tưởng của nhân tử hoá ma trận [6] là mô tả mỗi người dùng và mỗi sản phẩm bằng d con số, với $d \ll \min(M, N)$. Có thể hình dung mỗi chiều như một "khẩu vị" ẩn, chẳng hạn thiên về đồ thể thao hay đồ công sở, dù mô hình không đặt tên cho các chiều này. Người dùng u ứng với vector $p_u \in \mathbb{R}^d$, sản phẩm i ứng với $q_i \in \mathbb{R}^d$, và điểm dự đoán là tích vô hướng của hai vector:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{2.5}$$

Các biến thể của MF khác nhau ở cách học hai ma trận P và Q. Phân tích giá trị suy biến (*singular value decomposition*, SVD) cổ điển cần ma trận đầy đủ, nên không áp dụng trực tiếp được cho ma trận tương tác thưa, nơi phần lớn ô chưa được quan sát. Các biến thể dùng trong hệ khuyến nghị thay vào đó tối ưu sai số trên các ô đã biết, kèm điều chuẩn (*regularization*). Với phản hồi ẩn, BPR tối ưu trực tiếp thứ hạng theo

cặp, và đề tài dùng BPR-MF làm mô hình đối chứng MF chính.

2.2.2 Hạn chế của tích vô hướng

Tích vô hướng kết hợp các chiều ẩn theo dạng tuyến tính. Các tác giả của kiến trúc NCF lập luận rằng vì vậy phép toán này không học được tương tác phi tuyến giữa các chiều ẩn của người dùng và sản phẩm. Lập luận này là động cơ của kiến trúc NCF. Việc bổ sung thành phần phi tuyến có thực sự cải thiện chất lượng khuyến nghị hay không phụ thuộc vào dữ liệu, và được đề tài kiểm tra bằng thực nghiệm trên dữ liệu H&M.

2.2.3 Tối ưu thứ hạng theo cặp: BPR

MF, GMF và MLP được huấn luyện như một bài toán phân loại, trong đó mỗi cặp (u, i) được chấm riêng thành $\hat{y}_{ui}$ rồi so với nhãn 0 hoặc 1. Trong khi đó, một hệ khuyến nghị chỉ cần thứ tự đúng, tức món khách sẽ mua phải đứng trên món khách không mua. Bayesian Personalized Ranking (BPR) [13] huấn luyện thẳng theo yêu cầu này, với giả định người dùng thích một sản phẩm đã tương tác i hơn một sản phẩm chưa tương tác j. Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR là:

$$\mathcal{L}_{BPR} = - \sum_{(u,i,j)\in\mathcal{D}_S} \ln \sigma \left(\hat{y}_{ui} - \hat{y}_{uj}\right) + \lambda_\Theta \|\Theta\|^2 \tag{2.6}$$

trong đó $\mathcal{D}_S$ là tập các bộ ba được lấy mẫu. Khi $\hat{y}_{ui}$ được tính theo Công thức (2.5), ta có mô hình BPR-MF, một mô hình đối chứng của đề tài. Mục tiêu theo cặp của BPR sát với bài toán xếp hạng Top-K hơn hàm mất mát theo từng điểm, nhưng BPR-MF vẫn là mô hình tuyến tính.

2.3 Kiến trúc lọc cộng tác bằng mạng lưới thần kinh (NCF)

Kiến trúc NCF (*neural collaborative filtering*) do He và cộng sự [3] đề xuất gồm hai mô hình thành phần, GMF và MLP, và mô hình hợp nhất của chúng, NeuMF.

2.3.1 Generalized Matrix Factorization (GMF)

GMF viết lại MF dưới dạng một mạng lưới thần kinh. Thay vì cộng ngay các tích $p_{uf}q_{if}$ như Công thức (2.5), GMF giữ chúng thành một vector bằng phép nhân từng phần tử (tích Hadamard, ký hiệu $\odot$) giữa vector nhúng của người dùng p_u^G và của

sản phẩm q_i^G:

$$\phi^{GMF} = p_u^G \odot q_i^G \tag{2.7}$$

$$\hat{y}_{ui}^{GMF} = \sigma\left(h^T \phi^{GMF}\right) = \sigma\left(h^T (p_u^G \odot q_i^G)\right) \tag{2.8}$$

trong đó h là vector trọng số của lớp đầu ra và $\sigma(x) = 1/(1 + e^{-x})$ là hàm sigmoid. Nếu mọi phần tử của h bằng 1 và bỏ hàm sigmoid, GMF trở về đúng MF; khi h được học, mỗi chiều ẩn có trọng số riêng.

2.3.2 Multi-Layer Perceptron (MLP)

Nhánh MLP nối vector nhúng p_u^M và q_i^M thành đầu vào của một chuỗi lớp ẩn:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \tag{2.9}$$

$$\phi_L^{MLP} = a_L\left(W_L^T \phi_{L-1}^{MLP} + b_L\right) \tag{2.10}$$

trong đó W_L, b_L và a_L lần lượt là ma trận trọng số, vector độ lệch (*bias*) và hàm kích hoạt phi tuyến (ví dụ ReLU) của lớp thứ L. Cấu trúc này cho phép mô hình học tương tác phi tuyến giữa biểu diễn của người dùng và của sản phẩm.

2.3.3 Mô hình lai NeuMF

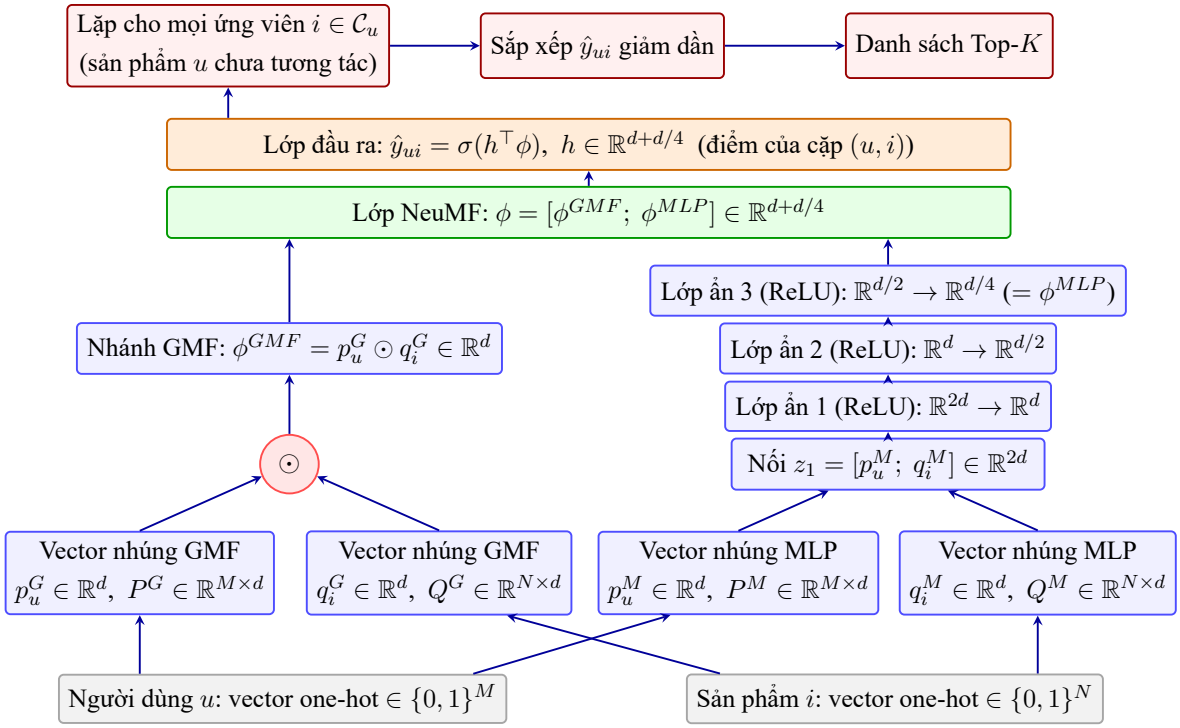
NeuMF ghép song song nhánh tuyến tính GMF và nhánh phi tuyến MLP trước lớp dự đoán:

$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \tag{2.11}$$

$$\hat{y}_{ui} = \sigma\left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix}\right) \tag{2.12}$$

Chữ "lai" trong tên đề tài trước hết chỉ việc kết hợp hai cách mô hình hoá tương tác, nhân tử hoá ma trận (tuyến tính) và mạng lưới thần kinh sâu (phi tuyến), trong cùng một mô hình. NeuMF ghép hai nhánh ngay ở mức biểu diễn, trước lớp dự đoán, nên là một mô hình hợp nhất sớm. Mô hình đề xuất NeuMF-F giữ cấu trúc này và bổ sung đặc trưng sản phẩm, khách hàng và thời gian vào vector của cả hai nhánh. Vì kết hợp lọc cộng tác với thông tin nội dung, NeuMF-F cũng là một hệ khuyến nghị lai theo nghĩa rộng của phân loại ở mục 2.1.1. Hình 2.1 trình bày kiến trúc NeuMF với kích thước của từng ma trận và từng lớp. Trong hình, M là số người dùng, N là số sản phẩm và d là số chiều vector nhúng. Trong cài đặt của đề tài, hai nhánh dùng cùng d,

và chuỗi lớp ẩn của MLP, thường gọi là tháp (*tower*), giảm một nửa số chiều qua mỗi lớp.



Hình 2.1: Kiến trúc NeuMF

2.3.4 Hợp nhất sớm và hợp nhất muộn

Khi hệ khuyến nghị kết hợp nhiều nguồn thông tin, hay nhiều góc nhìn về người dùng và sản phẩm, có hai cách hợp nhất cơ bản. Hai cách này khác nhau ở mức diễn ra phép hợp nhất [4], [14].

– Hợp nhất sớm (*early fusion*) diễn ra ở mức đặc trưng hoặc biểu diễn. Các vector $v_1, \ldots, v_m$ của từng góc nhìn được nối thành một biểu diễn chung, rồi một mô hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h\big([v_1;\ v_2;\ \ldots;\ v_m]\big) \tag{2.13}$$

– Hợp nhất muộn (*late fusion*) diễn ra ở mức điểm dự đoán. Mỗi góc nhìn được xử lý bởi một mô hình riêng h_j, rồi các dự đoán được kết hợp bằng một cơ chế F, như lấy trung bình, bỏ phiếu, trọng số cố định hoặc một mô hình học:

$$p = F\big(h_1(v_1),\ h_2(v_2),\ \ldots,\ h_m(v_m)\big) \tag{2.14}$$

Khi F là tổng có trọng số, đây chính là cách lai có trọng số trong phân loại

ở mục 2.1.1. Mô hình lai ở chương 3 luận án thuộc loại này, và mô hình đối chứng Hybrid-CBCF của đề tài cũng vậy. Ở hai mô hình này, F là bỏ phiếu hoặc tổng có trọng số của điểm từ ba mô hình truyền thống.

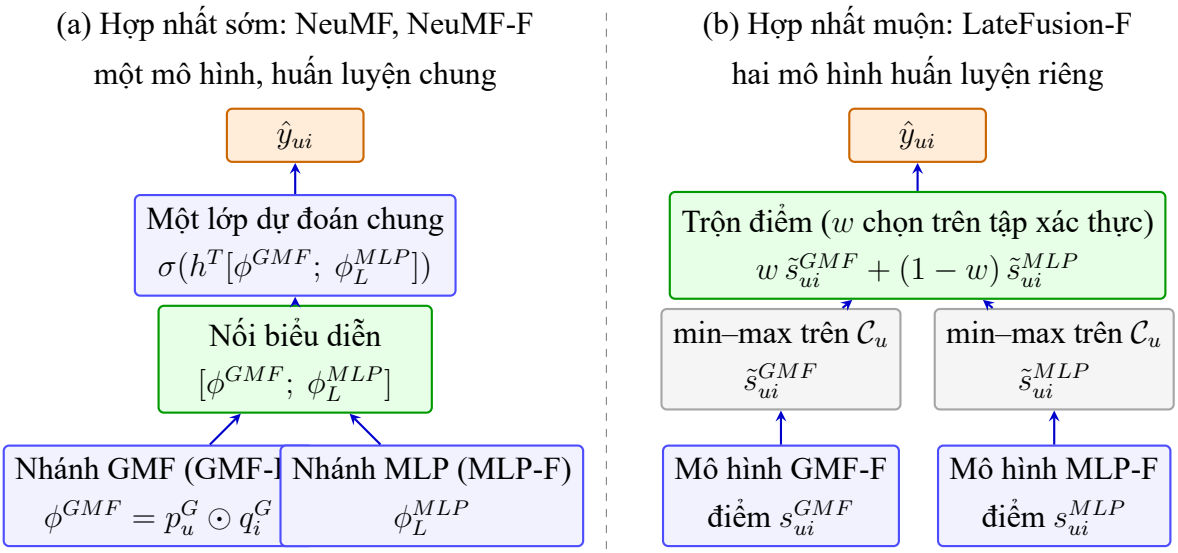
Ưu điểm của hợp nhất sớm là học được tương tác giữa các nguồn thông tin, nhưng nó đòi hỏi một mô hình phù hợp với mọi nguồn. Hợp nhất muộn linh hoạt hơn, song chỉ làm việc trên kết quả dự đoán nên không nắm được tương tác đó.

Trong đề tài, hai góc nhìn chính là hai cách mô hình hoá tương tác: góc nhìn tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và góc nhìn phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi đưa qua một lớp dự đoán chung (Công thức (2.11), (2.12)), nên là mô hình hợp nhất sớm ở mức biểu diễn và được huấn luyện chung từ đầu đến cuối (Hình 2.2a). NeuMF-F giữ cách hợp nhất này với hai nhánh có đặc trưng GMF-F và MLP-F. Ngoài ra, đặc trưng nội dung và ngữ cảnh được cộng vào vector của từng nhánh ngay ở đầu vào, nên cũng được hợp nhất sớm với thông tin cộng tác.

Hợp nhất muộn tương ứng là trộn điểm của hai mô hình MF và DNN được huấn luyện riêng:

$$\hat{y}_{ui} = w\,\tilde{s}_{ui}^{MF} + (1-w)\,\tilde{s}_{ui}^{DNN}, \qquad \tilde{s}_{ui} = \frac{s_{ui} - \min_{j\in\mathcal{C}_u} s_{uj}}{\max_{j\in\mathcal{C}_u} s_{uj} - \min_{j\in\mathcal{C}_u} s_{uj}} \tag{2.15}$$

trong đó điểm s_{ui} của mỗi mô hình được chuẩn hoá min–max trên tập ứng viên $\mathcal{C}_u$ của người dùng u để hai thang điểm so sánh được, và $w \in [0,1]$ được chọn trên tập xác thực. Với $w = 1$ hoặc $w = 0$, thứ hạng trùng với thứ hạng của từng thành phần. Để so sánh công bằng với NeuMF-F, đề tài dùng chính hai thành phần của nó: LateFusion-F trộn điểm của GMF-F và MLP-F được huấn luyện riêng (Hình 2.2b). Riêng nhánh MLP khi đứng một mình chỉ nối vector người dùng và sản phẩm ở đầu vào; đó là một mô hình DNN thuần, không phải phép hợp nhất MF với DNN.



Hình 2.2: Hợp nhất sớm và hợp nhất muộn

2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân

Dữ liệu mua hàng chỉ cho biết khách đã mua gì, nên chỉ có nhãn dương ($y_{ui} = 1$). Để mô hình học được cả chiều ngược lại, NCF lấy mẫu âm (*negative sampling*): với mỗi lượt mua, chọn ngẫu nhiên vài sản phẩm khách chưa mua và tạm coi là nhãn âm ($y_{ui} = 0$). Mô hình sau đó được huấn luyện như một bộ phân loại nhị phân, với hàm mất mát entropy chéo nhị phân (*binary cross-entropy*, BCE):

$$\mathcal{L}_{BCE} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui}\log\hat{y}_{ui} + (1-y_{ui})\log(1-\hat{y}_{ui})] \tag{2.16}$$

trong đó $\mathcal{Y}$ là tập tương tác dương và $\mathcal{Y}^-$ là tập cặp âm được lấy mẫu.

2.4 Các hướng nghiên cứu gần đây

Sau NCF, lĩnh vực hệ khuyến nghị phát triển theo nhiều hướng. Mục này chỉ trình bày những hướng liên quan trực tiếp tới thiết kế của đề tài.

2.4.1 Mô hình lai dựa trên đặc trưng

Một hướng phát triển trực tiếp của ý tưởng kết hợp tuyến tính và phi tuyến là các mô hình dùng nhiều đặc trưng hơn cặp mã người dùng và sản phẩm, xuất phát từ bài toán dự đoán tỉ lệ nhấp chuột. Factorization Machines (FM) [15] mở rộng MF từ hai loại đối tượng là người dùng và sản phẩm sang mọi đặc trưng: đặc trưng nào cũng có vector ẩn riêng, và mức độ hai đặc trưng "hợp nhau" là tích vô hướng của hai vector đó. Nếu chỉ có mã người dùng và mã sản phẩm, FM trở về MF. Wide & Deep

[16] đặt cạnh nhau một nhánh tuyến tính "rộng", giỏi nhớ những tổ hợp đặc trưng hay gặp, và một nhánh MLP "sâu", giỏi khái quát sang tổ hợp mới; hai nhánh được huấn luyện cùng lúc. DeepFM [17] giữ nhánh sâu và thay nhánh rộng bằng FM. Các kiến trúc này có chung cấu trúc của NeuMF: một thành phần tuyến tính kiểu nhân tử hoá, một thành phần phi tuyến kiểu MLP, hợp nhất ở lớp dự đoán. Điểm khác là đầu vào của chúng gồm cả đặc trưng chứ không chỉ mã ID. NeuMF-F đi theo hướng này. Mô hình giữ hai nhánh GMF và MLP, nhưng biểu diễn mỗi người dùng và sản phẩm bằng tổng của vector nhúng mã ID và một phép chiếu tuyến tính của đặc trưng.

Đặc trưng cũng là cách xử lý *cold start* của sản phẩm. Một sản phẩm mới chưa có tương tác nên không có vector mã ID có nghĩa, nhưng vẫn có thuộc tính và mô tả để đặt nó gần các sản phẩm tương tự. DropoutNet [18] đề xuất một kỹ thuật huấn luyện cho mô hình nhận cả biểu diễn sở thích lẫn nội dung: khi huấn luyện, phần biểu diễn học từ tương tác bị bỏ ngẫu nhiên, buộc mô hình học cách chấm điểm từ nội dung. NeuMF-F đưa kỹ thuật này vào không gian tinh chỉnh dưới dạng một siêu tham số, là xác suất bỏ ngẫu nhiên vector mã ID của sản phẩm khi huấn luyện. Trên tập xác thực, cấu hình được chọn của NeuMF-F có xác suất này bằng 0 (mục 4.2), nên kỹ thuật này không có mặt trong mô hình cuối. Vì sản phẩm mới không thuộc tập ứng viên của đề tài, kỹ thuật này ở đây chỉ đóng vai trò điều chuẩn.

Văn bản của sản phẩm (tên, mô tả) được biểu diễn theo cách cổ điển của lọc nội dung. TF-IDF [19] coi một từ là quan trọng với một sản phẩm khi từ đó lặp lại trong mô tả của sản phẩm nhưng ít gặp trong cả danh mục; một từ chỉ chất liệu hiếm gặp vì vậy nói về sản phẩm nhiều hơn những từ có mặt trong hầu hết mô tả. Ma trận TF-IDF sau đó được giảm chiều bằng phân tích giá trị suy biến rút gọn (*truncated SVD*), còn gọi là phân tích ngữ nghĩa tiềm ẩn [20], để các mô tả cùng chủ đề nhưng dùng từ khác nhau có vector gần nhau. Cách biểu diễn này không cần dữ liệu tương tác và không cần nhiều tài nguyên tính toán.

2.4.2 Các hướng ngoài phạm vi đề tài

Ngoài mô hình lai dựa trên đặc trưng, hệ khuyến nghị còn phát triển theo các hướng như mô hình theo chuỗi hành vi, học biểu diễn trên đồ thị tương tác và mô hình tự mã hoá biến phân. Đề tài không dùng các hướng này. Mô hình chuỗi cần thứ tự mua trong từng phiên, trong khi giao dịch H&M chỉ ghi ngày mua, không có giờ hay mã phiên, và nhiều sản phẩm được mua cùng ngày. Vì vậy đề tài dùng thời gian để chia dữ liệu và làm đặc trưng tổng hợp, như doanh số gần đây của sản phẩm và khoảng cách tới lần mua gần nhất của khách. Mô hình đồ thị và mô hình tự mã hoá biến phân

là hướng phát triển, với điều kiện được đánh giá theo cùng quy trình của đề tài.

2.4.3 Lý do chọn kiến trúc hai nhánh

Đề tài chọn kiến trúc hai nhánh của NeuMF và bổ sung đặc trưng thành NeuMF-F, thay vì các hướng ở trên, vì ba lý do. Về dữ liệu, tệp giao dịch H&M không có phiên để dùng mô hình chuỗi, nhưng có thuộc tính và mô tả văn bản của sản phẩm, loại thông tin mà cách biểu diễn "vector nhúng ID cộng đặc trưng" khai thác trực tiếp. Về mục tiêu, hai nhánh tách biệt cho phép đo riêng đóng góp của đặc trưng và của cách hợp nhất. Về tài nguyên, các mô hình sinh quy mô lớn như mô hình ngôn ngữ lớn hay mô hình khuếch tán vượt quá khả năng tính toán của đề tài.

2.5 Các độ đo đánh giá Top-K

Với mỗi người dùng được đánh giá u, mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\text{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm đúng của u và $\text{hits}_u = |T_u \cap \text{Rec}_K(u)|$. Khi chia dữ liệu theo một mốc thời gian chung như trong đề tài, một người dùng có thể có nhiều sản phẩm đúng. Mọi độ đo được tính cho từng người dùng rồi lấy trung bình trên tập người dùng được đánh giá $\mathcal{U}_{test}$.

Hit Ratio (HR@K) là độ đo đơn giản nhất. Nó kiểm tra trong K khuyến nghị có ít nhất một món khách thật sự mua hay không; mỗi người dùng được tính 1 nếu có và 0 nếu không:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}\left(\text{hits}_u \geq 1\right) \tag{2.17}$$

Precision@K là tỉ lệ khuyến nghị đúng trong K khuyến nghị, đo độ chính xác từ phía danh sách. Recall@K là tỉ lệ các món khách thật sự mua đã có mặt trong danh sách, đo độ bao phủ từ phía khách:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \qquad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \tag{2.18}$$

Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K bằng HR@K chia cho K; hai độ đo này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm đúng.

Ba độ đo trên không phân biệt món đúng nằm ở vị trí đầu hay vị trí thứ K, trong khi người dùng thường chỉ xem vài khuyến nghị đầu. NDCG@K (*normalized discounted cumulative gain*) tính đến vị trí bằng cách giảm dần đóng góp của một món đúng khi nó nằm càng xa đầu danh sách. Với mức liên quan nhị phân, định nghĩa của

Järvelin và Kekäläinen [21] là:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^{K} \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|,K)} \frac{1}{\log_2(j+1)} \end{aligned} \tag{2.19}$$

IDCG là giá trị DCG khi mọi sản phẩm đúng xếp ở đầu danh sách, nên NDCG@K nằm trong $[0, 1]$. Với $|T_u| = 1$ và sản phẩm đúng ở hạng r, NDCG@K bằng $1/\log_2(r+1)$ nếu $r \leq K$ và bằng 0 nếu ngược lại.

2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu

Một số công trình, trong đó có NCF, đánh giá bằng cách xếp sản phẩm đúng giữa một tập nhỏ ứng viên lấy mẫu, cụ thể là sản phẩm kiểm thử cùng 100 sản phẩm người dùng chưa tương tác. Krichene và Rendle [22] chứng minh độ đo trên tập ứng viên lấy mẫu không nhất quán với độ đo trên toàn bộ danh mục, thậm chí có thể đảo ngược kết luận "A tốt hơn B", và đề nghị không lấy mẫu. Đề tài vì vậy chỉ dùng cách xếp hạng toàn bộ (*full ranking*). Mỗi người dùng được xếp hạng trên toàn bộ tập ứng viên, trừ sản phẩm đã mua; ở tập kiểm thử (*test set*) của mẫu kiểm định, tập này có khoảng 6.710 sản phẩm. Giai đoạn phát triển của đề tài cũng gặp hiện tượng này: khi đổi sang cách lấy mẫu 99 sản phẩm, thứ hạng giữa các mô hình thay đổi.

2.5.2 Độ đo ngoài độ chính xác

Một mô hình chỉ khuyến nghị những món bán chạy nhất vẫn có thể đạt HR@K khá, vì món bán chạy dễ trúng, nhưng danh sách của nó gần như giống nhau với mọi khách [23]. Để mô tả danh sách khuyến nghị ngoài độ chính xác, đề tài dùng độ phủ (*coverage*): tỉ lệ sản phẩm của không gian ứng viên $\mathcal{I}_{cand}$ xuất hiện trong danh sách khuyến nghị của ít nhất một người dùng:

$$\text{Coverage@K} = \frac{\left|\bigcup_{u \in \mathcal{U}_{test}} \text{Rec}_K(u)\right|}{|\mathcal{I}_{cand}|} \tag{2.20}$$

Độ phủ thấp cho thấy mô hình chỉ dùng một phần nhỏ danh mục. Trường hợp giới hạn là Most Popular, khi mọi người dùng nhận gần như cùng một danh sách. Độ đo này chỉ mang tính mô tả.

2.6 Ba nghiên cứu nền tảng

Đề tài chọn ba nghiên cứu làm nền tảng tham chiếu, vì chúng liên quan trực tiếp tới mô hình và cách đánh giá của đề tài. Để tránh nhầm với các mô hình đối chứng ở Chương 3, các nghiên cứu này chỉ được dùng làm cơ sở phương pháp, không phải để so sánh số liệu. He và cộng sự [3] đề xuất kiến trúc NeuMF mà NeuMF-F kế thừa. Rendle và cộng sự [5] kiểm tra lại câu hỏi NeuMF có thực sự tốt hơn MF được tinh chỉnh kỹ hay không, câu hỏi mà đề tài đặt lại trên dữ liệu H&M. Luận án của Hồ Thị Linh [4] hệ thống hoá hai cách hợp nhất và việc bổ sung nguồn thông tin ngoài ma trận tương tác, khung phân loại mà đề tài dùng để so sánh NeuMF-F với LateFusion-F. Bảng 2.1 đối chiếu thiết lập thực nghiệm của ba nghiên cứu với đề tài; số liệu của mỗi nghiên cứu lấy từ chính bài gốc. Các nguồn khác trong báo cáo chỉ được trích cho phương pháp, dữ liệu hoặc công cụ mà đề tài dùng lại, không dùng số liệu của chúng để so sánh.

Các con số trong Bảng 2.1 không so sánh trực tiếp được với nhau. Hai bài về NCF xếp sản phẩm đúng giữa 101 ứng viên, nên HR@10 khoảng 0,7 đến 0,9. Đề tài xếp hạng trên khoảng 6 đến 7 nghìn ứng viên, nơi cùng độ đo cho giá trị thấp hơn nhiều. Luận án giải bài toán dự đoán điểm đánh giá với độ đo sai số, không xếp hạng. Vì vậy chỉ chiều và độ lớn tương đối của cải thiện so với đối chứng trong chính mỗi nghiên cứu là thông tin đọc được. Từ ba nghiên cứu này, đề tài kế thừa ba điều: kiến trúc và cách huấn luyện của NeuMF; yêu cầu tinh chỉnh đầy đủ mô hình đối chứng; khung hợp nhất sớm, hợp nhất muộn cùng ý tưởng bổ sung thông tin ngoài ma trận tương tác.

Bảng 2.1: Ba nghiên cứu nền tảng và thiết lập của đề tài

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
He và cộng sự, 2017 [3]	MovieLens 1M (6.040 người dùng, 3.706 phim, 1.000.209 tương tác) và Pinterest (55.187 người dùng, 9.916 sản phẩm, 1.500.809 tương tác), phản hồi ẩn. Xếp hạng Top-K; HR@10, NDCG@10	Giữ lại tương tác mới nhất của mỗi người dùng làm kiểm thử. 101 ứng viên: sản phẩm kiểm thử và 100 sản phẩm chưa tương tác lấy ngẫu nhiên	NeuMF có tiền huấn luyện: MovieLens HR@10 = 0,730, NDCG@10 = 0,447 (64 nhân tố); Pinterest HR@10 = 0,880, NDCG@10 = 0,558 (16 nhân tố). Trung bình cao hơn eALS 4,5% và BPR 4,9% (tương đối).
Rendle và cộng sự, 2020 [5]	Như NCF: MovieLens 1M và Pinterest; HR@10, NDCG@10	Như NCF: giữ lại tương tác mới nhất; 101 ứng viên	MF tinh chỉnh kỹ: MovieLens 0,7294 / 0,4523, Pinterest 0,8895 / 0,5794 (HR@10 / NDCG@10); NeuMF trong bảng so sánh của bài: 0,7093 / 0,4349 và 0,8777 / 0,5576. MF cao hơn NeuMF 2,8% HR@10 và 4,0% NDCG@10 (MovieLens), 1,3% và 3,9% (Pinterest).

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
Hồ Thị Linh, 2023 [4]	MovieLens (77.764 đánh giá, 27.042 người dùng, 8.203 phim); Amazon Electronics (85.065 đánh giá, 1.042 người dùng), Toys and Games (71.780; 5.462), Video Games (98.769; 2.291). Dự đoán điểm đánh giá; RMSE, MAE, Precision	Chia ngẫu nhiên 80% huấn luyện (20% trong đó để xác thực), 20% kiểm thử. Không xếp hạng trên tập ứng viên	Hợp nhất sớm vector MF và đặc trưng văn bản qua mạng lưới thần kinh (chương 4), Electronics: RMSE 1,01, Precision 82,86% so với SVD 1,16 và 69,55% (RMSE giảm 12,93%, Precision tăng 19,14%). Transformer hợp nhất nhiều góc nhìn (chương 5), Toys and Games: MAE 0,445, RMSE 0,743, Precision 92,07% so với SVD 0,844 / 1,120 / 68,06%.
Đề tài, 2026	H&M, mẫu kiểm định (7.994 khách, 6.749 sản phẩm, 243.696 cặp) và Amazon Beauty 5-core (10.681 khách, 6.069 sản phẩm, 94.009 cặp), phản hồi ẩn. Xếp hạng Top-K; NDCG@10 (chính), Recall, HR, Precision ở $K = 5, 10, 15, 20$	Theo mốc thời gian chung; mẫu khách hàng độc lập (H&M). Ứng viên: mọi sản phẩm đã có dữ liệu huấn luyện, trừ sản phẩm khách đã mua; trung bình 6.710 (H&M), 6.058 (Amazon)	NeuMF-F so với NeuMF chỉ dùng ID: NDCG@10 +43,8% (H&M) và +65,7% (Amazon), đều có ý nghĩa thống kê. NeuMF chỉ dùng ID so với BPR-MF trên H&M: +4,6%, không khác biệt có ý nghĩa.

2.7 Khoảng trống nghiên cứu

Các nghiên cứu nền tảng về NCF chủ yếu được đánh giá trên dữ liệu phim ảnh hoặc mạng xã hội hình ảnh, với giao thức giữ lại tương tác cuối và tập ứng viên lấy mẫu. Các nghiên cứu tái đánh giá cho thấy NeuMF chỉ dùng mã ID khó vượt các mô hình đơn giản được tinh chỉnh kỹ. Các mô hình dùng đặc trưng khai thác được thông tin ngoài mã ID, nhưng thường được đánh giá cho bài toán dự đoán nhấp chuột chứ

không phải xếp hạng Top-K trên toàn bộ danh mục. Các hướng mới hơn như học trên đồ thị, mô hình chuỗi hay mô hình ngôn ngữ lớn cần cấu trúc dữ liệu đặc thù hoặc tài nguyên vượt phạm vi của đề tài.

Đề tài tập trung vào hai khoảng trống cụ thể. Khoảng trống thứ nhất thuộc về mô hình, và đề tài lấp nó bằng NeuMF-F, một mô hình lai giữ cấu trúc MF và DNN của NeuMF nhưng khai thác được đặc trưng sản phẩm, khách hàng và thời gian. Khoảng trống thứ hai thuộc về đánh giá: mô hình cần được thử nghiệm trên dữ liệu giao dịch thời trang thực tế, theo một giao thức gần với tình huống triển khai. Giao thức chia dữ liệu theo thời gian, tính đặc trưng không dùng thông tin tương lai, và lấy kết luận trên một mẫu khách hàng chưa từng được dùng để ra quyết định. Giao thức cũng tránh ba lỗi phương pháp mà các nghiên cứu tái đánh giá đã chỉ ra: chọn mô hình trên tập kiểm thử, tinh chỉnh mô hình đối chứng sơ sài và đánh giá trên tập ứng viên lấy mẫu. Thiết kế đối chứng của đề tài trả lời lần lượt ba câu hỏi nghiên cứu đã nêu ở mục 1.1.3.

2.8 Tóm tắt chương

Chương này đã trình bày các khái niệm và mô hình mà đề tài dựa vào. Nhân tử hoá ma trận chỉ học tương tác tuyến tính và chỉ học từ mã ID, nên gặp khó trên dữ liệu thưa như H&M. NeuMF bổ sung một nhánh phi tuyến, nhưng các nghiên cứu tái đánh giá cho thấy lợi ích của nhánh này chưa chắc chắn khi MF được tinh chỉnh kỹ. Các mô hình dựa trên đặc trưng và khung hợp nhất sớm, hợp nhất muộn cho thấy một hướng khác là bổ sung thông tin ngoài mã ID. Đây là cơ sở để Chương 3 xây dựng NeuMF-F và thiết kế quy trình đánh giá cho ba câu hỏi nghiên cứu.

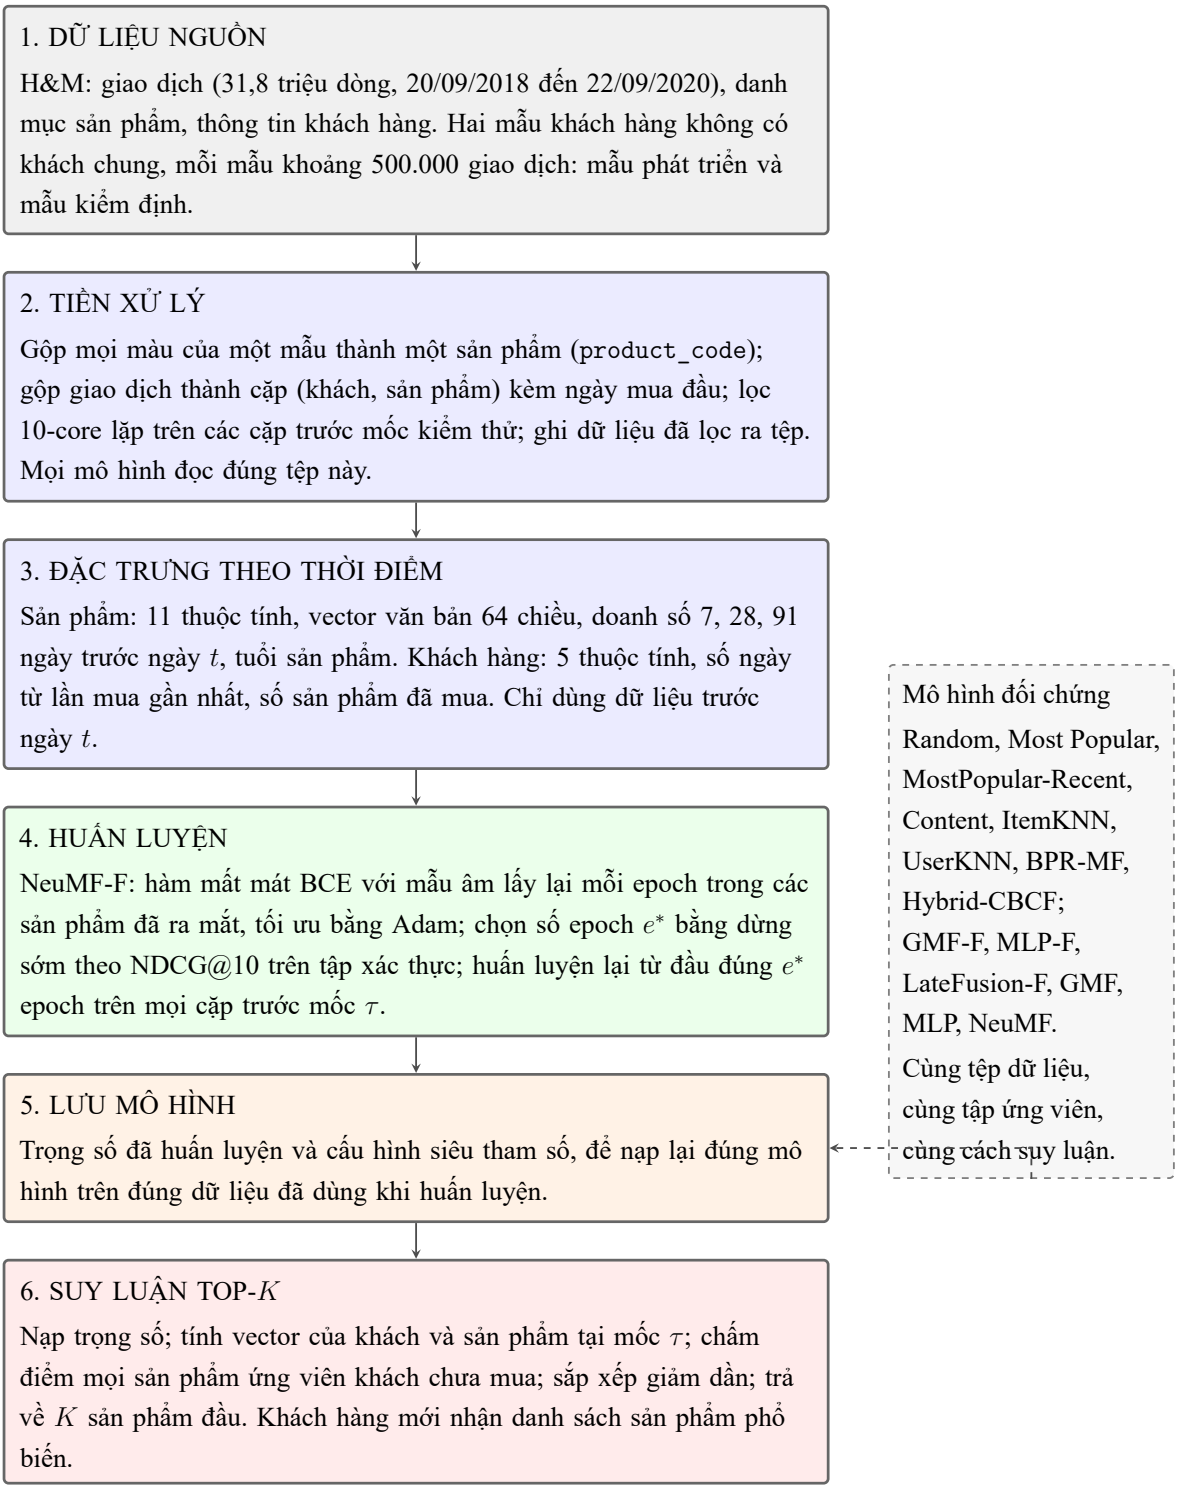
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F

Chương 2 đã chỉ ra hướng bổ sung thông tin ngoài mã ID cho mô hình lai. Chương này trình bày cách nhóm hiện thực hướng đó, theo đúng thứ tự thực hiện: dữ liệu, mô hình đề xuất và các mô hình đối chứng, huấn luyện, đánh giá, rồi suy luận và hệ thống demo. Điểm xuất phát là bộ dữ liệu H&M với đặc điểm thưa và biến động theo thời gian, từ đó quyết định cách chia dữ liệu, cách tính đặc trưng và cách thiết lập tập ứng viên. Mô hình đề xuất NeuMF-F được xây trên nền kiến trúc NeuMF, giữ nguyên hai nhánh GMF và MLP, và bổ sung đặc trưng vào biểu diễn của cả hai nhánh. Để kết luận có thể tin cậy, quy trình đánh giá được thiết kế riêng với tập kiểm định độc lập, đăng ký trước và kiểm định thống kê. Các bước xử lý chính được viết thành mã giả.

3.1 Quy trình tổng thể của hệ thống

Hệ thống được tổ chức theo trình tự một mô hình khuyến nghị đi qua khi đưa vào sử dụng: xây dựng đặc trưng, huấn luyện, lưu mô hình và suy luận (Hình 3.1). Chuỗi bước này được gọi là đường ống xử lý (*pipeline*). Mỗi lần chạy, đường ống nhận một mốc thời gian τ. Mọi bước chỉ dùng dữ liệu trước τ, và bước suy luận trả về danh sách khuyến nghị cho giai đoạn sau τ. Cách tổ chức này mô phỏng tình huống một doanh nghiệp huấn luyện mô hình trên lịch sử tính đến hôm nay rồi khuyến nghị cho những tuần tới. Việc đánh giá không nằm trong đường ống này mà là một quy trình riêng. Quy trình đó gọi lại đường ống với các mốc khác nhau, rồi so danh sách khuyến nghị với những gì khách đã mua thật.

Mọi mô hình, kể cả mô hình đối chứng, đi qua cùng đường ống: cùng tệp dữ liệu, cùng tập ứng viên và cùng quy tắc loại sản phẩm đã mua, nên chênh lệch giữa hai mô hình chỉ đến từ chính mô hình. Các mục sau trình bày lần lượt từng bước theo thứ tự trong hình.



Hình 3.1: Đường ống của hệ thống khuyến nghị

3.2 Dữ liệu và tiền xử lý

3.2.1 Đặc tả bộ dữ liệu H&M

Bộ dữ liệu H&M Personalized Fashion Recommendations [1] ghi lại hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn. Đề tài dùng ba tệp.

- `transactions_train.csv` (3,49 GB): 31.788.324 dòng giao dịch từ 20/09/2018 đến 22/09/2020, của 1.362.281 khách hàng trên 104.547 sản phẩm. Ba trường được dùng là `customer_id` (mã khách), `article_id` (mã sản phẩm, 10 chữ số) và `t_dat` (ngày mua, không có giờ). Giá và kênh bán không được dùng.
- `articles.csv`: 105.542 sản phẩm của danh mục. Mỗi sản phẩm có 11 thuộc tính dạng mã: loại sản phẩm, nhóm sản phẩm, hoạ tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu và nhóm may mặc. Sản phẩm còn có mô tả văn bản gồm tên và mô tả chi tiết.
- `customers.csv`: 1.371.980 khách hàng với tuổi, trạng thái hội viên, tần suất nhận tin thời trang và hai cờ FN, Active. Mã bưu chính không được dùng.

Ảnh sản phẩm có trong bộ dữ liệu nhưng không được dùng làm đầu vào của mô hình, và chỉ được hiển thị trong hệ thống demo.

Cách đánh giá xếp hạng toàn bộ phải chấm điểm mọi sản phẩm ứng viên cho mỗi người dùng được đánh giá, nên chi phí tăng theo tích của số người dùng và số sản phẩm. Để ước lượng quy mô bài toán, đề tài lọc k-core trên toàn bộ 31.788.324 dòng giao dịch với ba ngưỡng $k = 3, 5, 10$ (Bảng 3.1); mật độ trong bảng là số tương tác chia cho tích số người dùng và số sản phẩm. Ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm, tương ứng hàng chục tỷ cặp phải chấm điểm cho mỗi mô hình. Khối lượng này vượt quá tài nguyên tính toán của đề tài, nên đề tài thực nghiệm trên các mẫu lấy theo khách hàng.

Bảng 3.1: Lọc k-core trên toàn bộ dữ liệu H&M

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định

Đề tài lấy mẫu theo khách hàng thay vì theo dòng. Lấy mẫu theo dòng, hoặc cắt n dòng đầu, sẽ cắt vụn lịch sử của từng khách. Vì tệp gốc sắp theo ngày, cách đó còn chỉ phủ vài ngày giao dịch. Cả bước lọc k-core lẫn việc chia dữ liệu theo thời gian đều hỏng nếu làm vậy. Quy trình lấy mẫu gồm hai lượt đọc tệp theo lô, với bộ nhớ đỉnh khoảng 0,5 GB:

1. Lượt 1 chọn khách: băm `customer_id` bằng một khoá cố định vào 100.000 nhóm và đếm số giao dịch của từng nhóm. Hàm băm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua.
2. Lượt 2 ghi mẫu: giữ toàn bộ giao dịch của các khách được chọn, trải đủ từ 20/09/2018 đến 22/09/2020.

Các mẫu được lấy từ những đoạn nhóm băm liền nhau, không chồng lên nhau; mỗi mẫu gồm số nhóm ít nhất đủ khoảng 500.000 giao dịch.

- Mẫu phát triển gồm các nhóm $[0, 1597)$: 500.269 giao dịch của 21.599 khách hàng. Mẫu này chỉ dùng để tinh chỉnh trên tập xác thực.
- Mẫu kiểm định gồm các nhóm $[3160, 4734)$: 500.164 giao dịch của 21.351 khách hàng. Vì các đoạn nhóm không chồng nhau, không khách hàng nào thuộc cả mẫu phát triển lẫn mẫu kiểm định, và điều này đã được kiểm tra trực tiếp. Mẫu kiểm định chỉ dùng cho đánh giá cuối.

Vì dùng hàm băm với khoá cố định, lấy mẫu lại luôn cho đúng cùng hai mẫu. Mẫu kiểm định gồm những khách hàng khác hẳn và chưa từng được dùng để chọn mô hình, nên kết quả trên mẫu này ước lượng hiệu năng của mô hình với khách hàng khác của cùng cửa hàng, trong cùng giai đoạn thời gian.

3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử

Mỗi sản phẩm là một mẫu thiết kế. Mã `article_id` 10 chữ số của H&M gồm mã mẫu thiết kế `product_code` và ba chữ số cuối chỉ biến thể màu, nên một mẫu áo có thể mang nhiều `article_id`. Đề tài coi một sản phẩm là một `product_code`, nghĩa là mọi màu của cùng một mẫu được gộp làm một sản phẩm. Khách mua nhiều màu của cùng một mẫu chỉ được tính một cặp (khách, sản phẩm). Trước mốc kiểm thử, việc gộp này giảm số sản phẩm của mẫu phát triển từ 55.971 xuống 27.370 và số cặp từ 401.293 xuống 359.181. Với mẫu kiểm định, số sản phẩm giảm từ 55.683 xuống 27.291 và số cặp từ 398.653 xuống 356.740.

Một khách có thể mua cùng một sản phẩm nhiều lần. Các giao dịch lặp được gộp thành một cặp (khách, sản phẩm) duy nhất, giữ ngày mua đầu tiên t_{ui}, trước khi lọc k-core. Nếu lọc trực tiếp trên dòng giao dịch, số lượt mua lặp sẽ làm bậc của khách và sản phẩm cao hơn thực tế. Trên mẫu phát triển, 500.269 giao dịch sau khi gộp chỉ còn 429.964 cặp duy nhất.

Lọc k-core được lặp đến khi hội tụ, vì loại một sản phẩm có thể làm một khách rơi xuống dưới ngưỡng và ngược lại. Kết quả là mỗi khách và mỗi sản phẩm còn lại có ít nhất k đối tác khác nhau. Phép lọc chỉ dùng các cặp có ngày mua đầu trước mốc kiểm thử (29/07/2020), nên việc chọn khách và sản phẩm không dùng thông tin nào của giai đoạn kiểm thử. Thuật toán 3.1 tóm tắt bước chuẩn bị dữ liệu. Sau khi lọc với $k = 10$, mẫu phát triển còn 8.039 khách, 6.801 sản phẩm và 245.644 cặp; mẫu kiểm định còn 7.994 khách, 6.749 sản phẩm và 243.696 cặp. Mã khách và mã sản phẩm được đánh lại chỉ số liên tục, và $y_{ui} = 1$ khi khách u đã mua sản phẩm i (Công thức (2.4)). Dữ liệu đã lọc của mỗi mẫu được ghi ra một tệp, và mọi mô hình đọc đúng tệp này.

Khi nạp dữ liệu cho một giai đoạn, chỉ các khách và sản phẩm thuộc k-core được giữ, rồi dữ liệu huấn luyện và sản phẩm đúng được lấy theo các tập ở mục 3.2.4. Tệp chứa mọi cặp, kể cả sau mốc kiểm thử, nhưng tập kiểm thử chỉ được dựng khi chạy đánh giá cuối.

Thuật toán 3.1 Chuẩn bị dữ liệu và lọc k-core

Đầu vào: giao dịch (c, a, t) của một mẫu; mốc kiểm thử τ_{test}; ngưỡng k
Đầu ra: tệp các cặp (c, i, t_{ci}) kèm cờ thuộc k-core

$i \leftarrow \lfloor a/1000 \rfloor$ với mọi giao dịch ▷ *gộp màu theo* `product_code`
gộp theo cặp (c, i), giữ t_{ci} là ngày mua sớm nhất
$E \leftarrow \{(c, i) : t_{ci} < \tau_{test}\}$ ▷ *chỉ dữ liệu trước mốc*
lặp
    $E' \leftarrow E$
    $U \leftarrow$ các khách có ít nhất k sản phẩm trong E
    $I \leftarrow$ các sản phẩm có ít nhất k khách trong E
    $E \leftarrow \{(c, i) \in E : c \in U,\ i \in I\}$
đến khi $E = E'$
ghi mọi cặp kèm cờ $(c, i) \in E$ ra tệp ▷ *mọi mô hình đọc tệp này*

Ngưỡng k được chọn từ một khảo sát ở giai đoạn phát triển. Khảo sát này chạy

trên 429.964 cặp của mẫu phát triển trước khi lọc, khi mỗi sản phẩm vẫn còn là một `article_id`, nên số liệu ở Bảng 3.2 lớn hơn số liệu sau khi gộp màu ở mục 3.2.3. Các nghiên cứu thường dùng $k = 5$. Với ngưỡng này danh mục còn 23.067 sản phẩm, và đánh giá xếp hạng toàn bộ cần ước tính khoảng 10,7 GB bộ nhớ, vượt quá tài nguyên tính toán của đề tài. Đề tài vì vậy chọn $k = 10$, chấp nhận việc dữ liệu nghiêng về những khách mua nhiều.

Bảng 3.2: Lọc k-core trên mẫu phát triển

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	7.519	10.345	220.292	0,283
15	3.017	3.186	83.088	0,864

3.2.4 Giai đoạn đánh giá và tập ứng viên

Dữ liệu được chia theo thời gian bằng hai mốc cố định, chung cho mọi khách hàng. Mốc xác thực là τ_{val} = 01/07/2020, với cửa sổ xác thực 4 tuần từ 01/07 đến 28/07/2020. Mốc kiểm thử là τ_{test} = 29/07/2020, với cửa sổ kiểm thử 8 tuần từ 29/07 đến 22/09/2020. Với mỗi mốc τ, gọi là một giai đoạn, các tập sau được định nghĩa:

$$\mathcal{D}_\tau = \{(u,i) \text{ đã lọc } k\text{-core} : t_{ui} < \tau\} \quad \text{(dữ liệu huấn luyện)} \tag{3.1}$$

$$\mathcal{I}_\tau = \{i : \exists u,\ (u,i) \in \mathcal{D}_\tau\} \quad \text{(sản phẩm có dữ liệu huấn luyện)} \tag{3.2}$$

$$\mathcal{C}_u(\tau) = \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau) \quad \text{(tập ứng viên của khách } u) \tag{3.3}$$

$$T_u(\tau) = \{i \in \mathcal{C}_u(\tau) : \tau \le t_{ui} < \tau_{end}\} \quad \text{(sản phẩm đúng của } u) \tag{3.4}$$

trong đó $\mathcal{I}_u(\tau)$ là các sản phẩm u đã mua trước τ, và τ_{end} là cuối cửa sổ của giai đoạn. Chỉ những khách có dữ liệu huấn luyện trong $\mathcal{D}_\tau$ và có ít nhất một sản phẩm đúng mới được đánh giá. Có hai điểm cần giải thích.

– Tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện. Sản phẩm chưa có cặp nào trong dữ liệu huấn luyện của giai đoạn, trong đó có sản phẩm vừa ra mắt, không thuộc tập ứng viên lẫn tập sản phẩm đúng. Với tập ứng viên này, mọi mô hình, kể cả mô hình chỉ dùng mã ID, đều chấm được mọi ứng viên, nên so sánh không phụ thuộc vào khả năng xử lý sản phẩm chưa có lịch sử bán. Đổi lại, kết quả không nói về khả năng khuyến nghị sản phẩm vừa ra mắt.

– Mô hình được huấn luyện lại trên dữ liệu mới nhất. Ở giai đoạn kiểm thử, $\mathcal{D}_{\tau_{test}}$ gồm cả cửa sổ xác thực. Tập xác thực chỉ dùng để chọn cấu hình và số epoch. Trước khi đánh giá trên tập kiểm thử, mô hình được huấn luyện lại từ đầu trên $\mathcal{D}_{\tau_{test}}$, nên lúc dự đoán mô hình đã thấy toàn bộ quá khứ như khi triển khai thật.

Đề tài không chia theo cách giữ lại tương tác cuối của từng người dùng (*leave-one-out*), cách mà NCF dùng. Cách này để lọt thông tin tương lai, vì tập huấn luyện chứa tương tác của những người dùng khác xảy ra sau thời điểm cần dự đoán [24]. Đo trên mẫu phát triển ở giai đoạn phát triển, tính trung bình theo người dùng, 11,2% tương tác trong tập huấn luyện xảy ra sau ngày mua sản phẩm kiểm thử của người dùng đó. Ngoài ra, 60,9% người dùng có sản phẩm xác thực và sản phẩm kiểm thử mua cùng một ngày. Vì vậy đề tài chia theo một mốc thời gian chung cho mọi người dùng.

Theo định nghĩa, mỗi cặp (khách, sản phẩm) chỉ có một ngày mua đầu, nên một cặp không thể vừa thuộc dữ liệu huấn luyện vừa là sản phẩm đúng trong cùng một giai đoạn. Sản phẩm khách đã mua trước mốc cũng không bao giờ được tính là sản phẩm đúng, vì mục tiêu là dự đoán những món khách chưa từng mua.

Sau khi lọc, hai mẫu có số người dùng và số sản phẩm gần như bằng nhau (Bảng 3.3), cho thấy cách lấy mẫu theo hàm băm tạo ra hai mẫu tương đương nhau dù không có khách hàng chung. Số người dùng được đánh giá chỉ chiếm từ 32% (giai đoạn xác thực) đến 40% (giai đoạn kiểm thử) số người dùng sau lọc, vì chỉ những khách có mua sản phẩm mới trong cửa sổ đánh giá mới được tính. Mẫu phát triển chỉ được dùng ở giai đoạn xác thực, nên các dòng của giai đoạn kiểm thử ở cột này được để trống. Ở giai đoạn kiểm thử, mỗi người dùng được xếp hạng trên trung bình khoảng 6.710 ứng viên, trong khi trung bình chỉ có hơn ba sản phẩm đúng. Tỉ lệ này giải thích vì sao các độ đo ở Chương 4 có giá trị tuyệt đối thấp.

Bảng 3.3: Quy mô dữ liệu H&M

	Mẫu phát triển	Mẫu kiểm định
Người dùng sau lọc 10-core	8.039	7.994
Sản phẩm (`product_code`) sau lọc 10-core	6.801	6.749
Cặp (khách, sản phẩm) trước mốc kiểm thử	245.644	243.696
Xác thực: cặp huấn luyện (trước 01/07/2020)	236.845	234.610
Xác thực: người dùng được đánh giá	2.569	2.579
Xác thực: cặp đúng	8.636	8.985
Kiểm thử: người dùng được đánh giá	—	3.165
Kiểm thử: cặp đúng	—	10.285
Kiểm thử: số ứng viên trung bình mỗi người dùng	—	6.710

3.2.5 Xây dựng đặc trưng theo thời điểm

Nguyên tắc bắt buộc khi xây dựng đặc trưng (Bảng 3.4) là không dùng thông tin tương lai, nghĩa là đặc trưng của một cặp (khách u, sản phẩm i) tại ngày t chỉ được tính từ dữ liệu trước ngày t. Khi huấn luyện, mỗi cặp dương mang chính ngày mua đầu t_{ui} của nó. Khi đánh giá, t là mốc τ của giai đoạn.

Đặc trưng thời gian của sản phẩm được tính như sau. Gọi $n_{i,d}$ là số giao dịch của sản phẩm i trong ngày d trên toàn bộ H&M và d_i^0 là ngày bán đầu tiên. Tại ngày t:

$$\begin{aligned} s_i^{(w)}(t) &= \sum_{d=t-w}^{t-1} n_{i,d}, \\ x_i^{tg}(t) &= \left[\tfrac{\log(1+s_i^{(7)})}{10},\ \tfrac{\log(1+s_i^{(28)})}{10},\ \tfrac{\log(1+s_i^{(91)})}{10},\ \tfrac{\log(1+\max(0,\,t-d_i^0))}{10},\ \mathbb{I}(d_i^0 \geq t) \right] \end{aligned} \tag{3.5}$$

Tổng chỉ chạy tới ngày $t-1$, nên doanh số của chính ngày t không được dùng. Phép $\log(1+x)$ nén giá trị của các sản phẩm bán rất chạy, còn hệ số $1/10$ đưa đặc trưng về cỡ $[0, 1]$. Doanh số được tính trên toàn bộ giao dịch H&M, không chỉ trong mẫu. Đây là dữ liệu doanh nghiệp có tại thời điểm dự đoán, và nó phản ánh xu hướng bán gần đây của sản phẩm trên toàn cửa hàng.

Văn bản của sản phẩm được biểu diễn bằng TF-IDF trên từ đơn và cặp từ, rồi giảm còn 64 chiều bằng SVD rút gọn và chuẩn hoá về độ dài 1. Bộ từ vựng bỏ từ dừng tiếng Anh và giữ tối đa 30.000 mục từ xuất hiện ở ít nhất 3 sản phẩm. Phép biến đổi được khớp trên toàn bộ danh mục và không dùng dữ liệu mua hàng.

Đặc trưng ban đầu được tính cho từng `article_id`, rồi được gộp theo mẫu

thiết kế. Thuộc tính danh mục lấy theo biến thể có `article_id` nhỏ nhất. Ba thuộc tính màu (nhóm màu, độ đậm màu, màu chủ đạo) được đặt về một giá trị hằng vì không còn mô tả một màu cụ thể. Vector văn bản là trung bình các biến thể, chuẩn hoá lại về độ dài 1. Doanh số theo ngày là tổng các biến thể, và ngày bán đầu tiên là ngày sớm nhất của các biến thể.

Thuộc tính tĩnh của khách hàng lấy từ `customers.csv`. Tệp này không có mốc thời gian, nên thuộc tính được coi là ít thay đổi. Đặc trưng thời gian của khách tại ngày t chỉ dùng các cặp có ngày mua đầu trước t: khoảng cách tới lần mua gần nhất và số cặp đã mua.

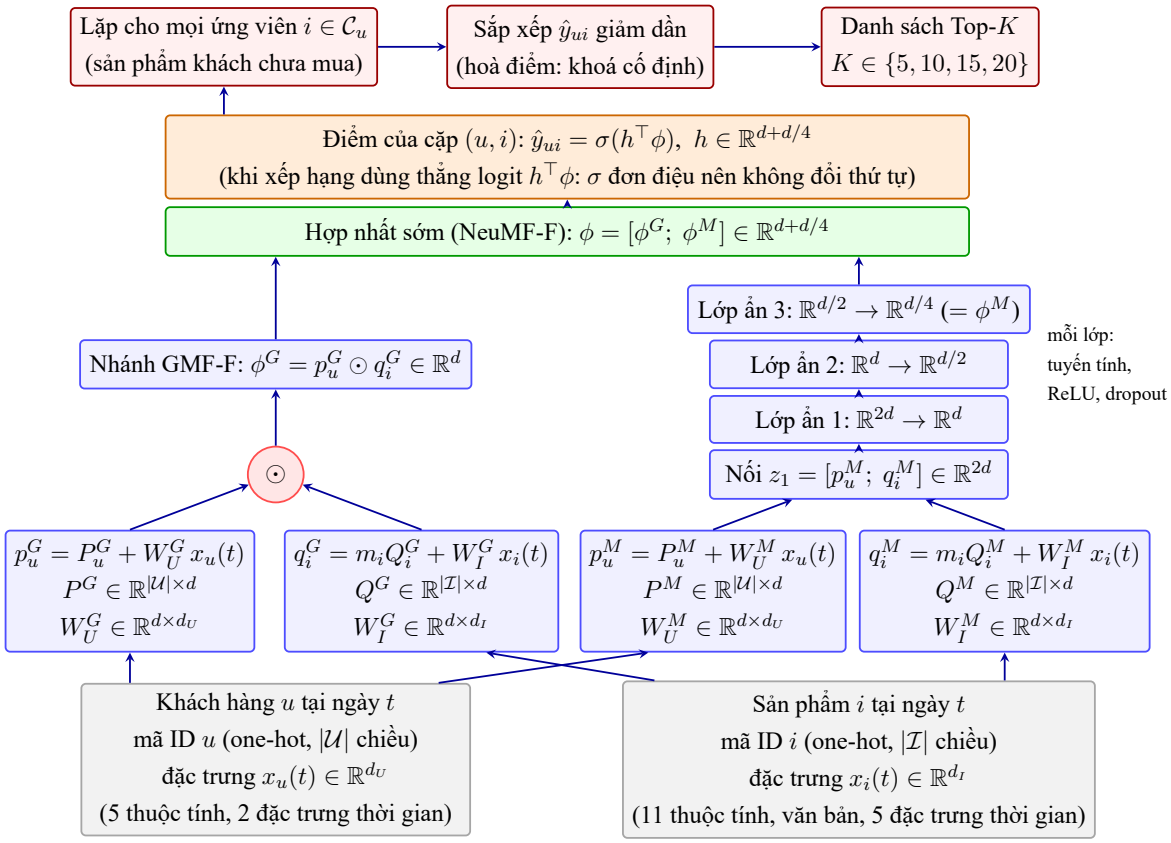
Bảng 3.4: Đặc trưng đầu vào trên H&M

Nhóm	Đặc trưng	Mã hoá	Nguồn
Sản phẩm: thuộc tính	11 thuộc tính danh mục (loại, nhóm sản phẩm, hoạ tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc); sau khi gộp theo mẫu, ba thuộc tính màu là hằng số	Vector nhúng 8 chiều mỗi thuộc tính (88 chiều), học cùng mô hình	`articles.csv`
Sản phẩm: văn bản	Tên và mô tả chi tiết	TF-IDF (từ đơn và cặp từ), SVD 64 chiều, chuẩn hoá L2	`articles.csv`
Sản phẩm: thời gian tại t	Doanh số trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ "chưa từng bán trước t"	$\log(1+x)/10$; cờ 0/1 (5 chiều)	Giao dịch toàn H&M
Khách hàng: tĩnh	Nhóm tuổi (9 mức, gồm "không rõ"), trạng thái hội viên, tần suất nhận tin, FN, Active	Vector nhúng 8 chiều mỗi thuộc tính (40 chiều)	`customers.csv`
Khách hàng: thời gian tại t	Số ngày từ lần mua gần nhất (tối đa 730); số cặp đã mua	$\log(1+x)/10$ (2 chiều)	Dữ liệu huấn luyện

3.3 Thiết kế mô hình lai NeuMF-F

NeuMF-F giữ nguyên cấu trúc hai nhánh của NeuMF: nhánh GMF mô hình hoá tương tác tuyến tính, nhánh MLP mô hình hoá tương tác phi tuyến, và hai nhánh

hợp nhất ở lớp dự đoán chung. Thay đổi duy nhất nằm ở biểu diễn đầu vào. Trong mỗi nhánh, vector của khách hàng và sản phẩm không còn chỉ là vector nhúng của mã ID mà là tổng của vector nhúng ID với một phép chiếu tuyến tính của đặc trưng. Chữ "F" (*features*) chỉ phần đặc trưng này. Hình 3.2 trình bày kiến trúc kèm kích thước của từng ma trận và từng lớp. Mỗi nhánh có bảng vector nhúng ID và ma trận chiếu đặc trưng riêng. Hệ số $m_i \in \{0, 1\}$ cho biết vector nhúng ID của sản phẩm có được dùng hay không. Ví dụ, với $d = 32$, tháp MLP là $64 \to 32 \to 16 \to 8$ và $\phi \in \mathbb{R}^{40}$. Trên mẫu kiểm định H&M, $|\mathcal{U}| = 7.994$, $|\mathcal{I}| = 6.749$, $d_U = 42$ và $d_I = 157$. Điểm $\hat{y}_{ui}$ được tính cho mọi sản phẩm ứng viên của khách, rồi các sản phẩm được sắp theo điểm giảm dần và K sản phẩm đầu là danh sách khuyến nghị.



Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F

3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng

Với mỗi nhánh $b \in \{G, M\}$ (GMF và MLP), mô hình có bảng vector nhúng ID của khách hàng $P^b \in \mathbb{R}^{|\mathcal{U}| \times d}$, của sản phẩm $Q^b \in \mathbb{R}^{|\mathcal{I}^{ID}| \times d}$, và hai ma trận chiếu đặc trưng $W_U^b \in \mathbb{R}^{d \times d_U}$, $W_I^b \in \mathbb{R}^{d \times d_I}$, không có độ lệch (*bias*). Vector của khách u và sản

phẩm i tại ngày t trong nhánh b là:

$$p_u^b(t) = P_u^b + W_U^b\, x_u(t), \qquad q_i^b(t) = m_i\, Q_i^b + W_I^b\, x_i(t) \tag{3.6}$$

Vector đặc trưng của sản phẩm $x_i(t) = [e(a_{i,1}); \ldots; e(a_{i,11});\ v_i;\ x_i^{tg}(t)] \in \mathbb{R}^{d_I}$ gồm vector nhúng 8 chiều của 11 thuộc tính danh mục, vector văn bản v_i (64 chiều) và 5 đặc trưng thời gian (Công thức (3.5)), tức $d_I = 88 + 64 + 5 = 157$. Tương tự, $x_u(t) = [e(c_{u,1}); \ldots; e(c_{u,5});\ x_u^{tg}(t)] \in \mathbb{R}^{d_U}$ với $d_U = 40 + 2 = 42$. Vector nhúng của các thuộc tính $e(\cdot)$ được học cùng mô hình và dùng chung cho hai nhánh, còn ma trận chiếu W^b riêng cho từng nhánh.

Hệ số m_i cho biết vector nhúng ID của sản phẩm có được dùng hay không. Khi $m_i = 0$, vector của sản phẩm chỉ còn phần đặc trưng. Mọi sản phẩm trong tập ứng viên đều có dữ liệu huấn luyện, nên khi chấm điểm luôn có $m_i = 1$. Khi huấn luyện, m_i có thể được đặt về 0 ngẫu nhiên với xác suất $\rho \in \{0;\ 0{,}25;\ 0{,}5\}$ theo ý tưởng của DropoutNet, gọi là bỏ ID ngẫu nhiên, để mô hình học chấm điểm một phần từ đặc trưng. ρ được chọn trên tập xác thực như các siêu tham số khác. Cấu hình được chọn của NeuMF-F có $\rho = 0$, nên mô hình cuối không dùng cơ chế này.

Như NeuMF, hai nhánh dùng hai không gian nhúng độc lập, vì nhánh GMF tối ưu vector cho phép nhân Hadamard còn nhánh MLP tối ưu vector làm đầu vào của mạng phi tuyến. Hai nhánh dùng cùng số chiều $d \in \{32, 64\}$. Các bảng vector nhúng được khởi tạo theo phân phối chuẩn $\mathcal{N}(0;\ 0{,}01^2)$; hàng "không có ID" là vector 0 cố định. Các lớp tuyến tính được khởi tạo theo Xavier, và lớp đầu ra h không có độ lệch.

3.3.2 Nhánh GMF-F

Nhánh GMF-F là dạng tổng quát của nhân tử hoá ma trận (Công thức (2.5)) trên vector lai. Thay vì cộng ngay tích các chiều thành một số, nhánh giữ kết quả nhân theo từng chiều qua phép nhân Hadamard:

$$\phi^G = p_u^G(t) \odot q_i^G(t) \tag{3.7}$$

Phép cộng các chiều được chuyển sang vector trọng số h ở lớp đầu ra, nên mô hình học được trọng số riêng cho từng chiều. Đây là phần "tổng quát" trong tên gọi GMF: khi $h = \mathbf{1}$ và không có đặc trưng, GMF-F trở về MF. Vì p_u^G và q_i^G đều chứa phần chiếu của đặc trưng, tích $p_u^G \odot q_i^G$ còn mô hình hoá tương tác tuyến tính giữa thuộc tính của khách và thuộc tính của sản phẩm, tương tự Factorization Machines.

3.3.3 Nhánh MLP-F

Nhánh MLP-F nối hai vector lai thành đầu vào của một mạng nhiều lớp, không áp đặt trước cách hai vector tương tác:

$$z_1 = \begin{bmatrix} p_u^M(t) \\ q_i^M(t) \end{bmatrix} \in \mathbb{R}^{2d}, \qquad \phi_L^M = a_L\big(W_L^T \cdots a_2(W_2^T z_1 + b_2) \cdots + b_L\big) \tag{3.8}$$

Như NCF, tháp giảm một nửa số chiều qua mỗi lớp ẩn: $[2d \to d \to d/2 \to d/4]$; với $d = 32$ là $[64 \to 32 \to 16 \to 8]$. Mỗi lớp ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và dropout với tỉ lệ được tinh chỉnh trong $\{0;\ 0{,}2\}$. Cùng với dropout, mô hình được chống quá khớp (*overfitting*) bằng điều chuẩn L_2 và dừng sớm (*early stopping*) theo NDCG@10 trên tập xác thực.

3.3.4 Lớp hợp nhất và lớp dự đoán

Vector của nhánh GMF-F và của nhánh MLP-F được nối thành một vector hợp nhất, rồi qua một lớp tuyến tính cuối và hàm sigmoid:

$$\hat{y}_{ui} = \sigma\big(h^T[\phi^G;\ \phi_L^M]\big) = \sigma\big(h_G^T\,(p_u^G \odot q_i^G) + h_M^T\,\phi_L^M\big) \tag{3.9}$$

Theo phân loại ở mục 2.3.4, đây là hợp nhất sớm ở mức biểu diễn của góc nhìn tuyến tính (MF) và góc nhìn phi tuyến (DNN). Một lớp dự đoán chung học trọng số giữa hai góc nhìn, và toàn bộ mạng được huấn luyện chung. Đặc trưng của sản phẩm và khách hàng được đưa vào ngay ở mức vector của cả hai nhánh, nên thông tin nội dung và ngữ cảnh cũng được hợp nhất sớm với thông tin cộng tác.

Khi xếp hạng, hệ thống dùng trực tiếp giá trị trước sigmoid (logit). Sigmoid đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hoà về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả. Khi đánh giá một giai đoạn, vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần rồi dùng lại cho mọi cặp, nên chi phí chấm toàn bộ tập ứng viên gần bằng chi phí của NeuMF chỉ dùng ID.

3.4 Mô hình đối chứng

Các mô hình đối chứng được xếp thành ba nhóm (Bảng 3.5), mỗi nhóm ứng với một câu hỏi riêng về mô hình đề xuất. Mọi mô hình được đánh giá trên cùng dữ liệu, cùng tập ứng viên và cùng quy tắc chấm. Mô hình Random cho điểm ngẫu nhiên và chỉ dùng làm mốc dưới. Tính cả NeuMF-F, đánh giá cuối gồm 14 mô hình đăng ký trước. Hybrid-CBCF, đánh dấu * trong bảng, là mô hình thứ 15, được bổ sung sau khi

đánh giá cuối của 14 mô hình đã hoàn tất, theo một kế hoạch riêng (mục 4.3.4).

Bảng 3.5: Ba nhóm mô hình đối chứng

Nhóm	Mô hình	Câu hỏi được trả lời
Mô hình đơn lẻ	GMF, MLP (chỉ dùng ID); GMF-F, MLP-F (có đặc trưng)	Hợp nhất hai nhánh MF và DNN có hơn từng nhánh đứng riêng không
Học máy truyền thống	Content, ItemKNN, UserKNN, BPR-MF; mô hình lai truyền thống Hybrid-CBCF*	Mô hình lai học sâu có hơn các phương pháp khuyến nghị truyền thống, kể cả một mô hình lai truyền thống, không
Chuyên biệt cho khuyến nghị	Most Popular, MostPopular-Recent; NeuMF (NCF chỉ dùng ID); LateFusion-F (hợp nhất muộn)	Mô hình đề xuất có hơn xu hướng phổ biến, kiến trúc NCF gốc và cách hợp nhất muộn của cùng hai nhánh không

3.4.1 Các mô hình cài đặt trên cùng khung với NeuMF-F

Để trả lời từng câu hỏi nghiên cứu bằng một phép so sánh trực tiếp, các mô hình sau được cài đặt trên cùng mã nguồn, cùng đặc trưng và cùng quy trình huấn luyện với NeuMF-F.

- GMF-F và MLP-F là NeuMF-F chỉ giữ một nhánh. Chúng đo đóng góp của từng nhánh và lợi ích của việc hợp nhất. MLP-F đứng riêng là một mô hình DNN thuần, không phải mô hình hợp nhất MF với DNN.
- LateFusion-F là hợp nhất muộn của cùng hai thành phần. GMF-F và MLP-F được huấn luyện riêng, rồi điểm đã chuẩn hoá min–max trên tập ứng viên của từng khách được trộn theo trọng số w chọn trên tập xác thực (Công thức (2.15)). So sánh NeuMF-F với LateFusion-F là so sánh hai cách hợp nhất trên cùng hai thành phần.
- GMF, MLP và NeuMF chỉ dùng ID là kiến trúc NCF gốc, không có đặc trưng. Chúng đo lợi ích của đặc trưng.
- Các biến thể bóc tách của NeuMF-F dùng cùng siêu tham số với NeuMF-F và tắt lần lượt một thành phần: vector văn bản, đặc trưng thời gian, thông tin khách hàng, thuộc tính sản phẩm, hoặc cơ chế bỏ ID ngẫu nhiên. Biến thể nào trùng với chính NeuMF-F thì không chạy.

3.4.2 Các mô hình đối chứng còn lại

Các mô hình còn lại được cài đặt riêng, nhưng dùng cùng tệp dữ liệu, cùng tập ứng viên và cùng cách chấm với NeuMF-F.

1. Most Popular: điểm của sản phẩm là số khách trong dữ liệu huấn luyện của mẫu đã mua sản phẩm đó. Mọi khách nhận cùng một danh sách, trừ sản phẩm đã mua.
2. MostPopular-Recent: độ phổ biến gần đây trên toàn bộ H&M. Điểm của sản phẩm i là số giao dịch của nó trong W ngày trước mốc dự đoán, $\sum_{d=\tau-W}^{\tau-1} n_{i,d}$, với W chọn trên tập xác thực. Đây là mô hình đối chứng mạnh với dữ liệu thời trang có xu hướng thay đổi nhanh. Nó dùng cùng nguồn doanh số với đặc trưng thời gian của NeuMF-F, nên so sánh với nó cho biết NeuMF-F có học được gì vượt trên xu hướng chung hay không.
3. Content: khuyến nghị theo nội dung thuần. Mỗi sản phẩm được biểu diễn bằng vector văn bản nối với mã hoá one-hot của ba thuộc tính: nhóm sản phẩm, nhóm chỉ mục và nhóm may mặc. Thuộc tính màu không được dùng vì sau khi gộp các màu của một mẫu thiết kế, nó không còn phân biệt sản phẩm. Vector được chuẩn hoá về độ dài 1. Hồ sơ của khách là trung bình có trọng số các vector sản phẩm đã mua, với trọng số giảm theo thời gian theo chu kỳ bán rã (*half-life*) h ngày, $\omega = 2^{-(\tau - t_{uj})/h}$, hoặc bằng 1 nếu không dùng trọng số. Điểm là độ tương đồng cosine giữa hồ sơ và sản phẩm.
4. ItemKNN và UserKNN: lọc cộng tác dựa trên láng giềng, với số láng giềng k và hệ số co chọn trên tập xác thực.
5. BPR-MF: nhân tử hoá ma trận tối ưu thứ hạng theo cặp, đại diện cho MF tuyến tính được tinh chỉnh cùng ngân sách.
6. Hybrid-CBCF: mô hình lai truyền thống theo kiểu lai có trọng số trong phân loại của Burke [9], áp dụng cho phản hồi ẩn. Mô hình kết hợp ba mô hình đơn lẻ truyền thống, Content, UserKNN và ItemKNN, ở mức điểm dự đoán. Cấu hình của ba thành phần giữ nguyên như khi tinh chỉnh. Điểm của mỗi thành phần được chuẩn hoá min–max trên tập ứng viên của khách như LateFusion-F (Công thức (2.15)), tạo thành vector $x_{ui} = (x_{ui}^{CB}, x_{ui}^{U}, x_{ui}^{I})$. Có hai cách kết hợp. Cách bỏ phiếu lấy trung bình, giá trị lớn nhất hoặc nhỏ nhất của ba điểm. Cách trọng số tính $\hat{y}_{ui} = w \cdot x_{ui}$. Phản hồi ẩn không có điểm đánh giá, nên đề tài học w theo cặp: với mỗi sản phẩm

đúng p và sản phẩm không đúng j trong tập ứng viên của cùng một khách, $P(p \text{ xếp trên } j) = \sigma\big(w \cdot (x_{up} - x_{uj})\big)$. Đây là hồi quy logistic trên hiệu đặc trưng, cùng tiêu chí với BPR (Công thức (2.6)) nhưng với hàm điểm tuyến tính. Mô hình không có tham số khởi tạo ngẫu nhiên nên cho cùng kết quả ở mọi seed.

Most Popular, ItemKNN, UserKNN và BPR-MF chỉ dùng mã ID, như GMF, MLP và NeuMF.

3.5 Lấy mẫu âm theo thời điểm và hàm mục tiêu

3.5.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm

Phản hồi ẩn chỉ ghi nhận các tương tác đã xảy ra, không có nhãn âm tường minh. Lấy mẫu âm giả định các sản phẩm khách chưa mua nhiều khả năng là âm. Với mô hình có đặc trưng, mỗi cặp dương (u, i) mang ngày mua đầu t_{ui}, nên việc chọn mẫu âm phải nhất quán về thời gian. Với mỗi cặp dương, hệ thống lấy ngẫu nhiên N_{ratio} sản phẩm j trong các sản phẩm của tập huấn luyện đã ra mắt trước hoặc trong ngày t_{ui} ($d_j^0 \leq t_{ui}$), trừ những sản phẩm khách u đã mua, và gán nhãn $y_{uj} = 0$. Đặc trưng của mẫu âm được tính tại cùng ngày t_{ui}.

Ràng buộc "đã ra mắt" là cần thiết. Một sản phẩm chưa ra mắt ở ngày t_{ui} thì khách không thể mua, nên không phải là mẫu âm có ý nghĩa. Nếu vẫn lấy, mô hình có thể học quy luật sai "sản phẩm có cờ chưa ra mắt là âm", một tín hiệu chỉ có trong cách tạo dữ liệu huấn luyện. Với mô hình chỉ dùng ID, mẫu âm được lấy đều trong các sản phẩm có ID, trừ sản phẩm khách đã mua, như NCF gốc. N_{ratio} được tinh chỉnh trong $\{4, 8\}$. Mẫu âm được lấy lại ở mỗi epoch, nên mô hình thấy nhiều tổ hợp cặp âm khác nhau. Thuật toán 3.2 mô tả bước này cho mô hình có đặc trưng.

Thuật toán 3.2 Lấy mẫu âm theo thời điểm

Đầu vào: cặp dương $\mathcal{D} = \{(u, i, t)\}$; ngày bán đầu tiên d_j^0; số mẫu âm N_{ratio}
Đầu ra: các bộ huấn luyện (u, j, t, y) của một epoch

$\mathcal{P} \leftarrow$ các sản phẩm có trong $\mathcal{D}$; $\mathcal{I}_u \leftarrow$ các sản phẩm u đã mua trong $\mathcal{D}$
$\mathcal{B} \leftarrow \emptyset$
với mỗi $(u, i, t) \in \mathcal{D}$ làm
    thêm $(u, i, t, 1)$ vào $\mathcal{B}$
    $\mathcal{A}_t \leftarrow \{j \in \mathcal{P} : d_j^0 \leq t\}$ ▷ *đã ra mắt tại ngày t*
    với $n = 1, \ldots, N_{ratio}$ làm
        rút đều $j \in \mathcal{A}_t$, rút lại nếu $j \in \mathcal{I}_u$ (tối đa 20 lần)
        thêm $(u, j, t, 0)$ vào $\mathcal{B}$ ▷ *cùng ngày t với mẫu dương*
trả về $\mathcal{B}$

3.5.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm mất mát entropy chéo nhị phân được tối thiểu hoá cùng số hạng điều chuẩn L_2:

$$\mathcal{L} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_\Theta \|\Theta\|_2^2 \tag{3.10}$$

trong đó Θ là toàn bộ tham số học được (vector nhúng ID, vector nhúng thuộc tính, ma trận chiếu, tháp MLP, lớp đầu ra) và $\lambda_\Theta \in \{0;\ 10^{-6}\}$ được tinh chỉnh. Hàm mất mát được tính trên logit để ổn định số học. Các mô hình được cài đặt bằng PyTorch [25] và tối ưu bằng Adam [26] với kích thước lô (*batch size*) 512.

3.6 Quy trình huấn luyện và tinh chỉnh

3.6.1 Không gian tinh chỉnh và dừng sớm

Để mọi mô hình có cùng ngân sách tinh chỉnh, mỗi mô hình có học được thử đúng 6 cấu hình trong không gian ở Bảng 3.6. Đó là cấu hình mặc định và 5 cấu hình rút ngẫu nhiên không lặp từ lưới của mô hình, bằng một bộ sinh số ngẫu nhiên cố định. Mô hình chỉ có một tham số (MostPopular-Recent, Content, LateFusion-F) được thử đủ lưới. Mọi cấu hình được huấn luyện với seed 42 và chấm trên tập xác thực của mẫu phát triển.

Bảng 3.6: Không gian tinh chỉnh

Mô hình	Siêu tham số và giá trị thử	Cấu hình mặc định
GMF, MLP, NeuMF; GMF-F, MLP-F, NeuMF-F	tốc độ học $\{10^{-3},\ 5 \cdot 10^{-4}\}$; số chiều d $\{32, 64\}$; số mẫu âm $\{4, 8\}$; hệ số điều chuẩn L2 $\{0,\ 10^{-6}\}$; dropout của tháp MLP $\{0;\ 0{,}2\}$ (trừ GMF, GMF-F)	10^{-3}; 32; 4; 10^{-6}; 0,2
Thêm cho GMF-F, MLP-F, NeuMF-F	xác suất bỏ ID ρ $\{0;\ 0{,}25;\ 0{,}5\}$	0,25
Cố định cho mọi mạng lưới thần kinh	Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm khi NDCG@10 xác thực không cải thiện sau 5 epoch; vector nhúng thuộc tính 8 chiều, vector văn bản 64 chiều	không có
BPR-MF	d $\{32, 64, 128\}$; tốc độ học $\{0{,}01;\ 0{,}03;\ 0{,}05\}$; hệ số điều chuẩn $\{0{,}001;\ 0{,}005;\ 0{,}01\}$; số epoch $\{20, 40\}$	32; 0,03; 0,005; 20
ItemKNN, UserKNN	số láng giềng k $\{20, 50, 100, 200, 500\}$; hệ số co $\{0, 10, 50\}$	100; 0
MostPopular-Recent	cửa sổ W $\{7, 14, 28, 56, 91\}$ ngày	thử đủ lưới
Content	chu kỳ bán rã của trọng số theo thời gian $\{$không trọng số$, 30, 90, 180, 365\}$ ngày	thử đủ lưới
LateFusion-F	w $\{0;\ 0{,}1;\ \ldots;\ 1\}$ trên GMF-F và MLP-F tốt nhất	thử đủ lưới
Hybrid-CBCF (bổ sung)	cách kết hợp: trung bình, lớn nhất, nhỏ nhất, tổng có trọng số học theo cặp	thử cả bốn

Sau mỗi epoch, mạng được chấm NDCG@10 trên tập xác thực bằng cách xếp hạng toàn bộ. Trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi độ đo không cải thiện sau 5 epoch liên tiếp (*patience* $P = 5$). Số epoch tốt nhất e^* được ghi lại để dùng khi huấn luyện lại. Trước khi dự đoán cho giai đoạn kiểm thử, mô hình được huấn luyện lại từ đầu trên mọi cặp trước mốc kiểm thử đúng e^* epoch. Lúc này không còn tập xác thực để dừng, và tập kiểm thử không bao giờ được dùng để dừng (Thuật toán 3.3).

Thuật toán 3.3 Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch

Đầu vào: cấu hình θ, seed s; $\mathcal{D}_{\tau_{val}}$ và tập xác thực V; $\mathcal{D}_{\tau_{test}}$; $E_{max} = 20$; $P = 5$
Đầu ra: mô hình f^* và số epoch e^*

hàm HuấnLuyện($\mathcal{D}, E, V$)
    khởi tạo f theo θ và s; $b \leftarrow -\infty$; $e^* \leftarrow 0$; $c \leftarrow 0$
    với $e = 1, \ldots, E$ làm
        lấy lại mẫu âm (Thuật toán 3.2); một lượt Adam theo BCE, lô 512
        nếu $V = \emptyset$ thì ▷ *huấn luyện lại: chạy đủ E epoch*
            $e^* \leftarrow e$
        ngược lại nếu NDCG@10 của f trên V lớn hơn b thì
            $b \leftarrow$ NDCG@10 đó; $e^* \leftarrow e$; lưu trọng số; $c \leftarrow 0$
        ngược lại
            $c \leftarrow c + 1$; dừng nếu $c = P$
    trả về f (trọng số đã lưu nếu $V \neq \emptyset$), e^*
$(\cdot, e^*) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{val}}, E_{max}, V$) ▷ *chọn số epoch*
$(f^*, \cdot) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{test}}, e^*, \emptyset$) ▷ *huấn luyện lại từ đầu*
trả về f^*, e^*

3.7 Quy trình đánh giá không thiên lệch

3.7.1 Khảo sát ban đầu và định hướng thiết kế

Trước khi xây dựng mô hình đề xuất, đề tài khảo sát NeuMF chỉ dùng mã khách hàng và mã sản phẩm, đồng thời thử đưa cả sản phẩm chưa từng bán vào tập ứng viên. Khảo sát cho ba định hướng thiết kế. Thứ nhất, NeuMF chỉ dùng mã định danh không vượt BPR-MF đã tinh chỉnh, nên mô hình cần thêm thông tin chứ không chỉ thêm tham số. Đây là cơ sở để xây dựng NeuMF-F. Thứ hai, ở quy mô mẫu này, khả năng khuyến nghị sản phẩm mới hầu như không đo được, nên quy trình cuối gộp màu theo mẫu thiết kế và chỉ giữ sản phẩm đã có dữ liệu huấn luyện trong tập ứng viên. Thứ ba, để kết luận không bị ảnh hưởng bởi những gì đã thấy khi khảo sát, kết luận chỉ được lấy trên một mẫu khách hàng chưa từng được dùng, theo các nguyên tắc dưới đây.

3.7.2 Các nguyên tắc đánh giá

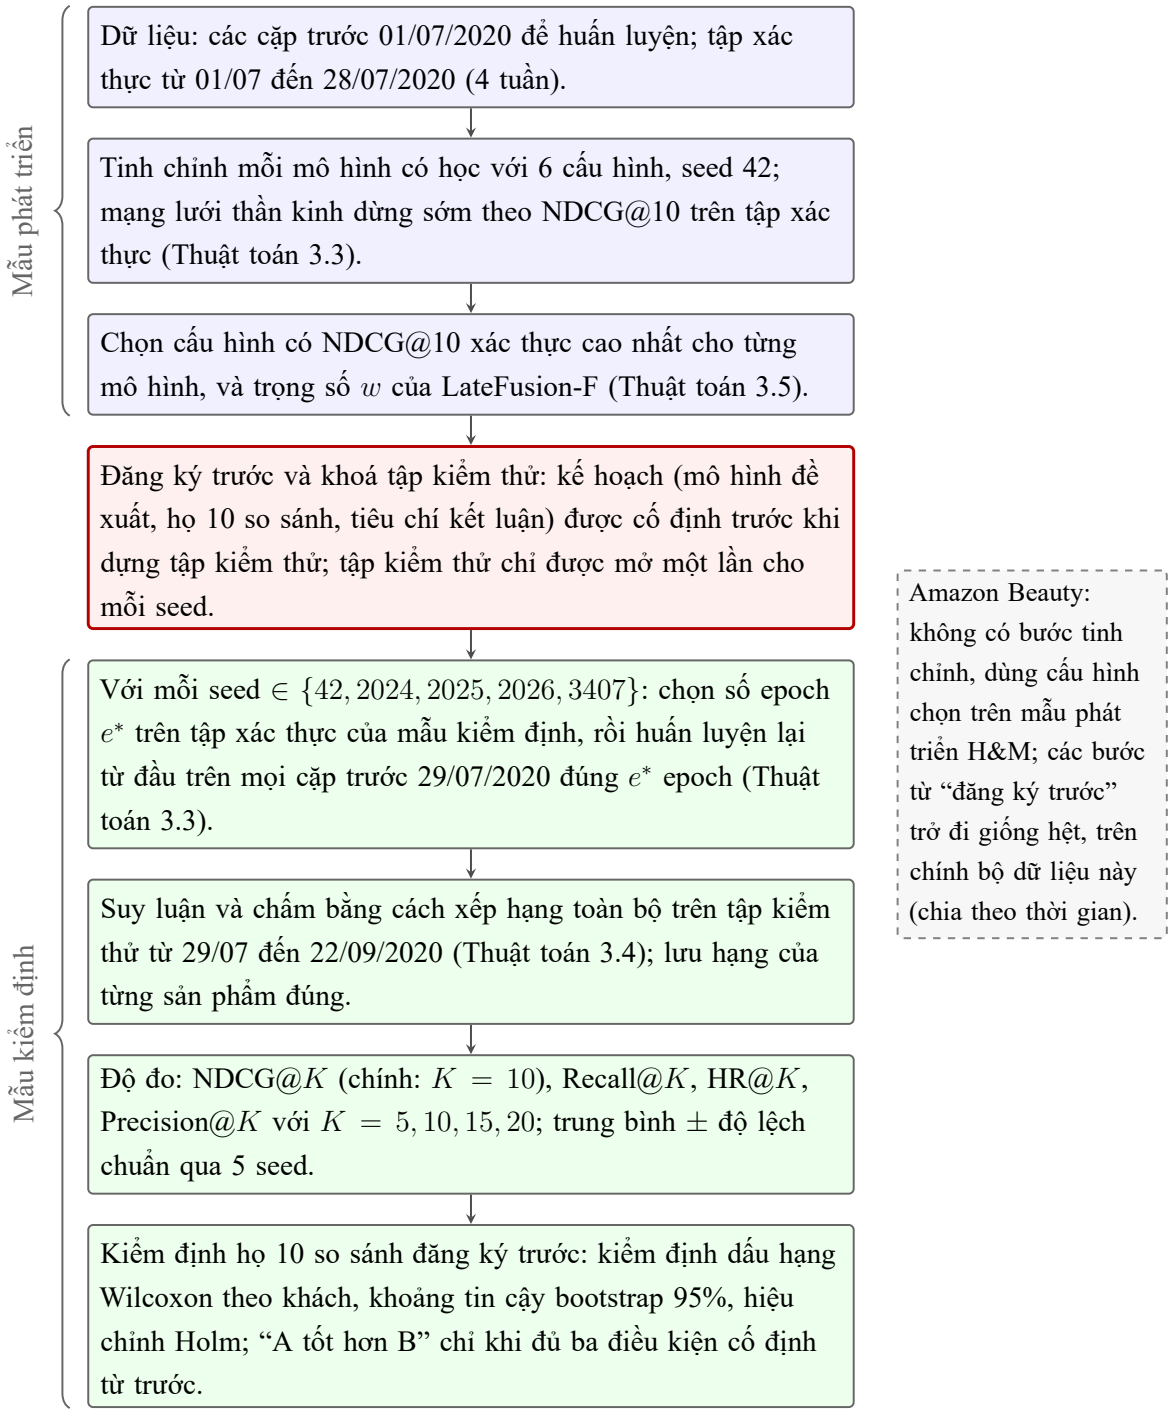
Ferrari Dacrema và cộng sự [27] chỉ ra hai lỗi phương pháp thường gặp khi đánh giá mô hình khuyến nghị học sâu: chọn số epoch hay cấu hình dựa trên chính tập

kiểm thử, và tinh chỉnh mô hình đối chứng sơ sài. Rendle và cộng sự [5] cũng cho thấy kết luận so sánh phụ thuộc mạnh vào việc mô hình đối chứng có được tinh chỉnh đầy đủ hay không. Ngoài ra còn một rủi ro thứ ba: khi tập kiểm thử đã được xem, những quyết định đưa ra sau đó dễ bị ảnh hưởng bởi kết quả đã thấy, dù người làm không chủ ý. Quy trình đánh giá của đề tài (Hình 3.3) xử lý cả ba rủi ro bằng sáu nguyên tắc dưới đây. Quy trình này tách khỏi đường ống ở Hình 3.1: nó chỉ gọi lại các bước huấn luyện và suy luận với những mốc thời gian khác nhau, rồi so danh sách khuyến nghị với những gì khách đã mua thật.

1. Tách mẫu phát triển và mẫu kiểm định. Mọi lựa chọn mô hình, siêu tham số và số epoch dựa trên tập xác thực: tinh chỉnh trên mẫu phát triển, chọn số epoch khi đánh giá cuối trên tập xác thực của mẫu kiểm định. Tập kiểm thử của mẫu kiểm định chỉ được mở một lần, ở đánh giá cuối.
2. Đăng ký trước và khoá tập kiểm thử. Mô hình đề xuất, danh sách mô hình, lưới tinh chỉnh, số seed, độ đo chính, họ so sánh và tiêu chí kết luận được ghi vào kế hoạch thực nghiệm trước khi có kết quả tinh chỉnh của mô hình có đặc trưng nào. Tập kiểm thử của mẫu kiểm định chỉ được dựng sau khi kế hoạch đã cố định. Kiểm chứng trên Amazon Beauty và phân tích bổ sung với Hybrid-CBCF có kế hoạch riêng theo cùng cách.
3. Cùng ngân sách tinh chỉnh. Mọi mô hình có học được thử 6 cấu hình.
4. Huấn luyện lại trước khi chấm. Với mỗi seed (42, 2024, 2025, 2026, 3407) và mỗi mạng lưới thần kinh, mô hình được huấn luyện trên dữ liệu trước 01/07/2020 của mẫu kiểm định và dừng sớm theo NDCG@10 trên tập xác thực của chính mẫu này để chọn số epoch e^*. Sau đó mô hình được huấn luyện lại từ đầu trên mọi cặp trước 29/07/2020 đúng e^* epoch rồi mới chấm tập kiểm thử (Thuật toán 3.3). BPR-MF và các mô hình không phải mạng lưới thần kinh được khớp trên mọi cặp trước 29/07/2020. LateFusion-F trộn đúng GMF-F và MLP-F đã huấn luyện lại ở cùng seed.
5. Kiểm định thống kê. Với mỗi khách được đánh giá, NDCG@10 được lấy trung bình qua 5 seed. Mô hình tất định cho cùng giá trị ở mọi seed. Kiểm định vì vậy đo khác biệt giữa hai mô hình trên cùng tập khách, còn dao động giữa các seed được báo cáo riêng bằng độ lệch chuẩn. Từng cặp mô hình được so sánh bằng kiểm định dấu hạng Wilcoxon ghép cặp theo người dùng [28] và khoảng tin cậy 95% của hiệu trung bình bằng bootstrap ghép cặp với 10.000 lần lấy mẫu lại [29]. Giá trị p được hiệu chỉnh Holm [30]

trên một họ 10 so sánh đăng ký trước. Chín so sánh đặt NeuMF-F cạnh: NeuMF (đặc trưng có giúp mô hình lai không); GMF-F và MLP-F (hợp nhất so với từng nhánh); LateFusion-F (hợp nhất sớm so với muộn); BPR-MF, ItemKNN, UserKNN, MostPopular-Recent và Content. So sánh thứ mười là NeuMF với BPR-MF (mô hình lai chỉ dùng ID so với MF).

6. Tiêu chí kết luận cố định. Kết luận "A tốt hơn B" chỉ được viết khi đồng thời $p_{Holm} < 0{,}05$, khoảng tin cậy không chứa 0 và chênh lệch tương đối NDCG@10 không dưới 5%; ngược lại, kết luận là "không khác biệt có ý nghĩa". Ngưỡng 5% là mức cải thiện tối thiểu có ý nghĩa thực tiễn, đặt theo quy ước. Bỏ ngưỡng này thì không kết luận nào ở Chương 4 thay đổi.



Hình 3.3: Quy trình tinh chỉnh và đánh giá cuối

Ngoài họ so sánh trên, phân tích bóc tách chỉ chạy một seed, được báo cáo kèm khoảng tin cậy nhưng không kiểm định và không dùng để kết luận chính. Độ phủ, số epoch và thời gian huấn luyện cũng chỉ mang tính mô tả.

Thuật toán 3.4 là cách mọi mô hình được chấm trên một giai đoạn, với tập ứng viên $\mathcal{C}_u$ và tập sản phẩm đúng T_u theo Công thức (3.3) và (3.4), và các độ đo theo Công

thức (2.17)–(2.19). Mọi mô hình dùng cùng tập ứng viên và cùng quy tắc phá hoà (*tie-breaking*) khi hai sản phẩm bằng điểm. Khoá phá hoà $h(u, i)$ là một giá trị băm của cặp (u, i), sinh từ seed cố định 2026. Nhờ vậy chênh lệch giữa hai mô hình chỉ đến từ điểm số của chúng. Hạng của từng sản phẩm đúng được lưu theo từng khách, nên độ đo ở một K bất kỳ tính lại được mà không phải chấm lại tập kiểm thử. Thuật toán 3.5 chọn trọng số trộn của LateFusion-F (Công thức (2.15)) chỉ trên tập xác thực của mẫu phát triển. Trọng số này (w=0,4 (GMF-F), $1 - w$=0,6 (MLP-F)) được giữ nguyên ở đánh giá cuối.

Thuật toán 3.4 Đánh giá bằng xếp hạng toàn bộ tập ứng viên

Đầu vào: hàm điểm $s(u, i)$; tập khách $\mathcal{U}_{eval}$, mỗi khách có $\mathcal{C}_u$ và T_u; các giá trị K
Đầu ra: độ đo trung bình theo khách; hạng R_u của các sản phẩm đúng

với mỗi $u \in \mathcal{U}_{eval}$ làm
    tính $s(u, i)$ với mọi $i \in \mathcal{C}_u$ ▷ *mạng lưới thần kinh: dùng logit*
    sắp $\mathcal{C}_u$ giảm dần theo $s(u, i)$; bằng điểm thì theo khoá cố định $h(u, i)$
    $R_u \leftarrow$ hạng của các $i \in T_u$ trong danh sách đã sắp; lưu R_u
    tính HR@K, Precision@K, Recall@K, NDCG@K của u từ R_u với mỗi K
trả về trung bình các độ đo trên $\mathcal{U}_{eval}$; các R_u

Thuật toán 3.5 Chọn trọng số của LateFusion-F

Đầu vào: GMF-F, MLP-F đã chọn khi tinh chỉnh; tập xác thực V; lưới $W = \{0;\ 0{,}1;\ \ldots;\ 1\}$
Đầu ra: trọng số w^*

với mỗi khách u của V làm
    $a_u \leftarrow \text{minmax}\big(s^{\text{GMF-F}}(u, \mathcal{C}_u)\big)$; $b_u \leftarrow \text{minmax}\big(s^{\text{MLP-F}}(u, \mathcal{C}_u)\big)$
với mỗi $w \in W$ làm
    $N(w) \leftarrow$ NDCG@10 trên V của điểm $w\, a_u + (1 - w)\, b_u$ ▷ *Thuật toán 3.4*
trả về $w^* = \arg\max_{w \in W} N(w)$

Thuật toán 3.6 chọn cách kết hợp của mô hình lai truyền thống Hybrid-CBCF, cũng chỉ trên tập xác thực của mẫu phát triển. Trọng số của cách kết hợp có trọng số được học, không chọn trên lưới. Vì vậy NDCG@10 dùng để so với các cách bỏ phiếu được tính bằng khớp chéo (*cross-fitting*) theo khách: trọng số dùng để chấm một khách luôn được học trên những khách khác. Hàm HọcTrọngSố rút $m = 50$ sản

phẩm không đúng cho mỗi sản phẩm đúng bằng một seed cố định, rồi khớp hồi quy logistic có điều chuẩn L_2, không hệ số chặn, tức tối đa hoá $\sum \ln \sigma\big(w \cdot (x_{up} - x_{uj})\big)$ như ở mục 3.4.2. Ba mô hình thành phần được khớp trên dữ liệu trước mốc xác thực. Cách kết hợp và trọng số được chọn giữ nguyên khi đánh giá trên mẫu kiểm định và trên Amazon Beauty.

Thuật toán 3.6 Chọn cách kết hợp của Hybrid-CBCF

Đầu vào: Content, UserKNN, ItemKNN đã tinh chỉnh; tập xác thực V; $m = 50$
Đầu ra: cách kết hợp F^*; trọng số w^* nếu F^* là tổng có trọng số

$x_{ui} \leftarrow$ ba điểm đã chuẩn hoá min–max trên $\mathcal{C}_u$, với mọi $u \in V$, $i \in \mathcal{C}_u$
với $F \in \{\text{trung bình}, \max, \min\}$ làm ▷ *bỏ phiếu*
    $N(F) \leftarrow$ NDCG@10 trên V của điểm $F(x_{ui})$
chia khách của V thành P_0, P_1 theo chỉ số chẵn, lẻ ▷ *cross-fitting*
với $k \in \{0, 1\}$ làm
    $w_k \leftarrow$ HọcTrọngSố($V \setminus P_k$); chấm khách $u \in P_k$ bằng $w_k \cdot x_{ui}$
$N(\text{trọng số}) \leftarrow$ NDCG@10 trên V của điểm vừa chấm
$F^* \leftarrow \arg\max_F N(F)$
nếu F^* là tổng có trọng số thì
    $w^* \leftarrow$ HọcTrọngSố(V)
trả về F^*, w^*

hàm HọcTrọngSố(tập khách S)
    với mỗi sản phẩm đúng p của $u \in S$: rút m sản phẩm không đúng $j \in \mathcal{C}_u$
    trả về hồi quy logistic (L_2, không hệ số chặn) trên các hiệu $\pm(x_{up} - x_{uj})$

3.8 Suy luận Top-K và xử lý khách hàng mới

Bước cuối của đường ống là suy luận. Với một khách hàng và một số K cho trước, hệ thống trả về K sản phẩm nên khuyến nghị. Thuật toán 3.7 mô tả bước này, và hệ thống demo khuyến nghị theo đúng các bước đó. Với khách đã có trong dữ liệu đã học, đây chính là các bước chấm điểm và sắp xếp của Thuật toán 3.4, chỉ khác là không có sản phẩm đúng để so sánh. Vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần khi nạp mô hình, nên mỗi yêu cầu khuyến nghị chỉ còn một lượt lan truyền thuận trên các sản phẩm ứng viên của khách.

Khách hàng mới là tình huống *cold start* của người dùng. Mô hình chỉ có vector

nhúng ID và đặc trưng thời gian cho những khách đã có trong dữ liệu đã học. Với một khách chưa mua gì, hoặc mua quá ít để qua bước lọc 10-core, mô hình đề xuất không có thông tin về sở thích. Trong trường hợp đó, hệ thống trả về danh sách các sản phẩm được nhiều khách mua nhất trước mốc, chính là mô hình đối chứng Most Popular. Khi khách đã có lịch sử mua trong dữ liệu đã học, hệ thống dùng NeuMF-F. Với quy tắc này, mọi yêu cầu đều nhận được một danh sách khuyến nghị. Đánh giá định lượng của đề tài chỉ đo nhóm khách đã có lịch sử, nên chất lượng khuyến nghị cho khách mới không được đo riêng.

Thuật toán 3.7 Suy luận Top-K cho một khách hàng

Đầu vào: mã khách c; số khuyến nghị K; NeuMF-F đã lưu; danh sách phổ biến L_{pop}
Đầu ra: K sản phẩm khuyến nghị

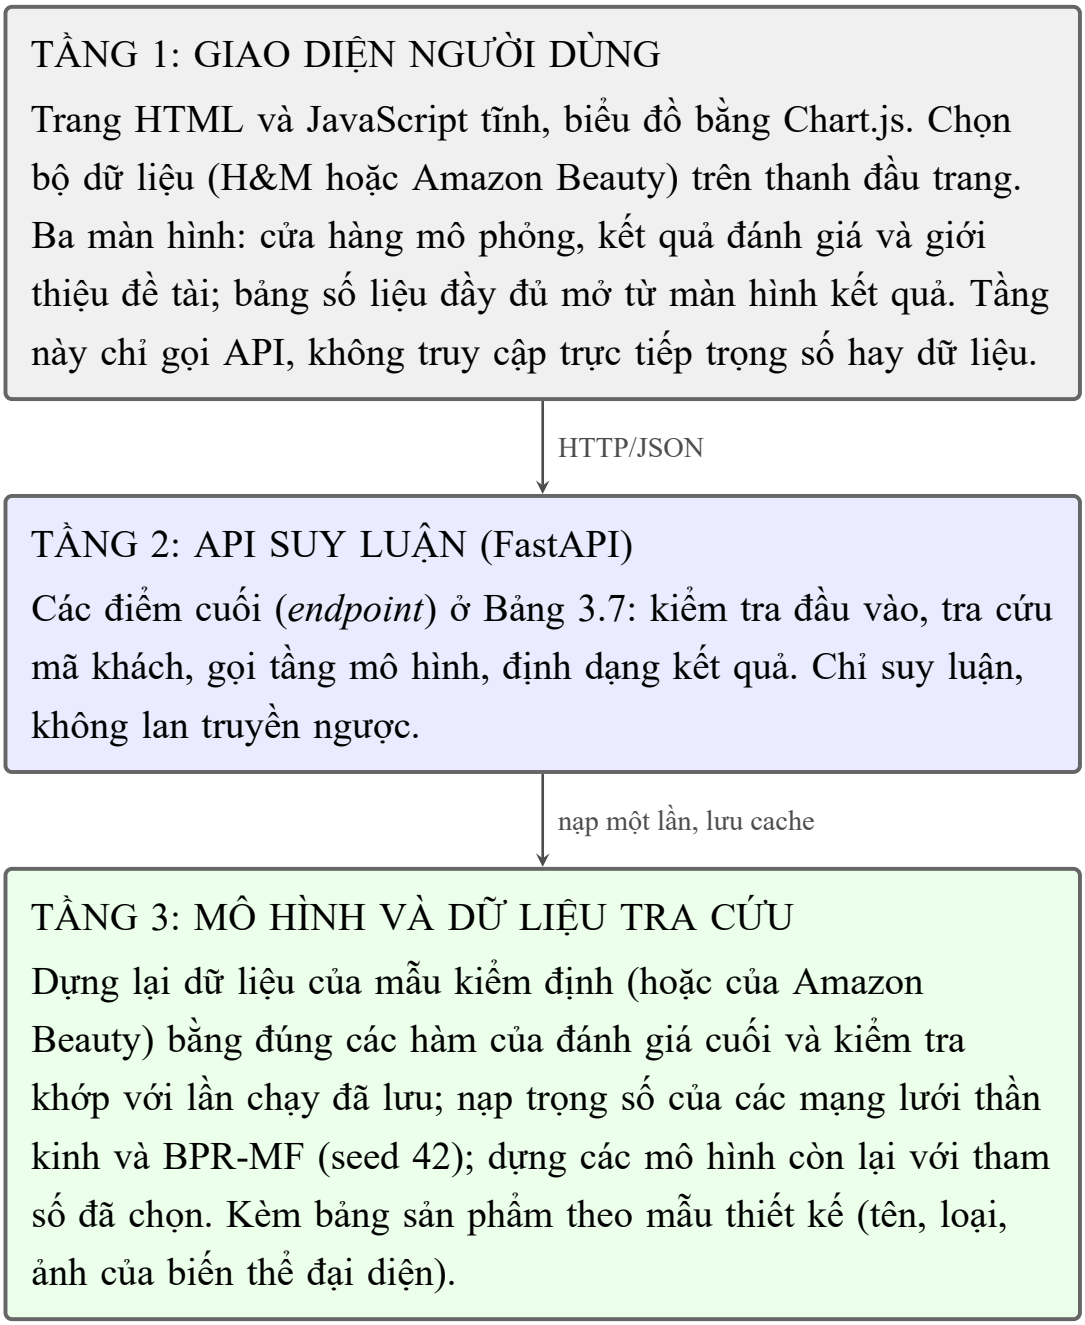
nếu c không có trong dữ liệu đã học thì ▷ *khách mới*
    trả về K sản phẩm đầu của L_{pop}
$u \leftarrow$ mã nội bộ của c; $\mathcal{C}_u \leftarrow \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau)$ ▷ *bỏ sản phẩm đã mua*
$s_{ui} \leftarrow h^\top \left[p_u^G \odot q_i^G;\ \mathrm{MLP}([p_u^M;\ q_i^M]) \right]$ với mọi $i \in \mathcal{C}_u$
trả về K sản phẩm có s_{ui} lớn nhất (bằng điểm: theo khoá cố định)

3.9 Thiết kế hệ thống demo

Hệ thống demo minh hoạ các mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt với phần huấn luyện. Nó chỉ nạp trọng số mô hình đã lưu và gọi lại đúng các hàm xử lý dữ liệu, xếp hạng của quy trình đánh giá, không huấn luyện lại.

3.9.1 Kiến trúc ba tầng

Demo được xây dựng theo hai nguyên tắc. Nguyên tắc thứ nhất là tách suy luận khỏi huấn luyện, để thời gian phản hồi không phụ thuộc chi phí huấn luyện. Nguyên tắc thứ hai là kiểm tra dữ liệu dựng lại khớp với dữ liệu đã dùng khi huấn luyện, để tránh tình huống ánh xạ mã sai nhưng mô hình vẫn chạy. Tập ứng viên và sản phẩm đích của mỗi khách được lấy từ dữ liệu của đánh giá cuối, và với khách đã được đánh giá, demo hiện kèm kết quả đã lưu để người xem đối chiếu.



Hình 3.4: Kiến trúc ba tầng của hệ thống demo

3.9.2 Thiết kế API suy luận

Chức năng chính của API là khuyến nghị Top-K. Các điểm cuối khác phục vụ việc tra cứu khách, sản phẩm và kết quả (Bảng 3.7). Chức năng khuyến nghị chạy đúng các bước của Thuật toán 3.7 và dùng lại các hàm của quy trình đánh giá. Kết quả được ánh xạ về mẫu thiết kế (`product_code`) kèm tên, loại sản phẩm, số màu và ảnh của biến thể đại diện trước khi trả về giao diện.

Bảng 3.7: Các điểm cuối của API suy luận

Điểm cuối	Chức năng
`GET /api/context`	Thông tin bộ dữ liệu, lần chạy đang dùng, số người dùng và sản phẩm, số ứng viên, các giá trị K hợp lệ, các mô hình khả dụng.
`GET /api/users/search`, `/random`	Tìm hoặc chọn ngẫu nhiên một khách hàng có sản phẩm đích, lọc theo nhóm ít, trung bình hoặc nhiều giao dịch.
`GET /api/users/{id}/history`	Lịch sử mua mà mô hình đã học (mọi cặp trước mốc kiểm thử), sắp theo thời gian; với khách mới, lịch sử rỗng và có đánh dấu khách mới.
`GET /api/users/{id}/recommend`	Top-K của một mô hình, hạng của từng sản phẩm đích, số ứng viên và HR@K, NDCG@K, Recall@K của khách đó ($K \in \{5, 10, 15, 20\}$). Khách mới nhận danh sách Most Popular gắn nhãn "gợi ý phổ biến". Khách có lịch sử nhưng không mua gì trong giai đoạn kiểm thử nhận khuyến nghị của mô hình, không có độ đo.
`GET /api/users/{id}/neighbors`	Các khách có gu giống nhất theo UserKNN: số sản phẩm mua chung, ví dụ sản phẩm mua chung, láng giềng nào đã mua sản phẩm khách này mua sau mốc.
`GET /api/items/{id}/similar`	Thông tin một sản phẩm (tên, loại, màu, mô tả, số khách đã mua) và các sản phẩm tương tự nhất theo ItemKNN.
`GET /api/results`	Kết quả của đánh giá cuối cho màn hình kết quả: NDCG@10 và HR@10 của từng mô hình, kết luận của họ so sánh, kết quả bóc tách.
`GET /api/example`	Một khách ví dụ cho màn hình tổng quan: khách mà NeuMF-F khuyến nghị đúng còn NeuMF chỉ dùng ID khuyến nghị sai, với hạng trùng hạng đã lưu ở đánh giá cuối.
`GET /api/dashboard`	Số liệu tổng hợp của đánh giá cuối, hiển thị ở bảng số liệu đầy đủ.

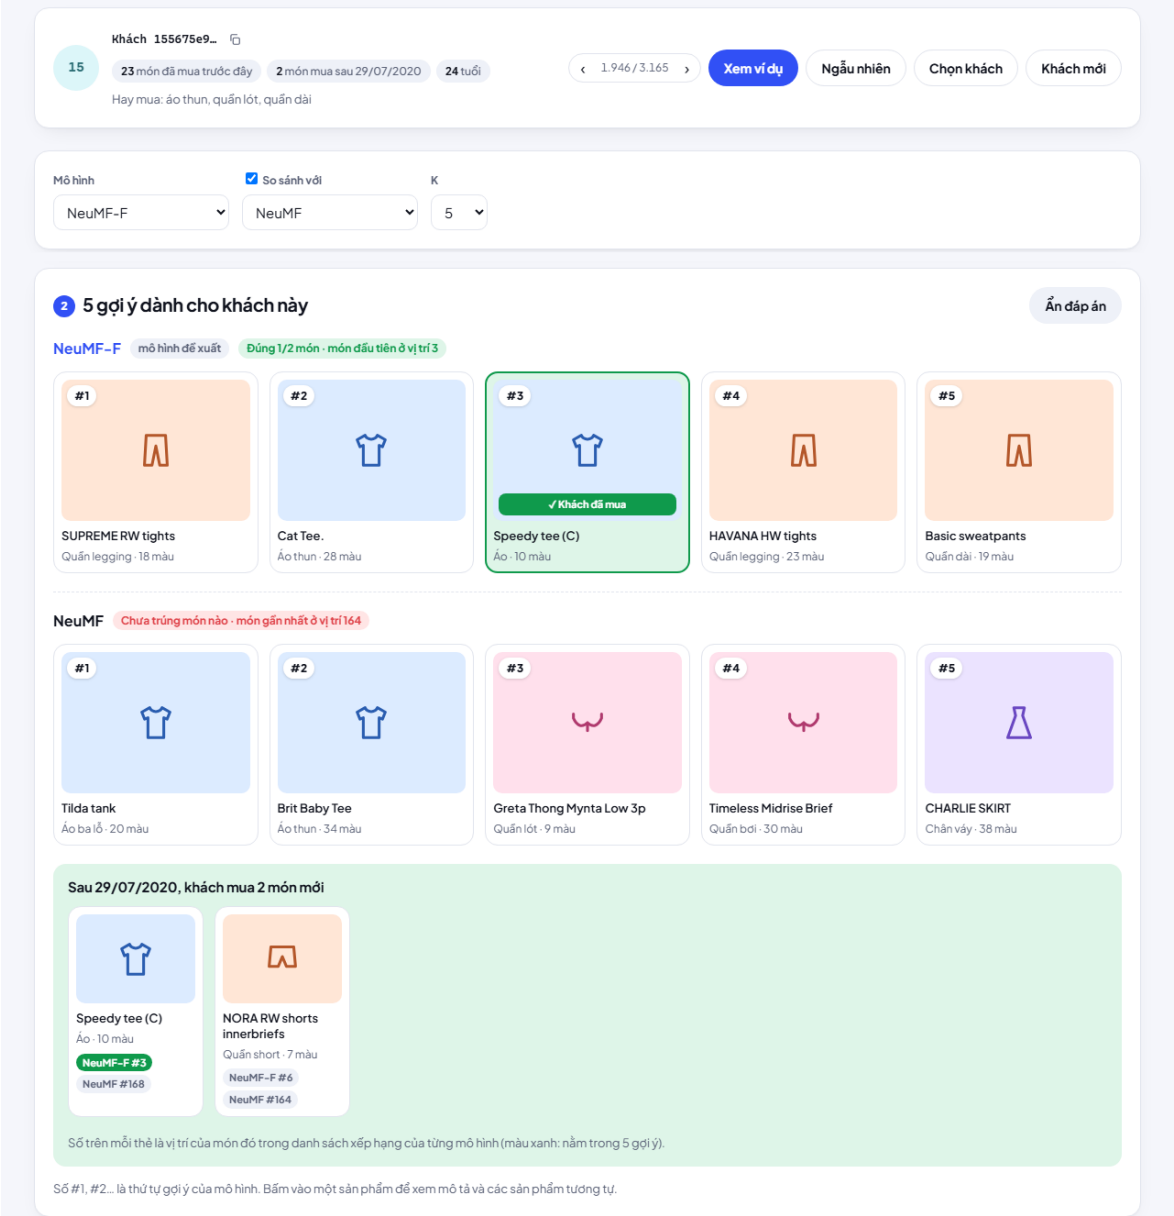
3.9.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng

Demo cho phép chọn và so sánh song song hai mô hình bất kỳ trong số 13 mô hình của đánh giá cuối (trừ Random) và Hybrid-CBCF. Mặc định là NeuMF-F và NeuMF chỉ dùng ID. Người xem có thể tự đối chiếu với kết luận của đánh giá cuối, ví dụ đặt danh sách của NeuMF-F cạnh danh sách của NeuMF trên cùng một khách.

Demo không khẳng định mô hình nào tốt nhất ngoài những gì kiểm định thống kê cho phép. Demo nạp các trọng số của đánh giá cuối ứng với seed 42 trên mẫu kiểm định H&M hoặc trên Amazon Beauty. Vì vậy hạng và độ đo của từng khách trong demo là kết quả của riêng seed này và có thể khác đôi chút so với giá trị trung bình 5 seed ở Chương 4. Lịch sử hiển thị đúng là dữ liệu mô hình đã học, và sản phẩm đích là các món khách mua lần đầu trong giai đoạn kiểm thử. Demo vì vậy minh hoạ lại kết quả của đánh giá cuối trên từng khách, không phải một lần đánh giá mới. Về yêu cầu phi chức năng, vector của mọi khách và sản phẩm tại mốc dự đoán được tính một lần khi nạp. Mỗi yêu cầu khuyến nghị vì vậy chỉ là một lượt lan truyền thuận trên khoảng 6.710 ứng viên. Đo trên máy thực nghiệm chỉ dùng CPU (AMD Ryzen 7 6800H), với 100 khách chọn ngẫu nhiên, một yêu cầu khuyến nghị Top-10 của NeuMF-F mất trung vị 10 ms và 12 ms ở phân vị 95, tính cả thời gian xử lý của API. Lần nạp dữ liệu và mô hình đầu tiên mất khoảng 20 giây với H&M và 6 giây với Amazon Beauty, sau đó được giữ trong bộ nhớ.

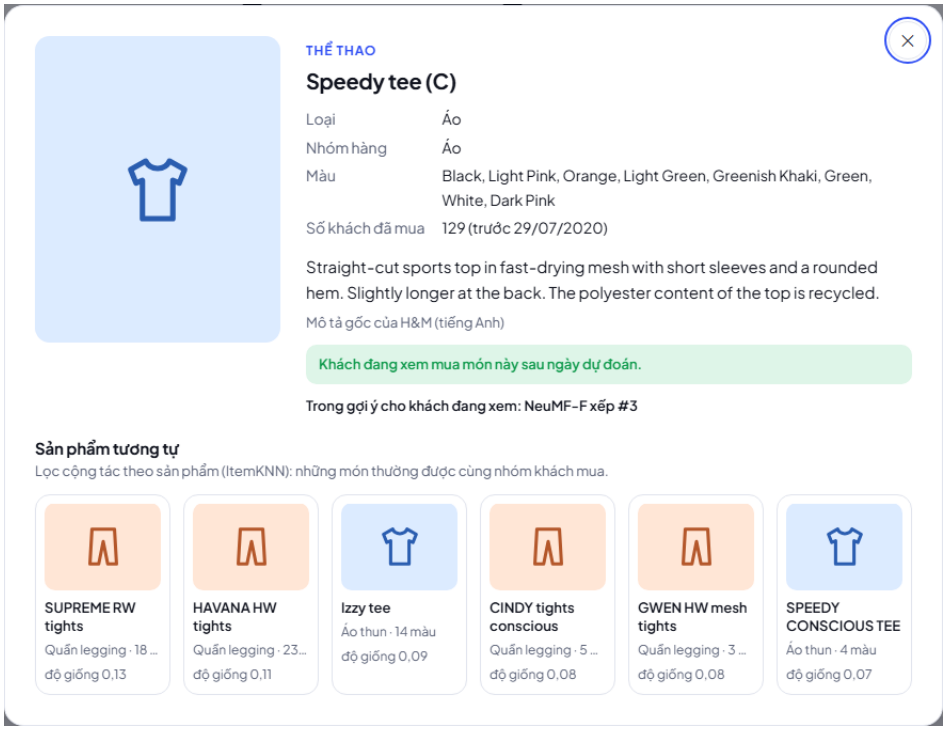
3.9.4 Minh hoạ hệ thống demo

Demo được thiết kế như một cửa hàng trực tuyến, để người xem thấy hệ khuyến nghị hoạt động trong tình huống sử dụng thật, rồi mới xem số liệu tổng hợp. Màn hình chính là cửa hàng mô phỏng (Hình 3.5). Người xem chọn một khách bằng mã, ngẫu nhiên, hoặc bằng nút khách ví dụ. Cửa hàng hiện những món khách đã mua trước mốc, đúng dữ liệu mô hình đã học, và K sản phẩm khuyến nghị dành cho khách dưới dạng thẻ sản phẩm. Khi bật chế độ so sánh, danh sách của hai mô hình được đặt cạnh nhau. Khi bấm nút “Xem khách đã mua gì”, những món khách thật sự mua sau mốc được đánh dấu trong danh sách, kèm vị trí của từng món trong xếp hạng của mỗi mô hình. Với khách ví dụ, NeuMF-F đưa hai món khách mua sau mốc lên vị trí 3 và 6, còn NeuMF chỉ dùng ID xếp món gần đầu nhất ở vị trí 164.

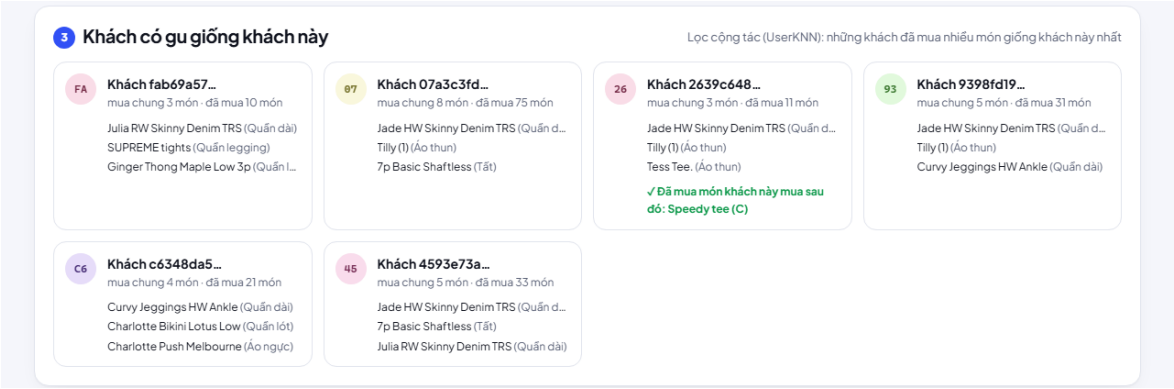


Hình 3.5: Giao diện demo: cửa hàng mô phỏng, đã hiện các món khách mua sau mốc

Bấm vào một sản phẩm bất kỳ sẽ mở thẻ chi tiết (Hình 3.6) với tên, loại, màu, mô tả gốc của H&M và số khách đã mua. Thẻ này cũng cho biết sản phẩm đứng ở vị trí nào trong khuyến nghị của khách đang xem, và liệt kê các sản phẩm tương tự nhất theo ItemKNN, là những món thường được cùng nhóm khách mua. Phía dưới cửa hàng là danh sách khách có gu giống khách đang xem theo UserKNN (Hình 3.7), kèm những món họ mua chung. Sau khi hiện các món khách mua sau mốc, những láng giềng cũng đã mua các món đó được đánh dấu, qua đó minh hoạ cách lọc cộng tác dựa trên láng giềng chọn ra khuyến nghị.

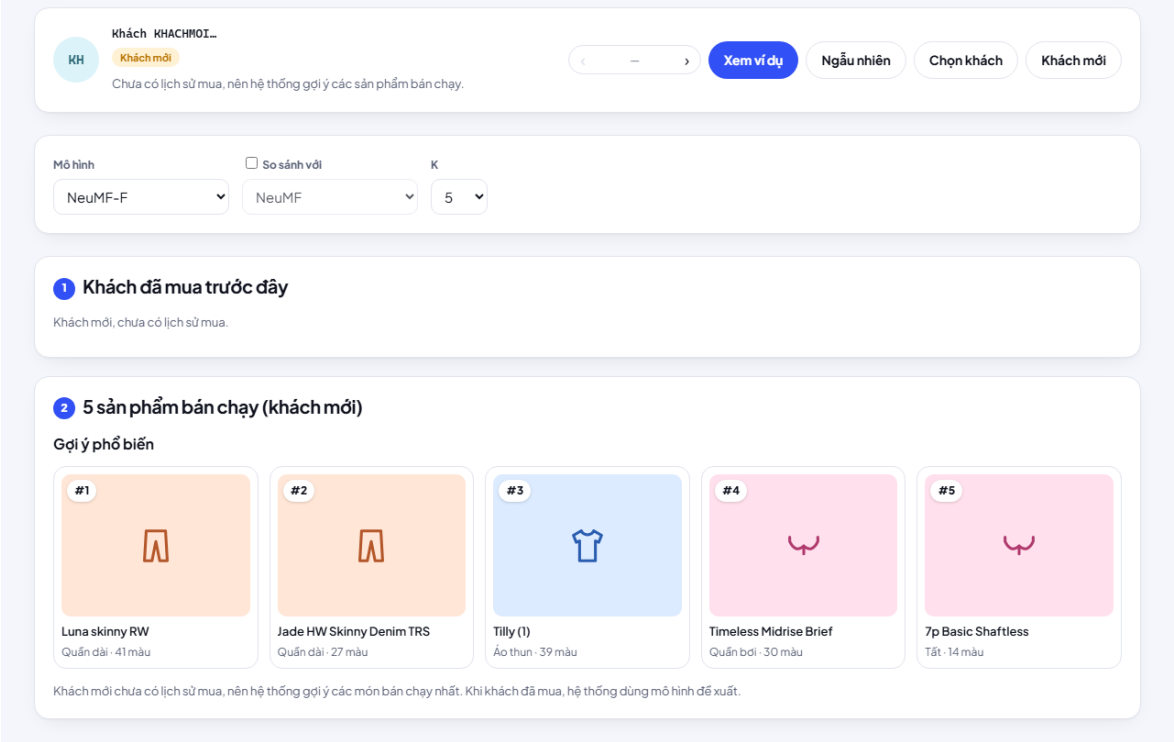


Hình 3.6: Giao diện demo: thẻ chi tiết sản phẩm và sản phẩm tương tự



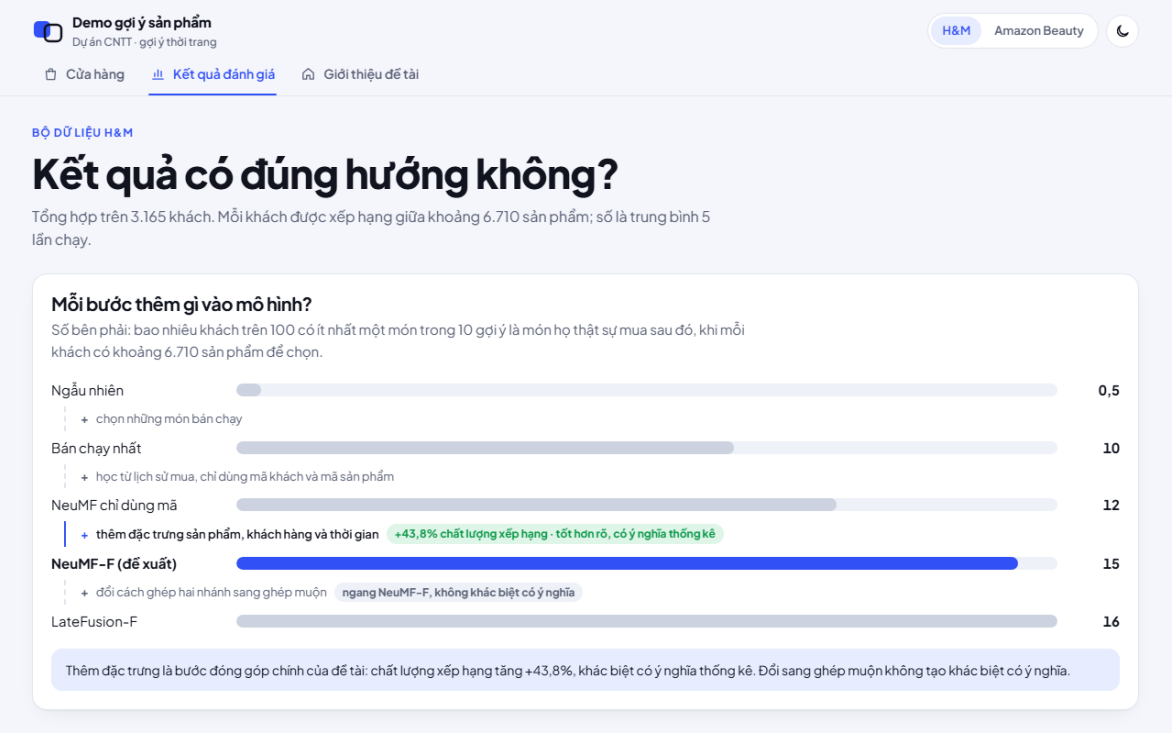
Hình 3.7: Giao diện demo: khách có gu giống khách đang xem

Khách mới chưa có trong dữ liệu đã học nhận danh sách sản phẩm bán chạy kèm nhãn rõ ràng, không báo lỗi (Hình 3.8).

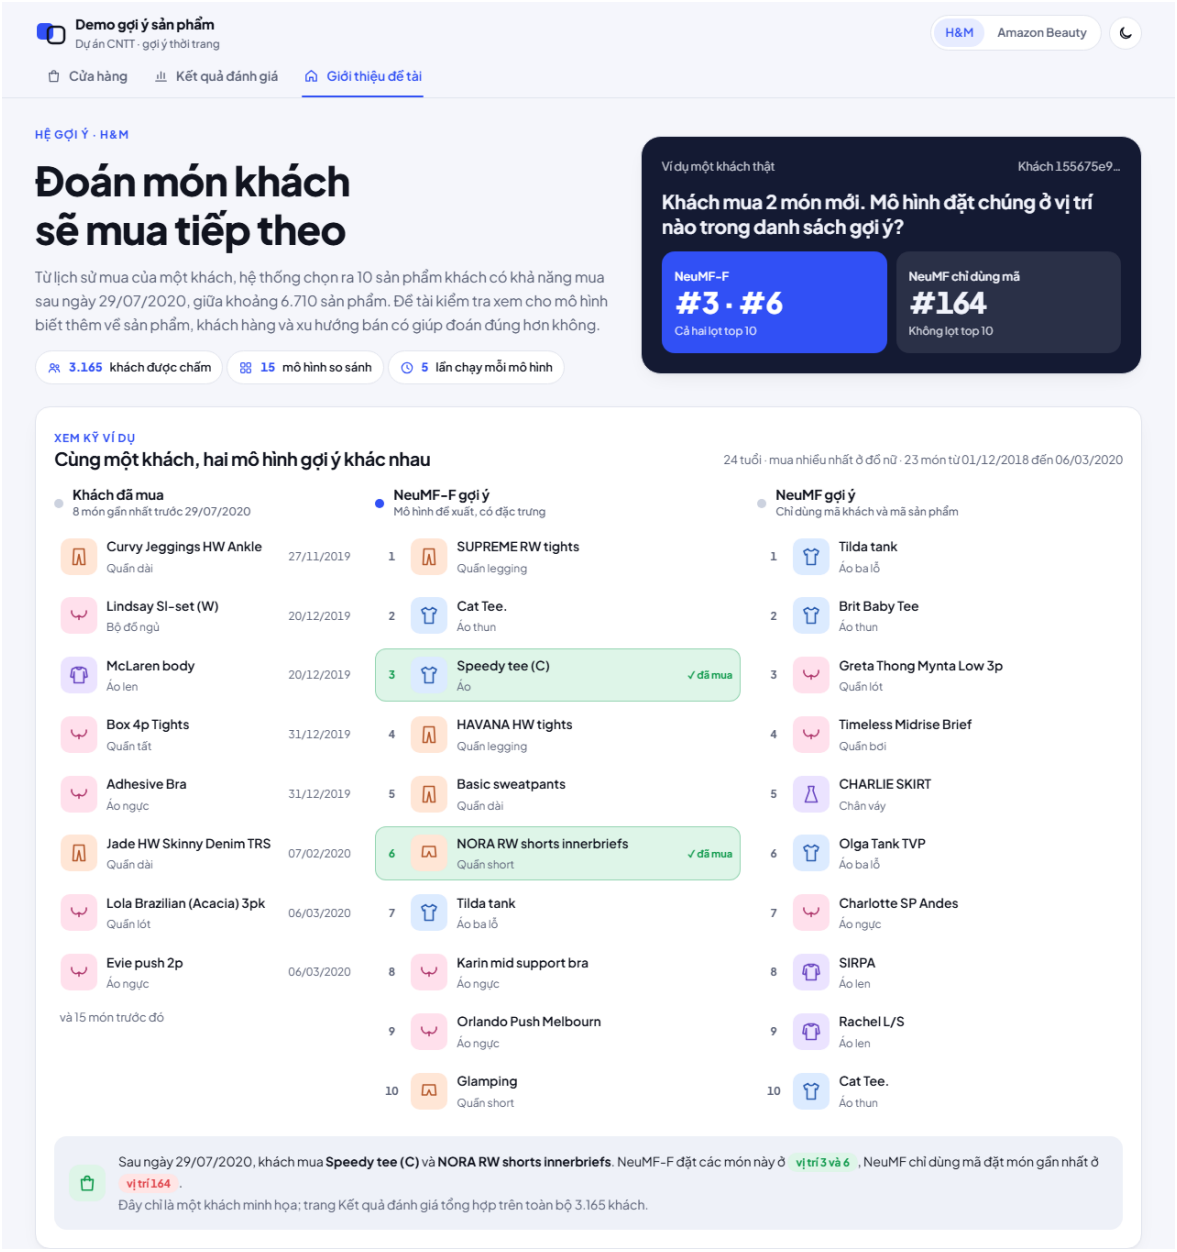


Hình 3.8: Giao diện demo: khuyến nghị cho khách hàng mới

Một khách chỉ là một ví dụ, nên màn hình kết quả đánh giá (Hình 3.9) tổng hợp trên toàn bộ khách của mẫu kiểm định. Màn hình xếp các mô hình thành một bậc thang, từ khuyến nghị ngẫu nhiên, khuyến nghị món bán chạy, NeuMF chỉ dùng mã, tới NeuMF-F và LateFusion-F. Mỗi bậc ghi số khách trên 100 có ít nhất một món đúng trong 10 khuyến nghị, và giữa hai bậc ghi rõ thứ được thêm vào mô hình. Cách trình bày này cho thấy phần cải thiện đến từ bước nào. Trên H&M, bước thêm đặc trưng tạo khác biệt có ý nghĩa thống kê, còn bước đổi cách ghép hai nhánh thì không. Bảng số liệu đầy đủ, cùng số liệu với Chương 4, được mở từ màn hình này. Màn hình giới thiệu đề tài (Hình 3.10) tóm tắt bài toán, dữ liệu, mô hình và cách chấm.



Hình 3.9: Giao diện demo: màn hình kết quả đánh giá



Hình 3.10: Giao diện demo: màn hình giới thiệu đề tài

3.10 Tóm tắt chương

Chương này đã trình bày dữ liệu, mô hình đề xuất NeuMF-F, các mô hình đối chứng, cách huấn luyện, quy trình đánh giá và hệ thống demo. Thiết kế đối chứng biến ba câu hỏi nghiên cứu thành các phép so sánh trực tiếp. So NeuMF-F với các mô hình đối chứng trả lời câu hỏi thứ nhất. So NeuMF-F với NeuMF chỉ dùng ID, cùng phân tích bóc tách, trả lời câu hỏi thứ hai. So NeuMF-F với GMF-F, MLP-F và LateFusion-F trả lời câu hỏi thứ ba. Quy trình đánh giá bảo đảm các phép so sánh này công bằng: cùng dữ liệu, cùng ngân sách tinh chỉnh, và kết luận lấy một lần trên

những khách hàng chưa từng được dùng để chọn mô hình. Chương tiếp theo trình bày kết quả của từng phép so sánh.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

Chương 3 đã trình bày mô hình NeuMF-F, các mô hình đối chứng và quy trình đánh giá. Chương này trình bày kết quả thực nghiệm theo đúng quy trình đó. Mục 4.2 trình bày kết quả tinh chỉnh trên mẫu phát triển. Mục 4.3 trình bày kết quả đánh giá cuối trên mẫu kiểm định của H&M, và mục 4.4 kiểm chứng lại trên Amazon Beauty. Cuối chương, mục 4.6 dùng các kết quả này để trả lời ba câu hỏi nghiên cứu đã nêu ở mục 1.1.3.

4.1 Cấu hình thực nghiệm

Thực nghiệm chính trên H&M gồm hai bước. Bước thứ nhất tinh chỉnh mọi mô hình trên tập xác thực của mẫu phát triển. Bước thứ hai đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định, theo quy trình ở mục 3.7. Quy mô dữ liệu của hai mẫu được trình bày ở Bảng 3.3. Độ đo chính là NDCG@10 lấy trung bình theo khách. Các độ đo còn lại được báo cáo ở $K = 5, 10, 15, 20$, và mỗi kết quả gồm giá trị trung bình cùng độ lệch chuẩn qua 5 seed. Chương này chỉ so sánh các mô hình do nhóm cài đặt và chạy trên cùng dữ liệu, cùng quy trình. Số liệu công bố trong các tài liệu tham khảo không được đặt cạnh để so sánh, vì chúng dùng dữ liệu và cách chia khác. Mã nguồn, dữ liệu đã lọc và toàn bộ kết quả của chương được lưu trong kho mã nguồn của đề tài.

4.2 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển

Trên tập xác thực của mẫu phát triển, bốn mô hình có đặc trưng đứng đầu, trong đó LateFusion-F và NeuMF-F dẫn đầu (Bảng 4.1). Không tính Hybrid-CBCF, mô hình đối chứng không dùng mạng lưới thần kinh cao nhất là UserKNN, tiếp theo là BPR-MF và ItemKNN. NeuMF-F và MLP-F đều chọn xác suất bỏ ID bằng 0, chỉ GMF-F chọn 0,25, nên cơ chế bỏ ID ngẫu nhiên không có mặt trong cấu hình cuối của mô hình đề xuất. Các số trong bảng chỉ dùng để chọn cấu hình, không dùng để kết luận. Cột cấu hình dùng các ký hiệu của Bảng 3.6: d là số chiều vector nhúng, lr là tốc độ học, neg là số mẫu âm cho mỗi mẫu dương. Ngoài ra, wd và reg là hệ số điều chuẩn, shrink là hệ số co của hai mô hình láng giềng, và "bỏ ID" là xác suất bỏ vector nhúng ID của sản phẩm. Dòng Hybrid-CBCF (đánh dấu *) là mô hình bổ sung, được chọn cấu hình sau cùng như trình bày dưới đây.

Bảng 4.1: Cấu hình tốt nhất trên tập xác thực

Mô hình	Cấu hình chọn	NDCG@10	HR@10
NeuMF-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03337	0,12807
LateFusion-F	w=0,4 (GMF-F), $1-w$=0,6 (MLP-F)	0,03556	0,14480
GMF-F	d=32; lr=0,001; neg=8; wd=0; bỏ ID=0,25	0,03162	0,13157
MLP-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03212	0,13429
NeuMF	d=64; lr=0,0005; neg=4; wd=10^{-6}; dropout=0,2	0,02696	0,11016
GMF	d=32; lr=0,001; neg=8; wd=10^{-6}	0,02857	0,11405
MLP	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0	0,02742	0,10977
BPR-MF	d=128; lr=0,03; reg=0,001; 20 epoch	0,02636	0,10666
ItemKNN	k=100; shrink=50	0,02599	0,09537
UserKNN	k=200; shrink=0	0,02753	0,10432
Content	chu kỳ bán rã 30 ngày	0,00459	0,02180
MostPopular-Recent	cửa sổ 28 ngày	0,02334	0,10432
Most Popular	—	0,02174	0,09420
Hybrid-CBCF*	tổng có trọng số học theo cặp: Content 0,12; UserKNN 0,60; ItemKNN 0,28	0,02815	0,10588

Với Hybrid-CBCF, tổng có trọng số học theo cặp là cách kết hợp tốt nhất trên tập xác thực và là cách duy nhất vượt thành phần mạnh nhất, nên được chọn. Bảng 4.2 đặt ba thành phần đứng riêng cạnh bốn cách kết hợp mô tả ở Thuật toán 3.6, với giá trị cao nhất của mỗi cột được in đậm. Bỏ phiếu lấy trung bình đạt NDCG@10 thấp hơn UserKNN đứng riêng, vì Content rất yếu nhưng vẫn nhận trọng số ngang hai thành phần còn lại. Lấy giá trị lớn nhất hoặc nhỏ nhất còn kém hơn nữa. Trong trọng số học được, lọc cộng tác giữ vai trò chính (UserKNN 0,60 và ItemKNN 0,28), còn lọc nội dung chỉ chiếm 0,12. NDCG@10 của Content trong bảng này lệch nhẹ so với Bảng 4.1 do vector văn bản được tính lại, nhưng thứ hạng của Content không đổi.

Bảng 4.2: Các cách kết hợp của Hybrid-CBCF

Mô hình	NDCG@10	HR@10
Thành phần đứng riêng		
Content	0,00435	0,02141
UserKNN	0,02753	0,10432
ItemKNN	0,02599	0,09537
Hybrid-CBCF theo cách kết hợp		
Bỏ phiếu: trung bình	0,02634	0,10004
Bỏ phiếu: lớn nhất	0,01483	0,05411
Bỏ phiếu: nhỏ nhất	0,02143	0,08447
Tổng có trọng số học theo cặp (được chọn)	**0,02815**	**0,10588**

4.3 Kết quả đánh giá cuối trên mẫu kiểm định

4.3.1 So sánh các độ đo xếp hạng

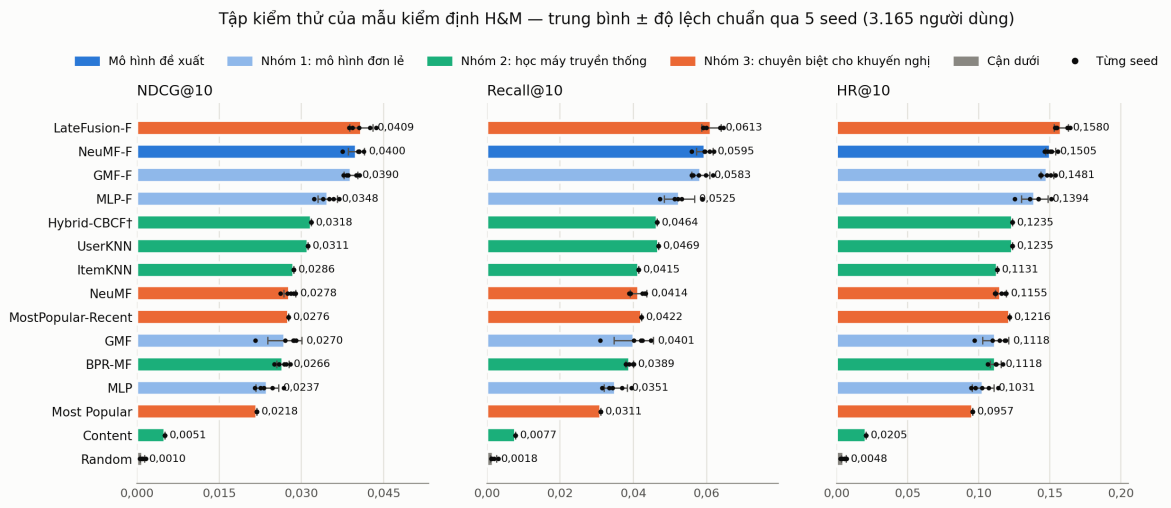
Trên tập kiểm thử, bốn mô hình có đặc trưng đứng đầu, như trên tập xác thực (Bảng 4.3, Hình 4.1). LateFusion-F đạt NDCG@10 cao nhất (0,04093), tiếp theo là NeuMF-F, rồi GMF-F và MLP-F. Mô hình đứng ngay sau nhóm này là UserKNN. NeuMF chỉ dùng ID thấp hơn rõ so với cùng kiến trúc khi có đặc trưng. Với NeuMF-F, khoảng 15% số khách có ít nhất một sản phẩm đúng trong 10 khuyến nghị đầu. Thứ hạng nêu trong chương tính trên 14 mô hình đăng ký trước. Hybrid-CBCF (đánh dấu *) được bàn riêng ở mục 4.3.4 và không thuộc họ 10 so sánh.

Trong bảng, các mô hình được xếp theo nhóm như Bảng 3.5. Mỗi ô có hai dòng: dòng trên là giá trị trung bình, dòng dưới là độ lệch chuẩn qua 5 seed, tính trên 3.165 khách được đánh giá. Các mô hình không có bước ngẫu nhiên khi huấn luyện, gồm UserKNN, ItemKNN, Content, hai mô hình phổ biến và Hybrid-CBCF, cho cùng một kết quả ở mọi seed nên có độ lệch chuẩn bằng 0. Giá trị cao nhất của mỗi cột được in đậm.

Giá trị tuyệt đối của các độ đo thấp vì mỗi khách chỉ có vài sản phẩm đúng giữa hàng nghìn ứng viên, và việc đoán trước những món khách sẽ mua lần đầu trong 8 tuần tới là bài toán khó với hàng thời trang. Khi đọc bảng, cần chú ý tới thứ hạng tương đối giữa các mô hình và việc chênh lệch có ý nghĩa thống kê hay không, hơn là giá trị tuyệt đối.

Bảng 4.3: Kết quả trên tập kiểm thử H&M

Mô hình	NDCG @10	Recall @10	HR @10	Precision @10	NDCG @5	NDCG @20
Mô hình đề xuất						
NeuMF-F	0,04003 ± 0,00147	0,05953 ± 0,00226	0,15046 ± 0,00354	0,01723 ± 0,00027	0,03120 ± 0,00178	0,05166 ± 0,00129
Nhóm 1: mô hình đơn lẻ						
GMF-F	0,03902 ± 0,00124	0,05834 ± 0,00243	0,14812 ± 0,00452	0,01712 ± 0,00049	0,03046 ± 0,00080	0,05051 ± 0,00087
MLP-F	0,03480 ± 0,00177	0,05251 ± 0,00417	0,13940 ± 0,00943	0,01584 ± 0,00096	0,02688 ± 0,00093	0,04689 ± 0,00220
GMF	0,02695 ± 0,00311	0,04007 ± 0,00539	0,11179 ± 0,00909	0,01243 ± 0,00121	0,02105 ± 0,00181	0,03562 ± 0,00297
MLP	0,02373 ± 0,00207	0,03510 ± 0,00316	0,10306 ± 0,00765	0,01129 ± 0,00092	0,01812 ± 0,00153	0,03269 ± 0,00195
Nhóm 2: học máy truyền thống						
Hybrid-CBCF*	0,03183 ± 0,00000	0,04641 ± 0,00000	0,12354 ± 0,00000	0,01362 ± 0,00000	0,02550 ± 0,00000	0,04194 ± 0,00000
UserKNN	0,03114 ± 0,00000	0,04686 ± 0,00000	0,12354 ± 0,00000	0,01365 ± 0,00000	0,02446 ± 0,00000	0,04086 ± 0,00000
ItemKNN	0,02860 ± 0,00000	0,04146 ± 0,00000	0,11311 ± 0,00000	0,01267 ± 0,00000	0,02330 ± 0,00000	0,03835 ± 0,00000
BPR-MF	0,02661 ± 0,00114	0,03895 ± 0,00106	0,11179 ± 0,00381	0,01238 ± 0,00040	0,02045 ± 0,00126	0,03641 ± 0,00163
Content	0,00506 ± 0,00000	0,00772 ± 0,00000	0,02054 ± 0,00000	0,00209 ± 0,00000	0,00384 ± 0,00000	0,00683 ± 0,00000
Nhóm 3: chuyên biệt cho khuyến nghị						
LateFusion-F	**0,04093** ± 0,00212	**0,06125** ± 0,00268	**0,15798** ± 0,00498	**0,01833** ± 0,00066	**0,03208** ± 0,00246	**0,05304** ± 0,00232
NeuMF	0,02783 ± 0,00109	0,04137 ± 0,00223	0,11545 ± 0,00382	0,01301 ± 0,00037	0,02139 ± 0,00115	0,03701 ± 0,00100
MostPopular-Recent	0,02760 ± 0,00000	0,04219 ± 0,00000	0,12164 ± 0,00000	0,01393 ± 0,00000	0,02161 ± 0,00000	0,03789 ± 0,00000
Most Popular	0,02184 ± 0,00000	0,03107 ± 0,00000	0,09573 ± 0,00000	0,01027 ± 0,00000	0,01783 ± 0,00000	0,02983 ± 0,00000
Cận dưới						
Random	0,00098 ± 0,00040	0,00176 ± 0,00082	0,00480 ± 0,00169	0,00049 ± 0,00018	0,00059 ± 0,00035	0,00150 ± 0,00039



Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử H&M

4.3.2 Kết quả theo $K = 5, 10, 15, 20$

Việc chọn $K = 10$ làm độ đo chính không làm thay đổi kết luận (Bảng 4.4 và Bảng 4.5, ghi giá trị trung bình qua 5 seed, giá trị cao nhất mỗi cột in đậm). Ở mọi K và với cả bốn độ đo, thứ tự của bốn mô hình có đặc trưng giữ nguyên: LateFusion-F, NeuMF-F, GMF-F rồi MLP-F, và cả bốn đứng trên mọi mô hình còn lại. Khi K tăng, HR@K và Recall@K của NeuMF-F tăng, còn Precision@K giảm, vì danh sách dài hơn chứa thêm sản phẩm đúng nhưng tỉ lệ sản phẩm đúng trong danh sách lại thấp đi. Thứ tự giữa các mô hình đối chứng chỉ đổi nhẹ, ví dụ MostPopular-Recent vượt UserKNN ở HR@15 và HR@20.

Bảng 4.4: NDCG@K và Recall@K trên H&M

Mô hình	NDCG@K				Recall@K			
	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0321**	**0,0409**	**0,0475**	**0,0530**	**0,0364**	**0,0613**	**0,0806**	**0,0985**
NeuMF-F	0,0312	0,0400	0,0464	0,0517	0,0345	0,0595	0,0780	0,0945
GMF-F	0,0305	0,0390	0,0455	0,0505	0,0345	0,0583	0,0771	0,0931
MLP-F	0,0269	0,0348	0,0415	0,0469	0,0300	0,0525	0,0720	0,0893
Hybrid-CBCF*	0,0255	0,0318	0,0375	0,0419	0,0282	0,0464	0,0625	0,0764
UserKNN	0,0245	0,0311	0,0357	0,0409	0,0279	0,0469	0,0596	0,0764
ItemKNN	0,0233	0,0286	0,0343	0,0384	0,0263	0,0415	0,0584	0,0713
NeuMF	0,0214	0,0278	0,0330	0,0370	0,0230	0,0414	0,0563	0,0693
MostPopular-Recent	0,0216	0,0276	0,0332	0,0379	0,0244	0,0422	0,0586	0,0730
GMF	0,0211	0,0270	0,0317	0,0356	0,0233	0,0401	0,0539	0,0665
BPR-MF	0,0205	0,0266	0,0320	0,0364	0,0221	0,0389	0,0542	0,0682
MLP	0,0181	0,0237	0,0287	0,0327	0,0199	0,0351	0,0492	0,0619
Most Popular	0,0178	0,0218	0,0255	0,0298	0,0200	0,0311	0,0417	0,0548
Content	0,0038	0,0051	0,0062	0,0068	0,0043	0,0077	0,0108	0,0131
Random	0,0006	0,0010	0,0013	0,0015	0,0007	0,0018	0,0026	0,0033

Bảng 4.5: HR@K và Precision@K trên H&M

Mô hình	HR@K				Precision@K			
	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0993**	**0,1580**	**0,1999**	**0,2367**	**0,0220**	**0,0183**	**0,0160**	**0,0146**
NeuMF-F	0,0935	0,1505	0,1941	0,2298	0,0205	0,0172	0,0153	0,0140
GMF-F	0,0922	0,1481	0,1917	0,2267	0,0201	0,0171	0,0152	0,0139
MLP-F	0,0861	0,1394	0,1844	0,2215	0,0186	0,0158	0,0145	0,0134
Hybrid-CBCF*	0,0793	0,1235	0,1621	0,1946	0,0167	0,0136	0,0125	0,0116
UserKNN	0,0799	0,1235	0,1589	0,1934	0,0167	0,0136	0,0121	0,0114
ItemKNN	0,0733	0,1131	0,1494	0,1779	0,0158	0,0127	0,0116	0,0106
NeuMF	0,0684	0,1155	0,1493	0,1773	0,0149	0,0130	0,0117	0,0107
MostPopular-Recent	0,0787	0,1216	0,1633	0,1991	0,0167	0,0139	0,0127	0,0119
GMF	0,0700	0,1118	0,1440	0,1717	0,0149	0,0124	0,0111	0,0102
BPR-MF	0,0672	0,1118	0,1494	0,1812	0,0140	0,0124	0,0115	0,0108
MLP	0,0604	0,1031	0,1390	0,1676	0,0127	0,0113	0,0105	0,0098
Most Popular	0,0629	0,0957	0,1220	0,1596	0,0128	0,0103	0,0091	0,0091
Content	0,0120	0,0205	0,0297	0,0348	0,0025	0,0021	0,0021	0,0018
Random	0,0021	0,0048	0,0075	0,0099	0,0004	0,0005	0,0005	0,0005

4.3.3 Kiểm định ý nghĩa thống kê

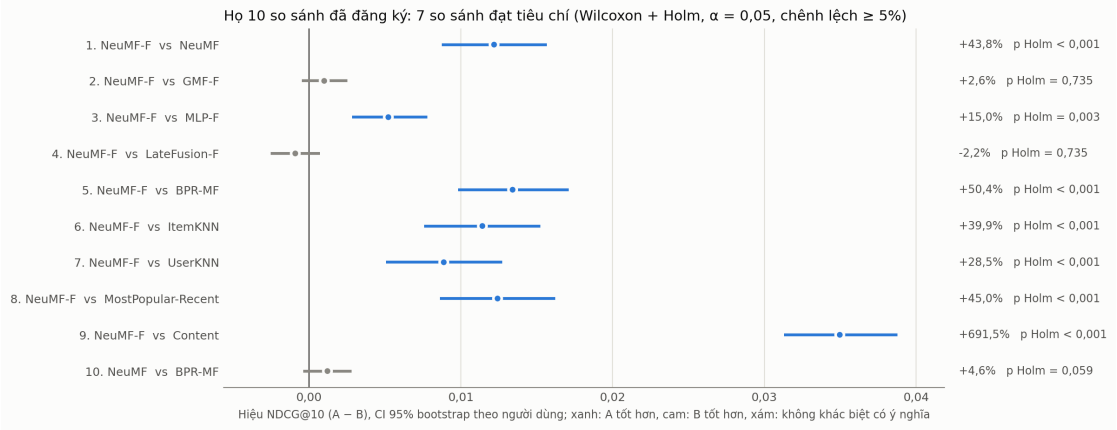
NeuMF-F tốt hơn có ý nghĩa ở 7 so sánh trong họ 10 so sánh đã đăng ký: so với NeuMF chỉ dùng ID, với nhánh MLP-F và với cả năm mô hình đối chứng (Bảng 4.6, Hình 4.2). Trong các so sánh giữa hai mô hình học sâu, chênh lệch lớn nhất là so với NeuMF chỉ dùng ID, +43,8%. Ba so sánh còn lại không khác biệt có ý nghĩa: NeuMF-F so với nhánh GMF-F, NeuMF-F so với LateFusion-F, và NeuMF chỉ dùng ID so với BPR-MF. Ở cả ba trường hợp, khoảng tin cậy đều chứa 0, nên kết luận không phụ thuộc vào ngưỡng 5%.

Mỗi dòng của bảng là một so sánh giữa mô hình A và mô hình B. Cột (A−B)/B là chênh lệch tương đối của NDCG@10. Cột CI 95% là khoảng tin cậy bootstrap của hiệu NDCG@10 theo khách, và cột p Holm là giá trị p của kiểm định Wilcoxon sau hiệu chỉnh Holm. Theo tiêu chí đăng ký trước ở mục 3.7, kết luận "A tốt hơn" chỉ được ghi khi cả ba điều kiện cùng thoả: $p_{Holm} < 0{,}05$, khoảng tin cậy không chứa 0 và chênh lệch tương đối từ 5% trở lên. Điều kiện thứ ba loại những khác biệt có ý nghĩa

thống kê nhưng quá nhỏ để có giá trị thực tế. Các trường hợp còn lại được ghi "—" (không khác biệt có ý nghĩa).

Bảng 4.6: Kiểm định họ 10 so sánh trên H&M

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F NeuMF	0,04003 0,02783	+43,8%	[+0,00876; +0,01566]	< 0,001	A tốt hơn
2	NeuMF-F GMF-F	0,04003 0,03902	+2,6%	[−0,00045; +0,00253]	0,735	—
3	NeuMF-F MLP-F	0,04003 0,03480	+15,0%	[+0,00283; +0,00782]	0,003	A tốt hơn
4	NeuMF-F LateFusion-F	0,04003 0,04093	−2,2%	[−0,00252; +0,00072]	0,735	—
5	NeuMF-F BPR-MF	0,04003 0,02661	+50,4%	[+0,00982; +0,01712]	< 0,001	A tốt hơn
6	NeuMF-F ItemKNN	0,04003 0,02860	+39,9%	[+0,00760; +0,01525]	< 0,001	A tốt hơn
7	NeuMF-F UserKNN	0,04003 0,03114	+28,5%	[+0,00509; +0,01273]	< 0,001	A tốt hơn
8	NeuMF-F MostPopular-Recent	0,04003 0,02760	+45,0%	[+0,00864; +0,01622]	< 0,001	A tốt hơn
9	NeuMF-F Content	0,04003 0,00506	+691,5%	[+0,03129; +0,03876]	< 0,001	A tốt hơn
10	NeuMF BPR-MF	0,02783 0,02661	+4,6%	[−0,00036; +0,00281]	0,059	—



Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh trên H&M

4.3.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống

Phân tích bổ sung cho thấy mô hình lai học sâu có đặc trưng vượt rõ mô hình lai truyền thống (Bảng 4.7, cùng cấu trúc và tiêu chí với Bảng 4.6). NeuMF-F tốt hơn Hybrid-CBCF có ý nghĩa, với chênh lệch +25,8%. Hybrid-CBCF xếp thứ năm trong 15 mô hình, đứng ngay sau bốn mô hình có đặc trưng và trên mọi mô hình đối chứng còn lại. Ngược lại, Hybrid-CBCF so với UserKNN chỉ chênh ít và không khác biệt có ý nghĩa. Kết quả này khớp với trọng số đã học, dồn phần lớn vào UserKNN, và với việc Content đứng riêng rất yếu trên H&M.

Hybrid-CBCF được bổ sung sau khi đánh giá cuối của 14 mô hình đã xong, theo một kế hoạch riêng được đăng ký trước. Cách kết hợp được chọn trên tập xác thực của mẫu phát triển, rồi chấm trên tập kiểm thử của mẫu kiểm định với cùng dữ liệu, tập ứng viên và quy tắc phá hoà như 14 mô hình còn lại. Hai so sánh bổ sung dùng hiệu chỉnh Holm riêng: B1 đặt NeuMF-F cạnh Hybrid-CBCF, B2 đặt Hybrid-CBCF cạnh UserKNN, thành phần mạnh nhất của nó.

Bảng 4.7: Kiểm định bổ sung với Hybrid-CBCF trên H&M

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F Hybrid-CBCF	0,04003 0,03183	+25,8%	[+0,00445; +0,01195]	< 0,001	A tốt hơn
B2	Hybrid-CBCF UserKNN	0,03183 0,03114	+2,2%	[−0,00061; +0,00195]	0,152	—

4.3.5 Phân tích bóc tách thành phần

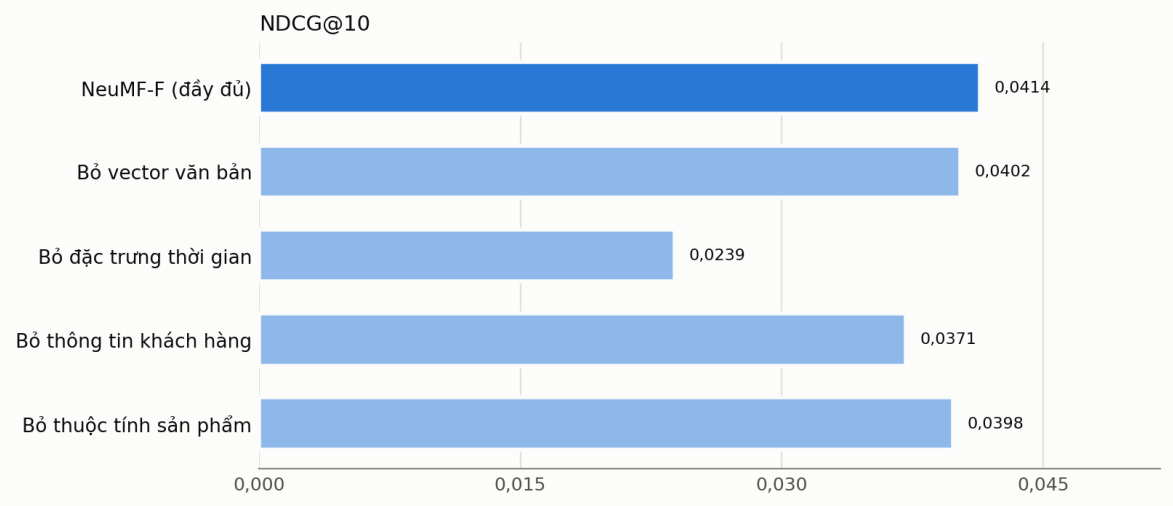
Phân tích bóc tách tắt lần lượt từng nhóm đặc trưng của NeuMF-F và đo NDCG@10 trên tập kiểm thử (Bảng 4.8, Hình 4.3). Phân tích chỉ chạy với seed 42, nên NDCG@10 của mô hình đầy đủ trong bảng (0,04137) là kết quả của riêng seed này và khác giá trị trung bình 5 seed ở Bảng 4.3. Cột "Thay đổi" là chênh lệch NDCG@10 của biến thể so với mô hình đầy đủ, chia cho NDCG@10 của mô hình đầy đủ. Cột cuối là khoảng tin cậy bootstrap 95% của hiệu này theo khách.

Đặc trưng thời gian đóng góp nhiều nhất cho NeuMF-F: bỏ nhóm đặc trưng này làm NDCG@10 thay đổi −42,3%, mức giảm lớn nhất trong các biến thể. Bỏ thông tin khách hàng làm NDCG@10 giảm nhiều thứ hai. Khoảng tin cậy của hiệu khi bỏ thuộc tính sản phẩm hoặc vector văn bản chứa 0, nên với một seed không khẳng định được hai nhóm đặc trưng này có đóng góp.

Mỗi biến thể chỉ tắt một thành phần và giữ nguyên siêu tham số cùng quy trình huấn luyện của NeuMF-F. Biến thể không bỏ ID ngẫu nhiên trùng với chính NeuMF-F, vì cấu hình được chọn của NeuMF-F có xác suất bỏ ID bằng 0 (Bảng 4.1), nên không được chạy. Phân tích này không qua kiểm định đa so sánh và không được dùng để chọn lại cấu hình. Kết quả bóc tách chỉ cho biết nhóm đặc trưng nào đáng giữ lại khi phát triển tiếp mô hình.

Bảng 4.8: Phân tích bóc tách NeuMF-F trên H&M

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,04137	—	—
Bỏ vector văn bản	0,04025	−2,7%	[−0,00450; +0,00236]
Bỏ đặc trưng thời gian	0,02386	−42,3%	[−0,02122; −0,01380]
Bỏ thông tin khách hàng	0,03712	−10,3%	[−0,00720; −0,00132]
Bỏ thuộc tính sản phẩm	0,03983	−3,7%	[−0,00467; +0,00158]



Hình 4.3: Phân tích bóc tách NeuMF-F trên H&M

4.3.6 Độ phủ và chi phí huấn luyện

Ngoài độ chính xác, đề tài đo thêm độ phủ của danh sách khuyến nghị và chi phí huấn luyện (Bảng 4.9). Độ phủ là tỉ lệ sản phẩm ứng viên xuất hiện trong danh sách 10 khuyến nghị đầu của ít nhất một khách, đo ở seed 42. Độ phủ thấp nghĩa là nhiều khách nhận những danh sách giống nhau.

Các mô hình dựa trên độ phổ biến cho danh sách khuyến nghị ít đa dạng nhất. Most Popular và MostPopular-Recent có độ phủ thấp nhất vì mọi khách nhận gần như cùng một danh sách. Trong các mô hình cá nhân hoá, MLP chỉ dùng ID có độ phủ thấp nhất, còn NeuMF-F có độ phủ cao nhất trong các mạng lưới thần kinh, chỉ sau Content và ItemKNN, hai mô hình chấm điểm theo độ giống thay vì độ phổ biến. Độ phủ của Hybrid-CBCF nằm giữa độ phủ của hai thành phần cộng tác UserKNN và ItemKNN. Random có độ phủ gần như toàn bộ danh mục nhưng độ chính xác thấp nhất, nên độ phủ chỉ có giá trị khi được xem cùng với độ chính xác.

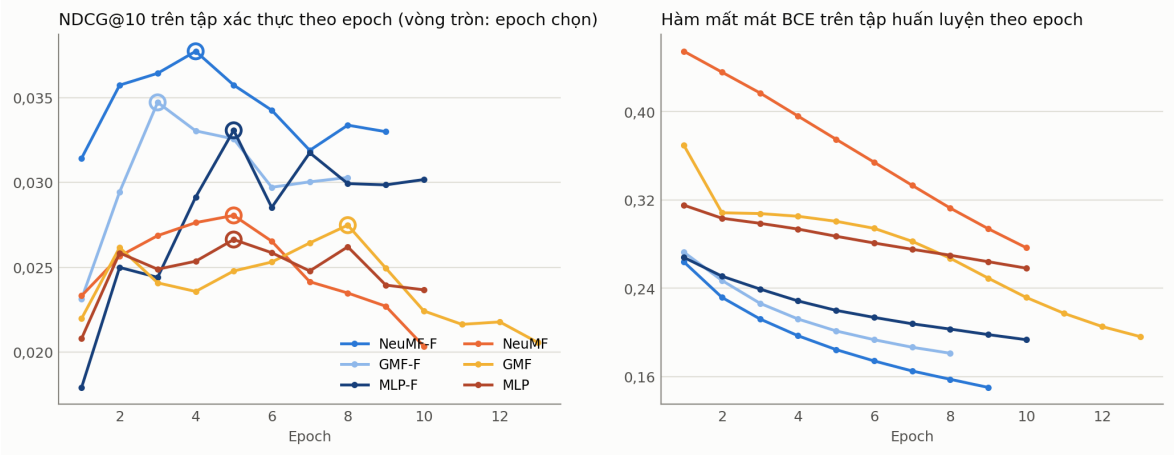
Hai cột còn lại của bảng là số epoch được chọn và thời gian huấn luyện, đều lấy trung bình qua 5 seed. Ô "—" dành cho mô hình không huấn luyện theo epoch. Các mạng lưới thần kinh chọn trung bình từ 3 đến khoảng 6 epoch, thấp hơn nhiều so với giới hạn 20 epoch. Điều đó cho thấy NDCG@10 trên tập xác thực đạt đỉnh sớm rồi không tăng thêm. LateFusion-F gần như không tốn thời gian riêng vì dùng lại GMF-F và MLP-F đã huấn luyện.

Bảng 4.9: Độ phủ top-10 và chi phí huấn luyện trên H&M

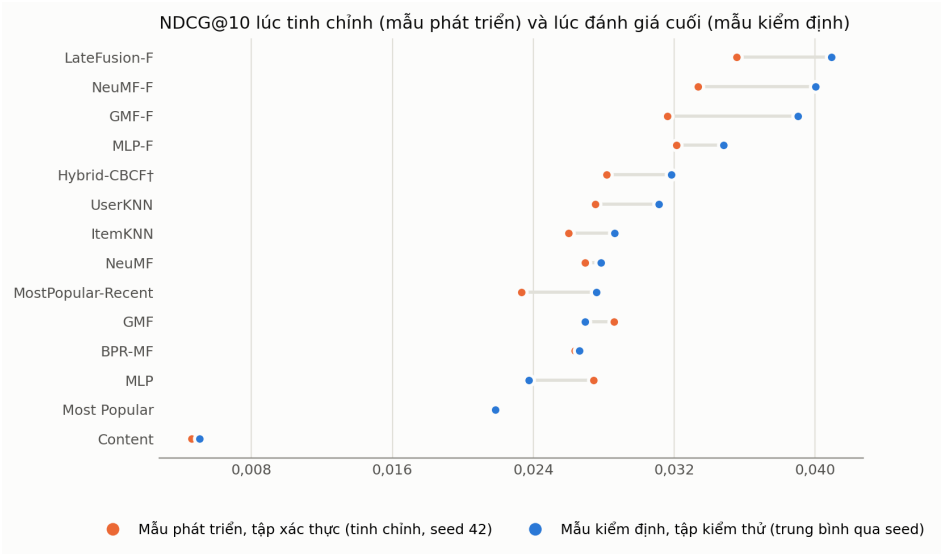
Mô hình	Độ phủ ứng viên	Số epoch chọn	Thời gian (phút)
LateFusion-F	5,3%	—	0,0
NeuMF-F	13,3%	3,0	15,2
GMF-F	6,9%	4,4	13,7
MLP-F	5,3%	4,6	16,4
Hybrid-CBCF*	10,8%	—	0,1
UserKNN	5,7%	—	0,0
ItemKNN	20,4%	—	0,0
NeuMF	6,0%	4,2	6,2
MostPopular-Recent	0,3%	—	0,0
GMF	7,3%	6,2	7,2
BPR-MF	5,1%	—	4,3
MLP	3,3%	4,8	8,4
Most Popular	0,3%	—	0,0
Content	78,2%	—	0,0
Random	98,9%	—	0,0

4.3.7 Hội tụ và độ ổn định giữa hai mẫu

Thứ hạng giữa các mô hình được giữ khá ổn định khi chuyển từ mẫu phát triển sang mẫu kiểm định (Hình 4.5). Bốn mô hình có đặc trưng đứng đầu ở cả hai, và LateFusion-F và NeuMF-F giữ hai vị trí đầu. Thay đổi lớn nhất thuộc về GMF và MLP chỉ dùng ID, tụt từ thứ năm và thứ bảy lúc tinh chỉnh xuống thứ chín và thứ mười một ở đánh giá cuối, còn ItemKNN đi theo chiều ngược lại. NDCG@10 của hai lần không cùng thang, vì khác mẫu khách hàng và cửa sổ kiểm thử dài gấp đôi cửa sổ xác thực, nên chỉ so thứ hạng. Hình 4.4 cho thấy NDCG@10 trên tập xác thực và hàm mất mát BCE theo epoch khi chọn số epoch cho đánh giá cuối (seed 42). Vòng tròn đánh dấu epoch được chọn.



Hình 4.4: Đường hội tụ của các mạng lưới thần kinh khi chọn số epoch



Hình 4.5: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối

4.4 Kiểm chứng trên dữ liệu Amazon Beauty

Mục này kiểm tra xem các kết luận trên H&M có còn đúng trên một bộ dữ liệu khác không, theo kế hoạch kiểm chứng đăng ký trước. Ba kết luận được đối chiếu là mô hình có đặc trưng so với mô hình chỉ dùng ID, NeuMF-F so với GMF-F, MLP-F và LateFusion-F, và NeuMF so với BPR-MF.

4.4.1 Dữ liệu và thiết lập kiểm chứng

Bộ dữ liệu kiểm chứng là Amazon Beauty, danh mục Làm đẹp của bộ dữ liệu đánh giá sản phẩm Amazon năm 2014 [2]. Bản 5-core gồm 198.502 đánh giá của 22.363 khách cho 12.101 sản phẩm, từ 12/06/2002 đến 23/07/2014. Kế hoạch kiểm

chứng được đăng ký trước khi chạy mô hình nào trên bộ này. Mã nguồn, 14 mô hình, số seed, độ đo, họ 10 so sánh và tiêu chí kết luận giữ nguyên như H&M. Chỉ những điểm sau thay đổi theo dữ liệu.

- Tương tác: mỗi đánh giá được coi là một tương tác ẩn giữa khách và sản phẩm, như một lượt mua của H&M. Số sao không được dùng. Một sản phẩm là một mã `asin`.
- Chia theo thời gian: chọn số epoch bằng các cặp trước 01/10/2013 và tập xác thực từ 01/10 đến 31/12/2013; huấn luyện lại trên mọi cặp trước 01/01/2014; tập kiểm thử từ 01/01 đến 23/07/2014. Tỉ lệ độ dài xác thực và kiểm thử khoảng 1 : 2 như H&M. Vì chỉ có một bộ dữ liệu, Amazon không có mẫu khách hàng độc lập: bước chọn số epoch và bước đánh giá cuối chỉ khác nhau về thời gian.
- Lọc 5-core chỉ trên các cặp trước mốc kiểm thử, bằng ngưỡng của bản 5-core gốc. H&M dùng $k = 10$, nhưng dữ liệu Amazon thưa hơn nhiều.
- Không tinh chỉnh lại: mọi mô hình dùng đúng cấu hình đã chọn trên tập xác thực của mẫu phát triển H&M (Bảng 4.1). Thứ duy nhất được chọn trên dữ liệu Amazon là số epoch của các mạng lưới thần kinh (Thuật toán 3.3). Hệ quả là mô hình nào có cấu hình không hợp với Amazon sẽ chịu thiệt, và phần thiệt đó không tách được khỏi bản thân mô hình.
- Đặc trưng thay theo những gì bộ dữ liệu có (Bảng 4.10). Amazon không có thông tin khách hàng, nên nhánh khách của NeuMF-F chỉ còn hai đặc trưng thời gian. Doanh số được thay bằng số đánh giá, đếm trên chính tệp 5-core.

So với H&M, văn bản được biểu diễn theo cùng một cách. Khác biệt nằm ở thuộc tính sản phẩm, nguồn của đặc trưng thời gian và thông tin khách hàng (Bảng 4.10). Hai mô hình đối chứng có dùng dữ liệu ngoài mã ID, Content và MostPopular-Recent, cũng đổi nguồn theo cùng cách.

Bảng 4.10: Đặc trưng trên H&M và Amazon Beauty

Thành phần	H&M	Amazon Beauty
Thuộc tính sản phẩm	11 thuộc tính danh mục (88 chiều)	5 thuộc tính: thương hiệu, danh mục cấp 1, 2, 3, nhóm giá (8 nhóm, 0 là không có giá) (40 chiều)
Văn bản	tên và mô tả, TF-IDF và SVD 64 chiều	tiêu đề và mô tả, cùng cách biểu diễn
Thời gian của sản phẩm tại t	doanh số toàn H&M trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ chưa từng bán (5 chiều)	số đánh giá trong tệp 5-core trong 7, 28, 91 ngày trước t; tuổi tính từ đánh giá đầu tiên; cờ chưa có đánh giá (5 chiều)
Vector đặc trưng sản phẩm	$d_I = 88 + 64 + 5 = 157$	$d_I = 40 + 64 + 5 = 109$
Thông tin khách hàng	5 thuộc tính tĩnh và 2 đặc trưng thời gian ($d_U = 42$)	chỉ 2 đặc trưng thời gian ($d_U = 2$)
Content (đối chứng)	one-hot nhóm sản phẩm, nhóm chỉ mục, nhóm may mặc	one-hot danh mục cấp 1 và cấp 2
MostPopular-Recent	số giao dịch toàn H&M trong cửa sổ W ngày	số đánh giá trong cửa sổ W ngày

Từ 198.502 đánh giá của bộ 5-core gốc, chỉ các cặp trước mốc kiểm thử được đưa vào bước lọc, và sau khi lọc lại 5-core còn 10.681 khách và 6.069 sản phẩm (Bảng 4.11). Số cặp huấn luyện của giai đoạn kiểm thử đúng bằng số cặp sau lọc, vì phép lọc chỉ dùng dữ liệu trước mốc kiểm thử. Mỗi khách được xếp hạng trên số ứng viên gần bằng H&M nhưng có ít sản phẩm đúng hơn (khoảng 2,3 so với 3,2 trên H&M), nên các độ đo trên Amazon cũng có giá trị tuyệt đối thấp.

Khi đọc kết quả cần lưu ý ba điểm khác với H&M. Đánh giá sản phẩm không đồng nghĩa với lượt mua. Đặc trưng thời gian của sản phẩm chỉ đếm trên tệp 5-core. Nhóm giá là giá tại thời điểm thu thập dữ liệu năm 2014.

Bảng 4.11: Quy mô dữ liệu Amazon Beauty

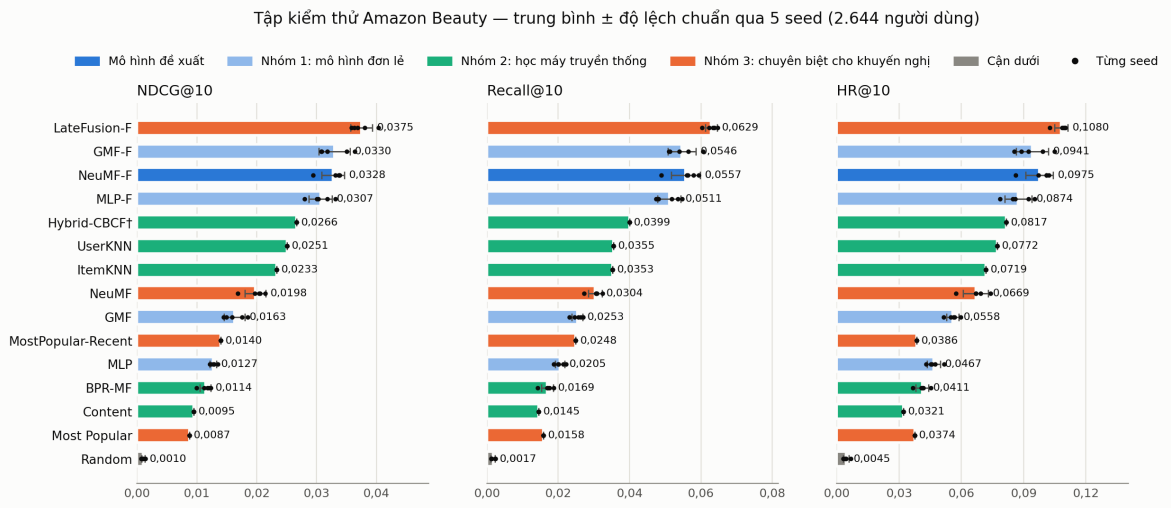
	Amazon Beauty
Đánh giá trong bộ 5-core gốc (mỗi đánh giá là một tương tác)	198.502
Sản phẩm có đánh giá trước 01/01/2014	11.493
Cặp (khách, sản phẩm) trước 01/01/2014	140.193
Khách sau lọc 5-core	10.681
Sản phẩm (`asin`) sau lọc 5-core	6.069
Cặp sau lọc 5-core	94.009
Xác thực: cặp huấn luyện (trước 01/10/2013)	82.281
Xác thực: khách được đánh giá	3.153
Xác thực: cặp đúng	7.880
Kiểm thử: cặp huấn luyện (trước 01/01/2014)	94.009
Kiểm thử: khách được đánh giá	2.644
Kiểm thử: cặp đúng	6.107
Kiểm thử: số ứng viên trung bình mỗi khách	6.058

4.4.2 Kết quả trên tập kiểm thử Amazon Beauty

Trên Amazon, LateFusion-F đạt NDCG@10 cao nhất (0,03747), còn NeuMF-F xếp thứ ba, sau cả GMF-F (Bảng 4.12, Hình 4.6). Bảng được trình bày theo cùng cách với Bảng 4.3, tính trên 2.644 khách, và mọi mô hình dùng cấu hình chọn trên H&M. Như trên H&M, bốn mô hình có đặc trưng đứng đầu. Trong các mô hình đăng ký trước, tiếp theo là UserKNN và ItemKNN. Khác H&M, BPR-MF chỉ đạt mức thấp hơn ItemKNN, UserKNN và cả MostPopular-Recent, với nguyên nhân được bàn ở mục 4.4.3.

Bảng 4.12: Kết quả trên tập kiểm thử Amazon Beauty

Mô hình	NDCG @10	Recall @10	HR @10	Precision @10	NDCG @5	NDCG @20
Mô hình đề xuất						
NeuMF-F	0,03277 ± 0,00189	0,05568 ± 0,00403	0,09750 ± 0,00657	0,01092 ± 0,00077	0,02450 ± 0,00148	0,04144 ± 0,00208
Nhóm 1: mô hình đơn lẻ						
GMF-F	0,03298 ± 0,00259	0,05465 ± 0,00397	0,09410 ± 0,00780	0,01042 ± 0,00088	0,02567 ± 0,00256	0,04159 ± 0,00195
MLP-F	0,03065 ± 0,00193	0,05107 ± 0,00327	0,08737 ± 0,00656	0,00998 ± 0,00092	0,02330 ± 0,00151	0,03764 ± 0,00184
GMF	0,01627 ± 0,00173	0,02533 ± 0,00154	0,05582 ± 0,00303	0,00640 ± 0,00036	0,01287 ± 0,00180	0,02090 ± 0,00166
MLP	0,01271 ± 0,00054	0,02045 ± 0,00132	0,04667 ± 0,00324	0,00513 ± 0,00037	0,00978 ± 0,00080	0,01694 ± 0,00062
Nhóm 2: học máy truyền thống						
Hybrid-CBCF*	0,02664 ± 0,00000	0,03992 ± 0,00000	0,08169 ± 0,00000	0,00998 ± 0,00000	0,02137 ± 0,00000	0,03212 ± 0,00000
UserKNN	0,02506 ± 0,00000	0,03553 ± 0,00000	0,07716 ± 0,00000	0,00930 ± 0,00000	0,02059 ± 0,00000	0,03096 ± 0,00000
ItemKNN	0,02333 ± 0,00000	0,03526 ± 0,00000	0,07186 ± 0,00000	0,00870 ± 0,00000	0,01895 ± 0,00000	0,02789 ± 0,00000
BPR-MF	0,01144 ± 0,00091	0,01691 ± 0,00164	0,04115 ± 0,00309	0,00498 ± 0,00035	0,00883 ± 0,00077	0,01476 ± 0,00082
Content	0,00945 ± 0,00000	0,01448 ± 0,00000	0,03215 ± 0,00000	0,00356 ± 0,00000	0,00737 ± 0,00000	0,01264 ± 0,00000
Nhóm 3: chuyên biệt cho khuyến nghị						
LateFusion-F	**0,03747** ± 0,00180	**0,06286** ± 0,00167	**0,10802** ± 0,00314	**0,01222** ± 0,00045	**0,02879** ± 0,00222	**0,04571** ± 0,00142
NeuMF	0,01978 ± 0,00176	0,03035 ± 0,00187	0,06694 ± 0,00605	0,00762 ± 0,00090	0,01599 ± 0,00161	0,02542 ± 0,00207
MostPopular-Recent	0,01401 ± 0,00000	0,02483 ± 0,00000	0,03858 ± 0,00000	0,00416 ± 0,00000	0,00964 ± 0,00000	0,01854 ± 0,00000
Most Popular	0,00872 ± 0,00000	0,01576 ± 0,00000	0,03744 ± 0,00000	0,00390 ± 0,00000	0,00619 ± 0,00000	0,00998 ± 0,00000
Cận dưới						
Random	0,00101 ± 0,00028	0,00168 ± 0,00059	0,00446 ± 0,00143	0,00045 ± 0,00014	0,00066 ± 0,00031	0,00153 ± 0,00031



Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty

LateFusion-F cao nhất ở mọi K và với cả bốn độ đo (Bảng 4.13 và Bảng 4.14). NeuMF-F và GMF-F bám sát nhau và đổi chỗ tuỳ độ đo: GMF-F cao hơn một chút ở NDCG@K, còn NeuMF-F cao hơn một chút ở Recall@K, HR@K và Precision@K từ $K = 10$ trở lên.

Bảng 4.13: NDCG@K và Recall@K trên Amazon Beauty

Mô hình	NDCG@K				Recall@K			
	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0288**	**0,0375**	**0,0425**	**0,0457**	**0,0378**	**0,0629**	**0,0794**	**0,0904**
GMF-F	0,0257	0,0330	0,0377	0,0416	0,0333	0,0546	0,0700	0,0840
NeuMF-F	0,0245	0,0328	0,0375	0,0414	0,0323	0,0557	0,0715	0,0856
MLP-F	0,0233	0,0307	0,0347	0,0376	0,0302	0,0511	0,0646	0,0749
Hybrid-CBCF*	0,0214	0,0266	0,0296	0,0321	0,0247	0,0399	0,0498	0,0586
UserKNN	0,0206	0,0251	0,0284	0,0310	0,0235	0,0355	0,0470	0,0557
ItemKNN	0,0189	0,0233	0,0253	0,0279	0,0220	0,0353	0,0418	0,0510
NeuMF	0,0160	0,0198	0,0228	0,0254	0,0195	0,0304	0,0399	0,0491
GMF	0,0129	0,0163	0,0190	0,0209	0,0156	0,0253	0,0341	0,0407
MostPopular-Recent	0,0096	0,0140	0,0171	0,0185	0,0122	0,0248	0,0351	0,0399
MLP	0,0098	0,0127	0,0148	0,0169	0,0126	0,0205	0,0271	0,0345
BPR-MF	0,0088	0,0114	0,0132	0,0148	0,0094	0,0169	0,0225	0,0278
Content	0,0074	0,0095	0,0115	0,0126	0,0087	0,0145	0,0213	0,0255
Most Popular	0,0062	0,0087	0,0095	0,0100	0,0084	0,0158	0,0186	0,0200
Random	0,0007	0,0010	0,0013	0,0015	0,0007	0,0017	0,0025	0,0035

Bảng 4.14: HR@K và Precision@K trên Amazon Beauty

Mô hình	HR@K				Precision@K			
	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0669**	**0,1080**	**0,1358**	**0,1546**	**0,0144**	**0,0122**	**0,0106**	**0,0092**
GMF-F	0,0591	0,0941	0,1200	0,1417	0,0126	0,0104	0,0092	0,0083
NeuMF-F	0,0589	0,0975	0,1224	0,1451	0,0124	0,0109	0,0094	0,0086
MLP-F	0,0524	0,0874	0,1099	0,1275	0,0113	0,0100	0,0085	0,0075
Hybrid-CBCF*	0,0548	0,0817	0,0991	0,1161	0,0123	0,0100	0,0081	0,0072
UserKNN	0,0511	0,0772	0,0957	0,1120	0,0114	0,0093	0,0078	0,0069
ItemKNN	0,0492	0,0719	0,0840	0,0983	0,0111	0,0087	0,0069	0,0062
NeuMF	0,0430	0,0669	0,0859	0,1011	0,0093	0,0076	0,0067	0,0061
GMF	0,0356	0,0558	0,0718	0,0846	0,0077	0,0064	0,0056	0,0051
MostPopular-Recent	0,0185	0,0386	0,0537	0,0639	0,0039	0,0042	0,0041	0,0038
MLP	0,0275	0,0467	0,0606	0,0750	0,0058	0,0051	0,0046	0,0043
BPR-MF	0,0244	0,0411	0,0526	0,0635	0,0055	0,0050	0,0045	0,0041
Content	0,0200	0,0321	0,0446	0,0514	0,0042	0,0036	0,0034	0,0030
Most Popular	0,0189	0,0374	0,0446	0,0492	0,0039	0,0039	0,0031	0,0026
Random	0,0020	0,0045	0,0064	0,0084	0,0004	0,0005	0,0004	0,0004

Kết luận bổ sung cũng lặp lại: NeuMF-F tốt hơn Hybrid-CBCF có ý nghĩa (Bảng 4.15). Hybrid-CBCF, dùng nguyên cách kết hợp và trọng số chọn trên H&M, xếp thứ năm trong 15 mô hình, cũng đứng ngay sau bốn mô hình có đặc trưng. Khác H&M, trên Amazon Hybrid-CBCF tốt hơn UserKNN có ý nghĩa. Một khác biệt có thể góp phần: NDCG@10 của Content đứng riêng chỉ bằng khoảng một phần sáu của UserKNN trên H&M, nhưng hơn một phần ba trên Amazon, nên thành phần nội dung mang thêm nhiều thông tin hơn.

Bảng 4.15: Kiểm định bổ sung với Hybrid-CBCF trên Amazon Beauty

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F Hybrid-CBCF	0,03277 0,02664	+23,0%	[+0,00138; +0,01083]	< 0,001	A tốt hơn
B2	Hybrid-CBCF UserKNN	0,02664 0,02506	+6,3%	[+0,00026; +0,00292]	0,009	A tốt hơn

4.4.3 Đối chiếu kết luận giữa H&M và Amazon Beauty

Trong ba kết luận được đối chiếu, kết luận về đặc trưng giữ nguyên trên Amazon, kết luận về cách hợp nhất hai nhánh chỉ đúng một phần, còn kết luận về NeuMF so với BPR-MF không đối chiếu được. Bảng 4.16 là kiểm định họ 10 so sánh trên Amazon, với cùng cấu trúc và tiêu chí như trên H&M. Bảng 4.17 đặt kết luận của từng so sánh trên hai bộ dữ liệu cạnh nhau. Cột "Chênh" là chênh lệch tương đối $(A - B)/B$ của NDCG@10, tính riêng cho từng bộ dữ liệu. Hai so sánh có BPR-MF trên Amazon được đánh dấu * vì cần đọc thận trọng: BPR-MF ở đây dùng cấu hình chọn trên H&M và kém cả ItemKNN lẫn UserKNN, như phân tích ở kết luận thứ ba dưới đây.

Kết luận thứ nhất, về đặc trưng so với chỉ dùng ID, còn đúng trên Amazon: NeuMF-F hơn NeuMF chỉ dùng ID +65,7% và tốt hơn có ý nghĩa cả năm mô hình đối chứng trong họ so sánh. Đây là kết luận vững nhất của đề tài, vì nó giữ nguyên khi đổi lĩnh vực (mỹ phẩm thay vì thời trang), loại tương tác (đánh giá thay vì lượt mua) và bộ đặc trưng (không có thông tin khách hàng), dù không tinh chỉnh lại.

Kết luận thứ hai, về NeuMF-F so với từng nhánh và với hợp nhất muộn, chỉ đúng một phần. NeuMF-F vẫn không khác biệt có ý nghĩa với nhánh GMF-F. Lợi thế so với MLP-F trên H&M không còn trên Amazon: giá trị p đã hiệu chỉnh xấp xỉ ngưỡng 0,05 nhưng khoảng tin cậy chứa 0, nên theo tiêu chí là không khác biệt có ý nghĩa. Ngược với H&M, hợp nhất muộn LateFusion-F tốt hơn NeuMF-F có ý nghĩa. Kết quả này cho thấy cách hợp nhất phù hợp phụ thuộc vào dữ liệu. Nguyên nhân chưa được kiểm chứng. Một giả thuyết là trên Amazon, hai nhánh GMF-F và MLP-F có độ phủ top-10 rất khác nhau, nghĩa là chúng khuyến nghị những tập sản phẩm khác nhau. Khi được huấn luyện riêng rồi trộn điểm, hai danh sách bổ sung cho nhau tốt hơn so với khi hai nhánh được học chung trong một mạng.

Kết luận thứ ba, về NeuMF chỉ dùng ID so với BPR-MF, không đối chiếu được. Trên Amazon, NeuMF tốt hơn BPR-MF có ý nghĩa, trong khi trên H&M hai mô hình không khác biệt có ý nghĩa. Tuy nhiên BPR-MF trên Amazon dùng cấu hình chọn trên H&M và kém hơn cả ItemKNN lẫn MostPopular-Recent, nên khoảng cách này nhiều khả năng phản ánh cấu hình không hợp với dữ liệu hơn là ưu thế của NeuMF. Vì lý do tương tự, so sánh NeuMF-F với BPR-MF trên Amazon không được dùng làm thước đo lợi ích của NeuMF-F.

Bảng 4.16: Kiểm định họ 10 so sánh trên Amazon Beauty

#	Mô hình A Mô hình B	NDCG@10 của A, B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F NeuMF	0,03277 0,01978	+65,7%	[+0,00936; +0,01681]	< 0,001	A tốt hơn
2	NeuMF-F GMF-F	0,03277 0,03298	−0,6%	[−0,00228; +0,00186]	0,534	—
3	NeuMF-F MLP-F	0,03277 0,03065	+6,9%	[−0,00044; +0,00457]	0,050	—
4	NeuMF-F LateFusion-F	0,03277 0,03747	−12,5%	[−0,00668; −0,00279]	< 0,001	B tốt hơn
5	NeuMF-F BPR-MF	0,03277 0,01144	+186,5%	[+0,01756; +0,02528]	< 0,001	A tốt hơn
6	NeuMF-F ItemKNN	0,03277 0,02333	+40,5%	[+0,00477; +0,01417]	< 0,001	A tốt hơn
7	NeuMF-F UserKNN	0,03277 0,02506	+30,8%	[+0,00313; +0,01232]	< 0,001	A tốt hơn
8	NeuMF-F MostPopular-Recent	0,03277 0,01401	+134,0%	[+0,01553; +0,02201]	< 0,001	A tốt hơn
9	NeuMF-F Content	0,03277 0,00945	+246,7%	[+0,01902; +0,02766]	< 0,001	A tốt hơn
10	NeuMF BPR-MF	0,01978 0,01144	+72,9%	[+0,00630; +0,01038]	< 0,001	A tốt hơn

Bảng 4.17: Kết luận họ 10 so sánh trên H&M và Amazon Beauty

#	So sánh (A so với B)	H&M		Amazon Beauty	
		Chênh	Kết luận	Chênh	Kết luận
1	NeuMF-F so với NeuMF	+43,8%	A tốt hơn	+65,7%	A tốt hơn
2	NeuMF-F so với GMF-F	+2,6%	không khác biệt có ý nghĩa	−0,6%	không khác biệt có ý nghĩa
3	NeuMF-F so với MLP-F	+15,0%	A tốt hơn	+6,9%	không khác biệt có ý nghĩa
4	NeuMF-F so với LateFusion-F	−2,2%	không khác biệt có ý nghĩa	−12,5%	B tốt hơn
5	NeuMF-F so với BPR-MF	+50,4%	A tốt hơn	+186,5%	A tốt hơn *
6	NeuMF-F so với ItemKNN	+39,9%	A tốt hơn	+40,5%	A tốt hơn
7	NeuMF-F so với UserKNN	+28,5%	A tốt hơn	+30,8%	A tốt hơn
8	NeuMF-F so với MostPopular-Recent	+45,0%	A tốt hơn	+134,0%	A tốt hơn
9	NeuMF-F so với Content	+691,5%	A tốt hơn	+246,7%	A tốt hơn
10	NeuMF so với BPR-MF	+4,6%	không khác biệt có ý nghĩa	+72,9%	A tốt hơn *

4.4.4 Phân tích bóc tách và độ phủ trên Amazon Beauty

Như trên H&M, bỏ đặc trưng thời gian làm NDCG@10 giảm nhiều nhất (Bảng 4.18, cùng cấu trúc với Bảng 4.8 và cũng chỉ chạy với seed 42). Vì Amazon không có thuộc tính khách hàng, biến thể "bỏ thông tin khách hàng" ở đây chỉ bỏ hai đặc trưng thời gian của khách. Khác H&M, thuộc tính sản phẩm (thương hiệu, danh mục, nhóm giá) có đóng góp rõ, với khoảng tin cậy của hiệu không chứa 0. Bỏ thông tin khách hàng không làm NDCG@10 thay đổi có ý nghĩa, và bỏ vector văn bản cũng vậy. Về độ phủ top-10, Most Popular và MostPopular-Recent vẫn thấp nhất.

Bảng 4.18: Phân tích bóc tách NeuMF-F trên Amazon Beauty

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,03378	—	—
Bỏ vector văn bản	0,03047	−9,8%	[−0,00701; +0,00051]
Bỏ đặc trưng thời gian	0,02310	−31,6%	[−0,01569; −0,00561]
Bỏ thông tin khách hàng	0,03424	+1,3%	[−0,00271; +0,00369]
Bỏ thuộc tính sản phẩm	0,02892	−14,4%	[−0,00844; −0,00133]

4.5 Phạm vi của kết luận

Các kết luận của chương áp dụng cho những khách hàng của H&M có lịch sử mua đủ dày để qua bước lọc 10-core, trong khung thời gian từ tháng 7 đến tháng 9 năm 2020 và ở mức mẫu thiết kế. Sản phẩm mới và khách hàng mới nằm ngoài tập được đánh giá. Phân tích bóc tách chạy một seed nên mang tính mô tả. Kiểm chứng trên Amazon Beauty dùng lại cấu hình chọn trên H&M, nên các kết luận lặp lại trên bộ này không nhờ vào việc tinh chỉnh theo dữ liệu mới.

4.6 Thảo luận và trả lời câu hỏi nghiên cứu

Mục này dùng kết quả trên hai bộ dữ liệu để trả lời ba câu hỏi nghiên cứu ở mục 1.1.3.

Câu hỏi thứ nhất là NeuMF-F có khuyến nghị tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ không. Câu trả lời là có. Theo tiêu chí đã đăng ký, NeuMF-F vượt cả năm mô hình đối chứng trong họ so sánh trên H&M, với chênh lệch nhỏ nhất so với UserKNN và lớn nhất so với Content. Trên Amazon Beauty, NeuMF-F cũng vượt cả năm mô hình đối chứng. Với mô hình lai truyền thống, NeuMF-F tốt hơn có ý nghĩa Hybrid-CBCF trên cả hai bộ dữ liệu, trong khi Hybrid-CBCF chỉ hơn thành phần mạnh nhất của nó một khoảng nhỏ. Ghép điểm của các kỹ thuật truyền thống giúp được ít, trong khi bổ sung đặc trưng vào mô hình lai học sâu giúp được nhiều hơn hẳn. Các so sánh này đáng tin cậy vì mọi mô hình được tinh chỉnh với cùng ngân sách, tập kiểm thử không được dùng để chọn mô hình, và kết luận lấy trên những khách hàng chưa từng được dùng để ra quyết định.

Câu hỏi thứ hai là bổ sung đặc trưng có giúp mô hình lai không. Câu trả lời cũng là có. Giá trị của đặc trưng được đo trực tiếp qua so sánh NeuMF-F với NeuMF chỉ dùng mã định danh, vì hai mô hình có cùng kiến trúc hai nhánh. Trong họ so sánh,

đây là chênh lệch lớn nhất giữa hai mô hình học sâu, và nó lặp lại trên Amazon. Ngược lại, khi chỉ dùng mã định danh, mô hình lai NeuMF không khác biệt có ý nghĩa với BPR-MF trên H&M. Phân tích bóc tách cho thấy phần lớn đóng góp đến từ đặc trưng thời gian, tiếp theo là thông tin khách hàng. Thuộc tính và mô tả văn bản của sản phẩm chỉ đóng góp nhỏ, chưa tách được khỏi dao động của một seed. Trên Amazon, đặc trưng thời gian cũng đóng góp nhiều nhất. Xu hướng bán gần đây của sản phẩm và nhịp mua của khách vì vậy mang nhiều thông tin về lần mua tiếp theo hơn mô tả tĩnh của sản phẩm.

Câu hỏi thứ ba là ghép hai nhánh có tốt hơn từng nhánh không, và nên hợp nhất sớm hay muộn. Khi đã có đặc trưng, các cách ghép cho kết quả gần nhau. Trên H&M, hợp nhất sớm vượt nhánh phi tuyến MLP-F nhưng không vượt nhánh tuyến tính GMF-F đứng riêng, và cũng không tốt hơn hợp nhất muộn. LateFusion-F có NDCG@10 trung bình cao nhất nhưng không khác biệt có ý nghĩa với NeuMF-F. Trên Amazon, lợi thế so với MLP-F không còn có ý nghĩa, còn hợp nhất muộn tốt hơn hợp nhất sớm có ý nghĩa. Trong hai cách ghép, hợp nhất muộn không kém hơn ở bộ dữ liệu nào trong hai bộ đã thử. Phần cải thiện của mô hình lai vì vậy đến chủ yếu từ biểu diễn có đặc trưng, còn cách ghép hai nhánh có thể được chọn theo dữ liệu.

Vì LateFusion-F có NDCG@10 cao nhất trên cả hai bộ dữ liệu, cần giải thích vì sao NeuMF-F vẫn là mô hình đề xuất. Lý do thứ nhất là về phương pháp. Mô hình đề xuất được cố định trong kế hoạch đăng ký trước, trước khi có kết quả trên mẫu kiểm định. Đổi mô hình đề xuất sau khi xem kết quả sẽ biến kiểm định thành một phép chọn mô hình trên tập kiểm thử, là lỗi mà quy trình của đề tài muốn tránh. Lý do thứ hai là về nội dung. LateFusion-F dùng chính hai nhánh có đặc trưng của NeuMF-F và chỉ khác ở bước trộn điểm. Kết quả tốt của LateFusion-F vì vậy cũng xác nhận phát hiện chính của đề tài, rằng phần cải thiện đến từ biểu diễn có đặc trưng.

Về thực tiễn, nếu cần triển khai, có thể dùng hai nhánh có đặc trưng rồi trộn điểm muộn. Cách này cho kết quả không kém hợp nhất sớm ở cả hai bộ dữ liệu, và trọng số trộn có thể được chỉnh lại theo dữ liệu mới mà không phải huấn luyện lại mạng. Đổi lại, chi phí huấn luyện gần gấp đôi, vì phải huấn luyện hai mạng GMF-F và MLP-F thay cho một mạng NeuMF-F (Bảng 4.9).

4.7 Tóm tắt chương

Chương này đã trình bày kết quả thực nghiệm trên H&M và kiểm chứng trên Amazon Beauty. Với câu hỏi thứ nhất, NeuMF-F vượt có ý nghĩa thống kê các mô

hình đối chứng được tinh chỉnh đầy đủ và mô hình lai truyền thống trên cả hai bộ dữ liệu. Với câu hỏi thứ hai, đặc trưng giúp mô hình lai rõ rệt, trong đó đặc trưng thời gian đóng góp nhiều nhất. Với câu hỏi thứ ba, hợp nhất sớm tốt hơn nhánh MLP-F trên H&M, còn hợp nhất muộn của cùng hai nhánh cho kết quả tương đương trên H&M và tốt hơn trên Amazon. Biểu diễn có đặc trưng vì vậy là yếu tố quyết định, còn cách hợp nhất có thể được chọn theo dữ liệu. Chương tiếp theo đánh giá mức độ hoàn thành mục tiêu và tổng kết đề tài.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chương này đối chiếu kết quả đạt được với các mục tiêu đặt ra ở Chương 1, tổng kết các kết luận chính, rồi nêu hạn chế và hướng phát triển của đề tài.

5.1 Kết quả đạt được

Đề tài đã hoàn thành cả năm mục tiêu đặt ra ở mục 1.2.1. Bảng 5.1 tóm tắt kết quả của từng mục tiêu và nơi trình bày trong báo cáo.

Bảng 5.1: Mức độ hoàn thành mục tiêu

Mục tiêu	Kết quả đạt được	Trình bày ở
(1) Hệ thống hoá cơ sở lý thuyết	Trình bày lọc cộng tác, nhân tử hoá ma trận, BPR, kiến trúc NCF, mô hình lai dựa trên đặc trưng, hợp nhất sớm và hợp nhất muộn, các độ đo Top-K. Đối chiếu thiết lập của ba nghiên cứu nền tảng.	Chương 2
(2) Quy trình xử lý dữ liệu	Lấy mẫu theo khách hàng bằng hàm băm, gộp sản phẩm theo mẫu thiết kế, lọc 10-core trước mốc kiểm thử, chia theo thời gian, tính đặc trưng theo thời điểm. Quy trình áp dụng lại được cho Amazon Beauty.	Mục 3.2, 4.4.1
(3) Cài đặt và tinh chỉnh mô hình	Cài đặt NeuMF-F, 13 mô hình đối chứng đăng ký trước và mô hình lai truyền thống Hybrid-CBCF. Mọi mô hình có học được tinh chỉnh với cùng ngân sách 6 cấu hình.	Mục 3.3–3.6, 4.2
(4) Đánh giá có kiểm định	Xếp hạng toàn bộ tập ứng viên, bốn độ đo ở $K = 5, 10, 15, 20$, 5 seed, kiểm định Wilcoxon, khoảng tin cậy bootstrap và hiệu chỉnh Holm trên mẫu kiểm định độc lập. Kiểm chứng trên Amazon Beauty.	Mục 3.7, 4.3, 4.4
(5) Hệ thống demo	Hệ thống ba tầng, so sánh hai mô hình trên từng khách, chạy trên cả hai bộ dữ liệu, luôn trả về khuyến nghị kể cả với khách hàng mới.	Mục 3.9

5.2 Kết luận

Kết quả thực nghiệm trả lời được cả ba câu hỏi nghiên cứu. Trên H&M, NeuMF-F tốt hơn có ý nghĩa thống kê NeuMF chỉ dùng ID, nhánh MLP-F và các mô hình đối chứng trong họ so sánh, gồm BPR-MF, hai mô hình láng giềng, mô hình phổ biến theo thời gian và mô hình lọc nội dung. NeuMF-F cũng vượt một mô hình lai truyền thống kết hợp lọc nội dung và lọc cộng tác trên cả hai bộ dữ liệu. Khi kiểm chứng, kết luận về đặc trưng lặp lại trên Amazon Beauty, dù bộ này khác lĩnh vực, khác loại tương tác, không có thông tin khách hàng và mô hình không được tinh chỉnh lại.

Phần cải thiện của mô hình lai đến chủ yếu từ biểu diễn có đặc trưng. Trong các nhóm đặc trưng, đặc trưng thời gian đóng góp nhiều nhất trên cả hai bộ dữ liệu. Về cách hợp nhất, NeuMF-F vượt nhánh MLP-F trên H&M và không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng trên cả hai bộ dữ liệu. Hợp nhất muộn LateFusion-F của cùng hai nhánh cho kết quả tương đương trên H&M và tốt hơn trên Amazon. Các kết quả này cho thấy hướng đi của đề tài là phù hợp với dữ liệu thời trang. Đưa thêm thông tin về sản phẩm, khách hàng và thời gian vào mô hình lai mang lại lợi ích lớn hơn nhiều so với việc thay đổi cách ghép hai nhánh. Kết quả cũng khớp với nhận định của các nghiên cứu tái đánh giá, vì trên H&M, mô hình lai chỉ dùng mã ID khó vượt nhân tử hoá ma trận được tinh chỉnh kỹ.

Về đóng góp, đề tài xây dựng được một mô hình lai có đặc trưng vượt các mô hình đối chứng trên hai bộ dữ liệu thuộc hai lĩnh vực. Đề tài chỉ ra được nhóm thông tin có giá trị nhất cho khuyến nghị thời trang, và xây dựng một quy trình đánh giá hạn chế thiên lệch có thể dùng lại cho các nghiên cứu hệ khuyến nghị khác. Về ứng dụng, doanh nghiệp bán lẻ có thể cải thiện rõ chất lượng khuyến nghị bằng chính dữ liệu sẵn có, trong đó nên ưu tiên cập nhật doanh số theo thời gian và lịch sử mua của khách. Khi triển khai, hai nhánh có đặc trưng có thể được ghép sớm như NeuMF-F để chỉ phải huấn luyện một mạng, hoặc trộn điểm muộn như LateFusion-F khi cần kết quả ổn định hơn giữa các bộ dữ liệu.

5.3 Hạn chế của đề tài

Đề tài còn một số hạn chế về phạm vi. Do giới hạn tài nguyên tính toán, thực nghiệm dùng các mẫu khoảng 1,5% khách hàng của H&M với ngưỡng lọc $k = 10$, nên kết luận áp dụng cho nhóm khách có lịch sử mua đủ dày. Bài toán *cold start* của sản phẩm và khách hàng mới nằm ngoài phạm vi đánh giá định lượng. Khi sử dụng, hệ thống xử lý khách hàng mới bằng danh sách sản phẩm phổ biến. Lợi ích của đặc

trưng được đo trong họ mô hình NeuMF, chưa được so với một mô hình không dùng mạng lưới thần kinh trên cùng bộ đặc trưng. Mô tả sản phẩm hiện chỉ được biểu diễn bằng TF-IDF, và ảnh sản phẩm chưa được khai thác.

5.4 Hướng phát triển

Kết quả của đề tài cho thấy hướng bổ sung đặc trưng vào mô hình lai là đúng, và khung NeuMF-F cho phép thêm thông tin mới mà không phải thay đổi kiến trúc. Từ đó, đề tài có thể được phát triển tiếp theo các hướng sau, sắp theo mức độ gắn với kết quả đã có.

- Làm giàu đặc trưng thời gian. Đây là nhóm đặc trưng đóng góp nhiều nhất, nên cũng là nơi dễ thu thêm lợi ích nhất. Có thể bổ sung tính mùa vụ như doanh số cùng kỳ năm trước và tuần trong năm, tốc độ tăng giảm doanh số trong vài tuần gần nhất, và nhịp mua của khách theo từng nhóm hàng. Các đặc trưng này được tính theo thời điểm như cách đề tài đang làm, nên đưa vào mô hình ngay mà không phải sửa quy trình đánh giá.
- Khai thác ảnh và mô tả bằng mô hình tiền huấn luyện. Với hàng thời trang, kiểu dáng và màu sắc nhìn thấy trên ảnh có tác động lớn tới quyết định mua, trong khi đề tài mới dùng mô tả văn bản ở dạng TF-IDF. Cách làm là dùng một mô hình thị giác đã huấn luyện sẵn để biến ảnh sản phẩm của H&M thành vector, và một mô hình ngôn ngữ tiền huấn luyện để biến mô tả thành vector, rồi nối các vector này vào đặc trưng sản phẩm của NeuMF-F. Hướng này cũng có thể đi xa hơn với việc hợp nhất nhiều góc nhìn bằng Transformer như đề xuất của Hồ Thị Linh [4].
- Khuyến nghị cho sản phẩm mới và khách hàng mới. Đây là nhu cầu thường xuyên của cửa hàng thời trang, vì mỗi mùa có rất nhiều mẫu mới lên kệ. NeuMF-F đã có sẵn cơ chế chấm điểm sản phẩm chỉ từ đặc trưng khi bỏ vector mã ID ($m_i = 0$). Bước tiếp theo là huấn luyện với xác suất bỏ ID lớn hơn 0 và đánh giá riêng trên tập sản phẩm mới. Với khách hàng mới, danh sách phổ biến chung có thể thay bằng danh sách phổ biến theo nhóm tuổi và trạng thái hội viên, hai thông tin có ngay khi khách đăng ký.
- Mở rộng quy mô và đưa vào vận hành. Để chạy trên toàn bộ 1,36 triệu khách, hệ thống có thể chia làm hai bước. Bước một dùng kiến trúc hai tháp kết hợp tìm kiếm lân cận gần đúng để lọc nhanh vài trăm sản phẩm ứng viên cho mỗi khách. Bước hai dùng NeuMF-F xếp hạng lại các ứng viên đó.

Mô hình được huấn luyện lại định kỳ theo tuần, và hiệu quả thực tế được đo bằng thử nghiệm A/B trên tỉ lệ khách bấm xem và mua.

– Học cách trộn điểm theo từng nhóm khách. Kết quả trên Amazon cho thấy hợp nhất muộn có thể tốt hơn hợp nhất sớm. Thay cho một trọng số chung cho mọi khách, trọng số trộn giữa GMF-F và MLP-F có thể được học riêng cho từng nhóm khách hoặc từng loại sản phẩm, bằng cách học theo cặp đã dùng cho Hybrid-CBCF (Thuật toán 3.6).
– Mở rộng so sánh. Thêm Factorization Machines [15] dùng cùng bộ đặc trưng để làm rõ vai trò của kiến trúc học sâu, và thử các mô hình chuỗi, mô hình đồ thị trên cùng quy trình đánh giá. Quy trình đánh giá của đề tài đã sẵn sàng cho việc này, vì mọi mô hình chỉ cần đọc cùng tệp dữ liệu và cùng tập ứng viên.
– Giải thích khuyến nghị cho người dùng. Khách hàng tin khuyến nghị hơn khi biết vì sao sản phẩm được khuyến nghị. Hệ thống demo đã có thông tin về khách có gu giống và sản phẩm tương tự. Có thể dùng một mô hình ngôn ngữ lớn để chuyển các thông tin này cùng thuộc tính sản phẩm thành một câu giải thích ngắn bên cạnh mỗi khuyến nghị.

TÀI LIỆU THAM KHẢO

Dữ liệu

[1] H&M Group, *H&M Personalized Fashion Recommendations*, https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations, Cuộc thi trên Kaggle, 2022.

[2] J. McAuley, C. Targett, Q. Shi, và A. van den Hengel, "Image-Based Recommendations on Styles and Substitutes," in *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '15)*, Santiago, Chile, 2015, pp. 43–52. DOI: 10.1145/2766462.2767755

Nghiên cứu nền tảng

[3] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, "Neural Collaborative Filtering," in *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

[4] Hồ Thị Linh, "Multi-Source Integration for Recommendation Systems," Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

[5] S. Rendle, W. Krichene, L. Zhang, và J. Anderson, "Neural Collaborative Filtering vs. Matrix Factorization Revisited," in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys '20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

Hệ gợi ý và lọc cộng tác

[6] Y. Koren, R. Bell, và C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

[7] P. Lops, M. de Gemmis, và G. Semeraro, "Content-based Recommender Systems: State of the Art and Trends," in *Recommender Systems Handbook*, F. Ricci, L. Rokach, B. Shapira, và P. B. Kantor, eds., Springer, 2011, pp. 73–105.

[8] X. Su và T. M. Khoshgoftaar, "A Survey of Collaborative Filtering Techniques," *Advances in Artificial Intelligence*, vol. 2009, pp. 1–19, 2009. DOI: 10.1155/2009/421425

[9] R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

[10] P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, và J. Riedl, "GroupLens: An Open Architecture for Collaborative Filtering of Netnews," in *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, 1994, pp. 175–186. DOI: 10.1145/192844.192905

[11] B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, "Item-based Collaborative Filtering Recommendation Algorithms," in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

[12] A. I. Schein, A. Popescul, L. H. Ungar, và D. M. Pennock, "Methods and Metrics for Cold-Start Recommendations," in *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '02)*, 2002, pp. 253–260.

[13] S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, "BPR: Bayesian Personalized Ranking from Implicit Feedback," in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI '09)*, Montreal, QC, Canada, 2009, pp. 452–461.

[14] P. K. Atrey, M. A. Hossain, A. El Saddik, và M. S. Kankanhalli, "Multimodal Fusion for Multimedia Analysis: A Survey," *Multimedia Systems*, vol. 16, no. 6, pp. 345–379, 2010.

Mô hình dựa trên đặc trưng và biểu diễn văn bản

[15] S. Rendle, "Factorization Machines," in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

[16] H.-T. Cheng và cộng sự, "Wide & Deep Learning for Recommender Systems," in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems*

(DLRS 2016), Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

[17] H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, "DeepFM: A Factorization-Machine based Neural Network for CTR Prediction," in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

[18] M. Volkovs, G. Yu, và T. Poutanen, "DropoutNet: Addressing Cold Start in Recommender Systems," in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 4957–4966.

[19] G. Salton và C. Buckley, "Term-weighting Approaches in Automatic Text Retrieval," *Information Processing and Management*, vol. 24, no. 5, pp. 513–523, 1988.

[20] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, và R. Harshman, "Indexing by Latent Semantic Analysis," *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

Đánh giá, kiểm định và công cụ

[21] K. Järvelin và J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

[22] W. Krichene và S. Rendle, "On Sampled Metrics for Item Recommendation," in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

[23] S. Vargas và P. Castells, "Rank and Relevance in Novelty and Diversity Metrics for Recommender Systems," in *Proceedings of the 5th ACM Conference on Recommender Systems (RecSys '11)*, 2011, pp. 109–116. DOI: 10.1145/2043932.2043955

[24] Z. Meng, R. McCreadie, C. Macdonald, và I. Ounis, "Exploring Data Splitting Strategies for the Evaluation of Recommendation Models," in *Proceedings of the*

14th ACM Conference on Recommender Systems (RecSys '20), 2020, pp. 681–686. DOI: 10.1145/3383313.3418479

[25] A. Paszke và cộng sự, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

[26] D. P. Kingma và J. Ba, "Adam: A Method for Stochastic Optimization," in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

[27] M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, "Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches," in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys '19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

[28] F. Wilcoxon, "Individual Comparisons by Ranking Methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[29] B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[30] S. Holm, "A Simple Sequentially Rejective Multiple Test Procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.