TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chỉn chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan báo cáo dự án này là công trình nghiên cứu độc lập của chúng tôi dưới sự hướng dẫn khoa học trực tiếp của TS. Hồ Thị Linh. Mọi số liệu, quá trình phân tích và kết quả thực nghiệm trình bày trong báo cáo là hoàn toàn trung thực, khách quan và chưa từng được công bố dưới bất kỳ hình thức nào trước đây.

Các nguồn tài liệu tham khảo, số liệu trích dẫn phục vụ cho dự án đều có nguồn gốc rõ ràng, có độ tin cậy cao và được chú thích đầy đủ trong danh mục tài liệu tham khảo.

Chúng tôi xin hoàn toàn chịu trách nhiệm trước Nhà trường và pháp luật về tính chân thực, bản quyền cũng như các vi phạm quyền sở hữu trí tuệ liên quan đến nội dung báo cáo dự án này.

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Nhân tử hóa ma trận (Matrix Factorization – MF) mô hình hóa tương tác giữa khách hàng và sản phẩm bằng tích vô hướng của hai vector ẩn [1]: một phép kết hợp tuyến tính, học chỉ từ mã khách hàng và mã sản phẩm. Với dữ liệu thời trang – cực thưa, lệch mạnh về sản phẩm phổ biến và thay đổi theo mùa – cả hai điều này đều là giới hạn. Dự án xây dựng **NeuMF-F**, một mô hình lai giữ cấu trúc hai nhánh của Neural Matrix Factorization [2] – nhánh tuyến tính Generalized Matrix Factorization (GMF) và nhánh phi tuyến Multi-Layer Perceptron (MLP), hợp nhất ở lớp dự đoán – nhưng biểu diễn mỗi khách hàng và sản phẩm bằng Embedding mã ID cộng với phép chiếu của đặc trưng: thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng, doanh số và thời gian.

Thực nghiệm dùng bộ dữ liệu H&M Personalized Fashion Recommendations [3] (31,8 triệu giao dịch). Hai mẫu khách hàng không giao nhau được lấy tái lập được theo hàm băm: mẫu phát triển (21.599 khách) chỉ dùng để tinh chỉnh trên tập xác thực, mẫu kiểm định (21.351 khách) chỉ dùng một lần cho đánh giá cuối. Mỗi sản phẩm là một mẫu thiết kế (gộp mọi màu); dữ liệu được chia theo thời gian; lọc k-core chỉ dùng dữ liệu trước mốc kiểm thử; tập ứng viên gồm các sản phẩm đã có dữ liệu huấn luyện trước mốc; mọi đặc trưng được tính theo thời điểm, không dùng thông tin tương lai. Mười bốn mô hình – NeuMF-F, từng nhánh GMF-F và MLP-F, hợp nhất muộn LateFusion-F, NeuMF chỉ dùng ID cùng hai nhánh của nó, và bảy baseline Random, Most Popular, MostPopular-Recent, gợi ý theo nội dung, ItemKNN, UserKNN, BPR-MF – được tinh chỉnh với cùng ngân sách. Đánh giá cuối theo kế hoạch đăng ký trước, có khoá tập kiểm thử: Full Ranking, 5 seed, kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm trên họ 10 so sánh.

Trên tập kiểm thử của mẫu kiểm định (3.165 khách hàng), mô hình đề xuất NeuMF-F đạt NDCG@10 = 0,04003, xếp thứ hai trong 14 mô hình, sau LateFusion-F (0,04093); NeuMF chỉ dùng ID đạt 0,02783, BPR-MF 0,02661, UserKNN 0,03114, MostPopular-Recent 0,02760. Trong họ 10 so sánh đã đăng ký, NeuMF-F tốt hơn có ý nghĩa NeuMF chỉ dùng ID (+43,8%), nhánh MLP-F (+15,0%) và cả năm baseline của họ so sánh (chênh từ +28,5% đến +691,5%); NeuMF-F không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng (+2,6%) và với LateFusion-F ($-2{,}2\%$): cải thiện đến

từ đặc trưng – đặc trưng thời gian đóng góp nhiều nhất trong ablation – chứ không từ cách hợp nhất hai nhánh. Bốn mô hình có đặc trưng giữ nguyên thứ tự và vị trí dẫn đầu khi đo ở $K = 5, 10, 15, 20$. Kiểm chứng trên bộ dữ liệu Amazon Beauty với cùng mã nguồn và cấu hình cho thấy kết luận về đặc trưng còn đúng (NeuMF-F hơn NeuMF chỉ dùng ID +65,7%, có ý nghĩa), nhưng trên bộ này hợp nhất muộn LateFusion-F tốt hơn NeuMF-F có ý nghĩa. Giai đoạn phát triển trước đó (NeuMF chỉ dùng ID, đánh giá trên chính mẫu phát triển) được báo cáo như lịch sử phát triển: NeuMF không vượt MF đã tinh chỉnh – lý do đề tài chuyển sang bổ sung thông tin thay vì chỉ tăng độ phức tạp của mô hình. Hệ thống demo suy diễn (FastAPI) minh họa và so sánh các mô hình trên từng khách hàng; khách hàng mới chưa có lịch sử được gợi ý các sản phẩm phổ biến.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Matrix Factorization (MF) models customer–item interactions with the inner product of two latent vectors [1]: a linear combination, learned from customer and item IDs only. On fashion data – extremely sparse, heavily skewed towards popular items and seasonal – both are limitations. This project builds **NeuMF-F**, a hybrid model that keeps the two-branch structure of Neural Matrix Factorization [2] – a linear Generalized Matrix Factorization (GMF) branch and a non-linear Multi-Layer Perceptron (MLP) branch fused at the prediction layer – but represents every customer and item by an ID embedding plus a projection of features: item attributes and text description, customer attributes, sales and time.

Experiments use the H&M Personalized Fashion Recommendations dataset [3] (31.8 million transactions). Two disjoint, reproducible customer samples are drawn by hashing: the development sample (21,599 customers) is used only for tuning on its validation set, and the holdout sample (21,351 customers) is used once, for the final evaluation. Each item is a product design (all colours merged); data are split by time; the k-core filter uses only data before the test cut-off; the candidate set contains the items with training data before the cut-off; all features are computed point-in-time, without future information. Fourteen models – NeuMF-F, its GMF-F and MLP-F branches, the late-fusion LateFusion-F, ID-only NeuMF with its two branches, and seven baselines (Random, Most Popular, recent popularity, content-based, ItemKNN, UserKNN, BPR-MF) – are tuned with the same budget. The final evaluation follows a pre-registered plan with a locked test set: full ranking, five seeds, per-user Wilcoxon signed-rank tests with bootstrap confidence intervals and Holm correction over a family of ten comparisons.

On the test set of the holdout sample (3.165 customers), the proposed NeuMF-F reaches NDCG@10 = 0,04003, second of 14 models after LateFusion-F (0,04093), compared with 0,02783 for ID-only NeuMF, 0,02661 for BPR-MF, 0,03114 for UserKNN and 0,02760 for recent popularity. In the pre-registered family of ten comparisons, NeuMF-F significantly outperforms ID-only NeuMF (+43,8%), its MLP-F branch (+15,0%) and all five baselines of the family (by +28,5% to +691,5%);

NeuMF-F is not significantly different from its GMF-F branch alone (+2,6%) or from LateFusion-F (−2,2%): the gain comes from the features – time features matter most in the ablation – rather than from how the two branches are fused. The four feature-based models keep their order and lead at $K = 5, 10, 15, 20$. A validation run on the Amazon Beauty dataset with the same code and configurations confirms the feature effect (NeuMF-F outperforms ID-only NeuMF by +65,7%), but there late fusion significantly outperforms NeuMF-F. The earlier development phase (ID-only NeuMF, evaluated on the development sample itself) is reported as development history: NeuMF did not outperform a tuned MF baseline, which is why the project turned to adding information rather than only model complexity. An inference-only demo (FastAPI) compares the models for individual customers and recommends popular items to new customers without purchase history.

MỤC LỤC

DANH MỤC HÌNH VẼ xii

DANH MỤC BẢNG BIỂU xiv

DANH MỤC THUẬT TOÁN xvi

DANH MỤC CÁC CHỮ VIẾT TẮT xvii

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI 1

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài 1

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài 1

1.1.2 Vì sao nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này 2

1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F) 2

1.2 Mục tiêu và phạm vi nghiên cứu 3

1.2.1 Mục tiêu nghiên cứu 3

1.2.2 Phạm vi nghiên cứu 3

1.3 Phương pháp nghiên cứu 4

1.4 Ý nghĩa khoa học và thực tiễn của đề tài 5

1.4.1 Ý nghĩa khoa học 5

1.4.2 Ý nghĩa thực tiễn 6

1.5 Bố cục của báo cáo dự án 6

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN 8

2.1 Tổng quan về hệ thống gợi ý (Recommendation System) 8

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai: lựa chọn của đề tài 8

2.1.2 Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based) 9

2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback) 10

2.1.4 Độ thưa dữ liệu và khởi đầu lạnh: hai giới hạn định hình thiết kế của đề tài 10

2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận 11

2.2.1 Mô hình Nhân tử hóa ma trận (Matrix Factorization – MF) 11
2.2.2 Hạn chế của tích vô hướng trong mô hình hóa tương tác 12
2.2.3 Tối ưu hóa xếp hạng theo cặp: Bayesian Personalized Ranking (BPR) 12
2.3 Kiến trúc Mạng khuyến nghị thần kinh (Neural Collaborative Filtering – NCF)..... 12
2.3.1 Generalized Matrix Factorization (GMF) 12
2.3.2 Multi-Layer Perceptron (MLP) 13
2.3.3 Kiến trúc mô hình lai NeuMF..... 13
2.3.4 Chiến lược hợp nhất: Early Fusion và Late Fusion..... 13
2.3.5 Lấy mẫu âm (Negative Sampling) và hàm tổn thất Binary Cross-Entropy . 16
2.4 Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu 16
2.4.1 Mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm 16
2.4.2 Gợi ý theo chuỗi hành vi và Transformer..... 17
2.4.3 Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering) 18
2.4.4 Mô hình tự mã hóa biến phân (Variational Autoencoder) cho lọc cộng tác 18
2.5 Các chỉ số đánh giá hệ thống gợi ý Top-K..... 19
2.5.1 Các chỉ số đánh giá ngoài độ chính xác (Beyond-Accuracy Metrics)..... 20
2.6 Tổng quan các công trình nghiên cứu liên quan..... 21
2.6.1 Ba nghiên cứu nền tảng và đối chiếu thiết lập thực nghiệm 24
2.7 Khoảng trống nghiên cứu 27
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F..... 28
3.1 Quy trình tổng thể của hệ thống..... 28
3.2 Dữ liệu và tiền xử lý..... 30
3.2.1 Đặc tả bộ dữ liệu H&M 30
3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định 31
3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử..... 32
3.2.4 Giai đoạn đánh giá và tập ứng viên..... 33
3.2.5 Xây dựng đặc trưng theo thời điểm..... 35

3.2.6 Dữ liệu kiểm chứng Amazon Beauty *37*
3.3 Thiết kế mô hình lai NeuMF-F 38
3.3.1 Biểu diễn lai: Embedding ID kết hợp đặc trưng *41*
3.3.2 Nhánh GMF-F *41*
3.3.3 Nhánh MLP-F *42*
3.3.4 Tầng hợp nhất và lớp dự đoán đầu ra *42*
3.3.5 Các mô hình đối chiếu xây dựng trên cùng khung *43*
3.4 Lấy mẫu âm theo thời điểm và hàm mục tiêu 43
3.4.1 Lấy mẫu âm động theo ngày ra mắt của sản phẩm *43*
3.4.2 Hàm tổn thất Binary Cross-Entropy và điều chuẩn *44*
3.5 Quy trình huấn luyện và tinh chỉnh 45
3.5.1 Bảng thiết lập siêu tham số và kỹ thuật dừng sớm *45*
3.6 Quy trình đánh giá không thiên lệch 47
3.7 Suy diễn Top-K và xử lý khách hàng mới 51
3.8 Thiết kế hệ thống giao diện thực nghiệm (Demo) 52
3.8.1 Kiến trúc tổng thể: ba tầng tách biệt *52*
3.8.2 Thiết kế API suy diễn *52*
3.8.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng *55*
3.8.4 Minh họa hệ thống demo đã cài đặt *55*
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 60
4.1 Cấu hình thực nghiệm 60
4.2 Phương pháp đối chứng (Baselines) 61
4.3 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển 62
4.4 Kết quả đánh giá cuối trên mẫu kiểm định 63
4.4.1 So sánh các độ đo xếp hạng (Full Ranking) *63*
4.4.2 Kết quả theo $K = 5, 10, 15, 20$ *64*
4.4.3 Kiểm định ý nghĩa thống kê *64*
4.4.4 Phân tích bóc tách thành phần (Ablation Study) *67*

4.4.5 Độ phủ và chi phí huấn luyện *67*
4.4.6 Hội tụ và độ ổn định giữa hai mẫu *69*
4.5 Kiểm chứng trên dữ liệu Amazon Beauty 70
4.5.1 Kết quả trên tập kiểm thử Amazon Beauty *70*
4.5.2 Đối chiếu kết luận giữa H&M và Amazon Beauty *73*
4.5.3 Ablation và độ phủ trên Amazon Beauty *75*
4.6 Lịch sử phát triển: giai đoạn chỉ dùng mã ID và bản đầu của kế hoạch đánh giá 76
4.7 Phạm vi và giới hạn thực nghiệm 77
4.8 Thảo luận 78
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 80
5.1 Kết luận 80
5.2 Hạn chế của đề tài 81
5.3 Hướng phát triển 82
5.4 Triển khai thực tế giao diện thực nghiệm 83
PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN 85
PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM 88
TÀI LIỆU THAM KHẢO 90

DANH MỤC HÌNH VẼ

Hình 2.1: Kiến trúc mô hình lai Neural Matrix Factorization (NeuMF) với kích thước của từng ma trận và từng tầng, từ đầu vào đến danh sách Top-K (M người dùng, N sản phẩm, d chiều Embedding; trong cài đặt của đề tài hai nhánh dùng cùng d và tháp MLP giảm một nửa qua mỗi tầng) 14

Hình 2.2: Hai cách hợp nhất cùng hai thành phần MF (GMF) và DNN (MLP): ở mức biểu diễn (NeuMF, NeuMF-F) và ở mức điểm dự đoán (Late Fusion, LateFusion-F) 15

Hình 3.1: Đường ống của hệ thống: đặc trưng $\rightarrow$ huấn luyện $\rightarrow$ lưu mô hình $\rightarrow$ suy diễn Top-K (quy trình đánh giá được trình bày riêng ở Hình 3.3) 29

Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F, từ đầu vào đến danh sách Top-K. Mỗi nhánh có bảng Embedding ID và phép chiếu đặc trưng riêng; $m_i \in \{0, 1\}$ cho biết Embedding ID của sản phẩm có được dùng hay không. Với cấu hình được chọn ($d = 32$): tháp $64 \rightarrow 32 \rightarrow 16 \rightarrow 8$, $\phi \in \mathbb{R}^{40}$; trên mẫu kiểm định H&M $|\mathcal{U}| = 7.994$, $|\mathcal{I}| = 6.749$, $d_U = 42$, $d_I = 157$ 40

Hình 3.3: Quy trình đánh giá: tinh chỉnh chỉ trên tập xác thực của mẫu phát triển, đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định theo kế hoạch đăng ký trước 48

Hình 3.4: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo) 53

Hình 3.5: Giao diện demo – màn hình Admin kiểm thử mô hình với mô hình của đánh giá cuối: lịch sử mua, Top-10 của NeuMF-F và NeuMF, hạng của từng sản phẩm đích trong tập kiểm thử 57

Hình 3.6: Giao diện demo – 10 khách hàng tương đồng nhất theo UserKNN: độ tương đồng cosine, số sản phẩm mua chung và láng giềng đã mua sản phẩm đích nào của khách 58

Hình 3.7: Giao diện demo – khách hàng mới chưa có trong dữ liệu đã học: danh sách Top-10 sản phẩm phổ biến (Most Popular) gắn nhãn "gợi ý phổ biến", không có sản phẩm đích để đối chiếu 59

Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử của mẫu kiểm định H&M: trung bình ± độ lệch chuẩn qua 5 seed, chấm đen là từng seed 64
Hình 4.2: Hiệu NDCG@10 (A − B) của họ 10 so sánh đã đăng ký trên H&M, với khoảng tin cậy 95% bootstrap theo người dùng và giá trị p đã hiệu chỉnh Holm 66
Hình 4.3: Ablation của NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M (seed 42): NDCG@10 của NeuMF-F đầy đủ và của từng biến thể tắt một thành phần 68
Hình 4.4: Đường hội tụ của các mạng nơ-ron khi chọn số epoch trên tập xác thực của mẫu kiểm định (seed 42): NDCG@10 trên tập xác thực và hàm mất mát BCE trên tập huấn luyện theo epoch; vòng tròn là epoch được chọn 69
Hình 4.5: NDCG@10 trên tập xác thực của mẫu phát triển (lúc tinh chỉnh) và trên tập kiểm thử của mẫu kiểm định (đánh giá cuối) 69
Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty: trung bình ± độ lệch chuẩn qua 5 seed, chấm đen là từng seed 71

DANH MỤC BẢNG BIỂU

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan 21
Bảng 2.2: Đối chiếu thiết lập thực nghiệm và kết quả công bố của ba nghiên cứu nền tảng với đề tài 25

Bảng 3.1: Độ nhạy k-core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ) 30
Bảng 3.2: Độ nhạy của mẫu phát triển theo ngưỡng lọc k-core (khảo sát ở giai đoạn phát triển, theo `article_id`, 429.964 cặp trước khi lọc)..... 33
Bảng 3.3: Quy mô dữ liệu H&M: mẫu phát triển (chỉ dùng tập xác thực) và mẫu kiểm định (khách hàng khác hẳn mẫu phát triển)..... 35
Bảng 3.4: Đặc trưng của mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F)..... 36
Bảng 3.5: Đặc trưng của mô hình có đặc trưng trên H&M và trên Amazon Beauty 39
Bảng 3.6: Quy mô dữ liệu Amazon Beauty (2014, 5-core): một bộ dữ liệu, chia theo thời gian 39
Bảng 3.7: Không gian tinh chỉnh (giá trị in đậm là cấu hình mặc định) 45
Bảng 3.8: Các endpoint chính của API suy diễn 54

Bảng 4.1: Cấu hình tốt nhất của từng mô hình trên tập xác thực của mẫu phát triển (seed 42; 6 cấu hình mỗi mô hình có học, mô hình một tham số thử đủ lưới) 62
Bảng 4.2: Kết quả trên tập kiểm thử của mẫu kiểm định: trung bình $\pm$ độ lệch chuẩn qua 5 seed (xếp hạng trên toàn bộ tập ứng viên; 3.165 người dùng) 63
Bảng 4.3: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định (trung bình qua 5 seed) 65
Bảng 4.4: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định (trung bình qua 5 seed) 65
Bảng 4.5: Kiểm định họ 10 so sánh đã đăng ký trước trên NDCG@10 (H&M, mẫu kiểm định, mỗi người dùng lấy trung bình qua 5 seed): Wilcoxon signed-rank, hiệu chỉnh Holm, khoảng tin cậy bootstrap 95% 66
Bảng 4.6: Ablation của NeuMF-F trên tập kiểm thử của mẫu kiểm định (seed 42; cùng siêu tham số, tắt một thành phần) 67

Bảng 4.7: Mô tả danh sách gợi ý top-10 (seed 42) và chi phí huấn luyện trên H&M, mẫu kiểm định (trung bình qua seed) 68
Bảng 4.8: Kết quả trên tập kiểm thử Amazon Beauty: trung bình ± độ lệch chuẩn qua 5 seed (xếp hạng trên toàn bộ tập ứng viên; 2.644 người dùng) 71
Bảng 4.9: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty (trung bình qua 5 seed)..... 72
Bảng 4.10: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty (trung bình qua 5 seed)..... 72
Bảng 4.11: Kiểm định họ 10 so sánh đã đăng ký trước trên NDCG@10 (Amazon Beauty, mỗi người dùng lấy trung bình qua 5 seed): Wilcoxon signed-rank, hiệu chỉnh Holm, khoảng tin cậy bootstrap 95%..... 73
Bảng 4.12: Kết luận của họ 10 so sánh đã đăng ký trên H&M (mẫu kiểm định) và trên Amazon Beauty (NDCG@10; chênh lệch $= (A - B)/B$).. 74
Bảng 4.13: Ablation của NeuMF-F trên tập kiểm thử Amazon Beauty (seed 42; cùng siêu tham số, tắt một thành phần) 75

DANH MỤC THUẬT TOÁN

Thuật toán 3.1: Chuẩn bị dữ liệu: gộp theo mẫu thiết kế và lọc k-core lặp . . 33
Thuật toán 3.2: Lấy mẫu âm theo thời điểm cho mô hình có đặc trưng (thực hiện lại ở đầu mỗi epoch) 44
Thuật toán 3.3: Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch . . 46
Thuật toán 3.4: Đánh giá Full Ranking một mô hình trên một giai đoạn . . . 50
Thuật toán 3.5: Chọn trọng số w của LateFusion-F trên tập xác thực của mẫu phát triển 50
Thuật toán 3.6: Suy diễn Top-K cho một khách hàng, có xử lý khách hàng mới 51

DANH MỤC CÁC CHỮ VIẾT TẮT

ALS	Alternating Least Squares (Bình phương tối thiểu luân phiên)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hóa Bayes)
CF	Collaborative Filtering (Lọc cộng tác)
CI	Confidence Interval (Khoảng tin cậy)
CPU	Central Processing Unit (Bộ xử lý trung tâm)
CTR	Click-Through Rate (Tỷ lệ nhấp chuột)
DCG	Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu)
DL	Deep Learning (Học sâu)
DNN	Deep Neural Network (Mạng nơ-ron sâu)
FM	Factorization Machines (Máy nhân tử hóa)
GMF	Generalized Matrix Factorization (Nhân tử hóa ma trận tổng quát)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
HR	Hit Ratio (Tỷ lệ đánh trúng)
iALS	implicit Alternating Least Squares (Bình phương tối thiểu luân phiên cho phản hồi ẩn)
IDCG	Ideal Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu lý tưởng)
ItemKNN	Item-based k-Nearest Neighbors (Lọc cộng tác theo k sản phẩm láng giềng gần nhất)
LSA	Latent Semantic Analysis (Phân tích ngữ nghĩa tiềm ẩn)

MD5	Message-Digest Algorithm 5 (Hàm băm MD5)
MF	Matrix Factorization (Nhân tử hóa ma trận)
MLP	Multi-Layer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
NCF	Neural Collaborative Filtering (Lọc cộng tác dựa trên nơ-ron)
NDCG	Normalized Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu chuẩn hóa)
NeuMF	Neural Matrix Factorization (Nhân tử hóa ma trận thần kinh)
NeuMF-F	NeuMF bổ sung đặc trưng (mô hình đề xuất; GMF-F, MLP-F: hai nhánh có đặc trưng)
RAM	Random Access Memory (Bộ nhớ truy cập ngẫu nhiên)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
SVD	Singular Value Decomposition (Phân rã giá trị kỳ dị)
TF-IDF	Term Frequency – Inverse Document Frequency (Tần suất từ – nghịch đảo tần suất văn bản)
UserKNN	User-based k-Nearest Neighbors (Lọc cộng tác theo k người dùng láng giềng gần nhất)
VAE	Variational Autoencoder (Bộ tự mã hóa biến phân)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài

Động lực trực tiếp của đề tài xuất phát từ việc khảo sát bộ dữ liệu H&M Personalized Fashion Recommendations [3]: tệp giao dịch gốc ghi nhận 31.788.324 dòng mua hàng của 1.362.281 khách hàng trên 104.547 sản phẩm thời trang trong hai năm (mục 3.2.1). Hai đặc điểm của dữ liệu này đặt ra yêu cầu cho mô hình gợi ý. Thứ nhất, ma trận tương tác *cực thưa*: ngay cả sau khi lọc k-core, mật độ chỉ khoảng 0,03% trên toàn bộ dữ liệu (Bảng 3.1) – mỗi khách chỉ mua một phần rất nhỏ của danh mục, và lệch mạnh về một nhóm nhỏ sản phẩm phổ biến. Thứ hai, nhu cầu thời trang *thay đổi theo mùa và theo xu hướng*: sản phẩm bán chạy trong vài tuần gần đây chưa chắc là sản phẩm được mua nhiều nhất trong hai năm. Một mô hình chỉ học từ mã khách hàng và mã sản phẩm không dùng được những thông tin này – xu hướng bán gần đây của sản phẩm, sản phẩm thuộc loại gì, khách hàng thuộc nhóm nào – trong khi bộ dữ liệu có sẵn thuộc tính và mô tả văn bản của từng sản phẩm, thông tin khách hàng và doanh số theo thời gian.

Câu hỏi của đề tài vì vậy là: trên dữ liệu giao dịch thời trang thực tế – cực thưa, lệch về sản phẩm phổ biến và thay đổi theo mùa – một mô hình lai kết hợp nhân tử hóa ma trận với mạng nơ-ron sâu, được bổ sung đặc trưng sản phẩm, khách hàng và thời gian, có cho chất lượng gợi ý tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ và tốt hơn chính các thành phần của nó hay không. Đề tài không dựa vào kết quả công bố của các công trình tham khảo (dùng dữ liệu phim ảnh, mạng xã hội hình ảnh với giao thức khác), mà xây dựng và đánh giá mô hình trực tiếp trên dữ liệu H&M với cách chia dữ liệu và giao thức đánh giá riêng.

Ở góc độ ứng dụng, cá nhân hóa gợi ý sản phẩm trong thương mại điện tử giúp giảm chi phí tìm kiếm của khách hàng và hỗ trợ doanh nghiệp dự báo nhu cầu [4], [5]. Với ngành thời trang, nơi nhu cầu thay đổi theo mùa, gợi ý còn cần phản ánh xu hướng theo thời gian chứ không chỉ sở thích lâu dài của khách.

1.1.2 Vì sao nhân tử hóa ma trận tuyến tính chưa đủ cho dữ liệu này

Cách tiếp cận đơn giản nhất cho bài toán trên là Nhân tử hóa ma trận (Matrix Factorization – MF): mỗi User u và Item i được gán một vector ẩn $p_u, q_i \in \mathbb{R}^d$, và mức độ tương tác được dự đoán bằng tích vô hướng của hai vector [1]:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{1.1}$$

Công thức này có hai giới hạn trên dữ liệu H&M. Một là giới hạn về *biểu diễn*: tích vô hướng cộng dồn các chiều đặc trưng theo cùng một trọng số cố định và chỉ mô hình hóa được tương tác tuyến tính – He và cộng sự [2] lấy đây làm động cơ để bổ sung một thành phần phi tuyến. Hai là giới hạn về *thông tin*: vector q_i chỉ học được từ các lần sản phẩm i đã được mua, nên sản phẩm ít người mua có biểu diễn được ước lượng từ rất ít dữ liệu, còn sản phẩm chưa có lần mua nào thì không có biểu diễn – vấn đề khởi đầu lạnh của sản phẩm [6]; những gì đã biết về chính sản phẩm (thuộc tính, mô tả, doanh số gần đây) và về khách hàng không được dùng. Giới hạn này không thể giải quyết chỉ bằng cách làm mô hình phức tạp hơn mà phải bổ sung thông tin.

1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F)

NeuMF – do He và cộng sự đề xuất năm 2017 [2] – giải quyết giới hạn thứ nhất bằng cách kết hợp thay vì thay thế MF: một nhánh tương đương MF dưới dạng mạng nơ-ron (Generalized Matrix Factorization, GMF) giữ khả năng học tương tác tuyến tính, và một nhánh Multi-Layer Perceptron (MLP) song song học thêm tương tác phi tuyến; hai nhánh được hợp nhất ở lớp dự đoán. Tuy nhiên, giai đoạn phát triển của đề tài (mục 4.6) cho thấy NeuMF chỉ dùng mã ID không vượt được MF được tinh chỉnh tốt trên dữ liệu H&M – phù hợp với các tái đánh giá độc lập [7], [8].

Đề tài vì vậy xây dựng mô hình đề xuất **NeuMF-F**: giữ nguyên cấu trúc hai nhánh GMF và MLP của NeuMF, nhưng biểu diễn mỗi khách hàng và sản phẩm bằng tổng của Embedding ID và một phép chiếu của đặc trưng (thuộc tính và mô tả sản phẩm, thông tin khách hàng, doanh số và thời gian), theo hướng các mô hình lai dựa trên đặc trưng như Wide & Deep [9] và DeepFM [10]. Phần đặc trưng đưa vào mô hình những thông tin mà mã ID không mang: sản phẩm thuộc loại gì, đang bán chạy hay không, khách hàng thuộc nhóm nào và mua gần đây hay không. Cấu trúc hai nhánh tường minh cho phép *tách bạch* từng đóng góp bằng các phép so sánh trực tiếp: với NeuMF chỉ dùng ID (đóng góp của đặc trưng), với từng nhánh đứng riêng (đóng góp

của việc hợp nhất), và với Late Fusion của cùng hai nhánh (hợp nhất sớm hay muộn).

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

- Nghiên cứu cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận, Mạng nơ-ron sâu, kiến trúc NeuMF, mô hình lai dựa trên đặc trưng và hai cách hợp nhất Early Fusion, Late Fusion [1], [2], [11].
- Xây dựng quy trình xử lý dữ liệu hoàn chỉnh trên bộ dữ liệu H&M [3]: lấy mẫu theo khách hàng, xây dựng ma trận tương tác phản hồi ẩn, chia dữ liệu theo thời gian, xây dựng đặc trưng sản phẩm, khách hàng và thời gian *theo thời điểm* – không dùng bất kỳ thông tin nào xảy ra sau thời điểm cần dự đoán.
- Thiết kế và cài đặt mô hình lai NeuMF-F trên nền tảng PyTorch [12], cùng các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, NeuMF chỉ dùng ID) và sáu baseline (Most Popular, MostPopular-Recent, gợi ý theo nội dung, ItemKNN, UserKNN, BPR-MF), mọi mô hình được tinh chỉnh với cùng ngân sách.
- Đánh giá thực nghiệm định lượng theo giao thức Full Ranking trên toàn bộ tập ứng viên, bằng các độ đo NDCG@K [13], Recall@K, HR@K, Precision@K với $K = 5, 10, 15, 20$; kết luận trên một mẫu khách hàng độc lập chưa từng được dùng để ra quyết định, theo kế hoạch đăng ký trước, với 5 lần chạy và kiểm định thống kê có hiệu chỉnh đa so sánh; ablation từng nhóm đặc trưng; kiểm chứng lại các kết luận trên một bộ dữ liệu thứ hai (Amazon Beauty) với cùng mã nguồn và cấu hình.
- Xây dựng hệ thống demo minh họa mô hình đã huấn luyện trong một kịch bản cửa hàng, luôn trả về gợi ý – kể cả cho khách hàng mới chưa có lịch sử mua.

1.2.2 Phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Kiến trúc Neural Collaborative Filtering (GMF, MLP, NeuMF) [2] và mở rộng có đặc trưng của nó (NeuMF-F); hai cách hợp nhất mô hình MF với mạng nơ-ron sâu – Early Fusion (mức biểu diễn) và Late Fusion (mức điểm dự đoán) [11]; các phương pháp đánh giá hệ thống gợi ý Top-K.

- **Dữ liệu thực nghiệm:** Bộ dữ liệu H&M Personalized Fashion Recommendations [3]: tệp giao dịch, tệp danh mục sản phẩm (thuộc tính, mô tả văn bản) và tệp thông tin khách hàng. Khảo sát quy mô được chạy trên toàn bộ 31,8 triệu giao dịch; huấn luyện và đánh giá được thực hiện trên hai mẫu khoảng 500.000 giao dịch, mỗi mẫu khoảng 21.000 khách hàng được chọn ngẫu nhiên theo hàm băm, không có khách chung, giữ trọn lịch sử 2 năm (lý do ở mục 3.2.2). Mỗi sản phẩm là một mẫu thiết kế (`product_code`): mọi biến thể màu của cùng một mẫu được gộp lại. Ảnh sản phẩm không được dùng làm đầu vào mô hình. Để kiểm chứng, toàn bộ đánh giá cuối được chạy lại trên bộ Amazon Beauty (đánh giá sản phẩm làm đẹp, bản 5-core năm 2014) [14] với cấu hình đã chọn trên H&M (mục 3.2.6).
- **Tín hiệu tương tác:** Phản hồi ẩn dạng nhị phân từ lịch sử mua hàng (mua hay chưa mua), kèm ngày mua.
- **Khởi đầu lạnh:** sản phẩm chưa có người mua trước thời điểm dự đoán (trong đó có sản phẩm vừa ra mắt) và người dùng chưa có lịch sử mua đều nằm ngoài phạm vi đánh giá định lượng (mục 3.2.4). Khi hệ thống được sử dụng, khách hàng mới được gợi ý các sản phẩm phổ biến; khách đã có lịch sử mua mới được gợi ý bằng mô hình đề xuất (mục 3.7).

1.3 Phương pháp nghiên cứu

Để giải quyết các mục tiêu đã đặt ra (mục 1.2.1), đề tài kết hợp bốn nhóm phương pháp, được triển khai tuần tự theo trình tự trình bày trong các chương tiếp theo:

1. **Phương pháp nghiên cứu lý thuyết (phân tích và tổng hợp tài liệu):** Hệ thống hóa cơ sở lý thuyết về Lọc cộng tác, Nhân tử hóa ma trận, kiến trúc NCF/NeuMF và mô hình lai dựa trên đặc trưng từ các công trình nền tảng [1], [2], [9], [15], đồng thời khảo sát các hướng nghiên cứu hiện đại hơn để xác định vị trí đóng góp và giới hạn của hướng tiếp cận được lựa chọn (Chương 2). Các công trình được dùng làm cơ sở về phương pháp; số liệu của chúng không được dùng làm chuẩn so sánh vì khác dữ liệu và giao thức.
2. **Phương pháp xử lý dữ liệu định lượng:** Xây dựng quy trình tiền xử lý tường minh, tái lập được và kiểm chứng được ở từng bước – lấy mẫu theo khách hàng, gộp giao dịch, lọc k-core chỉ trên dữ liệu trước mốc kiểm thử,

chia giai đoạn theo thời gian, xây dựng đặc trưng theo thời điểm – với bộ kiểm thử tự động xác nhận không rò rỉ thông tin tương lai (Chương 3).

3. **Phương pháp thực nghiệm khoa học (mô hình hóa và huấn luyện):** Cài đặt các mô hình bằng PyTorch [12], huấn luyện bằng hàm mất mát Binary Cross-Entropy với lấy mẫu âm theo thời điểm, tối ưu bằng Adam [16]; siêu tham số của mọi mô hình được tinh chỉnh với cùng ngân sách, chỉ trên tập xác thực của mẫu phát triển.
4. **Phương pháp đánh giá định lượng và kiểm chứng thống kê:** Đánh giá Full Ranking trên toàn bộ tập ứng viên; đăng ký trước kế hoạch đánh giá và khoá tập kiểm thử; kết luận trên một mẫu khách hàng độc lập; kiểm định Wilcoxon theo người dùng kèm khoảng tin cậy bootstrap và hiệu chỉnh Holm [17], [18], [19]; kiểm chứng trên bộ dữ liệu thứ hai (Chương 4).

Điểm xuyên suốt của phương pháp luận là ưu tiên tính tái lập và kiểm chứng được: mọi số liệu kết quả trong báo cáo đều được trích xuất tự động từ tệp kết quả do chính quy trình thực nghiệm sinh ra, không nhập tay.

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

- Cung cấp kết quả thực nghiệm có kiểm định thống kê, trên dữ liệu giao dịch thời trang thực tế và trên một mẫu khách hàng chưa từng dùng để ra quyết định, về việc mô hình lai MF + DNN có đặc trưng (NeuMF-F) có vượt các baseline được tinh chỉnh cùng ngân sách, vượt NeuMF chỉ dùng ID và vượt từng nhánh thành phần của nó hay không; kết luận được kiểm chứng lại trên một bộ dữ liệu thứ hai (kết quả ở Chương 4).
- Làm rõ vị trí của NeuMF/NeuMF-F trong phân loại Early Fusion/Late Fusion (mục 2.3.4) và so sánh trực tiếp hai cách hợp nhất trên cùng hai thành phần.
- Xây dựng một quy trình đánh giá chống thiên lệch có thể tái sử dụng cho các nghiên cứu hệ gợi ý khác: dữ liệu đã lọc ghi ra tệp kiểm bằng mã MD5, đặc trưng theo thời điểm, cùng ngân sách tinh chỉnh, mẫu kiểm định độc lập, đăng ký trước, khoá tập kiểm thử kèm nhật ký truy cập, kiểm định cặp có hiệu chỉnh đa so sánh.

1.4.2 Ý nghĩa thực tiễn

- Mô hình chỉ dùng dữ liệu mà một doanh nghiệp bán lẻ sẵn có (lịch sử giao dịch, danh mục sản phẩm, thông tin hội viên, doanh số theo ngày), và mọi đặc trưng được tính theo thời điểm, nên cách huấn luyện và chấm điểm dùng được nguyên như khi triển khai thật.
- Quy trình tiền xử lý tách phần đọc dữ liệu khỏi logic xử lý cốt lõi, đọc tệp theo lô (khoảng 0,5 GB RAM cho tệp 3,5 GB), nên thực nghiệm trên dữ liệu giao dịch lớn khả thi trên máy tính cá nhân và có thể tái sử dụng cho các bộ dữ liệu thương mại điện tử khác.
- Hệ thống demo suy diễn (FastAPI) cho phép so sánh trực quan các mô hình trên từng khách hàng của mẫu kiểm định, và luôn có gợi ý: khách hàng mới nhận danh sách sản phẩm phổ biến.

1.5 Bố cục của báo cáo dự án

Báo cáo dự án được trình bày trong 5 chương chính:

- **Chương 1 – Tổng quan về đề tài:** bối cảnh, tính cấp thiết, mục tiêu, phạm vi, phương pháp nghiên cứu và ý nghĩa của đề tài.
- **Chương 2 – Cơ sở lý thuyết và các công trình liên quan:** hệ thống gợi ý, Nhân tử hóa ma trận, BPR, GMF, MLP, NeuMF, Early/Late Fusion, mô hình lai dựa trên đặc trưng và khởi đầu lạnh, các chỉ số đánh giá, tổng quan các nghiên cứu liên quan và đối chiếu ba nghiên cứu nền tảng.
- **Chương 3 – Phương pháp nghiên cứu và thiết kế mô hình lai NeuMF-F:** quy trình tổng thể, dữ liệu H&M và hai mẫu khách hàng, dữ liệu kiểm chứng Amazon Beauty, giai đoạn đánh giá và tập ứng viên, đặc trưng theo thời điểm, kiến trúc NeuMF-F và các mô hình đối chiếu, lấy mẫu âm, huấn luyện, quy trình đánh giá không thiên lệch, suy diễn Top-K và xử lý khách hàng mới, thiết kế hệ thống demo; các bước chính được trình bày bằng mã giả.
- **Chương 4 – Thực nghiệm và đánh giá kết quả:** kết quả tinh chỉnh trên mẫu phát triển, kết quả đánh giá cuối trên mẫu kiểm định (ở $K = 5, 10, 15, 20$), kiểm định thống kê, ablation, độ phủ, kiểm chứng trên Amazon Beauty, lịch sử phát triển và thảo luận.
- **Chương 5 – Kết luận và hướng phát triển:** tổng kết kết quả, hạn chế và

hướng mở rộng.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

Chương này trình bày cơ sở lý thuyết về hệ thống gợi ý, các mô hình được sử dụng trong đề tài và các công trình liên quan. Các công trình được dẫn là cơ sở về phương pháp (định nghĩa mô hình, cách huấn luyện, cách đánh giá); thực nghiệm trong các công trình đó dùng dữ liệu và giao thức khác nên số liệu của chúng không được dùng làm chuẩn để so sánh với kết quả của đề tài. Trong chương này, *User* (người dùng) và *Item* (sản phẩm) được dùng như thuật ngữ kỹ thuật theo cách gọi phổ biến trong tài liệu về hệ gợi ý.

2.1 Tổng quan về hệ thống gợi ý (Recommendation System)

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai: lựa chọn của đề tài

Một hệ thống gợi ý có ba hướng tiếp cận chính. **Lọc dựa trên nội dung** (Content-Based) gợi ý những sản phẩm có đặc tính giống các sản phẩm User đã thích, dựa trên mô tả sản phẩm và hồ sơ sở thích của User [4], [20]. **Lọc cộng tác** (Collaborative Filtering – CF) khai thác lịch sử tương tác chung giữa nhiều User và Item: những User từng mua giống nhau có khả năng sẽ mua giống nhau [1], [21]; CF chỉ cần ma trận tương tác User–Item, không đòi hỏi đặc trưng mô tả đối tượng [22]. **Lọc lai** (Hybrid) kết hợp nhiều kỹ thuật – thường gặp nhất là kết hợp nội dung với cộng tác – để bù hạn chế của từng kỹ thuật [9], [10], [23].

Lựa chọn của đề tài được quyết định bởi *đặc điểm của dữ liệu*. Bộ dữ liệu H&M (mục 3.2.1) có lịch sử giao dịch đủ dài để CF học được sở thích của khách mua thường xuyên, nhưng danh mục thời trang thay đổi rất nhanh: một phần đáng kể sản phẩm khách mua trong vài tuần tới là sản phẩm chưa từng được bán (mục 3.2.4). CF thuần dựa trên ID không có thông tin gì về những sản phẩm này, trong khi bộ dữ liệu lại có sẵn thuộc tính, mô tả văn bản của sản phẩm, thông tin khách hàng và doanh số theo thời gian. Vì vậy đề tài chọn hướng **lai**: lõi của mô hình là lọc cộng tác dựa trên mô hình – nhân tử hóa ma trận kết hợp mạng nơ-ron sâu (mục 2.2, 2.3) – được bổ sung đặc trưng nội dung và ngữ cảnh (mục 2.4.1). Các mô hình chỉ dùng ID và một mô hình gợi ý theo nội dung thuần được giữ làm đối chứng, để đo riêng đóng góp của từng nguồn thông tin.

2.1.2 Lọc cộng tác dựa trên bộ nhớ (Memory-based) và dựa trên mô hình (Model-based)

Xét theo cách khai thác dữ liệu tương tác, các phương pháp Lọc cộng tác được chia thành hai nhánh chính, đặt nền móng lý thuyết cho toàn bộ hướng tiếp cận Model-based mà đề tài lựa chọn.

Lọc cộng tác dựa trên bộ nhớ (Memory-based CF) tính toán trực tiếp độ tương đồng giữa các User hoặc Item từ ma trận tương tác thô, không qua bước học tham số trung gian, theo nguyên lý khởi nguồn của hệ thống GroupLens [24]. Với **Item-based CF** [21] – kỹ thuật được Amazon triển khai thành công ở quy mô công nghiệp [5] – độ tương đồng cosine giữa hai sản phẩm i, j được tính theo vector cột tương tác của chúng:

$$\text{sim}(i,j) = \cos(\vec{i},\vec{j}) = \frac{\vec{i}\cdot\vec{j}}{\|\vec{i}\|\,\|\vec{j}\|} \tag{2.1}$$

Với phản hồi ẩn nhị phân, điểm của sản phẩm i cho User u là tổng độ tương đồng giữa i và những sản phẩm u đã mua, chỉ xét k láng giềng gần nhất $\mathcal{N}_k(i)$ của i (ItemKNN):

$$\hat{y}_{ui} = \sum_{j \in \mathcal{N}_k(i) \cap \mathcal{I}_u} \text{sim}(i,j) \tag{2.2}$$

Đối xứng với cách trên, **User-based CF** (UserKNN) tìm k User có lịch sử mua giống u nhất, $\mathcal{N}_k(u)$ – chính là "Top-K người dùng tương đồng" của u – rồi tính điểm mỗi sản phẩm bằng tổng độ tương đồng của những láng giềng đã mua sản phẩm đó:

$$\hat{y}_{ui} = \sum_{v \in \mathcal{N}_k(u)} \text{sim}(u,v)\, y_{vi} \tag{2.3}$$

Trong cài đặt của đề tài, độ tương đồng cosine được tính trên vector mua nhị phân, có thêm hệ số co (shrink) λ ở mẫu số để giảm trọng số của những cặp chỉ có rất ít tương tác chung: $\text{sim}(a,b) = |\mathcal{I}_a \cap \mathcal{I}_b| / (\sqrt{|\mathcal{I}_a|\,|\mathcal{I}_b|} + \lambda)$, với $\mathcal{I}_a$ là tập sản phẩm a đã mua (hoặc tập User đã mua sản phẩm a). Mỗi hàng của ma trận tương đồng chỉ giữ k láng giềng và được lưu dưới dạng ma trận thưa, nên chạy được với khoảng 10.000 sản phẩm; k và λ được chọn trên tập xác thực, và hai mô hình là baseline của đề tài (mục 4.2). Ưu điểm của nhánh này là đơn giản, không cần huấn luyện và dễ diễn giải – có thể chỉ ra cụ thể những User hoặc sản phẩm nào dẫn tới một gợi ý; nhược điểm là ma trận tương đồng đầy đủ tăng bậc hai theo số thực thể ($O(N^2)$) và chất lượng suy giảm khi ma trận tương tác quá thưa.

Lọc cộng tác dựa trên mô hình (Model-based CF) không tính tương đồng

trực tiếp mà học một hàm tham số hóa (Nhân tử hóa ma trận, mạng nơ-ron) để nén thông tin tương tác thành các vector biểu diễn ẩn có số chiều thấp, cho phép tổng quát hóa tốt hơn trên dữ liệu thưa và mở rộng quy mô tuyến tính theo số lượng tương tác thay vì bậc hai theo số Item [1], [22]. Toàn bộ các mô hình MF, GMF, MLP và NeuMF trình bày từ mục 2.2 trở đi thuộc nhánh Model-based, là hướng tiếp cận chính của đề tài.

2.1.3 Vì sao bài toán buộc phải dùng phản hồi ẩn (Implicit Feedback)

Về nguyên tắc, phản hồi của User có thể là phản hồi hiện (Explicit) – điểm số đánh giá trực tiếp như rating 1–5 sao – hoặc phản hồi ẩn (Implicit) – suy ra gián tiếp từ hành vi như lịch sử mua hàng, lượt click [2], [25]. Điểm cần nói rõ ở đây không phải là định nghĩa chung của hai khái niệm này, mà là một ràng buộc thực tế: tệp giao dịch H&M không có bất kỳ cột đánh giá (rating) nào – chỉ có bản ghi giao dịch đã xảy ra. Điều này loại bỏ hoàn toàn khả năng dùng Explicit Feedback, và buộc toàn bộ đề tài phải xây dựng tín hiệu tương tác dưới dạng nhị phân từ chính sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu tồn tại giao dịch giữa User } u \text{ và Item } i \text{ trong dữ liệu} \\ 0, & \text{ngược lại} \end{cases} \tag{2.4}$$

Hệ quả trực tiếp của cách xây dựng nhãn này – $y_{ui} = 1$ chỉ xác nhận *đã mua*, không xác nhận *hài lòng*, và $y_{ui} = 0$ có thể là "chưa từng biết đến sản phẩm" chứ không hẳn "không thích" [2] – là lý do trực tiếp khiến kỹ thuật lấy mẫu âm (Negative Sampling, mục 3.4.1) phải được thiết kế cẩn thận thay vì coi mọi cặp chưa tương tác là nhãn âm chắc chắn đúng.

2.1.4 Độ thưa dữ liệu và khởi đầu lạnh: hai giới hạn định hình thiết kế của đề tài

Hai thách thức kinh điển của Collaborative Filtering trực tiếp định hình thiết kế mô hình và phạm vi thực nghiệm của đề tài (mục 1.2.2):

- **Độ thưa dữ liệu (Data Sparsity):** Số cặp User–Item thực sự có tương tác chỉ chiếm một phần rất nhỏ trong toàn bộ ma trận $M \times N$ [1]. Trên dữ liệu của đề tài (Bảng 3.2, Bảng 3.1), ngay cả sau khi lọc k-core, mật độ chỉ khoảng 0,28% trên mẫu thực nghiệm ($k = 10$), và chỉ 0,03% trên toàn bộ 889.062 người dùng ở quy mô đầy đủ ($k = 5$).
- **Khởi đầu lạnh (Cold-Start):** xảy ra khi một User hoặc Item chưa có lịch

sử tương tác, khiến mô hình CF không có dữ liệu để học vector biểu diễn cho đối tượng đó [6]. Đề tài phân biệt hai trường hợp. *Khởi đầu lạnh của người dùng* nằm ngoài phạm vi đánh giá định lượng: mọi khách được đánh giá đều có lịch sử mua trước mốc dự đoán (sau lọc k-core, mục 3.2.3); khi hệ thống được sử dụng, khách mới chưa có lịch sử được gợi ý các sản phẩm phổ biến, và chỉ khi khách đã có lịch sử mua mới dùng mô hình đề xuất (mục 3.7). *Khởi đầu lạnh của sản phẩm* cũng nằm ngoài phạm vi đánh giá cuối: theo thiết kế cuối của giao thức, tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện trước mốc dự đoán (mục 3.2.4). Dù vậy, độ thưa vẫn khiến nhiều sản phẩm và khách hàng chỉ có ít tương tác, nên vector ID của chúng được học từ rất ít dữ liệu – lý do đề tài bổ sung đặc trưng nội dung và ngữ cảnh (mục 2.4.1, 3.3).

2.2 Cơ sở lý thuyết về Lọc cộng tác và Nhân tử hóa ma trận

2.2.1 Mô hình Nhân tử hóa ma trận (Matrix Factorization – MF)

Nhân tử hóa ma trận (MF) chiếu cả User và Item vào một không gian đặc trưng ẩn chung có số chiều $d \ll \min(M, N)$ [1]. Mỗi User u được biểu diễn bởi vector $p_u \in \mathbb{R}^d$ và mỗi Item i bởi vector $q_i \in \mathbb{R}^d$. Mức độ tương tác dự đoán $\hat{y}_{ui}$ được tính bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{2.5}$$

Các kỹ thuật MF khác nhau ở cách học hai ma trận nhân tử P và Q. Phân rã giá trị kỳ dị (Singular Value Decomposition – SVD) cổ điển phân rã một ma trận *đầy đủ*, nên không áp dụng trực tiếp được cho ma trận tương tác cực thưa, nơi phần lớn ô chưa được quan sát; các biến thể dùng trong hệ gợi ý thay vào đó tối ưu sai số trên các ô đã biết kèm điều chuẩn [1]. Với phản hồi ẩn, Bình phương tối thiểu luân phiên (Alternating Least Squares – ALS) dạng iALS [26] coi mọi ô là quan sát với độ tin cậy khác nhau và luân phiên giải bài toán bình phương tối thiểu cho P khi cố định Q rồi ngược lại; còn BPR (mục 2.2.3) tối ưu trực tiếp thứ hạng theo cặp. Đề tài dùng BPR-MF làm baseline MF chính; iALS [27] chỉ được thử trong giai đoạn phát triển (mục 4.6).

2.2.2 Hạn chế của tích vô hướng trong mô hình hóa tương tác

Tích vô hướng kết hợp các chiều đặc trưng ẩn độc lập theo dạng tuyến tính. He và cộng sự [2] lập luận rằng vì vậy phép toán này không học được các tương tác phức tạp, phi tuyến giữa các chiều đặc trưng của User và Item, và không đủ linh hoạt để biểu diễn chính xác quan hệ tương đồng giữa các User trong không gian ẩn. Lập luận này là động cơ lý thuyết của kiến trúc NCF (mục 2.3); việc bổ sung thành phần phi tuyến có thực sự cải thiện chất lượng gợi ý hay không phụ thuộc vào dữ liệu, và được đề tài kiểm tra bằng thực nghiệm trên dữ liệu H&M (Chương 4).

2.2.3 Tối ưu hóa xếp hạng theo cặp: Bayesian Personalized Ranking (BPR)

Khác với cách tiếp cận Pointwise (dự đoán độc lập từng điểm $\hat{y}_{ui}$ rồi so khớp với nhãn nhị phân như MF/GMF/MLP), Bayesian Personalized Ranking (BPR) [25] tối ưu hóa trực tiếp *thứ hạng tương đối* theo cặp (Pairwise Ranking), xuất phát từ giả định người dùng luôn ưa thích sản phẩm đã tương tác i hơn sản phẩm chưa tương tác j. Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR cực đại hóa xác suất hậu nghiệm dưới dạng:

$$\mathcal{L}_{BPR} = -\sum_{(u,i,j)\in\mathcal{D}_S} \ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) + \lambda_\Theta \|\Theta\|^2 \tag{2.6}$$

trong đó $\hat{y}_{ui}, \hat{y}_{uj}$ được tính theo Công thức (2.5) khi kết hợp với MF (tạo thành baseline BPR-MF dùng trong Chương 4), và $\mathcal{D}_S$ là tập các bộ ba lấy mẫu. So với hàm tổn thất Binary Cross-Entropy theo hướng Pointwise được NeuMF sử dụng (Công thức (2.16)), mục tiêu Pairwise của BPR bám sát hơn với bản chất bài toán xếp hạng Top-K nhưng không tận dụng được các tầng phi tuyến sâu như kiến trúc NCF.

2.3 Kiến trúc Mạng khuyến nghị thần kinh (Neural Collaborative Filtering – NCF)

2.3.1 Generalized Matrix Factorization (GMF)

Generalized Matrix Factorization (GMF) là sự mở rộng của MF dưới dạng biểu diễn mạng nơ-ron [2], thực hiện phép nhân Element-wise (Hadamard product $\odot$) giữa vector Embedding của User p_u^G và Item q_i^G:

$$\phi^{GMF} = p_u^G \odot q_i^G \tag{2.7}$$

$$\hat{y}_{ui}^{GMF} = \sigma\left(h^T \phi^{GMF}\right) = \sigma\left(h^T (p_u^G \odot q_i^G)\right) \tag{2.8}$$

trong đó $\odot$ là phép nhân từng phần tử, h là vector trọng số lớp đầu ra, và $\sigma(x) = \frac{1}{1+e^{-x}}$ là hàm kích hoạt Sigmoid.

2.3.2 Multi-Layer Perceptron (MLP)

Nhánh Multi-Layer Perceptron (MLP) nối vector Embedding p_u^M và q_i^M (Concatenation) làm đầu vào cho chuỗi các lớp mạng liên tiếp [2]:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \tag{2.9}$$

$$\phi_L^{MLP} = a_L \left(W_L^T \phi_{L-1}^{MLP} + b_L \right) \tag{2.10}$$

trong đó W_L, b_L, a_L lần lượt là trọng số, độ lệch (bias) và hàm kích hoạt phi tuyến (như ReLU) tại lớp thứ L. Cấu trúc này giúp mô hình học các tương tác phi tuyến tính phức tạp giữa đặc trưng của User và Item.

2.3.3 Kiến trúc mô hình lai NeuMF

Mô hình lai NeuMF kết hợp song song hai luồng biểu diễn tuyến tính (GMF) và phi tuyến (MLP) trước lớp dự đoán cuối cùng [2]:

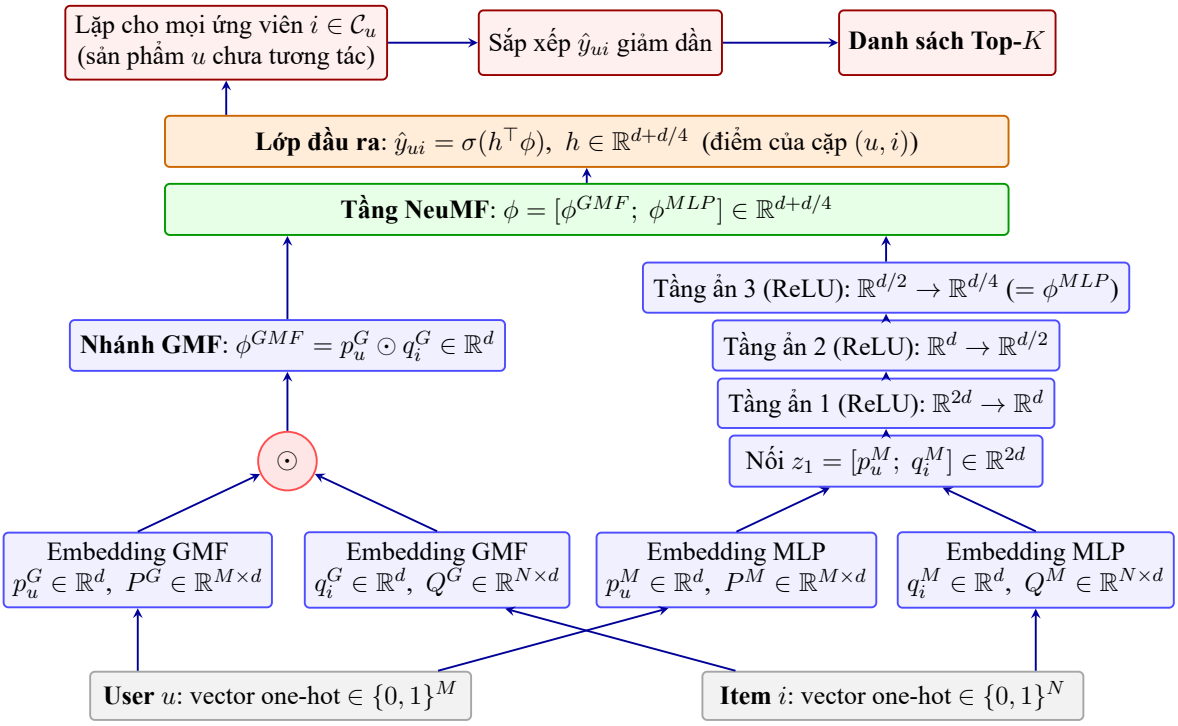
$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \tag{2.11}$$

$$\hat{y}_{ui} = \sigma \left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \right) \tag{2.12}$$

Chữ "lai" trong tên đề tài trước hết chỉ việc kết hợp hai cách mô hình hóa tương tác – nhân tử hóa ma trận (tuyến tính) và mạng nơ-ron sâu (phi tuyến) – trong cùng một mô hình, đúng như NeuMF được He và cộng sự [2] xây dựng bằng cách hợp nhất GMF với MLP. Theo phân loại cách hợp nhất ở mục 2.3.4, NeuMF là một mô hình Early Fusion ở mức biểu diễn. Mô hình đề xuất NeuMF-F (mục 3.3) giữ đúng cấu trúc này và bổ sung đặc trưng nội dung của sản phẩm, thông tin khách hàng và thời gian vào vector của cả hai nhánh, nên còn là "hệ gợi ý lai" theo nghĩa rộng của Burke [23] – kết hợp lọc cộng tác với thông tin nội dung.

2.3.4 Chiến lược hợp nhất: Early Fusion và Late Fusion

Khi một hệ gợi ý kết hợp nhiều nguồn thông tin hoặc nhiều góc nhìn (view) về người dùng và sản phẩm, có hai cách hợp nhất cơ bản, phân biệt theo *mức* diễn ra phép hợp nhất [11], [28], [29]:



Hình 2.1: Kiến trúc mô hình lai Neural Matrix Factorization (NeuMF) với kích thước của từng ma trận và từng tầng, từ đầu vào đến danh sách Top-K (M người dùng, N sản phẩm, d chiều Embedding; trong cài đặt của đề tài hai nhánh dùng cùng d và tháp MLP giảm một nửa qua mỗi tầng)

– **Early Fusion (hợp nhất ở mức đặc trưng/biểu diễn):** các vector đặc trưng $v_1, \ldots, v_m$ của từng view được nối thành một biểu diễn chung, rồi *một* mô hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h\big([v_1;\ v_2;\ \ldots;\ v_m]\big) \tag{2.13}$$

– **Late Fusion (hợp nhất ở mức quyết định/điểm dự đoán):** mỗi view được xử lý bởi một mô hình riêng h_j cho ra dự đoán độc lập, rồi các dự đoán được kết hợp bằng một cơ chế F – lấy trung bình, bỏ phiếu, trọng số cố định hoặc một mô hình học:

$$p = F\big(h_1(v_1),\ h_2(v_2),\ \ldots,\ h_m(v_m)\big) \tag{2.14}$$

Khi F là tổng có trọng số, đây chính là kiểu lai *weighted* trong phân loại hệ gợi ý lai của Burke [23].

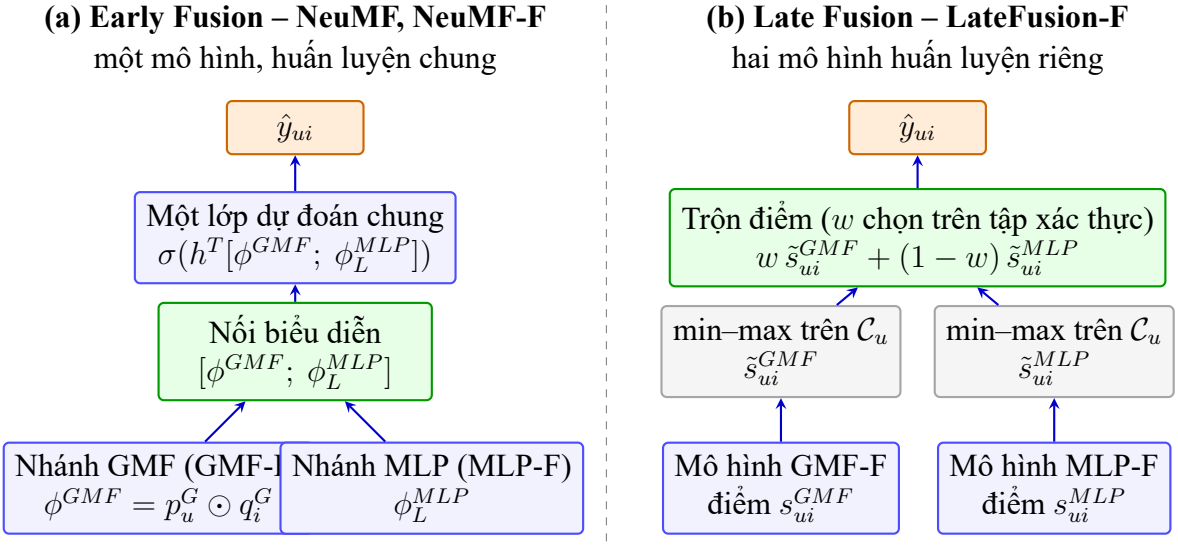
Ngoài hai cách trên còn có *hybrid fusion*, kết hợp cả mức đặc trưng lẫn mức quyết định [28]. Early Fusion học được tương tác giữa các view nhưng đòi hỏi một mô hình phù hợp với mọi view; Late Fusion linh hoạt hơn nhưng không nắm bắt được tương

tác ở mức tín hiệu giữa các view, vì chỉ làm việc trên kết quả dự đoán [11].

Vị trí của các mô hình trong đề tài. Hai view chính ở đây là hai cách mô hình hóa tương tác: view tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và view phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi đưa qua một lớp dự đoán chung (công thức (2.11)–(2.12)), nên là một mô hình **Early Fusion ở mức biểu diễn**, được huấn luyện chung từ đầu đến cuối (Hình 2.2a). Mô hình đề xuất NeuMF-F giữ nguyên cách hợp nhất này với hai nhánh có đặc trưng GMF-F và MLP-F; thêm vào đó, đặc trưng nội dung và ngữ cảnh được cộng vào vector của từng nhánh ngay ở đầu vào, tức cũng được hợp nhất sớm với thông tin cộng tác (mục 3.3.1). Late Fusion tương ứng là trộn điểm của hai mô hình MF và DNN được huấn luyện *riêng*:

$$\hat{y}_{ui} = w\,\tilde{s}_{ui}^{MF} + (1-w)\,\tilde{s}_{ui}^{DNN}, \qquad \tilde{s}_{ui} = \frac{s_{ui} - \min_{j\in\mathcal{C}_u} s_{uj}}{\max_{j\in\mathcal{C}_u} s_{uj} - \min_{j\in\mathcal{C}_u} s_{uj}} \tag{2.15}$$

trong đó điểm s_{ui} của từng mô hình được chuẩn hóa min–max trên tập ứng viên $\mathcal{C}_u$ của User u để hai thang điểm so sánh được, và $w \in [0,1]$ được chọn trên tập xác thực ($w=1$ và $w=0$ cho đúng thứ hạng của từng thành phần). Để so sánh công bằng với NeuMF-F, đề tài dùng chính hai thành phần của nó – **LateFusion-F** trộn điểm của GMF-F và MLP-F được huấn luyện riêng (Hình 2.2b); so sánh hai cách hợp nhất này là một câu hỏi của họ kiểm định (mục 3.6). Riêng nhánh MLP khi đứng một mình chỉ nối vector User và Item ở đầu vào: đó là mô hình DNN thuần, không phải phép hợp nhất MF với DNN (mục 3.3.5).



Hình 2.2: Hai cách hợp nhất cùng hai thành phần MF (GMF) và DNN (MLP): ở mức biểu diễn (NeuMF, NeuMF-F) và ở mức điểm dự đoán (Late Fusion, LateFusion-F)

2.3.5 Lấy mẫu âm (Negative Sampling) và hàm tổn thất Binary Cross-Entropy

Do dữ liệu phản hồi ẩn chỉ cung cấp các tương tác dương ($y_{ui} = 1$), kỹ thuật lấy mẫu âm (Negative Sampling) chọn ngẫu nhiên các Item mà User chưa từng tương tác để gán nhãn âm ($y_{ui} = 0$); đây là cách làm được He và cộng sự sử dụng khi huấn luyện NCF [2].

Hàm tổn thất Binary Cross-Entropy (BCE) được áp dụng để tối ưu hóa toàn bộ tham số mô hình:

$$\mathcal{L}_{BCE} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui}\log\hat{y}_{ui} + (1-y_{ui})\log(1-\hat{y}_{ui})] \tag{2.16}$$

trong đó $\mathcal{Y}$ là tập tương tác dương và $\mathcal{Y}^-$ là tập cặp âm được lấy mẫu.

2.4 Xu hướng nghiên cứu hiện đại trong hệ thống gợi ý học sâu

Sau NCF/NeuMF [2], lĩnh vực hệ gợi ý phát triển theo nhiều hướng song song. Mục này chỉ điểm qua những hướng liên quan trực tiếp tới vị trí của đề tài (mục 2.7) và tới các hướng phát triển (Chương 5); các khảo sát của Zhang và cộng sự [30] và Li và cộng sự [31] hệ thống hóa đầy đủ hơn.

2.4.1 Mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm

Một nhánh phát triển trực tiếp của ý tưởng "lai tuyến tính – phi tuyến" là các mô hình dùng nhiều đặc trưng hơn cặp mã User–Item, xuất phát từ bài toán dự đoán tỷ lệ nhấp chuột (Click-Through Rate – CTR). Factorization Machines (FM) [15] tổng quát hóa MF cho vector đặc trưng bất kỳ: mỗi đặc trưng có một vector ẩn, và tương tác bậc hai giữa hai đặc trưng được mô hình hóa bằng tích vô hướng của hai vector ẩn đó; khi đặc trưng chỉ gồm mã User và mã Item, FM suy biến đúng về MF. Wide & Deep [9] chạy song song một nhánh tuyến tính (Wide) để ghi nhớ các tổ hợp đặc trưng tường minh và một nhánh MLP (Deep) để khái quát hóa, hai nhánh được huấn luyện chung và cộng ở lớp đầu ra; DeepFM [10] thay nhánh Wide bằng FM, hai nhánh dùng chung Embedding đặc trưng; Deep Interest Network [32] thêm cơ chế Attention trên lịch sử hành vi. Điểm chung của các kiến trúc này – một thành phần tuyến tính kiểu nhân tử hóa và một thành phần phi tuyến kiểu MLP, hợp nhất ở lớp dự đoán và huấn luyện chung – chính là cấu trúc của NeuMF; khác biệt là đầu vào gồm cả đặc trưng chứ không chỉ mã ID. Mô hình đề xuất NeuMF-F (mục 3.3) đi theo hướng này: giữ hai nhánh GMF và MLP của NeuMF, và biểu diễn mỗi User/Item bằng tổng của Embedding ID và một phép chiếu tuyến tính của đặc trưng.

Đặc trưng cũng là cách tiếp cận chuẩn cho **khởi đầu lạnh của sản phẩm**: một sản phẩm mới chưa có tương tác nào nên không có Embedding ID có nghĩa, nhưng vẫn có thuộc tính và mô tả – đủ để đặt nó gần những sản phẩm tương tự đã bán. Schein và cộng sự [6] chỉ ra rằng gợi ý cho đối tượng khởi đầu lạnh đòi hỏi kết hợp thông tin nội dung với dữ liệu cộng tác. DropoutNet [33] đề xuất một kỹ thuật huấn luyện đơn giản cho mô hình nhận cả biểu diễn sở thích lẫn nội dung: khi huấn luyện, phần biểu diễn sở thích (học từ tương tác) của đối tượng bị bỏ ngẫu nhiên, buộc mô hình học cách chấm điểm chỉ từ nội dung – đúng tình huống của đối tượng mới lúc dự đoán. NeuMF-F kế thừa kỹ thuật này dưới dạng một siêu tham số – xác suất bỏ ngẫu nhiên Embedding ID của sản phẩm khi huấn luyện (mục 3.3.1). Vì sản phẩm khởi đầu lạnh không thuộc tập ứng viên của giao thức cuối (mục 3.2.4), trong đề tài kỹ thuật này chỉ đóng vai trò điều chuẩn: buộc mô hình dựa một phần vào đặc trưng thay vì chỉ vào ID.

Đặc trưng văn bản của sản phẩm (tên, mô tả) được biểu diễn theo cách cổ điển của truy hồi thông tin và lọc nội dung [20]: trọng số TF-IDF [34] – từ xuất hiện nhiều trong mô tả của một sản phẩm nhưng hiếm trong toàn danh mục thì có trọng số cao – rồi giảm chiều bằng phân rã giá trị kỳ dị rút gọn, tức phân tích ngữ nghĩa tiềm ẩn (Latent Semantic Analysis) [35], để các mô tả dùng từ khác nhau nhưng cùng chủ đề có vector gần nhau. Cách biểu diễn này không cần dữ liệu tương tác và không cần tài nguyên tính toán lớn như các mô hình ngôn ngữ hiện đại.

2.4.2 Gợi ý theo chuỗi hành vi và Transformer

NeuMF và MF coi lịch sử của User như một *tập hợp không thứ tự*. Gợi ý theo chuỗi mô hình hóa trình tự $(i_1, \ldots, i_t)$ để dự đoán i_{t+1}: GRU4Rec [36] dùng mạng hồi quy có cổng cho phiên duyệt web; SASRec [37] thay hồi quy bằng Self-Attention một chiều; BERT4Rec [38] dùng Transformer hai chiều, huấn luyện bằng cách che ngẫu nhiên một số vị trí trong chuỗi rồi dự đoán lại. Hướng này hợp với dữ liệu có phiên rõ ràng; trên H&M, giao dịch chỉ ghi ngày mua (không có giờ hay mã phiên) và nhiều sản phẩm được mua cùng giỏ trong một ngày nên thứ tự trong ngày không xác định – vì vậy đề tài dùng yếu tố thời gian để chia dữ liệu, để huấn luyện lại trên dữ liệu mới nhất (mục 3.2.4) và làm đặc trưng tổng hợp (doanh số gần đây của sản phẩm, khoảng cách tới lần mua gần nhất của khách, mục 3.2.5), còn mô hình chuỗi là hướng phát triển. Transformer còn được dùng theo cách khác: làm mô hình hợp nhất nhiều view theo kiểu Early Fusion, như trong hướng tích hợp đa nguồn của Hồ Thị Linh [11].

2.4.3 Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)

Ma trận tương tác User–Item có thể xem là một đồ thị hai phía. NGCF [39] lan truyền Embedding qua láng giềng nhiều bước để vector mã hóa cả tín hiệu tương tác bậc cao (*high-order connectivity*); LightGCN [40] bỏ các phép biến đổi và hàm kích hoạt phi tuyến – được chỉ ra là không cần thiết cho CF thuần – và chỉ giữ phép lan truyền tuyến tính:

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|}\sqrt{|\mathcal{N}_i|}} e_i^{(k)}, \qquad e_u^{*} = \sum_{k=0}^{K} \alpha_k \, e_u^{(k)} \tag{2.17}$$

trong đó $\mathcal{N}_u$ là tập Item lân cận của User u trên đồ thị và e_u^* là biểu diễn cuối, tổng hợp có trọng số qua K tầng lan truyền. LightGCN được báo cáo vượt MF và NGCF trên các bộ dữ liệu thưa như Gowalla và Amazon-Book [40]; đây là một hướng phát triển của đề tài (mục 5.3), với điều kiện được đánh giá theo cùng quy trình không thiên lệch.

2.4.4 Mô hình tự mã hóa biến phân (Variational Autoencoder) cho lọc cộng tác

Mult-VAE [41] nhận *toàn bộ* vector mua $x_u \in \{0,1\}^N$ của một User làm đầu vào, mã hóa thành một phân phối ẩn Gauss $q_\phi(z_u \mid x_u)$, rồi giải mã ra phân phối đa thức trên toàn bộ catalog $\pi(z_u) = \text{softmax}(f_\theta(z_u))$. Mô hình được huấn luyện bằng cách cực đại cận dưới biến phân (ELBO), với hệ số β điều chỉnh số hạng KL:

$$\mathcal{L}_\beta(x_u) = \mathbb{E}_{q_\phi(z_u \mid x_u)}\big[\log p_\theta(x_u \mid z_u)\big] - \beta \cdot \mathrm{KL}\big(q_\phi(z_u \mid x_u) \,\big\|\, p(z_u)\big) \tag{2.18}$$

với hàm hợp lý đa thức $\log p_\theta(x_u \mid z_u) = \sum_i x_{ui} \log \pi_i(z_u)$. Khác NeuMF (tính điểm từng cặp (u,i) độc lập và cần lấy mẫu âm), Mult-VAE tính điểm cho cả catalog trong một lượt và dùng toàn bộ sản phẩm chưa mua làm tín hiệu âm, nên hợp tự nhiên với giao thức Full Ranking. Đề tài chưa cài đặt mô hình này; nó là một ứng viên cho nhánh học sâu ở hướng phát triển.

Các hướng mới hơn – học tự giám sát trên đồ thị [42], gợi ý sinh và mô hình ngôn ngữ lớn [43], [44], mô hình khuếch tán [45] – cần tài nguyên tính toán vượt phạm vi của đề tài (máy tính cá nhân), nên chỉ được ghi nhận ở đây. Ở quy mô công nghiệp, kiến trúc hai tháp [46] mã hóa User và Item thành hai vector độc lập để truy hồi bằng tìm kiếm lân cận gần đúng – cũng là lý do mô hình tích vô hướng dễ triển khai hơn MLP khi catalog rất lớn. Khảo sát của Li và cộng sự [31] xác nhận các khối GMF/MLP theo tinh thần NCF vẫn được dùng phổ biến trong các hệ lai hiện đại, dù

không còn là hướng tiên phong.

Trong phạm vi đề tài, kiến trúc hai nhánh của NeuMF – bổ sung đặc trưng thành NeuMF-F – được lựa chọn làm trọng tâm (thay vì các hướng mới hơn kể trên) vì ba lý do cụ thể: *(i) Đặc điểm dữ liệu:* tệp giao dịch H&M chỉ ghi ngày mua, không có phiên để áp dụng trực tiếp mô hình chuỗi (mục 2.4.2), nhưng có thuộc tính và mô tả văn bản của sản phẩm – loại thông tin mà cách biểu diễn "Embedding ID + đặc trưng" khai thác được trực tiếp (mục 2.4.1); ảnh sản phẩm không được dùng vì chi phí tính toán; *(ii) Mục tiêu khoa học:* kiến trúc hai nhánh GMF/MLP tách biệt cho phép bóc tách từng thành phần, so sánh trực tiếp hai cách hợp nhất trên cùng hai thành phần (mục 2.3.4) và so sánh với chính NeuMF chỉ dùng ID để đo riêng đóng góp của đặc trưng – điều khó làm tương đương với các kiến trúc End-to-End phức tạp hơn; *(iii) Hạ tầng tính toán:* thực nghiệm chạy trên máy tính cá nhân với RAM 16 GB (mục 4.1), không đủ cho các mô hình sinh quy mô lớn. Ba lý do này nhất quán với khoảng trống nghiên cứu ở mục 2.7.

2.5 Các chỉ số đánh giá hệ thống gợi ý Top-K

Với mỗi người dùng được đánh giá u, mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\text{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm đúng của u (với giao thức Leave-One-Out $|T_u| = 1$; với giao thức chia theo mốc thời gian chung của đề tài, một người dùng có thể có nhiều sản phẩm đúng) và $\text{hits}_u = |T_u \cap \text{Rec}_K(u)|$. Mọi chỉ số được tính cho từng người dùng rồi lấy trung bình trên tập người dùng được đánh giá $\mathcal{U}_{test}$.

- **Hit Ratio at K (HR@K):** người dùng được tính là "trúng" nếu có ít nhất một sản phẩm đúng trong top-K [2]:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}\left(\text{hits}_u \geq 1\right) \tag{2.19}$$

- **Precision@K và Recall@K:** tỉ lệ gợi ý đúng trong K sản phẩm, và tỉ lệ sản phẩm đúng tìm lại được:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \qquad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \tag{2.20}$$

  Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K = HR@K$/K$ – lý do các chỉ số này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm đúng.

- **Normalized Discounted Cumulative Gain at K (NDCG@K):** thưởng

nhiều hơn khi sản phẩm đúng nằm ở vị trí cao, theo định nghĩa của Järvelin và Kekäläinen [13] với mức liên quan nhị phân:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^{K} \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|,K)} \frac{1}{\log_2(j+1)} \end{aligned} \tag{2.21}$$

IDCG là giá trị DCG khi mọi sản phẩm đúng xếp ở đầu danh sách, nên NDCG@K $\in [0,1]$. Với $|T_u| = 1$ và sản phẩm đúng ở hạng r: NDCG@K $= 1/\log_2(r+1)$ nếu $r \leq K$, ngược lại bằng 0.

Full Ranking và Sampled Ranking. Một số công trình, trong đó có He và cộng sự [2], đánh giá bằng cách xếp sản phẩm đúng giữa một tập nhỏ ứng viên lấy mẫu – với NCF là sản phẩm kiểm thử cùng 100 sản phẩm người dùng chưa tương tác, lấy ngẫu nhiên – gọi là Sampled Ranking. Krichene và Rendle [47] chứng minh chỉ số trên tập ứng viên lấy mẫu không nhất quán với chỉ số trên toàn bộ catalog – có thể đảo ngược kết luận "A tốt hơn B" – và khuyến nghị tránh lấy mẫu. Đề tài vì vậy chỉ dùng **Full Ranking**: xếp hạng toàn bộ tập ứng viên (khoảng 6.710 sản phẩm mỗi người dùng ở tập kiểm thử của mẫu kiểm định) trừ sản phẩm người dùng đã mua. Một phép đối chiếu với Sampled-99 ở giai đoạn phát triển cho thấy thứ hạng giữa các mô hình thay đổi giữa hai giao thức (mục 4.6).

2.5.1 Các chỉ số đánh giá ngoài độ chính xác (Beyond-Accuracy Metrics)

Chỉ tối ưu HR@K/NDCG@K có thể khiến mô hình thiên lệch về việc luôn gợi ý các sản phẩm phổ biến nhất (*popularity bias*), vốn dễ trúng nhưng ít giá trị cá nhân hóa [48]. Để mô tả danh sách gợi ý ngoài độ chính xác, đề tài dùng **độ phủ (Coverage)**: tỉ lệ sản phẩm của không gian ứng viên $\mathcal{I}_{cand}$ xuất hiện trong danh sách gợi ý của ít nhất một người dùng:

$$\text{Coverage@K} = \frac{\left|\bigcup_{u \in \mathcal{U}_{test}} \text{Rec}_K(u)\right|}{|\mathcal{I}_{cand}|} \tag{2.22}$$

Độ phủ thấp cho thấy mô hình chỉ khai thác một phần nhỏ danh mục – trường hợp giới hạn là Most Popular, mọi người dùng nhận gần như cùng một danh sách. Chỉ số này chỉ mang tính mô tả và được trình bày cạnh NDCG@K trong Chương 4.

2.6 Tổng quan các công trình nghiên cứu liên quan

Bảng 2.1 tổng hợp các công trình nền tảng liên quan trực tiếp đến hướng tiếp cận của dự án.

Bảng 2.1: Tổng quan các công trình nghiên cứu liên quan

Tác giả & Năm	**Mô hình / Phương pháp**	**Dữ liệu**	**Đóng góp chính & Hạn chế**
Sarwar et al. (2001) [21]	Item-based CF (ItemKNN)	MovieLens	Gợi ý theo độ tương đồng giữa sản phẩm, tính trước được và dễ diễn giải. *Hạn chế:* ma trận tương đồng tăng bậc hai theo số sản phẩm; chất lượng giảm khi dữ liệu quá thưa.
Rendle et al. (2009) [25]	BPR (Bayesian Personalized Ranking)	MovieLens, Netflix	Khung tối ưu dựa trên so sánh cặp cho implicit feed-back. *Hạn chế:* mô hình tuyến tính.
He et al. (2017) [2]	NCF / NeuMF	MovieLens, Pinterest	Đề xuất khung NCF kết hợp GMF và MLP; báo cáo NeuMF tốt hơn các baseline trên hai bộ dữ liệu của bài. *Hạn chế:* chưa tích hợp đặc trưng nội dung.
Cheng et al. (2016) [9]	Wide & Deep Learning	Google Play Store	Kết hợp ghi nhớ (Wide) và khái quát hóa (Deep). *Hạn chế:* cần kỹ nghệ đặc trưng thủ công.
Guo et al. (2017) [10]	DeepFM	Criteo, Dữ liệu doanh nghiệp	Thay Wide bằng Factoriza-tion Machine. *Hạn chế:* chi phí tính toán tăng khi số đặc trưng lớn.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Volkovs et al. (2017) [33]	DropoutNet	CiteULike, RecSys Challenge 2017	Huấn luyện mô hình nhận cả biểu diễn sở thích và nội dung, bỏ ngẫu nhiên phần sở thích để mô hình chấm được đối tượng khởi đầu lạnh. *Hạn chế:* cần đặc trưng nội dung đủ giàu thông tin.
Kang & McAuley (2018) [37]	SASRec (Self-Attention tuần tự)	Amazon, Steam, MovieLens	Mô hình hóa chuỗi hành vi bằng Self-Attention. *Hạn chế:* cần mốc thời gian/phiên rõ ràng, chưa khai thác được với dữ liệu chỉ ghi ngày mua như H&M.
Wang et al. (2019); He et al. (2020) [39], [40]	NGCF / LightGCN (Graph-based CF)	Gowalla, Amazon-Book, Yelp2018	Lan truyền tín hiệu tương tác bậc cao qua đồ thị hai phía. *Hạn chế:* chi phí tính toán lan truyền tăng theo số tầng, chi phí tăng nhanh theo quy mô đồ thị khi catalog lớn.
Li et al. (2024) [31]	Khảo sát DNN cho Collaborative Filtering	Tổng hợp đa miền (2020–2024)	Hệ thống hóa các kiến trúc MLP, CNN, RNN, GNN, Autoencoder, GAN đã tích hợp vào CF, xác nhận GMF/MLP vẫn là thành phần nền tảng phổ biến. *Hạn chế:* khảo sát tổng hợp, không đề xuất mô hình mới hay thực nghiệm riêng.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Liang et al. (2018) [41]	Mult-VAE (tự mã hóa biến phân)	MovieLens-20M, Netflix, Million Song	Mô hình hóa cả vector mua của User bằng phân phối đa thức, chấm toàn bộ catalog trong một lượt. *Hạn chế:* không dùng thứ tự thời gian; cần đủ lịch sử cho mỗi User.
Hồ Thị Linh (2023) [11]	Tích hợp đa nguồn: Late Fusion (bỏ phiếu, MLP) và Early Fusion Utility Matrix + văn bản (TF-IDF, BERT), Transformer	MovieLens, Amazon	Hệ thống hóa Early/Late Fusion cho hệ gợi ý đa nguồn; Transformer hợp nhất nhiều view cải thiện độ chính xác dự đoán rating. *Khác với đề tài:* bài toán dự đoán rating (MAE/RMSE) có nguồn văn bản; đề tài áp dụng phân loại Early/Late Fusion cho xếp hạng Top-K trên phản hồi ẩn.
Ferrari Dacrema et al. (2019) [8]	Tái lập 18 mô hình gợi ý học sâu	MovieLens, Pinterest, Netflix, …	Phần lớn mô hình học sâu được tái lập không vượt baseline đơn giản được tinh chỉnh tốt (ItemKNN, SLIM); chỉ ra mã nguồn NCF chọn số epoch trên tập kiểm thử. *Hạn chế:* chủ yếu dùng giao thức lấy mẫu của các bài gốc.
Rendle et al. (2020) [7]	MF tích vô hướng so với NeuMF	MovieLens 1M, Pinterest	MF được tinh chỉnh kỹ vượt NeuMF trên chính dữ liệu và giao thức của bài NCF; MLP khó học được tích vô hướng và không phù hợp truy hồi nhanh. *Hạn chế:* vẫn dùng giao thức Leave-One-Out lấy mẫu của bài gốc.

Tác giả & Năm	Mô hình / Phương pháp	Dữ liệu	Đóng góp chính & Hạn chế
Dự án đề xuất (2026)	NeuMF-F: hai nhánh GMF-F, MLP-F (Embedding ID + đặc trưng sản phẩm, khách hàng, thời gian), hợp nhất sớm	H&M Personalized Fashion Recommendations (hai mẫu khách hàng độc lập); kiểm chứng trên Amazon Beauty	Một sản phẩm là một mẫu thiết kế, đặc trưng theo thời điểm; tinh chỉnh trên mẫu phát triển, đánh giá một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước, 5 seed, kiểm định cặp có hiệu chỉnh Holm; so với NeuMF chỉ dùng ID, từng nhánh, Late Fusion của cùng hai nhánh và sáu baseline được tinh chỉnh cùng ngân sách; ablation từng nhóm đặc trưng; chạy lại trên bộ dữ liệu thứ hai với cùng cấu hình.

Các công trình trong Bảng 2.1 dùng dữ liệu, cách chia dữ liệu và giao thức đánh giá khác nhau; bảng chỉ tổng hợp phương pháp và đóng góp để làm cơ sở lựa chọn cách làm cho đề tài, không dùng số liệu của các công trình này làm chuẩn so sánh với kết quả của đề tài.

2.6.1 Ba nghiên cứu nền tảng và đối chiếu thiết lập thực nghiệm

Trong các công trình trên, ba nghiên cứu là nền tảng trực tiếp của đề tài: He và cộng sự [2] đề xuất kiến trúc NeuMF mà NeuMF-F kế thừa; Rendle và cộng sự [7] kiểm tra lại câu hỏi NeuMF có thực sự tốt hơn nhân tử hóa ma trận được tinh chỉnh kỹ hay không – câu hỏi mà đề tài đặt lại trên dữ liệu H&M; và luận án của Hồ Thị Linh [11] hệ thống hóa hai cách hợp nhất Early Fusion, Late Fusion và việc bổ sung nguồn thông tin ngoài ma trận tương tác – khung phân loại mà đề tài dùng để so sánh NeuMF-F với LateFusion-F. Bảng 2.2 đối chiếu thiết lập thực nghiệm của ba nghiên cứu với đề tài; số liệu của mỗi nghiên cứu lấy từ chính bài gốc.

Bảng 2.2: Đối chiếu thiết lập thực nghiệm và kết quả công bố của ba nghiên cứu nền tảng với đề tài

Nghiên cứu	**Dữ liệu; bài toán và độ đo**	**Cách chia; tập ứng viên**	**Kết quả công bố (số liệu của bài gốc)**
He et al. (2017) [2]: NCF, NeuMF	MovieLens 1M (6.040 người dùng, 3.706 phim, 1.000.209 tương tác) và Pinterest (55.187 người dùng, 9.916 sản phẩm, 1.500.809 tương tác), phản hồi ẩn. Xếp hạng Top-K; HR@10, NDCG@10	Leave-one-out: tương tác mới nhất của mỗi người dùng làm kiểm thử. 101 ứng viên: sản phẩm kiểm thử và 100 sản phẩm chưa tương tác lấy ngẫu nhiên	NeuMF có tiền huấn luyện: MovieLens HR@10 = 0,730, NDCG@10 = 0,447 (64 nhân tố); Pinterest HR@10 = 0,880, NDCG@10 = 0,558 (16 nhân tố). Trung bình cao hơn eALS 4,5% và BPR 4,9% (tương đối).
Rendle et al. (2020) [7]: MF so với NeuMF	Như NCF: MovieLens 1M và Pinterest; HR@10, NDCG@10	Như NCF: leave-one-out; 101 ứng viên	MF tích vô hướng tinh chỉnh kỹ: MovieLens 0,7294 / 0,4523, Pinterest 0,8895 / 0,5794 (HR@10 / NDCG@10); NeuMF trong bảng so sánh của bài: 0,7093 / 0,4349 và 0,8777 / 0,5576. MF cao hơn NeuMF 2,8% HR@10 và 4,0% NDCG@10 (MovieLens), 1,3% và 3,9% (Pinterest).

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
Hồ Thị Linh (2023) [11]: tích hợp đa nguồn	MovieLens (77.764 đánh giá, 27.042 người dùng, 8.203 phim); Amazon Electronics (85.065 đánh giá, 1.042 người dùng), Toys and Games (71.780; 5.462), Video Games (98.769; 2.291). Dự đoán điểm đánh giá; RMSE, MAE, Precision	Chia ngẫu nhiên 80% huấn luyện (20% trong đó để xác thực), 20% kiểm thử. Không xếp hạng trên tập ứng viên: dự đoán điểm cho từng cặp của tập kiểm thử	Early Fusion vector MF + đặc trưng văn bản qua DNN (chương 4), Electronics: RMSE 1,01, Precision 82,86% so với SVD 1,16 và 69,55% (RMSE giảm 12,93%, Precision tăng 19,14%). Transformer hợp nhất nhiều view (chương 5), Toys and Games: MAE 0,445, RMSE 0,743, Precision 92,07% so với SVD 0,844 / 1,120 / 68,06%.
Đề tài (2026)	H&M, mẫu kiểm định (7.994 khách, 6.749 sản phẩm, 243.696 cặp) và Amazon Beauty 5-core (10.681 khách, 6.069 sản phẩm, 94.009 cặp), phản hồi ẩn. Xếp hạng Top-K; NDCG@10 (chính), Recall, HR, Precision ở $K = 5, 10, 15, 20$	Theo mốc thời gian chung; mẫu khách hàng độc lập (H&M). Ứng viên: mọi sản phẩm đã có dữ liệu huấn luyện, trừ sản phẩm khách đã mua – trung bình 6.710 (H&M), 6.058 (Amazon)	NeuMF-F so với NeuMF chỉ dùng ID: NDCG@10 +43,8% (H&M) và +65,7% (Amazon), đều có ý nghĩa thống kê. NeuMF chỉ dùng ID so với BPR-MF trên H&M: +4,6%, không khác biệt có ý nghĩa (Chương 4).

Bảng 2.2 cho thấy vì sao các con số không đặt cạnh nhau để so sánh được. Hai bài về NCF xếp sản phẩm đúng giữa 101 ứng viên: HR@10 khoảng 0,7–0,9 nghĩa là với 70–90% người dùng, sản phẩm đúng nằm trong 10 vị trí đầu của một danh sách 101 sản phẩm; đề tài xếp hạng trên khoảng 6–7 nghìn ứng viên, nơi cùng độ đo cho giá trị thấp hơn nhiều; còn luận án giải bài toán dự đoán điểm đánh giá với độ đo sai số (RMSE, MAE), không xếp hạng. Vì vậy chỉ *chiều* và *độ lớn tương đối* của cải thiện so với đối chứng trong chính mỗi nghiên cứu là thông tin đọc được: NeuMF hơn các phương pháp MF của bài gốc vài phần trăm; khi MF được tinh chỉnh kỹ, chính MF

lại hơn NeuMF vài phần trăm; bổ sung nguồn thông tin (văn bản, danh mục) vào mô hình hợp nhất giảm rõ sai số so với SVD. Đề tài kế thừa từ ba nghiên cứu này kiến trúc và cách huấn luyện của NeuMF, yêu cầu tinh chỉnh đầy đủ mô hình đối chứng, và khung Early/Late Fusion cùng ý tưởng bổ sung thông tin ngoài ma trận tương tác; các con số của ba nghiên cứu không được dùng làm chuẩn để đánh giá kết quả của đề tài.

2.7 Khoảng trống nghiên cứu

Các nghiên cứu nền tảng về NCF/NeuMF [2] chủ yếu được đánh giá trên dữ liệu điện ảnh (MovieLens) hoặc mạng xã hội hình ảnh (Pinterest), với tín hiệu tương tác nhị phân và giao thức Leave-One-Out. Các tái đánh giá về sau [7], [8] cho thấy NeuMF chỉ dùng ID khó vượt các baseline đơn giản được tinh chỉnh kỹ. Các mô hình dùng đặc trưng (mục 2.4.1) khai thác được thông tin ngoài mã ID, nhưng thường được đánh giá cho bài toán dự đoán nhấp chuột chứ không phải xếp hạng Top-K trên toàn bộ danh mục. Còn các hướng mới hơn như Graph-based CF [39], [40], Sequential Recommendation [37], [38] hay LLM-based Recommendation [43], [44] đòi hỏi cấu trúc dữ liệu đặc thù hoặc tài nguyên tính toán vượt phạm vi của đề tài.

Khoảng trống mà đề tài tập trung giải quyết vì vậy là: xây dựng một mô hình lai giữ cấu trúc MF + DNN của NeuMF nhưng khai thác được đặc trưng sản phẩm, khách hàng và thời gian (NeuMF-F), rồi đánh giá nó trên dữ liệu giao dịch thời trang thực tế (H&M) theo một giao thức gần với tình huống triển khai – chia dữ liệu theo thời gian, đặc trưng không dùng thông tin tương lai, kết luận lấy trên một mẫu khách hàng chưa từng được dùng để ra quyết định – và tránh các lỗi phương pháp mà Ferrari Dacrema và cộng sự [8] và Rendle và cộng sự [7] đã chỉ ra (chọn mô hình trên tập kiểm thử, baseline tinh chỉnh sơ sài, chỉ số trên tập ứng viên lấy mẫu). Thiết kế đối chứng cho phép tách riêng ba câu hỏi: đặc trưng có giúp mô hình lai không (NeuMF-F so với NeuMF), hợp nhất có giúp so với từng nhánh không (NeuMF-F so với GMF-F, MLP-F), và hợp nhất sớm hay hợp nhất muộn phù hợp hơn (NeuMF-F so với LateFusion-F, theo phân loại của Hồ Thị Linh [11]).

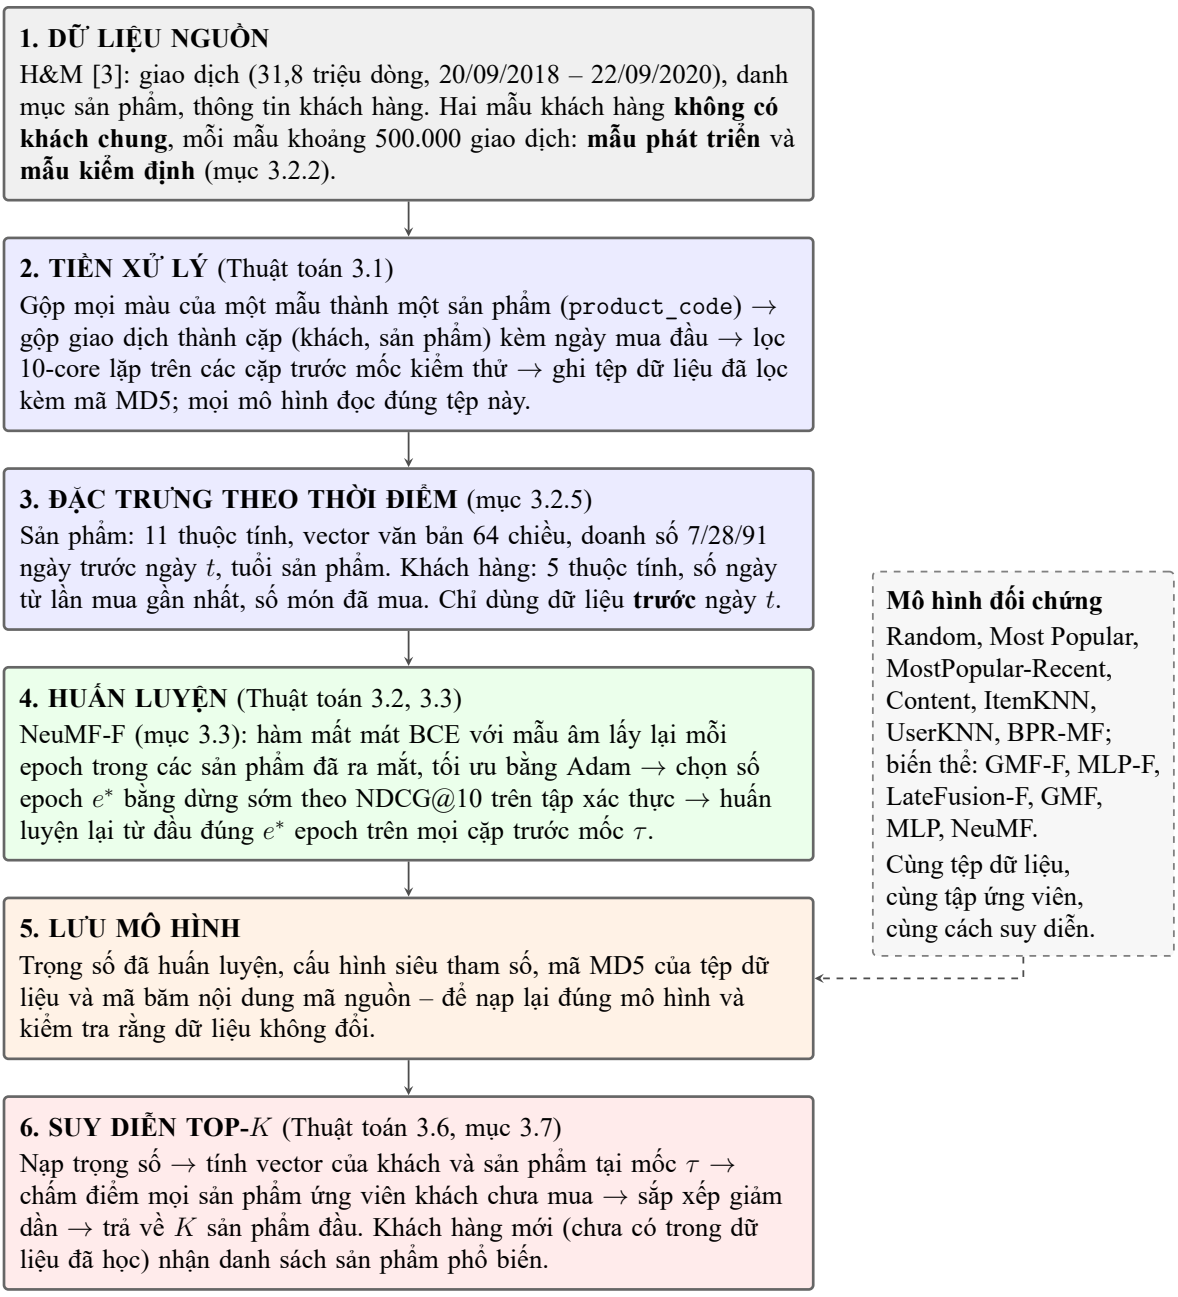
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F

Chương này trình bày phương pháp cho kết quả chính của báo cáo: quy trình tổng thể từ dữ liệu đến gợi ý (mục 3.1), dữ liệu và cách chia giai đoạn – gồm cả bộ dữ liệu kiểm chứng Amazon Beauty (mục 3.2), mô hình đề xuất NeuMF-F kết hợp nhân tử hóa ma trận với mạng nơ-ron sâu và đặc trưng của sản phẩm, khách hàng, thời gian (mục 3.3), cách huấn luyện (mục 3.4, 3.5), quy trình đánh giá không thiên lệch trên một mẫu khách hàng độc lập (mục 3.6), cách suy diễn Top-K và xử lý khách hàng mới (mục 3.7), cùng hệ thống demo (mục 3.8). Các bước xử lý chính được viết thành mã giả (Thuật toán 3.1–3.6). Giai đoạn phát triển trước đó – chỉ dùng mã khách hàng và mã sản phẩm, đánh giá trên chính mẫu phát triển – và bản đầu của kế hoạch đánh giá được tóm tắt như lịch sử phát triển ở mục 4.6; những gì rút ra từ hai giai đoạn này là lý do trực tiếp của các lựa chọn trong chương này.

3.1 Quy trình tổng thể của hệ thống

Hệ thống được tổ chức theo đúng trình tự mà một mô hình gợi ý đi qua khi đưa vào sử dụng (Hình 3.1): xây dựng đặc trưng → huấn luyện → lưu mô hình → suy diễn. Mỗi lần chạy, đường ống nhận một mốc thời gian τ: mọi bước chỉ dùng dữ liệu trước τ, và bước suy diễn trả về danh sách gợi ý cho giai đoạn sau τ – đúng tình huống doanh nghiệp huấn luyện mô hình trên lịch sử đến hôm nay rồi gợi ý cho những tuần tới. Việc đánh giá *không* nằm trong đường ống này mà là một quy trình riêng (mục 3.6, Hình 3.3): quy trình đó gọi lại đường ống với các mốc khác nhau, rồi mới so danh sách gợi ý với những gì khách đã mua thật.

Ba đặc điểm thiết kế xuyên suốt: *(i)* mọi mô hình – NeuMF-F lẫn mô hình đối chứng – dùng đúng một tệp dữ liệu, một tập ứng viên và một quy tắc loại sản phẩm đã mua, nên so sánh là công bằng; *(ii)* mọi lựa chọn mô hình và siêu tham số chỉ dựa trên tập xác thực của mẫu phát triển, còn kết luận chỉ dựa trên tập kiểm thử của mẫu kiểm định – những khách hàng chưa từng được dùng cho bất kỳ quyết định nào (mục 3.6); *(iii)* các mô hình đối chứng được tinh chỉnh với cùng ngân sách như mô hình đề xuất, theo khuyến nghị về phương pháp đánh giá trong [7], [8]: so sánh chỉ công bằng khi mô hình đối chứng được tinh chỉnh đầy đủ như mô hình được đề xuất.



Hình 3.1: Đường ống của hệ thống: đặc trưng → huấn luyện → lưu mô hình → suy diễn Top-K (quy trình đánh giá được trình bày riêng ở Hình 3.3)

3.2 Dữ liệu và tiền xử lý

3.2.1 Đặc tả bộ dữ liệu H&M

Bộ dữ liệu H&M Personalized Fashion Recommendations [3] phản ánh hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn, gồm ba tệp được đề tài sử dụng:

- **`transactions_train.csv`** (3,49 GB): 31.788.324 dòng giao dịch từ 20/09/2018 đến 22/09/2020, của 1.362.281 khách hàng trên 104.547 sản phẩm. Ba trường được dùng: `customer_id` (mã khách, chuỗi băm 64 ký tự), `article_id` (mã sản phẩm, 10 chữ số) và `t_dat` (ngày mua, không có giờ). Giá và kênh bán không được dùng.
- **`articles.csv`**: 105.542 sản phẩm của danh mục, mỗi sản phẩm có các thuộc tính dạng mã (loại sản phẩm, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc) và mô tả văn bản (tên, mô tả chi tiết).
- **`customers.csv`**: 1.371.980 khách hàng với tuổi, trạng thái hội viên, tần suất nhận tin thời trang và hai cờ FN, Active. Mã bưu chính không được dùng. Tệp này có nhiều dòng hơn giới hạn của bảng tính Excel (1.048.576 dòng), nên phải được đọc trực tiếp bằng chương trình; hệ thống kiểm tra số dòng trước khi dùng.

Ảnh sản phẩm có trong bộ dữ liệu nhưng không được dùng làm đầu vào của mô hình; ảnh chỉ được hiển thị trong hệ thống demo (mục 3.8).

Đánh giá Full Ranking (mục 2.5) phải chấm điểm *mọi* sản phẩm ứng viên cho mỗi người dùng được đánh giá, nên chi phí tỉ lệ với tích số người dùng và số sản phẩm. Bảng 3.1 cho thấy ở quy mô đầy đủ, ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm – tức hàng chục tỷ cặp cần tính điểm cho mỗi mô hình, vượt xa khả năng của phần cứng sẵn có (máy tính cá nhân, RAM 16 GB). Vì vậy đề tài thực nghiệm trên các mẫu theo khách hàng (mục 3.2.2).

Bảng 3.1: Độ nhạy k-core trên toàn bộ dữ liệu H&M (31.788.324 dòng, quy mô đầy đủ)

k	**Số người dùng**	**Số sản phẩm**	**Số tương tác**	**Mật độ (%)**
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định

Đề tài lấy mẫu *theo khách hàng* thay vì theo dòng: lấy mẫu theo dòng (hoặc cắt n dòng đầu) sẽ cắt vụn lịch sử của từng khách và – vì tệp gốc sắp theo ngày – chỉ phủ vài ngày giao dịch, làm hỏng cả bước lọc k-core lẫn việc chia dữ liệu theo thời gian. Quy trình gồm hai lượt đọc tệp theo lô (bộ nhớ đỉnh khoảng 0,5 GB):

1. **Lượt 1 – chọn khách:** băm `customer_id` bằng một khoá cố định vào 100.000 nhóm (hàm băm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua) và đếm số giao dịch của từng nhóm.
2. **Lượt 2 – ghi mẫu:** giữ *toàn bộ* giao dịch của các khách được chọn, trải đủ 20/09/2018 – 22/09/2020.

Các mẫu được lấy từ những đoạn nhóm băm liền nhau và không chồng lên nhau (gọi là các *khối*); mỗi khối gồm số nhóm ít nhất để đủ khoảng 500.000 giao dịch:

- **Mẫu phát triển** – khối 0, các nhóm $[0, 1597)$: 500.269 giao dịch của 21.599 khách hàng. Mẫu này được dùng trong toàn bộ giai đoạn phát triển ban đầu và, ở bản cuối của quy trình, chỉ dùng để tinh chỉnh trên tập xác thực.
- **Khối 1** – các nhóm $[1597, 3160)$: 500.125 giao dịch của 21.030 khách hàng. Khối này là mẫu kiểm định của bản đầu kế hoạch đánh giá và đã được mở ở lần đánh giá cuối ngày 04/10/2026, nên không còn dùng để kết luận (mục 4.6).
- **Mẫu kiểm định** – khối 2, các nhóm $[3160, 4734)$: 500.164 giao dịch của 21.351 khách hàng. Vì các đoạn nhóm không chồng nhau, **không có khách hàng nào thuộc cả mẫu phát triển lẫn mẫu kiểm định** (đã kiểm tra trực tiếp). Mẫu kiểm định chỉ dùng cho đánh giá cuối theo bản cuối của kế hoạch.

Vì dựa trên hàm băm với khoá cố định, chạy lại luôn cho đúng cùng các tệp (mã băm MD5 của hai tệp mẫu được ghi trong kế hoạch đăng ký trước, mục 3.6). Lý do cần một mẫu kiểm định riêng: tập kiểm thử của mẫu phát triển đã được xem nhiều lần trong giai đoạn phát triển, và tập kiểm thử của khối 1 đã được mở trước khi kế hoạch được sửa thành bản cuối (mục 4.6), nên cả hai không còn là dữ liệu "chưa từng thấy". Mẫu kiểm định gồm những khách hàng khác hẳn, nên kết quả trên mẫu này ước lượng hiệu năng của mô hình khi gặp khách hàng khác của cùng cửa hàng, trong cùng giai đoạn thời gian.

3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử

Một sản phẩm là một mẫu thiết kế. Mã `article_id` 10 chữ số của H&M gồm mã mẫu thiết kế `product_code` và ba chữ số cuối chỉ biến thể màu, nên cùng một mẫu áo có thể mang nhiều `article_id`. Theo góp ý của giảng viên hướng dẫn, bản cuối của giao thức coi một sản phẩm là một `product_code`: mọi màu của cùng một mẫu được gộp làm một sản phẩm, và khách mua nhiều màu của cùng một mẫu chỉ được tính một cặp (khách, sản phẩm). Trước mốc kiểm thử, việc gộp này giảm số sản phẩm của mẫu phát triển từ 55.971 xuống 27.370 và số cặp (khách, sản phẩm) từ 401.293 xuống 359.181; với mẫu kiểm định là từ 55.683 xuống 27.291 sản phẩm và từ 398.653 xuống 356.740 cặp.

Một khách có thể mua cùng một sản phẩm nhiều lần; các giao dịch lặp được gộp thành một cặp (khách, sản phẩm) duy nhất, giữ lại *ngày mua đầu tiên* t_{ui}, *trước* khi lọc k-core. Nếu lọc trực tiếp trên dòng giao dịch thô, bậc của một khách/sản phẩm bị thổi phồng bởi các lượt mua lặp: trên mẫu phát triển (theo `article_id`, cả hai năm), 500.269 giao dịch gộp lại chỉ còn 429.964 cặp duy nhất.

Lọc k-core được áp dụng lặp đến khi hội tụ (loại một sản phẩm có thể khiến một khách rơi xuống dưới ngưỡng và ngược lại), để mỗi khách và mỗi sản phẩm còn lại có ít nhất k đối tác riêng biệt. Điểm khác với giai đoạn phát triển ban đầu là phép lọc **chỉ dùng các cặp có ngày mua đầu trước mốc kiểm thử** (29/07/2020): việc chọn khách và sản phẩm nào được giữ lại không dùng bất kỳ thông tin nào của giai đoạn kiểm thử. Thuật toán 3.1 tóm tắt toàn bộ bước chuẩn bị dữ liệu. Sau khi lọc với $k = 10$, mẫu phát triển còn 8.039 khách, 6.801 sản phẩm và 245.644 cặp; mẫu kiểm định còn 7.994 khách, 6.749 sản phẩm và 243.696 cặp. Mã khách và mã sản phẩm được đánh lại chỉ số liên tục, và phản hồi ẩn nhị phân $y_{ui} = 1$ khi khách u đã mua sản phẩm i (Công thức (2.4)). Dữ liệu đã lọc của mỗi mẫu được ghi ra một tệp, kèm mã MD5 của nội dung; mọi mô hình đọc cùng tệp này và chương trình kiểm tra mã MD5 trước khi dùng, nên mọi mô hình chắc chắn được huấn luyện và đánh giá trên cùng dữ liệu.

Khi nạp dữ liệu cho một giai đoạn, chương trình kiểm tra lại mã MD5, giữ các khách và sản phẩm có cờ thuộc k-core, rồi lấy dữ liệu huấn luyện và sản phẩm đúng theo các tập ở mục 3.2.4; vì tệp chứa mọi cặp (kể cả sau mốc kiểm thử), tập kiểm thử chỉ được dựng khi chạy đánh giá cuối.

Ngưỡng k được chọn từ khảo sát ở giai đoạn phát triển (Bảng 3.2, tính trên mọi cặp của mẫu phát triển theo `article_id`) và được giữ ở bản cuối. Ngưỡng thường gặp trong tài liệu là $k = 5$, nhưng khi đó danh mục còn 23.067 sản phẩm và đánh giá Full

Thuật toán 3.1 Chuẩn bị dữ liệu: gộp theo mẫu thiết kế và lọc k-core lặp

Đầu vào: giao dịch (c, a, t) của một mẫu (khách c, mã `article_id` a, ngày mua t); mốc kiểm thử τ_{test}; ngưỡng k
Đầu ra: tệp cặp $(c, i, t_{ci}, \textit{thuộc_kcore})$ và mã MD5 của nội dung tệp

với mỗi giao dịch (c, a, t) **làm**
    $i \leftarrow \lfloor a/1000 \rfloor$ ▷ *`product_code`: bỏ 3 chữ số chỉ màu*
gộp các giao dịch theo cặp (c, i), giữ $t_{ci} \leftarrow$ ngày mua sớm nhất ▷ *mỗi cặp một dòng*
$E \leftarrow \{(c, i) : t_{ci} < \tau_{test}\}$ ▷ *chỉ dữ liệu trước mốc kiểm thử*
lặp
    $U \leftarrow \{c : |\{i : (c, i) \in E\}| \geq k\}$; $I \leftarrow \{i : |\{c : (c, i) \in E\}| \geq k\}$
    $E' \leftarrow \{(c, i) \in E : c \in U,\ i \in I\}$; *hội_tụ* $\leftarrow (|E'| = |E|)$; $E \leftarrow E'$
đến khi *hội_tụ*
ghi *mọi* cặp (c, i, t_{ci}) kèm cờ $(c, i) \in E$ ra tệp CSV nén, theo thứ tự cố định
md5 $\leftarrow$ MD5(nội dung tệp) ▷ *ghi vào `manifest.json`*
trả về tệp, *md5*

Ranking ước tính cần khoảng 10,7 GB RAM – vượt giới hạn của máy thực nghiệm (16 GB, đã tính hệ điều hành và dữ liệu huấn luyện). Đề tài vì vậy chọn **k = 10**. Cái giá của lựa chọn này là dữ liệu thiên về khách mua nhiều – được ghi nhận là một hạn chế (mục 5.2).

Bảng 3.2: Độ nhạy của mẫu phát triển theo ngưỡng lọc k-core (khảo sát ở giai đoạn phát triển, theo `article_id`, 429.964 cặp trước khi lọc)

k	**Số người dùng**	**Số sản phẩm**	**Số tương tác**	**Mật độ (%)**
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	**7.519**	**10.345**	**220.292**	**0,283**
15	3.017	3.186	83.088	0,864

3.2.4 Giai đoạn đánh giá và tập ứng viên

Dữ liệu được chia theo thời gian bằng hai mốc cố định chung cho mọi khách hàng: mốc xác thực τ_{val} = 01/07/2020 (cửa sổ xác thực 01/07 – 28/07/2020, 4 tuần) và mốc kiểm thử τ_{test} = 29/07/2020 (cửa sổ kiểm thử 29/07 – 22/09/2020, 8 tuần). Với

mỗi mốc τ (gọi là một *giai đoạn*), các tập sau được định nghĩa:

$$\mathcal{D}_\tau = \{(u,i) \text{ đã lọc } k\text{-core} : t_{ui} < \tau\} \quad \text{(dữ liệu huấn luyện)} \tag{3.1}$$

$$\mathcal{I}_\tau = \{i : \exists u,\ (u,i) \in \mathcal{D}_\tau\} \quad \text{(sản phẩm có dữ liệu huấn luyện)} \tag{3.2}$$

$$\mathcal{C}_u(\tau) = \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau) \quad \text{(tập ứng viên của khách } u) \tag{3.3}$$

$$T_u(\tau) = \{i \in \mathcal{C}_u(\tau) : \tau \le t_{ui} < \tau_{end}\} \quad \text{(sản phẩm đúng của } u) \tag{3.4}$$

trong đó $\mathcal{I}_u(\tau)$ là các sản phẩm u đã mua trước τ, và τ_{end} là cuối cửa sổ của giai đoạn. Chỉ những khách có dữ liệu huấn luyện trong $\mathcal{D}_\tau$ và có ít nhất một sản phẩm đúng mới được đánh giá. Hai điểm cần giải thích:

- **Chỉ sản phẩm đã có dữ liệu huấn luyện.** Sản phẩm chưa có cặp nào trong dữ liệu huấn luyện của giai đoạn – trong đó có sản phẩm vừa ra mắt – không thuộc tập ứng viên lẫn tập sản phẩm đúng. Đây là thay đổi của bản cuối kế hoạch đánh giá, theo góp ý của giảng viên hướng dẫn (bản đầu của kế hoạch giữ sản phẩm mới trong tập ứng viên, mục 4.6). Với tập ứng viên này, mọi mô hình – kể cả mô hình chỉ dùng ID – đều chấm được mọi ứng viên, nên so sánh giữa các mô hình không phụ thuộc vào khả năng xử lý sản phẩm chưa có lịch sử bán; đổi lại, kết quả không nói về khả năng gợi ý sản phẩm vừa ra mắt (mục 4.7).
- **Huấn luyện lại trên dữ liệu mới nhất.** Ở giai đoạn kiểm thử, $\mathcal{D}_{\tau_{test}}$ gồm cả cửa sổ xác thực, tức "tập huấn luyện ∪ xác thực". Tập xác thực chỉ dùng để chọn cấu hình và số epoch; trước khi đánh giá trên tập kiểm thử, mô hình được huấn luyện lại từ đầu trên $\mathcal{D}_{\tau_{test}}$ (mục 3.6), nên khi dự đoán, mô hình đã thấy toàn bộ quá khứ như lúc triển khai thật.

Vì sao không chia theo Leave-One-Out. Cách chia của He và cộng sự [2] lấy sản phẩm mua cuối cùng của từng người dùng làm tập kiểm thử, phần còn lại làm tập huấn luyện. Cách này để lọt thông tin tương lai: tập huấn luyện chứa tương tác của những người dùng khác xảy ra *sau* thời điểm cần dự đoán [49]. Đo trên mẫu phát triển ở giai đoạn phát triển, tính trung bình theo người dùng, 11,2% tương tác trong tập huấn luyện xảy ra sau ngày mua sản phẩm kiểm thử của người dùng đó; ngoài ra 60,9% người dùng có sản phẩm xác thực và sản phẩm kiểm thử mua cùng một ngày. Vì vậy đề tài chia theo mốc thời gian chung cho mọi người dùng.

Theo định nghĩa, mỗi cặp (khách, sản phẩm) chỉ có một ngày mua đầu, nên một cặp không thể vừa là dữ liệu huấn luyện vừa là sản phẩm đúng của cùng giai đoạn,

và sản phẩm khách đã mua trước mốc không bao giờ là sản phẩm đúng – mô hình dự đoán những món *mới đối với khách*. Các điều kiện này, cùng việc lọc k-core chỉ dùng dữ liệu trước mốc kiểm thử, được kiểm chứng bằng bộ kiểm thử tự động. Bảng 3.3 tổng hợp quy mô dữ liệu của hai mẫu.

Bảng 3.3: Quy mô dữ liệu H&M: mẫu phát triển (chỉ dùng tập xác thực) và mẫu kiểm định (khách hàng khác hẳn mẫu phát triển)

	Mẫu phát triển	Mẫu kiểm định
Người dùng sau lọc 10-core	8.039	7.994
Sản phẩm (product_code) sau lọc 10-core	6.801	6.749
Cặp (khách, sản phẩm) trước mốc kiểm thử	245.644	243.696
Xác thực: cặp huấn luyện (trước 01/07/2020)	236.845	234.610
Xác thực: người dùng được đánh giá	2.569	2.579
Xác thực: cặp đúng	8.636	8.985
Kiểm thử: người dùng được đánh giá	—	3.165
Kiểm thử: cặp đúng	—	10.285
Kiểm thử: số ứng viên trung bình mỗi người dùng	—	6.710

Một sản phẩm = một product_code (gộp mọi màu). Lọc 10-core chỉ trên các cặp trước mốc kiểm thử 29/07/2020. Ứng viên và cặp đúng chỉ gồm sản phẩm đã có cặp huấn luyện trước mốc của giai đoạn. Tập kiểm thử của mẫu phát triển không được dựng.

3.2.5 Xây dựng đặc trưng theo thời điểm

Bảng 3.4 liệt kê các đặc trưng mà mô hình có đặc trưng sử dụng. Nguyên tắc bắt buộc là **không dùng thông tin tương lai**: đặc trưng của một cặp (khách u, sản phẩm i) tại ngày t chỉ được tính từ dữ liệu trước ngày t. Khi huấn luyện, mỗi cặp dương mang chính ngày mua đầu t_{ui} của nó; khi đánh giá, t là mốc τ của giai đoạn.

Đặc trưng thời gian của sản phẩm. Gọi $n_{i,d}$ là số giao dịch của sản phẩm i trong ngày d trên toàn bộ H&M và d_i^0 là ngày bán đầu tiên. Tại ngày t:

$$
\begin{aligned}
s_i^{(w)}(t) &= \sum_{d=t-w}^{t-1} n_{i,d}, \\
x_i^{tg}(t) &= \left[\tfrac{\log(1+s_i^{(7)})}{10},\ \tfrac{\log(1+s_i^{(28)})}{10},\ \tfrac{\log(1+s_i^{(91)})}{10},\ \tfrac{\log(1+\max(0,\,t-d_i^0))}{10},\ \mathbb{I}(d_i^0 \geq t) \right]
\end{aligned}
\tag{3.5}
$$

Tổng chỉ chạy tới ngày $t-1$, nên doanh số của chính ngày t không được dùng. Phép $\log(1+x)$ nén các sản phẩm bán rất chạy, hệ số $1/10$ đưa đặc trưng về cỡ $[0,1]$. Doanh số lấy trên toàn bộ giao dịch H&M chứ không chỉ trong mẫu – đây là dữ liệu mà doanh nghiệp có tại thời điểm dự đoán, và phản ánh xu hướng bán gần đây của sản phẩm

Bảng 3.4: Đặc trưng của mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F)

Nhóm	**Đặc trưng**	**Mã hóa**	**Nguồn**
Sản phẩm – thuộc tính	11 thuộc tính danh mục (loại, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc); sau khi gộp theo mẫu, ba thuộc tính màu là hằng số	Embedding 8 chiều mỗi thuộc tính (88 chiều), học cùng mô hình	`articles.csv`
Sản phẩm – văn bản	Tên và mô tả chi tiết	TF-IDF (từ đơn và cặp từ) $\rightarrow$ SVD 64 chiều $\rightarrow$ chuẩn hóa L2	`articles.csv`
Sản phẩm – thời gian tại t	Doanh số trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ "chưa từng bán trước t"	$\log(1+x)/10$; cờ 0/1 (5 chiều)	Giao dịch toàn H&M
Khách hàng – tĩnh	Nhóm tuổi (9 mức, gồm "không rõ"), trạng thái hội viên, tần suất nhận tin, FN, Active	Embedding 8 chiều mỗi thuộc tính (40 chiều)	`customers.csv`
Khách hàng – thời gian tại t	Số ngày từ lần mua gần nhất (tối đa 730); số cặp đã mua	$\log(1+x)/10$ (2 chiều)	Dữ liệu huấn luyện

trên toàn cửa hàng.

Đặc trưng văn bản. Tên và mô tả của mỗi sản phẩm được biểu diễn bằng TF-IDF [34] trên từ đơn và cặp từ (bỏ từ dừng tiếng Anh, giữ tối đa 30.000 mục từ xuất hiện ở ít nhất 3 sản phẩm, tần suất từ theo thang logarit), rồi giảm còn 64 chiều bằng phân rã SVD rút gọn – tức phân tích ngữ nghĩa tiềm ẩn [35] – và chuẩn hóa về độ dài 1. Phép biến đổi này được khớp trên toàn bộ danh mục và không dùng dữ liệu mua hàng.

Gộp đặc trưng theo mẫu thiết kế. Đặc trưng ban đầu được tính cho từng `article_id`; vì một sản phẩm là một `product_code` (mục 3.2.3), đặc trưng của các biến thể màu được gộp lại: thuộc tính danh mục lấy theo biến thể có `article_id` nhỏ nhất, ba thuộc tính màu (nhóm màu, độ đậm màu, màu chủ đạo) đặt về một giá trị hằng vì không còn mô tả một màu cụ thể, vector văn bản là trung bình các biến thể rồi chuẩn hóa lại về độ dài 1, doanh số theo ngày là tổng các biến thể, và ngày bán đầu tiên là ngày sớm nhất của các biến thể.

Đặc trưng của khách hàng. Thuộc tính tĩnh lấy từ `customers.csv`; tệp này không có mốc thời gian nên thuộc tính được coi là ít thay đổi (một hạn chế được ghi nhận, mục 5.2). Đặc trưng thời gian của khách tại ngày t chỉ dùng các cặp có ngày mua đầu *trước* t: khoảng cách tới lần mua gần nhất và số cặp đã mua.

Bộ kiểm thử tự động xác nhận rằng đặc trưng thời gian của sản phẩm tại ngày t không thay đổi khi thêm giao dịch của ngày t trở về sau, và đặc trưng của khách tại ngày t chỉ đếm các cặp trước t.

3.2.6 Dữ liệu kiểm chứng Amazon Beauty

Để xem các kết luận rút ra từ H&M có còn đúng trên một bộ dữ liệu khác hay không, toàn bộ quy trình được chạy lại trên **Amazon Beauty** – danh mục Làm đẹp của bộ dữ liệu đánh giá sản phẩm Amazon năm 2014 [14], bản 5-core: 198.502 đánh giá của 22.363 khách cho 12.101 sản phẩm, từ 12/06/2002 đến 23/07/2014. Kế hoạch kiểm chứng được đăng ký trước khi chạy bất kỳ mô hình nào trên bộ này và trước khi mở tập kiểm thử của nó. Mã nguồn, 14 mô hình, số seed, độ đo, họ 10 so sánh và tiêu chí kết luận giữ nguyên như H&M; chỉ những điểm sau thay đổi theo dữ liệu:

- **Tương tác:** mỗi đánh giá được coi là một tương tác ẩn giữa khách và sản phẩm (như một lượt mua của H&M), không dùng số sao. Một sản phẩm là một mã `asin`, không gộp biến thể.

- **Chia theo thời gian:** chọn số epoch bằng các cặp trước 01/10/2013 và tập xác thực 01/10 – 31/12/2013; huấn luyện lại trên mọi cặp trước 01/01/2014; tập kiểm thử 01/01 – 23/07/2014 (tỉ lệ độ dài xác thực : kiểm thử khoảng 1 : 2 như H&M). Vì chỉ có một bộ dữ liệu, Amazon *không có mẫu khách hàng độc lập* như H&M: bước chọn số epoch và bước đánh giá cuối khác nhau theo thời gian chứ không theo khách hàng.
- **Lọc 5-core** chỉ trên các cặp trước mốc kiểm thử – bằng ngưỡng của bản 5-core gốc; H&M dùng $k = 10$ nhưng dữ liệu Amazon thưa hơn nhiều.
- **Không tinh chỉnh lại:** mọi mô hình dùng đúng cấu hình đã chọn trên tập xác thực của mẫu phát triển H&M (Bảng 4.1); thứ duy nhất được chọn trên dữ liệu Amazon là số epoch của các mạng nơ-ron, theo đúng Thuật toán 3.3. Hệ quả: mô hình nào có cấu hình của H&M không hợp với Amazon sẽ chịu thiệt – và không tách được phần thiệt đó khỏi bản thân mô hình (mục 4.5).
- **Đặc trưng** thay theo những gì bộ dữ liệu có (Bảng 3.5). Amazon không có thông tin khách hàng, nên nhánh khách của NeuMF-F chỉ còn hai đặc trưng thời gian; doanh số được thay bằng số đánh giá, đếm trên chính tệp 5-core.

Bảng 3.6 cho quy mô dữ liệu Amazon sau khi lọc. Ba hạn chế được ghi nhận từ lúc đăng ký: đánh giá không đồng nghĩa với mua; đặc trưng thời gian của sản phẩm chỉ đếm trên tệp 5-core chứ không trên toàn bộ đánh giá của Amazon; và *nhóm giá là giá tại thời điểm thu thập dữ liệu* (năm 2014), không phải giá tại ngày của từng đánh giá – tương tự thuộc tính khách hàng H&M chỉ có một ảnh chụp (mục 5.2).

3.3 Thiết kế mô hình lai NeuMF-F

NeuMF-F giữ nguyên cấu trúc hai nhánh của NeuMF [2] – nhánh GMF mô hình hóa tương tác tuyến tính, nhánh MLP mô hình hóa tương tác phi tuyến, hợp nhất ở lớp dự đoán chung – và thay đổi một điểm: vector của khách hàng và sản phẩm trong mỗi nhánh không còn chỉ là Embedding của mã ID mà là *tổng của Embedding ID và một phép chiếu tuyến tính của đặc trưng*. Chữ "F" (features) chỉ phần đặc trưng này. Hình 3.2 trình bày kiến trúc, kèm kích thước của từng ma trận và từng tầng, từ đầu vào đến danh sách Top-K: điểm $\hat{y}_{ui}$ được tính cho mọi sản phẩm ứng viên của khách, rồi các sản phẩm được sắp theo điểm giảm dần và K sản phẩm đầu là danh sách gợi ý.

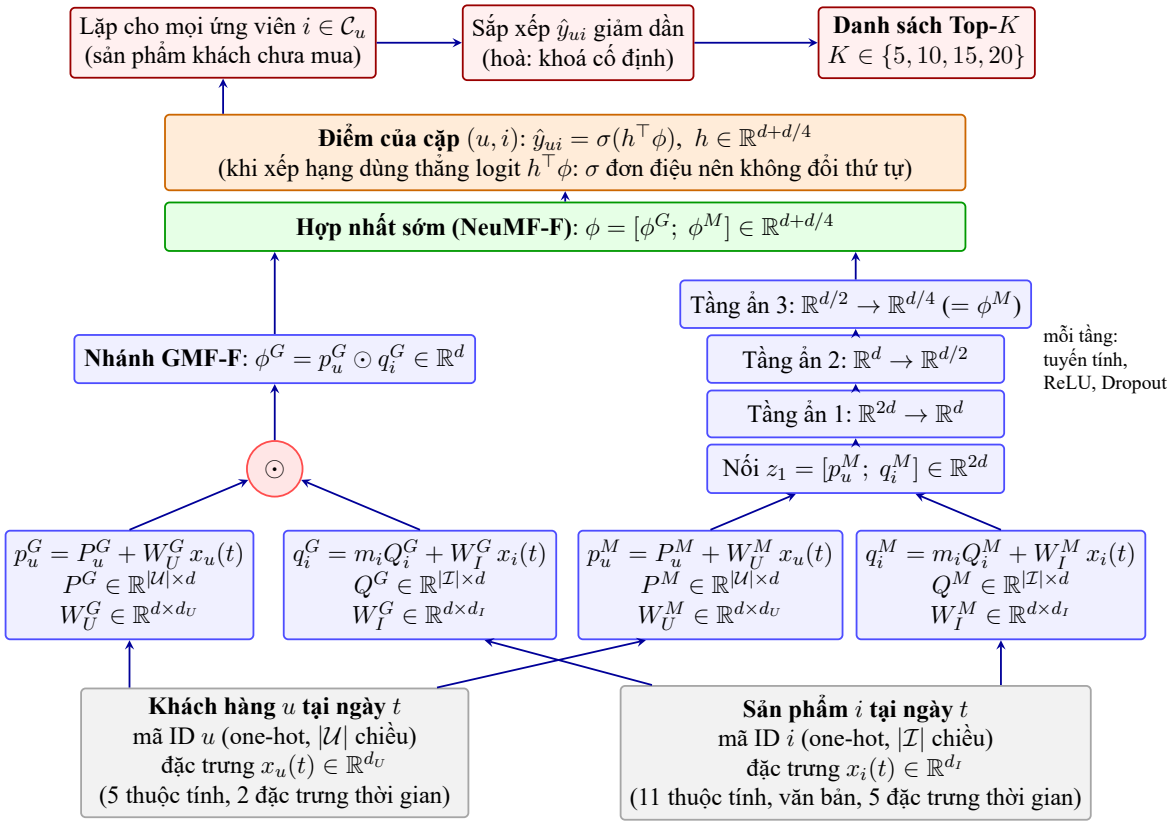
Bảng 3.5: Đặc trưng của mô hình có đặc trưng trên H&M và trên Amazon Beauty

Thành phần	**H&M**	**Amazon Beauty**
Thuộc tính sản phẩm	11 thuộc tính danh mục (88 chiều)	5 thuộc tính: thương hiệu, danh mục cấp 1, 2, 3 (dưới "Beauty"), nhóm giá (8 nhóm, 0 = không có giá) (40 chiều)
Văn bản	tên và mô tả, TF-IDF $\rightarrow$ SVD 64 chiều	tiêu đề và mô tả, cùng cách biểu diễn
Thời gian của sản phẩm tại t	doanh số toàn H&M trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ chưa từng bán (5 chiều)	số đánh giá trong tệp 5-core trong 7, 28, 91 ngày trước t; tuổi tính từ đánh giá đầu tiên; cờ chưa có đánh giá (5 chiều)
Vector đặc trưng sản phẩm	$d_I = 88 + 64 + 5 = 157$	$d_I = 40 + 64 + 5 = 109$
Thông tin khách hàng	5 thuộc tính tĩnh và 2 đặc trưng thời gian ($d_U = 40 + 2 = 42$)	không có thuộc tính tĩnh; chỉ 2 đặc trưng thời gian ($d_U = 2$)
Content (baseline)	one-hot nhóm sản phẩm, nhóm chỉ mục, nhóm may mặc	one-hot danh mục cấp 1 và cấp 2
MostPopular-Recent	số giao dịch toàn H&M trong cửa sổ W ngày	số đánh giá trong cửa sổ W ngày

Bảng 3.6: Quy mô dữ liệu Amazon Beauty (2014, 5-core): một bộ dữ liệu, chia theo thời gian

	Amazon Beauty
Đánh giá trong bộ 5-core gốc (mỗi đánh giá là một tương tác)	198.502
Sản phẩm có đánh giá trước 01/01/2014	11.493
Cặp (khách, sản phẩm) trước 01/01/2014	140.193
Khách sau lọc 5-core	10.681
Sản phẩm (asin) sau lọc 5-core	6.069
Cặp sau lọc 5-core	94.009
Xác thực: cặp huấn luyện (trước 01/10/2013)	82.281
Xác thực: khách được đánh giá	3.153
Xác thực: cặp đúng	7.880
Kiểm thử: cặp huấn luyện (trước 01/01/2014)	94.009
Kiểm thử: khách được đánh giá	2.644
Kiểm thử: cặp đúng	6.107
Kiểm thử: số ứng viên trung bình mỗi khách	6.058

Một sản phẩm = một asin. Lọc 5-core chỉ trên các cặp trước mốc kiểm thử 01/01/2014. Tập xác thực (01/10/2013 – 31/12/2013) chỉ dùng để chọn số epoch; không tinh chỉnh trên bộ này. Ứng viên và cặp đúng chỉ gồm sản phẩm đã có cặp huấn luyện trước mốc của giai đoạn.



Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F, từ đầu vào đến danh sách Top-K. Mỗi nhánh có bảng Embedding ID và phép chiếu đặc trưng riêng; $m_i \in \{0, 1\}$ cho biết Embedding ID của sản phẩm có được dùng hay không. Với cấu hình được chọn ($d = 32$): tháp $64 \to 32 \to 16 \to 8$, $\phi \in \mathbb{R}^{40}$; trên mẫu kiểm định H&M $|\mathcal{U}| = 7.994$, $|\mathcal{I}| = 6.749$, $d_U = 42$, $d_I = 157$

3.3.1 Biểu diễn lai: Embedding ID kết hợp đặc trưng

Với mỗi nhánh $b \in \{G, M\}$ (GMF và MLP), mô hình có bảng Embedding ID của khách hàng $P^b \in \mathbb{R}^{|\mathcal{U}| \times d}$, của sản phẩm $Q^b \in \mathbb{R}^{|\mathcal{I}^{ID}| \times d}$ và hai ma trận chiếu đặc trưng $W_U^b \in \mathbb{R}^{d \times d_U}$, $W_I^b \in \mathbb{R}^{d \times d_I}$ (không có hệ số chệch). Vector của khách u và sản phẩm i tại ngày t trong nhánh b là:

$$p_u^b(t) = P_u^b + W_U^b\, x_u(t), \qquad q_i^b(t) = m_i\, Q_i^b + W_I^b\, x_i(t) \tag{3.6}$$

trong đó vector đặc trưng của sản phẩm $x_i(t) = [e(a_{i,1}); \ldots; e(a_{i,11});\ v_i;\ x_i^{tg}(t)] \in \mathbb{R}^{d_I}$ gồm Embedding 8 chiều của 11 thuộc tính danh mục, vector văn bản v_i (64 chiều) và 5 đặc trưng thời gian (Công thức (3.5)), tức $d_I = 88 + 64 + 5 = 157$; tương tự $x_u(t) = [e(c_{u,1}); \ldots; e(c_{u,5});\ x_u^{tg}(t)] \in \mathbb{R}^{d_U}$ với $d_U = 40 + 2 = 42$. Embedding của các thuộc tính $e(\cdot)$ được học cùng mô hình và dùng chung cho hai nhánh; ma trận chiếu W^b riêng cho từng nhánh.

Hệ số m_i quyết định Embedding ID của sản phẩm có được dùng hay không: $m_i = 1$ với sản phẩm có dữ liệu huấn luyện ở giai đoạn đang xét – với tập ứng viên của đề tài (mục 3.2.4), đó là mọi sản phẩm được chấm – còn khi $m_i = 0$, vector của sản phẩm chỉ còn phần đặc trưng. Khi huấn luyện, m_i của từng mẫu được đặt về 0 ngẫu nhiên với xác suất ρ ("bỏ ID ngẫu nhiên", $\rho \in \{0;\ 0{,}25;\ 0{,}5\}$ được tinh chỉnh). Cơ chế này buộc mô hình học cách chấm điểm một phần từ đặc trưng thay vì dựa hoàn toàn vào Embedding ID; ý tưởng bỏ ngẫu nhiên đầu vào sở thích tham khảo từ DropoutNet [33], vốn được đề xuất để chấm điểm đối tượng khởi đầu lạnh. Trong đề tài, ρ là một siêu tham số như các siêu tham số khác và được chọn trên tập xác thực; cấu hình NeuMF-F được chọn có $\rho = 0$, tức không bỏ ID (mục 4.3).

Như NeuMF, hai nhánh dùng hai không gian nhúng độc lập: nhánh GMF tối ưu vector cho phép nhân Hadamard (tuyến tính), nhánh MLP tối ưu vector làm đầu vào của mạng phi tuyến sâu; ép hai mục tiêu khác bản chất này dùng chung tham số có thể khiến gradient của hai nhánh xung đột [2]. Hai nhánh dùng cùng số chiều $d \in \{32, 64\}$. Bảng Embedding và Embedding thuộc tính được khởi tạo theo phân phối chuẩn $\mathcal{N}(0;\ 0{,}01^2)$ như công trình gốc, hàng "không có ID" là vector 0 cố định; các tầng tuyến tính khởi tạo theo Xavier; lớp đầu ra h không có hệ số chệch.

3.3.2 Nhánh GMF-F

Nhánh GMF-F là dạng tổng quát hóa của nhân tử hóa ma trận (Công thức (2.5)) trên vector lai: thay vì cộng dồn ngay tích các chiều thành một số vô hướng, nhánh

giữ kết quả nhân theo từng chiều qua phép nhân Hadamard:

$$\phi^G = p_u^G(t) \odot q_i^G(t) \tag{3.7}$$

Phép cộng dồn được chuyển sang lớp trọng số h ở tầng đầu ra (mục 3.3.4), cho phép mô hình học trọng số riêng cho từng chiều – phần "tổng quát hóa" trong tên gọi GMF; khi $h = \mathbf{1}$ và không có đặc trưng, GMF-F trở về MF. Vì p_u^G và q_i^G đều chứa phần chiếu của đặc trưng, tích $p_u^G \odot q_i^G$ còn mô hình hóa tương tác tuyến tính giữa thuộc tính của khách và thuộc tính của sản phẩm – tinh thần tương tự Factorization Machines [15], mô hình tổng quát hóa MF cho vector đặc trưng bất kỳ.

3.3.3 Nhánh MLP-F

Nhánh MLP-F *nối* hai vector lai thành đầu vào của một mạng nhiều tầng, không áp đặt trước cách hai vector tương tác:

$$z_1 = \begin{bmatrix} p_u^M(t) \\ q_i^M(t) \end{bmatrix} \in \mathbb{R}^{2d}, \qquad \phi_L^M = a_L\big(W_L^T \cdots a_2(W_2^T z_1 + b_2) \cdots + b_L\big) \tag{3.8}$$

Tháp có kiến trúc giảm một nửa qua mỗi tầng ẩn theo thiết kế của He và cộng sự [2]: $[2d \to d \to d/2 \to d/4]$ (với $d = 32$: $[64 \to 32 \to 16 \to 8]$). Mỗi tầng ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và Dropout (tỉ lệ tinh chỉnh trong $\{0;\ 0{,}2\}$) để hạn chế quá khớp. Cùng với Dropout, mô hình được chống quá khớp bằng điều chuẩn L_2 (mục 3.4.2) và dừng sớm theo NDCG@10 trên tập xác thực (mục 3.5.1).

3.3.4 Tầng hợp nhất và lớp dự đoán đầu ra

Vector của nhánh GMF-F (tương tác tuyến tính) và của nhánh MLP-F (tương tác phi tuyến) được nối thành một vector hợp nhất rồi qua một tầng tuyến tính cuối và hàm Sigmoid:

$$\hat{y}_{ui} = \sigma\big(h^T[\phi^G;\ \phi_L^M]\big) = \sigma\big(h_G^T\,(p_u^G \odot q_i^G) + h_M^T\,\phi_L^M\big) \tag{3.9}$$

Theo phân loại ở mục 2.3.4, đây là **hợp nhất sớm (Early Fusion) ở mức biểu diễn** của view tuyến tính (MF) và view phi tuyến (DNN): một lớp dự đoán chung học trọng số giữa hai view, và toàn bộ mạng được huấn luyện chung từ đầu đến cuối. Đồng thời, đặc trưng của sản phẩm và khách hàng được đưa vào ngay ở mức vector của cả hai nhánh, tức thông tin nội dung và ngữ cảnh cũng được hợp nhất sớm với thông tin cộng tác (Embedding ID). Khi xếp hạng, hệ thống dùng trực tiếp giá trị trước Sigmoid (logit): Sigmoid đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hòa về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả. Khi đánh giá ở một

giai đoạn, vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần rồi dùng lại cho mọi cặp, nên chi phí chấm toàn bộ tập ứng viên gần với chi phí của NeuMF chỉ dùng ID.

3.3.5 Các mô hình đối chiếu xây dựng trên cùng khung

Để trả lời từng câu hỏi nghiên cứu bằng một phép so sánh trực tiếp, các mô hình sau được cài đặt trên cùng mã nguồn, cùng đặc trưng và cùng quy trình huấn luyện với NeuMF-F:

- **GMF-F** và **MLP-F**: NeuMF-F chỉ giữ một nhánh – đo đóng góp của từng nhánh và lợi ích của việc hợp nhất. MLP-F đứng riêng là một mô hình DNN thuần (chỉ có view phi tuyến), không phải mô hình hợp nhất MF với DNN.
- **LateFusion-F**: hợp nhất muộn (Late Fusion) của cùng hai thành phần – GMF-F và MLP-F được huấn luyện *riêng*, rồi trộn điểm đã chuẩn hóa min–max trên tập ứng viên của từng khách theo trọng số w chọn trên tập xác thực (Công thức (2.15)). So sánh NeuMF-F với LateFusion-F là so sánh hai cách hợp nhất trên cùng hai thành phần.
- **GMF, MLP, NeuMF chỉ dùng ID**: kiến trúc NCF gốc [2], không có đặc trưng – đo lợi ích của đặc trưng.
- **Ablation của NeuMF-F**: cùng siêu tham số với NeuMF-F, tắt lần lượt một thành phần – vector văn bản, đặc trưng thời gian, thông tin khách hàng, thuộc tính sản phẩm, hoặc cơ chế bỏ ID ngẫu nhiên. Biến thể nào trùng với chính NeuMF-F thì không chạy (mục 4.4.4).

Các baseline không thuộc khung này (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN, BPR-MF) được mô tả ở mục 4.2.

3.4 Lấy mẫu âm theo thời điểm và hàm mục tiêu

3.4.1 Lấy mẫu âm động theo ngày ra mắt của sản phẩm

Dữ liệu phản hồi ẩn (mục 2.1.3) chỉ ghi nhận tương tác đã xảy ra, không có nhãn âm tường minh; Negative Sampling giả định các sản phẩm khách chưa mua nhiều khả năng là âm [2]. Với mô hình có đặc trưng, mỗi cặp dương (u, i) mang ngày mua đầu t_{ui}, nên việc chọn mẫu âm phải nhất quán về thời gian: với mỗi cặp dương, hệ thống lấy ngẫu nhiên N_{ratio} sản phẩm j trong các sản phẩm của tập huấn luyện **đã ra mắt trước hoặc trong ngày** t_{ui} ($d_j^0 \leq t_{ui}$), trừ những sản phẩm khách u đã mua, và gán

nhãn $y_{uj} = 0$; mẫu âm được tính đặc trưng tại cùng ngày t_{ui}. Một sản phẩm chưa ra mắt ở ngày t_{ui} thì khách không thể mua, nên không phải mẫu âm có ý nghĩa; nếu vẫn lấy, mô hình có thể học quy luật sai "sản phẩm có cờ chưa ra mắt là âm" – một tín hiệu chỉ có trong cách tạo dữ liệu huấn luyện, không phản ánh sở thích của khách. Với mô hình chỉ dùng ID, mẫu âm được lấy đều trong các sản phẩm có ID, trừ sản phẩm khách đã mua, như NCF gốc. N_{ratio} được tinh chỉnh trong $\{4, 8\}$ (tham khảo thiết lập 3–6 mẫu âm cho mỗi mẫu dương của He và cộng sự [2]); mẫu âm được lấy lại ở *mỗi* epoch, giúp mô hình thấy nhiều tổ hợp cặp âm khác nhau. Thuật toán 3.2 mô tả bước này cho mô hình có đặc trưng.

Thuật toán 3.2 Lấy mẫu âm theo thời điểm cho mô hình có đặc trưng (thực hiện lại ở đầu mỗi epoch)

Đầu vào: tập cặp dương huấn luyện $\mathcal{D} = \{(u, i, t_{ui})\}$; ngày bán đầu tiên d_j^0 của mỗi sản phẩm; số mẫu âm N_{ratio}
Đầu ra: tập huấn luyện của epoch: các bộ (u, j, t, y)

$\mathcal{P} \leftarrow$ các sản phẩm xuất hiện trong $\mathcal{D}$, sắp tăng dần theo d_j^0
$\mathcal{I}_u \leftarrow \{i : (u, i, \cdot) \in \mathcal{D}\}$ với mọi khách u ▷ *sản phẩm khách đã mua*
$\mathcal{B} \leftarrow \emptyset$
với mỗi $(u, i, t) \in \mathcal{D}$ **làm**
    thêm $(u, i, t, 1)$ vào $\mathcal{B}$ ▷ *mẫu dương, đặc trưng tính tại ngày t*
    $\mathcal{A}_t \leftarrow \{j \in \mathcal{P} : d_j^0 \le t\}$ ▷ *sản phẩm đã ra mắt tính đến ngày t*
    với $n = 1, \ldots, N_{ratio}$ **làm**
        lấy j ngẫu nhiên đều trong $\mathcal{A}_t$; nếu $j \in \mathcal{I}_u$ thì lấy lại (tối đa 20 lần)
        thêm $(u, j, t, 0)$ vào $\mathcal{B}$ ▷ *mẫu âm dùng cùng ngày t*
trả về $\mathcal{B}$

3.4.2 Hàm tổn thất Binary Cross-Entropy và điều chuẩn

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm Binary Cross-Entropy được tối thiểu hóa cùng số hạng điều chuẩn L_2 (weight decay của bộ tối ưu):

$$\mathcal{L} = -\sum_{(u,i)\in\mathcal{Y}\cup\mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_\Theta \|\Theta\|_2^2 \tag{3.10}$$

trong đó Θ là toàn bộ tham số có thể học (Embedding ID, Embedding thuộc tính, ma trận chiếu, tháp MLP, lớp đầu ra) và $\lambda_\Theta \in \{0;\ 10^{-6}\}$ được tinh chỉnh. BCE được tính trên logit (`BCEWithLogitsLoss`) để ổn định số học; bộ tối ưu là Adam [16], kích thước lô 512.

3.5 Quy trình huấn luyện và tinh chỉnh

3.5.1 Bảng thiết lập siêu tham số và kỹ thuật dừng sớm

Bảng 3.7 liệt kê không gian tinh chỉnh của mọi mô hình có siêu tham số. Mỗi mô hình có học được thử đúng **6 cấu hình**: cấu hình mặc định (in đậm) cộng 5 cấu hình rút ngẫu nhiên không lặp từ lưới của mô hình đó bằng một bộ sinh số ngẫu nhiên cố định; mô hình chỉ có một tham số (MostPopular-Recent, Content, LateFusion-F) được thử đủ lưới. Mọi cấu hình được huấn luyện với seed 42 và chấm trên tập xác thực của mẫu phát triển.

Bảng 3.7: Không gian tinh chỉnh (giá trị in đậm là cấu hình mặc định)

Mô hình / siêu tham số	**Giá trị thử**
GMF, MLP, NeuMF; GMF-F, MLP-F, NeuMF-F	tốc độ học $\{\mathbf{10^{-3}},\ 5\cdot10^{-4}\}$; số chiều d $\{\mathbf{32}, 64\}$; số mẫu âm $\{\mathbf{4}, 8\}$; weight decay $\{0,\ \mathbf{10^{-6}}\}$; Dropout của tháp MLP $\{0;\ \mathbf{0}{,}\mathbf{2}\}$ (trừ GMF, GMF-F)
Thêm cho GMF-F, MLP-F, NeuMF-F	xác suất bỏ ID ρ $\{0;\ \mathbf{0}{,}\mathbf{25};\ 0{,}5\}$; Embedding thuộc tính 8 chiều và vector văn bản 64 chiều (cố định)
Cố định cho mọi mạng nơ-ron	Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm khi NDCG@10 trên tập xác thực không cải thiện sau 5 epoch
BPR-MF	d $\{\mathbf{32}, 64, 128\}$; tốc độ học $\{0{,}01;\ \mathbf{0}{,}\mathbf{03};\ 0{,}05\}$; hệ số điều chuẩn $\{0{,}001;\ \mathbf{0}{,}\mathbf{005};\ 0{,}01\}$; số epoch $\{\mathbf{20}, 40\}$
ItemKNN, UserKNN	số láng giềng k $\{20, 50, \mathbf{100}, 200, 500\}$; hệ số co $\{\mathbf{0}, 10, 50\}$
MostPopular-Recent	cửa sổ W $\{7, 14, 28, 56, 91\}$ ngày (đủ lưới)
Content	chu kỳ bán rã của trọng số theo thời gian {không trọng số, $30, 90, 180, 365$} ngày (đủ lưới)
LateFusion-F	w $\{0;\ 0{,}1;\ \ldots;\ 1\}$ (đủ lưới, trên GMF-F và MLP-F tốt nhất)

Dừng sớm (Early Stopping) và huấn luyện lại: sau mỗi epoch, mạng được chấm NDCG@10 theo Full Ranking trên tập xác thực; trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi chỉ số không cải thiện sau 5 epoch liên tiếp. Số epoch tốt nhất e^* được ghi lại để dùng khi huấn luyện lại: trước khi dự đoán cho giai đoạn kiểm thử, mô hình được huấn luyện lại *từ đầu* trên mọi cặp trước mốc kiểm thử đúng e^* epoch – lúc này không còn tập xác thực để dừng, và tập kiểm thử không bao giờ được dùng để dừng (Thuật toán 3.3, mục 3.6).

Thuật toán 3.3 Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch

Đầu vào: cấu hình θ; seed s; dữ liệu trước mốc xác thực $\mathcal{D}_{\tau_{val}}$ và tập xác thực V; dữ liệu trước mốc kiểm thử $\mathcal{D}_{\tau_{test}}$; $E_{max} = 20$, kiên nhẫn $P = 5$

Đầu ra: mô hình f^* để suy diễn sau mốc τ_{test} và số epoch e^*

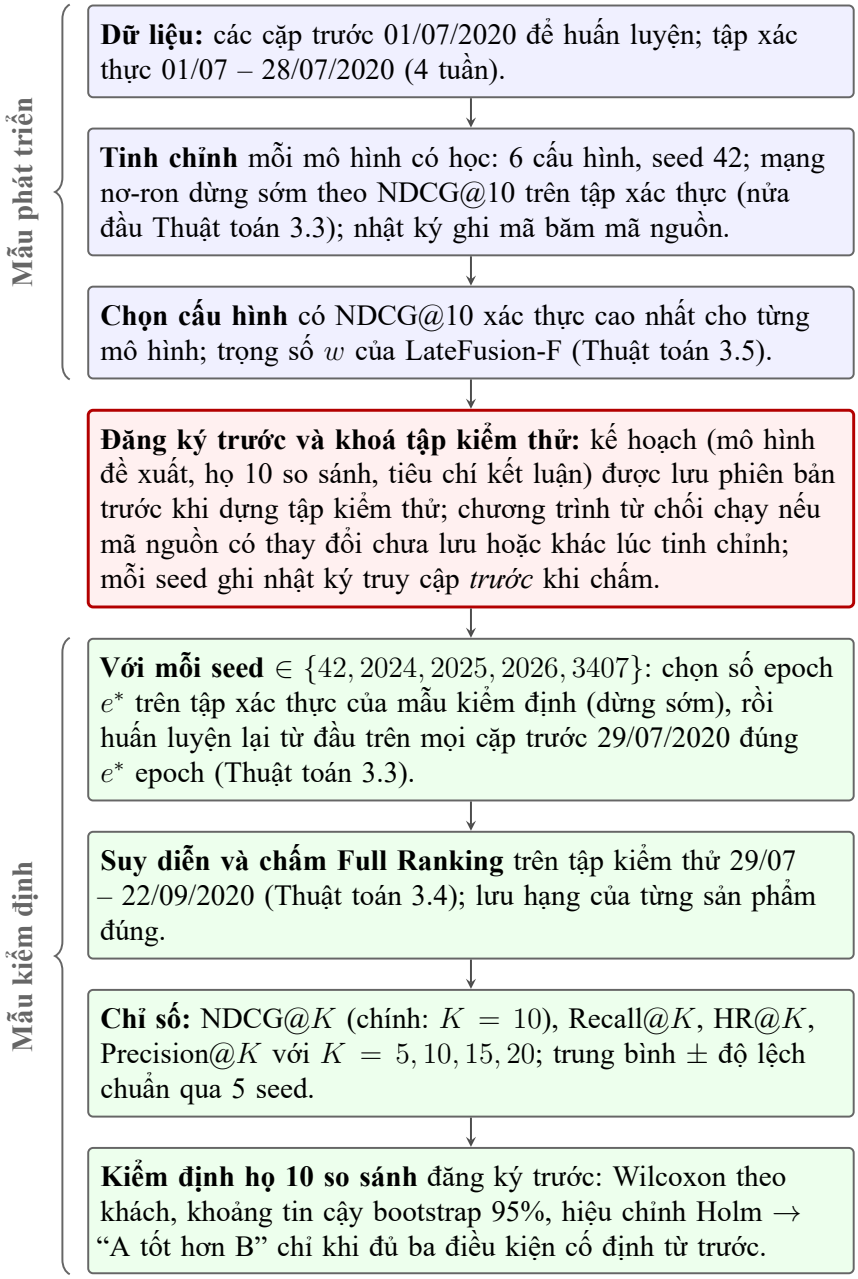
hàm HuấnLuyện($\mathcal{D}, E, V$)
  khởi tạo f theo θ và seed s; *tốt_nhất* $\leftarrow -\infty$; $e^* \leftarrow 0$; *chờ* $\leftarrow 0$
  với $e = 1, \ldots, E$ **làm**
    lấy lại mẫu âm (Thuật toán 3.2); xáo trộn
    với mỗi lô 512 mẫu **làm**
      cập nhật f bằng Adam theo BCE trên logit (Công thức (3.10))
    nếu $V \neq \emptyset$ **thì**
      $n \leftarrow$ NDCG@10 của f trên V (Full Ranking, Thuật toán 3.4)
      nếu $n >$ *tốt_nhất* **thì**
        tốt_nhất $\leftarrow n$; $e^* \leftarrow e$; lưu trọng số của f; *chờ* $\leftarrow 0$
      ngược lại
        chờ $\leftarrow$ *chờ* $+ 1$; **nếu** *chờ* $\geq P$ **thì** dừng vòng lặp
    ngược lại
      $e^* \leftarrow e$ ▷ *huấn luyện lại: chạy đủ E epoch*
  nếu $V \neq \emptyset$ **thì** nạp lại trọng số tốt nhất
  trả về f, e^*
$(\cdot, e^*) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{val}}, E_{max}, V$) ▷ *chọn số epoch*
$(f^*, \cdot) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{test}}, e^*, \emptyset$) ▷ *huấn luyện lại từ đầu*
lưu trọng số f^* ▷ *bước "lưu mô hình" của Hình 3.1*
trả về f^*, e^*

Nhật ký tinh chỉnh: mỗi cấu hình ghi một dòng gồm tham số, mã băm cấu hình, phiên bản mã nguồn (commit) và *mã băm nội dung mã nguồn* (gồm toàn bộ thư mục mã của mô hình, dữ liệu, đánh giá và tệp cấu hình), epoch tốt nhất, thời gian và chỉ số trên tập xác thực. Mã băm nội dung cho phép kiểm tra rằng mọi cấu hình được chạy với cùng một mã nguồn, kể cả khi chạy trước lúc lưu phiên bản, và rằng đánh giá cuối dùng đúng mã nguồn đã dùng khi tinh chỉnh.

3.6 Quy trình đánh giá không thiên lệch

Ferrari Dacrema và cộng sự [8] chỉ ra hai lỗi phương pháp thường gặp khi đánh giá mô hình gợi ý học sâu: chọn số epoch hay cấu hình dựa trên chính tập kiểm thử, và tinh chỉnh mô hình đối chứng sơ sài; Rendle và cộng sự [7] nhấn mạnh kết luận so sánh phụ thuộc mạnh vào việc mô hình đối chứng có được tinh chỉnh đầy đủ hay không. Giai đoạn phát triển của đề tài còn cho thấy một rủi ro thứ ba: khi tập kiểm thử đã được xem, mọi quyết định sau đó đều có thể bị ảnh hưởng bởi kết quả đã thấy (mục 4.6). Quy trình đánh giá của đề tài (Hình 3.3) xử lý cả ba rủi ro bằng sáu nguyên tắc. Quy trình này tách rời đường ống ở Hình 3.1: nó chỉ gọi lại các bước huấn luyện và suy diễn với những mốc thời gian khác nhau, rồi so danh sách gợi ý với những gì khách đã mua thật.

1. **Tách mẫu phát triển và mẫu kiểm định.** Mọi lựa chọn mô hình, siêu tham số và số epoch dựa trên tập *xác thực*: tinh chỉnh trên mẫu phát triển, chọn số epoch khi đánh giá cuối trên tập xác thực của mẫu kiểm định. Tập kiểm thử của mẫu kiểm định chỉ được mở **đúng một lần**, ở đánh giá cuối; tập kiểm thử của mẫu phát triển không được dựng ở bản cuối của quy trình.
2. **Đăng ký trước (pre-registration).** Danh sách mô hình, lưới tinh chỉnh, số seed, độ đo chính, họ so sánh, tiêu chí kết luận và các hạn chế đã biết được ghi vào kế hoạch thực nghiệm (03/10/2026) *trước* khi có kết quả tinh chỉnh của bất kỳ mô hình có đặc trưng nào, rồi được lưu vào hệ thống quản lý phiên bản. Bản cuối của kế hoạch (10/10/2026) đổi bốn điểm theo góp ý của giảng viên hướng dẫn và quyết định của nhóm – một sản phẩm là một mẫu thiết kế, bỏ sản phẩm chưa có người mua khỏi tập ứng viên, ghi dữ liệu đã lọc ra tệp kiểm bằng mã MD5, và đánh giá cuối trên mẫu kiểm định mới (khối 2). Các điểm này được quyết định sau khi đã xem kết quả trên khối 1, nên khối 1 không còn dùng để kết luận (mục 4.6). Bản cuối được lưu phiên bản sau khi tinh chỉnh lại trên dữ liệu mới của mẫu phát triển và trước



Hình 3.3: Quy trình đánh giá: tinh chỉnh chỉ trên tập xác thực của mẫu phát triển, đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định theo kế hoạch đăng ký trước

khi dựng tập kiểm thử của mẫu kiểm định; độ đo chính, họ so sánh và tiêu chí kết luận giữ nguyên như bản 03/10/2026. Mô hình đề xuất (NeuMF-F) được cố định từ trước, không chọn lại theo kết quả. Mọi thay đổi sau đó được ghi vào mục "lệch kế hoạch" kèm thời điểm. Kế hoạch kiểm chứng trên Amazon Beauty được đăng ký riêng theo cùng cách, trước khi chạy mô hình nào trên bộ này.

3. **Khoá tập kiểm thử.** Chương trình đánh giá cuối từ chối chạy nếu kế hoạch chưa được lưu phiên bản, thiếu lý do chạy, mã nguồn có thay đổi chưa lưu hoặc có tệp mã chưa được theo dõi, tinh chỉnh chưa đủ mô hình, mã băm nội dung mã nguồn khác lúc tinh chỉnh, hoặc seed đó đã từng mở tập kiểm thử. Mỗi seed ghi một dòng nhật ký truy cập (thời gian, phiên bản mã nguồn, mã băm cấu hình, danh sách mô hình, lý do) *trước* khi chấm.
4. **Cùng ngân sách tinh chỉnh** cho mọi mô hình có học (6 cấu hình, mục 3.5.1).
5. **Huấn luyện lại trước khi chấm.** Với mỗi seed trong 5 seed (42, 2024, 2025, 2026, 3407) và mỗi mạng nơ-ron: huấn luyện trên dữ liệu trước 01/07/2020 của mẫu kiểm định, dừng sớm theo NDCG@10 trên tập xác thực của chính mẫu này để chọn số epoch e^*; huấn luyện lại từ đầu trên mọi cặp trước 29/07/2020 đúng e^* epoch (không còn tập xác thực để dừng, và tập kiểm thử không được dùng để dừng); rồi chấm tập kiểm thử (Thuật toán 3.3). BPR-MF và các mô hình không phải mạng nơ-ron được khớp trên mọi cặp trước 29/07/2020; LateFusion-F trộn đúng GMF-F và MLP-F đã huấn luyện lại ở cùng seed, với w chọn trên mẫu phát triển.
6. **Kiểm định thống kê và tiêu chí kết luận cố định.** Với mỗi khách được đánh giá, NDCG@10 được lấy trung bình qua 5 seed (mô hình tất định cho cùng giá trị ở mọi seed), rồi so sánh từng cặp mô hình bằng kiểm định Wilcoxon signed-rank theo người dùng [17] và khoảng tin cậy 95% của hiệu trung bình bằng bootstrap ghép cặp (10.000 lần lấy mẫu lại) [18]; giá trị p được hiệu chỉnh Holm [19] trên một họ **10 so sánh** đăng ký trước: NeuMF-F so với NeuMF (đặc trưng có giúp mô hình lai không), với GMF-F và MLP-F (hợp nhất so với từng nhánh), với LateFusion-F (hợp nhất sớm so với muộn), với BPR-MF, ItemKNN, UserKNN, MostPopular-Recent, Content; và NeuMF so với BPR-MF (mô hình lai chỉ dùng ID so với MF). Chỉ viết "A tốt hơn B" khi đồng thời: $p_{Holm} < 0{,}05$, khoảng tin cậy không

chứa 0, và chênh lệch tương đối NDCG@10 $\geq$ 5%; ngược lại kết luận "không khác biệt có ý nghĩa".

Thuật toán 3.4 là cách mọi mô hình được chấm trên một giai đoạn – cùng tập ứng viên, cùng quy tắc phá hoà, nên chênh lệch giữa hai mô hình chỉ đến từ điểm số của chúng. Hạng của từng sản phẩm đúng được lưu lại theo từng khách, nên chỉ số ở một K bất kỳ tính lại được mà *không* phải chấm lại tập kiểm thử; các chỉ số ở $K = 15$ trong Chương 4 được tính theo cách này, và cách tính lại cho đúng các số @5, @10, @20 của lần đánh giá cuối. Thuật toán 3.5 chọn trọng số trộn của LateFusion-F chỉ trên tập xác thực của mẫu phát triển; trọng số này (w=0,4 (GMF-F), $1 - w$=0,6 (MLP-F)) được giữ nguyên ở đánh giá cuối.

Thuật toán 3.4 Đánh giá Full Ranking một mô hình trên một giai đoạn

Đầu vào: hàm điểm $s(u, i)$ của mô hình; tập khách được đánh giá $\mathcal{U}_{eval}$; với mỗi khách u: tập ứng viên $\mathcal{C}_u$ và tập sản phẩm đúng T_u (Công thức (3.3), (3.4)); seed phá hoà $s_0 = 2026$; các giá trị K

Đầu ra: chỉ số trung bình theo khách; hạng của từng sản phẩm đúng

với mỗi khách $u \in \mathcal{U}_{eval}$ **làm**
  tính $s(u, i)$ cho mọi $i \in \mathcal{C}_u$ theo lô ▷ *mạng nơ-ron: logit*
  sắp $\mathcal{C}_u$ theo $s(u, i)$ giảm dần; bằng điểm thì theo khoá $h(u, i, s_0)$ ▷ *cùng khoá cho mọi mô hình*
  $R_u \leftarrow$ hạng (tính từ 1) của từng $i \in T_u$ trong danh sách đã sắp; lưu R_u
  với mỗi K **làm**
    tính HR@$K(u)$, Precision@$K(u)$, Recall@$K(u)$, NDCG@$K(u)$ từ R_u (Công thức (2.19)–(2.21))
trả về trung bình từng chỉ số trên $\mathcal{U}_{eval}$ và các R_u

Thuật toán 3.5 Chọn trọng số w của LateFusion-F trên tập xác thực của mẫu phát triển

Đầu vào: GMF-F và MLP-F tốt nhất (cấu hình đã chọn khi tinh chỉnh); tập xác thực V của mẫu phát triển; lưới $W = \{0;\ 0{,}1;\ \ldots;\ 1\}$

Đầu ra: trọng số w^*

với mỗi $w \in W$ **làm**
  với mỗi khách u của V **làm**
    $a \leftarrow \text{minmax}\big(s^{\text{GMF-F}}(u, \mathcal{C}_u)\big)$; $b \leftarrow \text{minmax}\big(s^{\text{MLP-F}}(u, \mathcal{C}_u)\big)$ ▷ *Công thức* (2.15)
    điểm trộn của u: $w\,a + (1 - w)\,b$
  $N(w) \leftarrow$ NDCG@10 của điểm trộn trên V (Thuật toán 3.4)
trả về $w^* = \arg\max_{w \in W} N(w)$ ▷ *cố định từ đây, không chọn lại trên tập kiểm thử*

Ablation (một seed) được báo cáo kèm khoảng tin cậy nhưng không kiểm định và không dùng để kết luận chính; độ phủ, số epoch và thời gian huấn luyện chỉ mang tính mô tả. Mọi lần chạy đánh giá cuối được ghi vào nhật ký truy cập tập kiểm thử; nếu phải chạy lại một seed (ví dụ do lỗi máy), lần chạy lại được đánh dấu riêng và ghi vào mục lệch kế hoạch – điều này đã xảy ra một lần, với seed 42 (mục 4.1). Trên Amazon Beauty, quy trình giữ nguyên từ bước đăng ký trước trở đi (Hình 3.3); khác biệt duy nhất là không có bước tinh chỉnh và không có mẫu khách hàng độc lập (mục 3.2.6).

3.7 Suy diễn Top-K và xử lý khách hàng mới

Bước cuối của đường ống (Hình 3.1) là suy diễn: với một khách hàng và một số K, hệ thống trả về K sản phẩm nên gợi ý. Thuật toán 3.6 mô tả bước này đúng như cách hệ thống demo (mục 3.8) đang chạy. Với khách đã có trong dữ liệu đã học, đây chính là các bước chấm điểm và sắp xếp của Thuật toán 3.4, chỉ khác là không có sản phẩm đúng để so sánh. Vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần khi nạp mô hình, nên mỗi yêu cầu gợi ý chỉ còn một lượt suy diễn thuận trên các sản phẩm ứng viên của khách.

Thuật toán 3.6 Suy diễn Top-K cho một khách hàng, có xử lý khách hàng mới

Đầu vào: mã khách c; số gợi ý K; mô hình đã lưu f^* (NeuMF-F) cùng dữ liệu đã học trước mốc τ; danh sách phổ biến L_{pop} (sản phẩm xếp theo số khách đã mua trước τ)

Đầu ra: K sản phẩm gợi ý

nếu c không có trong dữ liệu đã học **thì** ▷ *khách mới, hoặc quá ít lần mua để qua lọc k-core*
  trả về K sản phẩm đầu của L_{pop}, gắn nhãn "gợi ý phổ biến"
$u \leftarrow$ mã nội bộ của c
$\mathcal{C}_u \leftarrow \{i : i$ có dữ liệu huấn luyện trước $\tau\} \setminus \mathcal{I}_u(\tau)$ ▷ *bỏ sản phẩm khách đã mua*
lấy p_u^G, p_u^M và q_i^G, q_i^M với mọi $i \in \mathcal{C}_u$ ▷ *đã tính sẵn tại τ khi nạp mô hình*
với mỗi lô sản phẩm $i \in \mathcal{C}_u$ **làm**
  $s_{ui} \leftarrow h^\top \left[p_u^G \odot q_i^G;\ \mathrm{MLP}([p_u^M;\ q_i^M]) \right]$ ▷ *logit; σ không đổi thứ tự*
sắp $\mathcal{C}_u$ theo s_{ui} giảm dần (bằng điểm: khoá cố định)
trả về K sản phẩm đầu, kèm tên, loại và ảnh

Khách hàng mới (khởi đầu lạnh của người dùng). Mô hình chỉ có Embedding ID và đặc trưng thời gian cho những khách đã có trong dữ liệu đã học. Một khách mới – chưa mua gì, hoặc mua quá ít để qua bước lọc 10-core – là tình huống khởi đầu

lạnh của người dùng (mục 2.1.4): mô hình đề xuất không có thông tin về sở thích của khách này. Hệ thống vì vậy dùng một quy tắc đơn giản: **khách mới được gợi ý các sản phẩm phổ biến nhất** – danh sách Most Popular tính trên dữ liệu trước mốc, cũng là một mô hình đối chứng được đánh giá ở Chương 4; **khi khách đã có lịch sử mua trong dữ liệu đã học, hệ thống dùng mô hình đề xuất NeuMF-F**. Nhờ vậy hệ thống luôn trả về một danh sách gợi ý, không để trống. Đánh giá định lượng của đề tài chỉ đo nhóm khách đã có lịch sử – mọi khách được đánh giá đều có dữ liệu huấn luyện trước mốc (mục 3.2.4) – nên chất lượng gợi ý cho khách mới không được đo riêng.

3.8 Thiết kế hệ thống giao diện thực nghiệm (Demo)

Mục này trình bày hệ thống demo minh họa các mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt về kiến trúc với phần huấn luyện: chỉ nạp trọng số mô hình đã lưu và gọi lại đúng các hàm xử lý dữ liệu, xếp hạng của quy trình đánh giá, không huấn luyện lại.

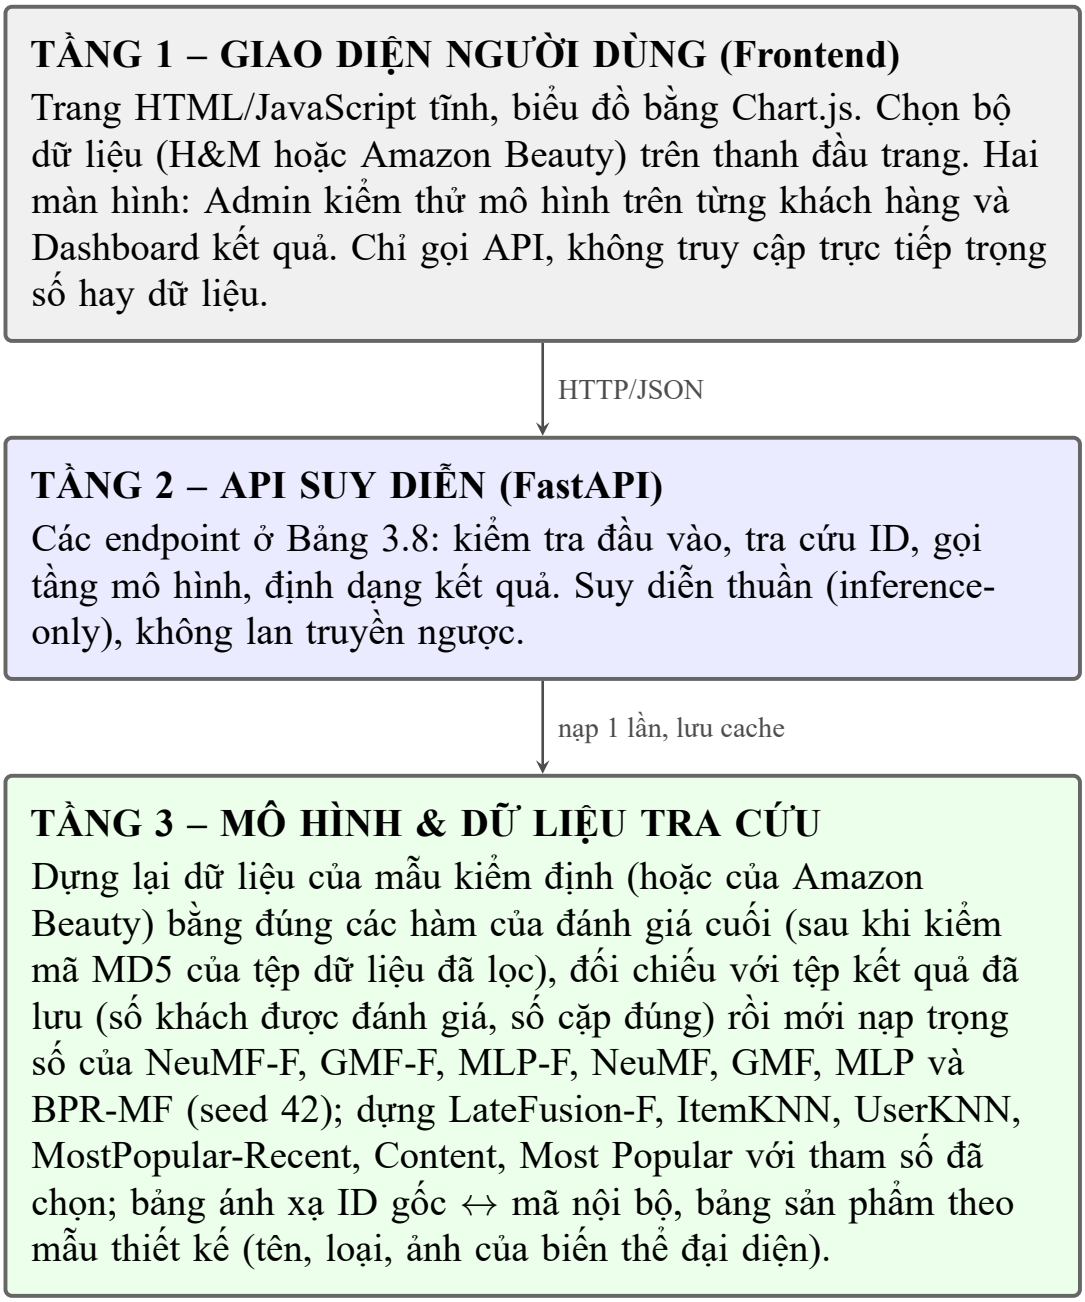
3.8.1 Kiến trúc tổng thể: ba tầng tách biệt

Hai nguyên tắc thiết kế quan trọng nhất: *(i)* tách suy diễn khỏi huấn luyện, nên thời gian phản hồi không phụ thuộc chi phí huấn luyện và tầng 2+3 có thể đóng gói thành một container độc lập; *(ii)* demo *tự kiểm tra* rằng dữ liệu dựng lại khớp với lần chạy đã huấn luyện – nếu lệch (ví dụ sai tệp dữ liệu hoặc sai ngưỡng k), máy chủ báo lỗi thay vì nạp trọng số với ánh xạ ID sai. Tập ứng viên và sản phẩm đích của mỗi khách được lấy thẳng từ dữ liệu dựng lại của đánh giá cuối. Bộ kiểm thử tự động của demo kiểm tra rằng hạng của từng sản phẩm đích và các chỉ số theo người dùng mà demo tính lại khớp tệp kết quả theo người dùng của Chương 4, lịch sử hiển thị đúng là dữ liệu mô hình đã học, và demo từ chối nạp kết quả được tạo từ dữ liệu khác. Nếu đánh giá cuối được chạy trên GPU, logit tính lại trên CPU có thể làm vài cặp sản phẩm gần như hoà điểm đổi chỗ ở hạng rất sâu (trên 100), không ảnh hưởng chỉ số @K.

3.8.2 Thiết kế API suy diễn

Luồng xử lý của chức năng gợi ý Top-K gồm 5 bước, theo đúng Thuật toán 3.6 và dùng lại đúng các hàm của quy trình đánh giá:

1. Tra định danh khách hàng để lấy mã nội bộ. Khách không có trong dữ liệu đã học (chưa có lịch sử mua, hoặc quá ít lần mua để qua lọc k-core) là tình huống khởi đầu lạnh của người dùng: API trả về danh sách sản phẩm phổ



Hình 3.4: Kiến trúc ba tầng của hệ thống giao diện thực nghiệm (demo)

Bảng 3.8: Các endpoint chính của API suy diễn

Endpoint	**Chức năng**
`GET /api/context`	Thông tin bộ dữ liệu, lần chạy đang dùng, số người dùng/sản phẩm, số ứng viên, các K hợp lệ, mô hình khả dụng.
`GET /api/users/search`, `/random`	Tìm hoặc chọn ngẫu nhiên một khách hàng có sản phẩm đích, lọc theo nhóm ít/trung bình/nhiều giao dịch.
`GET /api/users/{id}/history`	Lịch sử mua mà mô hình đã học (mọi cặp trước mốc kiểm thử), sắp theo thời gian; khách mới: lịch sử rỗng, đánh dấu là khách mới.
`GET /api/users/{id}/recommend`	Top-K của một mô hình, hạng của từng sản phẩm đích, số ứng viên, HR@K, NDCG@K, Recall@K của khách đó ($K \in \{5, 10, 15, 20\}$). Khách mới: danh sách Most Popular gắn nhãn "gợi ý phổ biến"; khách có lịch sử nhưng không mua gì trong giai đoạn kiểm thử: gợi ý của mô hình, không có chỉ số.
`GET /api/users/{id}/neighbors`	Top-K khách tương đồng nhất theo UserKNN: độ tương đồng, số sản phẩm mua chung, láng giềng nào đã mua sản phẩm đích của khách.
`GET /api/dashboard`	Số liệu tổng hợp đọc từ tệp kết quả đã chạy, kèm tên tệp nguồn.
`POST /api/reload`	Xoá cache, nạp lần chạy mới nhất mà không cần khởi động lại.

biến (Most Popular) gắn nhãn "gợi ý phổ biến", không báo lỗi và không để trống (mục 3.7); các bước dưới đây chỉ áp dụng cho khách đã có lịch sử.

2. Lấy tập ứng viên của khách: các sản phẩm có dữ liệu huấn luyện trước mốc, trừ những sản phẩm khách đã mua – đúng tập ứng viên của đánh giá Full Ranking (mục 3.2.4).
3. Tính điểm cho toàn bộ tập ứng viên theo lô (vector hoá), dùng logit với mô hình nơ-ron.
4. Sắp xếp giảm dần với cùng quy tắc phá hoà tất định như lúc đánh giá, lấy K phần tử đầu.
5. Ánh xạ ngược mã nội bộ về mã mẫu thiết kế (`product_code`) và biến thể đại diện (`article_id`, dùng để lấy ảnh), kèm tên, loại sản phẩm và số màu của mẫu, trả về Tầng 1.

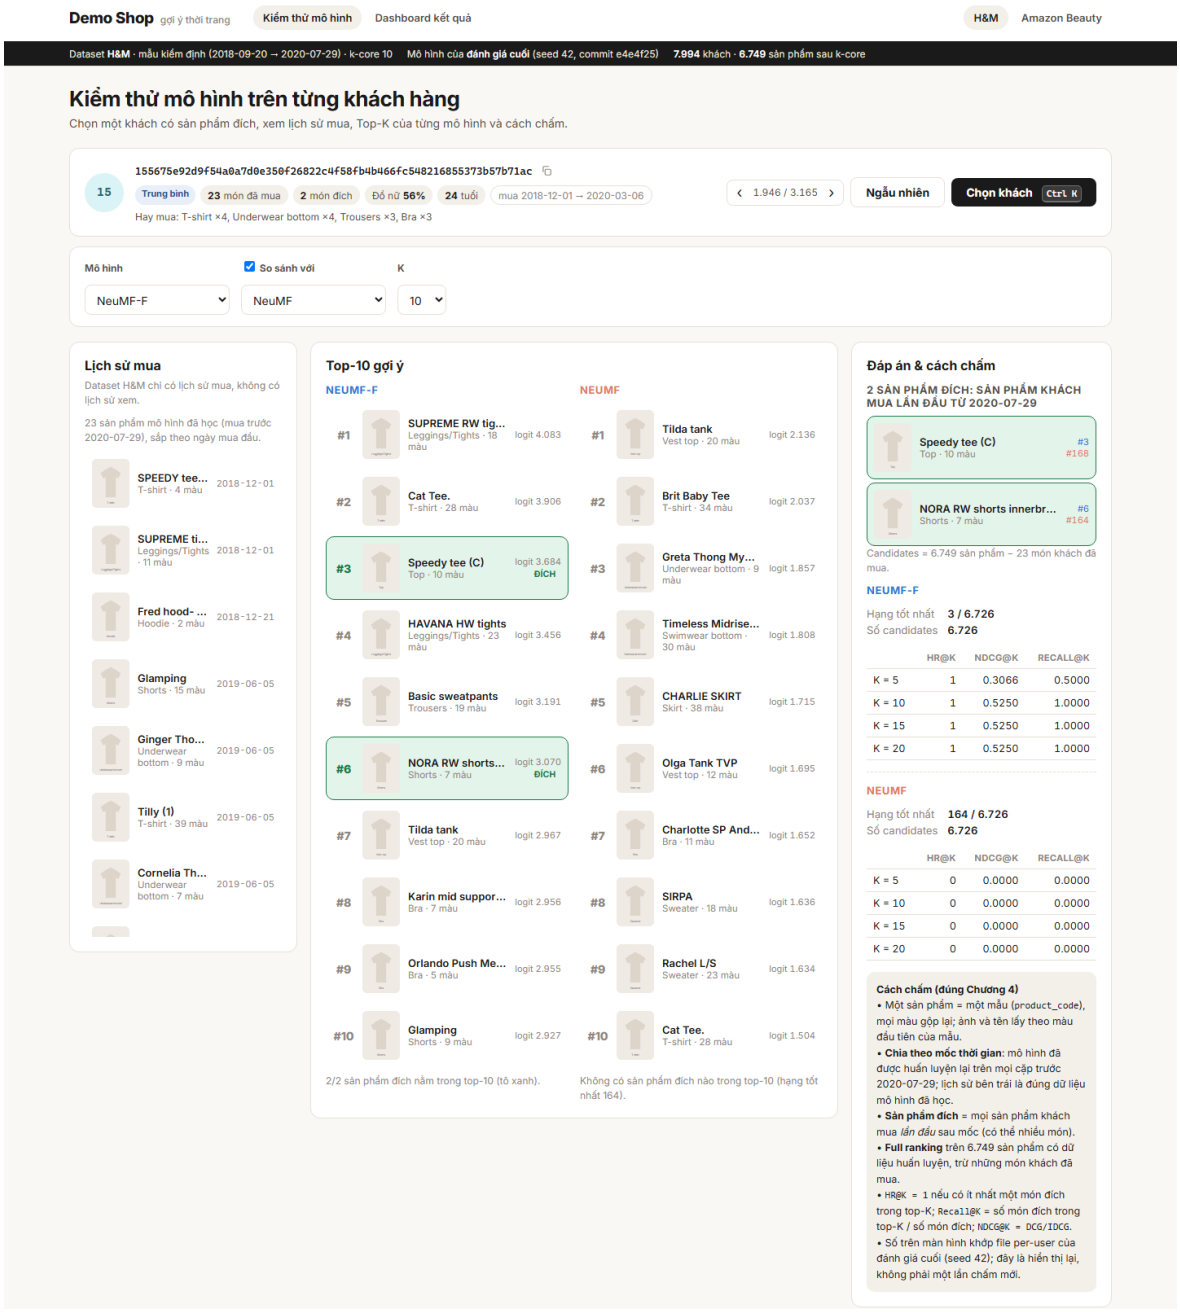
3.8.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng

Demo cho phép chọn và so sánh song song hai mô hình bất kỳ trong số 13 mô hình của đánh giá cuối (mặc định NeuMF-F và NeuMF chỉ dùng ID), để người xem tự đối chiếu với kết luận của Chương 4 – ví dụ đặt danh sách của NeuMF-F cạnh danh sách của NeuMF chỉ dùng ID trên cùng một khách; demo không khẳng định mô hình nào "tốt nhất" ngoài những gì kiểm định thống kê cho phép. Demo nạp đúng các trọng số của đánh giá cuối (seed 42) trên mẫu kiểm định của H&M, hoặc trên Amazon Beauty: lịch sử hiển thị là đúng dữ liệu mô hình đã học, và sản phẩm đích là các món khách mua lần đầu trong giai đoạn kiểm thử – nên số liệu trên demo là hiển thị lại kết quả của Chương 4, không phải một lần đánh giá mới trên tập kiểm thử. Màn hình Admin còn hiện 10 khách tương đồng nhất theo UserKNN để minh họa cách lọc cộng tác dựa trên láng giềng chọn ra gợi ý (mục 2.1.2). Về yêu cầu phi chức năng, vector của mọi khách và sản phẩm tại mốc dự đoán được tính một lần khi nạp, nên mỗi yêu cầu gợi ý chỉ là một lượt suy diễn thuận trên khoảng 6.710 ứng viên – đủ nhanh để phục vụ trực tuyến trên CPU.

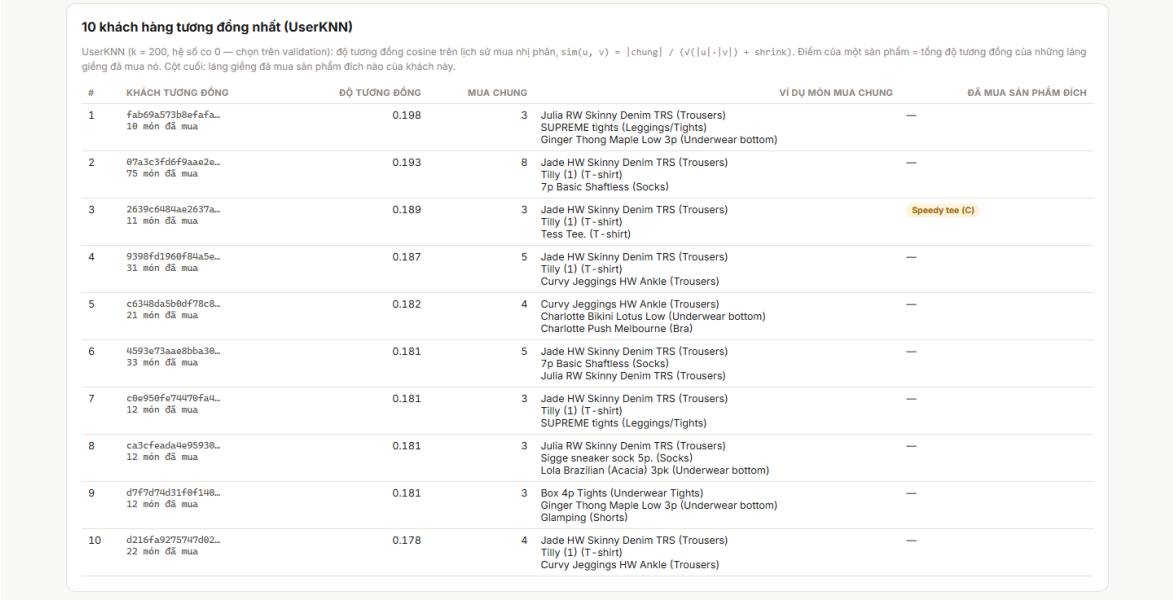
3.8.4 Minh họa hệ thống demo đã cài đặt

Hệ thống đã được cài đặt và có bộ kiểm thử tự động riêng (kiểm tra khớp số liệu với đánh giá cuối, đúng quy tắc tập ứng viên, đúng định dạng API, khách mới nhận danh sách phổ biến). Hình 3.5 minh họa màn hình Admin kiểm thử mô hình với một khách của mẫu kiểm định: NeuMF-F đưa hai sản phẩm đích lên hạng 3 và 6, còn

NeuMF chỉ dùng ID xếp sản phẩm đích tốt nhất ở hạng 164; bảng chỉ số bên phải tính ở $K = 5, 10, 15, 20$. Hình 3.6 là bảng khách tương đồng của cùng khách hàng, và Hình 3.7 là trường hợp khách mới chưa có trong dữ liệu đã học: hệ thống trả về danh sách sản phẩm phổ biến kèm nhãn, không báo lỗi.



Hình 3.5: Giao diện demo – màn hình Admin kiểm thử mô hình với mô hình của đánh giá cuối: lịch sử mua, Top-10 của NeuMF-F và NeuMF, hạng của từng sản phẩm đích trong tập kiểm thử

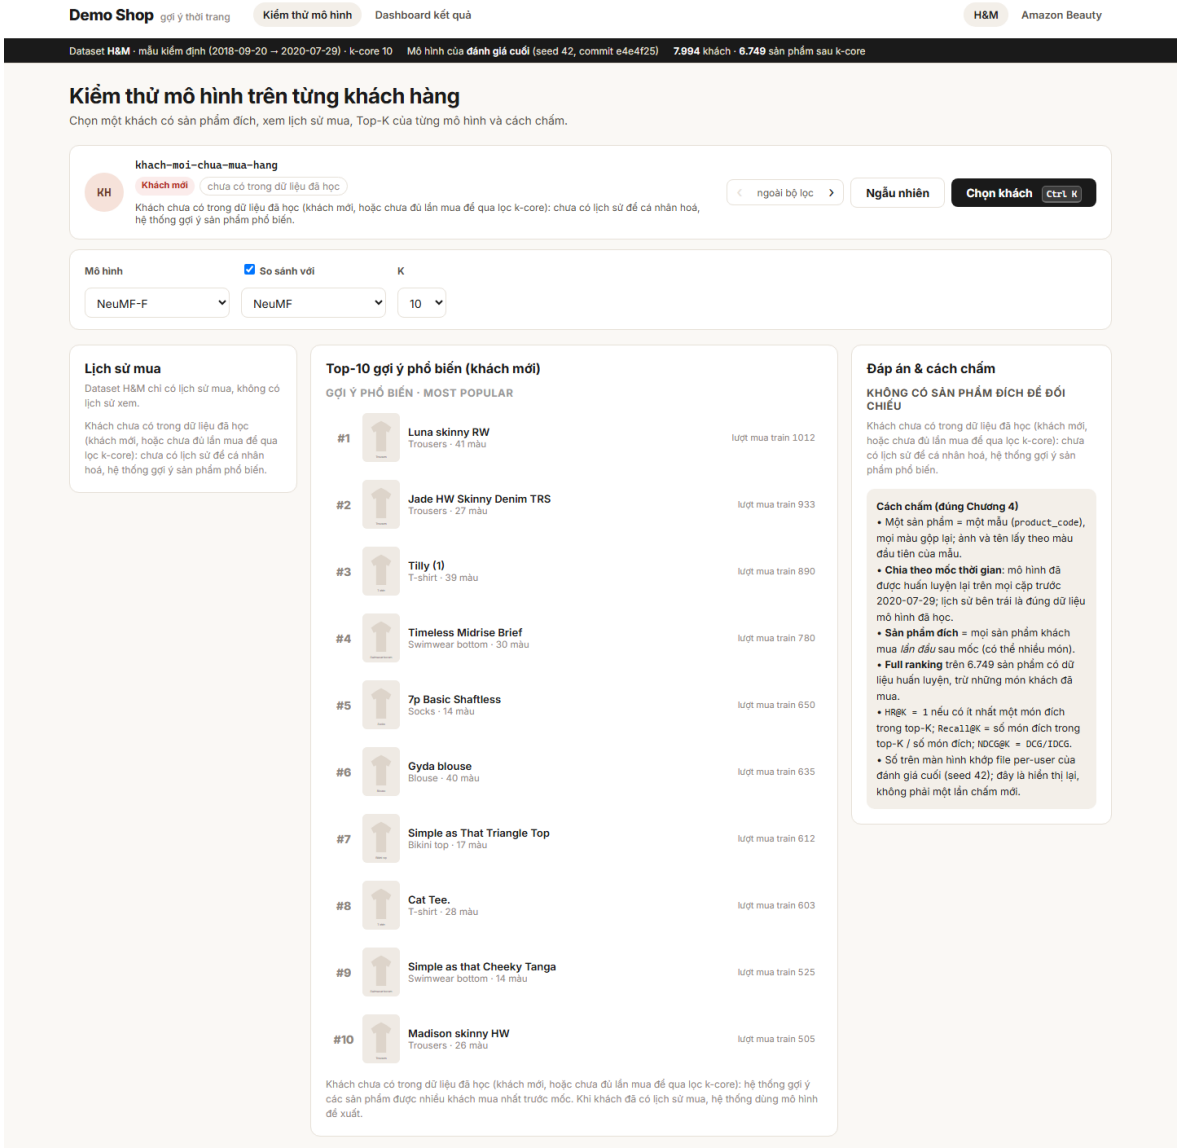


10 khách hàng tương đồng nhất (UserKNN)

UserKNN (k = 200, hệ số co 0 — chọn trên validation): độ tương đồng cosine trên lịch sử mua nhị phân, sim(u, v) = |chung| / (√(|u|·|v|) + shrink). Điểm của một sản phẩm = tổng độ tương đồng của những láng giềng đã mua nó. Cột cuối: láng giềng đã mua sản phẩm đích nào của khách này.

#	KHÁCH TƯƠNG ĐỒNG	ĐỘ TƯƠNG ĐỒNG	MUA CHUNG	VÍ DỤ MÓN MUA CHUNG	ĐÃ MUA SẢN PHẨM ĐÍCH
1	fab69a573b8efafa… 10 món đã mua	0.198	3	Julia RW Skinny Denim TRS (Trousers) SUPREME tights (Leggings/Tights) Ginger Thong Maple Low 3p (Underwear bottom)	—
2	07a3c3fd6f9aae2e… 75 món đã mua	0.193	8	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) 7p Basic Shaftless (Socks)	—
3	2639c6484ae2637a… 11 món đã mua	0.189	3	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Tess Tee. (T-shirt)	Speedy tee (C)
4	9398fd1960f84a5e… 31 món đã mua	0.187	5	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Curvy Jeggings HW Ankle (Trousers)	—
5	c6348da5b0df78c8… 21 món đã mua	0.182	4	Curvy Jeggings HW Ankle (Trousers) Charlotte Bikini Lotus Low (Underwear bottom) Charlotte Push Melbourne (Bra)	—
6	4593e73aae8bba38… 33 món đã mua	0.181	5	Jade HW Skinny Denim TRS (Trousers) 7p Basic Shaftless (Socks) Julia RW Skinny Denim TRS (Trousers)	—
7	c0e950fe7447 0fa4… 12 món đã mua	0.181	3	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) SUPREME tights (Leggings/Tights)	—
8	ca3cfeada4e95938… 12 món đã mua	0.181	3	Julia RW Skinny Denim TRS (Trousers) Sigge sneaker sock 5p. (Socks) Lola Brazilian (Acacia) 3pk (Underwear bottom)	—
9	d7f7d744d31f0f140… 12 món đã mua	0.181	3	Box 4p Tights (Underwear Tights) Ginger Thong Maple Low 3p (Underwear bottom) Glamping (Shorts)	—
10	d216fa92757 47d02… 22 món đã mua	0.178	4	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Curvy Jeggings HW Ankle (Trousers)	—

Hình 3.6: Giao diện demo – 10 khách hàng tương đồng nhất theo UserKNN: độ tương đồng cosine, số sản phẩm mua chung và láng giềng đã mua sản phẩm đích nào của khách



Hình 3.7: Giao diện demo – khách hàng mới chưa có trong dữ liệu đã học: danh sách Top-10 sản phẩm phổ biến (Most Popular) gắn nhãn "gợi ý phổ biến", không có sản phẩm đích để đối chiếu

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

Thực nghiệm gồm hai phần. Phần chính trên H&M (Chương 3) gồm hai bước tách biệt: tinh chỉnh trên tập xác thực của mẫu phát triển, và đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định – những khách hàng không có trong mẫu phát triển. Quy mô dữ liệu của hai mẫu ở Bảng 3.3 (mục 3.2.4). Phần kiểm chứng chạy lại đánh giá cuối trên bộ dữ liệu Amazon Beauty với đúng cấu hình đã chọn trên H&M (mục 3.2.6, 4.5). Mọi bảng số liệu, hình và con số kết quả trong chương này được sinh tự động từ tệp kết quả của quy trình thực nghiệm, không nhập tay. Các tài liệu tham khảo được dùng làm cơ sở về phương pháp (định nghĩa mô hình, cách huấn luyện và cách đánh giá); vì đề tài dùng dữ liệu, cách chia dữ liệu và giao thức đánh giá riêng, số liệu trong chương này *không* được so sánh trực tiếp với số liệu công bố trong các tài liệu đó – mọi so sánh đều giữa các mô hình của đề tài, trên cùng dữ liệu và cùng giao thức.

- **Full Ranking:** với mỗi khách được đánh giá, xếp hạng toàn bộ tập ứng viên – các sản phẩm (mẫu thiết kế, `product_code`) đã có dữ liệu huấn luyện trước mốc, trừ những sản phẩm khách đã mua (trung bình 6.710 ứng viên mỗi khách ở tập kiểm thử của mẫu kiểm định). Khi nhiều sản phẩm có điểm bằng nhau, thứ tự giữa chúng được quyết định bằng một khoá giả ngẫu nhiên cố định (seed 2026), giống nhau cho mọi mô hình (Thuật toán 3.4).
- **Độ đo chính:** NDCG@10 trung bình theo người dùng trên tập kiểm thử của mẫu kiểm định (3.165 người dùng, 10.285 cặp đúng). Độ đo phụ: Recall@10, HR@10, Precision@10, NDCG@5, NDCG@20 (định nghĩa ở mục 2.5); ngoài ra mọi độ đo được báo cáo ở $K = 5, 10, 15, 20$ (mục 4.4.2).
- **Số lần chạy:** mỗi mô hình được chạy với 5 seed (42, 2024, 2025, 2026, 3407); với mỗi seed, số epoch được chọn trên tập xác thực của mẫu kiểm định, rồi mô hình được huấn luyện lại trên mọi cặp trước 29/07/2020 trước khi chấm tập kiểm thử (mục 3.6). Báo cáo trung bình $\pm$ độ lệch chuẩn qua seed; kiểm định theo mục 3.6.
- **Môi trường chạy:** tinh chỉnh mất tổng cộng 4,7 giờ cho 76 cấu hình. Đánh giá cuối trên H&M chạy trên GPU (CPU AMD Ryzen 7 6800H with Radeon

Graphics; GPU: NVIDIA GeForce RTX 3050 Laptop GPU), Python 3.12.2, PyTorch 2.6.0+cu124 [12], mất 7,5 giờ cho 5 seed. Mọi dòng nhật ký tinh chỉnh và mọi lần đánh giá cuối trên H&M có cùng một mã băm nội dung mã nguồn (`0f1ea1eec5a86c31`); đánh giá cuối chạy trên phiên bản mã nguồn `e4e4f25` đã lưu, mã nguồn không có thay đổi chưa lưu. Đánh giá cuối trên Amazon Beauty chạy trên cùng máy, mất 3,0 giờ cho 5 seed, với phiên bản mã nguồn `f866337`; mã nguồn đã được bổ sung phần đọc dữ liệu Amazon nên mã băm khác lần chạy H&M, còn với H&M hành vi mặc định không đổi (bộ kiểm thử tự động cũ vẫn qua).

– **Lệch kế hoạch:** lần chạy đánh giá cuối đầu tiên trên H&M dừng giữa chừng ở seed 42 – sau khi đã chấm Random và năm mô hình tất định (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN), trước khi lưu bất kỳ kết quả hay trọng số nào. Seed 42 được chạy lại từ đầu với cùng mã nguồn, cấu hình và dữ liệu; lần chạy lại được ghi riêng trong nhật ký truy cập tập kiểm thử và trong mục "lệch kế hoạch" của kế hoạch đăng ký trước. Không quyết định nào được đưa ra sau khi xem các con số đã hiện trên màn hình: cấu hình đã cố định từ bước tinh chỉnh, và các mô hình tất định cho cùng kết quả ở lần chạy lại.

4.2 Phương pháp đối chứng (Baselines)

Ngoài mô hình đề xuất NeuMF-F và các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, GMF, MLP, NeuMF – mục 3.3.5), bảy baseline được đánh giá với cùng dữ liệu, tập ứng viên và quy tắc đánh giá:

1. **Random** – điểm ngẫu nhiên, cận dưới.
2. **Most Popular** – điểm của sản phẩm là số khách trong dữ liệu huấn luyện của mẫu đã mua sản phẩm đó; mọi khách nhận cùng một danh sách (trừ sản phẩm đã mua).
3. **MostPopular-Recent** – độ phổ biến *gần đây* trên toàn bộ H&M: điểm của sản phẩm i là số giao dịch của nó trong W ngày trước mốc dự đoán, $\sum_{d=\tau-W}^{\tau-1} n_{i,d}$, với W chọn trên tập xác thực. Đây là baseline mạnh với dữ liệu thời trang có xu hướng thay đổi nhanh; nó dùng cùng nguồn doanh số với đặc trưng thời gian của NeuMF-F (mục 3.2.5), nên so sánh với nó cho biết NeuMF-F có học được gì vượt trên xu hướng chung hay không.
4. **Content** – gợi ý theo nội dung thuần [20]: mỗi sản phẩm được biểu diễn

bằng vector văn bản (mục 3.2.5) nối với mã hóa one-hot của bốn thuộc tính (nhóm sản phẩm, nhóm màu, nhóm chỉ mục, nhóm may mặc), chuẩn hóa về độ dài 1; hồ sơ của khách là trung bình có trọng số các vector sản phẩm đã mua, trọng số giảm theo thời gian với chu kỳ bán rã h ngày ($\omega = 2^{-(\tau - t_{uj})/h}$, hoặc bằng 1 nếu không dùng trọng số); điểm là độ tương đồng cosine giữa hồ sơ và sản phẩm. Content không dùng ID và không học từ hành vi của những khách khác.

5. **ItemKNN** [21] và **UserKNN** – lọc cộng tác dựa trên láng giềng (mục 2.1.2), với số láng giềng k và hệ số co chọn trên tập xác thực.
6. **BPR-MF** [25] – nhân tử hóa ma trận tối ưu xếp hạng theo cặp, đại diện cho MF tuyến tính được tinh chỉnh cùng ngân sách.

Most Popular, ItemKNN, UserKNN và BPR-MF chỉ dùng ID, như GMF, MLP và NeuMF. Đặt mô hình học sâu cạnh các baseline đơn giản được tinh chỉnh đầy đủ là nguyên tắc đánh giá được khuyến nghị trong Ferrari Dacrema và cộng sự [8].

4.3 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển

Bảng 4.1 liệt kê cấu hình tốt nhất của từng mô hình. Mọi con số trong bảng là trên tập *xác thực* của mẫu phát triển; chúng lạc quan vì chính tập này được dùng để chọn cấu hình, nên chỉ dùng để chọn, không dùng để kết luận.

Bảng 4.1: Cấu hình tốt nhất của từng mô hình trên tập xác thực của mẫu phát triển (seed 42; 6 cấu hình mỗi mô hình có học, mô hình một tham số thử đủ lưới)

Mô hình	Cấu hình chọn	NDCG@10	HR@10
NeuMF-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03337	0,12807
LateFusion-F	w=0,4 (GMF-F), $1-w$=0,6 (MLP-F)	0,03556	0,14480
GMF-F	d=32; lr=0,001; neg=8; wd=0; bỏ ID=0,25	0,03162	0,13157
MLP-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03212	0,13429
NeuMF	d=64; lr=0,0005; neg=4; wd=10^{-6}; dropout=0,2	0,02696	0,11016
GMF	d=32; lr=0,001; neg=8; wd=10^{-6}	0,02857	0,11405
MLP	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0	0,02742	0,10977
BPR-MF	d=128; lr=0,03; reg=0,001; 20 epoch	0,02636	0,10666
ItemKNN	k=100; shrink=50	0,02599	0,09537
UserKNN	k=200; shrink=0	0,02753	0,10432
Content	chu kỳ bán rã 30 ngày	0,00459	0,02180
MostPopular-Recent	cửa sổ 28 ngày	0,02334	0,10432
Most Popular	—	0,02174	0,09420

d: số chiều embedding; neg: số mẫu âm mỗi mẫu dương; wd: weight decay; bỏ ID: xác suất bỏ embedding ID của sản phẩm khi huấn luyện. Số trên tập xác thực dùng để chọn cấu hình, không dùng để kết luận.

Trên tập xác thực của mẫu phát triển, bốn mô hình có đặc trưng đứng đầu và cách nhau không nhiều: LateFusion-F đạt NDCG@10 = 0,03556 (w=0,4 (GMF-F), $1-w$=0,6 (MLP-F)), NeuMF-F 0,03337 với cấu hình d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0, MLP-F 0,03212 và GMF-F 0,03162; NeuMF chỉ dùng ID đạt 0,02696. Trong các baseline, cao nhất là UserKNN (0,02753), tiếp theo là BPR-MF (0,02636) và ItemKNN (0,02599); MostPopular-Recent đạt 0,02334. Các mạng nơ-ron đạt NDCG@10 tốt nhất trên tập xác thực ở epoch trung vị 7 (muộn nhất epoch 16) trong 36 cấu hình mạng nơ-ron đã thử.

4.4 Kết quả đánh giá cuối trên mẫu kiểm định

4.4.1 So sánh các độ đo xếp hạng (Full Ranking)

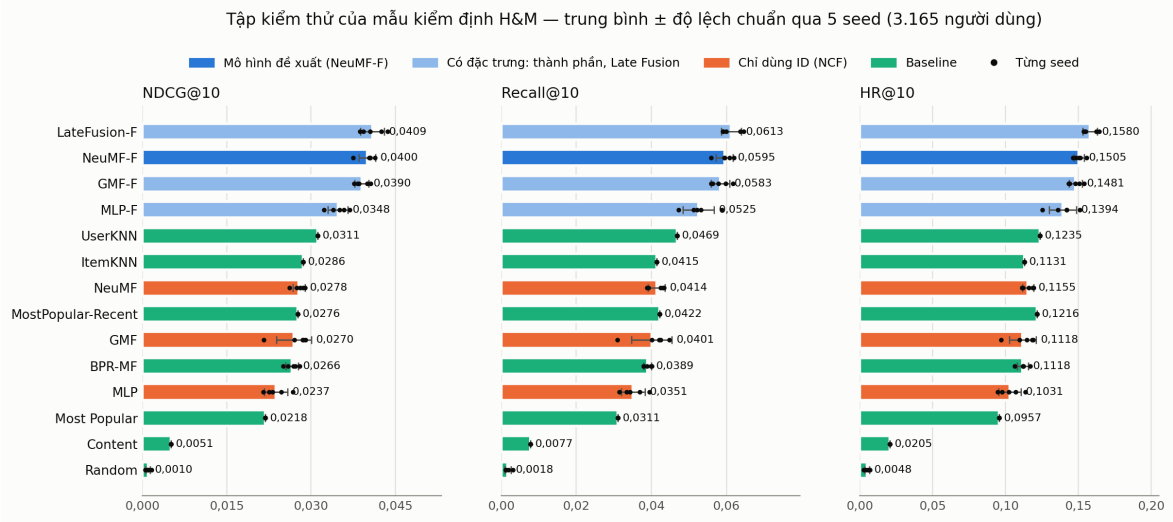
Bảng 4.2 và Hình 4.1 trình bày kết quả trên tập kiểm thử của mẫu kiểm định, trung bình qua 5 seed.

Bảng 4.2: Kết quả trên tập kiểm thử của mẫu kiểm định: trung bình ± độ lệch chuẩn qua 5 seed (xếp hạng trên toàn bộ tập ứng viên; 3.165 người dùng)

Mô hình	NDCG@10	Recall@10	HR@10	Precision@10	NDCG@5	NDCG@20
LateFusion-F	**0,04093** ± 0,00212	**0,06125** ± 0,00268	**0,15798** ± 0,00498	**0,01833** ± 0,00066	**0,03208** ± 0,00246	**0,05304** ± 0,00232
NeuMF-F	0,04003 ± 0,00147	0,05953 ± 0,00226	0,15046 ± 0,00354	0,01723 ± 0,00027	0,03120 ± 0,00178	0,05166 ± 0,00129
GMF-F	0,03902 ± 0,00124	0,05834 ± 0,00243	0,14812 ± 0,00452	0,01712 ± 0,00049	0,03046 ± 0,00080	0,05051 ± 0,00087
MLP-F	0,03480 ± 0,00177	0,05251 ± 0,00417	0,13940 ± 0,00943	0,01584 ± 0,00096	0,02688 ± 0,00093	0,04689 ± 0,00220
UserKNN	0,03114 ± 0,00000	0,04686 ± 0,00000	0,12354 ± 0,00000	0,01365 ± 0,00000	0,02446 ± 0,00000	0,04086 ± 0,00000
ItemKNN	0,02860 ± 0,00000	0,04146 ± 0,00000	0,11311 ± 0,00000	0,01267 ± 0,00000	0,02330 ± 0,00000	0,03835 ± 0,00000
NeuMF	0,02783 ± 0,00109	0,04137 ± 0,00223	0,11545 ± 0,00382	0,01301 ± 0,00037	0,02139 ± 0,00115	0,03701 ± 0,00100
MostPopular-Recent	0,02760 ± 0,00000	0,04219 ± 0,00000	0,12164 ± 0,00000	0,01393 ± 0,00000	0,02161 ± 0,00000	0,03789 ± 0,00000
GMF	0,02695 ± 0,00311	0,04007 ± 0,00539	0,11179 ± 0,00909	0,01243 ± 0,00121	0,02105 ± 0,00181	0,03562 ± 0,00297
BPR-MF	0,02661 ± 0,00114	0,03895 ± 0,00106	0,11179 ± 0,00381	0,01238 ± 0,00040	0,02045 ± 0,00126	0,03641 ± 0,00163
MLP	0,02373 ± 0,00207	0,03510 ± 0,00316	0,10306 ± 0,00765	0,01129 ± 0,00092	0,01812 ± 0,00153	0,03269 ± 0,00195
Most Popular	0,02184 ± 0,00000	0,03107 ± 0,00000	0,09573 ± 0,00000	0,01027 ± 0,00000	0,01783 ± 0,00000	0,02983 ± 0,00000
Content	0,00506 ± 0,00000	0,00772 ± 0,00000	0,02054 ± 0,00000	0,00209 ± 0,00000	0,00384 ± 0,00000	0,00683 ± 0,00000
Random	0,00098 ± 0,00040	0,00176 ± 0,00082	0,00480 ± 0,00169	0,00049 ± 0,00018	0,00059 ± 0,00035	0,00150 ± 0,00039

In đậm: trung bình cao nhất mỗi cột. Mô hình tất định (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN) cho cùng kết quả ở mọi seed.

LateFusion-F đạt NDCG@10 cao nhất (0,04093 ± 0,00212). Mô hình đề xuất NeuMF-F đạt NDCG@10 = 0,04003 ± 0,00147, xếp thứ hai trong 14 mô hình, tiếp theo là GMF-F (0,03902) và MLP-F (0,03480) – bốn mô hình có đặc trưng đứng đầu, như trên tập xác thực. HR@10 của NeuMF-F là 0,15046: khoảng 15% số khách có ít nhất một sản phẩm đúng trong 10 gợi ý đầu. NeuMF chỉ dùng ID đạt 0,02783 ± 0,00109, BPR-MF 0,02661 ± 0,00114, UserKNN 0,03114, ItemKNN 0,02860, MostPopular-Recent 0,02760 và Content 0,00506. Thang giá trị tuyệt đối thấp vì mỗi khách có vài sản phẩm đúng giữa khoảng 6.710 ứng viên, và dự đoán những món



Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử của mẫu kiểm định H&M: trung bình ± độ lệch chuẩn qua 5 seed, chấm đen là từng seed

chưa từng mua trong 8 tuần tới là bài toán khó với dữ liệu thời trang; thông tin quan trọng là thứ hạng tương đối và chênh lệch có ý nghĩa thống kê hay không.

4.4.2 Kết quả theo $K = 5, 10, 15, 20$

Bảng 4.3 và Bảng 4.4 trình bày bốn độ đo ở $K = 5, 10, 15, 20$. Các số ở $K = 15$ được tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối (Thuật toán 3.4), không chấm lại tập kiểm thử; cùng cách tính cho đúng các số ở $K = 5, 10, 20$ của lần đánh giá đó.

Ở mọi K và với cả bốn độ đo, thứ tự của bốn mô hình có đặc trưng giữ nguyên: LateFusion-F, NeuMF-F, GMF-F rồi MLP-F, đứng trên mọi mô hình chỉ dùng ID và mọi baseline. Khi K tăng từ 5 lên 20, HR@K của NeuMF-F tăng từ 0,09352 lên 0,22976 và Recall@K từ 0,03453 lên 0,09451, còn Precision@K giảm từ 0,02046 xuống 0,01403: danh sách dài hơn chứa thêm sản phẩm đúng nhưng tỉ lệ đúng trong danh sách thấp đi. Thứ tự giữa các baseline với nhau có thay đổi nhỏ theo K – ví dụ MostPopular-Recent vượt UserKNN ở HR@15 và HR@20 – nhưng vị trí dẫn đầu của bốn mô hình có đặc trưng không đổi, nên việc chọn $K = 10$ làm độ đo chính (đã đăng ký trước) không làm thay đổi bức tranh chung. Kiểm định thống kê chỉ được thực hiện ở NDCG@10, theo kế hoạch.

4.4.3 Kiểm định ý nghĩa thống kê

Bảng 4.5 và Hình 4.2 trình bày kiểm định họ 10 so sánh đã đăng ký trước (mục 3.6). 7/10 so sánh đã đăng ký đạt tiêu chí "tốt hơn": NeuMF-F cao hơn NeuMF

Bảng 4.3: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định (trung bình qua 5 seed)

	NDCG@K				Recall@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0321**	**0,0409**	**0,0475**	**0,0530**	**0,0364**	**0,0613**	**0,0806**	**0,0985**
NeuMF-F	0,0312	0,0400	0,0464	0,0517	0,0345	0,0595	0,0780	0,0945
GMF-F	0,0305	0,0390	0,0455	0,0505	0,0345	0,0583	0,0771	0,0931
MLP-F	0,0269	0,0348	0,0415	0,0469	0,0300	0,0525	0,0720	0,0893
UserKNN	0,0245	0,0311	0,0357	0,0409	0,0279	0,0469	0,0596	0,0764
ItemKNN	0,0233	0,0286	0,0343	0,0384	0,0263	0,0415	0,0584	0,0713
NeuMF	0,0214	0,0278	0,0330	0,0370	0,0230	0,0414	0,0563	0,0693
MostPopular-Recent	0,0216	0,0276	0,0332	0,0379	0,0244	0,0422	0,0586	0,0730
GMF	0,0211	0,0270	0,0317	0,0356	0,0233	0,0401	0,0539	0,0665
BPR-MF	0,0205	0,0266	0,0320	0,0364	0,0221	0,0389	0,0542	0,0682
MLP	0,0181	0,0237	0,0287	0,0327	0,0199	0,0351	0,0492	0,0619
Most Popular	0,0178	0,0218	0,0255	0,0298	0,0200	0,0311	0,0417	0,0548
Content	0,0038	0,0051	0,0062	0,0068	0,0043	0,0077	0,0108	0,0131
Random	0,0006	0,0010	0,0013	0,0015	0,0007	0,0018	0,0026	0,0033

Tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối (không chấm lại tập kiểm thử); cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột. Độ lệch chuẩn qua seed ở tệp by_k.csv.

Bảng 4.4: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định (trung bình qua 5 seed)

	HR@K				Precision@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0993**	**0,1580**	**0,1999**	**0,2367**	**0,0220**	**0,0183**	**0,0160**	**0,0146**
NeuMF-F	0,0935	0,1505	0,1941	0,2298	0,0205	0,0172	0,0153	0,0140
GMF-F	0,0922	0,1481	0,1917	0,2267	0,0201	0,0171	0,0152	0,0139
MLP-F	0,0861	0,1394	0,1844	0,2215	0,0186	0,0158	0,0145	0,0134
UserKNN	0,0799	0,1235	0,1589	0,1934	0,0167	0,0136	0,0121	0,0114
ItemKNN	0,0733	0,1131	0,1494	0,1779	0,0158	0,0127	0,0116	0,0106
NeuMF	0,0684	0,1155	0,1493	0,1773	0,0149	0,0130	0,0117	0,0107
MostPopular-Recent	0,0787	0,1216	0,1633	0,1991	0,0167	0,0139	0,0127	0,0119
GMF	0,0700	0,1118	0,1440	0,1717	0,0149	0,0124	0,0111	0,0102
BPR-MF	0,0672	0,1118	0,1494	0,1812	0,0140	0,0124	0,0115	0,0108
MLP	0,0604	0,1031	0,1390	0,1676	0,0127	0,0113	0,0105	0,0098
Most Popular	0,0629	0,0957	0,1220	0,1596	0,0128	0,0103	0,0091	0,0091
Content	0,0120	0,0205	0,0297	0,0348	0,0025	0,0021	0,0021	0,0018
Random	0,0021	0,0048	0,0075	0,0099	0,0004	0,0005	0,0005	0,0005

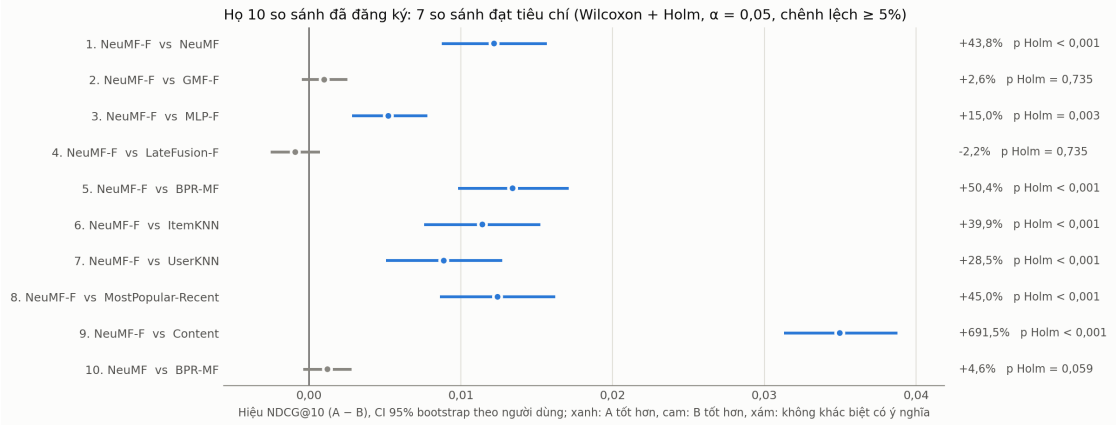
Tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối (không chấm lại tập kiểm thử); cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột. Độ lệch chuẩn qua seed ở tệp by_k.csv.

43,8% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn MLP-F 15,0% ($p_{Holm} = 0{,}003$); NeuMF-F cao hơn BPR-MF 50,4% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn ItemKNN 39,9% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn UserKNN 28,5% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn MostPopular-Recent 45,0% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn Content 691,5% ($p_{Holm} < 0{,}001$).

Bảng 4.5: Kiểm định họ 10 so sánh đã đăng ký trước trên NDCG@10 (H&M, mẫu kiểm định, mỗi người dùng lấy trung bình qua 5 seed): Wilcoxon signed-rank, hiệu chỉnh Holm, khoảng tin cậy bootstrap 95%

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F	NeuMF	0,04003	0,02783	+43,8%	[+0,00876; +0,01566]	< 0,001	A tốt hơn
2	NeuMF-F	GMF-F	0,04003	0,03902	+2,6%	[−0,00045; +0,00253]	0,735	—
3	NeuMF-F	MLP-F	0,04003	0,03480	+15,0%	[+0,00283; +0,00782]	0,003	A tốt hơn
4	NeuMF-F	LateFusion-F	0,04003	0,04093	−2,2%	[−0,00252; +0,00072]	0,735	—
5	NeuMF-F	BPR-MF	0,04003	0,02661	+50,4%	[+0,00982; +0,01712]	< 0,001	A tốt hơn
6	NeuMF-F	ItemKNN	0,04003	0,02860	+39,9%	[+0,00760; +0,01525]	< 0,001	A tốt hơn
7	NeuMF-F	UserKNN	0,04003	0,03114	+28,5%	[+0,00509; +0,01273]	< 0,001	A tốt hơn
8	NeuMF-F	MostPopular-Recent	0,04003	0,02760	+45,0%	[+0,00864; +0,01622]	< 0,001	A tốt hơn
9	NeuMF-F	Content	0,04003	0,00506	+691,5%	[+0,03129; +0,03876]	< 0,001	A tốt hơn
10	NeuMF	BPR-MF	0,02783	0,02661	+4,6%	[−0,00036; +0,00281]	0,059	—

—: không khác biệt có ý nghĩa. "A tốt hơn" (hoặc "B tốt hơn") chỉ khi đồng thời p Holm < 0,05, CI không chứa 0 và chênh lệch tương đối ≥ 5%.



Hình 4.2: Hiệu NDCG@10 (A − B) của họ 10 so sánh đã đăng ký trên H&M, với khoảng tin cậy 95% bootstrap theo người dùng và giá trị p đã hiệu chỉnh Holm

Theo từng câu hỏi nghiên cứu: *(1) đặc trưng có cải thiện mô hình lai không* – NeuMF-F so với NeuMF chênh +43,8% (NeuMF-F tốt hơn có ý nghĩa); *(2) hợp nhất có giúp so với từng nhánh không* – so với GMF-F chênh +2,6% (không khác biệt có ý nghĩa), so với MLP-F chênh +15,0% (NeuMF-F tốt hơn có ý nghĩa); *(3) hợp nhất sớm hay muộn* – so với LateFusion-F chênh −2,2% (không khác biệt có ý nghĩa); *(4) so với các baseline* – BPR-MF +50,4% (NeuMF-F tốt hơn có ý nghĩa), ItemKNN

+39,9% (NeuMF-F tốt hơn có ý nghĩa), UserKNN +28,5% (NeuMF-F tốt hơn có ý nghĩa), MostPopular-Recent +45,0% (NeuMF-F tốt hơn có ý nghĩa), Content +691,5% (NeuMF-F tốt hơn có ý nghĩa); *(5) mô hình lai chỉ dùng ID so với MF* – NeuMF so với BPR-MF chênh +4,6% (không khác biệt có ý nghĩa).

4.4.4 Phân tích bóc tách thành phần (Ablation Study)

Bảng 4.6 và Hình 4.3 so sánh NeuMF-F đầy đủ với bốn biến thể tắt một thành phần, cùng siêu tham số và cùng quy trình huấn luyện (seed 42, mục 3.3.5). Biến thể thứ năm của kế hoạch – không bỏ ID ngẫu nhiên khi huấn luyện – trùng với chính NeuMF-F, vì cấu hình được chọn của NeuMF-F có xác suất bỏ ID $\rho = 0$ (Bảng 4.1), nên không được chạy. Đây là phân tích mô tả với một seed, không dùng để chọn lại cấu hình.

Bảng 4.6: Ablation của NeuMF-F trên tập kiểm thử của mẫu kiểm định (seed 42; cùng siêu tham số, tắt một thành phần)

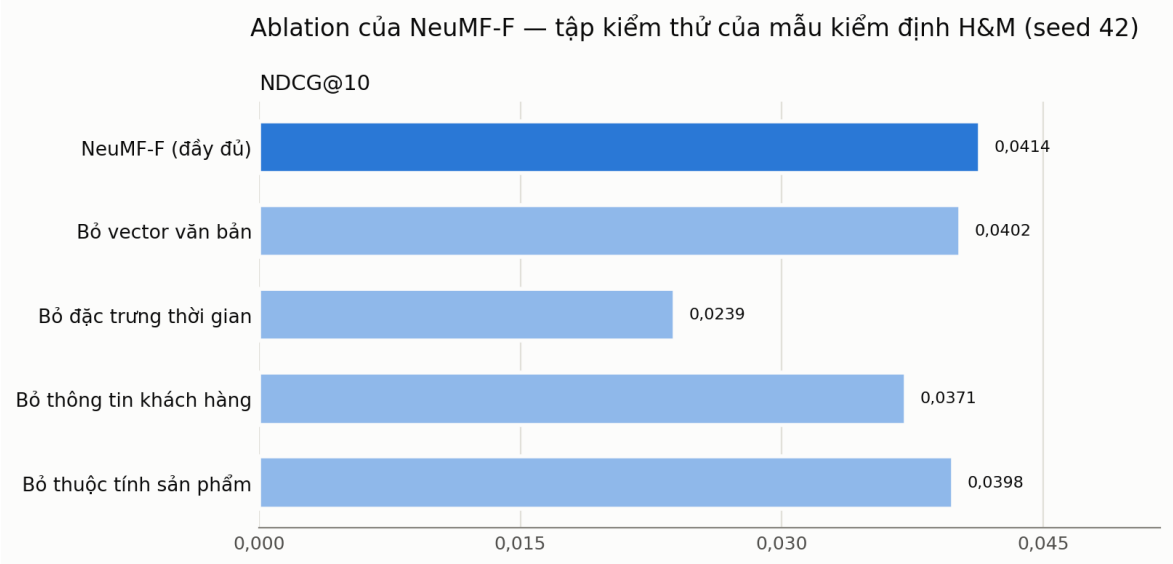
Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,04137	—	—
Bỏ vector văn bản	0,04025	−2,7%	[−0,00450; +0,00236]
Bỏ đặc trưng thời gian	0,02386	−42,3%	[−0,02122; −0,01380]
Bỏ thông tin khách hàng	0,03712	−10,3%	[−0,00720; −0,00132]
Bỏ thuộc tính sản phẩm	0,03983	−3,7%	[−0,00467; +0,00158]

Thay đổi: (biến thể − đầy đủ)/đầy đủ. CI: bootstrap theo người dùng của hiệu biến thể − đầy đủ. Chỉ mô tả, không kiểm định. Biến thể trùng NeuMF-F (vd. không bỏ ID ngẫu nhiên khi cấu hình chọn đã có tỉ lệ bỏ ID bằng 0) không chạy.

So với NeuMF-F đầy đủ (NDCG@10 = 0,04137 ở seed 42), bỏ đặc trưng thời gian làm NDCG@10 thay đổi −42,3% (khoảng tin cậy 95% của hiệu: [−0,02122; −0,01380]), bỏ thông tin khách hàng −10,3% ([−0,00720; −0,00132]), bỏ thuộc tính sản phẩm −3,7% ([−0,00467; +0,00158]) và bỏ vector văn bản −2,7% ([−0,00450; +0,00236]). Đặc trưng thời gian – doanh số gần đây và tuổi của sản phẩm, khoảng cách tới lần mua gần nhất và số sản phẩm đã mua của khách – vì vậy đóng góp nhiều nhất. Khoảng tin cậy của hiệu khi bỏ thuộc tính sản phẩm hoặc vector văn bản chứa 0: với một seed, không khẳng định được hai nhóm đặc trưng này có đóng góp.

4.4.5 Độ phủ và chi phí huấn luyện

Bảng 4.7 mô tả danh sách top-10 (mục 2.5.1) và chi phí huấn luyện. Most Popular và MostPopular-Recent có độ phủ thấp nhất (0,3% và 0,3%) vì mọi khách



Hình 4.3: Ablation của NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M (seed 42): NDCG@10 của NeuMF-F đầy đủ và của từng biến thể tắt một thành phần

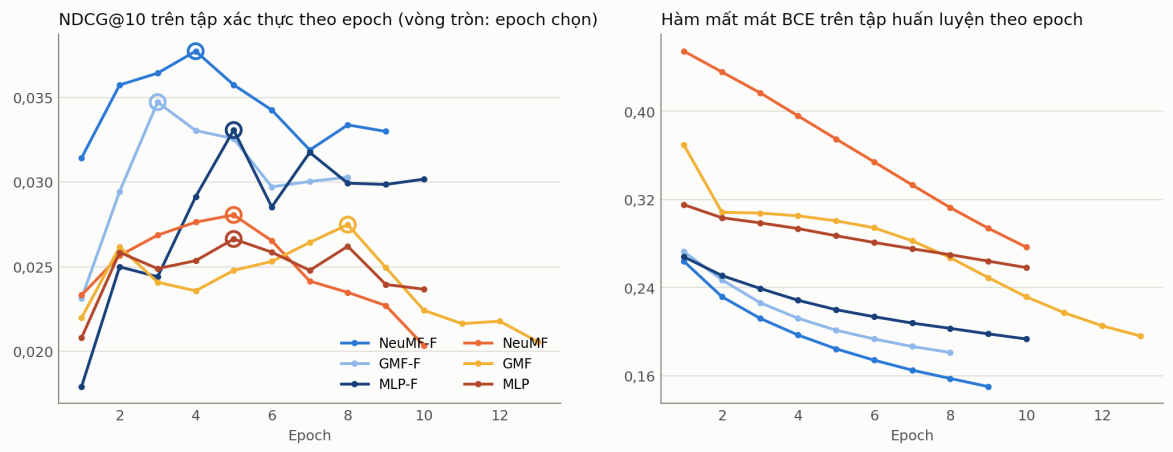
Bảng 4.7: Mô tả danh sách gợi ý top-10 (seed 42) và chi phí huấn luyện trên H&M, mẫu kiểm định (trung bình qua seed)

Mô hình	Độ phủ ứng viên	Số epoch chọn	Thời gian (phút)
LateFusion-F	5,3%	—	0,0
NeuMF-F	13,3%	3,0	15,2
GMF-F	6,9%	4,4	13,7
MLP-F	5,3%	4,6	16,4
UserKNN	5,7%	—	0,0
ItemKNN	20,4%	—	0,0
NeuMF	6,0%	4,2	6,2
MostPopular-Recent	0,3%	—	0,0
GMF	7,3%	6,2	7,2
BPR-MF	5,1%	—	4,3
MLP	3,3%	4,8	8,4
Most Popular	0,3%	—	0,0
Content	78,2%	—	0,0
Random	98,9%	—	0,0

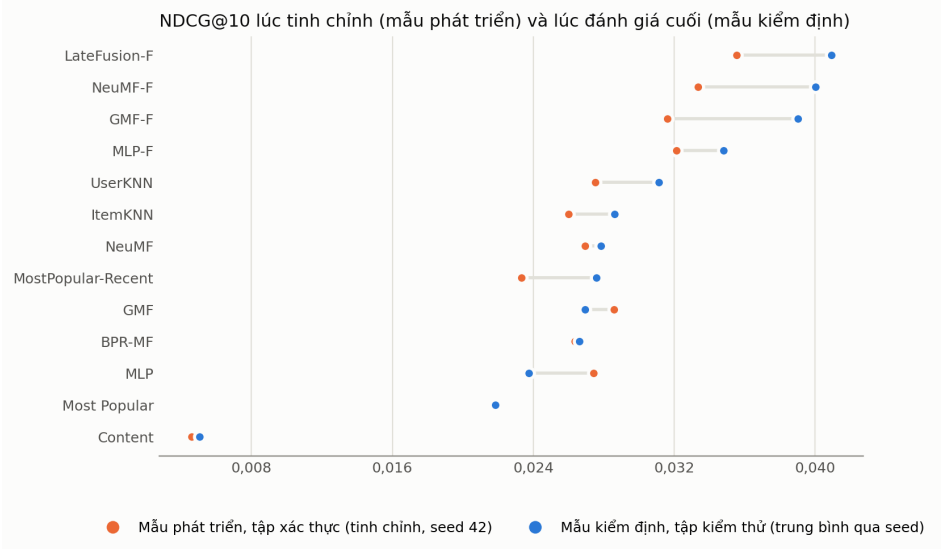
Độ phủ: tỉ lệ sản phẩm của không gian ứng viên xuất hiện trong top-10 của ít nhất một người dùng. Số epoch chọn trên tập xác thực của mẫu kiểm định trước khi huấn luyện lại. Thời gian: chọn epoch + huấn luyện lại (mạng nơ-ron) hoặc khớp mô hình, không gồm thời gian chấm.

nhận gần như cùng một danh sách. Trong các mô hình cá nhân hóa, MLP chỉ dùng ID có độ phủ thấp nhất (3,3%); NeuMF-F có độ phủ cao nhất trong các mạng nơ-ron (13,3%), chỉ sau ItemKNN (20,4%) và Content (78,2%) – mô hình chấm điểm theo độ giống nội dung, không theo độ phổ biến. Thời gian huấn luyện trung bình mỗi seed của NeuMF-F là 15,2 phút, so với 6,2 phút của NeuMF chỉ dùng ID và 4,3 phút của BPR-MF.

4.4.6 Hội tụ và độ ổn định giữa hai mẫu



Hình 4.4: Đường hội tụ của các mạng nơ-ron khi chọn số epoch trên tập xác thực của mẫu kiểm định (seed 42): NDCG@10 trên tập xác thực và hàm mất mát BCE trên tập huấn luyện theo epoch; vòng tròn là epoch được chọn



Hình 4.5: NDCG@10 trên tập xác thực của mẫu phát triển (lúc tinh chỉnh) và trên tập kiểm thử của mẫu kiểm định (đánh giá cuối)

Hình 4.4 cho thấy diễn biến NDCG@10 trên tập xác thực theo epoch khi chọn số epoch cho đánh giá cuối; Hình 4.5 đặt NDCG@10 lúc tinh chỉnh (mẫu phát triển, tập xác thực) cạnh NDCG@10 lúc đánh giá cuối (mẫu kiểm định, tập kiểm thử). Hai con số không cùng thang – khác mẫu khách hàng, và cửa sổ kiểm thử dài gấp đôi cửa sổ xác thực – nên điều cần xem là thứ hạng giữa các mô hình có được giữ khi chuyển sang khách hàng khác hay không. Bốn mô hình có đặc trưng đứng đầu ở cả hai, LateFusion-F và NeuMF-F giữ hai vị trí đầu. Thay đổi thứ hạng lớn nhất thuộc về GMF và MLP chỉ dùng ID – từ thứ năm và thứ bảy lúc tinh chỉnh xuống thứ chín và thứ mười một ở đánh giá cuối, cũng là hai mô hình duy nhất có NDCG@10 trên tập kiểm thử thấp hơn lúc tinh chỉnh – và ItemKNN, từ thứ mười lên thứ sáu.

4.5 Kiểm chứng trên dữ liệu Amazon Beauty

Phần này trả lời một câu hỏi: các kết luận rút ra từ H&M có còn đúng trên một bộ dữ liệu khác hay không. Theo kế hoạch kiểm chứng đã đăng ký trước, ba kết luận của H&M được đối chiếu: *(1)* mô hình có đặc trưng so với mô hình chỉ dùng ID; *(2)* NeuMF-F so với GMF-F, MLP-F và LateFusion-F; *(3)* NeuMF so với BPR-MF. Với từng kết luận, kết quả trên Amazon được ghi là còn đúng, ngược lại, hay không khác biệt có ý nghĩa; mô hình đề xuất và tiêu chí kết luận không được chọn lại sau khi xem kết quả. Hai điều cần nhớ khi đọc: *(i)* mọi mô hình dùng *cấu hình chọn trên H&M* (mục 3.2.6) – nếu một mô hình kém đi trên Amazon, không tách được do bản thân mô hình hay do cấu hình không hợp với dữ liệu này; *(ii)* Amazon chỉ có một bộ dữ liệu, chia theo thời gian, không có mẫu khách hàng độc lập như H&M. Dữ liệu ở Bảng 3.6: 2.644 khách được đánh giá, 6.107 cặp đúng, trung bình 6.058 ứng viên mỗi khách.

4.5.1 Kết quả trên tập kiểm thử Amazon Beauty

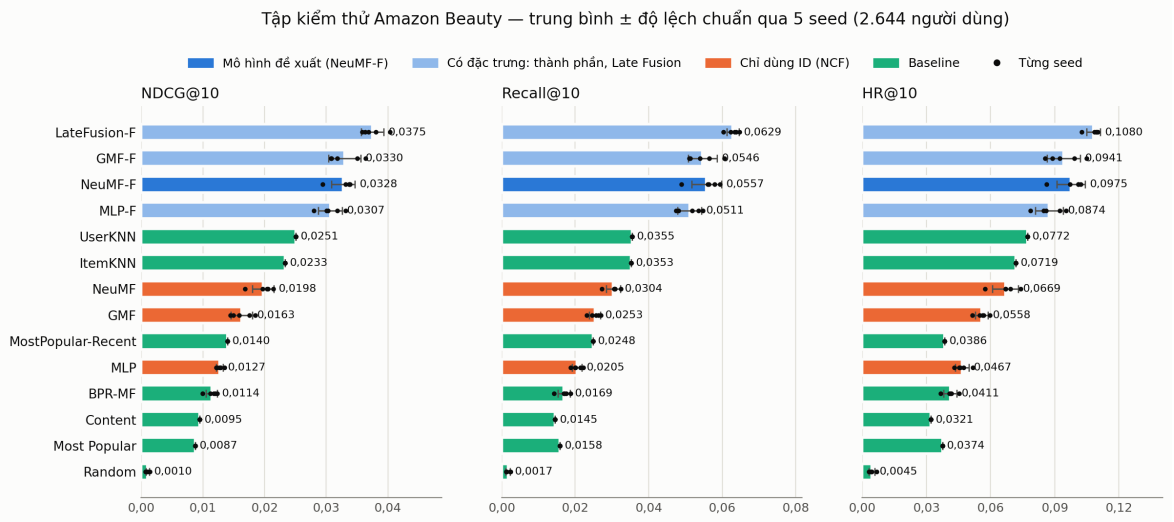
Bảng 4.8 và Hình 4.6 cho kết quả trên tập kiểm thử Amazon. LateFusion-F đạt NDCG@10 cao nhất (0,03747 $\pm$ 0,00180); NeuMF-F đạt 0,03277 $\pm$ 0,00189, xếp thứ ba trong 14 mô hình, sau cả GMF-F (0,03298); MLP-F đạt 0,03065. Như trên H&M, bốn mô hình có đặc trưng đứng đầu, rồi đến UserKNN (0,02506) và ItemKNN (0,02333); NeuMF chỉ dùng ID đạt 0,01978. BPR-MF chỉ đạt 0,01144 – thấp hơn ItemKNN, UserKNN và cả MostPopular-Recent (0,01401), trong khi trên H&M nó xấp xỉ NeuMF chỉ dùng ID. Bảng 4.9 và Bảng 4.10 cho bốn độ đo ở $K = 5, 10, 15, 20$, tính lại từ hạng đã lưu như với H&M.

Trên Amazon, LateFusion-F cao nhất ở mọi K và với cả bốn độ đo. NeuMF-F

Bảng 4.8: Kết quả trên tập kiểm thử Amazon Beauty: trung bình ± độ lệch chuẩn qua 5 seed (xếp hạng trên toàn bộ tập ứng viên; 2.644 người dùng)

Mô hình	NDCG@10	Recall@10	HR@10	Precision@10	NDCG@5	NDCG@20
LateFusion-F	**0,03747** ± 0,00180	**0,06286** ± 0,00167	**0,10802** ± 0,00314	**0,01222** ± 0,00045	**0,02879** ± 0,00222	**0,04571** ± 0,00142
GMF-F	0,03298 ± 0,00259	0,05465 ± 0,00397	0,09410 ± 0,00780	0,01042 ± 0,00088	0,02567 ± 0,00256	0,04159 ± 0,00195
NeuMF-F	0,03277 ± 0,00189	0,05568 ± 0,00403	0,09750 ± 0,00657	0,01092 ± 0,00077	0,02450 ± 0,00148	0,04144 ± 0,00208
MLP-F	0,03065 ± 0,00193	0,05107 ± 0,00327	0,08737 ± 0,00656	0,00998 ± 0,00092	0,02330 ± 0,00151	0,03764 ± 0,00184
UserKNN	0,02506 ± 0,00000	0,03553 ± 0,00000	0,07716 ± 0,00000	0,00930 ± 0,00000	0,02059 ± 0,00000	0,03096 ± 0,00000
ItemKNN	0,02333 ± 0,00000	0,03526 ± 0,00000	0,07186 ± 0,00000	0,00870 ± 0,00000	0,01895 ± 0,00000	0,02789 ± 0,00000
NeuMF	0,01978 ± 0,00176	0,03035 ± 0,00187	0,06694 ± 0,00605	0,00762 ± 0,00090	0,01599 ± 0,00161	0,02542 ± 0,00207
GMF	0,01627 ± 0,00173	0,02533 ± 0,00154	0,05582 ± 0,00303	0,00640 ± 0,00036	0,01287 ± 0,00180	0,02090 ± 0,00166
MostPopular-Recent	0,01401 ± 0,00000	0,02483 ± 0,00000	0,03858 ± 0,00000	0,00416 ± 0,00000	0,00964 ± 0,00000	0,01854 ± 0,00000
MLP	0,01271 ± 0,00054	0,02045 ± 0,00132	0,04667 ± 0,00324	0,00513 ± 0,00037	0,00978 ± 0,00080	0,01694 ± 0,00062
BPR-MF	0,01144 ± 0,00091	0,01691 ± 0,00164	0,04115 ± 0,00309	0,00498 ± 0,00035	0,00883 ± 0,00077	0,01476 ± 0,00082
Content	0,00945 ± 0,00000	0,01448 ± 0,00000	0,03215 ± 0,00000	0,00356 ± 0,00000	0,00737 ± 0,00000	0,01264 ± 0,00000
Most Popular	0,00872 ± 0,00000	0,01576 ± 0,00000	0,03744 ± 0,00000	0,00390 ± 0,00000	0,00619 ± 0,00000	0,00998 ± 0,00000
Random	0,00101 ± 0,00028	0,00168 ± 0,00059	0,00446 ± 0,00143	0,00045 ± 0,00014	0,00066 ± 0,00031	0,00153 ± 0,00031

In đậm: trung bình cao nhất mỗi cột. Mô hình tất định (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN) cho cùng kết quả ở mọi seed. Không tinh chỉnh trên bộ này: cấu hình chọn trên tập xác thực của mẫu phát triển H&M, chỉ số epoch của mạng nơ-ron được chọn trên tập xác thực của chính bộ này.



Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty: trung bình ± độ lệch chuẩn qua 5 seed, chấm đen là từng seed

Bảng 4.9: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty (trung bình qua 5 seed)

	NDCG@K				Recall@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0288**	**0,0375**	**0,0425**	**0,0457**	**0,0378**	**0,0629**	**0,0794**	**0,0904**
GMF-F	0,0257	0,0330	0,0377	0,0416	0,0333	0,0546	0,0700	0,0840
NeuMF-F	0,0245	0,0328	0,0375	0,0414	0,0323	0,0557	0,0715	0,0856
MLP-F	0,0233	0,0307	0,0347	0,0376	0,0302	0,0511	0,0646	0,0749
UserKNN	0,0206	0,0251	0,0284	0,0310	0,0235	0,0355	0,0470	0,0557
ItemKNN	0,0189	0,0233	0,0253	0,0279	0,0220	0,0353	0,0418	0,0510
NeuMF	0,0160	0,0198	0,0228	0,0254	0,0195	0,0304	0,0399	0,0491
GMF	0,0129	0,0163	0,0190	0,0209	0,0156	0,0253	0,0341	0,0407
MostPopular-Recent	0,0096	0,0140	0,0171	0,0185	0,0122	0,0248	0,0351	0,0399
MLP	0,0098	0,0127	0,0148	0,0169	0,0126	0,0205	0,0271	0,0345
BPR-MF	0,0088	0,0114	0,0132	0,0148	0,0094	0,0169	0,0225	0,0278
Content	0,0074	0,0095	0,0115	0,0126	0,0087	0,0145	0,0213	0,0255
Most Popular	0,0062	0,0087	0,0095	0,0100	0,0084	0,0158	0,0186	0,0200
Random	0,0007	0,0010	0,0013	0,0015	0,0007	0,0017	0,0025	0,0035

Tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối (không chấm lại tập kiểm thử); cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột. Độ lệch chuẩn qua seed ở tệp by_k.csv.

Bảng 4.10: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty (trung bình qua 5 seed)

	HR@K				Precision@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0669**	**0,1080**	**0,1358**	**0,1546**	**0,0144**	**0,0122**	**0,0106**	**0,0092**
GMF-F	0,0591	0,0941	0,1200	0,1417	0,0126	0,0104	0,0092	0,0083
NeuMF-F	0,0589	0,0975	0,1224	0,1451	0,0124	0,0109	0,0094	0,0086
MLP-F	0,0524	0,0874	0,1099	0,1275	0,0113	0,0100	0,0085	0,0075
UserKNN	0,0511	0,0772	0,0957	0,1120	0,0114	0,0093	0,0078	0,0069
ItemKNN	0,0492	0,0719	0,0840	0,0983	0,0111	0,0087	0,0069	0,0062
NeuMF	0,0430	0,0669	0,0859	0,1011	0,0093	0,0076	0,0067	0,0061
GMF	0,0356	0,0558	0,0718	0,0846	0,0077	0,0064	0,0056	0,0051
MostPopular-Recent	0,0185	0,0386	0,0537	0,0639	0,0039	0,0042	0,0041	0,0038
MLP	0,0275	0,0467	0,0606	0,0750	0,0058	0,0051	0,0046	0,0043
BPR-MF	0,0244	0,0411	0,0526	0,0635	0,0055	0,0050	0,0045	0,0041
Content	0,0200	0,0321	0,0446	0,0514	0,0042	0,0036	0,0034	0,0030
Most Popular	0,0189	0,0374	0,0446	0,0492	0,0039	0,0039	0,0031	0,0026
Random	0,0020	0,0045	0,0064	0,0084	0,0004	0,0005	0,0004	0,0004

Tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối (không chấm lại tập kiểm thử); cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột. Độ lệch chuẩn qua seed ở tệp by_k.csv.

và GMF-F bám sát nhau và đổi chỗ tùy độ đo: GMF-F cao hơn một chút ở NDCG@K với mọi K, NeuMF-F cao hơn một chút ở Recall@K, HR@K và Precision@K từ $K = 10$ trở lên.

4.5.2 Đối chiếu kết luận giữa H&M và Amazon Beauty

Bảng 4.11: Kiểm định họ 10 so sánh đã đăng ký trước trên NDCG@10 (Amazon Beauty, mỗi người dùng lấy trung bình qua 5 seed): Wilcoxon signed-rank, hiệu chỉnh Holm, khoảng tin cậy bootstrap 95%

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F	NeuMF	0,03277	0,01978	+65,7%	[+0,00936; +0,01681]	< 0,001	A tốt hơn
2	NeuMF-F	GMF-F	0,03277	0,03298	−0,6%	[−0,00228; +0,00186]	0,534	—
3	NeuMF-F	MLP-F	0,03277	0,03065	+6,9%	[−0,00044; +0,00457]	0,050	—
4	NeuMF-F	LateFusion-F	0,03277	0,03747	−12,5%	[−0,00668; −0,00279]	< 0,001	B tốt hơn
5	NeuMF-F	BPR-MF	0,03277	0,01144	+186,5%	[+0,01756; +0,02528]	< 0,001	A tốt hơn
6	NeuMF-F	ItemKNN	0,03277	0,02333	+40,5%	[+0,00477; +0,01417]	< 0,001	A tốt hơn
7	NeuMF-F	UserKNN	0,03277	0,02506	+30,8%	[+0,00313; +0,01232]	< 0,001	A tốt hơn
8	NeuMF-F	MostPopular-Recent	0,03277	0,01401	+134,0%	[+0,01553; +0,02201]	< 0,001	A tốt hơn
9	NeuMF-F	Content	0,03277	0,00945	+246,7%	[+0,01902; +0,02766]	< 0,001	A tốt hơn
10	NeuMF	BPR-MF	0,01978	0,01144	+72,9%	[+0,00630; +0,01038]	< 0,001	A tốt hơn

—: không khác biệt có ý nghĩa. "A tốt hơn" (hoặc "B tốt hơn") chỉ khi đồng thời p Holm $< 0{,}05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$.

Bảng 4.11 là kiểm định họ 10 so sánh trên Amazon, cùng tiêu chí như H&M. 8/10 so sánh đã đăng ký đạt tiêu chí "tốt hơn": NeuMF-F cao hơn NeuMF 65,7% ($p_{Holm} < 0{,}001$); NeuMF-F thấp hơn LateFusion-F 12,5% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn BPR-MF 186,5% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn ItemKNN 40,5% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn UserKNN 30,8% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn MostPopular-Recent 134,0% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn Content 246,7% ($p_{Holm} < 0{,}001$); NeuMF cao hơn BPR-MF 72,9% ($p_{Holm} < 0{,}001$). Bảng 4.12 đặt kết luận của từng so sánh trên hai bộ dữ liệu cạnh nhau; đây là đặt cạnh *kết luận*, không gộp số của hai bộ dữ liệu.

Kết luận (1) – đặc trưng so với chỉ dùng ID: còn đúng. NeuMF-F hơn NeuMF chỉ dùng ID +65,7% trên Amazon (NeuMF-F tốt hơn có ý nghĩa), so với +43,8% trên H&M; bốn mô hình có đặc trưng đứng đầu trên cả hai bộ dữ liệu, và NeuMF-F hơn có ý nghĩa cả năm baseline trong họ so sánh trên cả hai. Đây là kết luận vững nhất của đề tài: nó giữ nguyên khi đổi sang một lĩnh vực khác (mỹ phẩm thay vì thời trang), một loại tương tác khác (đánh giá thay vì lượt mua) và một bộ đặc trưng nghèo hơn (không có thông tin khách hàng), dù không tinh chỉnh lại.

Kết luận (2) – NeuMF-F so với từng nhánh và với hợp nhất muộn: chỉ đúng một phần. NeuMF-F vẫn không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng

Bảng 4.12: Kết luận của họ 10 so sánh đã đăng ký trên H&M (mẫu kiểm định) và trên Amazon Beauty (NDCG@10; chênh lệch $= (A - B)/B$)

#	So sánh (A so với B)	H&M		Amazon Beauty	
		Chênh	**Kết luận**	**Chênh**	**Kết luận**
1	NeuMF-F so với NeuMF	+43,8%	A tốt hơn	+65,7%	A tốt hơn
2	NeuMF-F so với GMF-F	+2,6%	không khác biệt có ý nghĩa	−0,6%	không khác biệt có ý nghĩa
3	NeuMF-F so với MLP-F	+15,0%	A tốt hơn	+6,9%	không khác biệt có ý nghĩa
4	NeuMF-F so với LateFusion-F	−2,2%	không khác biệt có ý nghĩa	−12,5%	B tốt hơn
5	NeuMF-F so với BPR-MF	+50,4%	A tốt hơn	+186,5%	A tốt hơn *
6	NeuMF-F so với ItemKNN	+39,9%	A tốt hơn	+40,5%	A tốt hơn
7	NeuMF-F so với UserKNN	+28,5%	A tốt hơn	+30,8%	A tốt hơn
8	NeuMF-F so với MostPopular-Recent	+45,0%	A tốt hơn	+134,0%	A tốt hơn
9	NeuMF-F so với Content	+691,5%	A tốt hơn	+246,7%	A tốt hơn
10	NeuMF so với BPR-MF	+4,6%	không khác biệt có ý nghĩa	+72,9%	A tốt hơn *

"A tốt hơn" (hoặc "B tốt hơn") chỉ khi đồng thời $p_{Holm} < 0{,}05$, khoảng tin cậy 95% không chứa 0 và chênh lệch $\geq 5\%$. * Trên Amazon, BPR-MF dùng cấu hình chọn trên H&M và kém hơn cả ItemKNN, UserKNN, MostPopular-Recent; hai so sánh có BPR-MF chỉ nên đọc kèm cảnh báo này.

(−0,6%). Lợi thế so với MLP-F trên H&M (+15,0%, có ý nghĩa) không còn trên Amazon: chênh +6,9%, giá trị p đã hiệu chỉnh xấp xỉ ngưỡng 0,05 (0,050) nhưng khoảng tin cậy chứa 0 ([−0,00044; +0,00457]), nên theo tiêu chí là không khác biệt có ý nghĩa. Ngược với H&M, **trên Amazon hợp nhất muộn LateFusion-F tốt hơn NeuMF-F có ý nghĩa** (NeuMF-F thấp hơn −12,5%, khoảng tin cậy [−0,00668; −0,00279]). Kết quả này được báo cáo đúng như vậy: NeuMF-F vẫn là mô hình đề xuất như đã đăng ký trước, và ở đây nó không phải là cách hợp nhất tốt nhất. Một khác biệt có thể góp phần (nhận định, chưa kiểm chứng): trên Amazon, hai nhánh GMF-F và MLP-F có độ phủ top-10 rất khác nhau (32,1% so với 5,4%), tức hai nhánh gợi ý những tập sản phẩm khác nhau, và trộn điểm của hai mô hình huấn luyện riêng tận dụng được sự khác nhau đó; cũng có thể trọng số trộn w và cấu hình chọn trên H&M hợp với LateFusion-F hơn với NeuMF-F.

Kết luận (3) – NeuMF chỉ dùng ID so với BPR-MF: không đối chiếu được. Trên H&M hai mô hình không khác biệt có ý nghĩa (+4,6%); trên Amazon NeuMF hơn BPR-MF +72,9%. Tuy nhiên BPR-MF trên Amazon dùng cấu hình chọn trên H&M (d=128; lr=0,03; reg=0,001; 20 epoch) và kém hơn cả ItemKNN lẫn MostPopular-Recent, nên khoảng cách này nhiều khả năng phản ánh cấu hình không hợp với dữ liệu Amazon hơn là ưu thế của NeuMF; vì không tinh chỉnh trên Amazon, đề tài không tách được hai nguyên nhân. Vì lý do tương tự, mức chênh +186,5% của NeuMF-F so với BPR-MF trên Amazon không nên dùng làm thước đo lợi ích của NeuMF-F.

4.5.3 Ablation và độ phủ trên Amazon Beauty

Bảng 4.13: Ablation của NeuMF-F trên tập kiểm thử Amazon Beauty (seed 42; cùng siêu tham số, tắt một thành phần)

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,03378	—	—
Bỏ vector văn bản	0,03047	−9,8%	[−0,00701; +0,00051]
Bỏ đặc trưng thời gian	0,02310	−31,6%	[−0,01569; −0,00561]
Bỏ thông tin khách hàng	0,03424	+1,3%	[−0,00271; +0,00369]
Bỏ thuộc tính sản phẩm	0,02892	−14,4%	[−0,00844; −0,00133]

Thay đổi: (biến thể − đầy đủ)/đầy đủ. CI: bootstrap theo người dùng của hiệu biến thể − đầy đủ. Chỉ mô tả, không kiểm định. Biến thể trùng NeuMF-F (vd. không bỏ ID ngẫu nhiên khi cấu hình chọn đã có tỉ lệ bỏ ID bằng 0) không chạy. Amazon không có thuộc tính khách: "bỏ thông tin khách hàng" là bỏ đặc trưng thời gian của khách.

Bảng 4.13 lặp lại ablation của NeuMF-F trên Amazon (seed 42). Như trên

H&M, bỏ đặc trưng thời gian làm NDCG@10 giảm nhiều nhất (−31,6%, khoảng tin cậy [−0,01569; −0,00561]). Khác H&M, thuộc tính sản phẩm (thương hiệu, danh mục, nhóm giá) có đóng góp rõ (−14,4%, khoảng tin cậy không chứa 0), còn bỏ thông tin khách hàng – trên Amazon chỉ là hai đặc trưng thời gian của khách – không làm thay đổi có ý nghĩa (+1,3%); bỏ vector văn bản làm NDCG@10 thay đổi −9,8% với khoảng tin cậy chứa 0. Về độ phủ top-10, NeuMF-F đạt 20,5% trên Amazon; Most Popular và MostPopular-Recent vẫn thấp nhất (0,2% và 0,3%).

4.6 Lịch sử phát triển: giai đoạn chỉ dùng mã ID và bản đầu của kế hoạch đánh giá

Trước quy trình đánh giá ở Chương 3, đề tài đã thực nghiệm trong một giai đoạn phát triển ban đầu trên mẫu phát triển: chỉ dùng mã khách hàng và mã sản phẩm (lọc cộng tác thuần), mỗi `article_id` là một sản phẩm, lọc k-core trên toàn bộ mẫu, chỉ giữ người dùng và sản phẩm đã có trong dữ liệu huấn luyện, và đánh giá trên tập kiểm thử của chính mẫu phát triển (2.996 người dùng, 10.216 sản phẩm ứng viên). Bảy mô hình được so sánh: Random, Most Popular, BPR-MF, GMF, MLP và hai biến thể NeuMF – NeuMF-Scratch (khởi tạo ngẫu nhiên) và NeuMF-Pretrained (khởi tạo từ GMF, MLP đã huấn luyện theo chiến lược tiền huấn luyện của He và cộng sự [2]). Kết quả (trung bình 3 seed):

- BPR-MF có NDCG@10 trung bình cao nhất (0,01007); NeuMF-Pretrained đạt 0,00957, NeuMF-Scratch 0,00910, Most Popular 0,00917, GMF 0,00907, MLP 0,00931. Không so sánh nào trong họ 8 so sánh đăng ký trước đạt tiêu chí "tốt hơn" (0/8): NeuMF chỉ dùng ID không vượt MF đã tinh chỉnh, không vượt Most Popular và không khác biệt có ý nghĩa với chính các nhánh GMF, MLP của nó. Tiền huấn luyện không mang lại lợi ích đo được.
- Gần như toàn bộ độ chính xác đến từ nhóm sản phẩm phổ biến nhất (10% sản phẩm được mua nhiều nhất); trên nhóm sản phẩm ít phổ biến, không mô hình nào gợi ý đúng đáng kể.
- Theo giao thức lấy mẫu Sampled-99 (mỗi sản phẩm đúng xếp cùng 99 sản phẩm âm), mọi chỉ số bị thổi phồng nhiều lần và thứ hạng giữa các mô hình thay đổi (Most Popular đứng đầu) – minh họa cho khuyến nghị chỉ dùng Full Ranking [47].

Giai đoạn này để lại ba bài học, là cơ sở trực tiếp của quy trình ở Chương 3: *(i)* với dữ

liệu thưa như H&M, chỉ tăng độ phức tạp của mô hình trên cùng thông tin ID (NeuMF so với MF) không mang lại lợi ích – cần bổ sung *thông tin* chứ không chỉ bổ sung tham số; *(ii)* lọc k-core trên toàn bộ mẫu dùng cả thông tin của giai đoạn kiểm thử; *(iii)* tập kiểm thử của mẫu phát triển đã được xem nhiều lần (27/09, 29/09/2026) và một số quyết định – như bổ sung bước huấn luyện lại trên tập huấn luyện ∪ xác thực, thêm Late Fusion và baseline láng giềng – được đưa ra sau khi đã xem kết quả, nên số liệu của giai đoạn này không còn là ước lượng không thiên lệch.

Bản đầu của kế hoạch đánh giá (khối 1). Kế hoạch đánh giá đầu tiên (đăng ký ngày 03/10/2026) dùng cùng các mô hình, lưới tinh chỉnh, độ đo và họ 10 so sánh như bản cuối, nhưng khác ở ba điểm: mỗi `article_id` (từng màu) là một sản phẩm; tập ứng viên gồm cả sản phẩm mới – chưa từng bán trước mốc dự đoán – với giả định doanh nghiệp biết trước danh mục sắp bán; và mẫu kiểm định là khối 1 (mục 3.2.2). Tập kiểm thử của khối 1 được mở ngày 04/10/2026 (5 seed). Trên khối 1, NDCG@10 trên nhóm sản phẩm đúng mới của mọi mô hình đều dưới 0,002, tức khả năng gợi ý sản phẩm mới hầu như không đo được ở quy mô này. Sau lần đánh giá đó, theo góp ý của giảng viên hướng dẫn, kế hoạch được sửa thành bản cuối (mục 3.6): một sản phẩm là một mẫu thiết kế (`product_code`), bỏ sản phẩm chưa có người mua khỏi tập ứng viên, ghi dữ liệu đã lọc ra tệp kiểm bằng mã MD5. Vì các thay đổi này được quyết định sau khi đã xem kết quả trên khối 1, khối 1 không còn dùng để kết luận: các mô hình được tinh chỉnh lại trên mẫu phát triển theo dữ liệu mới, và đánh giá cuối dùng một mẫu khách hàng chưa từng được dùng – khối 2, tức mẫu kiểm định.

Kết quả của giai đoạn phát triển ban đầu và kết quả trên khối 1 vì vậy chỉ được báo cáo như lịch sử phát triển, không gộp hay đặt cạnh kết quả trên mẫu kiểm định (khác dữ liệu: theo `article_id`, khối 1 còn có sản phẩm mới); mọi kết luận của báo cáo lấy từ mẫu kiểm định, và được kiểm chứng trên Amazon Beauty.

4.7 Phạm vi và giới hạn thực nghiệm

Kết quả của chương này có giá trị trong phạm vi sau: *(i)* một mẫu kiểm định 21.351 khách hàng (khoảng 1,5% khách của H&M; còn 7.994 khách sau lọc $k = 10$), thiên về khách mua nhiều; *(ii)* khung thời gian 07–09/2020; *(iii)* sản phẩm chưa có người mua trước mốc dự đoán – trong đó có sản phẩm vừa ra mắt – không thuộc tập ứng viên (mục 3.2.4), nên kết quả không nói về khả năng gợi ý sản phẩm mới; gợi ý ở mức mẫu thiết kế, không ở mức màu; *(iv)* khách hàng mới chưa có lịch sử mua không được đánh giá định lượng – hệ thống gợi ý cho họ danh sách sản phẩm phổ biến

(mục 3.7); *(v)* lọc k-core dùng mọi cặp trước mốc kiểm thử, nên tập người dùng/sản phẩm ở giai đoạn xác thực phụ thuộc một phần vào dữ liệu tháng 7/2020 – điều này chỉ ảnh hưởng việc chọn cấu hình trên mẫu phát triển, không ảnh hưởng tập kiểm thử của mẫu kiểm định; *(vi)* thuộc tính khách hàng là ảnh chụp tại thời điểm công bố dữ liệu (không có mốc thời gian); *(vii)* ngân sách tinh chỉnh nhỏ (6 cấu hình mỗi mô hình có học), và vài cấu hình được chọn nằm ở biên lưới – BPR-MF với số chiều lớn nhất và hệ số điều chuẩn nhỏ nhất, ItemKNN với hệ số co lớn nhất – nên các mô hình này có thể còn tốt hơn nếu mở rộng lưới; *(viii)* ablation chỉ chạy một seed; *(ix)* kiểm chứng trên bộ dữ liệu thứ hai (Amazon Beauty) dùng lại cấu hình chọn trên H&M, không có mẫu khách hàng độc lập, coi mỗi đánh giá là một tương tác, và dùng nhóm giá tại thời điểm thu thập dữ liệu. Đánh giá cuối được tính trên GPU; chạy lại trên phần cứng khác (CPU so với GPU) có thể làm các mạng nơ-ron lệch nhẹ ở chữ số cuối – kết luận thống kê mới là điều cần được giữ nguyên khi chạy lại.

4.8 Thảo luận

Mô hình lai có đặc trưng có vượt các baseline hay không? Theo tiêu chí đã đăng ký trước, trên H&M: 7/10 so sánh đã đăng ký đạt tiêu chí "tốt hơn": NeuMF-F cao hơn NeuMF 43,8% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn MLP-F 15,0% ($p_{Holm} = 0{,}003$); NeuMF-F cao hơn BPR-MF 50,4% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn ItemKNN 39,9% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn UserKNN 28,5% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn MostPopular-Recent 45,0% ($p_{Holm} < 0{,}001$); NeuMF-F cao hơn Content 691,5% ($p_{Holm} < 0{,}001$). NeuMF-F vượt cả năm baseline trong họ so sánh, với chênh lệch từ +28,5% (UserKNN) đến +691,5% (Content); trên Amazon Beauty, NeuMF-F cũng vượt cả năm baseline (từ +30,8% với UserKNN). So sánh này có ý nghĩa vì ba điều kiện về phương pháp được bảo đảm: mọi mô hình được tinh chỉnh với cùng ngân sách, tập kiểm thử không được dùng để chọn mô hình, và kết luận lấy trên những khách hàng chưa từng được dùng để ra quyết định – các nguyên tắc đánh giá mà đề tài áp dụng theo khuyến nghị của Ferrari Dacrema và cộng sự [8] và Rendle và cộng sự [7].

Đặc trưng đóng góp gì? So sánh NeuMF-F với NeuMF chỉ dùng ID (+43,8%, NeuMF-F tốt hơn có ý nghĩa) đo trực tiếp giá trị của đặc trưng trong cùng kiến trúc hai nhánh; đây là chênh lệch lớn nhất giữa hai mô hình học sâu trong họ so sánh, và nó lặp lại trên Amazon (+65,7%). Ngược lại, khi chỉ dùng ID, mô hình lai NeuMF không khác biệt có ý nghĩa với BPR-MF trên H&M (+4,6%) – cùng kết luận với giai

đoạn phát triển (mục 4.6). Ablation (mục 4.4.4) cho thấy phần lớn đóng góp đến từ đặc trưng thời gian (−42,3% khi bỏ), tiếp theo là thông tin khách hàng (−10,3%); thuộc tính và mô tả văn bản của sản phẩm chỉ có đóng góp nhỏ, chưa tách được khỏi dao động của một seed. Trên Amazon, đặc trưng thời gian cũng đóng góp nhiều nhất (−31,6% khi bỏ). Kết quả này gợi ý rằng xu hướng bán (hay được đánh giá) gần đây của sản phẩm và nhịp mua của khách mang nhiều thông tin về lần mua tiếp theo hơn mô tả tĩnh của sản phẩm.

Kết hợp tuyến tính – phi tuyến có mang lại lợi ích? So với từng nhánh đứng riêng, NeuMF-F chênh +2,6% so với GMF-F (không khác biệt có ý nghĩa) và +15,0% so với MLP-F (NeuMF-F tốt hơn có ý nghĩa); so với hợp nhất muộn của chính hai nhánh, chênh −2,2% (không khác biệt có ý nghĩa). Như vậy trên H&M, khi đã có đặc trưng, hợp nhất sớm hai nhánh vượt nhánh phi tuyến MLP-F nhưng không vượt nhánh tuyến tính GMF-F đứng riêng, và không tốt hơn hợp nhất muộn; LateFusion-F có NDCG@10 trung bình cao nhất nhưng không khác biệt có ý nghĩa với NeuMF-F. Trên Amazon, phần "vượt MLP-F" không còn có ý nghĩa và hợp nhất muộn tốt hơn hợp nhất sớm có ý nghĩa (mục 4.5.2). Lợi ích của mô hình lai vì vậy nằm chủ yếu ở phần đặc trưng chứ không ở cách ghép hai nhánh, và trong hai cách ghép, hợp nhất muộn không kém hơn ở dữ liệu nào trong hai bộ đã thử.

Kết quả trả lời giả thuyết đến đâu? Phần "mô hình lai có đặc trưng tốt hơn các baseline được tinh chỉnh đầy đủ và tốt hơn NeuMF chỉ dùng ID" được ủng hộ theo đúng tiêu chí đã đăng ký, trên cả hai bộ dữ liệu. Phần "hợp nhất sớm hai nhánh tốt hơn từng nhánh và tốt hơn hợp nhất muộn" chỉ được ủng hộ so với nhánh MLP-F trên H&M, và bị bác bỏ ở so sánh với hợp nhất muộn trên Amazon. Kết quả được báo cáo đúng như quy tắc đã đăng ký trước, không chọn lọc số liệu có lợi; giá trị của đề tài vì vậy nằm ở cả mô hình lẫn một quy trình đánh giá đáng tin cậy – đặc trưng không dùng thông tin tương lai, cùng ngân sách tinh chỉnh, mẫu kiểm định độc lập, khoá tập kiểm thử, kiểm định cặp có hiệu chỉnh đa so sánh, kiểm chứng trên bộ dữ liệu thứ hai – cho phép tách riêng đóng góp của từng thành phần.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đối chiếu với các mục tiêu ở mục 1.2.1, đề tài đạt được các kết quả sau:

1. **Cơ sở lý thuyết:** Hệ thống hóa lý thuyết về lọc cộng tác trên phản hồi ẩn, nhân tử hóa ma trận, BPR, GMF, MLP, mô hình lai NeuMF, hai cách hợp nhất Early Fusion và Late Fusion, mô hình lai dựa trên đặc trưng và khởi đầu lạnh của sản phẩm [1], [2], [15], [25], [33], cùng các nghiên cứu về phương pháp đánh giá hệ gợi ý [7], [8], [47]; đối chiếu thiết lập thực nghiệm của ba nghiên cứu nền tảng (mục 2.6.1).
2. **Quy trình dữ liệu tái lập được, không rò rỉ thông tin tương lai:** lấy hai mẫu khách hàng không giao nhau từ 31,8 triệu giao dịch H&M; coi mỗi mẫu thiết kế (`product_code`) là một sản phẩm; lọc k-core chỉ trên dữ liệu trước mốc kiểm thử; ghi dữ liệu đã lọc ra tệp kiểm bằng mã MD5 để mọi mô hình dùng đúng cùng dữ liệu; đặc trưng sản phẩm, khách hàng và thời gian được tính theo thời điểm; lấy mẫu âm chỉ trong sản phẩm đã ra mắt; các điều kiện này được kiểm chứng bằng bộ kiểm thử tự động (mục 3.2). Các bước chính được trình bày thành mã giả (Thuật toán 3.1–3.6).
3. **Mô hình đề xuất NeuMF-F:** giữ cấu trúc hai nhánh GMF và MLP hợp nhất sớm của NeuMF, biểu diễn mỗi khách hàng và sản phẩm bằng Embedding ID cộng phép chiếu của đặc trưng, với cơ chế bỏ ngẫu nhiên ID sản phẩm khi huấn luyện là một siêu tham số được tinh chỉnh (mục 3.3); cùng các mô hình đối chiếu trên cùng khung (GMF-F, MLP-F, LateFusion-F, NeuMF chỉ dùng ID) và bảy baseline được tinh chỉnh cùng ngân sách.
4. **Đánh giá không thiên lệch:** tinh chỉnh chỉ trên tập xác thực của mẫu phát triển; đánh giá cuối một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước, có khoá tập kiểm thử và nhật ký truy cập; 5 seed; kiểm định Wilcoxon theo người dùng kèm bootstrap và hiệu chỉnh Holm trên họ 10 so sánh (mục 3.6); chỉ số ở $K = 5, 10, 15, 20$.
5. **Kết quả chính trên H&M:** Trên tập kiểm thử của mẫu kiểm định, NeuMF-F đạt NDCG@10 = 0,04003 $\pm$ 0,00147 (xếp thứ hai trong 14 mô hình, sau LateFusion-F với 0,04093); NeuMF chỉ dùng ID đạt 0,02783, BPR-MF

0,02661, UserKNN 0,03114, MostPopular-Recent 0,02760. 7/10 so sánh đã đăng ký đạt tiêu chí "tốt hơn": NeuMF-F cao hơn NeuMF 43,8% (p_{Holm} < 0,001); NeuMF-F cao hơn MLP-F 15,0% (p_{Holm} = 0,003); NeuMF-F cao hơn BPR-MF 50,4% (p_{Holm} < 0,001); NeuMF-F cao hơn ItemKNN 39,9% (p_{Holm} < 0,001); NeuMF-F cao hơn UserKNN 28,5% (p_{Holm} < 0,001); NeuMF-F cao hơn MostPopular-Recent 45,0% (p_{Holm} < 0,001); NeuMF-F cao hơn Content 691,5% (p_{Holm} < 0,001). Bổ sung đặc trưng là nguồn cải thiện chính – NeuMF-F so với NeuMF chỉ dùng ID chênh +43,8% – trong đó đặc trưng thời gian đóng góp nhiều nhất (bỏ đi, NDCG@10 thay đổi −42,3%). Hợp nhất sớm hai nhánh vượt nhánh MLP-F đứng riêng (+15,0%) nhưng không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng (+2,6%) và với hợp nhất muộn LateFusion-F (−2,2%). Bốn mô hình có đặc trưng giữ nguyên thứ tự và vị trí dẫn đầu ở mọi $K = 5, 10, 15, 20$. Kết quả được báo cáo đầy đủ theo đúng kế hoạch đã đăng ký (Chương 4).

6. **Kiểm chứng trên Amazon Beauty:** chạy lại toàn bộ đánh giá cuối với cấu hình chọn trên H&M. Kết luận về đặc trưng còn đúng: NeuMF-F hơn NeuMF chỉ dùng ID +65,7% và hơn có ý nghĩa cả năm baseline. Kết luận về cách hợp nhất không còn đúng hoàn toàn: NeuMF-F không khác biệt có ý nghĩa với GMF-F lẫn MLP-F, và LateFusion-F tốt hơn NeuMF-F có ý nghĩa (NeuMF-F thấp hơn −12,5%). So sánh với BPR-MF trên Amazon không dùng để kết luận vì cấu hình của BPR-MF chọn trên H&M không hợp với dữ liệu này (mục 4.5).
7. **Khả năng triển khai:** Hệ thống demo FastAPI chỉ suy diễn, dùng đúng các mô hình của đánh giá cuối trên H&M và Amazon Beauty, tự kiểm tra khớp dữ liệu với lần chạy đã huấn luyện; khách hàng mới chưa có lịch sử được gợi ý sản phẩm phổ biến, khách đã có lịch sử nhận gợi ý của mô hình đề xuất, nên hệ thống luôn có gợi ý (mục 3.7, 3.8).

5.2 Hạn chế của đề tài

– **Quy mô dữ liệu:** Hai mẫu khoảng 500.000 giao dịch (mỗi mẫu khoảng 1,5% khách hàng), không phải toàn bộ 31,8 triệu giao dịch, vì đánh giá Full Ranking trên toàn bộ danh mục vượt khả năng của phần cứng sẵn có (máy tính cá nhân, RAM 16 GB).

– **Ngưỡng k-core = 10:** chọn vì giới hạn bộ nhớ thay vì ngưỡng thường gặp

$k = 5$; dữ liệu sau lọc thiên về khách mua nhiều, nên kết quả chưa đại diện cho khách ít giao dịch.

- **Phạm vi sản phẩm:** sản phẩm chưa có người mua trước mốc dự đoán – trong đó có sản phẩm vừa ra mắt – không thuộc tập ứng viên, nên kết quả không nói về khả năng gợi ý sản phẩm mới; gợi ý ở mức mẫu thiết kế, không ở mức màu. Thuộc tính khách hàng không có mốc thời gian nên được coi là ít thay đổi.
- **Khách hàng mới:** khách chưa có lịch sử mua được gợi ý danh sách phổ biến; đề tài không đánh giá định lượng chất lượng gợi ý cho nhóm khách này.
- **Kiểm chứng trên bộ dữ liệu thứ hai còn hạn chế:** kết luận trên H&M đúng cho khách hàng khác của cùng cửa hàng trong giai đoạn 07–09/2020. Phần kiểm chứng trên Amazon Beauty dùng lại cấu hình chọn trên H&M (một số mô hình, nhất là BPR-MF, có thể bị thiệt), không có mẫu khách hàng độc lập, coi mỗi đánh giá là một lần mua, và dùng nhóm giá tại thời điểm thu thập dữ liệu (năm 2014) chứ không phải giá tại ngày của từng đánh giá.
- **Ngân sách tinh chỉnh:** mỗi mô hình có học chỉ được thử 6 cấu hình; vài cấu hình được chọn nằm ở biên lưới (mục 4.7), nên một số mô hình có thể còn tốt hơn nếu mở rộng lưới.
- **Phạm vi đặc trưng và mô hình:** chưa dùng ảnh sản phẩm, giá (trên H&M), chuỗi hành vi; mô tả văn bản chỉ được biểu diễn bằng TF-IDF và SVD; ablation chỉ chạy một seed.
- **Lịch sử phát triển:** tập kiểm thử của mẫu phát triển đã được xem nhiều lần ở giai đoạn phát triển ban đầu, và tập kiểm thử của khối 1 đã được mở ở bản đầu của kế hoạch đánh giá trước khi kế hoạch được sửa thành bản cuối (mục 4.6); hai lần đánh giá này vì vậy chỉ được dùng như lịch sử phát triển. Thiết kế bản cuối có tham khảo những gì rút ra từ hai giai đoạn đó – nhưng không dùng bất kỳ dữ liệu nào của mẫu kiểm định.

5.3 Hướng phát triển

1. **Đặc trưng đa phương thức:** biểu diễn mô tả sản phẩm bằng mô hình ngôn ngữ (ví dụ BERT) và ảnh sản phẩm bằng mạng tích chập, hoặc dùng Transformer để hợp nhất nhiều view như hướng của Hồ Thị Linh [11], với

cùng quy trình đánh giá không thiên lệch để đo đúng lợi ích so với vector TF-IDF hiện tại.

2. **Gợi ý sản phẩm mới:** đưa lại sản phẩm chưa có người mua vào tập ứng viên, với một giả định về danh mục được nêu rõ, để đo riêng khả năng xử lý khởi đầu lạnh của sản phẩm – điều bản đầu của kế hoạch đánh giá đã thử nhưng không đo được rõ ở quy mô mẫu hiện tại (mục 4.6).
3. **Khách hàng mới:** thay danh sách phổ biến chung bằng danh sách phổ biến gần đây hoặc theo nhóm khách (tuổi, khu vực mua sắm) và đánh giá riêng trên nhóm khách chưa có lịch sử.
4. **Hợp nhất muộn có trọng số học được:** kết quả trên Amazon cho thấy hợp nhất muộn có thể tốt hơn hợp nhất sớm; bước tiếp theo là thay trọng số cố định của Late Fusion bằng trọng số học được theo nhóm khách hàng (ví dụ ít/nhiều giao dịch) hoặc theo loại sản phẩm (ví dụ bán chạy/ít bán).
5. **Mở rộng quy mô và kiểm chứng chéo:** chạy trên mẫu lớn hơn với $k = 5$ hoặc trên toàn bộ H&M bằng Full Ranking theo lô trên GPU, lặp lại trên khung thời gian khác; trên Amazon, tinh chỉnh riêng cho bộ dữ liệu này để tách ảnh hưởng của cấu hình khỏi bản thân mô hình. Quy trình hiện tại tách phần đọc dữ liệu thành adapter riêng nên chỉ cần bổ sung một adapter mới cho mỗi bộ dữ liệu.
6. **Mô hình chuỗi, đồ thị và tự mã hóa biến phân:** thử SASRec [37], LightGCN [40] hoặc Mult-VAE [41] trên cùng giao thức, với baseline được tinh chỉnh cùng ngân sách.
7. **Triển khai:** kiểm tra đầy đủ bản đóng gói Docker của demo; với danh mục lớn, dùng kiến trúc hai tháp và tìm kiếm lân cận gần đúng [46] thay vì chấm điểm toàn bộ danh mục bằng MLP.

5.4 Triển khai thực tế giao diện thực nghiệm

Thiết kế hệ thống demo (mục 3.8) đã được cài đặt thành hệ thống chạy được: chọn bộ dữ liệu H&M hoặc Amazon Beauty, nạp đúng trọng số của đánh giá cuối để suy diễn trực tiếp, tự đối chiếu dữ liệu với lần chạy trước khi nạp, tính lại các chỉ số theo người dùng khớp với kết quả của Chương 4 ở $K = 5, 10, 15, 20$, và minh họa "Top-K khách tương đồng" bằng UserKNN. Khách đã có lịch sử nhận gợi ý của mô hình được chọn; khách chưa có trong dữ liệu đã học nhận danh sách sản phẩm phổ biến kèm nhãn "gợi ý phổ biến" thay vì thông báo lỗi (Thuật toán 3.6). Tệp Dockerfile

đã có nhưng chưa được kiểm tra đầy đủ; đây là công việc tiếp theo nêu ở mục 5.3.

PHỤ LỤC A. ĐỐI CHIẾU LUẬN ĐIỂM VÀ NGUỒN TRÍCH DẪN

Phụ lục này liệt kê từng luận điểm lý thuyết và phương pháp luận được sử dụng trong dự án kèm nguồn gốc học thuật tương ứng, nhằm bảo đảm mọi khẳng định đều truy nguyên được về tài liệu công bố chính thống. Các tài liệu là cơ sở về phương pháp; số liệu của chúng không được dùng làm chuẩn so sánh với kết quả của đề tài.

Mục	**Luận điểm**	**Nguồn**
A.1. Tổng quan về Hệ thống gợi ý & Lọc cộng tác		
1.1.1	Vai trò cá nhân hóa gợi ý trong thương mại điện tử	Schafer và cộng sự [4]; Linden và cộng sự [5]
2.1.1, 4.2	Lọc dựa trên nội dung; hệ gợi ý lai kết hợp nội dung với cộng tác	Lops và cộng sự [20]; Burke [23]
2.1.2	Nền tảng Lọc cộng tác dựa trên bộ nhớ (Memory-based CF, GroupLens, Item-based CF)	Resnick và cộng sự [24]; Sarwar và cộng sự [21]; Su và Khoshgoftaar [22]
2.1.2, 4.2	Baseline láng giềng (ItemKNN, UserKNN); nguyên tắc đặt mô hình học sâu cạnh baseline đơn giản được tinh chỉnh đầy đủ	Sarwar và cộng sự [21]; Ferrari Dacrema và cộng sự [8]
1.1.2	Hạn chế của tích vô hướng trong Nhân tử hóa ma trận (Matrix Factorization)	Koren và cộng sự [1]; He và cộng sự [2]
2.1.4, 1.1.2	Khởi đầu lạnh (Cold-Start) và nhu cầu kết hợp thông tin nội dung	Schein và cộng sự [6]
1.2.2	Bộ dữ liệu H&M Personalized Fashion Recommendations	H&M Group [3]
3.2.6	Bộ dữ liệu đánh giá sản phẩm Amazon (2014), danh mục Beauty, bản 5-core – dữ liệu kiểm chứng	McAuley và cộng sự [14]
A.2. Phản hồi ẩn, NCF, mô hình lai có đặc trưng & chiến lược hợp nhất		
2.2.3	Xếp hạng cá nhân hóa Bayes (BPR) từ phản hồi ẩn	Rendle và cộng sự [25]

Mục	Luận điểm	Nguồn
2.3	Khung làm việc NCF và kiến trúc mô hình lai NeuMF (GMF + MLP)	He và cộng sự [2]
2.4.1, 3.3.2	Mô hình lai dựa trên đặc trưng: Factorization Machines, Wide & Deep, DeepFM, DIN	Rendle [15]; Cheng và cộng sự [9]; Guo và cộng sự [10]; Zhou và cộng sự [32]
2.4.1, 3.3.1	Bỏ ngẫu nhiên biểu diễn sở thích khi huấn luyện để chấm được đối tượng khởi đầu lạnh (DropoutNet)	Volkovs và cộng sự [33]
2.4.1, 3.2.5	Biểu diễn văn bản bằng TF-IDF và phân tích ngữ nghĩa tiềm ẩn (SVD rút gọn)	Salton và Buckley [34]; Deerwester và cộng sự [35]
2.3.4	Chiến lược hợp nhất Early Fusion và Late Fusion; Late Fusion có trọng số là kiểu lai weighted	Atrey và cộng sự [28]; Liu và cộng sự [29]; Hồ Thị Linh [11]; Burke [23]
3.4.2	Thuật toán tối ưu hóa thích ứng Adam	Kingma và Ba [16]
A.3. Xu hướng nghiên cứu hiện đại		
2.4.2	Gợi ý theo chuỗi hành vi và Transformer	Hidasi và cộng sự [36]; Kang và McAuley [37]; Sun và cộng sự [38]
2.4.3	Học biểu diễn trên đồ thị (Graph-based Collaborative Filtering)	Wang và cộng sự [39]; He và cộng sự [40]
2.4.4	Tự mã hóa biến phân cho lọc cộng tác (Mult-VAE)	Liang và cộng sự [41]
2.4	Học tự giám sát, gợi ý sinh, mô hình ngôn ngữ lớn, mô hình khuếch tán; kiến trúc hai tháp; khảo sát tổng quan	Wu và cộng sự [42]; Rajput và cộng sự [43]; Wu và cộng sự [44]; Wei và Fang [45]; Covington và cộng sự [46]; Zhang và cộng sự [30]; Li và cộng sự [31]
A.4. Đánh giá Top-K, cài đặt & kiểm định		
2.5	Giao thức đánh giá hiệu năng xếp hạng Top-N Recommendation	Cremonesi và cộng sự [50]; He và cộng sự [2]

Mục	Luận điểm	Nguồn
2.5, 4.6	Vấn đề đánh giá bằng tập ứng viên lấy mẫu (Sampled Metrics); chọn Full Ranking	Krichene và Rendle [47]
3.2.4	Chia dữ liệu theo một mốc thời gian chung thay vì Leave-One-Out	Meng và cộng sự [49]
3.6, 4.8	Baseline phải được tinh chỉnh cùng ngân sách; không chọn mô hình trên tập kiểm thử	Ferrari Dacrema và cộng sự [8]; Rendle và cộng sự [7]
2.6.1	Ba nghiên cứu nền tảng: kiến trúc NeuMF, tái đánh giá NeuMF so với MF, hợp nhất đa nguồn Early/Late Fusion	He và cộng sự [2]; Rendle và cộng sự [7]; Hồ Thị Linh [11]
2.2.1, 4.6	Thuật toán iALS cho phản hồi ẩn và cách tinh chỉnh iALS	Hu và cộng sự [26]; Rendle và cộng sự [27]
3.6	Kiểm định Wilcoxon signed-rank, paired bootstrap, hiệu chỉnh Holm	Wilcoxon [17]; Efron và Tib-shirani [18]; Holm [19]
1.3	Nền tảng và thư viện tính toán học sâu PyTorch	Paszke và cộng sự [12]
2.5	Đánh giá xếp hạng dựa trên độ đo NDCG	Järvelin và Kekäläinen [13]
2.5.1	Thiên lệch phổ biến và các chỉ số ngoài độ chính xác	Vargas và Castells [48]

Ghi chú. Các thông số cấu hình và thiết kế hệ thống trình bày trong Chương 3 và kết quả thực nghiệm trong Chương 4 do nhóm tác giả tự triển khai và tính toán từ mã nguồn thực nghiệm của dự án.

PHỤ LỤC B. TÁI LẬP KẾT QUẢ THỰC NGHIỆM

Mã nguồn nằm trong thư mục `neumf_project/` của kho mã dự án; hướng dẫn chi tiết ở tệp `README.md`. Các bước tạo ra toàn bộ số liệu của Chương 4 (tên lệnh giữ nguyên như trong mã nguồn):

1. **Dữ liệu:** đặt `transactions_train.csv`, `articles.csv` và `customers.csv` của cuộc thi H&M vào `data/raw/hm/`; chạy `python run.py sample-hm` để tạo mẫu phát triển và `python run.py v2-data` để tạo mẫu kiểm định, các tệp đặc trưng (danh mục sản phẩm, doanh số theo ngày) và tệp dữ liệu đã lọc của hai mẫu (gộp theo `product_code`, lọc 10-core) kèm mã MD5 trong `outputs/data/manifest.json`. Mọi bước đều tất định.
2. **Tinh chỉnh (chỉ tập xác thực của mẫu phát triển):** `python run.py v2-tune --resume`; mỗi cấu hình ghi một dòng vào `audit/v2/tuning_log.csv` (kèm phiên bản và mã băm nội dung mã nguồn), cấu hình tốt nhất vào `audit/v2/best_configs.json`.
3. **Đăng ký trước:** kế hoạch `audit/PREREG_v2.md` phải được lưu vào git trước bước đánh giá cuối.
4. **Chạy thử (không chạm tập kiểm thử):** `python run.py v2-dry-run` chạy trọn đường ống đánh giá cuối trên tập xác thực của mẫu phát triển với 1 epoch, để phát hiện lỗi trước khi mở tập kiểm thử.
5. **Đánh giá cuối:** `python run.py v2-final --reason "..."` chạy `23_final_v2.py` (5 seed trên mẫu kiểm định, có khoá tập kiểm thử: từ chối chạy nếu kế hoạch chưa lưu, thiếu lý do, mã nguồn có thay đổi chưa lưu hoặc khác mã nguồn lúc tinh chỉnh; mỗi seed ghi một dòng vào `audit/test_access_log.csv` trước khi chấm) rồi `24_report_v2.py` (kiểm định, chỉ số ở $K = 5, 10, 15, 20$ tính từ hạng đã lưu, bảng, hình và macro số liệu sang báo cáo; bản tóm tắt dạng chữ ở `outputs/v2/final/ket_qua.txt`).
6. **Kiểm chứng trên Amazon Beauty:** đặt tệp đánh giá và metadata danh mục Beauty (2014) vào `data/raw/amazon/`; `python run.py amazon-data` tạo đặc trưng và tệp dữ liệu đã lọc (5-core), `python run.py amazon-final --reason "..."` chạy đánh giá cuối theo

kế hoạch `audit/PREREG_amazon.md` với cấu hình chọn trên H&M; `python run.py amazon-report` xuất bảng, hình và macro vào `content/tables/amazon/` và `media/figures/amazon/`.

7. **Đối chiếu câu chữ:** `python run.py check-report` kiểm tra các câu nhận xét bằng chữ trong báo cáo với số liệu hiện có và báo các macro, bảng, hình còn thiếu.
8. **Biên dịch báo cáo:** chạy `compile.bat` trong thư mục báo cáo.

Kế hoạch của giai đoạn phát triển ban đầu (mục 4.6) vẫn ở `audit/PREREG.md`; mã nguồn và kết quả của giai đoạn này được giữ trong lịch sử git (commit `9799f1a`, trước khi dọn mã cũ). Kế hoạch của bản đầu kế hoạch đánh giá (đánh giá trên khối 1) ở `audit/PREREG_v2_cu.md`. Nhật ký `audit/test_access_log.csv` liệt kê mọi lần đánh giá trên tập kiểm thử – giai đoạn phát triển ban đầu, bản đầu và bản cuối của kế hoạch đánh giá (kể cả lần chạy lại seed 42), và đánh giá cuối trên Amazon Beauty – kèm phiên bản mã nguồn và mã băm cấu hình tương ứng.

TÀI LIỆU THAM KHẢO

Y. Koren, R. Bell, và C. Volinsky, “Matrix Factorization Techniques for Recommender Systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, “Neural Collaborative Filtering,” in *Proceedings of the 26th International Conference on World Wide Web (WWW ’17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

H&M Group, *H&M Personalized Fashion Recommendations*, https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations, Cuộc thi trên Kaggle, 2022.

J. B. Schafer, J. A. Konstan, và J. Riedl, “E-Commerce Recommendation Applications,” *Data Mining and Knowledge Discovery*, vol. 5, no. 1-2, pp. 115–153, 2001. DOI: 10.1023/A:1009804230409

G. Linden, B. Smith, và J. York, “Amazon.com Recommendations: Item-to-Item Collaborative Filtering,” *IEEE Internet Computing*, vol. 7, no. 1, pp. 76–80, 2003. DOI: 10.1109/MIC.2003.1167344

A. I. Schein, A. Popescul, L. H. Ungar, và D. M. Pennock, “Methods and Metrics for Cold-Start Recommendations,” in *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’02)*, 2002, pp. 253–260.

S. Rendle, W. Krichene, L. Zhang, và J. Anderson, “Neural Collaborative Filtering vs. Matrix Factorization Revisited,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys ’20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, “Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys ’19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

H.-T. Cheng và cộng sự, “Wide & Deep Learning for Recommender Systems,” in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS 2016)*, Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, “DeepFM: A Factorization-Machine based Neural Network for CTR Prediction,” in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

Hồ Thị Linh, “Multi-Source Integration for Recommendation Systems,” Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

K. Järvelin và J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

J. McAuley, C. Targett, Q. Shi, và A. van den Hengel, “Image-Based Recommendations on Styles and Substitutes,” in *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’15)*, Santiago, Chile, 2015, pp. 43–52. DOI: 10.1145/2766462.2767755

S. Rendle, “Factorization Machines,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

P. Lops, M. de Gemmis, và G. Semeraro, “Content-based Recommender Systems: State of the Art and Trends,” in *Recommender Systems Handbook*, F. Ricci, L. Rokach, B. Shapira, và P. B. Kantor, eds., Springer, 2011, pp. 73–105.

B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, “Item-based Collaborative Filtering Recommendation Algorithms,” in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

X. Su và T. M. Khoshgoftaar, “A Survey of Collaborative Filtering Techniques,” *Advances in Artificial Intelligence*, vol. 2009, pp. 1–19, 2009. DOI: 10.1155/2009/421425

R. Burke, “Hybrid Recommender Systems: Survey and Experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, và J. Riedl, “GroupLens: An Open Architecture for Collaborative Filtering of Netnews,” in *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, 1994, pp. 175–186. DOI: 10.1145/192844.192905

S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, “BPR: Bayesian Personalized Ranking from Implicit Feedback,” in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI ’09)*, Montreal, QC, Canada, 2009, pp. 452–461.

Y. Hu, Y. Koren, và C. Volinsky, “Collaborative Filtering for Implicit Feedback Datasets,” in *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, 2008, pp. 263–272. DOI: 10.1109/ICDM.2008.22

S. Rendle, W. Krichene, L. Zhang, và Y. Koren, “Revisiting the Performance of iALS on Item Recommendation Benchmarks,” in *Proceedings of the 16th ACM Conference on Recommender Systems (RecSys ’22)*, 2022. DOI: 10.1145/3523227.3548486

P. K. Atrey, M. A. Hossain, A. El Saddik, và M. S. Kankanhalli, “Multimodal Fusion for Multimedia Analysis: A Survey,” *Multimedia Systems*, vol. 16, no. 6, pp. 345–379, 2010.

K. Liu, Y. Li, N. Xu, và P. Natarajan, “Learn to Combine Modalities in Multimodal Deep Learning,” *arXiv preprint arXiv:1805.11730*, 2018.

S. Zhang, L. Yao, A. Sun, và Y. Tay, “Deep Learning Based Recommender System: A Survey and New Perspectives,” *ACM Computing Surveys*, vol. 52, no. 1, pp. 1–38, 2019. DOI: 10.1145/3285029

P. Li, S. A. Mohd Noah, và H. Mohd Sarim, “A Survey on Deep Neural Networks in Collaborative Filtering Recommendation Systems,” *arXiv preprint arXiv:2412.01378*, 2024.

G. Zhou và cộng sự, “Deep Interest Network for Click-Through Rate Prediction,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD ’18)*, 2018, pp. 1059–1068. DOI: 10.1145/3219819.3219823

M. Volkovs, G. Yu, và T. Poutanen, “DropoutNet: Addressing Cold Start in Recommender Systems,” in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 4957–4966.

G. Salton và C. Buckley, “Term-weighting Approaches in Automatic Text Retrieval,” *Information Processing and Management*, vol. 24, no. 5, pp. 513–523, 1988.

S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, và R. Harshman, “Indexing by Latent Semantic Analysis,” *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

B. Hidasi, A. Karatzoglou, L. Baltrunas, và D. Tikk, “Session-based Recommendations with Recurrent Neural Networks,” in *Proceedings of the 4th International Conference on Learning Representations (ICLR)*, 2016.

W.-C. Kang và J. McAuley, “Self-Attentive Sequential Recommendation,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2018, pp. 197–206. DOI: 10.1109/ICDM.2018.00035

F. Sun và cộng sự, “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer,” in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM ’19)*, 2019, pp. 1441–1450. DOI: 10.1145/3357384.3357895

X. Wang, X. He, M. Wang, F. Feng, và T.-S. Chua, “Neural Graph Collaborative Filtering,” in *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’19)*, 2019, pp. 165–174. DOI: 10.1145/3331184.3331267

X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, và M. Wang, “LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’20)*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063

D. Liang, R. G. Krishnan, M. D. Hoffman, và T. Jebara, “Variational Autoencoders for Collaborative Filtering,” in *Proceedings of the 2018 World Wide Web Conference (WWW ’18)*, 2018, pp. 689–698. DOI: 10.1145/3178876.3186150

J. Wu và cộng sự, “Self-supervised Graph Learning for Recommendation,” in *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’21)*, 2021, pp. 726–735. DOI: 10.1145/3404835.3462862

S. Rajput và cộng sự, “Recommender Systems with Generative Retrieval,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.

L. Wu và cộng sự, “A Survey on Large Language Models for Recommendation,” *World Wide Web*, vol. 27, no. 60, 2024. DOI: 10.1007/s11280-024-01291-2

T.-R. Wei và Y. Fang, “Diffusion Models in Recommendation Systems: A Survey,” *arXiv preprint arXiv:2501.10548*, 2025.

P. Covington, J. Adams, và E. Sargin, “Deep Neural Networks for YouTube Recommendations,” in *Proceedings of the 10th ACM Conference on Recommender Systems (RecSys ’16)*, 2016, pp. 191–198. DOI: 10.1145/2959100.2959190

W. Krichene và S. Rendle, “On Sampled Metrics for Item Recommendation,” in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD ’20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

S. Vargas và P. Castells, “Rank and Relevance in Novelty and Diversity Metrics for Recommender Systems,” in *Proceedings of the 5th ACM Conference on Recommender Systems (RecSys ’11)*, 2011, pp. 109–116. DOI: 10.1145/2043932.2043955

Z. Meng, R. McCreadie, C. Macdonald, và I. Ounis, “Exploring Data Splitting Strategies for the Evaluation of Recommendation Models,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys ’20)*, 2020. DOI: 10.1145/3383313.3418479

P. Cremonesi, Y. Koren, và R. Turrin, “Performance of Recommender Algorithms on Top-N Recommendation Tasks,” in *Proceedings of the 4th ACM Conference on Recommender Systems (RecSys)*, 2010, pp. 39–46. DOI: 10.1145/1864708.1864721