TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



LÊ MINH LÝ - 52300220
SỬ THỊ YẾN LINH - 52300218

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

DỰ ÁN CÔNG NGHỆ THÔNG TIN

MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG DỮ LIỆU

Giảng viên hướng dẫn
TS. HỒ THỊ LINH

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Hồ Thị Linh – người Cô đã luôn tận tình hướng dẫn, dành nhiều tâm huyết và đồng hành cùng chúng em trong suốt quá trình thực hiện dự án này. Những lời khuyên định hướng quý báu, sự chỉ dẫn ân cần và nguồn động viên to lớn của Cô chính là điểm tựa vững chắc giúp chúng em vượt qua những khó khăn để hoàn thành đề tài một cách tốt nhất.

Chúng em cũng xin gửi lời tri ân sâu sắc đến Ban giám hiệu cùng toàn thể quý Thầy Cô trường Đại học Tôn Đức Thắng, đặc biệt là các Thầy Cô thuộc Khoa Công nghệ Thông tin, những người đã truyền dạy cho chúng em nền tảng kiến thức chuyên môn vững chắc và rèn luyện kỹ năng thực tiễn trong suốt những năm học tập dưới mái trường.

Dù đã dành nhiều tâm huyết và nỗ lực hoàn thiện dự án một cách chỉn chu nhất, song do giới hạn về kiến thức và kinh nghiệm thực tiễn, báo cáo chắc chắn không tránh khỏi những thiếu sót ngoài ý muốn. Chúng em rất mong nhận được sự cảm thông cùng những ý kiến đóng góp, chỉ bảo quý báu từ quý Thầy Cô trong Hội đồng chấm dự án để đề tài được hoàn thiện hơn.

Chúng em xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp cao quý của mình!

Chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Chúng tôi xin cam đoan báo cáo dự án này là công trình nghiên cứu độc lập của chúng tôi dưới sự hướng dẫn khoa học trực tiếp của TS. Hồ Thị Linh. Mọi số liệu, quá trình phân tích và kết quả thực nghiệm trình bày trong báo cáo là hoàn toàn trung thực, khách quan và chưa từng được công bố dưới bất kỳ hình thức nào trước đây.

Các nguồn tài liệu tham khảo, số liệu trích dẫn phục vụ cho dự án đều có nguồn gốc rõ ràng, có độ tin cậy cao và được chú thích đầy đủ trong danh mục tài liệu tham khảo.

Chúng tôi xin hoàn toàn chịu trách nhiệm trước Nhà trường và pháp luật về tính chân thực, bản quyền cũng như các vi phạm quyền sở hữu trí tuệ liên quan đến nội dung báo cáo dự án này.

TP. Hồ Chí Minh, ngày …… tháng …… năm 2026

Tác giả	**Tác giả**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*
Lê Minh Lý	**Sử Thị Yến Linh**

PHẦN XÁC NHẬN VÀ ĐÁNH GIÁ CỦA GIẢNG VIÊN

Phần xác nhận của GV hướng dẫn

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

Phần đánh giá của GV chấm bài

Tp. Hồ Chí Minh, ngày ……tháng ……năm ……
(Ký và ghi họ tên)

XÂY DỰNG MÔ HÌNH KHUYẾN NGHỊ LAI KẾT HỢP NHÂN TỬ HOÁ MA TRẬN VÀ MẠNG LƯỚI THẦN KINH SÂU

TÓM TẮT

Nhân tử hóa ma trận dự đoán mức độ quan tâm của khách hàng với sản phẩm bằng tích vô hướng của hai vector ẩn học từ mã khách hàng và mã sản phẩm. Trên dữ liệu thời trang rất thưa và biến động theo mùa, cả dạng kết hợp tuyến tính lẫn việc chỉ dùng mã định danh đều hạn chế chất lượng gợi ý. Đề tài đề xuất NeuMF-F, một mô hình lai giữ cấu trúc hai nhánh của Neural Matrix Factorization (NeuMF), gồm nhánh nhân tử hóa ma trận tổng quát (GMF) và nhánh mạng nơ-ron nhiều tầng (MLP), đồng thời biểu diễn mỗi khách hàng và sản phẩm bằng vector nhúng mã định danh kết hợp với đặc trưng sản phẩm, khách hàng, doanh số và thời gian.

Mô hình được đánh giá trên bộ dữ liệu giao dịch thời trang H&M theo một quy trình hạn chế thiên lệch. Dữ liệu được chia theo thời gian, đặc trưng chỉ dùng thông tin trước thời điểm dự đoán, cấu hình được chọn trên một mẫu khách hàng riêng, và kết luận được rút ra một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước, có kiểm định thống kê. Các mô hình đối chứng được tinh chỉnh với cùng ngân sách và chia thành ba nhóm: mô hình đơn lẻ, học máy truyền thống và mô hình chuyên biệt cho gợi ý.

Kết quả cho thấy NeuMF-F tốt hơn có ý nghĩa thống kê so với NeuMF chỉ dùng mã định danh, nhánh MLP-F và các mô hình đối chứng trong họ so sánh, nhưng không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng và với mô hình hợp nhất muộn LateFusion-F. Như vậy, phần cải thiện chủ yếu đến từ việc bổ sung đặc trưng, trong đó đặc trưng thời gian đóng góp nhiều nhất, chứ không đến từ cách hợp nhất hai nhánh. Kiểm chứng trên bộ dữ liệu Amazon Beauty xác nhận lợi ích của đặc trưng, nhưng trên bộ này LateFusion-F tốt hơn NeuMF-F có ý nghĩa. Phân tích bổ sung cho thấy NeuMF-F cũng tốt hơn có ý nghĩa một mô hình lai truyền thống kết hợp lọc nội dung và lọc cộng tác. Đề tài xây dựng thêm một hệ thống demo minh họa gợi ý cho từng khách hàng.

BUILDING A HYBRID RECOMMENDATION MODEL COMBINING MATRIX FACTORIZATION AND DEEP NEURAL NETWORKS

ABSTRACT

Matrix factorization predicts a customer's interest in an item with the inner product of two latent vectors learned from customer and item identifiers. On fashion data, which are extremely sparse and seasonal, both this linear form and the reliance on identifiers limit recommendation quality. This project proposes NeuMF-F, a hybrid model that keeps the two-branch structure of Neural Matrix Factorization (NeuMF), with a generalized matrix factorization (GMF) branch and a multi-layer perceptron (MLP) branch, and represents every customer and item by an identifier embedding combined with item, customer, sales and time features.

The model is evaluated on the H&M fashion transaction dataset under a protocol designed to limit bias. Data are split by time, features use only information available before the prediction time, configurations are selected on a separate customer sample, and conclusions are drawn once on an independent customer sample under a pre-registered plan with statistical testing. The baselines are tuned with the same budget and grouped into single models, traditional machine learning and recommendation-specific models.

NeuMF-F is significantly better than identifier-only NeuMF, its MLP-F branch and the baselines of the comparison family, but it is not significantly different from its GMF-F branch alone or from the late-fusion model LateFusion-F. The improvement therefore comes mainly from the features, with time features contributing most, rather than from how the two branches are fused. A validation on the Amazon Beauty dataset confirms the benefit of the features, but on that dataset LateFusion-F significantly outperforms NeuMF-F. A supplementary analysis shows that NeuMF-F also significantly outperforms a traditional hybrid of content-based and collaborative filtering. The project also builds a demo system that illustrates the recommendations for each customer.

MỤC LỤC

DANH MỤC HÌNH VẼ ..... **x**

DANH MỤC BẢNG BIỂU ..... **xi**

DANH MỤC THUẬT TOÁN ..... **xiii**

DANH MỤC CÁC CHỮ VIẾT TẮT ..... **xiv**

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI **1**

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài 1

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài *1*

1.1.2 Giới hạn của nhân tử hóa ma trận trên dữ liệu này *1*

1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F) *2*

1.2 Mục tiêu và phạm vi nghiên cứu 3

1.2.1 Mục tiêu nghiên cứu *3*

1.2.2 Phạm vi nghiên cứu *3*

1.3 Phương pháp nghiên cứu 4

1.4 Ý nghĩa khoa học và thực tiễn của đề tài 4

1.4.1 Ý nghĩa khoa học *4*

1.4.2 Ý nghĩa thực tiễn *5*

1.5 Bố cục của báo cáo 5

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN **6**

2.1 Tổng quan về hệ gợi ý 6

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai *6*

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình *7*

2.1.3 Phản hồi ẩn *8*

2.1.4 Độ thưa dữ liệu và khởi đầu lạnh *9*

2.2 Lọc cộng tác và nhân tử hóa ma trận 9

2.2.1 Mô hình nhân tử hóa ma trận *9*

2.2.2 Hạn chế của tích vô hướng *10*

2.2.3 Tối ưu thứ hạng theo cặp: BPR *10*
2.3 Kiến trúc lọc cộng tác bằng mạng nơ-ron (NCF) 10
2.3.1 Generalized Matrix Factorization (GMF) *10*
2.3.2 Multi-Layer Perceptron (MLP) *11*
2.3.3 Mô hình lai NeuMF *11*
2.3.4 Hợp nhất sớm và hợp nhất muộn *11*
2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân *14*
2.4 Các hướng nghiên cứu gần đây 14
2.4.1 Mô hình lai dựa trên đặc trưng *14*
2.4.2 Gợi ý theo chuỗi hành vi *15*
2.4.3 Học biểu diễn trên đồ thị *15*
2.4.4 Mô hình tự mã hóa biến phân *16*
2.4.5 Lý do chọn kiến trúc hai nhánh *16*
2.5 Các độ đo đánh giá Top-K 16
2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu *17*
2.5.2 Độ đo ngoài độ chính xác *17*
2.6 Các công trình liên quan 18
2.6.1 Ba nghiên cứu nền tảng và đối chiếu thiết lập thực nghiệm *20*
2.7 Khoảng trống nghiên cứu 23
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F 24
3.1 Quy trình tổng thể của hệ thống 24
3.2 Dữ liệu và tiền xử lý 24
3.2.1 Đặc tả bộ dữ liệu H&M *24*
3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định *26*
3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử *27*
3.2.4 Giai đoạn đánh giá và tập ứng viên *29*
3.2.5 Xây dựng đặc trưng theo thời điểm *30*

3.2.6 Dữ liệu kiểm chứng Amazon Beauty *32*
3.3 Thiết kế mô hình lai NeuMF-F 33
3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng *34*
3.3.2 Nhánh GMF-F *36*
3.3.3 Nhánh MLP-F *36*
3.3.4 Tầng hợp nhất và lớp dự đoán *37*
3.3.5 Các mô hình đối chiếu trên cùng khung *37*
3.4 Lấy mẫu âm theo thời điểm và hàm mục tiêu 38
3.4.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm *38*
3.4.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn *38*
3.5 Quy trình huấn luyện và tinh chỉnh 39
3.5.1 Không gian tinh chỉnh và dừng sớm *39*
3.6 Quy trình đánh giá không thiên lệch 39
3.7 Suy diễn Top-K và xử lý khách hàng mới 46
3.8 Thiết kế hệ thống demo 47
3.8.1 Kiến trúc ba tầng *47*
3.8.2 Thiết kế API suy diễn *48*
3.8.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng *48*
3.8.4 Minh họa hệ thống demo *49*
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ 53
4.1 Cấu hình thực nghiệm 53
4.2 Mô hình đối chứng 53
4.3 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển 55
4.4 Kết quả đánh giá cuối trên mẫu kiểm định 57
4.4.1 So sánh các độ đo xếp hạng *57*
4.4.2 Kết quả theo $K = 5, 10, 15, 20$ *58*
4.4.3 Kiểm định ý nghĩa thống kê *58*
4.4.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống *60*

4.4.5 Phân tích bóc tách thành phần 61
4.4.6 Độ phủ và chi phí huấn luyện 63
4.4.7 Hội tụ và độ ổn định giữa hai mẫu 63
4.5 Kiểm chứng trên dữ liệu Amazon Beauty 65
4.5.1 Kết quả trên tập kiểm thử Amazon Beauty 65
4.5.2 Đối chiếu kết luận giữa H&M và Amazon Beauty 66
4.5.3 Phân tích bóc tách và độ phủ trên Amazon Beauty 70
4.6 Lịch sử phát triển: giai đoạn chỉ dùng mã ID và bản đầu của kế hoạch đánh giá 70
4.7 Phạm vi của kết luận 72
4.8 Thảo luận 72
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 74
5.1 Kết luận 74
5.2 Hạn chế của đề tài 74
5.3 Hướng phát triển 75
PHỤ LỤC A. NGUỒN TRÍCH DẪN VÀ VỊ TRÍ SỬ DỤNG 77
TÀI LIỆU THAM KHẢO 79

DANH MỤC HÌNH VẼ

Hình 2.1: Kiến trúc NeuMF 12
Hình 2.2: Hợp nhất sớm ở mức biểu diễn (NeuMF, NeuMF-F) và hợp nhất muộn ở mức điểm dự đoán (LateFusion-F)..... 13

Hình 3.1: Đường ống của hệ thống từ dữ liệu đến danh sách gợi ý Top-K 25
Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F..... 35
Hình 3.3: Quy trình tinh chỉnh và đánh giá cuối..... 42
Hình 3.4: Kiến trúc ba tầng của hệ thống demo..... 47
Hình 3.5: Giao diện demo: màn hình kiểm thử mô hình..... 50
Hình 3.6: Giao diện demo: 10 khách hàng tương đồng nhất theo UserKNN..... 51
Hình 3.7: Giao diện demo: gợi ý cho khách hàng mới 52

Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử của mẫu kiểm định H&M..... 58
Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh đã đăng ký trên H&M, kèm khoảng tin cậy 95% 60
Hình 4.3: Phân tích bóc tách NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M..... 62
Hình 4.4: Đường hội tụ của các mạng nơ-ron khi chọn số epoch 64
Hình 4.5: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối 64
Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty 66

DANH MỤC BẢNG BIỂU

Bảng 2.1: Các công trình nghiên cứu liên quan 18
Bảng 2.2: Thiết lập thực nghiệm và kết quả công bố của ba nghiên cứu nền tảng, đặt cạnh thiết lập của đề tài 21

Bảng 3.1: Độ nhạy của lọc k-core trên toàn bộ dữ liệu H&M (31.788.324 dòng) 26
Bảng 3.2: Độ nhạy của mẫu phát triển theo ngưỡng lọc k-core 29
Bảng 3.3: Quy mô dữ liệu H&M của mẫu phát triển và mẫu kiểm định..... 30
Bảng 3.4: Đặc trưng của các mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F) 31
Bảng 3.5: Đặc trưng của các mô hình có đặc trưng trên H&M và trên Amazon Beauty 33
Bảng 3.6: Quy mô dữ liệu Amazon Beauty 34
Bảng 3.7: Không gian tinh chỉnh của các mô hình 40
Bảng 3.8: Các điểm cuối chính của API suy diễn..... 48

Bảng 4.1: Ba nhóm mô hình đối chứng của mô hình đề xuất NeuMF-F..... 54
Bảng 4.2: Cấu hình tốt nhất của từng mô hình trên tập xác thực của mẫu phát triển..... 55
Bảng 4.3: Các cách kết hợp của Hybrid-CBCF trên tập xác thực của mẫu phát triển..... 56
Bảng 4.4: Kết quả trên tập kiểm thử của mẫu kiểm định H&M theo ba nhóm mô hình đối chứng 57
Bảng 4.5: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định H&M..... 59
Bảng 4.6: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định H&M..... 59
Bảng 4.7: Kiểm định họ 10 so sánh đã đăng ký trước trên mẫu kiểm định H&M (NDCG@10)..... 60
Bảng 4.8: Kiểm định các so sánh bổ sung với Hybrid-CBCF trên mẫu kiểm định H&M (NDCG@10) 61
Bảng 4.9: Phân tích bóc tách NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M..... 62
Bảng 4.10: Độ phủ danh sách top-10 và chi phí huấn luyện trên mẫu kiểm định H&M..... 63

Bảng 4.11: Kết quả trên tập kiểm thử Amazon Beauty theo ba nhóm mô hình đối chứng 65
Bảng 4.12: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty 67
Bảng 4.13: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty 67
Bảng 4.14: Kiểm định các so sánh bổ sung với Hybrid-CBCF trên Amazon Beauty (NDCG@10) 68
Bảng 4.15: Kiểm định họ 10 so sánh đã đăng ký trước trên Amazon Beauty (NDCG@10)..... 68
Bảng 4.16: Kết luận của họ 10 so sánh đã đăng ký trên H&M (mẫu kiểm định) và trên Amazon Beauty (NDCG@10; chênh lệch $= (A - B)/B$).. 69
Bảng 4.17: Phân tích bóc tách NeuMF-F trên tập kiểm thử Amazon Beauty 70

DANH MỤC THUẬT TOÁN

Thuật toán 3.1: Chuẩn bị dữ liệu: gộp theo mẫu thiết kế và lọc k-core lặp . . 28
Thuật toán 3.2: Lấy mẫu âm theo thời điểm cho mô hình có đặc trưng (thực hiện lại ở đầu mỗi epoch) 39
Thuật toán 3.3: Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch . . 41
Thuật toán 3.4: Đánh giá một mô hình trên một giai đoạn bằng cách xếp hạng toàn bộ tập ứng viên 44
Thuật toán 3.5: Chọn trọng số w của LateFusion-F trên tập xác thực của mẫu phát triển 45
Thuật toán 3.6: Chọn cách kết hợp và học trọng số của mô hình lai truyền thống Hybrid-CBCF trên tập xác thực của mẫu phát triển . . 45
Thuật toán 3.7: Suy diễn Top-K cho một khách hàng, có xử lý khách hàng mới 46

DANH MỤC CÁC CHỮ VIẾT TẮT

API	Application Programming Interface (Giao diện lập trình ứng dụng)
BCE	Binary Cross-Entropy (Entropy chéo nhị phân)
BPR	Bayesian Personalized Ranking (Xếp hạng cá nhân hóa Bayes)
CF	Collaborative Filtering (Lọc cộng tác)
CI	Confidence Interval (Khoảng tin cậy)
CPU	Central Processing Unit (Bộ xử lý trung tâm)
DCG	Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu)
DNN	Deep Neural Network (Mạng nơ-ron sâu)
FM	Factorization Machines (Máy nhân tử hóa)
GMF	Generalized Matrix Factorization (Nhân tử hóa ma trận tổng quát)
GPU	Graphics Processing Unit (Bộ xử lý đồ họa)
HR	Hit Ratio (Tỷ lệ đánh trúng)
IDCG	Ideal Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu lý tưởng)
ItemKNN	Item-based k-Nearest Neighbors (Lọc cộng tác theo k sản phẩm láng giềng gần nhất)
MD5	Message-Digest Algorithm 5 (Hàm băm MD5)
MF	Matrix Factorization (Nhân tử hóa ma trận)
MLP	Multi-Layer Perceptron (Mạng nơ-ron truyền thẳng đa tầng)
NCF	Neural Collaborative Filtering (Lọc cộng tác dựa trên nơ-ron)
NDCG	Normalized Discounted Cumulative Gain (Mức tăng tích lũy chiết khấu chuẩn hóa)

NeuMF	Neural Matrix Factorization (Nhân tử hóa ma trận thần kinh)
NeuMF-F	NeuMF bổ sung đặc trưng (mô hình đề xuất; GMF-F, MLP-F: hai nhánh có đặc trưng)
RAM	Random Access Memory (Bộ nhớ truy cập ngẫu nhiên)
ReLU	Rectified Linear Unit (Đơn vị chỉnh lưu tuyến tính)
SVD	Singular Value Decomposition (Phân rã giá trị kỳ dị)
TF-IDF	Term Frequency–Inverse Document Frequency (Tần suất từ nhân nghịch đảo tần suất văn bản)
UserKNN	User-based k-Nearest Neighbors (Lọc cộng tác theo k người dùng láng giềng gần nhất)
VAE	Variational Autoencoder (Bộ tự mã hóa biến phân)

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI

1.1 Bối cảnh nghiên cứu và tính cấp thiết của đề tài

1.1.1 Quan sát ban đầu từ dữ liệu và động lực chọn đề tài

Đề tài xuất phát từ việc khảo sát bộ dữ liệu H&M Personalized Fashion Recommendations [1]. Tệp giao dịch gốc gồm 31.788.324 lượt mua của 1.362.281 khách hàng trên 104.547 sản phẩm thời trang trong hai năm (mục 3.2.1). Dữ liệu này có hai đặc điểm đặt ra yêu cầu cho mô hình gợi ý.

Thứ nhất, ma trận tương tác rất thưa. Mỗi khách chỉ mua một phần rất nhỏ của danh mục, và lượt mua tập trung vào một nhóm nhỏ sản phẩm phổ biến. Ngay cả sau khi lọc k-core, mật độ của toàn bộ dữ liệu chỉ khoảng 0,03% (Bảng 3.1).

Thứ hai, nhu cầu thời trang thay đổi theo mùa và theo xu hướng. Sản phẩm bán chạy trong vài tuần gần đây chưa chắc là sản phẩm bán nhiều nhất trong hai năm.

Một mô hình chỉ học từ mã khách hàng và mã sản phẩm không khai thác được những thông tin như xu hướng bán gần đây, loại sản phẩm hay nhóm khách hàng. Trong khi đó, bộ dữ liệu có sẵn thuộc tính và mô tả văn bản của sản phẩm, thông tin khách hàng và doanh số theo ngày.

Từ đó, đề tài đặt hai câu hỏi nghiên cứu cho mô hình lai giữa nhân tử hóa ma trận và mạng nơ-ron sâu, có bổ sung đặc trưng sản phẩm, khách hàng và thời gian. Trên dữ liệu giao dịch thời trang thực tế, mô hình này có gợi ý tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ không? Nó có tốt hơn chính các thành phần của nó không? Đề tài xây dựng và đánh giá mô hình trực tiếp trên dữ liệu H&M, với cách chia dữ liệu và quy trình đánh giá riêng. Về ứng dụng, gợi ý cá nhân hóa giúp khách hàng tìm sản phẩm nhanh hơn và giúp doanh nghiệp đưa đúng sản phẩm tới đúng khách. Với ngành thời trang, gợi ý còn cần phản ánh xu hướng theo thời gian, không chỉ sở thích lâu dài của khách.

1.1.2 Giới hạn của nhân tử hóa ma trận trên dữ liệu này

Cách tiếp cận cơ bản cho bài toán trên là nhân tử hóa ma trận (*matrix factorization*, MF) [2]. Mỗi người dùng u và sản phẩm i được gán một vector ẩn $p_u, q_i \in \mathbb{R}^d$,

và mức độ tương tác được dự đoán bằng tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{1.1}$$

Công thức này có hai giới hạn trên dữ liệu H&M.

Giới hạn thứ nhất là về biểu diễn. Tích vô hướng cộng các chiều ẩn với trọng số như nhau và chỉ mô hình hóa được tương tác tuyến tính. He và cộng sự [3] lấy đây làm động cơ để bổ sung một thành phần phi tuyến.

Giới hạn thứ hai là về thông tin. Vector q_i chỉ học được từ các lần sản phẩm i được mua, nên sản phẩm ít người mua có biểu diễn kém tin cậy, còn sản phẩm chưa ai mua thì không có biểu diễn. Những gì đã biết về chính sản phẩm và về khách hàng không được dùng. Giới hạn này không khắc phục được bằng cách làm mô hình phức tạp hơn mà cần bổ sung thông tin.

1.1.3 Lựa chọn mô hình: NeuMF bổ sung đặc trưng (NeuMF-F)

NeuMF khắc phục giới hạn thứ nhất bằng cách kết hợp chứ không thay thế MF. Nhánh GMF (*generalized matrix factorization*) giữ khả năng học tương tác tuyến tính. Nhánh MLP (*multi-layer perceptron*) chạy song song để học tương tác phi tuyến. Hai nhánh được hợp nhất ở lớp dự đoán. Tuy nhiên, ở giai đoạn phát triển của đề tài, NeuMF chỉ dùng mã ID không vượt được MF đã tinh chỉnh trên dữ liệu H&M (mục 4.6).

Đề tài vì vậy xây dựng mô hình đề xuất NeuMF-F. Mô hình giữ nguyên hai nhánh GMF và MLP của NeuMF, nhưng biểu diễn mỗi khách hàng và sản phẩm bằng tổng của vector nhúng mã ID và một phép chiếu của đặc trưng. Đặc trưng gồm thuộc tính và mô tả sản phẩm, thông tin khách hàng, doanh số và thời gian. Chúng cho mô hình biết điều mà mã ID không mang: sản phẩm thuộc loại gì, có đang bán chạy không, khách thuộc nhóm nào và mua gần đây hay không.

Cấu trúc hai nhánh tường minh cho phép tách riêng từng đóng góp bằng so sánh trực tiếp. So với NeuMF chỉ dùng ID, ta đo được đóng góp của đặc trưng. So với từng nhánh đứng riêng, ta đo được lợi ích của việc hợp nhất. So với hợp nhất muộn của cùng hai nhánh, ta so được hai cách hợp nhất.

1.2 Mục tiêu và phạm vi nghiên cứu

1.2.1 Mục tiêu nghiên cứu

- Hệ thống hóa cơ sở lý thuyết về lọc cộng tác, nhân tử hóa ma trận, mạng nơ-ron sâu, kiến trúc NeuMF, mô hình lai dựa trên đặc trưng và hai cách hợp nhất mô hình: hợp nhất sớm và hợp nhất muộn.
- Xây dựng quy trình xử lý dữ liệu H&M: lấy mẫu theo khách hàng, dựng ma trận tương tác từ phản hồi ẩn và chia dữ liệu theo thời gian. Đặc trưng được tính theo thời điểm, tức không dùng thông tin xảy ra sau thời điểm dự đoán.
- Cài đặt mô hình đề xuất NeuMF-F và các mô hình đối chứng, tinh chỉnh mọi mô hình với cùng ngân sách. Mô hình đối chứng được xếp thành ba nhóm: mô hình đơn lẻ, học máy truyền thống và chuyên biệt cho gợi ý. Nhóm học máy truyền thống gồm cả một mô hình lai truyền thống (Hybrid-CBCF).
- Đánh giá định lượng bằng cách xếp hạng toàn bộ tập ứng viên, với các độ đo NDCG@K, Recall@K, HR@K và Precision@K ở $K = 5, 10, 15, 20$. Kết luận được lấy trên một mẫu khách hàng độc lập, theo kế hoạch đăng ký trước, với 5 lần chạy và kiểm định thống kê, rồi được kiểm chứng lại trên bộ dữ liệu thứ hai (Amazon Beauty).
- Xây dựng hệ thống demo minh họa mô hình đã huấn luyện, luôn trả về gợi ý kể cả cho khách hàng mới.

1.2.2 Phạm vi nghiên cứu

Đối tượng nghiên cứu là kiến trúc NCF (GMF, MLP, NeuMF), mở rộng có đặc trưng của nó (NeuMF-F), hai cách hợp nhất nhân tử hóa ma trận với mạng nơ-ron sâu và các phương pháp đánh giá hệ gợi ý Top-K.

Dữ liệu chính là bộ H&M, gồm tệp giao dịch, tệp danh mục sản phẩm và tệp thông tin khách hàng. Khảo sát quy mô dùng toàn bộ 31,8 triệu giao dịch. Huấn luyện và đánh giá dùng hai mẫu, mỗi mẫu khoảng 500.000 giao dịch của khoảng 21.000 khách hàng chọn ngẫu nhiên theo hàm băm. Hai mẫu không có khách chung và giữ trọn lịch sử hai năm của mỗi khách (mục 3.2.2). Mỗi sản phẩm là một mẫu thiết kế (`product_code`), tức mọi màu của cùng một mẫu được gộp lại. Ảnh sản phẩm không được dùng làm đầu vào của mô hình. Để kiểm chứng, toàn bộ đánh giá cuối được chạy lại trên bộ Amazon Beauty [4] với cấu hình đã chọn trên H&M (mục 3.2.6).

Tín hiệu tương tác là phản hồi ẩn nhị phân từ lịch sử mua hàng (đã mua hoặc chưa mua), kèm ngày mua.

Khởi đầu lạnh nằm ngoài phạm vi đánh giá định lượng. Sản phẩm chưa có người mua trước thời điểm dự đoán và khách hàng chưa có lịch sử mua đều không được đánh giá (mục 3.2.4). Khi hệ thống được sử dụng, khách hàng mới nhận danh sách sản phẩm phổ biến, còn khách đã có lịch sử mua nhận gợi ý của mô hình đề xuất (mục 3.7).

1.3 Phương pháp nghiên cứu

Đề tài kết hợp bốn nhóm phương pháp, trình bày lần lượt trong các chương sau.

1. Nghiên cứu lý thuyết: phân tích và tổng hợp tài liệu về lọc cộng tác, nhân tử hóa ma trận, kiến trúc NeuMF và mô hình lai dựa trên đặc trưng. Các hướng nghiên cứu gần đây được khảo sát để xác định vị trí của đề tài (Chương 2).
2. Xử lý dữ liệu: xây dựng quy trình tiền xử lý tái lập được và kiểm chứng được ở từng bước. Quy trình gồm lấy mẫu theo khách hàng, gộp giao dịch, lọc k-core chỉ trên dữ liệu trước mốc kiểm thử, chia giai đoạn theo thời gian và tính đặc trưng theo thời điểm, bảo đảm không dùng thông tin tương lai (Chương 3).
3. Thực nghiệm: cài đặt các mô hình, huấn luyện bằng hàm mất mát entropy chéo nhị phân với lấy mẫu âm theo thời điểm, và tinh chỉnh mọi mô hình với cùng ngân sách, chỉ trên tập xác thực của mẫu phát triển.
4. Đánh giá và kiểm định: xếp hạng toàn bộ tập ứng viên, đăng ký trước kế hoạch đánh giá và khoá tập kiểm thử. Kết luận được lấy trên một mẫu khách hàng độc lập bằng kiểm định Wilcoxon theo người dùng, khoảng tin cậy bootstrap và hiệu chỉnh Holm, rồi được kiểm chứng trên bộ dữ liệu thứ hai (Chương 4).

1.4 Ý nghĩa khoa học và thực tiễn của đề tài

1.4.1 Ý nghĩa khoa học

– Trả lời bằng thực nghiệm có kiểm định thống kê câu hỏi: mô hình lai MF và DNN có đặc trưng có vượt các mô hình đối chứng, vượt NeuMF chỉ dùng ID và vượt từng nhánh của nó hay không. Câu trả lời dựa trên dữ liệu giao

dịch thời trang thực tế, lấy trên một mẫu khách hàng chưa từng dùng để ra quyết định, và được kiểm chứng lại trên bộ dữ liệu thứ hai.

- So sánh trực tiếp hợp nhất sớm và hợp nhất muộn trên cùng hai thành phần MF và DNN, và so sánh mô hình lai học sâu với một mô hình lai truyền thống.
- Xây dựng một quy trình đánh giá hạn chế thiên lệch, dùng lại được cho các nghiên cứu hệ gợi ý khác: đặc trưng được tính theo thời điểm, mọi mô hình được tinh chỉnh với cùng ngân sách, và kết luận lấy trên mẫu kiểm định độc lập theo kế hoạch đăng ký trước, với kiểm định có hiệu chỉnh đa so sánh.

1.4.2 Ý nghĩa thực tiễn

- Mô hình chỉ dùng dữ liệu mà doanh nghiệp bán lẻ sẵn có: lịch sử giao dịch, danh mục sản phẩm, thông tin hội viên và doanh số theo ngày. Mọi đặc trưng được tính theo thời điểm, nên cách huấn luyện và chấm điểm dùng được nguyên khi triển khai.
- Quy trình xử lý dữ liệu chạy được trên máy tính cá nhân và áp dụng được cho bộ dữ liệu thương mại điện tử khác, như đã làm với Amazon Beauty.
- Hệ thống demo cho phép so sánh trực quan các mô hình trên từng khách hàng và luôn có gợi ý: khách hàng mới nhận danh sách sản phẩm phổ biến.

1.5 Bố cục của báo cáo

Báo cáo gồm năm chương.

- Chương 1 trình bày bối cảnh, mục tiêu, phạm vi, phương pháp nghiên cứu và ý nghĩa của đề tài.
- Chương 2 trình bày cơ sở lý thuyết về hệ gợi ý, nhân tử hóa ma trận, kiến trúc NCF và NeuMF, các cách hợp nhất mô hình, mô hình lai, các độ đo đánh giá và các công trình liên quan.
- Chương 3 trình bày dữ liệu, cách chia giai đoạn, đặc trưng theo thời điểm, kiến trúc NeuMF-F, cách huấn luyện, quy trình đánh giá, cách suy diễn và hệ thống demo.
- Chương 4 trình bày kết quả tinh chỉnh, kết quả đánh giá cuối, kiểm định thống kê, phân tích bóc tách, kiểm chứng trên Amazon Beauty và thảo luận.
- Chương 5 tổng kết kết quả, hạn chế và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC CÔNG TRÌNH LIÊN QUAN

Chương này trình bày cơ sở lý thuyết về hệ gợi ý, các mô hình được dùng trong đề tài và các công trình liên quan. Các công trình được dẫn là cơ sở về phương pháp, tức định nghĩa mô hình, cách huấn luyện và cách đánh giá. Thực nghiệm trong các công trình đó dùng dữ liệu và giao thức khác, nên số liệu của chúng không được dùng làm chuẩn so sánh với kết quả của đề tài.

2.1 Tổng quan về hệ gợi ý

2.1.1 Lọc nội dung, lọc cộng tác và lọc lai

Hệ gợi ý có ba hướng tiếp cận chính. Lọc dựa trên nội dung (*content-based filtering*) gợi ý những sản phẩm có đặc tính giống các sản phẩm người dùng đã thích, dựa trên mô tả sản phẩm và hồ sơ sở thích của người dùng [5]. Lọc cộng tác (*collaborative filtering*, CF) khai thác lịch sử tương tác của nhiều người dùng: những người từng mua giống nhau có khả năng sẽ mua giống nhau. Lọc cộng tác chỉ cần ma trận tương tác giữa người dùng và sản phẩm, không cần đặc trưng mô tả [6]. Lọc lai (*hybrid filtering*) kết hợp nhiều kỹ thuật, thường gặp nhất là kết hợp nội dung với cộng tác, để bù hạn chế của từng kỹ thuật.

Trước khi có học sâu, hệ gợi ý lai được ghép từ các kỹ thuật truyền thống. Burke [7] phân loại bảy cách lai:

- lai có trọng số (*weighted*): cộng có trọng số điểm của nhiều kỹ thuật;
- lai chuyển đổi (*switching*): chọn một kỹ thuật tùy tình huống;
- lai hỗn hợp (*mixed*): trình bày đồng thời gợi ý của nhiều kỹ thuật;
- kết hợp đặc trưng (*feature combination*): dùng dữ liệu của kỹ thuật này làm đặc trưng cho kỹ thuật kia;
- lai phân tầng (*cascade*): kỹ thuật sau tinh chỉnh kết quả của kỹ thuật trước;
- tăng cường đặc trưng (*feature augmentation*): đầu ra của kỹ thuật này làm đầu vào cho kỹ thuật kia;
- lai mức mô hình (*meta-level*): mô hình học được của kỹ thuật này làm đầu vào cho kỹ thuật kia.

Chương 3 luận án của Hồ Thị Linh [8] đề xuất một mô hình lai thuộc loại này. Ba mô hình đơn lẻ là lọc nội dung, lọc cộng tác theo người dùng và lọc cộng tác theo sản phẩm, mỗi mô hình dự đoán độc lập. Điểm của chúng sau đó được kết hợp bằng bỏ phiếu (lấy giá trị lớn nhất, nhỏ nhất hoặc trung bình) hoặc bằng tổng có trọng số, với trọng số học bởi một mạng truyền thẳng. Đề tài dùng đúng cấu trúc này, điều chỉnh cho phản hồi ẩn và xếp hạng Top-K, làm mô hình lai truyền thống trong nhóm đối chứng học máy truyền thống (Hybrid-CBCF, mục 4.2). Mô hình đề xuất là một mô hình lai học sâu, nên so sánh hai mô hình này cho biết lợi ích của việc dùng mạng nơ-ron để hợp nhất các nguồn thông tin.

Đề tài chọn hướng lai vì đặc điểm của dữ liệu. Bộ dữ liệu H&M (mục 3.2.1) có lịch sử giao dịch đủ dài để lọc cộng tác học được sở thích của khách mua thường xuyên. Tuy nhiên, nhiều sản phẩm chỉ có ít lượt mua, và danh mục thời trang thay đổi nhanh. Lọc cộng tác chỉ dựa trên mã ID có rất ít thông tin về những sản phẩm này, trong khi bộ dữ liệu có sẵn thuộc tính, mô tả văn bản của sản phẩm, thông tin khách hàng và doanh số theo thời gian. Vì vậy lõi của mô hình là lọc cộng tác dựa trên mô hình, kết hợp nhân tử hóa ma trận với mạng nơ-ron sâu (mục 2.2, 2.3), được bổ sung đặc trưng nội dung và ngữ cảnh (mục 2.4.1). Các mô hình chỉ dùng mã ID và mô hình gợi ý theo nội dung thuần được giữ làm đối chứng để đo riêng đóng góp của từng nguồn thông tin.

2.1.2 Lọc cộng tác dựa trên bộ nhớ và dựa trên mô hình

Theo cách khai thác dữ liệu tương tác, lọc cộng tác chia thành hai nhánh.

Lọc cộng tác dựa trên bộ nhớ (*memory-based*) tính trực tiếp độ tương đồng giữa người dùng hoặc giữa sản phẩm từ ma trận tương tác, không qua bước học tham số. Nguyên lý này có từ hệ thống GroupLens [9]. Với lọc cộng tác theo sản phẩm (ItemKNN) [10], độ tương đồng cosine giữa hai sản phẩm i và j được tính trên vector cột tương tác của chúng:

$$\text{sim}(i, j) = \cos(\vec{i}, \vec{j}) = \frac{\vec{i} \cdot \vec{j}}{\|\vec{i}\| \, \|\vec{j}\|} \tag{2.1}$$

Với phản hồi ẩn nhị phân, điểm của sản phẩm i đối với người dùng u là tổng độ tương đồng giữa i và các sản phẩm u đã mua, chỉ xét k láng giềng gần nhất $\mathcal{N}_k(i)$ của i:

$$\hat{y}_{ui} = \sum_{j \in \mathcal{N}_k(i) \cap \mathcal{I}_u} \text{sim}(i, j) \tag{2.2}$$

Lọc cộng tác theo người dùng (UserKNN) làm đối xứng. Mô hình tìm k người dùng

có lịch sử mua giống u nhất, ký hiệu $\mathcal{N}_k(u)$, rồi tính điểm mỗi sản phẩm bằng tổng độ tương đồng của các láng giềng đã mua sản phẩm đó:

$$\hat{y}_{ui} = \sum_{v \in \mathcal{N}_k(u)} \text{sim}(u, v)\, y_{vi} \tag{2.3}$$

Trong cài đặt của đề tài, độ tương đồng cosine được tính trên vector mua nhị phân. Mẫu số có thêm hệ số co λ để giảm trọng số của các cặp có quá ít tương tác chung: $\text{sim}(a, b) = |\mathcal{I}_a \cap \mathcal{I}_b| / (\sqrt{|\mathcal{I}_a|\,|\mathcal{I}_b|} + \lambda)$, với $\mathcal{I}_a$ là tập sản phẩm a đã mua (hoặc tập người dùng đã mua sản phẩm a). Mỗi hàng của ma trận tương đồng chỉ giữ k láng giềng và được lưu dạng ma trận thưa. Số láng giềng k và hệ số co λ được chọn trên tập xác thực. Ưu điểm của nhánh này là đơn giản, không cần huấn luyện và dễ giải thích, vì chỉ ra được những người dùng hay sản phẩm nào dẫn tới một gợi ý. Nhược điểm là ma trận tương đồng đầy đủ tăng theo bình phương số đối tượng, và chất lượng giảm khi dữ liệu quá thưa.

Lọc cộng tác dựa trên mô hình (*model-based*) không tính tương đồng trực tiếp mà học một hàm có tham số, như nhân tử hóa ma trận hay mạng nơ-ron. Hàm này nén thông tin tương tác thành các vector ẩn có số chiều thấp, nên tổng quát hóa tốt hơn trên dữ liệu thưa và có chi phí tăng tuyến tính theo số tương tác. Các mô hình MF, GMF, MLP và NeuMF trình bày từ mục 2.2 thuộc nhánh này.

2.1.3 Phản hồi ẩn

Phản hồi của người dùng có hai dạng. Phản hồi hiện (*explicit feedback*) là điểm đánh giá trực tiếp, ví dụ từ 1 đến 5 sao. Phản hồi ẩn (*implicit feedback*) được suy ra từ hành vi, như lịch sử mua hay lượt nhấp. Tệp giao dịch H&M không có cột điểm đánh giá nào, chỉ có các giao dịch đã xảy ra. Vì vậy đề tài dùng phản hồi ẩn dạng nhị phân, lấy từ sự kiện mua hàng:

$$y_{ui} = \begin{cases} 1, & \text{nếu người dùng } u \text{ đã mua sản phẩm } i \\ 0, & \text{ngược lại} \end{cases} \tag{2.4}$$

Nhãn $y_{ui} = 1$ chỉ xác nhận khách đã mua, không xác nhận khách hài lòng. Nhãn $y_{ui} = 0$ có thể nghĩa là khách chưa biết đến sản phẩm, không nhất thiết là không thích. Do đó các cặp chưa tương tác không thể coi là nhãn âm chắc chắn, và kỹ thuật lấy mẫu âm (mục 3.4.1) phải được thiết kế cẩn thận.

2.1.4 Độ thưa dữ liệu và khởi đầu lạnh

Hai thách thức quen thuộc của lọc cộng tác định hình thiết kế mô hình và phạm vi thực nghiệm của đề tài (mục 1.2.2).

Độ thưa dữ liệu: số cặp người dùng và sản phẩm có tương tác chỉ chiếm một phần rất nhỏ của ma trận $M \times N$. Trên dữ liệu của đề tài, sau khi lọc k-core, mật độ khoảng 0,28% trên mẫu thực nghiệm với $k = 10$ (Bảng 3.2), và khoảng 0,03% trên toàn bộ dữ liệu với $k = 5$ (Bảng 3.1).

Khởi đầu lạnh xảy ra khi một người dùng hoặc sản phẩm chưa có lịch sử tương tác, nên mô hình lọc cộng tác không có dữ liệu để học vector biểu diễn của đối tượng đó [11]. Đề tài phân biệt hai trường hợp. Khởi đầu lạnh của người dùng nằm ngoài phạm vi đánh giá định lượng: mọi khách được đánh giá đều có lịch sử mua trước mốc dự đoán (mục 3.2.3). Khi hệ thống được sử dụng, khách mới nhận danh sách sản phẩm phổ biến, và chỉ khi khách đã có lịch sử mua thì mô hình đề xuất mới được dùng (mục 3.7). Khởi đầu lạnh của sản phẩm cũng nằm ngoài phạm vi đánh giá, vì tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện trước mốc dự đoán (mục 3.2.4). Dù vậy, do dữ liệu thưa, nhiều sản phẩm và khách hàng chỉ có ít tương tác, nên vector mã ID của chúng được học từ rất ít dữ liệu. Đây là lý do đề tài bổ sung đặc trưng nội dung và ngữ cảnh (mục 2.4.1, 3.3).

2.2 Lọc cộng tác và nhân tử hóa ma trận

2.2.1 Mô hình nhân tử hóa ma trận

Nhân tử hóa ma trận chiếu người dùng và sản phẩm vào một không gian ẩn chung có số chiều $d \ll \min(M, N)$ [2]. Người dùng u được biểu diễn bởi vector $p_u \in \mathbb{R}^d$, sản phẩm i bởi vector $q_i \in \mathbb{R}^d$, và mức độ tương tác dự đoán là tích vô hướng:

$$\hat{y}_{ui} = p_u^T q_i = \sum_{f=1}^{d} p_{uf} q_{if} \tag{2.5}$$

Các biến thể của MF khác nhau ở cách học hai ma trận P và Q. Phân rã giá trị kỳ dị (SVD) cổ điển cần ma trận đầy đủ, nên không áp dụng trực tiếp được cho ma trận tương tác thưa, nơi phần lớn ô chưa được quan sát. Các biến thể dùng trong hệ gợi ý thay vào đó tối ưu sai số trên các ô đã biết, kèm điều chuẩn. Với phản hồi ẩn, BPR (mục 2.2.3) tối ưu trực tiếp thứ hạng theo cặp; đề tài dùng BPR-MF làm mô hình đối chứng MF chính.

2.2.2 Hạn chế của tích vô hướng

Tích vô hướng kết hợp các chiều ẩn theo dạng tuyến tính. Các tác giả của kiến trúc NCF (mục 2.3) lập luận rằng vì vậy phép toán này không học được tương tác phi tuyến giữa các chiều ẩn của người dùng và sản phẩm. Lập luận này là động cơ của kiến trúc NCF. Việc bổ sung thành phần phi tuyến có thực sự cải thiện chất lượng gợi ý hay không phụ thuộc vào dữ liệu, và được đề tài kiểm tra bằng thực nghiệm trên dữ liệu H&M (Chương 4).

2.2.3 Tối ưu thứ hạng theo cặp: BPR

Các mô hình MF, GMF và MLP dự đoán độc lập từng điểm $\hat{y}_{ui}$ rồi so với nhãn nhị phân. Bayesian Personalized Ranking (BPR) [12] thay vào đó tối ưu trực tiếp thứ hạng tương đối theo cặp. BPR giả định người dùng ưa thích sản phẩm đã tương tác i hơn sản phẩm chưa tương tác j. Với mỗi bộ ba (u, i, j) trong đó $i \in \mathcal{I}_u$ và $j \notin \mathcal{I}_u$, hàm mất mát BPR là:

$$\mathcal{L}_{BPR} = -\sum_{(u,i,j)\in\mathcal{D}_S} \ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) + \lambda_\Theta \|\Theta\|^2 \tag{2.6}$$

trong đó $\mathcal{D}_S$ là tập các bộ ba được lấy mẫu. Khi $\hat{y}_{ui}$ được tính theo Công thức (2.5), ta có mô hình BPR-MF dùng làm đối chứng ở Chương 4. Mục tiêu theo cặp của BPR sát với bài toán xếp hạng Top-K hơn hàm mất mát theo từng điểm, nhưng BPR-MF vẫn là mô hình tuyến tính.

2.3 Kiến trúc lọc cộng tác bằng mạng nơ-ron (NCF)

Kiến trúc NCF (*neural collaborative filtering*) do He và cộng sự [3] đề xuất gồm hai mô hình thành phần, GMF và MLP, và mô hình hợp nhất của chúng, NeuMF.

2.3.1 Generalized Matrix Factorization (GMF)

GMF là dạng mạng nơ-ron của MF. Mô hình nhân từng phần tử (tích Hadamard, ký hiệu $\odot$) vector nhúng của người dùng p_u^G với vector nhúng của sản phẩm q_i^G:

$$\phi^{GMF} = p_u^G \odot q_i^G \tag{2.7}$$

$$\hat{y}_{ui}^{GMF} = \sigma\left(h^T \phi^{GMF}\right) = \sigma\left(h^T (p_u^G \odot q_i^G)\right) \tag{2.8}$$

trong đó h là vector trọng số của lớp đầu ra và $\sigma(x) = 1/(1+e^{-x})$ là hàm sigmoid.

2.3.2 *Multi-Layer Perceptron (MLP)*

Nhánh MLP nối vector nhúng p_u^M và q_i^M thành đầu vào của một chuỗi tầng ẩn:

$$z_1 = \phi_1^{MLP} = \begin{bmatrix} p_u^M \\ q_i^M \end{bmatrix} \tag{2.9}$$

$$\phi_L^{MLP} = a_L \left(W_L^T \phi_{L-1}^{MLP} + b_L \right) \tag{2.10}$$

trong đó W_L, b_L và a_L lần lượt là ma trận trọng số, vector hệ số chệch và hàm kích hoạt phi tuyến (ví dụ ReLU) của tầng thứ L. Cấu trúc này cho phép mô hình học tương tác phi tuyến giữa biểu diễn của người dùng và của sản phẩm.

2.3.3 *Mô hình lai NeuMF*

NeuMF ghép song song nhánh tuyến tính GMF và nhánh phi tuyến MLP trước lớp dự đoán:

$$\phi^{NeuMF} = \begin{bmatrix} \phi^{GMF} \\ \phi_L^{MLP} \end{bmatrix} = \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \tag{2.11}$$

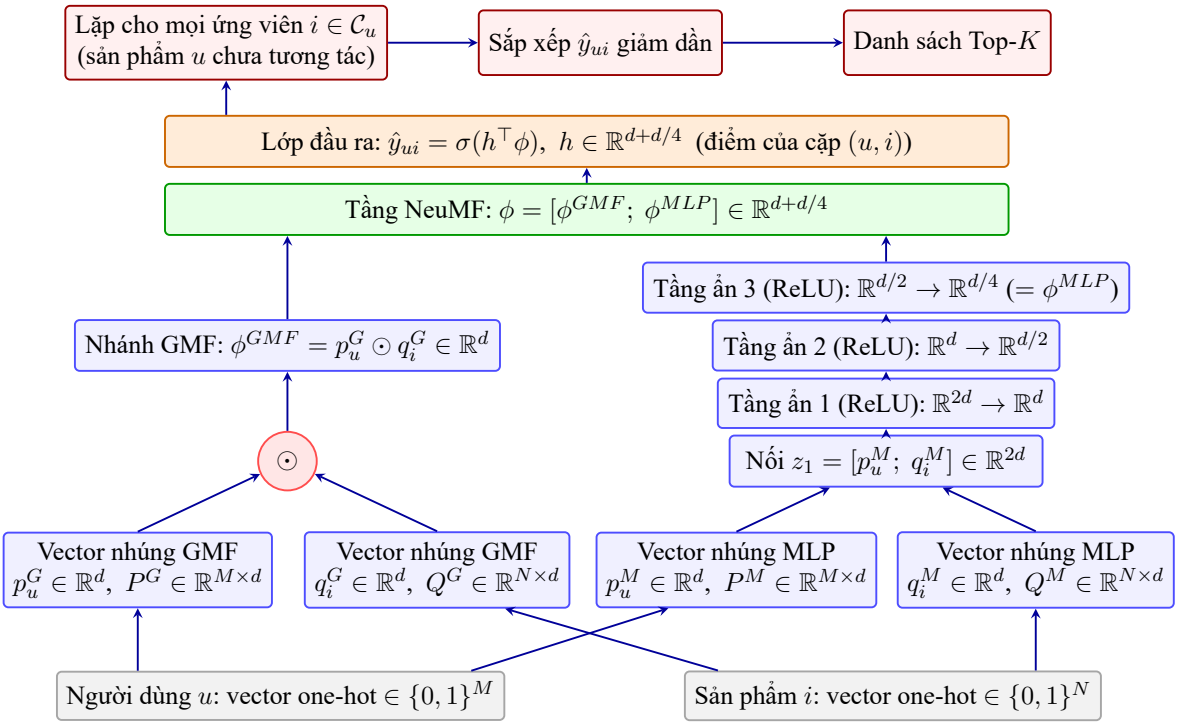
$$\hat{y}_{ui} = \sigma \left(h^T \begin{bmatrix} p_u^G \odot q_i^G \\ \phi_L^{MLP} \end{bmatrix} \right) \tag{2.12}$$

Chữ "lai" trong tên đề tài trước hết chỉ việc kết hợp hai cách mô hình hóa tương tác, nhân tử hóa ma trận (tuyến tính) và mạng nơ-ron sâu (phi tuyến), trong cùng một mô hình. Theo phân loại ở mục 2.3.4, NeuMF là mô hình hợp nhất sớm ở mức biểu diễn. Mô hình đề xuất NeuMF-F (mục 3.3) giữ cấu trúc này và bổ sung đặc trưng sản phẩm, khách hàng và thời gian vào vector của cả hai nhánh. Vì kết hợp lọc cộng tác với thông tin nội dung, NeuMF-F cũng là một hệ gợi ý lai theo nghĩa rộng của phân loại ở mục 2.1.1. Hình 2.1 trình bày kiến trúc NeuMF với kích thước của từng ma trận và từng tầng.

2.3.4 *Hợp nhất sớm và hợp nhất muộn*

Khi hệ gợi ý kết hợp nhiều nguồn thông tin, hay nhiều góc nhìn về người dùng và sản phẩm, có hai cách hợp nhất cơ bản. Hai cách này khác nhau ở mức diễn ra phép hợp nhất [8], [13].

– Hợp nhất sớm (*early fusion*) diễn ra ở mức đặc trưng hoặc biểu diễn. Các vector $v_1, \ldots, v_m$ của từng góc nhìn được nối thành một biểu diễn chung,



Hình 2.1: Kiến trúc NeuMF từ đầu vào đến danh sách Top-K. M là số người dùng, N là số sản phẩm và d là số chiều vector nhúng. Trong cài đặt của đề tài, hai nhánh dùng cùng d và tháp MLP giảm một nửa số chiều qua mỗi tầng.

rồi một mô hình h duy nhất học tương tác giữa chúng và đưa ra dự đoán:

$$p = h\big([v_1;\ v_2;\ \ldots;\ v_m]\big) \tag{2.13}$$

– Hợp nhất muộn (*late fusion*) diễn ra ở mức điểm dự đoán. Mỗi góc nhìn được xử lý bởi một mô hình riêng h_j, rồi các dự đoán được kết hợp bằng một cơ chế F, như lấy trung bình, bỏ phiếu, trọng số cố định hoặc một mô hình học:

$$p = F\big(h_1(v_1),\ h_2(v_2),\ \ldots,\ h_m(v_m)\big) \tag{2.14}$$

Khi F là tổng có trọng số, đây chính là cách lai có trọng số trong phân loại ở mục 2.1.1. Mô hình lai ở chương 3 luận án (mục 2.1.1) thuộc loại này, và mô hình đối chứng Hybrid-CBCF của đề tài cũng vậy. Ở hai mô hình này, F là bỏ phiếu hoặc tổng có trọng số của điểm từ ba mô hình truyền thống.

Hợp nhất sớm học được tương tác giữa các góc nhìn nhưng cần một mô hình phù hợp với mọi góc nhìn. Hợp nhất muộn linh hoạt hơn nhưng không nắm được tương tác giữa các góc nhìn, vì chỉ làm việc trên kết quả dự đoán.

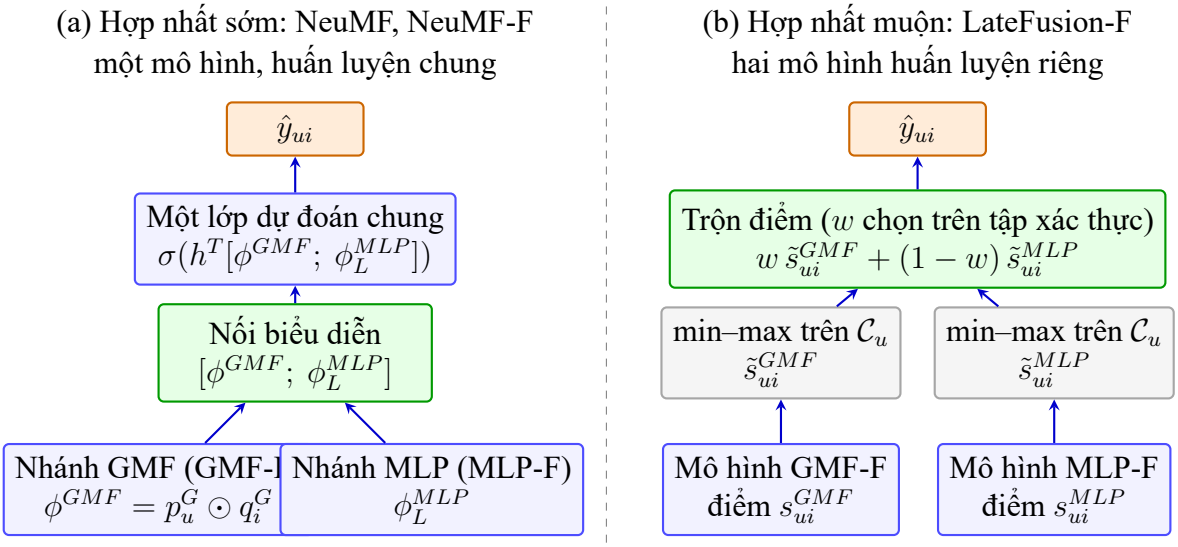
Trong đề tài, hai góc nhìn chính là hai cách mô hình hóa tương tác: góc nhìn

tuyến tính của nhánh MF (vector $p_u^G \odot q_i^G$ của GMF) và góc nhìn phi tuyến của nhánh DNN (vector cuối ϕ_L^{MLP} của MLP). NeuMF nối hai vector này rồi đưa qua một lớp dự đoán chung (Công thức (2.11), (2.12)), nên là mô hình hợp nhất sớm ở mức biểu diễn và được huấn luyện chung từ đầu đến cuối (Hình 2.2a). NeuMF-F giữ cách hợp nhất này với hai nhánh có đặc trưng GMF-F và MLP-F. Ngoài ra, đặc trưng nội dung và ngữ cảnh được cộng vào vector của từng nhánh ngay ở đầu vào, tức cũng được hợp nhất sớm với thông tin cộng tác (mục 3.3.1).

Hợp nhất muộn tương ứng là trộn điểm của hai mô hình MF và DNN được huấn luyện riêng:

$$\hat{y}_{ui} = w\,\tilde{s}_{ui}^{MF} + (1-w)\,\tilde{s}_{ui}^{DNN}, \qquad \tilde{s}_{ui} = \frac{s_{ui} - \min_{j\in\mathcal{C}_u} s_{uj}}{\max_{j\in\mathcal{C}_u} s_{uj} - \min_{j\in\mathcal{C}_u} s_{uj}} \tag{2.15}$$

trong đó điểm s_{ui} của mỗi mô hình được chuẩn hóa min–max trên tập ứng viên $\mathcal{C}_u$ của người dùng u để hai thang điểm so sánh được, và $w \in [0,1]$ được chọn trên tập xác thực. Với $w = 1$ hoặc $w = 0$, thứ hạng trùng với thứ hạng của từng thành phần. Để so sánh công bằng với NeuMF-F, đề tài dùng chính hai thành phần của nó: LateFusion-F trộn điểm của GMF-F và MLP-F được huấn luyện riêng (Hình 2.2b). Riêng nhánh MLP khi đứng một mình chỉ nối vector người dùng và sản phẩm ở đầu vào; đó là một mô hình DNN thuần, không phải phép hợp nhất MF với DNN.



Hình 2.2: Hợp nhất sớm ở mức biểu diễn (NeuMF, NeuMF-F) và hợp nhất muộn ở mức điểm dự đoán (LateFusion-F)

2.3.5 Lấy mẫu âm và hàm mất mát entropy chéo nhị phân

Phản hồi ẩn chỉ cho các tương tác dương ($y_{ui} = 1$). Kỹ thuật lấy mẫu âm (*negative sampling*) chọn ngẫu nhiên các sản phẩm người dùng chưa tương tác để gán nhãn âm ($y_{ui} = 0$); đây là cách huấn luyện NCF. Hàm mất mát entropy chéo nhị phân (*binary cross-entropy*, BCE) được dùng để tối ưu tham số mô hình:

$$\mathcal{L}_{BCE} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] \tag{2.16}$$

trong đó $\mathcal{Y}$ là tập tương tác dương và $\mathcal{Y}^-$ là tập cặp âm được lấy mẫu.

2.4 Các hướng nghiên cứu gần đây

Sau NCF, lĩnh vực hệ gợi ý phát triển theo nhiều hướng. Mục này chỉ trình bày những hướng liên quan trực tiếp tới thiết kế của đề tài và tới hướng phát triển ở Chương 5.

2.4.1 Mô hình lai dựa trên đặc trưng

Một hướng phát triển trực tiếp của ý tưởng kết hợp tuyến tính và phi tuyến là các mô hình dùng nhiều đặc trưng hơn cặp mã người dùng và sản phẩm, xuất phát từ bài toán dự đoán tỉ lệ nhấp chuột. Factorization Machines (FM) [14] tổng quát hóa MF cho vector đặc trưng bất kỳ: mỗi đặc trưng có một vector ẩn, và tương tác bậc hai giữa hai đặc trưng được mô hình hóa bằng tích vô hướng của hai vector ẩn đó. Khi đặc trưng chỉ gồm mã người dùng và mã sản phẩm, FM trở về MF. Wide & Deep [15] chạy song song một nhánh tuyến tính để ghi nhớ các tổ hợp đặc trưng và một nhánh MLP để khái quát hóa, hai nhánh được huấn luyện chung. DeepFM [16] thay nhánh tuyến tính bằng FM. Các kiến trúc này có chung cấu trúc của NeuMF: một thành phần tuyến tính kiểu nhân tử hóa, một thành phần phi tuyến kiểu MLP, hợp nhất ở lớp dự đoán. Khác biệt là đầu vào gồm cả đặc trưng chứ không chỉ mã ID. NeuMF-F đi theo hướng này: giữ hai nhánh GMF và MLP, và biểu diễn mỗi người dùng, sản phẩm bằng tổng của vector nhúng mã ID và một phép chiếu tuyến tính của đặc trưng (mục 3.3).

Đặc trưng cũng là cách xử lý khởi đầu lạnh của sản phẩm. Một sản phẩm mới chưa có tương tác nên không có vector mã ID có nghĩa, nhưng vẫn có thuộc tính và mô tả để đặt nó gần các sản phẩm tương tự. DropoutNet [17] đề xuất một kỹ thuật huấn luyện cho mô hình nhận cả biểu diễn sở thích lẫn nội dung: khi huấn luyện, phần biểu diễn học từ tương tác bị bỏ ngẫu nhiên, buộc mô hình học cách chấm điểm từ nội dung. NeuMF-F dùng kỹ thuật này dưới dạng một siêu tham số, là xác suất bỏ

ngẫu nhiên vector mã ID của sản phẩm khi huấn luyện (mục 3.3.1). Vì sản phẩm mới không thuộc tập ứng viên của đề tài (mục 3.2.4), kỹ thuật này ở đây chỉ đóng vai trò điều chuẩn.

Văn bản của sản phẩm (tên, mô tả) được biểu diễn theo cách cổ điển của lọc nội dung. Trọng số TF-IDF [18] cho từ xuất hiện nhiều trong mô tả của một sản phẩm nhưng hiếm trong toàn danh mục trọng số cao. Ma trận TF-IDF sau đó được giảm chiều bằng phân rã giá trị kỳ dị rút gọn, tức phân tích ngữ nghĩa tiềm ẩn [19], để các mô tả cùng chủ đề nhưng dùng từ khác nhau có vector gần nhau. Cách biểu diễn này không cần dữ liệu tương tác và không cần nhiều tài nguyên tính toán.

2.4.2 Gợi ý theo chuỗi hành vi

NeuMF và MF coi lịch sử của người dùng là một tập hợp không thứ tự. Gợi ý theo chuỗi mô hình hóa trình tự $(i_1, \ldots, i_t)$ để dự đoán i_{t+1}. SASRec [20] dùng cơ chế tự chú ý một chiều trên chuỗi hành vi; BERT4Rec [21] dùng Transformer hai chiều và học bằng cách che ngẫu nhiên một số vị trí trong chuỗi rồi dự đoán lại. Hướng này hợp với dữ liệu có phiên rõ ràng. Giao dịch H&M chỉ ghi ngày mua, không có giờ hay mã phiên, và nhiều sản phẩm được mua cùng ngày nên thứ tự trong ngày không xác định. Vì vậy đề tài dùng thời gian để chia dữ liệu và làm đặc trưng tổng hợp, như doanh số gần đây của sản phẩm và khoảng cách tới lần mua gần nhất của khách (mục 3.2.5); mô hình chuỗi là hướng phát triển.

2.4.3 Học biểu diễn trên đồ thị

Ma trận tương tác giữa người dùng và sản phẩm có thể xem là một đồ thị hai phía. NGCF [22] lan truyền vector nhúng qua láng giềng nhiều bước để mã hóa cả tương tác bậc cao. LightGCN [23] bỏ các phép biến đổi và hàm kích hoạt phi tuyến, chỉ giữ phép lan truyền tuyến tính:

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|}\sqrt{|\mathcal{N}_i|}} e_i^{(k)}, \qquad e_u^* = \sum_{k=0}^{K} \alpha_k \, e_u^{(k)} \tag{2.17}$$

trong đó $\mathcal{N}_u$ là tập sản phẩm kề với người dùng u trên đồ thị và e_u^* là biểu diễn cuối, tổng có trọng số qua K tầng lan truyền. LightGCN là một hướng phát triển của đề tài (mục 5.3), với điều kiện được đánh giá theo cùng quy trình.

2.4.4 Mô hình tự mã hóa biến phân

Mult-VAE [24] nhận toàn bộ vector mua $x_u \in \{0,1\}^N$ của một người dùng làm đầu vào, mã hóa thành một phân phối ẩn Gauss $q_\phi(z_u \mid x_u)$, rồi giải mã ra phân phối đa thức trên toàn bộ danh mục, $\pi(z_u) = \text{softmax}(f_\theta(z_u))$. Mô hình được huấn luyện bằng cách cực đại cận dưới biến phân, với hệ số β điều chỉnh số hạng KL:

$$\mathcal{L}_\beta(x_u) = \mathbb{E}_{q_\phi(z_u|x_u)}\big[\log p_\theta(x_u \mid z_u)\big] - \beta \cdot \mathrm{KL}\big(q_\phi(z_u \mid x_u) \,\big\|\, p(z_u)\big) \tag{2.18}$$

với $\log p_\theta(x_u \mid z_u) = \sum_i x_{ui} \log \pi_i(z_u)$. Khác NeuMF, Mult-VAE chấm điểm cả danh mục trong một lượt và không cần lấy mẫu âm, nên hợp với cách đánh giá xếp hạng toàn bộ. Đề tài chưa cài đặt mô hình này; nó là một hướng phát triển.

2.4.5 Lý do chọn kiến trúc hai nhánh

Đề tài chọn kiến trúc hai nhánh của NeuMF và bổ sung đặc trưng thành NeuMF-F, thay vì các hướng ở trên, vì ba lý do. Về dữ liệu, tệp giao dịch H&M không có phiên để dùng mô hình chuỗi, nhưng có thuộc tính và mô tả văn bản của sản phẩm, loại thông tin mà cách biểu diễn "vector nhúng ID cộng đặc trưng" khai thác trực tiếp. Về mục tiêu, hai nhánh tách biệt cho phép đo riêng đóng góp của đặc trưng và của cách hợp nhất (mục 1.1.3). Về tài nguyên, thực nghiệm chạy trên máy tính cá nhân với 16 GB bộ nhớ, không đủ cho các mô hình sinh quy mô lớn như mô hình ngôn ngữ lớn hay mô hình khuếch tán.

2.5 Các độ đo đánh giá Top-K

Với mỗi người dùng được đánh giá u, mô hình xếp hạng tập ứng viên $\mathcal{C}_u$ và trả về danh sách $\text{Rec}_K(u)$ gồm K sản phẩm đầu. Gọi T_u là tập sản phẩm đúng của u và $\text{hits}_u = |T_u \cap \text{Rec}_K(u)|$. Khi chia dữ liệu theo một mốc thời gian chung như trong đề tài, một người dùng có thể có nhiều sản phẩm đúng. Mọi độ đo được tính cho từng người dùng rồi lấy trung bình trên tập người dùng được đánh giá $\mathcal{U}_{test}$.

Hit Ratio (HR@K) tính một người dùng là "trúng" nếu có ít nhất một sản phẩm đúng trong top-K:

$$\text{HR@K} = \frac{1}{|\mathcal{U}_{test}|} \sum_{u \in \mathcal{U}_{test}} \mathbb{I}\left(\text{hits}_u \geq 1\right) \tag{2.19}$$

Precision@K là tỉ lệ gợi ý đúng trong K sản phẩm; Recall@K là tỉ lệ sản phẩm

đúng được tìm lại:

$$\text{Precision@K}(u) = \frac{\text{hits}_u}{K}, \qquad \text{Recall@K}(u) = \frac{\text{hits}_u}{|T_u|} \tag{2.20}$$

Khi $|T_u| = 1$, Recall@K trùng HR@K và Precision@K bằng HR@K chia cho K; hai độ đo này chỉ mang thông tin riêng khi người dùng có nhiều sản phẩm đúng.

NDCG@K (*normalized discounted cumulative gain*) thưởng nhiều hơn khi sản phẩm đúng nằm ở vị trí cao. Với mức liên quan nhị phân, định nghĩa của Järvelin và Kekäläinen [25] là:

$$\begin{aligned} \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}, \\ \text{DCG@K}(u) &= \sum_{j=1}^{K} \frac{\mathbb{I}(\text{Rec}_K(u)_j \in T_u)}{\log_2(j+1)}, \\ \text{IDCG@K}(u) &= \sum_{j=1}^{\min(|T_u|,K)} \frac{1}{\log_2(j+1)} \end{aligned} \tag{2.21}$$

IDCG là giá trị DCG khi mọi sản phẩm đúng xếp ở đầu danh sách, nên NDCG@K nằm trong $[0, 1]$. Với $|T_u| = 1$ và sản phẩm đúng ở hạng r, NDCG@K bằng $1/\log_2(r+1)$ nếu $r \leq K$ và bằng 0 nếu ngược lại.

2.5.1 Xếp hạng toàn bộ và xếp hạng trên tập lấy mẫu

Một số công trình, trong đó có NCF, đánh giá bằng cách xếp sản phẩm đúng giữa một tập nhỏ ứng viên lấy mẫu, cụ thể là sản phẩm kiểm thử cùng 100 sản phẩm người dùng chưa tương tác. Krichene và Rendle [26] chứng minh độ đo trên tập ứng viên lấy mẫu không nhất quán với độ đo trên toàn bộ danh mục, thậm chí có thể đảo ngược kết luận "A tốt hơn B", và khuyến nghị không lấy mẫu. Đề tài vì vậy chỉ dùng cách xếp hạng toàn bộ (*full ranking*). Mỗi người dùng được xếp hạng trên toàn bộ tập ứng viên, trừ sản phẩm đã mua; ở tập kiểm thử của mẫu kiểm định, tập này có khoảng 6.710 sản phẩm. Ở giai đoạn phát triển, một phép đối chiếu với cách lấy mẫu 99 sản phẩm cho thấy thứ hạng giữa các mô hình thay đổi giữa hai cách đánh giá (mục 4.6).

2.5.2 Độ đo ngoài độ chính xác

Nếu chỉ tối ưu HR@K và NDCG@K, mô hình có thể thiên về gợi ý các sản phẩm phổ biến nhất, vốn dễ trúng nhưng ít giá trị cá nhân hóa [27]. Để mô tả danh sách gợi ý ngoài độ chính xác, đề tài dùng độ phủ (*coverage*): tỉ lệ sản phẩm của không

gian ứng viên $\mathcal{I}_{cand}$ xuất hiện trong danh sách gợi ý của ít nhất một người dùng:

$$\text{Coverage@K} = \frac{\left|\bigcup_{u \in \mathcal{U}_{test}} \text{Rec}_K(u)\right|}{|\mathcal{I}_{cand}|} \tag{2.22}$$

Độ phủ thấp cho thấy mô hình chỉ dùng một phần nhỏ danh mục. Trường hợp giới hạn là Most Popular, khi mọi người dùng nhận gần như cùng một danh sách. Độ đo này chỉ mang tính mô tả.

2.6 Các công trình liên quan

Bảng 2.1 tổng hợp các công trình liên quan trực tiếp đến hướng tiếp cận của đề tài. Các công trình dùng dữ liệu, cách chia dữ liệu và giao thức đánh giá khác nhau; bảng chỉ tổng hợp phương pháp và đóng góp để làm cơ sở lựa chọn cách làm, không dùng số liệu của chúng làm chuẩn so sánh.

Bảng 2.1: Các công trình nghiên cứu liên quan

Tác giả, năm	Mô hình, phương pháp	Dữ liệu	Đóng góp chính và hạn chế
Sarwar và cộng sự, 2001 [10]	Lọc cộng tác theo sản phẩm (ItemKNN)	MovieLens	Gợi ý theo độ tương đồng giữa sản phẩm, tính trước được và dễ giải thích. Hạn chế: ma trận tương đồng tăng theo bình phương số sản phẩm; chất lượng giảm khi dữ liệu quá thưa.
Rendle và cộng sự, 2009 [12]	BPR	MovieLens, Netflix	Khung tối ưu theo cặp cho phản hồi ẩn. Hạn chế: mô hình đi kèm là tuyến tính.
He và cộng sự, 2017 [3]	NCF, NeuMF	MovieLens, Pinterest	Đề xuất khung NCF kết hợp GMF và MLP. Hạn chế: chỉ dùng mã ID, chưa dùng đặc trưng nội dung.
Cheng và cộng sự, 2016 [15]	Wide & Deep	Google Play	Kết hợp ghi nhớ (nhánh tuyến tính) và khái quát hóa (nhánh sâu). Hạn chế: cần xây dựng tổ hợp đặc trưng thủ công.
Guo và cộng sự, 2017 [16]	DeepFM	Criteo, dữ liệu doanh nghiệp	Thay nhánh tuyến tính bằng Factorization Machines. Hạn chế: chi phí tăng khi số đặc trưng lớn.

Tác giả, năm	Mô hình, phương pháp	Dữ liệu	Đóng góp chính và hạn chế
Volkovs và cộng sự, 2017 [17]	DropoutNet	CiteULike, RecSys Challenge 2017	Bỏ ngẫu nhiên biểu diễn sở thích khi huấn luyện để mô hình chấm được đối tượng khởi đầu lạnh. Hạn chế: cần đặc trưng nội dung đủ giàu thông tin.
Kang và McAuley, 2018 [20]	SASRec	Amazon, Steam, MovieLens	Mô hình hóa chuỗi hành vi bằng cơ chế tự chú ý. Hạn chế: cần thứ tự hoặc phiên rõ ràng, không có trên dữ liệu chỉ ghi ngày mua như H&M.
Wang và cộng sự, 2019; He và cộng sự, 2020 [22], [23]	NGCF, LightGCN	Gowalla, Amazon-Book, Yelp2018	Lan truyền tín hiệu tương tác bậc cao trên đồ thị hai phía. Hạn chế: chi phí tăng nhanh theo quy mô đồ thị.
Liang và cộng sự, 2018 [24]	Mult-VAE	MovieLens-20M, Netflix, Million Song	Mô hình hóa cả vector mua của người dùng, chấm toàn bộ danh mục trong một lượt. Hạn chế: không dùng thứ tự thời gian; cần đủ lịch sử cho mỗi người dùng.
Li và cộng sự, 2024 [28]	Khảo sát mạng nơ-ron sâu cho lọc cộng tác	Nhiều lĩnh vực	Hệ thống hóa các kiến trúc mạng nơ-ron dùng trong lọc cộng tác. Hạn chế: là bài khảo sát, không có thực nghiệm riêng.
Hồ Thị Linh, 2023 [8]	Tích hợp đa nguồn: hợp nhất muộn (bỏ phiếu, MLP), hợp nhất sớm ma trận tương tác và văn bản, Transformer	MovieLens, Amazon	Hệ thống hóa hợp nhất sớm và hợp nhất muộn cho hệ gợi ý đa nguồn. Khác với đề tài: bài toán dự đoán điểm đánh giá (MAE, RMSE), không xếp hạng Top-K trên phản hồi ẩn.

Tác giả, năm	Mô hình, phương pháp	Dữ liệu	Đóng góp chính và hạn chế
Ferrari Dacrema và cộng sự, 2019 [29]	Tái lập 18 mô hình gợi ý học sâu	MovieLens, Pinterest, Netflix	Phần lớn mô hình học sâu được tái lập không vượt các mô hình đơn giản được tinh chỉnh tốt; mã nguồn NCF chọn số epoch trên tập kiểm thử. Hạn chế: chủ yếu dùng giao thức lấy mẫu của bài gốc.
Rendle và cộng sự, 2020 [30]	So sánh MF với NeuMF	MovieLens 1M, Pinterest	MF được tinh chỉnh kỹ vượt NeuMF trên chính dữ liệu và giao thức của bài NCF. Hạn chế: vẫn dùng giao thức lấy mẫu của bài gốc.
Đề tài, 2026	NeuMF-F: hai nhánh GMF-F, MLP-F (vector nhúng ID cộng đặc trưng), hợp nhất sớm	H&M (hai mẫu khách hàng độc lập); kiểm chứng trên Amazon Beauty	Một sản phẩm là một mẫu thiết kế; đặc trưng theo thời điểm; tinh chỉnh trên mẫu phát triển, đánh giá một lần trên mẫu khách hàng độc lập theo kế hoạch đăng ký trước; so với 13 mô hình đối chứng xếp thành ba nhóm, kèm một mô hình lai truyền thống bổ sung; kiểm định có hiệu chỉnh Holm; phân tích bóc tách; chạy lại trên bộ dữ liệu thứ hai.

2.6.1 Ba nghiên cứu nền tảng và đối chiếu thiết lập thực nghiệm

Ba nghiên cứu là nền tảng trực tiếp của đề tài. He và cộng sự [3] đề xuất kiến trúc NeuMF mà NeuMF-F kế thừa. Rendle và cộng sự [30] kiểm tra lại câu hỏi NeuMF có thực sự tốt hơn MF được tinh chỉnh kỹ hay không, câu hỏi mà đề tài đặt lại trên dữ liệu H&M. Luận án của Hồ Thị Linh [8] hệ thống hóa hai cách hợp nhất và việc bổ sung nguồn thông tin ngoài ma trận tương tác, khung phân loại mà đề tài dùng để so sánh NeuMF-F với LateFusion-F. Bảng 2.2 đối chiếu thiết lập thực nghiệm của ba nghiên cứu với đề tài; số liệu của mỗi nghiên cứu lấy từ chính bài gốc.

Bảng 2.2: Thiết lập thực nghiệm và kết quả công bố của ba nghiên cứu nền tảng, đặt cạnh thiết lập của đề tài

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
He và cộng sự, 2017 [3]: NCF, NeuMF	MovieLens 1M (6.040 người dùng, 3.706 phim, 1.000.209 tương tác) và Pinterest (55.187 người dùng, 9.916 sản phẩm, 1.500.809 tương tác), phản hồi ẩn. Xếp hạng Top-K; HR@10, NDCG@10	Giữ lại tương tác mới nhất của mỗi người dùng làm kiểm thử. 101 ứng viên: sản phẩm kiểm thử và 100 sản phẩm chưa tương tác lấy ngẫu nhiên	NeuMF có tiền huấn luyện: MovieLens HR@10 = 0,730, NDCG@10 = 0,447 (64 nhân tố); Pinterest HR@10 = 0,880, NDCG@10 = 0,558 (16 nhân tố). Trung bình cao hơn eALS 4,5% và BPR 4,9% (tương đối).
Rendle và cộng sự, 2020 [30]: MF so với NeuMF	Như NCF: MovieLens 1M và Pinterest; HR@10, NDCG@10	Như NCF: giữ lại tương tác mới nhất; 101 ứng viên	MF tinh chỉnh kỹ: MovieLens 0,7294 / 0,4523, Pinterest 0,8895 / 0,5794 (HR@10 / NDCG@10); NeuMF trong bảng so sánh của bài: 0,7093 / 0,4349 và 0,8777 / 0,5576. MF cao hơn NeuMF 2,8% HR@10 và 4,0% NDCG@10 (MovieLens), 1,3% và 3,9% (Pinterest).

Nghiên cứu	Dữ liệu; bài toán và độ đo	Cách chia; tập ứng viên	Kết quả công bố (số liệu của bài gốc)
Hồ Thị Linh, 2023 [8]: tích hợp đa nguồn	MovieLens (77.764 đánh giá, 27.042 người dùng, 8.203 phim); Amazon Electronics (85.065 đánh giá, 1.042 người dùng), Toys and Games (71.780; 5.462), Video Games (98.769; 2.291). Dự đoán điểm đánh giá; RMSE, MAE, Precision	Chia ngẫu nhiên 80% huấn luyện (20% trong đó để xác thực), 20% kiểm thử. Không xếp hạng trên tập ứng viên	Hợp nhất sớm vector MF và đặc trưng văn bản qua mạng nơ-ron (chương 4), Electronics: RMSE 1,01, Precision 82,86% so với SVD 1,16 và 69,55% (RMSE giảm 12,93%, Precision tăng 19,14%). Transformer hợp nhất nhiều góc nhìn (chương 5), Toys and Games: MAE 0,445, RMSE 0,743, Precision 92,07% so với SVD 0,844 / 1,120 / 68,06%.
Đề tài, 2026	H&M, mẫu kiểm định (7.994 khách, 6.749 sản phẩm, 243.696 cặp) và Amazon Beauty 5-core (10.681 khách, 6.069 sản phẩm, 94.009 cặp), phản hồi ẩn. Xếp hạng Top-K; NDCG@10 (chính), Recall, HR, Precision ở $K = 5, 10, 15, 20$	Theo mốc thời gian chung; mẫu khách hàng độc lập (H&M). Ứng viên: mọi sản phẩm đã có dữ liệu huấn luyện, trừ sản phẩm khách đã mua; trung bình 6.710 (H&M), 6.058 (Amazon)	NeuMF-F so với NeuMF chỉ dùng ID: NDCG@10 +43,8% (H&M) và +65,7% (Amazon), đều có ý nghĩa thống kê. NeuMF chỉ dùng ID so với BPR-MF trên H&M: +4,6%, không khác biệt có ý nghĩa (Chương 4).

Các con số trong Bảng 2.2 không so sánh trực tiếp được với nhau. Hai bài về NCF xếp sản phẩm đúng giữa 101 ứng viên, nên HR@10 khoảng 0,7 đến 0,9. Đề tài xếp hạng trên khoảng 6 đến 7 nghìn ứng viên, nơi cùng độ đo cho giá trị thấp hơn nhiều. Luận án giải bài toán dự đoán điểm đánh giá với độ đo sai số, không xếp hạng. Vì vậy chỉ chiều và độ lớn tương đối của cải thiện so với đối chứng trong chính mỗi nghiên cứu là thông tin đọc được. Từ ba nghiên cứu này, đề tài kế thừa ba điều: kiến trúc và cách huấn luyện của NeuMF; yêu cầu tinh chỉnh đầy đủ mô hình đối chứng;

khung hợp nhất sớm, hợp nhất muộn cùng ý tưởng bổ sung thông tin ngoài ma trận tương tác.

2.7 Khoảng trống nghiên cứu

Các nghiên cứu nền tảng về NCF chủ yếu được đánh giá trên dữ liệu phim ảnh hoặc mạng xã hội hình ảnh, với giao thức giữ lại tương tác cuối và tập ứng viên lấy mẫu. Các nghiên cứu tái đánh giá cho thấy NeuMF chỉ dùng mã ID khó vượt các mô hình đơn giản được tinh chỉnh kỹ (mục 2.6). Các mô hình dùng đặc trưng khai thác được thông tin ngoài mã ID, nhưng thường được đánh giá cho bài toán dự đoán nhấp chuột chứ không phải xếp hạng Top-K trên toàn bộ danh mục. Các hướng mới hơn như học trên đồ thị, mô hình chuỗi hay mô hình ngôn ngữ lớn cần cấu trúc dữ liệu đặc thù hoặc tài nguyên vượt phạm vi của đề tài (mục 2.4).

Đề tài tập trung vào khoảng trống sau. Thứ nhất, xây dựng một mô hình lai giữ cấu trúc MF và DNN của NeuMF nhưng khai thác được đặc trưng sản phẩm, khách hàng và thời gian (NeuMF-F). Thứ hai, đánh giá mô hình này trên dữ liệu giao dịch thời trang thực tế, theo một giao thức gần với tình huống triển khai. Giao thức chia dữ liệu theo thời gian, tính đặc trưng không dùng thông tin tương lai, và lấy kết luận trên một mẫu khách hàng chưa từng được dùng để ra quyết định. Giao thức cũng tránh ba lỗi phương pháp mà các nghiên cứu tái đánh giá đã chỉ ra: chọn mô hình trên tập kiểm thử, tinh chỉnh mô hình đối chứng sơ sài và đánh giá trên tập ứng viên lấy mẫu. Thiết kế đối chứng cho phép trả lời riêng ba câu hỏi đã nêu ở mục 1.1.3: đặc trưng có giúp mô hình lai không, hợp nhất có giúp so với từng nhánh không, và hợp nhất sớm hay hợp nhất muộn phù hợp hơn.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ THIẾT KẾ MÔ HÌNH LAI NEUMF-F

Chương này trình bày phương pháp cho kết quả chính của báo cáo. Mục 3.1 mô tả quy trình tổng thể từ dữ liệu đến gợi ý, mục 3.2 trình bày dữ liệu và cách chia giai đoạn, mục 3.3 trình bày mô hình đề xuất NeuMF-F. Mục 3.4 và 3.5 trình bày cách huấn luyện, mục 3.6 quy trình đánh giá, mục 3.7 cách suy diễn và xử lý khách hàng mới, mục 3.8 hệ thống demo. Các bước xử lý chính được viết thành mã giả (Thuật toán 3.1 đến 3.7). Giai đoạn phát triển trước đó được tóm tắt ở mục 4.6; những gì rút ra từ giai đoạn này là lý do của nhiều lựa chọn trong chương.

3.1 Quy trình tổng thể của hệ thống

Hệ thống được tổ chức theo trình tự một mô hình gợi ý đi qua khi đưa vào sử dụng: xây dựng đặc trưng, huấn luyện, lưu mô hình và suy diễn (Hình 3.1). Mỗi lần chạy, đường ống nhận một mốc thời gian τ. Mọi bước chỉ dùng dữ liệu trước τ, và bước suy diễn trả về danh sách gợi ý cho giai đoạn sau τ. Đây đúng là tình huống doanh nghiệp huấn luyện mô hình trên lịch sử đến hôm nay rồi gợi ý cho những tuần tới. Việc đánh giá không nằm trong đường ống này mà là một quy trình riêng (mục 3.6). Quy trình đó gọi lại đường ống với các mốc khác nhau, rồi so danh sách gợi ý với những gì khách đã mua thật.

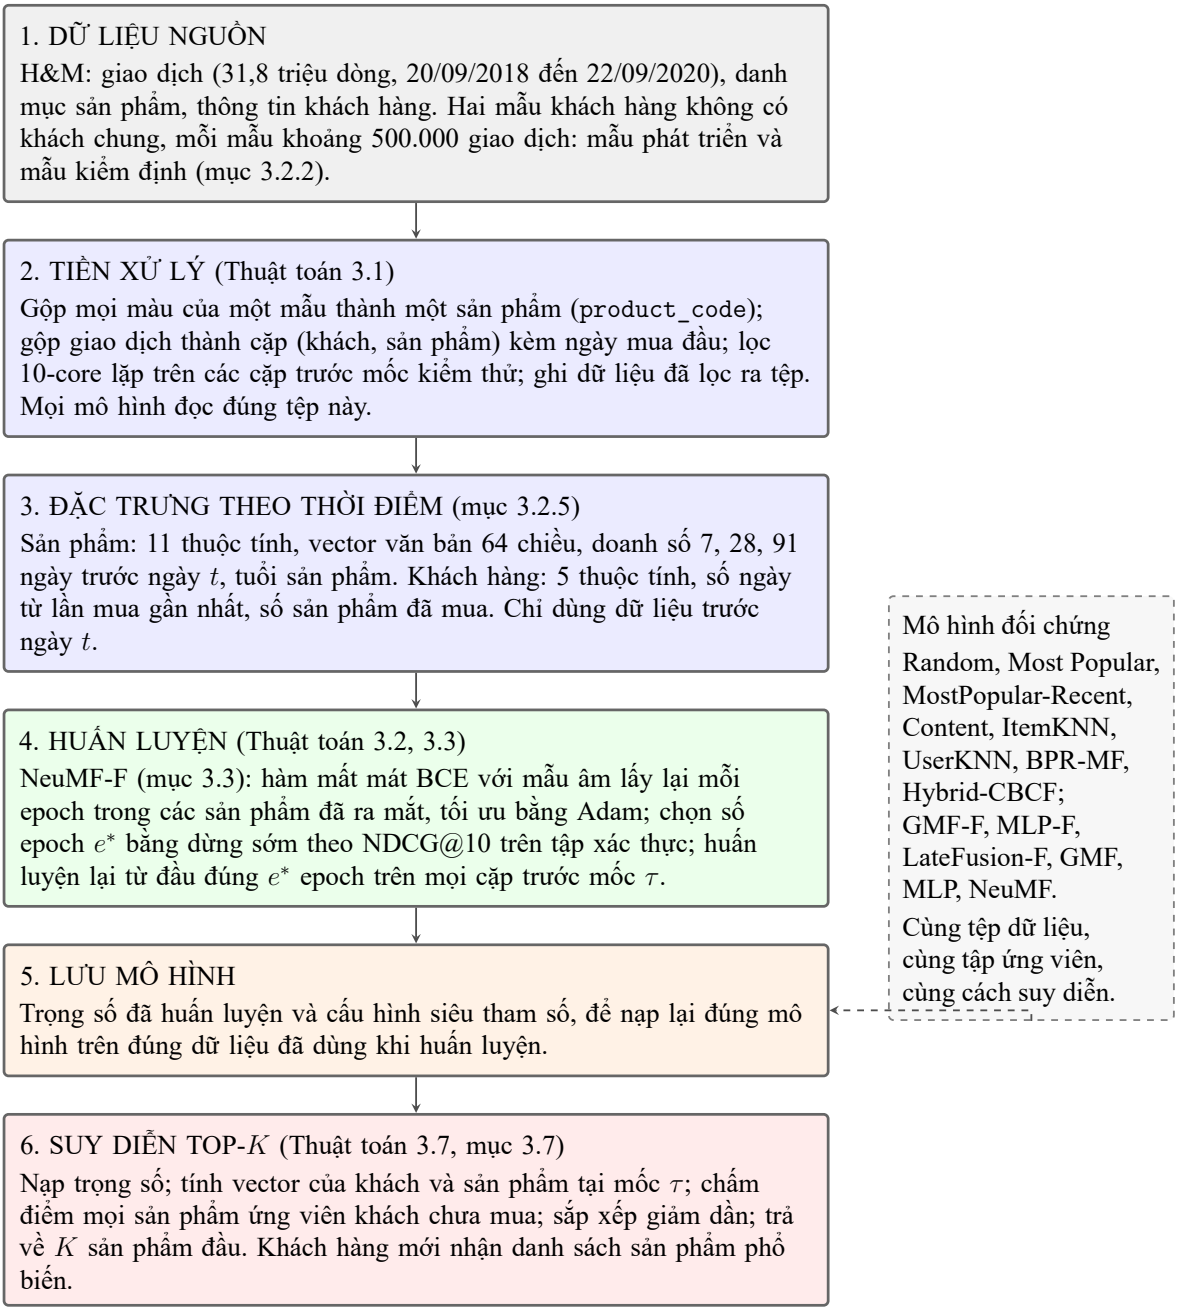
Mọi mô hình, kể cả mô hình đối chứng, đi qua cùng đường ống: cùng tệp dữ liệu, cùng tập ứng viên và cùng quy tắc loại sản phẩm đã mua, nên chênh lệch giữa hai mô hình chỉ đến từ chính mô hình. Các nguyên tắc chọn cấu hình và đánh giá được trình bày ở mục 3.6.

3.2 Dữ liệu và tiền xử lý

3.2.1 Đặc tả bộ dữ liệu H&M

Bộ dữ liệu H&M Personalized Fashion Recommendations [1] ghi lại hoạt động mua sắm thời trang thực tế của một chuỗi bán lẻ lớn. Đề tài dùng ba tệp.

- `transactions_train.csv` (3,49 GB): 31.788.324 dòng giao dịch từ 20/09/2018 đến 22/09/2020, của 1.362.281 khách hàng trên 104.547 sản phẩm. Ba trường được dùng là `customer_id` (mã khách), `article_id`



Hình 3.1: Đường ống của hệ thống từ dữ liệu đến danh sách gợi ý Top-K

(mã sản phẩm, 10 chữ số) và `t_dat` (ngày mua, không có giờ). Giá và kênh bán không được dùng.

- `articles.csv`: 105.542 sản phẩm của danh mục. Mỗi sản phẩm có 11 thuộc tính dạng mã: loại sản phẩm, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu và nhóm may mặc. Sản phẩm còn có mô tả văn bản gồm tên và mô tả chi tiết.
- `customers.csv`: 1.371.980 khách hàng với tuổi, trạng thái hội viên, tần suất nhận tin thời trang và hai cờ FN, Active. Mã bưu chính không được dùng.

Ảnh sản phẩm có trong bộ dữ liệu nhưng không được dùng làm đầu vào của mô hình; ảnh chỉ được hiển thị trong hệ thống demo (mục 3.8).

Cách đánh giá xếp hạng toàn bộ (mục 2.5) phải chấm điểm mọi sản phẩm ứng viên cho mỗi người dùng được đánh giá, nên chi phí tỉ lệ với tích số người dùng và số sản phẩm. Theo Bảng 3.1, ở quy mô đầy đủ, ngay cả với $k = 10$ vẫn còn 633.130 người dùng và 80.265 sản phẩm, tức hàng chục tỷ cặp cần chấm điểm cho mỗi mô hình. Con số này vượt khả năng của máy tính cá nhân 16 GB bộ nhớ, nên đề tài thực nghiệm trên các mẫu theo khách hàng (mục 3.2.2).

Bảng 3.1: Độ nhạy của lọc k-core trên toàn bộ dữ liệu H&M (31.788.324 dòng)

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	1.074.388	96.264	26.873.935	0,0260
5	889.062	90.690	26.215.294	0,0325
10	633.130	80.265	24.426.258	0,0481

3.2.2 Lấy mẫu theo khách hàng: mẫu phát triển và mẫu kiểm định

Đề tài lấy mẫu theo khách hàng thay vì theo dòng. Lấy mẫu theo dòng, hoặc cắt n dòng đầu, sẽ cắt vụn lịch sử của từng khách; vì tệp gốc sắp theo ngày, cách đó còn chỉ phủ vài ngày giao dịch. Cả bước lọc k-core lẫn việc chia dữ liệu theo thời gian đều hỏng nếu làm vậy. Quy trình lấy mẫu gồm hai lượt đọc tệp theo lô, với bộ nhớ đỉnh khoảng 0,5 GB:

1. Lượt 1 chọn khách: băm `customer_id` bằng một khoá cố định vào 100.000 nhóm và đếm số giao dịch của từng nhóm. Hàm băm phân khách vào nhóm một cách giả ngẫu nhiên, độc lập với hành vi mua.
2. Lượt 2 ghi mẫu: giữ toàn bộ giao dịch của các khách được chọn, trải đủ từ

20/09/2018 đến 22/09/2020.

Các mẫu được lấy từ những đoạn nhóm băm liền nhau, không chồng lên nhau, gọi là các khối. Mỗi khối gồm số nhóm ít nhất đủ khoảng 500.000 giao dịch.

- Mẫu phát triển là khối 0, các nhóm $[0, 1597)$: 500.269 giao dịch của 21.599 khách hàng. Mẫu này được dùng trong giai đoạn phát triển ban đầu; ở bản cuối của quy trình, nó chỉ dùng để tinh chỉnh trên tập xác thực.
- Khối 1 gồm các nhóm $[1597, 3160)$: 500.125 giao dịch của 21.030 khách hàng. Đây là mẫu kiểm định của bản đầu kế hoạch đánh giá. Tập kiểm thử của khối này đã được mở ngày 04/10/2026, nên khối 1 không còn dùng để kết luận (mục 4.6).
- Mẫu kiểm định là khối 2, các nhóm $[3160, 4734)$: 500.164 giao dịch của 21.351 khách hàng. Vì các đoạn nhóm không chồng nhau, không khách hàng nào thuộc cả mẫu phát triển lẫn mẫu kiểm định; điều này đã được kiểm tra trực tiếp. Mẫu kiểm định chỉ dùng cho đánh giá cuối.

Vì dùng hàm băm với khoá cố định, chạy lại luôn cho đúng cùng hai mẫu. Cần một mẫu kiểm định riêng vì tập kiểm thử của mẫu phát triển đã được xem trong giai đoạn phát triển (mục 4.6). Mẫu kiểm định gồm những khách hàng khác hẳn, nên kết quả trên mẫu này ước lượng hiệu năng của mô hình với khách hàng khác của cùng cửa hàng, trong cùng giai đoạn thời gian.

3.2.3 Ma trận tương tác và lọc k-core trước mốc kiểm thử

Mỗi sản phẩm là một mẫu thiết kế. Mã `article_id` 10 chữ số của H&M gồm mã mẫu thiết kế `product_code` và ba chữ số cuối chỉ biến thể màu, nên một mẫu áo có thể mang nhiều `article_id`. Theo góp ý của giảng viên hướng dẫn, bản cuối của giao thức coi một sản phẩm là một `product_code`, tức mọi màu của cùng một mẫu được gộp làm một sản phẩm. Khách mua nhiều màu của cùng một mẫu chỉ được tính một cặp (khách, sản phẩm). Trước mốc kiểm thử, việc gộp này giảm số sản phẩm của mẫu phát triển từ 55.971 xuống 27.370 và số cặp từ 401.293 xuống 359.181. Với mẫu kiểm định, số sản phẩm giảm từ 55.683 xuống 27.291 và số cặp từ 398.653 xuống 356.740.

Một khách có thể mua cùng một sản phẩm nhiều lần. Các giao dịch lặp được gộp thành một cặp (khách, sản phẩm) duy nhất, giữ ngày mua đầu tiên t_{ui}, trước khi lọc k-core. Nếu lọc trực tiếp trên dòng giao dịch, số lượt mua lặp sẽ làm tăng giả bậc của khách và sản phẩm: trên mẫu phát triển, 500.269 giao dịch gộp lại chỉ còn 429.964

cặp duy nhất.

Lọc k-core được lặp đến khi hội tụ, vì loại một sản phẩm có thể làm một khách rơi xuống dưới ngưỡng và ngược lại. Kết quả là mỗi khách và mỗi sản phẩm còn lại có ít nhất k đối tác khác nhau. Khác với giai đoạn phát triển ban đầu, phép lọc chỉ dùng các cặp có ngày mua đầu trước mốc kiểm thử (29/07/2020), nên việc chọn khách và sản phẩm không dùng thông tin nào của giai đoạn kiểm thử. Thuật toán 3.1 tóm tắt bước chuẩn bị dữ liệu. Sau khi lọc với $k = 10$, mẫu phát triển còn 8.039 khách, 6.801 sản phẩm và 245.644 cặp; mẫu kiểm định còn 7.994 khách, 6.749 sản phẩm và 243.696 cặp. Mã khách và mã sản phẩm được đánh lại chỉ số liên tục, và $y_{ui} = 1$ khi khách u đã mua sản phẩm i (Công thức (2.4)). Dữ liệu đã lọc của mỗi mẫu được ghi ra một tệp, và mọi mô hình đọc đúng tệp này.

Thuật toán 3.1 Chuẩn bị dữ liệu: gộp theo mẫu thiết kế và lọc k-core lặp

Đầu vào: giao dịch (c, a, t) của một mẫu (khách c, mã `article_id` a, ngày mua t); mốc kiểm thử τ_{test}; ngưỡng k
Đầu ra: tệp cặp $(c, i, t_{ci}, \textit{thuộc_kcore})$

với mỗi giao dịch (c, a, t) **làm**
  $i \leftarrow \lfloor a/1000 \rfloor$ ▷ *`product_code`: bỏ 3 chữ số chỉ màu*
gộp các giao dịch theo cặp (c, i), giữ $t_{ci} \leftarrow$ ngày mua sớm nhất ▷ *mỗi cặp một dòng*
$E \leftarrow \{(c, i) : t_{ci} < \tau_{test}\}$ ▷ *chỉ dữ liệu trước mốc kiểm thử*
lặp
  $U \leftarrow \{c : |\{i : (c, i) \in E\}| \geq k\}$; $I \leftarrow \{i : |\{c : (c, i) \in E\}| \geq k\}$
  $E' \leftarrow \{(c, i) \in E : c \in U,\ i \in I\}$; *hội_tụ* $\leftarrow (|E'| = |E|)$; $E \leftarrow E'$
đến khi *hội_tụ*
ghi mọi cặp (c, i, t_{ci}) kèm cờ $(c, i) \in E$ ra tệp, theo thứ tự cố định ▷ *mọi mô hình đọc tệp này*
trả về tệp

Khi nạp dữ liệu cho một giai đoạn, chỉ các khách và sản phẩm thuộc k-core được giữ, rồi dữ liệu huấn luyện và sản phẩm đúng được lấy theo các tập ở mục 3.2.4. Tệp chứa mọi cặp, kể cả sau mốc kiểm thử, nhưng tập kiểm thử chỉ được dựng khi chạy đánh giá cuối.

Ngưỡng k được chọn từ khảo sát ở giai đoạn phát triển (Bảng 3.2) và được giữ ở bản cuối. Ngưỡng thường gặp là $k = 5$, nhưng khi đó danh mục còn 23.067 sản phẩm và đánh giá xếp hạng toàn bộ ước tính cần khoảng 10,7 GB bộ nhớ, vượt giới hạn của máy thực nghiệm. Đề tài vì vậy chọn $k = 10$. Cái giá của lựa chọn này là dữ liệu thiên về khách mua nhiều, một hạn chế được ghi ở mục 5.2.

Bảng 3.2: Độ nhạy của mẫu phát triển theo ngưỡng lọc k-core

k	Số người dùng	Số sản phẩm	Số tương tác	Mật độ (%)
3	16.377	33.620	387.733	0,070
5	12.900	23.067	340.267	0,114
10	7.519	10.345	220.292	0,283
15	3.017	3.186	83.088	0,864

Khảo sát ở giai đoạn phát triển, theo `article_id`, trên 429.964 cặp trước khi lọc. Đề tài chọn $k = 10$.

3.2.4 Giai đoạn đánh giá và tập ứng viên

Dữ liệu được chia theo thời gian bằng hai mốc cố định, chung cho mọi khách hàng. Mốc xác thực là τ_{val} = 01/07/2020, với cửa sổ xác thực 4 tuần từ 01/07 đến 28/07/2020. Mốc kiểm thử là τ_{test} = 29/07/2020, với cửa sổ kiểm thử 8 tuần từ 29/07 đến 22/09/2020. Với mỗi mốc τ, gọi là một giai đoạn, các tập sau được định nghĩa:

$$\mathcal{D}_\tau = \{(u,i) \text{ đã lọc } k\text{-core} : t_{ui} < \tau\} \quad \text{(dữ liệu huấn luyện)} \tag{3.1}$$

$$\mathcal{I}_\tau = \{i : \exists u,\ (u,i) \in \mathcal{D}_\tau\} \quad \text{(sản phẩm có dữ liệu huấn luyện)} \tag{3.2}$$

$$\mathcal{C}_u(\tau) = \mathcal{I}_\tau \setminus \mathcal{I}_u(\tau) \quad \text{(tập ứng viên của khách } u) \tag{3.3}$$

$$T_u(\tau) = \{i \in \mathcal{C}_u(\tau) : \tau \le t_{ui} < \tau_{end}\} \quad \text{(sản phẩm đúng của } u) \tag{3.4}$$

trong đó $\mathcal{I}_u(\tau)$ là các sản phẩm u đã mua trước τ, và τ_{end} là cuối cửa sổ của giai đoạn. Chỉ những khách có dữ liệu huấn luyện trong $\mathcal{D}_\tau$ và có ít nhất một sản phẩm đúng mới được đánh giá. Có hai điểm cần giải thích.

- Tập ứng viên chỉ gồm sản phẩm đã có dữ liệu huấn luyện. Sản phẩm chưa có cặp nào trong dữ liệu huấn luyện của giai đoạn, trong đó có sản phẩm vừa ra mắt, không thuộc tập ứng viên lẫn tập sản phẩm đúng. Đây là thay đổi của bản cuối kế hoạch đánh giá, theo góp ý của giảng viên hướng dẫn. Với tập ứng viên này, mọi mô hình, kể cả mô hình chỉ dùng mã ID, đều chấm được mọi ứng viên, nên so sánh không phụ thuộc vào khả năng xử lý sản phẩm chưa có lịch sử bán. Đổi lại, kết quả không nói về khả năng gợi ý sản phẩm vừa ra mắt.
- Mô hình được huấn luyện lại trên dữ liệu mới nhất. Ở giai đoạn kiểm thử, $\mathcal{D}_{\tau_{test}}$ gồm cả cửa sổ xác thực. Tập xác thực chỉ dùng để chọn cấu hình và số epoch. Trước khi đánh giá trên tập kiểm thử, mô hình được huấn luyện lại từ đầu trên $\mathcal{D}_{\tau_{test}}$ (mục 3.6), nên lúc dự đoán mô hình đã thấy toàn bộ quá khứ như khi triển khai thật.

Đề tài không chia theo cách giữ lại tương tác cuối của từng người dùng (*leave-one-out*), cách mà NCF dùng. Cách này để lọt thông tin tương lai, vì tập huấn luyện chứa tương tác của những người dùng khác xảy ra sau thời điểm cần dự đoán [31]. Đo trên mẫu phát triển ở giai đoạn phát triển, tính trung bình theo người dùng, 11,2% tương tác trong tập huấn luyện xảy ra sau ngày mua sản phẩm kiểm thử của người dùng đó. Ngoài ra, 60,9% người dùng có sản phẩm xác thực và sản phẩm kiểm thử mua cùng một ngày. Vì vậy đề tài chia theo một mốc thời gian chung cho mọi người dùng.

Theo định nghĩa, mỗi cặp (khách, sản phẩm) chỉ có một ngày mua đầu. Do đó một cặp không thể vừa là dữ liệu huấn luyện vừa là sản phẩm đúng của cùng giai đoạn. Sản phẩm khách đã mua trước mốc cũng không bao giờ là sản phẩm đúng: mô hình dự đoán những món mới đối với khách. Bảng 3.3 tổng hợp quy mô dữ liệu của hai mẫu.

Bảng 3.3: Quy mô dữ liệu H&M của mẫu phát triển và mẫu kiểm định

	Mẫu phát triển	Mẫu kiểm định
Người dùng sau lọc 10-core	8.039	7.994
Sản phẩm (product_code) sau lọc 10-core	6.801	6.749
Cặp (khách, sản phẩm) trước mốc kiểm thử	245.644	243.696
Xác thực: cặp huấn luyện (trước 01/07/2020)	236.845	234.610
Xác thực: người dùng được đánh giá	2.569	2.579
Xác thực: cặp đúng	8.636	8.985
Kiểm thử: người dùng được đánh giá	—	3.165
Kiểm thử: cặp đúng	—	10.285
Kiểm thử: số ứng viên trung bình mỗi người dùng	—	6.710

Mỗi sản phẩm là một mẫu thiết kế (`product_code`), gộp mọi màu. Mẫu kiểm định gồm những khách hàng không có trong mẫu phát triển. Mẫu phát triển chỉ dùng tập xác thực; tập kiểm thử của nó không được dựng. Lọc 10-core chỉ dùng các cặp trước mốc kiểm thử 29/07/2020. Ứng viên và cặp đúng chỉ gồm sản phẩm đã có cặp huấn luyện trước mốc của giai đoạn.

3.2.5 Xây dựng đặc trưng theo thời điểm

Bảng 3.4 liệt kê các đặc trưng của mô hình có đặc trưng. Nguyên tắc bắt buộc là không dùng thông tin tương lai: đặc trưng của một cặp (khách u, sản phẩm i) tại ngày t chỉ được tính từ dữ liệu trước ngày t. Khi huấn luyện, mỗi cặp dương mang chính ngày mua đầu t_{ui} của nó; khi đánh giá, t là mốc τ của giai đoạn.

Đặc trưng thời gian của sản phẩm được tính như sau. Gọi $n_{i,d}$ là số giao dịch

Bảng 3.4: Đặc trưng của các mô hình có đặc trưng (NeuMF-F, GMF-F, MLP-F)

Nhóm	Đặc trưng	Mã hóa	Nguồn
Sản phẩm: thuộc tính	11 thuộc tính danh mục (loại, nhóm sản phẩm, họa tiết, nhóm màu, độ đậm màu, màu chủ đạo, bộ phận, chỉ mục, nhóm chỉ mục, khu, nhóm may mặc); sau khi gộp theo mẫu, ba thuộc tính màu là hằng số	Vector nhúng 8 chiều mỗi thuộc tính (88 chiều), học cùng mô hình	`articles.csv`
Sản phẩm: văn bản	Tên và mô tả chi tiết	TF-IDF (từ đơn và cặp từ), SVD 64 chiều, chuẩn hóa L2	`articles.csv`
Sản phẩm: thời gian tại t	Doanh số trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ "chưa từng bán trước t"	$\log(1+x)/10$; cờ 0/1 (5 chiều)	Giao dịch toàn H&M
Khách hàng: tĩnh	Nhóm tuổi (9 mức, gồm "không rõ"), trạng thái hội viên, tần suất nhận tin, FN, Active	Vector nhúng 8 chiều mỗi thuộc tính (40 chiều)	`customers.csv`
Khách hàng: thời gian tại t	Số ngày từ lần mua gần nhất (tối đa 730); số cặp đã mua	$\log(1+x)/10$ (2 chiều)	Dữ liệu huấn luyện

của sản phẩm i trong ngày d trên toàn bộ H&M và d_i^0 là ngày bán đầu tiên. Tại ngày t:

$$\begin{aligned} s_i^{(w)}(t) &= \sum_{d=t-w}^{t-1} n_{i,d}, \\ x_i^{tg}(t) &= \left[\tfrac{\log(1+s_i^{(7)})}{10},\ \tfrac{\log(1+s_i^{(28)})}{10},\ \tfrac{\log(1+s_i^{(91)})}{10},\ \tfrac{\log(1+\max(0,\,t-d_i^0))}{10},\ \mathbb{I}(d_i^0 \geq t)\right] \end{aligned} \tag{3.5}$$

Tổng chỉ chạy tới ngày $t-1$, nên doanh số của chính ngày t không được dùng. Phép $\log(1+x)$ nén giá trị của các sản phẩm bán rất chạy, còn hệ số $1/10$ đưa đặc trưng về cỡ $[0,1]$. Doanh số được tính trên toàn bộ giao dịch H&M, không chỉ trong mẫu. Đây là dữ liệu doanh nghiệp có tại thời điểm dự đoán, và nó phản ánh xu hướng bán gần đây của sản phẩm trên toàn cửa hàng.

Văn bản của sản phẩm được biểu diễn bằng TF-IDF trên từ đơn và cặp từ, rồi giảm còn 64 chiều bằng SVD rút gọn và chuẩn hóa về độ dài 1 (mục 2.4.1). Bộ từ vựng bỏ từ dừng tiếng Anh và giữ tối đa 30.000 mục từ xuất hiện ở ít nhất 3 sản phẩm. Phép biến đổi được khớp trên toàn bộ danh mục và không dùng dữ liệu mua hàng.

Đặc trưng ban đầu được tính cho từng `article_id`, rồi được gộp theo mẫu thiết kế. Thuộc tính danh mục lấy theo biến thể có `article_id` nhỏ nhất. Ba thuộc

tính màu (nhóm màu, độ đậm màu, màu chủ đạo) được đặt về một giá trị hằng vì không còn mô tả một màu cụ thể. Vector văn bản là trung bình các biến thể, chuẩn hóa lại về độ dài 1. Doanh số theo ngày là tổng các biến thể, và ngày bán đầu tiên là ngày sớm nhất của các biến thể.

Thuộc tính tĩnh của khách hàng lấy từ `customers.csv`. Tệp này không có mốc thời gian, nên thuộc tính được coi là ít thay đổi; đây là một hạn chế được ghi ở mục 5.2. Đặc trưng thời gian của khách tại ngày t chỉ dùng các cặp có ngày mua đầu trước t: khoảng cách tới lần mua gần nhất và số cặp đã mua.

3.2.6 Dữ liệu kiểm chứng Amazon Beauty

Để xem các kết luận rút ra từ H&M có còn đúng trên bộ dữ liệu khác hay không, toàn bộ quy trình được chạy lại trên Amazon Beauty. Đây là danh mục Làm đẹp của bộ dữ liệu đánh giá sản phẩm Amazon năm 2014 [4]. Bản 5-core gồm 198.502 đánh giá của 22.363 khách cho 12.101 sản phẩm, từ 12/06/2002 đến 23/07/2014. Kế hoạch kiểm chứng được đăng ký trước khi chạy mô hình nào trên bộ này. Mã nguồn, 14 mô hình, số seed, độ đo, họ 10 so sánh và tiêu chí kết luận giữ nguyên như H&M. Chỉ những điểm sau thay đổi theo dữ liệu.

- Tương tác: mỗi đánh giá được coi là một tương tác ẩn giữa khách và sản phẩm, như một lượt mua của H&M; số sao không được dùng. Một sản phẩm là một mã `asin`.
- Chia theo thời gian: chọn số epoch bằng các cặp trước 01/10/2013 và tập xác thực từ 01/10 đến 31/12/2013; huấn luyện lại trên mọi cặp trước 01/01/2014; tập kiểm thử từ 01/01 đến 23/07/2014. Tỉ lệ độ dài xác thực và kiểm thử khoảng $1:2$ như H&M. Vì chỉ có một bộ dữ liệu, Amazon không có mẫu khách hàng độc lập: bước chọn số epoch và bước đánh giá cuối khác nhau theo thời gian chứ không theo khách hàng.
- Lọc 5-core chỉ trên các cặp trước mốc kiểm thử, bằng ngưỡng của bản 5-core gốc. H&M dùng $k = 10$, nhưng dữ liệu Amazon thưa hơn nhiều.
- Không tinh chỉnh lại: mọi mô hình dùng đúng cấu hình đã chọn trên tập xác thực của mẫu phát triển H&M (Bảng 4.2). Thứ duy nhất được chọn trên dữ liệu Amazon là số epoch của các mạng nơ-ron (Thuật toán 3.3). Hệ quả là mô hình nào có cấu hình không hợp với Amazon sẽ chịu thiệt, và phần thiệt đó không tách được khỏi bản thân mô hình.
- Đặc trưng thay theo những gì bộ dữ liệu có (Bảng 3.5). Amazon không có

thông tin khách hàng, nên nhánh khách của NeuMF-F chỉ còn hai đặc trưng thời gian; doanh số được thay bằng số đánh giá, đếm trên chính tệp 5-core.

Bảng 3.5: Đặc trưng của các mô hình có đặc trưng trên H&M và trên Amazon Beauty

Thành phần	H&M	Amazon Beauty
Thuộc tính sản phẩm	11 thuộc tính danh mục (88 chiều)	5 thuộc tính: thương hiệu, danh mục cấp 1, 2, 3, nhóm giá (8 nhóm, 0 là không có giá) (40 chiều)
Văn bản	tên và mô tả, TF-IDF và SVD 64 chiều	tiêu đề và mô tả, cùng cách biểu diễn
Thời gian của sản phẩm tại t	doanh số toàn H&M trong 7, 28, 91 ngày trước t; tuổi sản phẩm; cờ chưa từng bán (5 chiều)	số đánh giá trong tệp 5-core trong 7, 28, 91 ngày trước t; tuổi tính từ đánh giá đầu tiên; cờ chưa có đánh giá (5 chiều)
Vector đặc trưng sản phẩm	$d_I = 88 + 64 + 5 = 157$	$d_I = 40 + 64 + 5 = 109$
Thông tin khách hàng	5 thuộc tính tĩnh và 2 đặc trưng thời gian ($d_U = 42$)	chỉ 2 đặc trưng thời gian ($d_U = 2$)
Content (đối chứng)	one-hot nhóm sản phẩm, nhóm chỉ mục, nhóm may mặc	one-hot danh mục cấp 1 và cấp 2
MostPopular-Recent	số giao dịch toàn H&M trong cửa sổ W ngày	số đánh giá trong cửa sổ W ngày

Bảng 3.6 cho quy mô dữ liệu Amazon sau khi lọc. Ba hạn chế được ghi nhận từ lúc đăng ký. Thứ nhất, đánh giá không đồng nghĩa với mua. Thứ hai, đặc trưng thời gian của sản phẩm chỉ đếm trên tệp 5-core chứ không trên toàn bộ đánh giá của Amazon. Thứ ba, nhóm giá là giá tại thời điểm thu thập dữ liệu (năm 2014), không phải giá tại ngày của từng đánh giá.

3.3 Thiết kế mô hình lai NeuMF-F

NeuMF-F giữ nguyên cấu trúc hai nhánh của NeuMF (mục 2.3): nhánh GMF mô hình hóa tương tác tuyến tính, nhánh MLP mô hình hóa tương tác phi tuyến, và hai nhánh hợp nhất ở lớp dự đoán chung. Mô hình chỉ thay đổi một điểm: vector của khách hàng và sản phẩm trong mỗi nhánh không còn chỉ là vector nhúng của mã ID mà là tổng của vector nhúng ID và một phép chiếu tuyến tính của đặc trưng. Chữ "F" (*features*) chỉ phần đặc trưng này. Hình 3.2 trình bày kiến trúc kèm kích thước của từng ma trận và từng tầng. Điểm $\hat{y}_{ui}$ được tính cho mọi sản phẩm ứng viên của khách, rồi các sản phẩm được sắp theo điểm giảm dần và K sản phẩm đầu là danh sách gợi

Bảng 3.6: Quy mô dữ liệu Amazon Beauty

	Amazon Beauty
Đánh giá trong bộ 5-core gốc (mỗi đánh giá là một tương tác)	198.502
Sản phẩm có đánh giá trước 01/01/2014	11.493
Cặp (khách, sản phẩm) trước 01/01/2014	140.193
Khách sau lọc 5-core	10.681
Sản phẩm (asin) sau lọc 5-core	6.069
Cặp sau lọc 5-core	94.009
Xác thực: cặp huấn luyện (trước 01/10/2013)	82.281
Xác thực: khách được đánh giá	3.153
Xác thực: cặp đúng	7.880
Kiểm thử: cặp huấn luyện (trước 01/01/2014)	94.009
Kiểm thử: khách được đánh giá	2.644
Kiểm thử: cặp đúng	6.107
Kiểm thử: số ứng viên trung bình mỗi khách	6.058

Bản 5-core năm 2014, một bộ dữ liệu chia theo thời gian. Mỗi sản phẩm là một mã asin. Lọc 5-core chỉ dùng các cặp trước mốc kiểm thử 01/01/2014. Tập xác thực, từ 01/10/2013 đến 31/12/2013, chỉ dùng để chọn số epoch; không tinh chỉnh trên bộ này. Ứng viên và cặp đúng chỉ gồm sản phẩm đã có cặp huấn luyện trước mốc của giai đoạn.

ý.

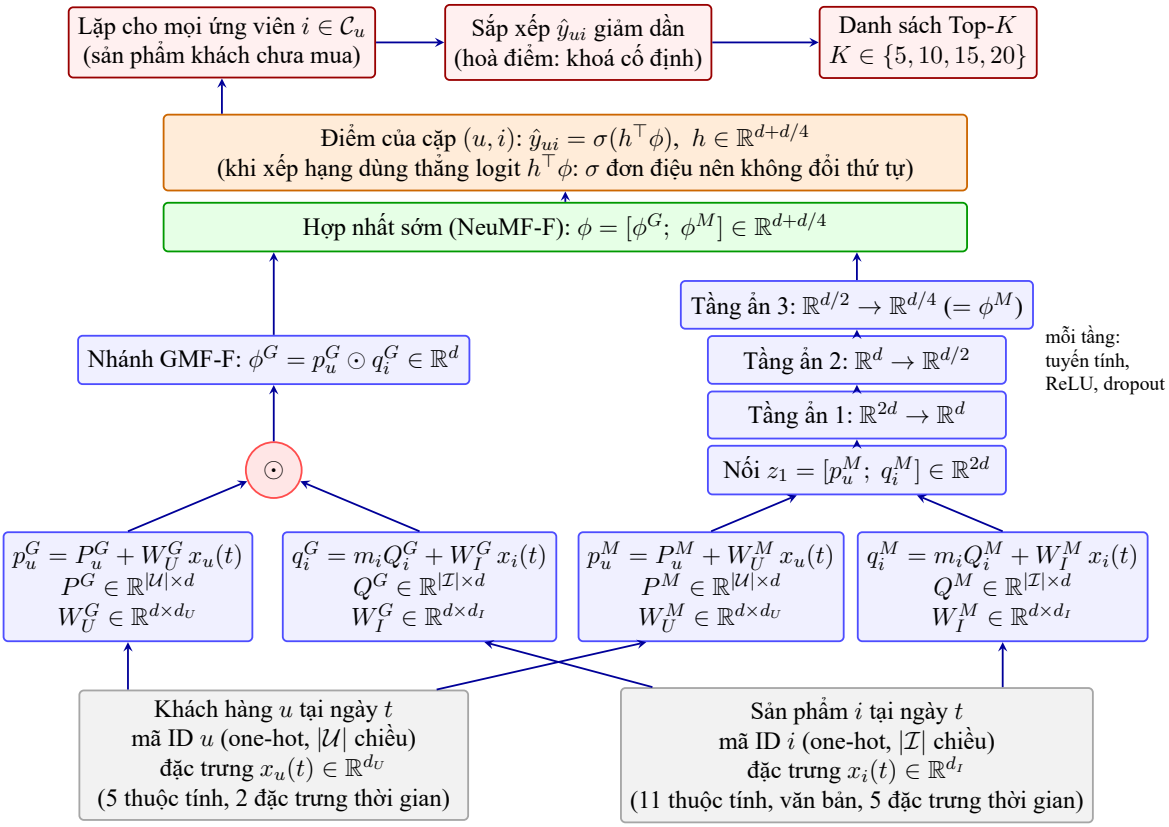
3.3.1 Biểu diễn lai: vector nhúng ID kết hợp đặc trưng

Với mỗi nhánh $b \in \{G, M\}$ (GMF và MLP), mô hình có bảng vector nhúng ID của khách hàng $P^b \in \mathbb{R}^{|\mathcal{U}| \times d}$, của sản phẩm $Q^b \in \mathbb{R}^{|\mathcal{I}^{ID}| \times d}$, và hai ma trận chiếu đặc trưng $W_U^b \in \mathbb{R}^{d \times d_U}$, $W_I^b \in \mathbb{R}^{d \times d_I}$, không có hệ số chệch. Vector của khách u và sản phẩm i tại ngày t trong nhánh b là:

$$p_u^b(t) = P_u^b + W_U^b\, x_u(t), \qquad q_i^b(t) = m_i\, Q_i^b + W_I^b\, x_i(t) \tag{3.6}$$

Vector đặc trưng của sản phẩm $x_i(t) = [e(a_{i,1}); \ldots; e(a_{i,11});\ v_i;\ x_i^{tg}(t)] \in \mathbb{R}^{d_I}$ gồm vector nhúng 8 chiều của 11 thuộc tính danh mục, vector văn bản v_i (64 chiều) và 5 đặc trưng thời gian (Công thức (3.5)), tức $d_I = 88 + 64 + 5 = 157$. Tương tự, $x_u(t) = [e(c_{u,1}); \ldots; e(c_{u,5});\ x_u^{tg}(t)] \in \mathbb{R}^{d_U}$ với $d_U = 40 + 2 = 42$. Vector nhúng của các thuộc tính $e(\cdot)$ được học cùng mô hình và dùng chung cho hai nhánh; ma trận chiếu W^b riêng cho từng nhánh.

Hệ số m_i quyết định vector nhúng ID của sản phẩm có được dùng hay không. $m_i = 1$ với sản phẩm có dữ liệu huấn luyện ở giai đoạn đang xét. Với tập ứng viên của đề tài (mục 3.2.4), đó là mọi sản phẩm được chấm. Khi $m_i = 0$, vector của sản



Hình 3.2: Kiến trúc mô hình đề xuất NeuMF-F, từ đầu vào đến danh sách Top-K. Mỗi nhánh có bảng vector nhúng ID và phép chiếu đặc trưng riêng; $m_i \in \{0, 1\}$ cho biết vector nhúng ID của sản phẩm có được dùng hay không. Với cấu hình được chọn ($d = 32$), tháp MLP là $64 \to 32 \to 16 \to 8$ và $\phi \in \mathbb{R}^{40}$. Trên mẫu kiểm định H&M, $|\mathcal{U}| = 7.994$, $|\mathcal{I}| = 6.749$, $d_U = 42$ và $d_I = 157$.

phẩm chỉ còn phần đặc trưng. Khi huấn luyện, m_i của từng mẫu được đặt về 0 ngẫu nhiên với xác suất $\rho \in \{0;\ 0{,}25;\ 0{,}5\}$, gọi là bỏ ID ngẫu nhiên. Cơ chế này, lấy ý tưởng từ DropoutNet (mục 2.4.1), buộc mô hình học cách chấm điểm một phần từ đặc trưng thay vì dựa hoàn toàn vào vector nhúng ID. Trong đề tài, ρ là một siêu tham số được chọn trên tập xác thực; cấu hình NeuMF-F được chọn có $\rho = 0$, tức không bỏ ID (mục 4.3).

Như NeuMF, hai nhánh dùng hai không gian nhúng độc lập, vì nhánh GMF tối ưu vector cho phép nhân Hadamard còn nhánh MLP tối ưu vector làm đầu vào của mạng phi tuyến. Hai nhánh dùng cùng số chiều $d \in \{32, 64\}$. Các bảng vector nhúng được khởi tạo theo phân phối chuẩn $\mathcal{N}(0;\ 0{,}01^2)$; hàng "không có ID" là vector 0 cố định. Các tầng tuyến tính được khởi tạo theo Xavier, và lớp đầu ra h không có hệ số chệch.

3.3.2 Nhánh GMF-F

Nhánh GMF-F là dạng tổng quát của nhân tử hóa ma trận (Công thức (2.5)) trên vector lai. Thay vì cộng ngay tích các chiều thành một số, nhánh giữ kết quả nhân theo từng chiều qua phép nhân Hadamard:

$$\phi^G = p_u^G(t) \odot q_i^G(t) \tag{3.7}$$

Phép cộng các chiều được chuyển sang vector trọng số h ở tầng đầu ra (mục 3.3.4), nên mô hình học được trọng số riêng cho từng chiều. Đây là phần "tổng quát" trong tên gọi GMF: khi $h = \mathbf{1}$ và không có đặc trưng, GMF-F trở về MF. Vì p_u^G và q_i^G đều chứa phần chiếu của đặc trưng, tích $p_u^G \odot q_i^G$ còn mô hình hóa tương tác tuyến tính giữa thuộc tính của khách và thuộc tính của sản phẩm, tương tự Factorization Machines (mục 2.4.1).

3.3.3 Nhánh MLP-F

Nhánh MLP-F nối hai vector lai thành đầu vào của một mạng nhiều tầng, không áp đặt trước cách hai vector tương tác:

$$z_1 = \begin{bmatrix} p_u^M(t) \\ q_i^M(t) \end{bmatrix} \in \mathbb{R}^{2d}, \qquad \phi_L^M = a_L\big(W_L^T \cdots a_2(W_2^T z_1 + b_2) \cdots + b_L\big) \tag{3.8}$$

Như NCF, tháp giảm một nửa số chiều qua mỗi tầng ẩn: $[2d \to d \to d/2 \to d/4]$; với $d = 32$ là $[64 \to 32 \to 16 \to 8]$. Mỗi tầng ẩn gồm một phép biến đổi tuyến tính, hàm kích hoạt ReLU và dropout với tỉ lệ được tinh chỉnh trong $\{0;\ 0{,}2\}$. Cùng với dropout,

mô hình được chống quá khớp bằng điều chuẩn L_2 (mục 3.4.2) và dừng sớm theo NDCG@10 trên tập xác thực (mục 3.5.1).

3.3.4 Tầng hợp nhất và lớp dự đoán

Vector của nhánh GMF-F và của nhánh MLP-F được nối thành một vector hợp nhất, rồi qua một tầng tuyến tính cuối và hàm sigmoid:

$$\hat{y}_{ui} = \sigma\big(h^T[\phi^G;\ \phi_L^M]\big) = \sigma\big(h_G^T\,(p_u^G \odot q_i^G) + h_M^T\,\phi_L^M\big) \tag{3.9}$$

Theo phân loại ở mục 2.3.4, đây là hợp nhất sớm ở mức biểu diễn của góc nhìn tuyến tính (MF) và góc nhìn phi tuyến (DNN). Một lớp dự đoán chung học trọng số giữa hai góc nhìn, và toàn bộ mạng được huấn luyện chung. Đặc trưng của sản phẩm và khách hàng được đưa vào ngay ở mức vector của cả hai nhánh, nên thông tin nội dung và ngữ cảnh cũng được hợp nhất sớm với thông tin cộng tác.

Khi xếp hạng, hệ thống dùng trực tiếp giá trị trước sigmoid (logit). Sigmoid đơn điệu nên không đổi thứ tự, nhưng ở độ chính xác float32 nó bão hòa về đúng 1,0 với điểm lớn và tạo ra các giá trị bằng nhau giả. Khi đánh giá một giai đoạn, vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần rồi dùng lại cho mọi cặp, nên chi phí chấm toàn bộ tập ứng viên gần bằng chi phí của NeuMF chỉ dùng ID.

3.3.5 Các mô hình đối chiếu trên cùng khung

Để trả lời từng câu hỏi nghiên cứu bằng một phép so sánh trực tiếp, các mô hình sau được cài đặt trên cùng mã nguồn, cùng đặc trưng và cùng quy trình huấn luyện với NeuMF-F.

- GMF-F và MLP-F là NeuMF-F chỉ giữ một nhánh. Chúng đo đóng góp của từng nhánh và lợi ích của việc hợp nhất. MLP-F đứng riêng là một mô hình DNN thuần, không phải mô hình hợp nhất MF với DNN.
- LateFusion-F là hợp nhất muộn của cùng hai thành phần. GMF-F và MLP-F được huấn luyện riêng, rồi điểm đã chuẩn hóa min–max trên tập ứng viên của từng khách được trộn theo trọng số w chọn trên tập xác thực (Công thức (2.15)). So sánh NeuMF-F với LateFusion-F là so sánh hai cách hợp nhất trên cùng hai thành phần.
- GMF, MLP và NeuMF chỉ dùng ID là kiến trúc NCF gốc, không có đặc trưng. Chúng đo lợi ích của đặc trưng.
- Các biến thể bóc tách của NeuMF-F dùng cùng siêu tham số với NeuMF-F và tắt lần lượt một thành phần: vector văn bản, đặc trưng thời gian, thông

tin khách hàng, thuộc tính sản phẩm, hoặc cơ chế bỏ ID ngẫu nhiên. Biến thể nào trùng với chính NeuMF-F thì không chạy (mục 4.4.5).

Các mô hình đối chứng còn lại (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN, BPR-MF) và mô hình lai truyền thống Hybrid-CBCF được mô tả ở mục 4.2, cùng cách xếp mọi mô hình đối chứng thành ba nhóm.

3.4 Lấy mẫu âm theo thời điểm và hàm mục tiêu

3.4.1 Lấy mẫu âm theo ngày ra mắt của sản phẩm

Phản hồi ẩn chỉ ghi nhận các tương tác đã xảy ra, không có nhãn âm tường minh (mục 2.1.3). Lấy mẫu âm giả định các sản phẩm khách chưa mua nhiều khả năng là âm. Với mô hình có đặc trưng, mỗi cặp dương (u, i) mang ngày mua đầu t_{ui}, nên việc chọn mẫu âm phải nhất quán về thời gian. Với mỗi cặp dương, hệ thống lấy ngẫu nhiên N_{ratio} sản phẩm j trong các sản phẩm của tập huấn luyện đã ra mắt trước hoặc trong ngày t_{ui} ($d_j^0 \leq t_{ui}$), trừ những sản phẩm khách u đã mua, và gán nhãn $y_{uj} = 0$. Đặc trưng của mẫu âm được tính tại cùng ngày t_{ui}.

Ràng buộc "đã ra mắt" là cần thiết. Một sản phẩm chưa ra mắt ở ngày t_{ui} thì khách không thể mua, nên không phải là mẫu âm có ý nghĩa. Nếu vẫn lấy, mô hình có thể học quy luật sai "sản phẩm có cờ chưa ra mắt là âm", một tín hiệu chỉ có trong cách tạo dữ liệu huấn luyện. Với mô hình chỉ dùng ID, mẫu âm được lấy đều trong các sản phẩm có ID, trừ sản phẩm khách đã mua, như NCF gốc. N_{ratio} được tinh chỉnh trong $\{4, 8\}$. Mẫu âm được lấy lại ở mỗi epoch, nên mô hình thấy nhiều tổ hợp cặp âm khác nhau. Thuật toán 3.2 mô tả bước này cho mô hình có đặc trưng.

3.4.2 Hàm mất mát entropy chéo nhị phân và điều chuẩn

Với cả nhãn dương và nhãn âm, huấn luyện trở thành bài toán phân loại nhị phân. Hàm mất mát entropy chéo nhị phân được tối thiểu hóa cùng số hạng điều chuẩn L_2:

$$\mathcal{L} = - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} [y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui})] + \lambda_\Theta \|\Theta\|_2^2 \tag{3.10}$$

trong đó Θ là toàn bộ tham số học được (vector nhúng ID, vector nhúng thuộc tính, ma trận chiếu, tháp MLP, lớp đầu ra) và $\lambda_\Theta \in \{0;\ 10^{-6}\}$ được tinh chỉnh. Hàm mất mát được tính trên logit để ổn định số học. Các mô hình được cài đặt bằng PyTorch [32] và tối ưu bằng Adam [33] với kích thước lô 512.

Thuật toán 3.2 Lấy mẫu âm theo thời điểm cho mô hình có đặc trưng (thực hiện lại ở đầu mỗi epoch)

Đầu vào: tập cặp dương huấn luyện $\mathcal{D} = \{(u, i, t_{ui})\}$; ngày bán đầu tiên d_j^0 của mỗi sản phẩm; số mẫu âm N_{ratio}
Đầu ra: tập huấn luyện của epoch: các bộ (u, j, t, y)

$\mathcal{P} \leftarrow$ các sản phẩm xuất hiện trong $\mathcal{D}$, sắp tăng dần theo d_j^0
$\mathcal{I}_u \leftarrow \{i : (u, i, \cdot) \in \mathcal{D}\}$ với mọi khách u ▷ *sản phẩm khách đã mua*
$\mathcal{B} \leftarrow \emptyset$
với mỗi $(u, i, t) \in \mathcal{D}$ **làm**
    thêm $(u, i, t, 1)$ vào $\mathcal{B}$ ▷ *mẫu dương, đặc trưng tính tại ngày t*
    $\mathcal{A}_t \leftarrow \{j \in \mathcal{P} : d_j^0 \leq t\}$ ▷ *sản phẩm đã ra mắt tính đến ngày t*
    với $n = 1, \ldots, N_{ratio}$ **làm**
        lấy j ngẫu nhiên đều trong $\mathcal{A}_t$; nếu $j \in \mathcal{I}_u$ thì lấy lại (tối đa 20 lần)
        thêm $(u, j, t, 0)$ vào $\mathcal{B}$ ▷ *mẫu âm dùng cùng ngày t*
trả về $\mathcal{B}$

3.5 Quy trình huấn luyện và tinh chỉnh

3.5.1 Không gian tinh chỉnh và dừng sớm

Bảng 3.7 liệt kê không gian tinh chỉnh của mọi mô hình có siêu tham số. Mỗi mô hình có học được thử đúng 6 cấu hình: cấu hình mặc định và 5 cấu hình rút ngẫu nhiên không lặp từ lưới của mô hình đó, bằng một bộ sinh số ngẫu nhiên cố định. Mô hình chỉ có một tham số (MostPopular-Recent, Content, LateFusion-F) được thử đủ lưới. Mọi cấu hình được huấn luyện với seed 42 và chấm trên tập xác thực của mẫu phát triển.

Sau mỗi epoch, mạng được chấm NDCG@10 trên tập xác thực bằng cách xếp hạng toàn bộ. Trạng thái tốt nhất được giữ lại, và huấn luyện dừng khi độ đo không cải thiện sau 5 epoch liên tiếp. Số epoch tốt nhất e^* được ghi lại để dùng khi huấn luyện lại. Trước khi dự đoán cho giai đoạn kiểm thử, mô hình được huấn luyện lại từ đầu trên mọi cặp trước mốc kiểm thử đúng e^* epoch. Lúc này không còn tập xác thực để dừng, và tập kiểm thử không bao giờ được dùng để dừng (Thuật toán 3.3).

3.6 Quy trình đánh giá không thiên lệch

Ferrari Dacrema và cộng sự [29] chỉ ra hai lỗi phương pháp thường gặp khi đánh giá mô hình gợi ý học sâu: chọn số epoch hay cấu hình dựa trên chính tập kiểm thử, và tinh chỉnh mô hình đối chứng sơ sài. Rendle và cộng sự [30] cũng cho thấy

Bảng 3.7: Không gian tinh chỉnh của các mô hình

Mô hình	Siêu tham số và giá trị thử	Cấu hình mặc định
GMF, MLP, NeuMF; GMF-F, MLP-F, NeuMF-F	tốc độ học $\{10^{-3},\ 5 \cdot 10^{-4}\}$; số chiều d $\{32, 64\}$; số mẫu âm $\{4, 8\}$; hệ số điều chuẩn L2 $\{0,\ 10^{-6}\}$; dropout của tháp MLP $\{0;\ 0{,}2\}$ (trừ GMF, GMF-F)	10^{-3}; 32; 4; 10^{-6}; 0,2
Thêm cho GMF-F, MLP-F, NeuMF-F	xác suất bỏ ID ρ $\{0;\ 0{,}25;\ 0{,}5\}$	0,25
Cố định cho mọi mạng nơ-ron	Adam, kích thước lô 512, tối đa 20 epoch, dừng sớm khi NDCG@10 xác thực không cải thiện sau 5 epoch; vector nhúng thuộc tính 8 chiều, vector văn bản 64 chiều	không có
BPR-MF	d $\{32, 64, 128\}$; tốc độ học $\{0{,}01;\ 0{,}03;\ 0{,}05\}$; hệ số điều chuẩn $\{0{,}001;\ 0{,}005;\ 0{,}01\}$; số epoch $\{20, 40\}$	32; 0,03; 0,005; 20
ItemKNN, UserKNN	số láng giềng k $\{20, 50, 100, 200, 500\}$; hệ số co $\{0, 10, 50\}$	100; 0
MostPopular-Recent	cửa sổ W $\{7, 14, 28, 56, 91\}$ ngày	thử đủ lưới
Content	chu kỳ bán rã của trọng số theo thời gian $\{$không trọng số$, 30, 90, 180, 365\}$ ngày	thử đủ lưới
LateFusion-F	w $\{0;\ 0{,}1;\ \ldots;\ 1\}$ trên GMF-F và MLP-F tốt nhất	thử đủ lưới
Hybrid-CBCF (bổ sung)	cách kết hợp: trung bình, lớn nhất, nhỏ nhất, tổng có trọng số học theo cặp (Thuật toán 3.6)	thử cả bốn

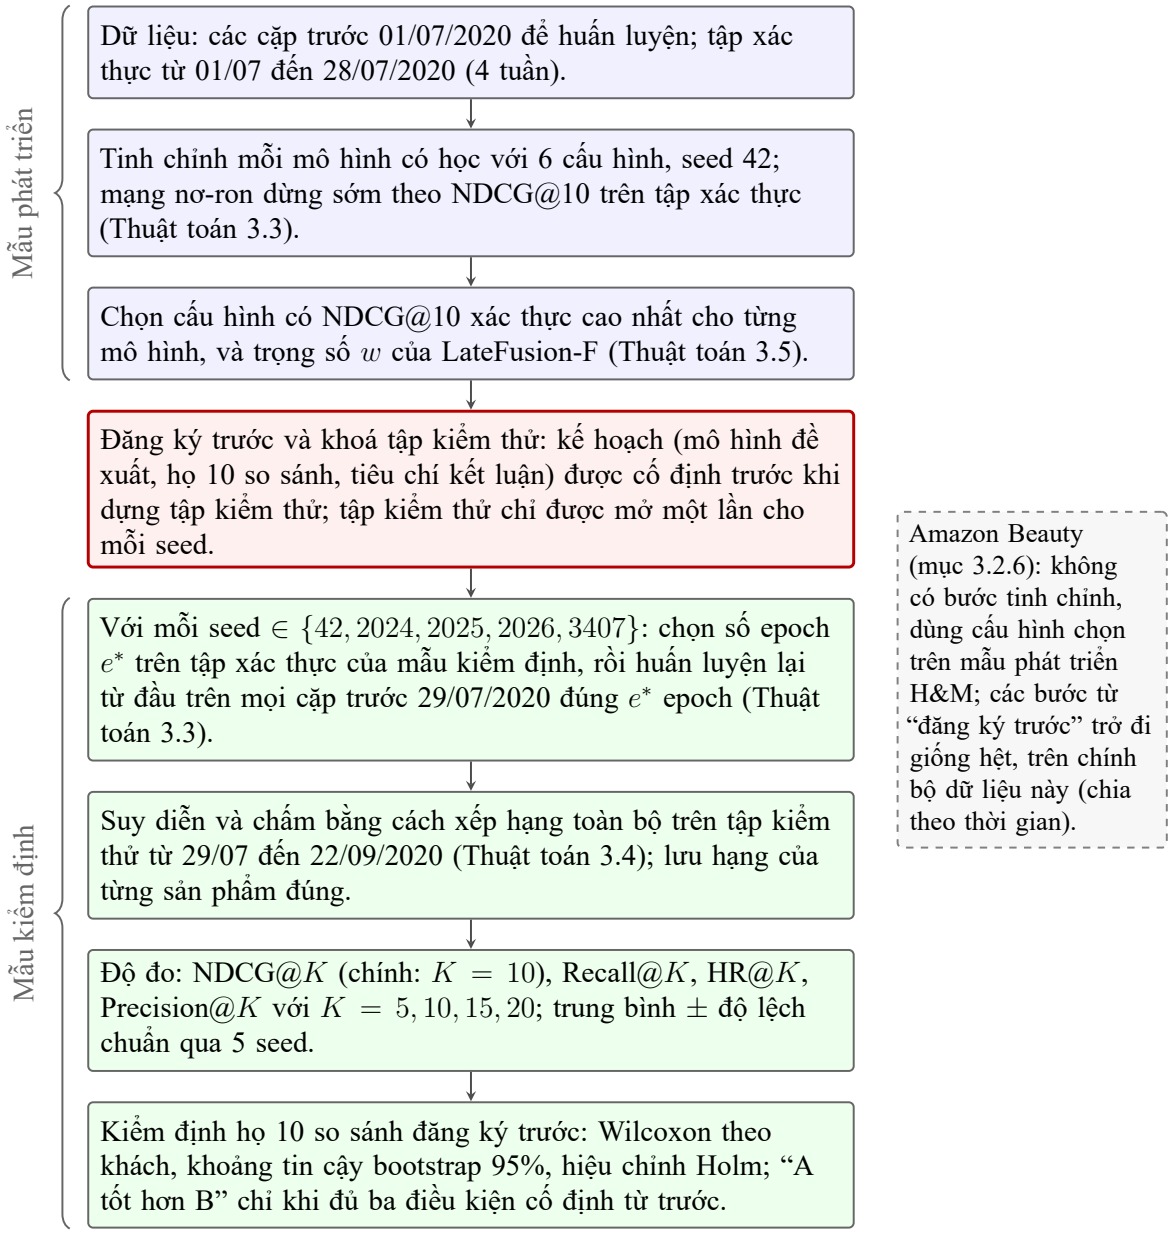
Thuật toán 3.3 Huấn luyện có dừng sớm và huấn luyện lại đúng số epoch

Đầu vào: cấu hình θ; seed s; dữ liệu trước mốc xác thực $\mathcal{D}_{\tau_{val}}$ và tập xác thực V; dữ liệu trước mốc kiểm thử $\mathcal{D}_{\tau_{test}}$; $E_{max} = 20$, kiên nhẫn $P = 5$

Đầu ra: mô hình f^* để suy diễn sau mốc τ_{test} và số epoch e^*

hàm HuấnLuyện($\mathcal{D}, E, V$)
  khởi tạo f theo θ và seed s; *tốt_nhất* $\leftarrow -\infty$; $e^* \leftarrow 0$; *chờ* $\leftarrow 0$
  với $e = 1, \ldots, E$ **làm**
    lấy lại mẫu âm (Thuật toán 3.2); xáo trộn
    với mỗi lô 512 mẫu **làm**
      cập nhật f bằng Adam theo BCE trên logit (Công thức (3.10))
    nếu $V \neq \emptyset$ **thì**
      $n \leftarrow$ NDCG@10 của f trên V (xếp hạng toàn bộ, Thuật toán 3.4)
      nếu $n >$ *tốt_nhất* **thì**
        tốt_nhất $\leftarrow n$; $e^* \leftarrow e$; lưu trọng số của f; *chờ* $\leftarrow 0$
      ngược lại
        chờ $\leftarrow$ *chờ* $+ 1$; **nếu** *chờ* $\geq P$ **thì** dừng vòng lặp
    ngược lại
      $e^* \leftarrow e$ ▷ *huấn luyện lại: chạy đủ E epoch*
  nếu $V \neq \emptyset$ **thì** nạp lại trọng số tốt nhất
  trả về f, e^*
$(\cdot, e^*) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{val}}, E_{max}, V$) ▷ *chọn số epoch*
$(f^*, \cdot) \leftarrow$ HuấnLuyện($\mathcal{D}_{\tau_{test}}, e^*, \emptyset$) ▷ *huấn luyện lại từ đầu*
lưu trọng số f^* ▷ *bước "lưu mô hình" của Hình 3.1*
trả về f^*, e^*

kết luận so sánh phụ thuộc mạnh vào việc mô hình đối chứng có được tinh chỉnh đầy đủ hay không. Giai đoạn phát triển của đề tài còn cho thấy một rủi ro thứ ba: khi tập kiểm thử đã được xem, các quyết định sau đó có thể bị ảnh hưởng bởi kết quả đã thấy (mục 4.6). Quy trình đánh giá của đề tài (Hình 3.3) xử lý cả ba rủi ro bằng sáu nguyên tắc dưới đây. Quy trình này tách khỏi đường ống ở Hình 3.1: nó chỉ gọi lại các bước huấn luyện và suy diễn với những mốc thời gian khác nhau, rồi so danh sách gợi ý với những gì khách đã mua thật.



Hình 3.3: Quy trình tinh chỉnh và đánh giá cuối

1. Tách mẫu phát triển và mẫu kiểm định. Mọi lựa chọn mô hình, siêu tham

số và số epoch dựa trên tập xác thực: tinh chỉnh trên mẫu phát triển, chọn số epoch khi đánh giá cuối trên tập xác thực của mẫu kiểm định. Tập kiểm thử của mẫu kiểm định chỉ được mở một lần, ở đánh giá cuối.

2. Đăng ký trước. Danh sách mô hình, lưới tinh chỉnh, số seed, độ đo chính, họ so sánh, tiêu chí kết luận và các hạn chế đã biết được ghi vào kế hoạch thực nghiệm trước khi có kết quả tinh chỉnh của mô hình có đặc trưng nào. Bản cuối của kế hoạch được cố định trước khi dựng tập kiểm thử của mẫu kiểm định; những điểm thay đổi so với bản đầu và lý do được trình bày ở mục 4.6. Mô hình đề xuất NeuMF-F, độ đo chính, họ so sánh và tiêu chí kết luận được cố định từ bản đầu, và mọi thay đổi sau đó được ghi nhận như lệch kế hoạch. Kiểm chứng trên Amazon Beauty và phân tích bổ sung với Hybrid-CBCF có kế hoạch riêng theo cùng cách.
3. Khoá tập kiểm thử. Tập kiểm thử của mẫu kiểm định chỉ được mở khi kế hoạch đã được cố định và mã nguồn trùng với mã nguồn đã dùng khi tinh chỉnh. Mỗi lần mở được ghi lại, nên số lần tập kiểm thử được xem có thể kiểm chứng.
4. Cùng ngân sách tinh chỉnh. Mọi mô hình có học được thử 6 cấu hình (mục 3.5.1).
5. Huấn luyện lại trước khi chấm. Với mỗi seed (42, 2024, 2025, 2026, 3407) và mỗi mạng nơ-ron, mô hình được huấn luyện trên dữ liệu trước 01/07/2020 của mẫu kiểm định và dừng sớm theo NDCG@10 trên tập xác thực của chính mẫu này để chọn số epoch e^*. Sau đó mô hình được huấn luyện lại từ đầu trên mọi cặp trước 29/07/2020 đúng e^* epoch rồi mới chấm tập kiểm thử (Thuật toán 3.3). BPR-MF và các mô hình không phải mạng nơ-ron được khớp trên mọi cặp trước 29/07/2020. LateFusion-F trộn đúng GMF-F và MLP-F đã huấn luyện lại ở cùng seed.
6. Kiểm định thống kê và tiêu chí kết luận cố định. Với mỗi khách được đánh giá, NDCG@10 được lấy trung bình qua 5 seed; mô hình tất định cho cùng giá trị ở mọi seed. Từng cặp mô hình được so sánh bằng kiểm định Wilcoxon theo người dùng [34] và khoảng tin cậy 95% của hiệu trung bình bằng bootstrap ghép cặp với 10.000 lần lấy mẫu lại [35]. Giá trị p được hiệu chỉnh Holm [36] trên một họ 10 so sánh đăng ký trước. Chín so sánh đặt NeuMF-F cạnh: NeuMF (đặc trưng có giúp mô hình lai không); GMF-F và MLP-F (hợp nhất so với từng nhánh); LateFusion-F (hợp nhất sớm so với

muộn); BPR-MF, ItemKNN, UserKNN, MostPopular-Recent và Content. So sánh thứ mười là NeuMF với BPR-MF (mô hình lai chỉ dùng ID so với MF). Kết luận "A tốt hơn B" chỉ được viết khi đồng thời $p_{Holm} < 0{,}05$, khoảng tin cậy không chứa 0 và chênh lệch tương đối NDCG@10 không dưới 5%; ngược lại, kết luận là "không khác biệt có ý nghĩa".

Thuật toán 3.4 là cách mọi mô hình được chấm trên một giai đoạn. Mọi mô hình dùng cùng tập ứng viên và cùng quy tắc phá hoà, nên chênh lệch giữa hai mô hình chỉ đến từ điểm số của chúng. Hạng của từng sản phẩm đúng được lưu theo từng khách, nên độ đo ở một K bất kỳ tính lại được mà không phải chấm lại tập kiểm thử. Các độ đo ở $K = 15$ trong Chương 4 được tính theo cách này; cách tính lại cho đúng các số ở $K = 5, 10, 20$ của lần đánh giá cuối. Thuật toán 3.5 chọn trọng số trộn của LateFusion-F chỉ trên tập xác thực của mẫu phát triển; trọng số này (w=0,4 (GMF-F), $1 - w$=0,6 (MLP-F)) được giữ nguyên ở đánh giá cuối.

Thuật toán 3.4 Đánh giá một mô hình trên một giai đoạn bằng cách xếp hạng toàn bộ tập ứng viên

---

Đầu vào: hàm điểm $s(u, i)$ của mô hình; tập khách được đánh giá $\mathcal{U}_{eval}$; với mỗi khách u: tập ứng viên $\mathcal{C}_u$ và tập sản phẩm đúng T_u (Công thức (3.3), (3.4)); seed phá hoà $s_0 = 2026$; các giá trị K

Đầu ra: chỉ số trung bình theo khách; hạng của từng sản phẩm đúng

với mỗi khách $u \in \mathcal{U}_{eval}$ **làm**
  tính $s(u, i)$ cho mọi $i \in \mathcal{C}_u$ theo lô ▷ *mạng nơ-ron: logit*
  sắp $\mathcal{C}_u$ theo $s(u, i)$ giảm dần; bằng điểm thì theo khoá $h(u, i, s_0)$ ▷ *cùng khoá cho mọi mô hình*
  $R_u \leftarrow$ hạng (tính từ 1) của từng $i \in T_u$ trong danh sách đã sắp; lưu R_u
  với mỗi K **làm**
    tính HR@$K(u)$, Precision@$K(u)$, Recall@$K(u)$, NDCG@$K(u)$ từ R_u (Công thức (2.19)–(2.21))
trả về trung bình từng chỉ số trên $\mathcal{U}_{eval}$ và các R_u

---

Thuật toán 3.6 chọn cách kết hợp của mô hình lai truyền thống Hybrid-CBCF (mục 4.2), cũng chỉ trên tập xác thực của mẫu phát triển. Trọng số của cách kết hợp có trọng số được học chứ không chọn trên lưới. Vì vậy NDCG@10 dùng để so với các cách bỏ phiếu được tính bằng khớp chéo theo khách: trọng số dùng để chấm một khách luôn được học trên những khách khác. Cách kết hợp và trọng số được chọn giữ nguyên khi đánh giá trên mẫu kiểm định và trên Amazon Beauty.

Phân tích bóc tách chạy một seed, được báo cáo kèm khoảng tin cậy nhưng

Thuật toán 3.5 Chọn trọng số w của LateFusion-F trên tập xác thực của mẫu phát triển

Đầu vào: GMF-F và MLP-F tốt nhất (cấu hình đã chọn khi tinh chỉnh); tập xác thực V của mẫu phát triển; lưới $W = \{0;\ 0{,}1;\ \ldots;\ 1\}$

Đầu ra: trọng số w^*

với mỗi $w \in W$ **làm**
  với mỗi khách u của V **làm**
    $a \leftarrow \text{minmax}\big(s^{\text{GMF-F}}(u, \mathcal{C}_u)\big)$; $b \leftarrow \text{minmax}\big(s^{\text{MLP-F}}(u, \mathcal{C}_u)\big)$ ▷ *Công thức* (2.15)
    điểm trộn của u: $w\,a + (1-w)\,b$
  $N(w) \leftarrow$ NDCG@10 của điểm trộn trên V (Thuật toán 3.4)
trả về $w^* = \arg\max_{w \in W} N(w)$ ▷ *cố định từ đây, không chọn lại trên tập kiểm thử*

Thuật toán 3.6 Chọn cách kết hợp và học trọng số của mô hình lai truyền thống Hybrid-CBCF trên tập xác thực của mẫu phát triển

Đầu vào: Content, UserKNN, ItemKNN với cấu hình đã chọn khi tinh chỉnh, khớp trên dữ liệu trước mốc xác thực; tập xác thực V; $m = 50$ sản phẩm không đúng mỗi sản phẩm đúng (rút bằng seed cố định)

Đầu ra: cách kết hợp F^*; trọng số w^* nếu F^* là tổng có trọng số

với mỗi khách u của V và mỗi $i \in \mathcal{C}_u$ **làm**
  $x_{ui} \leftarrow \big(\text{minmax}(s^{CB}(u, \mathcal{C}_u))_i,\ \text{minmax}(s^{UserKNN}(u, \mathcal{C}_u))_i,\ \text{minmax}(s^{ItemKNN}(u, \mathcal{C}_u))_i\big)$
với $F \in \{\text{trung bình}, \max, \min\}$ **làm** ▷ *bỏ phiếu*
  $N(F) \leftarrow$ NDCG@10 trên V của điểm $F(x_{ui})$ (Thuật toán 3.4)
chia khách của V thành hai phần P_0, P_1 theo chỉ số chẵn, lẻ ▷ *khớp chéo*
với $k \in \{0, 1\}$ **làm**
  $D \leftarrow \emptyset$
  với mỗi khách $u \notin P_k$ và mỗi sản phẩm đúng p của u **làm**
    rút m sản phẩm không đúng $j \in \mathcal{C}_u$; thêm $(x_{up} - x_{uj},\ 1)$ và $(x_{uj} - x_{up},\ 0)$ vào D
  $w_k \leftarrow$ hồi quy logistic không hệ số chặn trên D ▷ $\max \sum \ln \sigma(w \cdot (x_{up} - x_{uj}))$
  điểm của mỗi khách $u \in P_k$: $w_k \cdot x_{ui}$
$N(\text{trọng số}) \leftarrow$ NDCG@10 trên V của điểm khớp chéo
$F^* \leftarrow \arg\max_F N(F)$; nếu F^* là tổng có trọng số thì $w^* \leftarrow$ hồi quy logistic trên các cặp của mọi khách của V
trả về F^*, w^* ▷ *cố định từ đây, không chọn lại trên tập kiểm thử*

không kiểm định và không dùng để kết luận chính. Độ phủ, số epoch và thời gian huấn luyện chỉ mang tính mô tả.

3.7 Suy diễn Top-K và xử lý khách hàng mới

Bước cuối của đường ống là suy diễn: với một khách hàng và một số K, hệ thống trả về K sản phẩm nên gợi ý. Thuật toán 3.7 mô tả bước này; hệ thống demo (mục 3.8) gợi ý theo đúng các bước đó. Với khách đã có trong dữ liệu đã học, đây chính là các bước chấm điểm và sắp xếp của Thuật toán 3.4, chỉ khác là không có sản phẩm đúng để so sánh. Vector của mọi khách và mọi sản phẩm tại mốc τ được tính một lần khi nạp mô hình, nên mỗi yêu cầu gợi ý chỉ còn một lượt suy diễn thuận trên các sản phẩm ứng viên của khách.

Thuật toán 3.7 Suy diễn Top-K cho một khách hàng, có xử lý khách hàng mới

Đầu vào: mã khách c; số gợi ý K; mô hình đã lưu f^* (NeuMF-F) cùng dữ liệu đã học trước mốc τ; danh sách phổ biến L_{pop} (sản phẩm xếp theo số khách đã mua trước τ)
Đầu ra: K sản phẩm gợi ý

nếu c không có trong dữ liệu đã học **thì** ▷ *khách mới, hoặc quá ít lần mua để qua lọc k-core*
    trả về K sản phẩm đầu của L_{pop}, gắn nhãn "gợi ý phổ biến"
$u \leftarrow$ mã nội bộ của c
$\mathcal{C}_u \leftarrow \{i : i \text{ có dữ liệu huấn luyện trước } \tau\} \setminus \mathcal{I}_u(\tau)$ ▷ *bỏ sản phẩm khách đã mua*
lấy p_u^G, p_u^M và q_i^G, q_i^M với mọi $i \in \mathcal{C}_u$ ▷ *đã tính sẵn tại τ khi nạp mô hình*
với mỗi lô sản phẩm $i \in \mathcal{C}_u$ **làm**
    $s_{ui} \leftarrow h^\top \left[\, p_u^G \odot q_i^G;\ \mathrm{MLP}([p_u^M;\ q_i^M]) \,\right]$ ▷ *logit; σ không đổi thứ tự*
sắp $\mathcal{C}_u$ theo s_{ui} giảm dần (bằng điểm: khoá cố định)
trả về K sản phẩm đầu, kèm tên, loại và ảnh

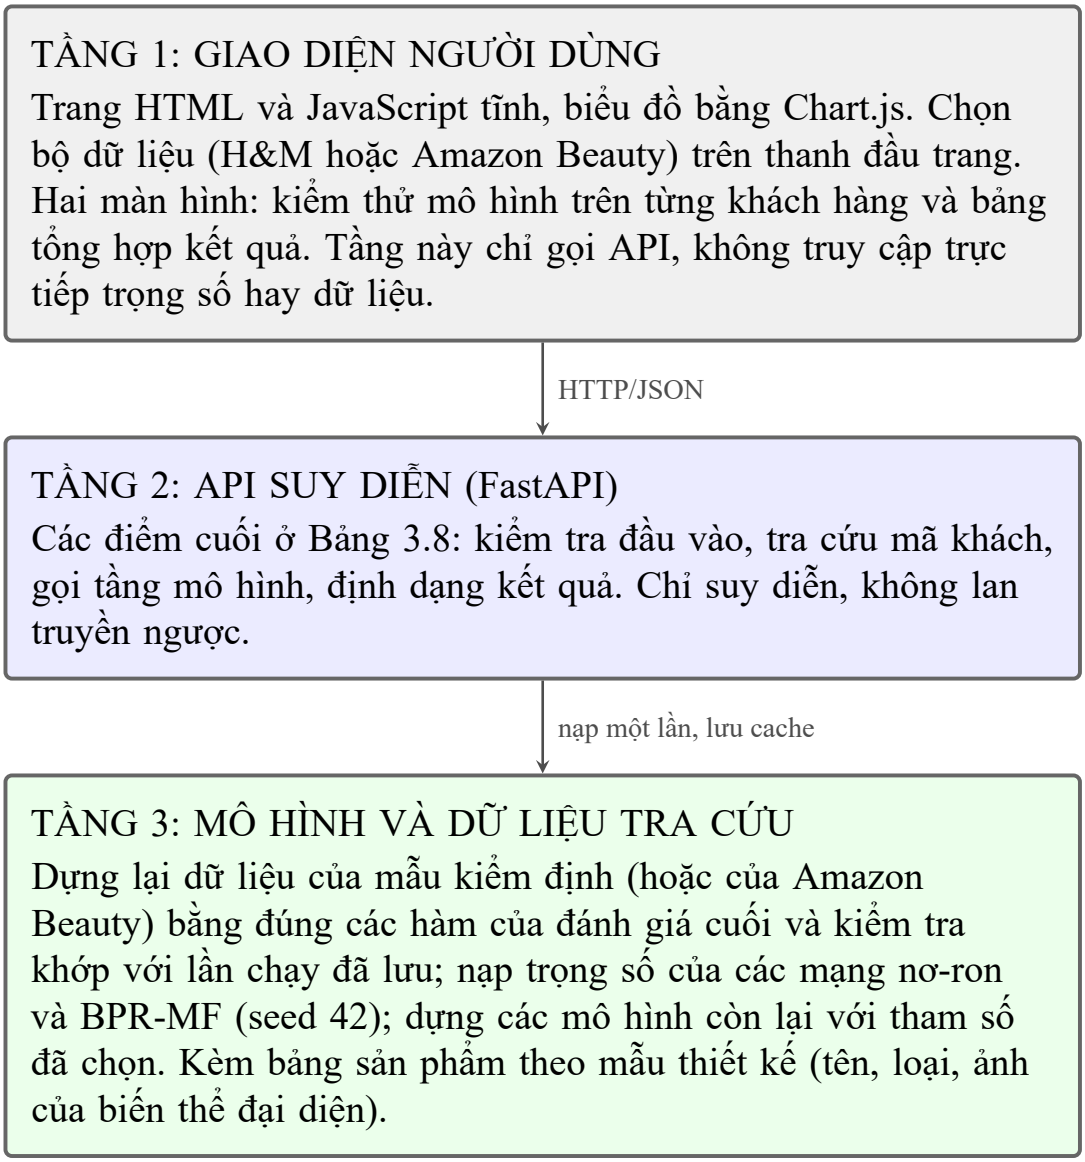
Khách hàng mới là tình huống khởi đầu lạnh của người dùng (mục 2.1.4). Mô hình chỉ có vector nhúng ID và đặc trưng thời gian cho những khách đã có trong dữ liệu đã học. Với một khách chưa mua gì, hoặc mua quá ít để qua bước lọc 10-core, mô hình đề xuất không có thông tin về sở thích. Hệ thống vì vậy dùng một quy tắc đơn giản. Khách mới nhận danh sách các sản phẩm phổ biến nhất, tính trên dữ liệu trước mốc; đây cũng là mô hình đối chứng Most Popular được đánh giá ở Chương 4. Khi khách đã có lịch sử mua trong dữ liệu đã học, hệ thống dùng mô hình đề xuất NeuMF-F. Nhờ vậy hệ thống luôn trả về một danh sách gợi ý. Đánh giá định lượng của đề tài chỉ đo nhóm khách đã có lịch sử, nên chất lượng gợi ý cho khách mới không

được đo riêng.

3.8 Thiết kế hệ thống demo

Hệ thống demo minh họa các mô hình đã huấn luyện trong một kịch bản cửa hàng thời trang. Demo tách biệt với phần huấn luyện: nó chỉ nạp trọng số mô hình đã lưu và gọi lại đúng các hàm xử lý dữ liệu, xếp hạng của quy trình đánh giá, không huấn luyện lại.

3.8.1 Kiến trúc ba tầng



Hình 3.4: Kiến trúc ba tầng của hệ thống demo

Thiết kế theo hai nguyên tắc. Thứ nhất, suy diễn tách khỏi huấn luyện, nên thời

gian phản hồi không phụ thuộc chi phí huấn luyện. Thứ hai, demo kiểm tra rằng dữ liệu dựng lại khớp với lần chạy đã huấn luyện; nếu lệch, máy chủ báo lỗi thay vì nạp trọng số với ánh xạ mã sai. Tập ứng viên và sản phẩm đích của mỗi khách được lấy từ dữ liệu của đánh giá cuối, và với khách đã được đánh giá, demo hiện kèm kết quả đã lưu ở đánh giá cuối để người xem đối chiếu.

3.8.2 Thiết kế API suy diễn

Bảng 3.8: Các điểm cuối chính của API suy diễn

Điểm cuối	Chức năng
`GET /api/context`	Thông tin bộ dữ liệu, lần chạy đang dùng, số người dùng và sản phẩm, số ứng viên, các giá trị K hợp lệ, các mô hình khả dụng.
`GET /api/users/search, /random`	Tìm hoặc chọn ngẫu nhiên một khách hàng có sản phẩm đích, lọc theo nhóm ít, trung bình hoặc nhiều giao dịch.
`GET /api/users/{id}/history`	Lịch sử mua mà mô hình đã học (mọi cặp trước mốc kiểm thử), sắp theo thời gian; với khách mới, lịch sử rỗng và có đánh dấu khách mới.
`GET /api/users/{id}/recommend`	Top-K của một mô hình, hạng của từng sản phẩm đích, số ứng viên và HR@K, NDCG@K, Recall@K của khách đó ($K \in \{5, 10, 15, 20\}$). Khách mới nhận danh sách Most Popular gắn nhãn "gợi ý phổ biến". Khách có lịch sử nhưng không mua gì trong giai đoạn kiểm thử nhận gợi ý của mô hình, không có độ đo.
`GET /api/users/{id}/neighbors`	Các khách tương đồng nhất theo UserKNN: độ tương đồng, số sản phẩm mua chung, láng giềng nào đã mua sản phẩm đích của khách.
`GET /api/dashboard`	Số liệu tổng hợp của đánh giá cuối, hiển thị ở màn hình bảng tổng hợp.

Chức năng gợi ý Top-K chạy đúng các bước của Thuật toán 3.7 và dùng lại các hàm của quy trình đánh giá. Kết quả được ánh xạ về mẫu thiết kế (`product_code`) kèm tên, loại sản phẩm, số màu và ảnh của biến thể đại diện trước khi trả về giao diện.

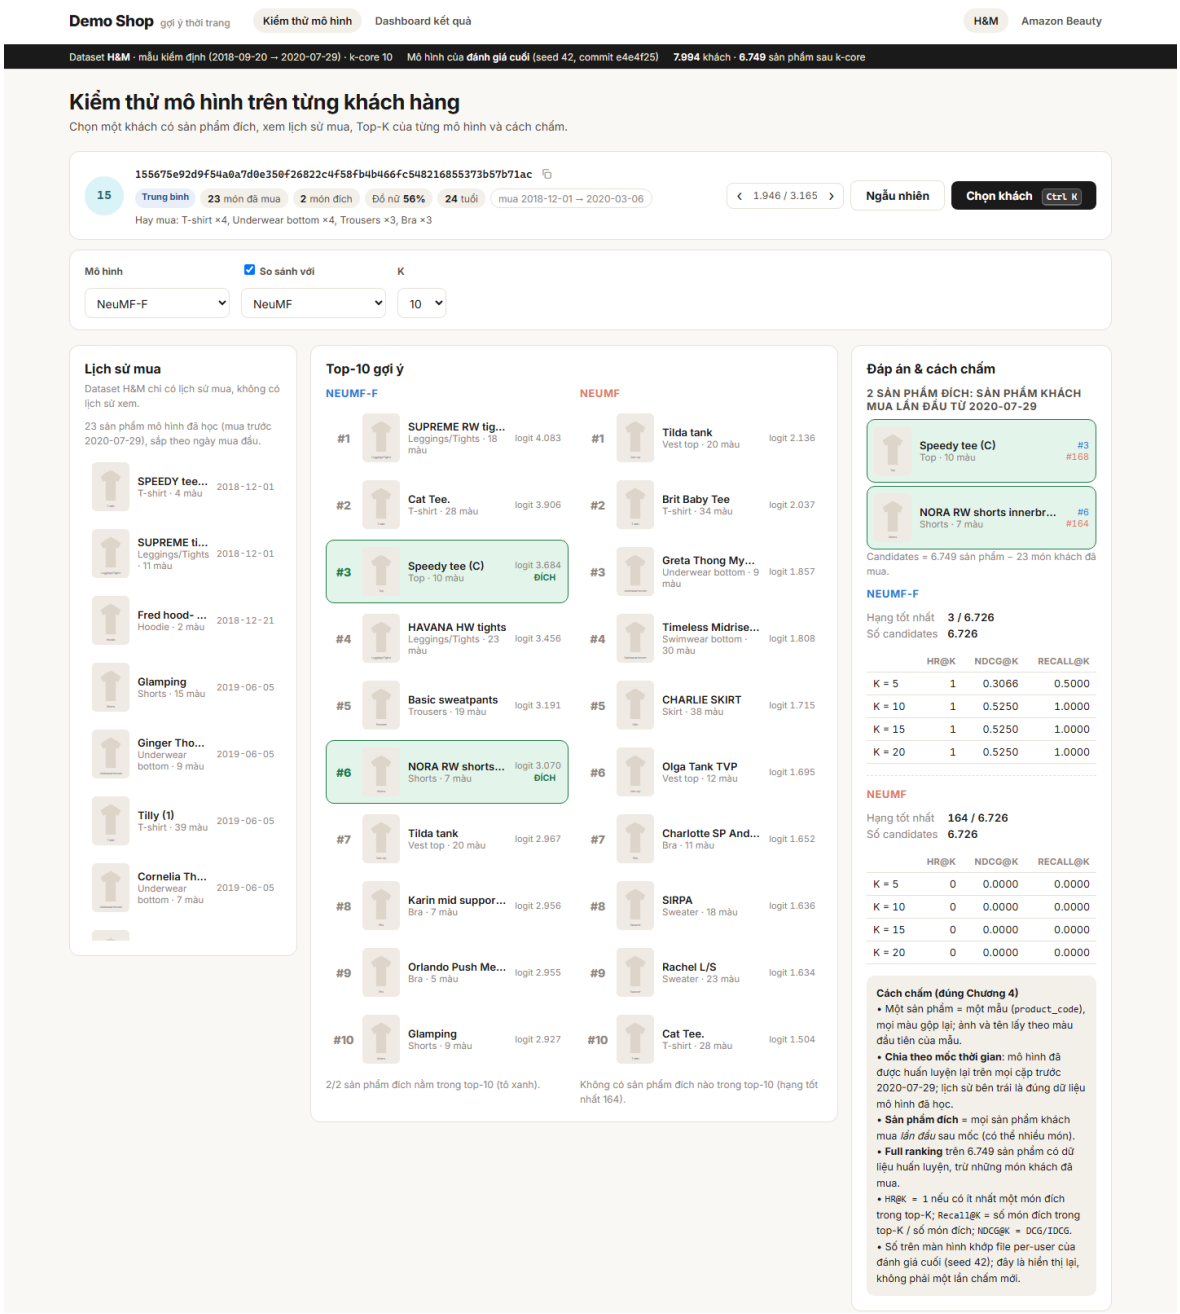
3.8.3 Lựa chọn mô hình triển khai và yêu cầu phi chức năng

Demo cho phép chọn và so sánh song song hai mô hình bất kỳ trong số 13 mô hình của đánh giá cuối và mô hình lai truyền thống bổ sung; mặc định là NeuMF-F và NeuMF chỉ dùng ID. Người xem có thể tự đối chiếu với kết luận của Chương 4, ví dụ đặt danh sách của NeuMF-F cạnh danh sách của NeuMF trên cùng một khách. Demo không khẳng định mô hình nào tốt nhất ngoài những gì kiểm định thống kê cho

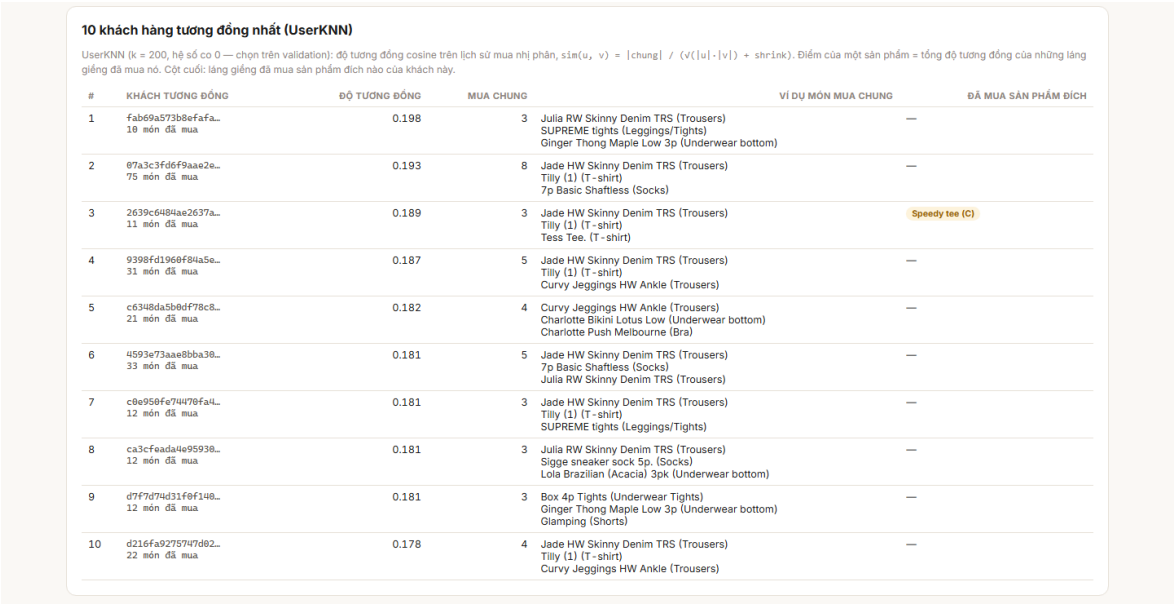
phép. Demo nạp các trọng số của đánh giá cuối (seed 42) trên mẫu kiểm định H&M hoặc trên Amazon Beauty. Lịch sử hiển thị đúng là dữ liệu mô hình đã học, và sản phẩm đích là các món khách mua lần đầu trong giai đoạn kiểm thử. Demo vì vậy minh họa lại kết quả của Chương 4 trên từng khách, không phải một lần đánh giá mới. Màn hình kiểm thử còn hiện 10 khách tương đồng nhất theo UserKNN để minh họa cách lọc cộng tác dựa trên láng giềng chọn ra gợi ý (mục 2.1.2). Về yêu cầu phi chức năng, vector của mọi khách và sản phẩm tại mốc dự đoán được tính một lần khi nạp. Mỗi yêu cầu gợi ý vì vậy chỉ là một lượt suy diễn thuận trên khoảng 6.710 ứng viên, đủ nhanh để phục vụ trực tuyến trên CPU.

3.8.4 Minh họa hệ thống demo

Hình 3.5 là màn hình kiểm thử mô hình với một khách của mẫu kiểm định. Màn hình hiện lịch sử mua, Top-10 của NeuMF-F và của NeuMF, và hạng của từng sản phẩm đích trong tập kiểm thử. Với khách này, NeuMF-F đưa hai sản phẩm đích lên hạng 3 và 6, còn NeuMF chỉ dùng ID xếp sản phẩm đích tốt nhất ở hạng 164. Bảng độ đo bên phải tính ở $K = 5, 10, 15, 20$. Hình 3.6 là bảng 10 khách tương đồng nhất của cùng khách hàng theo UserKNN, gồm độ tương đồng cosine, số sản phẩm mua chung và những sản phẩm đích mà láng giềng đã mua. Hình 3.7 là trường hợp khách mới chưa có trong dữ liệu đã học. Hệ thống trả về Top-10 sản phẩm phổ biến kèm nhãn “gợi ý phổ biến”, không báo lỗi. Khách này không có sản phẩm đích nên không có độ đo để đối chiếu.



Hình 3.5: Giao diện demo: màn hình kiểm thử mô hình

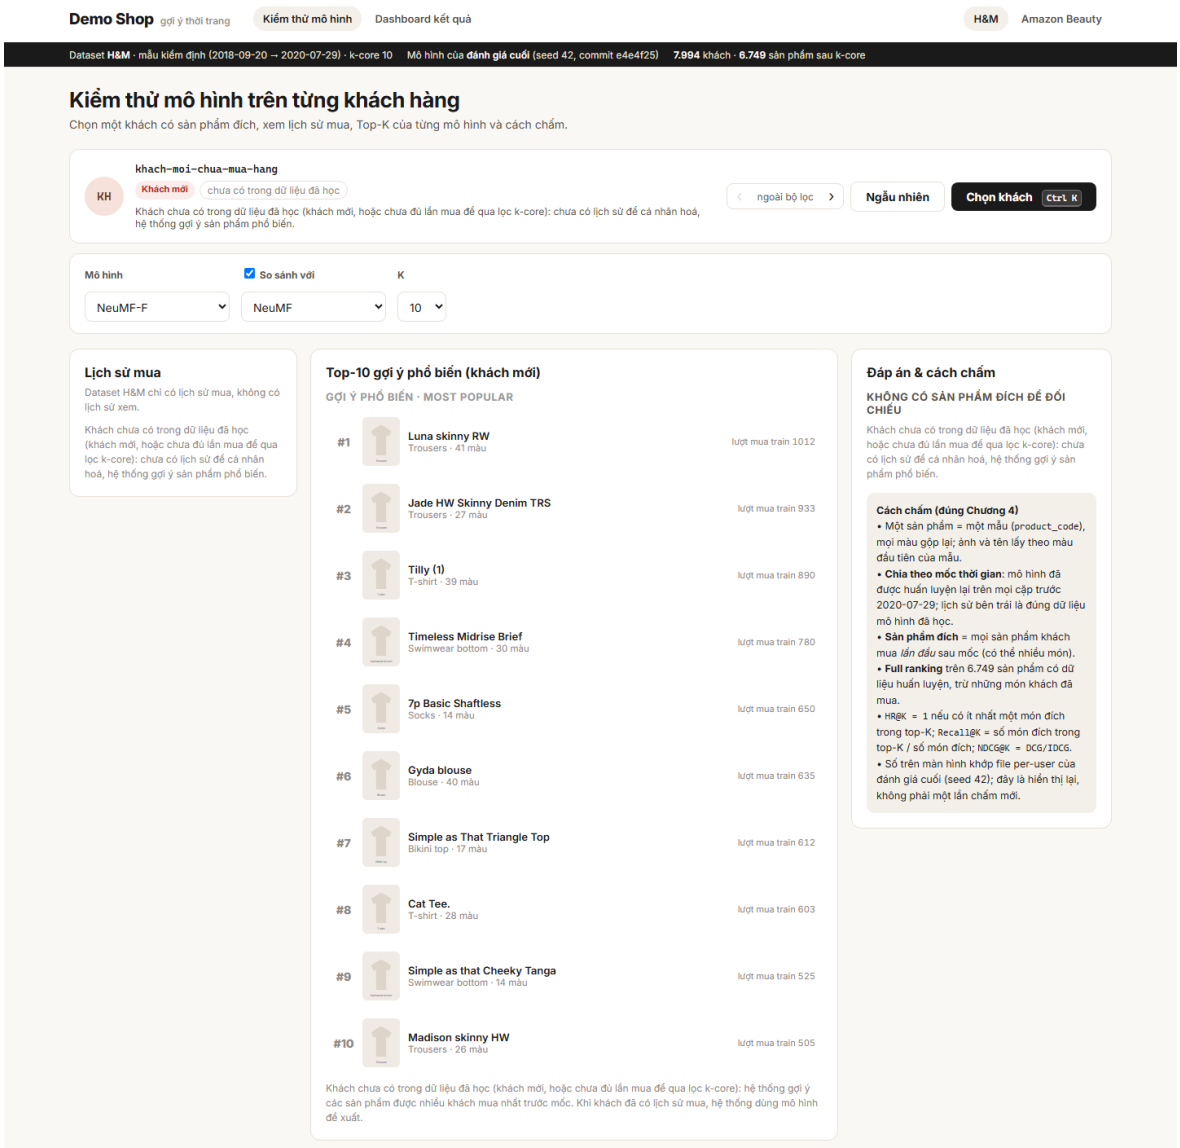


10 khách hàng tương đồng nhất (UserKNN)

UserKNN (k = 200, hệ số co 0 — chọn trên validation): độ tương đồng cosine trên lịch sử mua nhị phân, `sim(u, v) = |chung| / (√(|u|·|v|) + shrink)`. Điểm của một sản phẩm = tổng độ tương đồng của những láng giềng đã mua nó. Cột cuối: láng giềng đã mua sản phẩm đích nào của khách này.

#	KHÁCH TƯƠNG ĐỒNG	ĐỘ TƯƠNG ĐỒNG	MUA CHUNG	VÍ DỤ MÓN MUA CHUNG	ĐÃ MUA SẢN PHẨM ĐÍCH
1	fab69a573b8efafa… 10 món đã mua	0.198	3	Julia RW Skinny Denim TRS (Trousers) SUPREME tights (Leggings/Tights) Ginger Thong Maple Low 3p (Underwear bottom)	—
2	07a3c3fd6f9aae2e… 75 món đã mua	0.193	8	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) 7p Basic Shaftless (Socks)	—
3	2639c6484ae2637a… 11 món đã mua	0.189	3	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Tess Tee. (T-shirt)	Speedy tee (C)
4	9398fd1960f84a5e… 31 món đã mua	0.187	5	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Curvy Jeggings HW Ankle (Trousers)	—
5	c6348da5b0df78c8… 21 món đã mua	0.182	4	Curvy Jeggings HW Ankle (Trousers) Charlotte Bikini Lotus Low (Underwear bottom) Charlotte Push Melbourne (Bra)	—
6	4593e73aae8bba30… 33 món đã mua	0.181	5	Jade HW Skinny Denim TRS (Trousers) 7p Basic Shaftless (Socks) Julia RW Skinny Denim TRS (Trousers)	—
7	c0e950fe744f0fa4… 12 món đã mua	0.181	3	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) SUPREME tights (Leggings/Tights)	—
8	ca3cfeada4e95938… 12 món đã mua	0.181	3	Julia RW Skinny Denim TRS (Trousers) Sigge sneaker sock 5p. (Socks) Lola Brazilian (Acacia) 3pk (Underwear bottom)	—
9	d7f7d74d31f0f140… 12 món đã mua	0.181	3	Box 4p Tights (Underwear Tights) Ginger Thong Maple Low 3p (Underwear bottom) Glamping (Shorts)	—
10	d216fa92757f47d02… 22 món đã mua	0.178	4	Jade HW Skinny Denim TRS (Trousers) Tilly (1) (T-shirt) Curvy Jeggings HW Ankle (Trousers)	—

Hình 3.6: Giao diện demo: 10 khách hàng tương đồng nhất theo UserKNN



Hình 3.7: Giao diện demo: gợi ý cho khách hàng mới

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Cấu hình thực nghiệm

Thực nghiệm chính trên H&M gồm hai bước tách biệt: tinh chỉnh trên tập xác thực của mẫu phát triển, rồi đánh giá cuối một lần trên tập kiểm thử của mẫu kiểm định theo quy trình ở mục 3.6. Quy mô dữ liệu của hai mẫu ở Bảng 3.3. Tập kiểm thử của mẫu kiểm định gồm 3.165 khách hàng và 10.285 cặp đúng; mỗi khách được xếp hạng trên trung bình 6.710 sản phẩm ứng viên. Độ đo chính là NDCG@10 trung bình theo khách, các độ đo khác được báo cáo ở $K = 5, 10, 15, 20$, và mỗi kết quả là trung bình $\pm$ độ lệch chuẩn qua 5 seed. Kết luận được kiểm chứng lại trên bộ Amazon Beauty (mục 4.5). Mọi so sánh trong chương đều giữa các mô hình của đề tài, trên cùng dữ liệu và cùng quy trình; số liệu công bố của các tài liệu tham khảo không được dùng để so sánh.

Bước tinh chỉnh thử 76 cấu hình trong 4,7 giờ. Đánh giá cuối chạy trên NVIDIA GeForce RTX 3050 Laptop GPU với PyTorch 2.6.0+cu124, mất 7,5 giờ cho 5 seed trên H&M và 3,0 giờ trên Amazon Beauty. Có một lệch kế hoạch: lần chạy đầu tiên trên H&M dừng giữa chừng ở seed 42, trước khi lưu kết quả nào, nên seed này được chạy lại từ đầu với cùng cấu hình và dữ liệu. Lần chạy lại được ghi nhận như lệch kế hoạch; không lựa chọn nào thay đổi sau đó vì cấu hình đã cố định từ bước tinh chỉnh.

4.2 Mô hình đối chứng

Theo góp ý của giảng viên hướng dẫn, các mô hình đối chứng được xếp thành ba nhóm (Bảng 4.1). Mỗi nhóm trả lời một câu hỏi khác nhau về mô hình đề xuất. Mọi mô hình được đánh giá với cùng dữ liệu, tập ứng viên và quy tắc đánh giá; Random (điểm ngẫu nhiên) là cận dưới.

Các mô hình của nhóm đơn lẻ, cùng NeuMF và LateFusion-F, được cài đặt trên cùng khung với NeuMF-F (mục 3.3.5). Các mô hình còn lại như sau.

1. Most Popular: điểm của sản phẩm là số khách trong dữ liệu huấn luyện của mẫu đã mua sản phẩm đó. Mọi khách nhận cùng một danh sách, trừ sản phẩm đã mua.
2. MostPopular-Recent: độ phổ biến gần đây trên toàn bộ H&M. Điểm của sản phẩm i là số giao dịch của nó trong W ngày trước mốc dự đoán,

Bảng 4.1: Ba nhóm mô hình đối chứng của mô hình đề xuất NeuMF-F

Nhóm	Mô hình	Câu hỏi được trả lời
Mô hình đơn lẻ	GMF, MLP (chỉ dùng ID); GMF-F, MLP-F (có đặc trưng)	Hợp nhất hai nhánh MF và DNN có hơn từng nhánh đứng riêng không (mục 3.3.5)
Học máy truyền thống	Content, ItemKNN, UserKNN, BPR-MF; mô hình lai truyền thống Hybrid-CBCF†	Mô hình lai học sâu có hơn các phương pháp gợi ý truyền thống, kể cả một mô hình lai truyền thống, không
Chuyên biệt cho gợi ý	Most Popular, MostPopular-Recent; NeuMF (NCF chỉ dùng ID); LateFusion-F (hợp nhất muộn)	Mô hình đề xuất có hơn xu hướng phổ biến, kiến trúc NCF gốc và cách hợp nhất muộn của cùng hai nhánh không

†Bổ sung sau đánh giá cuối theo góp ý của giảng viên hướng dẫn, với kế hoạch đăng ký bổ sung riêng (mục 4.4.4). Cách xếp nhóm do nhóm thực hiện đề xuất.

$\sum_{d=\tau-W}^{\tau-1} n_{i,d}$, với W chọn trên tập xác thực. Đây là mô hình đối chứng mạnh với dữ liệu thời trang có xu hướng thay đổi nhanh. Nó dùng cùng nguồn doanh số với đặc trưng thời gian của NeuMF-F (mục 3.2.5), nên so sánh với nó cho biết NeuMF-F có học được gì vượt trên xu hướng chung hay không.

3. Content: gợi ý theo nội dung thuần (mục 2.1.1). Mỗi sản phẩm được biểu diễn bằng vector văn bản (mục 3.2.5) nối với mã hóa one-hot của ba thuộc tính: nhóm sản phẩm, nhóm chỉ mục và nhóm may mặc. Thuộc tính màu không được dùng vì sau khi gộp các màu của một mẫu thiết kế, nó không còn phân biệt sản phẩm. Vector được chuẩn hóa về độ dài 1. Hồ sơ của khách là trung bình có trọng số các vector sản phẩm đã mua, với trọng số giảm theo thời gian theo chu kỳ bán rã h ngày, $\omega = 2^{-(\tau - t_{uj})/h}$, hoặc bằng 1 nếu không dùng trọng số. Điểm là độ tương đồng cosine giữa hồ sơ và sản phẩm.
4. ItemKNN và UserKNN: lọc cộng tác dựa trên láng giềng (mục 2.1.2), với số láng giềng k và hệ số co chọn trên tập xác thực.
5. BPR-MF: nhân tử hóa ma trận tối ưu thứ hạng theo cặp (mục 2.2.3), đại diện cho MF tuyến tính được tinh chỉnh cùng ngân sách.
6. Hybrid-CBCF: mô hình lai truyền thống theo chương 3 luận án của giảng viên hướng dẫn (mục 2.1.1). Mô hình kết hợp ba mô hình đơn lẻ truyền

thống, Content, UserKNN và ItemKNN, ở mức điểm dự đoán; cấu hình của ba thành phần giữ nguyên như khi tinh chỉnh. Điểm của mỗi thành phần được chuẩn hóa min–max trên tập ứng viên của khách như LateFusion-F (Công thức (2.15)), tạo thành vector $x_{ui} = (x_{ui}^{CB}, x_{ui}^{U}, x_{ui}^{I})$. Như trong luận án, có hai cách kết hợp. Cách bỏ phiếu lấy trung bình, giá trị lớn nhất hoặc nhỏ nhất của ba điểm. Cách trọng số tính $\hat{y}_{ui} = w \cdot x_{ui}$. Luận án học w bằng một mạng truyền thẳng trên điểm đánh giá; phản hồi ẩn không có điểm đánh giá, nên đề tài học w theo cặp. Với mỗi sản phẩm đúng p và sản phẩm không đúng j trong tập ứng viên của cùng một khách, $P(p \text{ xếp trên } j) = \sigma\big(w \cdot (x_{up} - x_{uj})\big)$. Đây là hồi quy logistic trên hiệu đặc trưng, cùng tiêu chí với BPR (Công thức (2.6)) nhưng với hàm điểm tuyến tính (Thuật toán 3.6). Mô hình không có tham số khởi tạo ngẫu nhiên nên cho cùng kết quả ở mọi seed.

Most Popular, ItemKNN, UserKNN và BPR-MF chỉ dùng mã ID, như GMF, MLP và NeuMF.

4.3 Kết quả tinh chỉnh trên tập xác thực của mẫu phát triển

Bảng 4.2 liệt kê cấu hình tốt nhất của từng mô hình trên tập xác thực của mẫu phát triển. Các số này chỉ dùng để chọn cấu hình, không dùng để kết luận, vì chính tập này được dùng để chọn.

Bảng 4.2: Cấu hình tốt nhất của từng mô hình trên tập xác thực của mẫu phát triển

Mô hình	Cấu hình chọn	NDCG@10	HR@10
NeuMF-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03337	0,12807
LateFusion-F	w=0,4 (GMF-F), $1-w$=0,6 (MLP-F)	0,03556	0,14480
GMF-F	d=32; lr=0,001; neg=8; wd=0; bỏ ID=0,25	0,03162	0,13157
MLP-F	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0; bỏ ID=0	0,03212	0,13429
NeuMF	d=64; lr=0,0005; neg=4; wd=10^{-6}; dropout=0,2	0,02696	0,11016
GMF	d=32; lr=0,001; neg=8; wd=10^{-6}	0,02857	0,11405
MLP	d=32; lr=0,001; neg=8; wd=10^{-6}; dropout=0	0,02742	0,10977
BPR-MF	d=128; lr=0,03; reg=0,001; 20 epoch	0,02636	0,10666
ItemKNN	k=100; shrink=50	0,02599	0,09537
UserKNN	k=200; shrink=0	0,02753	0,10432
Content	chu kỳ bán rã 30 ngày	0,00459	0,02180
MostPopular-Recent	cửa sổ 28 ngày	0,02334	0,10432
Most Popular	—	0,02174	0,09420
Hybrid-CBCF†	tổng có trọng số học theo cặp: Content 0,12; UserKNN 0,60; ItemKNN 0,28	0,02815	0,10588

Seed 42. Mỗi mô hình có học thử 6 cấu hình; mô hình chỉ có một tham số thử đủ lưới. d: số chiều vector nhúng; lr: tốc độ học; reg: hệ số điều chuẩn; neg: số mẫu âm cho mỗi mẫu dương; wd: hệ số điều chuẩn L2; shrink: hệ số co; bỏ ID: xác suất bỏ vector nhúng ID của sản phẩm khi huấn luyện. Số trên tập xác thực dùng để chọn cấu hình, không dùng để kết luận. †Mô hình lai truyền thống bổ sung sau đánh giá cuối; trọng số đã chia cho tổng; NDCG@10 tính bằng khớp chéo theo khách (Bảng 4.3).

Trên tập xác thực của mẫu phát triển, bốn mô hình có đặc trưng đứng đầu và cách nhau không nhiều, trong đó LateFusion-F và NeuMF-F dẫn đầu. Không tính mô hình lai truyền thống Hybrid-CBCF (đoạn sau), mô hình đối chứng không dùng mạng nơ-ron cao nhất là UserKNN, tiếp theo là BPR-MF và ItemKNN. Các mạng nơ-ron đạt NDCG@10 tốt nhất ở epoch trung vị 7 và muộn nhất ở epoch 16, trong giới hạn 20 epoch.

Với Hybrid-CBCF, cách kết hợp được chọn trên cùng tập xác thực (Bảng 4.3, Thuật toán 3.6). Bỏ phiếu lấy trung bình đạt NDCG@10 thấp hơn UserKNN đứng riêng, vì Content đứng riêng rất yếu nhưng nhận trọng số ngang hai thành phần còn lại; lấy giá trị lớn nhất hoặc nhỏ nhất còn thấp hơn. Tổng có trọng số học theo cặp, đánh giá bằng khớp chéo theo khách, là cách tốt nhất và tốt hơn từng thành phần đứng riêng, nên được chọn. Trọng số chuẩn hóa là 0,60 cho UserKNN, 0,28 cho ItemKNN và 0,12 cho Content: lọc cộng tác giữ vai trò chính, lọc nội dung chỉ đóng góp một phần nhỏ.

Bảng 4.3: Các cách kết hợp của Hybrid-CBCF trên tập xác thực của mẫu phát triển

Mô hình	NDCG@10	HR@10
Thành phần đứng riêng		
Content	0,00435	0,02141
UserKNN	0,02753	0,10432
ItemKNN	0,02599	0,09537
Hybrid-CBCF theo cách kết hợp		
Bỏ phiếu: trung bình	0,02634	0,10004
Bỏ phiếu: lớn nhất	0,01483	0,05411
Bỏ phiếu: nhỏ nhất	0,02143	0,08447
Tổng có trọng số học theo cặp (được chọn)	**0,02815**	**0,10588**

In đậm: cao nhất mỗi cột. Điểm của mỗi thành phần được chuẩn hoá min–max trên tập ứng viên của khách. Bỏ phiếu lấy trung bình, giá trị lớn nhất hoặc nhỏ nhất của ba điểm. Tổng có trọng số dùng trọng số học bằng hồi quy logistic trên các cặp (sản phẩm đúng, sản phẩm không đúng) của cùng một khách, 50 sản phẩm không đúng cho mỗi sản phẩm đúng; NDCG@10 của cách này tính bằng khớp chéo hai phần theo khách. Số trên tập xác thực chỉ dùng để chọn. Content khác Bảng 4.2 (0,00459) do vector văn bản được dựng lại.

4.4 Kết quả đánh giá cuối trên mẫu kiểm định

4.4.1 So sánh các độ đo xếp hạng

Bảng 4.4 và Hình 4.1 trình bày kết quả trên tập kiểm thử của mẫu kiểm định, xếp theo ba nhóm mô hình đối chứng; hình vẽ thêm độ lệch chuẩn và giá trị của từng seed. Thứ hạng nêu dưới đây tính trên 14 mô hình đăng ký trước; Hybrid-CBCF (dấu †) được bàn riêng ở mục 4.4.4.

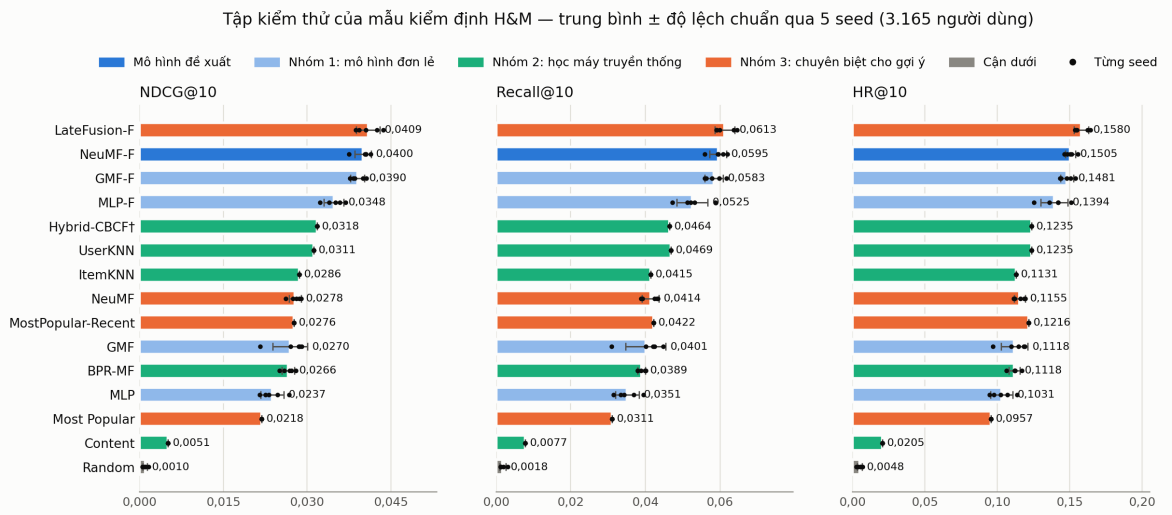
Bảng 4.4: Kết quả trên tập kiểm thử của mẫu kiểm định H&M theo ba nhóm mô hình đối chứng

Mô hình	NDCG@10	Recall@10	HR@10	Precision@10	NDCG@5	NDCG@20
Mô hình đề xuất						
NeuMF-F	0,04003 ± 0,00147	0,05953 ± 0,00226	0,15046 ± 0,00354	0,01723 ± 0,00027	0,03120 ± 0,00178	0,05166 ± 0,00129
Nhóm 1: mô hình đơn lẻ						
GMF-F	0,03902 ± 0,00124	0,05834 ± 0,00243	0,14812 ± 0,00452	0,01712 ± 0,00049	0,03046 ± 0,00080	0,05051 ± 0,00087
MLP-F	0,03480 ± 0,00177	0,05251 ± 0,00417	0,13940 ± 0,00943	0,01584 ± 0,00096	0,02688 ± 0,00093	0,04689 ± 0,00220
GMF	0,02695 ± 0,00311	0,04007 ± 0,00539	0,11179 ± 0,00909	0,01243 ± 0,00121	0,02105 ± 0,00181	0,03562 ± 0,00297
MLP	0,02373 ± 0,00207	0,03510 ± 0,00316	0,10306 ± 0,00765	0,01129 ± 0,00092	0,01812 ± 0,00153	0,03269 ± 0,00195
Nhóm 2: học máy truyền thống						
Hybrid-CBCF†	0,03183 ± 0,00000	0,04641 ± 0,00000	0,12354 ± 0,00000	0,01362 ± 0,00000	0,02550 ± 0,00000	0,04194 ± 0,00000
UserKNN	0,03114 ± 0,00000	0,04686 ± 0,00000	0,12354 ± 0,00000	0,01365 ± 0,00000	0,02446 ± 0,00000	0,04086 ± 0,00000
ItemKNN	0,02860 ± 0,00000	0,04146 ± 0,00000	0,11311 ± 0,00000	0,01267 ± 0,00000	0,02330 ± 0,00000	0,03835 ± 0,00000
BPR-MF	0,02661 ± 0,00114	0,03895 ± 0,00106	0,11179 ± 0,00381	0,01238 ± 0,00040	0,02045 ± 0,00126	0,03641 ± 0,00163
Content	0,00506 ± 0,00000	0,00772 ± 0,00000	0,02054 ± 0,00000	0,00209 ± 0,00000	0,00384 ± 0,00000	0,00683 ± 0,00000
Nhóm 3: chuyên biệt cho gợi ý						
LateFusion-F	**0,04093** ± 0,00212	**0,06125** ± 0,00268	**0,15798** ± 0,00498	**0,01833** ± 0,00066	**0,03208** ± 0,00246	**0,05304** ± 0,00232
NeuMF	0,02783 ± 0,00109	0,04137 ± 0,00223	0,11545 ± 0,00382	0,01301 ± 0,00037	0,02139 ± 0,00115	0,03701 ± 0,00100
MostPopular-Recent	0,02760 ± 0,00000	0,04219 ± 0,00000	0,12164 ± 0,00000	0,01393 ± 0,00000	0,02161 ± 0,00000	0,03789 ± 0,00000
Most Popular	0,02184 ± 0,00000	0,03107 ± 0,00000	0,09573 ± 0,00000	0,01027 ± 0,00000	0,01783 ± 0,00000	0,02983 ± 0,00000
Cận dưới						
Random	0,00098 ± 0,00040	0,00176 ± 0,00082	0,00480 ± 0,00169	0,00049 ± 0,00018	0,00059 ± 0,00035	0,00150 ± 0,00039

Trung bình ± độ lệch chuẩn qua 5 seed; xếp hạng trên toàn bộ tập ứng viên của 3.165 người dùng. In đậm: trung bình cao nhất mỗi cột. Mô hình tất định (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN, Hybrid-CBCF) cho cùng kết quả ở mọi seed. †Mô hình lai truyền thống bổ sung sau đánh giá cuối theo góp ý của giảng viên hướng dẫn: chấm một lần trên cùng tập kiểm thử, không thuộc họ 10 so sánh đăng ký trước.

Kết quả trên tập kiểm thử giữ đúng bức tranh của bước tinh chỉnh: bốn mô hình có đặc trưng đứng đầu, như trên tập xác thực. LateFusion-F đạt NDCG@10 cao nhất (0,04093), tiếp theo là mô hình đề xuất NeuMF-F (0,04003 ± 0,00147), rồi GMF-F và MLP-F. Mô hình đứng ngay sau nhóm này là UserKNN (0,03114); NeuMF chỉ dùng ID chỉ đạt 0,02783, thấp hơn rõ so với cùng kiến trúc khi có đặc trưng. HR@10 của NeuMF-F là 0,15046, tức khoảng 15% số khách có ít nhất một sản phẩm đúng trong 10 gợi ý đầu.

Giá trị tuyệt đối của các độ đo thấp vì mỗi khách chỉ có vài sản phẩm đúng giữa hàng nghìn ứng viên, và dự đoán những món khách chưa từng mua trong 8 tuần tới là



Hình 4.1: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử của mẫu kiểm định H&M

bài toán khó với dữ liệu thời trang. Thông tin quan trọng vì vậy là thứ hạng tương đối giữa các mô hình và việc chênh lệch có ý nghĩa thống kê hay không.

4.4.2 Kết quả theo $K = 5, 10, 15, 20$

Bảng 4.5 và Bảng 4.6 trình bày bốn độ đo ở $K = 5, 10, 15, 20$, tính từ hạng đã lưu như mô tả ở mục 3.6.

Ở mọi K và với cả bốn độ đo, thứ tự của bốn mô hình có đặc trưng giữ nguyên: LateFusion-F, NeuMF-F, GMF-F rồi MLP-F, đứng trên mọi mô hình chỉ dùng ID và mọi mô hình đối chứng. Khi K tăng từ 5 lên 20, HR@K và Recall@K của NeuMF-F tăng, còn Precision@K giảm: danh sách dài hơn chứa thêm sản phẩm đúng nhưng tỉ lệ đúng trong danh sách thấp đi. Thứ tự giữa các mô hình đối chứng có thay đổi nhỏ theo K, ví dụ MostPopular-Recent vượt UserKNN ở HR@15 và HR@20, nhưng vị trí dẫn đầu của bốn mô hình có đặc trưng không đổi. Việc chọn $K = 10$ làm độ đo chính vì vậy không làm thay đổi bức tranh chung.

4.4.3 Kiểm định ý nghĩa thống kê

Bảng 4.7 và Hình 4.2 trình bày kiểm định họ 10 so sánh đã đăng ký trước, với tiêu chí kết luận ở mục 3.6. NeuMF-F tốt hơn có ý nghĩa ở 7 so sánh: so với NeuMF chỉ dùng ID (+43,8%), với nhánh MLP-F (+15,0%) và với cả năm mô hình đối chứng, từ +28,5% so với UserKNN đến +691,5% so với Content. Ba so sánh còn lại không khác biệt có ý nghĩa: NeuMF-F so với nhánh GMF-F (+2,6%), NeuMF-F so với LateFusion-F ($-2{,}2\%$), và NeuMF chỉ dùng ID so với BPR-MF (+4,6%). Ý nghĩa

Bảng 4.5: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định H&M

	NDCG@K				Recall@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0321**	**0,0409**	**0,0475**	**0,0530**	**0,0364**	**0,0613**	**0,0806**	**0,0985**
NeuMF-F	0,0312	0,0400	0,0464	0,0517	0,0345	0,0595	0,0780	0,0945
GMF-F	0,0305	0,0390	0,0455	0,0505	0,0345	0,0583	0,0771	0,0931
MLP-F	0,0269	0,0348	0,0415	0,0469	0,0300	0,0525	0,0720	0,0893
Hybrid-CBCF†	0,0255	0,0318	0,0375	0,0419	0,0282	0,0464	0,0625	0,0764
UserKNN	0,0245	0,0311	0,0357	0,0409	0,0279	0,0469	0,0596	0,0764
ItemKNN	0,0233	0,0286	0,0343	0,0384	0,0263	0,0415	0,0584	0,0713
NeuMF	0,0214	0,0278	0,0330	0,0370	0,0230	0,0414	0,0563	0,0693
MostPopular-Recent	0,0216	0,0276	0,0332	0,0379	0,0244	0,0422	0,0586	0,0730
GMF	0,0211	0,0270	0,0317	0,0356	0,0233	0,0401	0,0539	0,0665
BPR-MF	0,0205	0,0266	0,0320	0,0364	0,0221	0,0389	0,0542	0,0682
MLP	0,0181	0,0237	0,0287	0,0327	0,0199	0,0351	0,0492	0,0619
Most Popular	0,0178	0,0218	0,0255	0,0298	0,0200	0,0311	0,0417	0,0548
Content	0,0038	0,0051	0,0062	0,0068	0,0043	0,0077	0,0108	0,0131
Random	0,0006	0,0010	0,0013	0,0015	0,0007	0,0018	0,0026	0,0033

Trung bình qua 5 seed, tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối, không chấm lại tập kiểm thử; cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột.
†Mô hình lai truyền thống bổ sung sau đánh giá cuối (hạng đã lưu ở lần chấm bổ sung).

Bảng 4.6: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử của mẫu kiểm định H&M

	HR@K				Precision@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0993**	**0,1580**	**0,1999**	**0,2367**	**0,0220**	**0,0183**	**0,0160**	**0,0146**
NeuMF-F	0,0935	0,1505	0,1941	0,2298	0,0205	0,0172	0,0153	0,0140
GMF-F	0,0922	0,1481	0,1917	0,2267	0,0201	0,0171	0,0152	0,0139
MLP-F	0,0861	0,1394	0,1844	0,2215	0,0186	0,0158	0,0145	0,0134
Hybrid-CBCF†	0,0793	0,1235	0,1621	0,1946	0,0167	0,0136	0,0125	0,0116
UserKNN	0,0799	0,1235	0,1589	0,1934	0,0167	0,0136	0,0121	0,0114
ItemKNN	0,0733	0,1131	0,1494	0,1779	0,0158	0,0127	0,0116	0,0106
NeuMF	0,0684	0,1155	0,1493	0,1773	0,0149	0,0130	0,0117	0,0107
MostPopular-Recent	0,0787	0,1216	0,1633	0,1991	0,0167	0,0139	0,0127	0,0119
GMF	0,0700	0,1118	0,1440	0,1717	0,0149	0,0124	0,0111	0,0102
BPR-MF	0,0672	0,1118	0,1494	0,1812	0,0140	0,0124	0,0115	0,0108
MLP	0,0604	0,1031	0,1390	0,1676	0,0127	0,0113	0,0105	0,0098
Most Popular	0,0629	0,0957	0,1220	0,1596	0,0128	0,0103	0,0091	0,0091
Content	0,0120	0,0205	0,0297	0,0348	0,0025	0,0021	0,0021	0,0018
Random	0,0021	0,0048	0,0075	0,0099	0,0004	0,0005	0,0005	0,0005

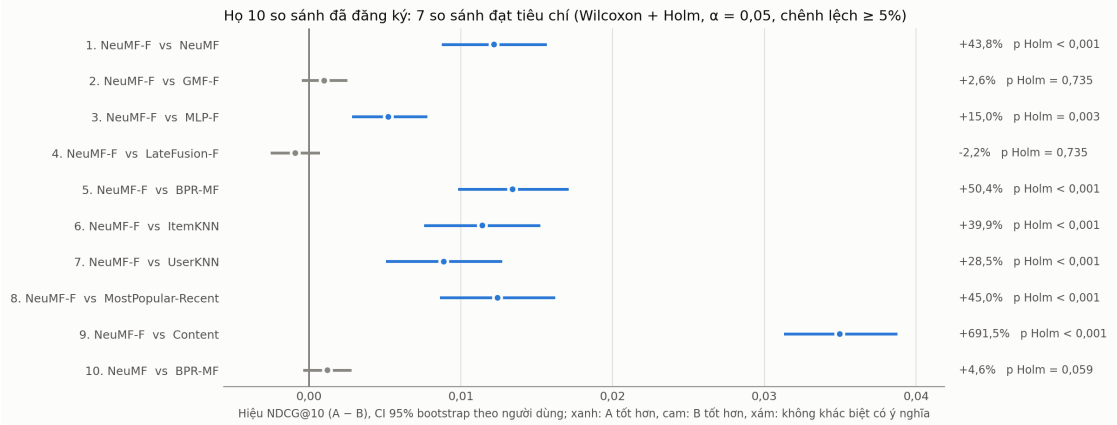
Trung bình qua 5 seed, tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối, không chấm lại tập kiểm thử; cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột.
†Mô hình lai truyền thống bổ sung sau đánh giá cuối (hạng đã lưu ở lần chấm bổ sung).

của các kết quả này được thảo luận ở mục 4.8.

Bảng 4.7: Kiểm định họ 10 so sánh đã đăng ký trước trên mẫu kiểm định H&M (NDCG@10)

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F	NeuMF	0,04003	0,02783	+43,8%	[+0,00876; +0,01566]	< 0,001	A tốt hơn
2	NeuMF-F	GMF-F	0,04003	0,03902	+2,6%	[−0,00045; +0,00253]	0,735	—
3	NeuMF-F	MLP-F	0,04003	0,03480	+15,0%	[+0,00283; +0,00782]	0,003	A tốt hơn
4	NeuMF-F	LateFusion-F	0,04003	0,04093	−2,2%	[−0,00252; +0,00072]	0,735	—
5	NeuMF-F	BPR-MF	0,04003	0,02661	+50,4%	[+0,00982; +0,01712]	< 0,001	A tốt hơn
6	NeuMF-F	ItemKNN	0,04003	0,02860	+39,9%	[+0,00760; +0,01525]	< 0,001	A tốt hơn
7	NeuMF-F	UserKNN	0,04003	0,03114	+28,5%	[+0,00509; +0,01273]	< 0,001	A tốt hơn
8	NeuMF-F	MostPopular-Recent	0,04003	0,02760	+45,0%	[+0,00864; +0,01622]	< 0,001	A tốt hơn
9	NeuMF-F	Content	0,04003	0,00506	+691,5%	[+0,03129; +0,03876]	< 0,001	A tốt hơn
10	NeuMF	BPR-MF	0,02783	0,02661	+4,6%	[−0,00036; +0,00281]	0,059	—

Mỗi người dùng lấy trung bình qua 5 seed; kiểm định Wilcoxon theo người dùng, khoảng tin cậy bootstrap 95%, hiệu chỉnh Holm. —: không khác biệt có ý nghĩa. “A tốt hơn” (hoặc “B tốt hơn”) chỉ khi đồng thời p Holm $< 0{,}05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$.



Hình 4.2: Hiệu NDCG@10 của họ 10 so sánh đã đăng ký trên H&M, kèm khoảng tin cậy 95%

4.4.4 Phân tích bổ sung: so sánh với mô hình lai truyền thống

Hybrid-CBCF (mục 4.2) được thêm theo góp ý của giảng viên hướng dẫn sau khi đánh giá cuối của 14 mô hình đã xong. Để không ảnh hưởng tới các kết luận đã đăng ký, phần này có kế hoạch riêng. Cách kết hợp được chọn trên tập xác thực của mẫu phát triển (mục 4.3). Tập kiểm thử của mẫu kiểm định được mở thêm đúng một lần, với cùng dữ liệu, tập ứng viên và quy tắc phá hoà. Hai so sánh bổ sung được kiểm định như họ đăng ký trước nhưng hiệu chỉnh Holm riêng. So sánh B1 đặt NeuMF-F cạnh Hybrid-CBCF, tức mô hình lai học sâu cạnh mô hình lai truyền thống. So sánh B2 đặt Hybrid-CBCF cạnh UserKNN, thành phần mạnh nhất của nó trên tập xác thực.

Trên tập kiểm thử, Hybrid-CBCF xếp thứ năm trong 15 mô hình của Bảng 4.4.

Bảng 4.8: Kiểm định các so sánh bổ sung với Hybrid-CBCF trên mẫu kiểm định H&M (NDCG@10)

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F	Hybrid-CBCF	0,04003	0,03183	+25,8%	[+0,00445; +0,01195]	< 0,001	A tốt hơn
B2	Hybrid-CBCF	UserKNN	0,03183	0,03114	+2,2%	[−0,00061; +0,00195]	0,152	—

Mỗi người dùng lấy trung bình qua 5 seed; kiểm định Wilcoxon theo người dùng, khoảng tin cậy bootstrap 95%, hiệu chỉnh Holm trong họ bổ sung. —: không khác biệt có ý nghĩa. Tiêu chí "tốt hơn" như họ 10 so sánh đăng ký trước: p Holm $< 0,05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$. Họ bổ sung được đăng ký sau đánh giá cuối và không làm thay đổi họ 10 so sánh.

Như vậy Hybrid-CBCF đứng ngay sau bốn mô hình có đặc trưng và trên mọi mô hình đối chứng còn lại. Theo Bảng 4.8, NeuMF-F so với Hybrid-CBCF chênh +25,8% (NeuMF-F tốt hơn có ý nghĩa), tức mô hình lai học sâu có đặc trưng vượt rõ mô hình lai truyền thống. Ngược lại, Hybrid-CBCF so với UserKNN chỉ chênh +2,2% (không khác biệt có ý nghĩa). Điều này khớp với trọng số đã học, vốn dồn phần lớn vào UserKNN, và với việc Content đứng riêng rất yếu trên H&M. Ba thành phần được chấm lại ở lần bổ sung cho kết quả trùng lần đánh giá cuối, trừ Content lệch nhẹ (NDCG@10 0,00481 so với 0,00506); mức lệch này không đáng kể vì Content chỉ chiếm trọng số 0,12.

4.4.5 Phân tích bóc tách thành phần

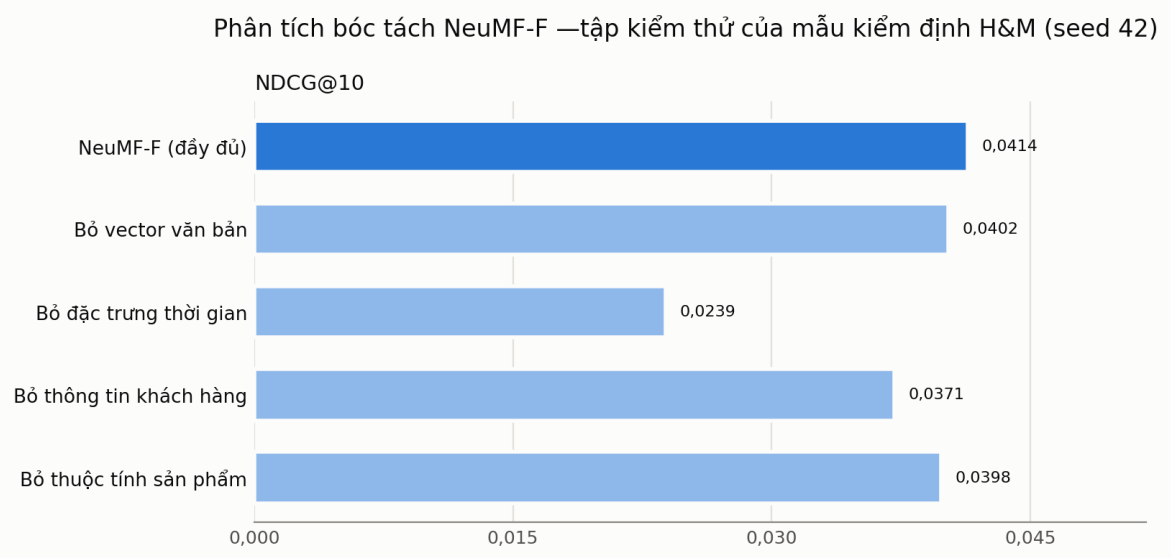
Bảng 4.9 và Hình 4.3 so sánh NeuMF-F đầy đủ với bốn biến thể tắt một thành phần, cùng siêu tham số và cùng quy trình huấn luyện (seed 42). Biến thể thứ năm của kế hoạch, không bỏ ID ngẫu nhiên khi huấn luyện, trùng với chính NeuMF-F, vì cấu hình được chọn của NeuMF-F có xác suất bỏ ID $\rho = 0$ (Bảng 4.2); biến thể này vì vậy không được chạy. Đây là phân tích mô tả với một seed, không dùng để chọn lại cấu hình.

Bỏ đặc trưng thời gian làm NDCG@10 thay đổi −42,3%, với khoảng tin cậy 95% của hiệu là [−0,02122; −0,01380]; bỏ thông tin khách hàng làm NDCG@10 thay đổi −10,3%. Đặc trưng thời gian, gồm doanh số gần đây và tuổi của sản phẩm, khoảng cách tới lần mua gần nhất và số sản phẩm đã mua của khách, vì vậy đóng góp nhiều nhất. Bỏ thuộc tính sản phẩm (−3,7%) hoặc vector văn bản (−2,7%) chỉ làm NDCG@10 thay đổi ít. Khoảng tin cậy của hiệu khi bỏ thuộc tính sản phẩm hoặc vector văn bản chứa 0, nên với một seed không khẳng định được hai nhóm đặc trưng này có đóng góp.

Bảng 4.9: Phân tích bóc tách NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,04137	—	—
Bỏ vector văn bản	0,04025	−2,7%	[−0,00450; +0,00236]
Bỏ đặc trưng thời gian	0,02386	−42,3%	[−0,02122; −0,01380]
Bỏ thông tin khách hàng	0,03712	−10,3%	[−0,00720; −0,00132]
Bỏ thuộc tính sản phẩm	0,03983	−3,7%	[−0,00467; +0,00158]

Seed 42; cùng siêu tham số, mỗi biến thể tắt một thành phần. Thay đổi: (biến thể − đầy đủ)/đầy đủ. CI: khoảng tin cậy bootstrap theo người dùng của hiệu (biến thể − đầy đủ). Chỉ mô tả, không kiểm định. Biến thể trùng NeuMF-F, ví dụ không bỏ ID ngẫu nhiên khi cấu hình chọn đã có xác suất bỏ ID bằng 0, không được chạy.



Hình 4.3: Phân tích bóc tách NeuMF-F trên tập kiểm thử của mẫu kiểm định H&M

4.4.6 Độ phủ và chi phí huấn luyện

Bảng 4.10: Độ phủ danh sách top-10 và chi phí huấn luyện trên mẫu kiểm định H&M

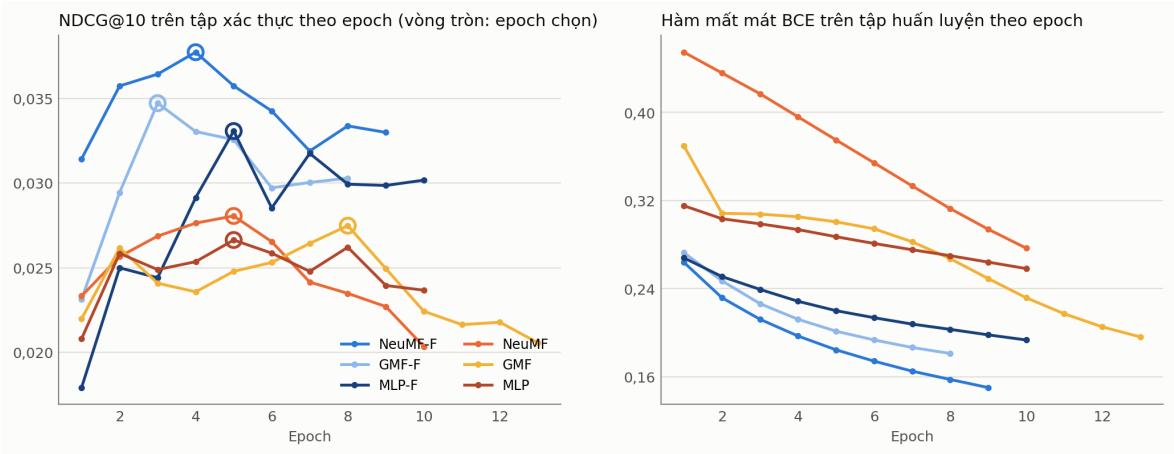
Mô hình	Độ phủ ứng viên	Số epoch chọn	Thời gian (phút)
LateFusion-F	5,3%	—	0,0
NeuMF-F	13,3%	3,0	15,2
GMF-F	6,9%	4,4	13,7
MLP-F	5,3%	4,6	16,4
Hybrid-CBCF†	10,8%	—	0,1
UserKNN	5,7%	—	0,0
ItemKNN	20,4%	—	0,0
NeuMF	6,0%	4,2	6,2
MostPopular-Recent	0,3%	—	0,0
GMF	7,3%	6,2	7,2
BPR-MF	5,1%	—	4,3
MLP	3,3%	4,8	8,4
Most Popular	0,3%	—	0,0
Content	78,2%	—	0,0
Random	98,9%	—	0,0

Độ phủ (seed 42): tỉ lệ sản phẩm của tập ứng viên xuất hiện trong top-10 của ít nhất một người dùng. Số epoch và thời gian là trung bình qua seed; số epoch chọn trên tập xác thực của mẫu kiểm định trước khi huấn luyện lại. Thời gian gồm chọn epoch và huấn luyện lại (mạng nơ-ron) hoặc khớp mô hình, không gồm thời gian chấm. †Bổ sung sau đánh giá cuối; thời gian đo trên máy chỉ có CPU.

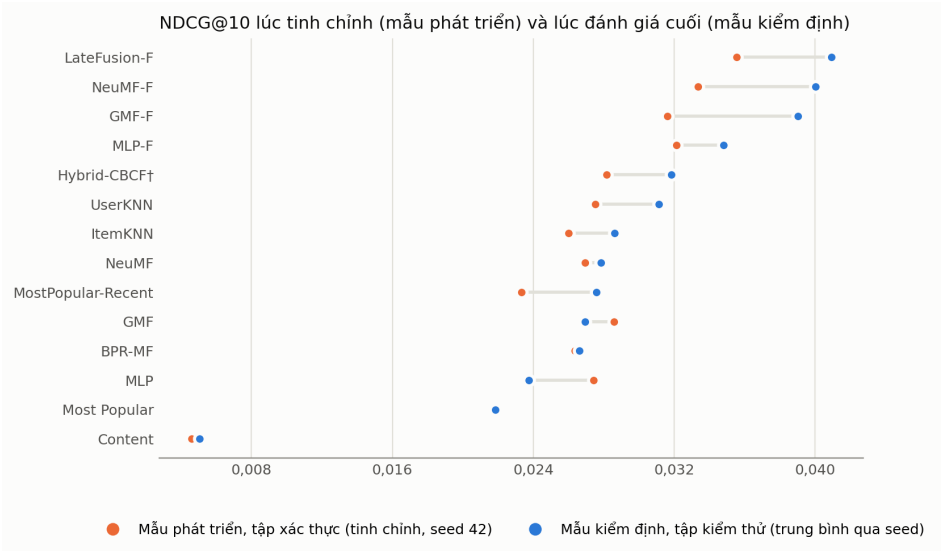
Bảng 4.10 mô tả danh sách top-10 (mục 2.5.2) và chi phí huấn luyện. Most Popular và MostPopular-Recent có độ phủ thấp nhất vì mọi khách nhận gần như cùng một danh sách. Trong các mô hình cá nhân hóa, MLP chỉ dùng ID có độ phủ thấp nhất, còn NeuMF-F có độ phủ cao nhất trong các mạng nơ-ron (13,3%), chỉ sau ItemKNN và Content, hai mô hình chấm điểm theo độ giống thay vì độ phổ biến. Độ phủ của Hybrid-CBCF nằm giữa độ phủ của hai thành phần cộng tác UserKNN và ItemKNN. Về chi phí, mỗi seed của NeuMF-F huấn luyện mất 15,2 phút, so với 6,2 phút của NeuMF chỉ dùng ID.

4.4.7 Hội tụ và độ ổn định giữa hai mẫu

Hình 4.4 cho thấy NDCG@10 trên tập xác thực của mẫu kiểm định và hàm mất mát BCE trên tập huấn luyện theo epoch, khi chọn số epoch cho đánh giá cuối (seed 42); vòng tròn đánh dấu epoch được chọn. Hình 4.5 đặt NDCG@10 lúc tinh chỉnh (mẫu phát triển, tập xác thực) cạnh NDCG@10 lúc đánh giá cuối (mẫu kiểm định, tập kiểm thử). Hai con số không cùng thang, vì khác mẫu khách hàng và cửa sổ kiểm thử



Hình 4.4: Đường hội tụ của các mạng nơ-ron khi chọn số epoch



Hình 4.5: NDCG@10 lúc tinh chỉnh và lúc đánh giá cuối

dài gấp đôi cửa sổ xác thực; điều cần xem là thứ hạng giữa các mô hình có được giữ khi chuyển sang khách hàng khác hay không. Bốn mô hình có đặc trưng đứng đầu ở cả hai, và LateFusion-F và NeuMF-F giữ hai vị trí đầu. Thay đổi thứ hạng lớn nhất thuộc về GMF và MLP chỉ dùng ID, từ thứ năm và thứ bảy lúc tinh chỉnh xuống thứ chín và thứ mười một ở đánh giá cuối. Đây cũng là hai mô hình duy nhất có NDCG@10 trên tập kiểm thử thấp hơn lúc tinh chỉnh. ItemKNN đi theo chiều ngược lại, từ thứ mười lên thứ sáu.

4.5 Kiểm chứng trên dữ liệu Amazon Beauty

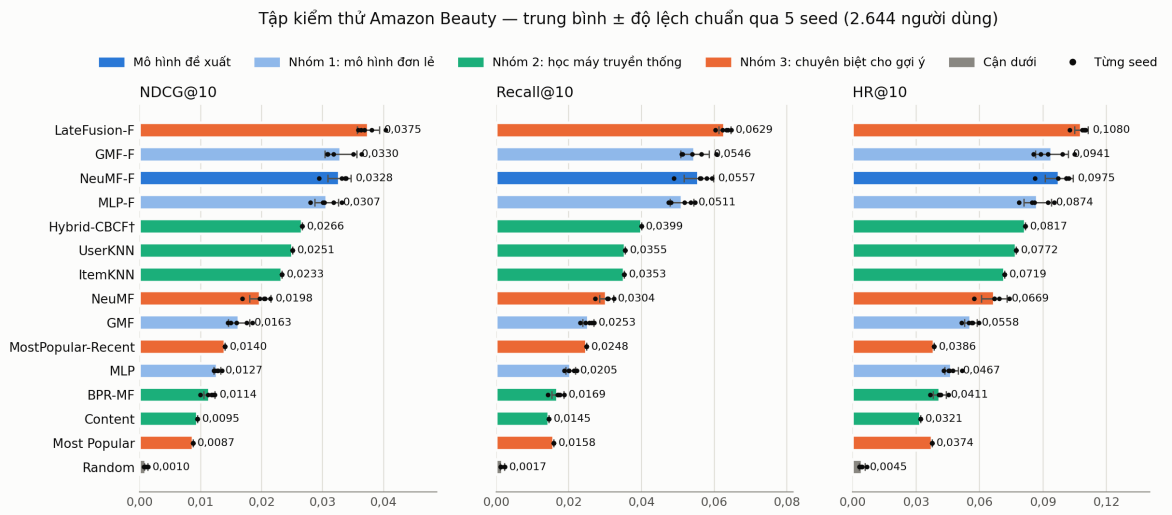
Phần này kiểm tra các kết luận của H&M trên một bộ dữ liệu khác. Theo kế hoạch kiểm chứng đăng ký trước, ba kết luận được đối chiếu: mô hình có đặc trưng so với mô hình chỉ dùng ID; NeuMF-F so với GMF-F, MLP-F và LateFusion-F; NeuMF so với BPR-MF. Cách chia dữ liệu, việc dùng lại cấu hình chọn trên H&M và hạn chế đi kèm đã được trình bày ở mục 3.2.6. Tập kiểm thử gồm 2.644 khách hàng (Bảng 3.6).

4.5.1 Kết quả trên tập kiểm thử Amazon Beauty

Bảng 4.11: Kết quả trên tập kiểm thử Amazon Beauty theo ba nhóm mô hình đối chứng

Mô hình	NDCG@10	Recall@10	HR@10	Precision@10	NDCG@5	NDCG@20
Mô hình đề xuất						
NeuMF-F	0,03277 ± 0,00189	0,05568 ± 0,00403	0,09750 ± 0,00657	0,01092 ± 0,00077	0,02450 ± 0,00148	0,04144 ± 0,00208
Nhóm 1: mô hình đơn lẻ						
GMF-F	0,03298 ± 0,00259	0,05465 ± 0,00397	0,09410 ± 0,00780	0,01042 ± 0,00088	0,02567 ± 0,00256	0,04159 ± 0,00195
MLP-F	0,03065 ± 0,00193	0,05107 ± 0,00327	0,08737 ± 0,00656	0,00998 ± 0,00092	0,02330 ± 0,00151	0,03764 ± 0,00184
GMF	0,01627 ± 0,00173	0,02533 ± 0,00154	0,05582 ± 0,00303	0,00640 ± 0,00036	0,01287 ± 0,00180	0,02090 ± 0,00166
MLP	0,01271 ± 0,00054	0,02045 ± 0,00132	0,04667 ± 0,00324	0,00513 ± 0,00037	0,00978 ± 0,00080	0,01694 ± 0,00062
Nhóm 2: học máy truyền thống						
Hybrid-CBCF†	0,02664 ± 0,00000	0,03992 ± 0,00000	0,08169 ± 0,00000	0,00998 ± 0,00000	0,02137 ± 0,00000	0,03212 ± 0,00000
UserKNN	0,02506 ± 0,00000	0,03553 ± 0,00000	0,07716 ± 0,00000	0,00930 ± 0,00000	0,02059 ± 0,00000	0,03096 ± 0,00000
ItemKNN	0,02333 ± 0,00000	0,03526 ± 0,00000	0,07186 ± 0,00000	0,00870 ± 0,00000	0,01895 ± 0,00000	0,02789 ± 0,00000
BPR-MF	0,01144 ± 0,00091	0,01691 ± 0,00164	0,04115 ± 0,00309	0,00498 ± 0,00035	0,00883 ± 0,00077	0,01476 ± 0,00082
Content	0,00945 ± 0,00000	0,01448 ± 0,00000	0,03215 ± 0,00000	0,00356 ± 0,00000	0,00737 ± 0,00000	0,01264 ± 0,00000
Nhóm 3: chuyên biệt cho gợi ý						
LateFusion-F	**0,03747** ± 0,00180	**0,06286** ± 0,00167	**0,10802** ± 0,00314	**0,01222** ± 0,00045	**0,02879** ± 0,00222	**0,04571** ± 0,00142
NeuMF	0,01978 ± 0,00176	0,03035 ± 0,00187	0,06694 ± 0,00605	0,00762 ± 0,00090	0,01599 ± 0,00161	0,02542 ± 0,00207
MostPopular-Recent	0,01401 ± 0,00000	0,02483 ± 0,00000	0,03858 ± 0,00000	0,00416 ± 0,00000	0,00964 ± 0,00000	0,01854 ± 0,00000
Most Popular	0,00872 ± 0,00000	0,01576 ± 0,00000	0,03744 ± 0,00000	0,00390 ± 0,00000	0,00619 ± 0,00000	0,00998 ± 0,00000
Cận dưới						
Random	0,00101 ± 0,00028	0,00168 ± 0,00059	0,00446 ± 0,00143	0,00045 ± 0,00014	0,00066 ± 0,00031	0,00153 ± 0,00031

Trung bình ± độ lệch chuẩn qua 5 seed; xếp hạng trên toàn bộ tập ứng viên của 2.644 người dùng. In đậm: trung bình cao nhất mỗi cột. Mô hình tất định (Most Popular, MostPopular-Recent, Content, ItemKNN, UserKNN, Hybrid-CBCF) cho cùng kết quả ở mọi seed. †Mô hình lai truyền thống bổ sung sau đánh giá cuối theo góp ý của giảng viên hướng dẫn: chấm một lần trên cùng tập kiểm thử, không thuộc họ 10 so sánh đăng ký trước. Không tinh chỉnh trên bộ này: cấu hình chọn trên tập xác thực của mẫu phát triển H&M, chỉ số epoch của mạng nơ-ron được chọn trên tập xác thực của chính bộ này.



Hình 4.6: NDCG@10, Recall@10 và HR@10 trên tập kiểm thử Amazon Beauty

Bảng 4.11 và Hình 4.6 trình bày kết quả trên tập kiểm thử Amazon. LateFusion-F đạt NDCG@10 cao nhất (0,03747); NeuMF-F (0,03277) xếp thứ ba trong 14 mô hình, sau cả GMF-F. Như trên H&M, bốn mô hình có đặc trưng đứng đầu; trong các mô hình đăng ký trước, tiếp theo là UserKNN và ItemKNN. Khác H&M, BPR-MF chỉ đạt 0,01144, thấp hơn ItemKNN, UserKNN và cả MostPopular-Recent; nguyên nhân được bàn ở mục 4.5.2.

Theo Bảng 4.12 và Bảng 4.13, LateFusion-F cao nhất ở mọi K và với cả bốn độ đo. NeuMF-F và GMF-F bám sát nhau và đổi chỗ tùy độ đo: GMF-F cao hơn một chút ở NDCG@K, còn NeuMF-F cao hơn một chút ở Recall@K, HR@K và Precision@K từ $K = 10$ trở lên.

Hybrid-CBCF, dùng nguyên cách kết hợp và trọng số chọn trên H&M, xếp thứ năm trong 15 mô hình, tức cũng đứng ngay sau bốn mô hình có đặc trưng. NeuMF-F so với Hybrid-CBCF chênh +23,0% (NeuMF-F tốt hơn có ý nghĩa), giống H&M. Khác H&M, trên Amazon Hybrid-CBCF tốt hơn UserKNN có ý nghĩa, với chênh lệch +6,3% (Bảng 4.14). Một khác biệt có thể góp phần: NDCG@10 của Content đứng riêng chỉ bằng khoảng một phần sáu của UserKNN trên H&M, nhưng hơn một phần ba trên Amazon, nên thành phần nội dung mang thêm nhiều thông tin hơn.

4.5.2 Đối chiếu kết luận giữa H&M và Amazon Beauty

Bảng 4.15 là kiểm định họ 10 so sánh trên Amazon, cùng tiêu chí như H&M. Bảng 4.16 đặt kết luận của từng so sánh trên hai bộ dữ liệu cạnh nhau, không gộp số của hai bộ.

Kết luận thứ nhất, về đặc trưng so với chỉ dùng ID, còn đúng trên Amazon:

Bảng 4.12: NDCG@K và Recall@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty

	NDCG@K				Recall@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0288**	**0,0375**	**0,0425**	**0,0457**	**0,0378**	**0,0629**	**0,0794**	**0,0904**
GMF-F	0,0257	0,0330	0,0377	0,0416	0,0333	0,0546	0,0700	0,0840
NeuMF-F	0,0245	0,0328	0,0375	0,0414	0,0323	0,0557	0,0715	0,0856
MLP-F	0,0233	0,0307	0,0347	0,0376	0,0302	0,0511	0,0646	0,0749
Hybrid-CBCF†	0,0214	0,0266	0,0296	0,0321	0,0247	0,0399	0,0498	0,0586
UserKNN	0,0206	0,0251	0,0284	0,0310	0,0235	0,0355	0,0470	0,0557
ItemKNN	0,0189	0,0233	0,0253	0,0279	0,0220	0,0353	0,0418	0,0510
NeuMF	0,0160	0,0198	0,0228	0,0254	0,0195	0,0304	0,0399	0,0491
GMF	0,0129	0,0163	0,0190	0,0209	0,0156	0,0253	0,0341	0,0407
MostPopular-Recent	0,0096	0,0140	0,0171	0,0185	0,0122	0,0248	0,0351	0,0399
MLP	0,0098	0,0127	0,0148	0,0169	0,0126	0,0205	0,0271	0,0345
BPR-MF	0,0088	0,0114	0,0132	0,0148	0,0094	0,0169	0,0225	0,0278
Content	0,0074	0,0095	0,0115	0,0126	0,0087	0,0145	0,0213	0,0255
Most Popular	0,0062	0,0087	0,0095	0,0100	0,0084	0,0158	0,0186	0,0200
Random	0,0007	0,0010	0,0013	0,0015	0,0007	0,0017	0,0025	0,0035

Trung bình qua 5 seed, tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối, không chấm lại tập kiểm thử; cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột.
†Mô hình lai truyền thống bổ sung sau đánh giá cuối (hạng đã lưu ở lần chấm bổ sung).

Bảng 4.13: HR@K và Precision@K với K = 5, 10, 15, 20 trên tập kiểm thử Amazon Beauty

	HR@K				Precision@K			
Mô hình	@5	@10	@15	@20	@5	@10	@15	@20
LateFusion-F	**0,0669**	**0,1080**	**0,1358**	**0,1546**	**0,0144**	**0,0122**	**0,0106**	**0,0092**
GMF-F	0,0591	0,0941	0,1200	0,1417	0,0126	0,0104	0,0092	0,0083
NeuMF-F	0,0589	0,0975	0,1224	0,1451	0,0124	0,0109	0,0094	0,0086
MLP-F	0,0524	0,0874	0,1099	0,1275	0,0113	0,0100	0,0085	0,0075
Hybrid-CBCF†	0,0548	0,0817	0,0991	0,1161	0,0123	0,0100	0,0081	0,0072
UserKNN	0,0511	0,0772	0,0957	0,1120	0,0114	0,0093	0,0078	0,0069
ItemKNN	0,0492	0,0719	0,0840	0,0983	0,0111	0,0087	0,0069	0,0062
NeuMF	0,0430	0,0669	0,0859	0,1011	0,0093	0,0076	0,0067	0,0061
GMF	0,0356	0,0558	0,0718	0,0846	0,0077	0,0064	0,0056	0,0051
MostPopular-Recent	0,0185	0,0386	0,0537	0,0639	0,0039	0,0042	0,0041	0,0038
MLP	0,0275	0,0467	0,0606	0,0750	0,0058	0,0051	0,0046	0,0043
BPR-MF	0,0244	0,0411	0,0526	0,0635	0,0055	0,0050	0,0045	0,0041
Content	0,0200	0,0321	0,0446	0,0514	0,0042	0,0036	0,0034	0,0030
Most Popular	0,0189	0,0374	0,0446	0,0492	0,0039	0,0039	0,0031	0,0026
Random	0,0020	0,0045	0,0064	0,0084	0,0004	0,0005	0,0004	0,0004

Trung bình qua 5 seed, tính lại từ hạng của từng sản phẩm đúng đã lưu ở lần đánh giá cuối, không chấm lại tập kiểm thử; cột @5, @10, @20 trùng với số của lần đánh giá đó. In đậm: cao nhất mỗi cột.
†Mô hình lai truyền thống bổ sung sau đánh giá cuối (hạng đã lưu ở lần chấm bổ sung).

Bảng 4.14: Kiểm định các so sánh bổ sung với Hybrid-CBCF trên Amazon Beauty (NDCG@10)

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
B1	NeuMF-F	Hybrid-CBCF	0,03277	0,02664	+23,0%	[+0,00138; +0,01083]	< 0,001	A tốt hơn
B2	Hybrid-CBCF	UserKNN	0,02664	0,02506	+6,3%	[+0,00026; +0,00292]	0,009	A tốt hơn

Mỗi người dùng lấy trung bình qua 5 seed; kiểm định Wilcoxon theo người dùng, khoảng tin cậy bootstrap 95%, hiệu chỉnh Holm trong họ bổ sung. —: không khác biệt có ý nghĩa. Tiêu chí "tốt hơn" như họ 10 so sánh đăng ký trước: p Holm $< 0{,}05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$. Họ bổ sung được đăng ký sau đánh giá cuối và không làm thay đổi họ 10 so sánh.

Bảng 4.15: Kiểm định họ 10 so sánh đã đăng ký trước trên Amazon Beauty (NDCG@10)

#	A	B	NDCG@10 A	NDCG@10 B	(A−B)/B	CI 95% của A−B	p Holm	Kết luận
1	NeuMF-F	NeuMF	0,03277	0,01978	+65,7%	[+0,00936; +0,01681]	< 0,001	A tốt hơn
2	NeuMF-F	GMF-F	0,03277	0,03298	−0,6%	[−0,00228; +0,00186]	0,534	—
3	NeuMF-F	MLP-F	0,03277	0,03065	+6,9%	[−0,00044; +0,00457]	0,050	—
4	NeuMF-F	LateFusion-F	0,03277	0,03747	−12,5%	[−0,00668; −0,00279]	< 0,001	B tốt hơn
5	NeuMF-F	BPR-MF	0,03277	0,01144	+186,5%	[+0,01756; +0,02528]	< 0,001	A tốt hơn
6	NeuMF-F	ItemKNN	0,03277	0,02333	+40,5%	[+0,00477; +0,01417]	< 0,001	A tốt hơn
7	NeuMF-F	UserKNN	0,03277	0,02506	+30,8%	[+0,00313; +0,01232]	< 0,001	A tốt hơn
8	NeuMF-F	MostPopular-Recent	0,03277	0,01401	+134,0%	[+0,01553; +0,02201]	< 0,001	A tốt hơn
9	NeuMF-F	Content	0,03277	0,00945	+246,7%	[+0,01902; +0,02766]	< 0,001	A tốt hơn
10	NeuMF	BPR-MF	0,01978	0,01144	+72,9%	[+0,00630; +0,01038]	< 0,001	A tốt hơn

Mỗi người dùng lấy trung bình qua 5 seed; kiểm định Wilcoxon theo người dùng, khoảng tin cậy bootstrap 95%, hiệu chỉnh Holm. —: không khác biệt có ý nghĩa. "A tốt hơn" (hoặc "B tốt hơn") chỉ khi đồng thời p Holm $< 0{,}05$, CI không chứa 0 và chênh lệch tương đối $\geq 5\%$.

NeuMF-F hơn NeuMF chỉ dùng ID +65,7% và tốt hơn có ý nghĩa cả năm mô hình đối chứng trong họ so sánh. Đây là kết luận vững nhất của đề tài, vì nó giữ nguyên khi đổi lĩnh vực (mỹ phẩm thay vì thời trang), loại tương tác (đánh giá thay vì lượt mua) và bộ đặc trưng (không có thông tin khách hàng), dù không tinh chỉnh lại.

Kết luận thứ hai, về NeuMF-F so với từng nhánh và với hợp nhất muộn, chỉ đúng một phần. NeuMF-F vẫn không khác biệt có ý nghĩa với nhánh GMF-F. Lợi thế so với MLP-F trên H&M không còn trên Amazon: giá trị p đã hiệu chỉnh xấp xỉ ngưỡng 0,05 (0,050) nhưng khoảng tin cậy chứa 0, nên theo tiêu chí là không khác biệt có ý nghĩa. Ngược với H&M, hợp nhất muộn LateFusion-F tốt hơn NeuMF-F có ý nghĩa (NeuMF-F thấp hơn $-12{,}5\%$). NeuMF-F vẫn là mô hình đề xuất như đã đăng ký, và kết quả này được báo cáo đúng như vậy. Một nguyên nhân có thể, chưa được kiểm chứng, là hai nhánh GMF-F và MLP-F có độ phủ top-10 rất khác nhau trên Amazon (32,1% so với 5,4%). Hai nhánh vì vậy gợi ý những tập sản phẩm khác nhau, và trộn điểm của hai mô hình huấn luyện riêng tận dụng được sự khác nhau đó.

Kết luận thứ ba, về NeuMF chỉ dùng ID so với BPR-MF, không đối chiếu được. Trên Amazon, NeuMF hơn BPR-MF +72,9%, trong khi trên H&M hai mô hình không

Bảng 4.16: Kết luận của họ 10 so sánh đã đăng ký trên H&M (mẫu kiểm định) và trên Amazon Beauty (NDCG@10; chênh lệch $= (A - B)/B$)

#	So sánh (A so với B)	H&M		Amazon Beauty	
		Chênh	Kết luận	Chênh	Kết luận
1	NeuMF-F so với NeuMF	+43,8%	A tốt hơn	+65,7%	A tốt hơn
2	NeuMF-F so với GMF-F	+2,6%	không khác biệt có ý nghĩa	−0,6%	không khác biệt có ý nghĩa
3	NeuMF-F so với MLP-F	+15,0%	A tốt hơn	+6,9%	không khác biệt có ý nghĩa
4	NeuMF-F so với LateFusion-F	−2,2%	không khác biệt có ý nghĩa	−12,5%	B tốt hơn
5	NeuMF-F so với BPR-MF	+50,4%	A tốt hơn	+186,5%	A tốt hơn *
6	NeuMF-F so với ItemKNN	+39,9%	A tốt hơn	+40,5%	A tốt hơn
7	NeuMF-F so với UserKNN	+28,5%	A tốt hơn	+30,8%	A tốt hơn
8	NeuMF-F so với MostPopular-Recent	+45,0%	A tốt hơn	+134,0%	A tốt hơn
9	NeuMF-F so với Content	+691,5%	A tốt hơn	+246,7%	A tốt hơn
10	NeuMF so với BPR-MF	+4,6%	không khác biệt có ý nghĩa	+72,9%	A tốt hơn *

"A tốt hơn" (hoặc "B tốt hơn") chỉ khi đồng thời $p_{Holm} < 0{,}05$, khoảng tin cậy 95% không chứa 0 và chênh lệch không dưới 5%. *Trên Amazon, BPR-MF dùng cấu hình chọn trên H&M và kém hơn cả ItemKNN, UserKNN, MostPopular-Recent; hai so sánh có BPR-MF chỉ nên đọc kèm cảnh báo này.

khác biệt có ý nghĩa. Tuy nhiên BPR-MF trên Amazon dùng cấu hình chọn trên H&M và kém hơn cả ItemKNN lẫn MostPopular-Recent, nên khoảng cách này nhiều khả năng phản ánh cấu hình không hợp với dữ liệu hơn là ưu thế của NeuMF. Vì lý do tương tự, so sánh NeuMF-F với BPR-MF trên Amazon không được dùng làm thước đo lợi ích của NeuMF-F.

4.5.3 Phân tích bóc tách và độ phủ trên Amazon Beauty

Bảng 4.17: Phân tích bóc tách NeuMF-F trên tập kiểm thử Amazon Beauty

Biến thể	NDCG@10	Thay đổi	CI 95% của hiệu
NeuMF-F (đầy đủ)	0,03378	—	—
Bỏ vector văn bản	0,03047	−9,8%	[−0,00701; +0,00051]
Bỏ đặc trưng thời gian	0,02310	−31,6%	[−0,01569; −0,00561]
Bỏ thông tin khách hàng	0,03424	+1,3%	[−0,00271; +0,00369]
Bỏ thuộc tính sản phẩm	0,02892	−14,4%	[−0,00844; −0,00133]

Seed 42; cùng siêu tham số, mỗi biến thể tắt một thành phần. Thay đổi: (biến thể − đầy đủ)/đầy đủ. CI: khoảng tin cậy bootstrap theo người dùng của hiệu (biến thể − đầy đủ). Chỉ mô tả, không kiểm định. Biến thể trùng NeuMF-F, ví dụ không bỏ ID ngẫu nhiên khi cấu hình chọn đã có xác suất bỏ ID bằng 0, không được chạy. Amazon không có thuộc tính khách: "bỏ thông tin khách hàng" là bỏ đặc trưng thời gian của khách.

Bảng 4.17 lặp lại phân tích bóc tách NeuMF-F trên Amazon (seed 42). Như trên H&M, bỏ đặc trưng thời gian làm NDCG@10 giảm nhiều nhất (−31,6%). Khác H&M, thuộc tính sản phẩm (thương hiệu, danh mục, nhóm giá) có đóng góp rõ (−14,4%, khoảng tin cậy không chứa 0). Bỏ thông tin khách hàng, trên Amazon chỉ là hai đặc trưng thời gian của khách, không làm thay đổi có ý nghĩa; bỏ vector văn bản cũng vậy. Về độ phủ top-10, Most Popular và MostPopular-Recent vẫn thấp nhất.

4.6 Lịch sử phát triển: giai đoạn chỉ dùng mã ID và bản đầu của kế hoạch đánh giá

Trước quy trình đánh giá ở Chương 3, đề tài đã thực nghiệm trong một giai đoạn phát triển ban đầu trên mẫu phát triển. Giai đoạn này chỉ dùng mã khách hàng và mã sản phẩm (lọc cộng tác thuần), coi mỗi `article_id` là một sản phẩm, và đánh giá trên tập kiểm thử của chính mẫu phát triển. Bảy mô hình được so sánh: Random, Most Popular, BPR-MF, GMF, MLP và hai biến thể NeuMF, khởi tạo ngẫu nhiên (NeuMF-Scratch) và khởi tạo từ GMF, MLP đã huấn luyện theo chiến lược tiền huấn luyện của NCF (NeuMF-Pretrained). Trung bình 3 seed, BPR-MF có NDCG@10 cao nhất

(0,01007), cao hơn cả NeuMF-Pretrained (0,00957) và NeuMF-Scratch (0,00910), và không so sánh nào trong họ 8 so sánh đăng ký trước đạt tiêu chí "tốt hơn". NeuMF chỉ dùng ID không vượt MF đã tinh chỉnh, không vượt Most Popular và không khác biệt có ý nghĩa với các nhánh GMF, MLP của nó; tiền huấn luyện không mang lại lợi ích đo được. Gần như toàn bộ độ chính xác đến từ nhóm 10% sản phẩm được mua nhiều nhất. Khi đánh giá bằng cách xếp mỗi sản phẩm đúng cùng 99 sản phẩm âm lấy mẫu, mọi độ đo bị thổi phồng nhiều lần và Most Popular lên đứng đầu, minh họa cho khuyến nghị chỉ dùng cách xếp hạng toàn bộ (mục 2.5).

Giai đoạn này để lại ba bài học, là cơ sở trực tiếp của quy trình ở Chương 3. Thứ nhất, với dữ liệu thưa như H&M, chỉ tăng độ phức tạp của mô hình trên cùng thông tin ID không mang lại lợi ích; cần bổ sung thông tin chứ không chỉ bổ sung tham số. Thứ hai, lọc k-core trên toàn bộ mẫu đã dùng cả thông tin của giai đoạn kiểm thử. Thứ ba, tập kiểm thử của mẫu phát triển đã được xem nhiều lần, và một số quyết định, như bổ sung bước huấn luyện lại hay thêm hợp nhất muộn và mô hình láng giềng, được đưa ra sau khi đã xem kết quả. Số liệu của giai đoạn này vì vậy không còn là ước lượng không thiên lệch.

Kế hoạch đánh giá đầu tiên, đăng ký ngày 03/10/2026, dùng cùng các mô hình, lưới tinh chỉnh, độ đo và họ 10 so sánh như bản cuối. Kế hoạch này khác bản cuối ở ba điểm. Thứ nhất, mỗi `article_id` (từng màu) là một sản phẩm. Thứ hai, tập ứng viên gồm cả sản phẩm chưa từng bán trước mốc dự đoán, với giả định doanh nghiệp biết trước danh mục sắp bán. Thứ ba, mẫu kiểm định là khối 1 (mục 3.2.2). Trên khối 1, NDCG@10 trên nhóm sản phẩm đúng mới của mọi mô hình đều dưới 0,002, tức khả năng gợi ý sản phẩm mới hầu như không đo được ở quy mô này. Sau lần đánh giá đó, theo góp ý của giảng viên hướng dẫn, kế hoạch được sửa thành bản cuối (mục 3.6). Ở bản cuối, một sản phẩm là một mẫu thiết kế, sản phẩm chưa có người mua bị bỏ khỏi tập ứng viên, và mọi mô hình đọc cùng một tệp dữ liệu đã lọc. Vì các thay đổi này được quyết định sau khi đã xem kết quả trên khối 1, khối 1 không còn dùng để kết luận. Các mô hình được tinh chỉnh lại trên mẫu phát triển, và đánh giá cuối dùng một mẫu khách hàng chưa từng được dùng là khối 2, tức mẫu kiểm định. Kết quả của giai đoạn phát triển ban đầu và của khối 1 vì vậy chỉ được báo cáo như lịch sử phát triển, không đặt cạnh kết quả trên mẫu kiểm định.

4.7 Phạm vi của kết luận

Các kết luận của chương có giá trị cho những khách hàng của H&M có lịch sử mua đủ dày để qua bước lọc 10-core. Chúng gắn với khung thời gian từ tháng 7 đến tháng 9 năm 2020 và với mức mẫu thiết kế, không phải mức màu. Chúng không nói về khả năng gợi ý sản phẩm mới hay khách hàng mới, vì hai nhóm này nằm ngoài tập được đánh giá (mục 3.2.4). Phân tích bóc tách chạy một seed nên chỉ mang tính mô tả, và kiểm chứng trên Amazon Beauty dùng lại cấu hình chọn trên H&M. Các hạn chế này được tổng hợp ở mục 5.2.

4.8 Thảo luận

Câu hỏi đầu tiên là mô hình lai có đặc trưng có vượt các mô hình đối chứng hay không. Theo tiêu chí đã đăng ký, NeuMF-F vượt cả năm mô hình đối chứng trong họ so sánh trên H&M, với chênh lệch nhỏ nhất so với UserKNN và lớn nhất so với Content. Trên Amazon Beauty, NeuMF-F cũng vượt cả năm mô hình đối chứng. So sánh này có ý nghĩa vì mọi mô hình được tinh chỉnh với cùng ngân sách, tập kiểm thử không được dùng để chọn mô hình, và kết luận lấy trên những khách hàng chưa từng được dùng để ra quyết định.

Câu hỏi thứ hai là đặc trưng đóng góp gì. So sánh NeuMF-F với NeuMF chỉ dùng ID đo trực tiếp giá trị của đặc trưng trong cùng kiến trúc hai nhánh. Trong họ so sánh, đây là chênh lệch lớn nhất giữa hai mô hình học sâu, và nó lặp lại trên Amazon. Ngược lại, khi chỉ dùng ID, mô hình lai NeuMF không khác biệt có ý nghĩa với BPR-MF trên H&M, cùng kết luận với giai đoạn phát triển (mục 4.6). Phân tích bóc tách cho thấy phần lớn đóng góp đến từ đặc trưng thời gian, tiếp theo là thông tin khách hàng; thuộc tính và mô tả văn bản của sản phẩm chỉ đóng góp nhỏ, chưa tách được khỏi dao động của một seed. Trên Amazon, đặc trưng thời gian cũng đóng góp nhiều nhất. Kết quả này gợi ý rằng xu hướng bán gần đây của sản phẩm và nhịp mua của khách mang nhiều thông tin về lần mua tiếp theo hơn mô tả tĩnh của sản phẩm.

Câu hỏi thứ ba là kết hợp tuyến tính và phi tuyến có mang lại lợi ích hay không. Trên H&M, khi đã có đặc trưng, hợp nhất sớm hai nhánh vượt nhánh phi tuyến MLP-F nhưng không vượt nhánh tuyến tính GMF-F đứng riêng, và không tốt hơn hợp nhất muộn. LateFusion-F có NDCG@10 trung bình cao nhất nhưng không khác biệt có ý nghĩa với NeuMF-F. Trên Amazon, lợi thế so với MLP-F không còn có ý nghĩa, còn hợp nhất muộn tốt hơn hợp nhất sớm có ý nghĩa. Lợi ích của mô hình lai vì vậy nằm chủ yếu ở phần đặc trưng chứ không ở cách ghép hai nhánh, và trong hai cách ghép,

hợp nhất muộn không kém hơn ở dữ liệu nào trong hai bộ đã thử.

Câu hỏi thứ tư, từ phân tích bổ sung, là mô hình lai học sâu có hơn mô hình lai truyền thống hay không. NeuMF-F tốt hơn có ý nghĩa Hybrid-CBCF trên cả hai bộ dữ liệu, trong khi Hybrid-CBCF chỉ hơn thành phần mạnh nhất của nó một khoảng nhỏ, không có ý nghĩa trên H&M và có ý nghĩa trên Amazon. Như vậy ghép điểm của các kỹ thuật truyền thống giúp được ít, còn bổ sung đặc trưng vào mô hình lai học sâu giúp được nhiều hơn hẳn. Phân tích này cho biết thêm vị trí của mô hình đề xuất giữa ba nhóm mô hình đối chứng, không thay đổi các kết luận đã đăng ký.

Tóm lại, phần giả thuyết "mô hình lai có đặc trưng tốt hơn các mô hình đối chứng được tinh chỉnh đầy đủ và tốt hơn NeuMF chỉ dùng ID" được ủng hộ trên cả hai bộ dữ liệu. Phần "hợp nhất sớm hai nhánh tốt hơn từng nhánh và tốt hơn hợp nhất muộn" chỉ được ủng hộ so với nhánh MLP-F trên H&M, và bị bác bỏ ở so sánh với hợp nhất muộn trên Amazon.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đề tài đã xây dựng NeuMF-F, một mô hình gợi ý lai giữ cấu trúc hai nhánh nhân tử hóa ma trận và mạng nơ-ron sâu của NeuMF, đồng thời bổ sung đặc trưng sản phẩm, khách hàng và thời gian vào biểu diễn của cả hai nhánh. Mô hình được đặt trong một quy trình dữ liệu không dùng thông tin tương lai. Nó được so sánh với các mô hình đối chứng thuộc ba nhóm, mô hình đơn lẻ, học máy truyền thống và chuyên biệt cho gợi ý, tất cả được tinh chỉnh với cùng ngân sách. Kết luận được rút ra một lần trên mẫu khách hàng độc lập của H&M theo kế hoạch đăng ký trước, có kiểm định thống kê, rồi được kiểm chứng trên bộ dữ liệu Amazon Beauty.

Kết quả chính là việc bổ sung đặc trưng mang lại cải thiện rõ và ổn định. Trên H&M, NeuMF-F tốt hơn có ý nghĩa NeuMF chỉ dùng ID, nhánh MLP-F và các mô hình đối chứng trong họ so sánh; kết luận về đặc trưng lặp lại trên Amazon Beauty dù không tinh chỉnh lại. Trong các nhóm đặc trưng, đặc trưng thời gian đóng góp nhiều nhất. Ngược lại, cách hợp nhất hai nhánh không tạo ra khác biệt đáng kể: NeuMF-F không khác biệt có ý nghĩa với nhánh GMF-F đứng riêng trên cả hai bộ dữ liệu, không khác biệt với hợp nhất muộn LateFusion-F trên H&M, và kém LateFusion-F trên Amazon. Phân tích bổ sung cho thấy NeuMF-F cũng vượt một mô hình lai truyền thống kết hợp lọc nội dung và lọc cộng tác.

Về phương pháp, kết quả cho thấy một mô hình lai học sâu chỉ dùng mã ID khó vượt nhân tử hóa ma trận được tinh chỉnh kỹ trên dữ liệu thưa, và lợi ích chỉ xuất hiện khi mô hình được cung cấp thêm thông tin. Quy trình đánh giá của đề tài gồm chia dữ liệu theo thời gian, tinh chỉnh với cùng ngân sách, mẫu kiểm định độc lập và đăng ký trước. Quy trình này cho phép tách riêng đóng góp của đặc trưng và của cách hợp nhất, và có thể dùng lại cho các nghiên cứu hệ gợi ý khác. Hệ thống demo đi kèm minh họa gợi ý của các mô hình trên từng khách hàng, và gợi ý sản phẩm phổ biến cho khách hàng mới.

5.2 Hạn chế của đề tài

Về dữ liệu, đề tài chỉ dùng hai mẫu, mỗi mẫu khoảng 1,5% khách hàng của H&M, do giới hạn phần cứng. Ngưỡng lọc $k = 10$ làm dữ liệu sau lọc thiên về khách

mua nhiều. Thuộc tính khách hàng không có mốc thời gian nên được coi là ít thay đổi. Phép lọc k-core dùng mọi cặp trước mốc kiểm thử, nên tập khách và sản phẩm ở giai đoạn xác thực phụ thuộc một phần vào dữ liệu tháng 7/2020. Điều này chỉ ảnh hưởng việc chọn cấu hình, không ảnh hưởng tập kiểm thử của mẫu kiểm định.

Về đánh giá, sản phẩm chưa có người mua trước mốc dự đoán và khách hàng mới nằm ngoài tập được đánh giá, nên kết quả không nói về khả năng xử lý khởi đầu lạnh. Kết luận được lấy trên một mẫu kiểm định và một khung thời gian. Kiểm chứng trên Amazon Beauty dùng lại cấu hình chọn trên H&M và không có mẫu khách hàng độc lập; mỗi đánh giá sản phẩm được coi là một lần mua, và nhóm giá là giá tại thời điểm thu thập dữ liệu. Tập kiểm thử của mẫu phát triển và của khối 1 đã được xem trước khi kế hoạch được chốt, nên hai lần đánh giá này chỉ được dùng như lịch sử phát triển (mục 4.6).

Về mô hình, mỗi mô hình có học chỉ được thử 6 cấu hình, và vài cấu hình được chọn nằm ở biên lưới, nên một số mô hình đối chứng có thể còn tốt hơn nếu mở rộng lưới. Mô tả văn bản chỉ được biểu diễn bằng TF-IDF và SVD; ảnh sản phẩm, giá sản phẩm trên H&M và chuỗi hành vi chưa được dùng; phân tích bóc tách chỉ chạy một seed. Mô hình lai truyền thống Hybrid-CBCF được thêm sau khi đã biết kết quả kiểm thử của 14 mô hình, nên kết quả của nó chỉ là phân tích bổ sung.

5.3 Hướng phát triển

Hướng phát triển trực tiếp nhất là khắc phục các hạn chế về đánh giá. Đưa lại sản phẩm chưa có người mua vào tập ứng viên, với giả định về danh mục được nêu rõ, sẽ cho phép đo riêng khả năng gợi ý sản phẩm mới. Nhóm khách hàng mới cần được đánh giá riêng, với danh sách phổ biến theo thời gian hoặc theo nhóm khách thay cho danh sách phổ biến chung. Thực nghiệm cũng cần được mở rộng sang mẫu lớn hơn, ngưỡng $k = 5$ và các khung thời gian khác, cùng với việc tinh chỉnh riêng trên Amazon để tách ảnh hưởng của cấu hình khỏi bản thân mô hình.

Về mô hình, kết quả trên Amazon cho thấy hợp nhất muộn có thể tốt hơn hợp nhất sớm. Một bước tiếp theo vì vậy là học trọng số trộn theo nhóm khách hoặc loại sản phẩm, chẳng hạn bằng cách học theo cặp đã dùng cho Hybrid-CBCF (Thuật toán 3.6). Đặc trưng có thể được làm giàu bằng mô hình ngôn ngữ cho mô tả sản phẩm và mạng tích chập cho ảnh, hoặc bằng cách hợp nhất nhiều góc nhìn bằng Transformer như chương 5 luận án của giảng viên hướng dẫn (mục 2.6.1). Các mô hình chuỗi, đồ thị và tự mã hóa biến phân ở mục 2.4 cũng cần được thử trên cùng quy trình đánh giá, với

mô hình đối chứng được tinh chỉnh cùng ngân sách. Khi triển khai trên danh mục lớn, kiến trúc hai tháp với tìm kiếm lân cận gần đúng có thể thay cho việc chấm điểm toàn bộ danh mục.

PHỤ LỤC A. NGUỒN TRÍCH DẪN VÀ VỊ TRÍ SỬ DỤNG

Bảng dưới liệt kê mọi nguồn được trích dẫn trong báo cáo, mục sử dụng và nội dung được dùng.

Mục	Nội dung sử dụng	Nguồn
Dữ liệu		
1.1.1, 3.2.1	Bộ dữ liệu H&M Personalized Fashion Recommendations	H&M Group [1]
1.2.2, 3.2.6	Bộ dữ liệu Amazon Beauty dùng để kiểm chứng	McAuley và cộng sự [4]
Hệ gợi ý, lọc cộng tác và hệ gợi ý lai		
2.1.1	Lọc dựa trên nội dung	Lops và cộng sự [5]
2.1.1	Lọc cộng tác chỉ cần ma trận tương tác	Su và Khoshgoftaar [6]
2.1.1	Bảy cách lai các kỹ thuật gợi ý	Burke [7]
2.1.1, 2.3.4, 2.6.1	Mô hình lai truyền thống kết hợp lọc nội dung và lọc cộng tác; hợp nhất sớm và hợp nhất muộn cho hệ gợi ý đa nguồn	Hồ Thị Linh [8]
2.1.2	Lọc cộng tác theo người dùng	Resnick và cộng sự [9]
2.1.2	Lọc cộng tác theo sản phẩm	Sarwar và cộng sự [10]
2.1.4	Khởi đầu lạnh	Schein và cộng sự [11]
Nhân tử hóa ma trận và lọc cộng tác bằng mạng nơ-ron		
1.1.2, 2.2.1	Nhân tử hóa ma trận	Koren và cộng sự [2]
2.2.3	Tối ưu thứ hạng theo cặp (BPR)	Rendle và cộng sự [12]
1.1.2, 2.3, 2.6.1	Hạn chế của tích vô hướng; khung NCF và mô hình NeuMF	He và cộng sự [3]
2.3.4	Hợp nhất sớm và hợp nhất muộn trong học đa phương thức	Atrey và cộng sự [13]
Mô hình lai dựa trên đặc trưng và các hướng nghiên cứu gần đây		
2.4.1	Factorization Machines	Rendle [14]
2.4.1	Wide & Deep, DeepFM	Cheng và cộng sự [15]; Guo và cộng sự [16]
2.4.1	Bỏ ngẫu nhiên biểu diễn sở thích khi huấn luyện (DropoutNet)	Volkovs và cộng sự [17]

Mục	Nội dung sử dụng	Nguồn
2.4.1	TF-IDF và phân tích ngữ nghĩa tiềm ẩn	Salton và Buckley [18]; Deerwester và cộng sự [19]
2.4.2	Gợi ý theo chuỗi hành vi: SASRec, BERT4Rec	Kang và McAuley [20]; Sun và cộng sự [21]
2.4.3	Học biểu diễn trên đồ thị: NGCF, Light-GCN	Wang và cộng sự [22]; He và cộng sự [23]
2.4.4	Tự mã hóa biến phân cho lọc cộng tác (Mult-VAE)	Liang và cộng sự [24]
2.6	Khảo sát mạng nơ-ron sâu cho lọc cộng tác	Li và cộng sự [28]
Đánh giá, kiểm định và cài đặt		
2.5	Độ đo NDCG	Järvelin và Kekäläinen [25]
2.5	Sai lệch khi đánh giá trên tập ứng viên lấy mẫu	Krichene và Rendle [26]
2.5.2	Thiên lệch về sản phẩm phổ biến; độ đo ngoài độ chính xác	Vargas và Castells [27]
3.2.4	Chia dữ liệu theo một mốc thời gian chung	Meng và cộng sự [31]
2.6, 3.6	Lỗi phương pháp khi đánh giá mô hình học sâu; tinh chỉnh mô hình đối chứng cùng ngân sách	Ferrari Dacrema và cộng sự [29]
2.6.1, 3.6	So sánh lại NeuMF với MF được tinh chỉnh kỹ	Rendle và cộng sự [30]
3.6	Kiểm định Wilcoxon, khoảng tin cậy bootstrap, hiệu chỉnh Holm	Wilcoxon [34]; Efron và Tibshirani [35]; Holm [36]
3.4.2	Thuật toán tối ưu Adam; thư viện PyTorch	Kingma và Ba [33]; Paszke và cộng sự [32]

TÀI LIỆU THAM KHẢO

H&M Group, *H&M Personalized Fashion Recommendations*, https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations, Cuộc thi trên Kaggle, 2022.

Y. Koren, R. Bell, và C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," *Computer*, vol. 42, no. 8, pp. 30–37, 2009. DOI: 10.1109/MC.2009.263

X. He, L. Liao, H. Zhang, L. Nie, X. Hu, và T.-S. Chua, "Neural Collaborative Filtering," in *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, Perth, Australia, 2017, pp. 173–182. DOI: 10.1145/3038912.3052569

J. McAuley, C. Targett, Q. Shi, và A. van den Hengel, "Image-Based Recommendations on Styles and Substitutes," in *Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '15)*, Santiago, Chile, 2015, pp. 43–52. DOI: 10.1145/2766462.2767755

P. Lops, M. de Gemmis, và G. Semeraro, "Content-based Recommender Systems: State of the Art and Trends," in *Recommender Systems Handbook*, F. Ricci, L. Rokach, B. Shapira, và P. B. Kantor, eds., Springer, 2011, pp. 73–105.

X. Su và T. M. Khoshgoftaar, "A Survey of Collaborative Filtering Techniques," *Advances in Artificial Intelligence*, vol. 2009, pp. 1–19, 2009. DOI: 10.1155/2009/421425

R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Modeling and User-Adapted Interaction*, vol. 12, no. 4, pp. 331–370, 2002.

Hồ Thị Linh, "Multi-Source Integration for Recommendation Systems," Doctoral dissertation, Ton Duc Thang University, Ho Chi Minh City, 2023.

P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, và J. Riedl, "GroupLens: An Open Architecture for Collaborative Filtering of Netnews," in *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work (CSCW)*, 1994, pp. 175–186. DOI: 10.1145/192844.192905

B. Sarwar, G. Karypis, J. Konstan, và J. Riedl, “Item-based Collaborative Filtering Recommendation Algorithms,” in *Proceedings of the 10th International Conference on World Wide Web (WWW)*, 2001, pp. 285–295. DOI: 10.1145/371920.372071

A. I. Schein, A. Popescul, L. H. Ungar, và D. M. Pennock, “Methods and Metrics for Cold-Start Recommendations,” in *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’02)*, 2002, pp. 253–260.

S. Rendle, C. Freudenthaler, Z. Gantner, và L. Schmidt-Thieme, “BPR: Bayesian Personalized Ranking from Implicit Feedback,” in *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI ’09)*, Montreal, QC, Canada, 2009, pp. 452–461.

P. K. Atrey, M. A. Hossain, A. El Saddik, và M. S. Kankanhalli, “Multimodal Fusion for Multimedia Analysis: A Survey,” *Multimedia Systems*, vol. 16, no. 6, pp. 345–379, 2010.

S. Rendle, “Factorization Machines,” in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2010, pp. 995–1000. DOI: 10.1109/ICDM.2010.127

H.-T. Cheng và cộng sự, “Wide & Deep Learning for Recommender Systems,” in *Proceedings of the 1st Workshop on Deep Learning for Recommender Systems (DLRS 2016)*, Boston, MA, USA, 2016, pp. 7–10. DOI: 10.1145/2988450.2988454

H. Guo, R. Tang, Y. Ye, Z. Li, và X. He, “DeepFM: A Factorization-Machine based Neural Network for CTR Prediction,” in *Proceedings of the 26th International Joint Conference on Artificial Intelligence (IJCAI 2017)*, Melbourne, Australia, 2017, pp. 1725–1731. DOI: 10.24963/ijcai.2017/239

M. Volkovs, G. Yu, và T. Poutanen, “DropoutNet: Addressing Cold Start in Recommender Systems,” in *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, 2017, pp. 4957–4966.

G. Salton và C. Buckley, “Term-weighting Approaches in Automatic Text Retrieval,” *Information Processing and Management*, vol. 24, no. 5, pp. 513–523, 1988.

S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, và R. Harshman, "Indexing by Latent Semantic Analysis," *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.

W.-C. Kang và J. McAuley, "Self-Attentive Sequential Recommendation," in *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2018, pp. 197–206. DOI: 10.1109/ICDM.2018.00035

F. Sun và cộng sự, "BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer," in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM '19)*, 2019, pp. 1441–1450. DOI: 10.1145/3357384.3357895

X. Wang, X. He, M. Wang, F. Feng, và T.-S. Chua, "Neural Graph Collaborative Filtering," in *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '19)*, 2019, pp. 165–174. DOI: 10.1145/3331184.3331267

X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, và M. Wang, "LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation," in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '20)*, 2020, pp. 639–648. DOI: 10.1145/3397271.3401063

D. Liang, R. G. Krishnan, M. D. Hoffman, và T. Jebara, "Variational Autoencoders for Collaborative Filtering," in *Proceedings of the 2018 World Wide Web Conference (WWW '18)*, 2018, pp. 689–698. DOI: 10.1145/3178876.3186150

K. Järvelin và J. Kekäläinen, "Cumulated gain-based evaluation of IR techniques," *ACM Transactions on Information Systems*, vol. 20, no. 4, pp. 422–446, 2002. DOI: 10.1145/582415.582418

W. Krichene và S. Rendle, "On Sampled Metrics for Item Recommendation," in *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*, 2020, pp. 1748–1757. DOI: 10.1145/3394486.3403226

S. Vargas và P. Castells, “Rank and Relevance in Novelty and Diversity Metrics for Recommender Systems,” in *Proceedings of the 5th ACM Conference on Recommender Systems (RecSys ’11)*, 2011, pp. 109–116. DOI: 10.1145/2043932.2043955

P. Li, S. A. Mohd Noah, và H. Mohd Sarim, “A Survey on Deep Neural Networks in Collaborative Filtering Recommendation Systems,” *arXiv preprint arXiv:2412.01378*, 2024.

M. Ferrari Dacrema, P. Cremonesi, và D. Jannach, “Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches,” in *Proceedings of the 13th ACM Conference on Recommender Systems (RecSys ’19)*, 2019, pp. 101–109. DOI: 10.1145/3298689.3347058

S. Rendle, W. Krichene, L. Zhang, và J. Anderson, “Neural Collaborative Filtering vs. Matrix Factorization Revisited,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys ’20)*, 2020, pp. 240–248. DOI: 10.1145/3383313.3412488

Z. Meng, R. McCreadie, C. Macdonald, và I. Ounis, “Exploring Data Splitting Strategies for the Evaluation of Recommendation Models,” in *Proceedings of the 14th ACM Conference on Recommender Systems (RecSys ’20)*, 2020. DOI: 10.1145/3383313.3418479

A. Paszke và cộng sự, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.

D. P. Kingma và J. Ba, “Adam: A Method for Stochastic Optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

B. Efron và R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

S. Holm, “A Simple Sequentially Rejective Multiple Test Procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.